

PROCESOS ESTOCÁSTICOS CON ÍNDICE DE DIFERENCIACIÓN FRACCIONARIO

TEMA: Instituciones Financieras y Otras

SUBTEMA: Modelos actuariales para la cuantificación y gestión de los riesgos de mercado, crédito y operativo

Quinto Congreso Argentino de Actuarios

Octavo Congreso Panamericano de Actuarios

“Los horizontes de la profesión”

Ciudad Autónoma de Buenos Aires, 18 al 26 de Octubre de 2006

Autores:

Act. Alberto Landro
Federico Alcalde Bessia
Lara Viviana Vazquez

SUMARIO

1. INTRODUCCIÓN A LOS PROCESOS ESTOCÁSTICOS

1.1 Proceso estocástico. Proceso autorregresivo. Definiciones

1.2 Teorema de descomposición de Wold

2. REPRESENTACIONES DE LOS PROCESOS ESTOCÁSTICOS

2.1 Representaciones del valor medio

2.1.1 Procesos representados por ARFIMA(p,d,q)

2.1.1.I Representaciones ARMA(p,q)

2.1.1.II Representaciones ARIMA(p,d,q)

2.1.1.III Procesos de memoria larga

2.1.3.IV Representación ARFIMA(p,d,q)

2.1.3.V Diferenciación fraccionaria

2.1.3.VI Determinación de la presencia de memoria larga

2.1.2. Otros procesos de Memoria Larga. Modelos GARMA

2.2 Representaciones de la varianza

2.2.1 Detección de comportamiento ARCH

2.2.2 Procesos representados por ARCH

2.2.3 Procesos representados por GARCH

2.2.4 Procesos representados por IGARCH

2.2.5 Procesos representados por FIGARCH

3. APLICACIÓN AL ÍNDICE DE LA BOLSA DE COMERCIO DE BUENOS AIRES

4. COMENTARIOS FINALES

BIBLIOGRAFÍA

1. Introducción a los procesos estocásticos

El presente trabajo constituye una introducción a los modelos de diferenciación fraccionaria para la estimación de la media y la varianza de una variable aleatoria y_t que forma parte de un proceso estocástico discreto en el dominio del tiempo. El objetivo de este trabajo es presentar el modelado de la media condicionada a través de los procesos autorregresivos de medias móviles con índice de integración fraccionario (ARFIMA¹) y el modelado de la varianza condicionada a través de los procesos generalizados autorregresivos heterocedásticos condicionados con índice de integración fraccionario (FIGARCH²).

Es nuestra intención describir el comportamiento teórico de los modelos a los que hacemos referencia y, al mismo tiempo, considerar su aplicación. Por ello, incluimos una aplicación en donde se testea la presencia de memoria larga en los rendimientos logarítmicos del índice de la Bolsa de Comercio de Buenos Aires.

1.1 Proceso estocástico. Proceso autorregresivo. Definiciones

Definimos como proceso estocástico a una sucesión de variables aleatorias en el tiempo de la forma $y(t; \omega)$, quedando este proceso en función del tiempo $t \in T$ y de cada una de sus posibles trayectorias $\omega \in \Omega^3$, pudiendo ser un proceso unidimensional o multidimensional. Estos procesos tienen dos tipos de definición: una fuerte o estricta y otra débil. Se dice que un proceso estocás-

¹ Siglas del inglés: “Autoregressive Fractionally Integrated Moving Averages”

² Sigla del inglés: “Fractionally Integrated Generalised Autoregressive Conditional Heteroskedasticity”

tico está definido en forma estricta cuando es posible definir la función de probabilidad conjunta para cualquier sucesión finita de sus variables aleatorias, es decir, se conocen todas las probabilidades asociadas a las infinitas o finitas trayectorias posibles del proceso. Por otro lado, la forma débil de definición está asociada al sistema de momentos del proceso. Particularmente, resultan importantes para una caracterización del proceso el valor esperado, la varianza y las autocovarianzas. Por ejemplo, un proceso queda definido en forma débil de orden dos cuando sólo se conocen la media y la varianza⁴.

Hay dos propiedades a tener en cuenta al momento de analizar los procesos estocásticos: la estacionariedad y la ergodicidad. Intuitivamente, puede decirse que un proceso es estacionario⁵ si su estructura temporal no depende del tiempo. El concepto de ergodicidad se refiere a la posibilidad de inferir los elementos más importantes del proceso a partir de la muestra finita que constituye una de sus realizaciones. Los procesos ergódicos son aquellos para los cuales sus momentos muestrales finitos, obtenidos a partir de una observación de una trayectoria particular del proceso, convergen a los momentos poblacionales del proceso.

³ A lo largo del trabajo escribiremos $y(t; \omega) = y(t)$ dejando de lado la especificación de las causas que produjeron cierta trayectoria a lo largo del tiempo. En este trabajo se utilizará indistintamente y_t por $y(t)$.

⁴ Si el proceso es normal queda estrictamente definido por los momentos de primer y segundo orden, y si no lo es, pero cada valor del proceso es generado a partir de la combinación lineal de sus realizaciones pasadas y de los valores pasados y actuales de otros procesos relacionados con él, entonces se puede asegurar que sus características más importantes están en los momentos de primer y segundo orden.

⁵ La palabra, sustantivo, estacionariedad deriva del verbo “estacionar” que significa asentarse o permanecer en un lugar.

1.2 Teorema de descomposición de Wold

Si un proceso estocástico unidimensional posee las características de ser débilmente estacionario de orden dos con valor esperado nulo y varianza σ_y^2 , entonces puede ser representado como la suma de una combinación lineal de shocks aleatorios y una combinación lineal de los valores pasados del proceso de interés. Lo expuesto constituye el teorema de descomposición de Wold.

A partir de este teorema surgen las diferentes representaciones del proceso: la representación MA y la representación AR.

La representación denominada en medias móviles (MA), tiene la forma: $y_t = \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \dots$ ó, también, $y_t = \Psi(B) \varepsilon_t$, donde $\Psi(B)$ es un operador MA de orden infinito. La representación denominada autorregresiva (AR) es: $y_t = -\pi_1 y_{t-1} - \pi_2 y_{t-2} - \dots + \varepsilon_t$, que puede expresarse a través del operador AR de orden infinito $\Pi(B)$ como $\Pi(B) y_t = \varepsilon_t$

2. Representaciones de los procesos estocásticos

A continuación se exponen distintos tipos de representación de un proceso estocástico con orden de integración fraccionario. Se comenzará por exponer particularmente la representación ARFIMA y, luego, se introducirá aquella que recibe el nombre de GARMA. En este primer apartado, se hablará de las representaciones del proceso que constituye la media condicionada. Posteriormente, dado que un proceso puede ser descripto por su media y por varianza, se expodrán las representaciones que tienen que ver con la varianza para

las cuales también es posible introducir un índice de diferenciación fraccionario. Allí comenzaremos con las representaciones ARCH y terminaremos con las FIGARCH.

De esta forma, desde los ARFIMA a los FIGARCH, pasamos de representaciones lineales a las no lineales. En el ámbito de la teoría de los modelos lineales, se parte de los siguientes supuestos: i) que la estructura del proceso es aditiva, ii) que la varianza de las variables que componen el proceso es constante y iii) que las variables aleatorias de la sucesión que genera el proceso estocástico están Normalmente distribuidas. La teoría de los modelos no lineales tiene que ver con el cumplimiento de del segundo supuesto de los modelos lineales: la homocedasticidad. Si encontramos que el modelo no es adecuado por observarse no-estacionariedad en la varianza, entraremos en ámbito de la teoría de los modelos no lineales.

2.1 Representaciones del valor medio

La observación de un proceso estocástico se realiza con el objetivo de poder realizar predicciones o descripciones de su comportamiento. En el ámbito de las series de tiempo, una representación autorregresiva o en medias móviles de un proceso determinado intenta modelar la media de este proceso observado. El problema con el que se enfrenta el observador es: dado el conjunto de realizaciones del proceso (llamado muestra), hállese una representación por combinación lineal de sus realizaciones y de las realizaciones de su parte aleatoria pura o residuo. El observador hará las hipótesis necesarias sobre la parte aleatoria pura, que constituye un proceso estocástico, y, además, la forma de la

combinación lineal. En la literatura clásica se hipotetiza que la parte aleatoria pura sigue una distribución Normal con media cero y varianza finita y constante, pudiendo suponerse otras distribuciones. La representación, entonces, tiene la siguiente estructura: $E[y_t | F_{t-1}] = \bar{\mu} + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p}$ ⁶

Es importante observar el comportamiento de las autocovarianzas y las autocorrelaciones dado que será a través de ellas, de su estimación, que se podrá definir cierta representación como más o menos adecuada (sin perder de vista los test referidos a este problema).

2.1.1 Procesos representados por ARFIMA(p,d,q)

2.1.1.1 Representaciones ARMA(p,q)

Si en el teorema de descomposición de Wold consideramos que sólo los primeros “q” shocks aleatorios y las primeras “p” realizaciones pasadas son la mejor combinación que influye en la determinación del proceso y_t , obtenemos la representación ARMA(p,q):

$$y_t = \bar{\mu} + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q}$$

En consecuencia, el comportamiento de la variable y_t no se ve afectado por las realizaciones de la misma en momentos del tiempo que resultan lejanos y esto se manifiesta en el decrecimiento exponencial de su función de autocorrelaciones. Básicamente, el decrecimiento exponencial implica que la depen-

⁶ En la literatura especializada la nomenclatura F_{t-1} se refiere a la información con la que se cuenta del proceso al momento “t-1”. Se la suele llamar filtración (traducción literal del inglés *filtration*) y la cual, se supone, compone una sigma álgebra.

dencia temporal es de corto plazo y, por lo tanto, el proceso que quiere describirse puede ser representado por un orden “p” de autorregresividad.

2.1.1.II Representaciones ARIMA(p,d,q)

El proceso a considerar puede no ser estacionario: su estructura temporal depende del tiempo. La forma más común de no estacionariedad en la media es la existencia de *tendencia determinística* en el proceso. Esto provoca que una parte del posible valor del proceso en un momento dado pueda ser predicha con total exactitud y dependa exclusivamente del tiempo transcurrido. La tendencia determinística dentro del proceso se manifiesta en la existencia de raíces de la ecuación característica de la componente AR iguales a la unidad. La función de autocorrelaciones expresa este fenómeno a través de un decrecimiento lento que puede demostrarse que es de tipo lineal.

La solución que se presenta consiste en la sumación (integración) del mismo obteniendo otro proceso al cual pueda hallársele una representación ARMA(p,q). Si suponemos que existen “d” raíces unitarias, podemos expresar: $\varphi(B)(y_t - \mu) = \Phi(B)(1-B)^d (y_t - \mu)$ donde $\Phi(B)(y_t - \mu) = z_t$. Obtenido $\{z_t\}$ el mismo resulta estacionario y admite una representación ARMA(p,q). Integrando “d” veces a este proceso (es decir, aplicando el operador inverso a ∇^d), tenemos una representación de y_t a la que denominamos ARIMA(p,d,q).

2.1.1.III Procesos de memoria larga

Al observar una serie cuyas autocorrelaciones decaen de manera lenta pero, finalmente, convergen a cero, lo que notamos es una persistencia en el tiempo de la influencia de las realizaciones pasadas, pero sin que la misma resulte permanente. Si nos limitáramos a los modelos introducidos hasta este apartado del trabajo nos encontraríamos frente a un problema en cuanto a la modelización: un proceso de tipo ARMA no sería de aplicación, dado que es apto para los casos de memoria corta (o sea un decaimiento exponencial en las autocorrelaciones). Por otra parte, si diferenciáramos la serie de tiempo del proceso estocástico con el objetivo de considerar la presencia de un ARIMA, notaríamos las consecuencias de una sobrediferenciación. Esto implica que no podríamos determinar la existencia de un componente determinístico en la estimación de la media. O sea, no podríamos ver un decaimiento lineal en la autocorrelación del proceso.

En respuesta a la existencia de procesos para los cuales la función de autocorrelación muestra una caída menor que la exponencial pero mayor que la lineal surge la integración fraccionaria. El mencionado comportamiento de las autocorrelaciones implica, como dicen Pérez y Ruiz⁷, que las innovaciones de las series de tiempo tienen efectos transitorios pero que perduran durante mucho tiempo. A los procesos que generan series de tiempo que presentan correlaciones que decaen con ese comportamiento, se les llama: *procesos de memoria larga*.

⁷ Pérez, A. y Ruiz, E.(2001). (23)

Existen varias definiciones formales de memoria larga, Banerjee y Urga⁸ presentan algunas de ellas. Mencionan que un proceso se dice que presenta memoria larga si su función de autocorrelación es tal que en el *lag* “j” satisface

$$\lim_{j \rightarrow \infty} \frac{\rho_j}{c_p j^{-\alpha}} = 1 \text{ para un par de constantes } 0 < c_p < \infty \text{ y } 0 < \alpha < 1. \text{ Esta definición}$$

implica que la dependencia entre observaciones sucesivas decae lentamente a medida que el número de *lags* tiende a infinito. También se está afirmando que las autocorrelaciones presentan un decrecimiento de tipo hiperbólico. Una defi-

$$\text{nición más general debida a McLeod y Hipel de 1978 es } \lim_{T \rightarrow \infty} \sum_{j=-T}^T |\rho_j(Y)| = \infty$$

donde “T” es el número de observaciones de la serie de tiempo. Ambas definiciones son consistentes con los procesos que no tienen raíces unitarias pero cuyas autocorrelaciones no caen rápidamente ni tan lentamente como la linealidad.

Por otro lado, Resnick en 1987 define la memoria larga para cualquier proceso que tenga autocovarianzas para “j” suficientemente grande tales que $\gamma_j \approx \Xi(j) j^{2(H-1)}$ donde H es el coeficiente de Hurst (que se definirá más adelante) y $\Xi(k)$ es “de variación lenta en el infinito”⁹.

Banerjee y Urga también presentan las características de estos procesos en el dominio de las frecuencias (sólo necesitando de los datos para el intervalo $[0, \pi]$) y enuncian que un proceso con función de densidad espectral **f** es

⁸ Urga, G., (2005). (29)

⁹ Las funciones de “variación lenta en el infinito” son aquellas tales que: $\lim_{t \rightarrow \infty} \frac{f(tx)}{f(t)} = 1 \quad \forall x > 0$

de memoria larga si se verifica que no está acotada para bajas frecuencias, es

$$\text{decir, } \lim_{\lambda \rightarrow 0} \frac{f(\lambda)}{c_f |\lambda|^{-\beta}} = 1 \quad 0 < c_f < \infty, \quad 0 < \beta < 1$$

2.1.3.IV Representación ARFIMA(p,d,q)

Introducido ya el concepto de memoria larga, consideremos una serie en donde, si se observa el comportamiento de la función de autocorrelaciones, puede verse un decrecimiento hiperbólico a medida que aumenta el orden de la autocorrelación. La diferencia sustancial con los modelos ARMA y ARIMA es que, mientras en un proceso ARIMA no existe reversión a la media dada la tendencia determinística, en un proceso cuyas correlaciones decrecen de manera hiperbólica sí se presenta esta reversión, aunque de manera más lenta que en un proceso ARMA. En particular, vamos entonces a estar trabajando con procesos estacionarios de memoria larga.

Para su tratamiento, se introducen los modelos ARFIMA(p, d, q) en donde el valor del parámetro “d” no es ya un número entero como en el caso de un modelo ARIMA sino que puede tomar cualquier valor real en el intervalo (-1,1). Estamos frente a procesos de orden de diferenciación fraccionario, los cuales fueron formalizados por primera vez por Mandelbrot y Van Ness¹⁰.

Estos procesos admiten una representación del tipo:

$$\varphi(B)(1-B)^d(y_t - \mu) = \psi(B)\varepsilon_t \quad \text{donde: } \varphi(B) \text{ es un operador de tipo}$$

AR(p), $\psi(B)$ es un operador MA(q), ε_t representa un ruido blanco y, como se

¹⁰ Mandelbrot, B., Van Ness, J.W. (1968). (20)

mencionó en el párrafo anterior, d es un parámetro cuyo valor pertenece al intervalo $(-1, 1)$.

Teniendo en cuenta las características de la función de densidad espectral de estos procesos, Robinson y Baillie demuestran que el proceso tiene memoria larga si $0 < d < 1/2$. Por el contrario, el proceso muestra persistencia negativa o antipersistencia si $-1/2 < d < 0$; es decir, es de memoria corta.

2.1.3.V Diferenciación fraccionaria

En el caso de la diferenciación fraccionaria, no podríamos, de manera directa y a partir de los datos empíricos, determinar, por ejemplo el valor de $(1-B)^d y_t$, dado que los valores se consideran en intervalos discretos y enteros. Una primera dificultad entonces consiste en diferenciar la serie de manera de poder luego aplicar los operadores ya conocidos. Para ello se considera el

desarrollo de un binomio: $(1-B)^d = \sum_{j=0}^{\infty} \binom{d}{j} (-B)^j \quad d \in (0; 1)$. De esta ma-

nera, los retardos que se considerarán serán aquellos para los cuales se cuenta con información. La consideración de infinitos retardos (como se observa en el límite superior de la suma) cuando la información de la que se dispone es de un número finito de observaciones del proceso presenta un inconveniente. Esta particularidad hace que el desarrollo deba truncarse. Dado que siempre se dispondrá de una cantidad finita de datos, se deberán incorporar valores de la variable que resulten representativos para considerar realizaciones pasadas de momentos anteriores a los considerados. Lo que se contempla en esos casos es tomar la media de las realizaciones.

2.1.3.VI Determinación de la presencia de memoria larga

La representación de un proceso ARFIMA (p, d, q) es:

$$\varphi(B)(1-B)^d(y_t - \mu) = \psi(B)\varepsilon_t$$

A partir de los datos de la serie con los cuales se cuenta, se necesitará determinar: el orden de diferenciación, el orden autorregresivo “p”, el orden de promedios móviles “q” y los coeficientes. Esta representación permite mostrar las dos influencias del proceso: la dependencia a corto plazo estará capturada por los coeficientes del modelo ARMA, mientras que la de largo plazo dependerá del valor que tenga el coeficiente “d”.

Previo a comenzar con la estimación, dada una serie cuyas autocorrelaciones muestrales presentan un decrecimiento hiperbólico, debemos testear la presencia de memoria larga en la misma, de modo tal de comprobar que el modelo ARFIMA resulta adecuado para la modelización del proceso. Existen numerosos test contruidos para verificar la persistencia. Muchos de ellos surgen de una adaptación de los test de raíces unitarias a los de orden de integración fraccionaria, basándose en las diferencias en el comportamiento de unos u otros. La desventaja que en general presentan es que, si bien permiten diferenciar los procesos no integrados de los que sí lo son, no siempre permiten diferenciar los casos $d = 1$ de los casos en los que $d = 1/m$.

En este apartado, describiremos el uso rango reescalado, el rango reescalado modificado y la estimación del parámetro “d” a partir del método GPH.

Rango reescalado

La utilización del coeficiente R/S para el testeo de la persistencia se debe a Mandelbrot, quien se basa en el coeficiente propuesto por Hurst en 1951¹¹. El mismo resulta indicador del rango de las sumas parciales de los desvíos de la serie respecto de su valor medio, medidos en forma relativa a través de su desviación estándar. Se corresponde con la fórmula siguiente:

$$\tilde{Q}_T = \frac{\max_{1 \leq k \leq T} \sum_{j=1}^k (y_j - \bar{y}_T) - \min_{1 \leq k \leq T} \sum_{j=1}^k (y_j - \bar{y}_T)}{\hat{\sigma}_T}$$

La desviación estándar es calculada a partir de los “T” datos de la serie con la cual se cuenta, al igual que el valor de la media. Se obtiene, en forma aproximada, que: $\ln[E(\tilde{Q}_T)] \cong k + H \cdot \ln T$ y por lo tanto $\hat{H} = \frac{\ln \tilde{Q}_T}{\ln T}$.

La importancia en la determinación del coeficiente de Hurst está en que si este coeficiente resulta ser igual a 1/2, la serie puede considerarse estacionaria. En el caso en el que, por el contrario, el coeficiente es mayor a ese valor, puede afirmarse que la serie es *persistente*. De esta manera, podríamos considerar la aplicabilidad de un modelo ARFIMA para la modelización del proceso estocástico que subyace en las realizaciones analizadas.

Sin embargo, uno de los problemas que se plantean con el uso de este test es que se considera que hay una importante sensibilidad en el resultado a

¹¹ Este estadístico nace como resultado de un análisis para la aplicación al diseño de reservas fluviales para el río Nilo. El rango aparece como un estimado de la capacidad que debe tener la

los cambios en la dependencia de corto plazo. En consecuencia, surge el test de rango reescalado modificado, el cual exponemos a continuación.

Rango reescalado modificado

El rango reescalado modificado (al que denominaremos Q_T) se obtiene:

$$Q_T = \frac{\max_{1 \leq k \leq T} \sum_{j=1}^k (y_j - \bar{y}_T) - \min_{1 \leq k \leq T} \sum_{j=1}^k (y_j - \bar{y}_T)}{\hat{\sigma}_T(q)}$$

Se demuestra que valores extremos del estimador, en ambos sentidos, se consideran indicativos de la posible existencia de memoria larga. El valor de $\hat{\sigma}_T(q)$ es la raíz de un estimador consistente de la varianza de las sumas parciales y se obtiene haciendo:

$$\hat{\sigma}_T(q) = \sqrt{\hat{\sigma}_T^2 + 2 \cdot \sum_{j=1}^q w_j(q) \cdot \hat{\gamma}_j} \quad \text{donde} \quad w_j(q) = 1 - \frac{j}{q+1} \quad \text{con } q < T$$

Esta estructura intenta reflejar que, si el proceso está sujeto a dependencia de corto plazo, la varianza de las sumas parciales no va a ser únicamente la suma de los cuadrados de cada uno de los términos sino que también deberá incluir las autocovarianzas. De esta manera las incluye, hasta el lag “q”, ponderadas por los factores w_j sugeridos por Newey y West en 1987¹². Es necesario entonces estimar también el parámetro “q”, que es un parámetro de trunca-

reserva de modo tal de contrarrestar las variaciones estacionales en el nivel del Nilo (entre los períodos 1 y n que se tengan en cuenta). Véase, Hurst, H.E. (1951). (13)

¹² Véase Newey, W., West, K. (1987). (21)

miento (determina hasta qué orden van a considerarse las autocovarianzas). El autor Lo (1991), basándose en el trabajo de Andrews (1991), a partir del resultado de simulaciones, considera que el valor de “q” óptimo para el estadístico

es la función parte entera de k_T , donde $q = [k_T]$ con $k_T = \left(\frac{3T}{2}\right)^{\frac{1}{3}} \left(\frac{2\hat{\rho}_1}{1-\hat{\rho}_1^2}\right)^{\frac{2}{3}}$

Al comenzar la descripción de este test, destacamos qué valores extremos del estimador indicaban la presencia de memoria larga. Para contrastar la hipótesis nula de memoria corta respecto a la hipótesis alternativa de memoria larga debe considerarse la distribución de Q_T .

Estimación del coeficiente d

Para la estimación del coeficiente “d” se suelen usar métodos semiparamétricos. Uno de los métodos es el método de Geweke y Porter-Hudak de 1983 conocido como método GPH. El estimador GPH se basa en el logaritmo natural del periodograma y una regresión lineal. Supongamos que tenemos una sucesión de observaciones $\{y_t\}_{t=0}^T$. Definimos el periodograma para “n” compo-

nentes como $I_j = \frac{1}{2\pi T} \left| \sum_{t=0}^{T-1} y_t e^{i\omega_j t} \right|^2$ donde $\omega_j = \frac{2\pi j}{T}$ para $j = 1, 2, \dots, n$ y “n” es un

entero positivo¹³. La estimación de “d” se obtiene mediante una regresión lineal entre el logaritmo de I_j como variable dependiente y una constante y

$X_j = \ln \left| 2 \sin \left(\frac{\omega_j}{2} \right) \right|$ como variable independiente de donde se obtiene:

¹³ Para la elección de “n” consúltase Soofi, Whang y Zang (2006) (26)

$$\hat{d}^{GPH} = - \frac{\sum_{j=1}^n (X_j - \bar{X}) \ln I_j}{2 \cdot \sum_{j=1}^n (X_j - \bar{X})}$$

En 1995, Robinson¹⁴, demuestra que este estimador es consistente y asintóticamente normal con desvío $\frac{\pi}{\sqrt{24n}}$ para el caso en que $-0,5 < d < 0,5$ y que las variables están distribuidas según una distribución normal. Se demuestra, además, que la consistencia puede ser llevada al intervalo $-0,5 < d < 1$ y que la normalidad asintótica al intervalo $-0,5 < d < 0,75$.

2.1.2. Otros procesos de Memoria Larga. Modelos GARMA

Otro de los procesos que requiere de nuestra mención son los procesos ARMA de Gegenbauer, también llamados procesos GARMA. La característica que distingue a los procesos GARMA de los ARFIMA es que los primeros son capaces de capturar comportamientos *persistentes y periódicos*, periodicidad (o comportamiento cíclico) que no refleja un modelo ARFIMA. En el caso de la modelización GARMA, la función de autocorrelaciones del proceso presenta un decrecimiento hiperbólico pero, a diferencia del decrecimiento propio de las autocorrelaciones de un ARFIMA, este decrecimiento puede presentarse de manera sinusoidal.

Tenemos entonces: $\rho_j = K \cdot j^{2d-1} \cdot \text{sen}(\pi d - jG)$, siendo G conocido como la frecuencia del proceso.

¹⁴ Véase Robinson, P.E. (1995). (24)

En cuanto a su estructura, un proceso GARMA (p, ξ, d, q) toma como base los polinomios de Gegenbauer. Aplicando a los procesos estocásticos este polinomio, definimos el *proceso de Gegenbauer* como aquel que admite una representación: $(y_t - \mu) = (1 - 2\xi B + B^2)^{-d} \varepsilon_t$

El proceso de Gegenbauer es el caso más sencillo de los modelos GARMA (p, ξ, d, q) . Estos últimos permiten la coexistencia de memoria larga y memoria corta a partir de la inclusión de los coeficientes del modelo ARMA (p, q) :

$$\varphi(B)(1 - 2\xi B + B^2)^d (y_t - \mu) = \psi(B) \varepsilon_t$$

De la observación del polinomio surge que si el parámetro ξ toma el valor 1 el proceso es equivalente a un ARFIMA $(p, 2d, q)$, con lo que claramente se observa la inclusión de los ARFIMA como caso particular de la representación GARMA.

2.2 Representaciones de la varianza

Una vez hallado el modelo que representa el proceso estocástico que constituye la media, testaremos la hipótesis fundamental de las representaciones antes mencionadas: los residuos son independientes y están idénticamente distribuidos según una Normal con media cero y varianza finita y constante. Dado que la media de los errores es cero, tendremos que la expresión de la varianza de una serie puede escribirse de la siguiente manera:

$$E\left[(y_t - E(y_t))^2\right] = E(\varepsilon_t^2) = \sigma_\varepsilon^2$$

Engle en 1982¹⁵ detectó que la correlación entre los errores al cuadrado es significativa, lo cual implica que la varianza observada se ve afectada por las realizaciones de los errores de períodos anteriores. Formalmente, esta afirmación puede escribirse según una representación autorregresiva, AR, de orden “p”:

$$\varepsilon_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 + w_t \quad \text{donde } w_t \sim N(0, \lambda^2).$$

Esta representación de los errores al cuadrado es conocida como representación ARCH¹⁶ o representación de la heterocedasticidad condicionada autorregresiva y se explicará en los siguientes apartados.

2.2.1 Detección de comportamiento ARCH

Engle, en el mismo trabajo de 1982, propone un test para la detección de comportamiento ARCH en los residuos al cuadrado denominado test del multiplicador de Lagrange o test LM. La hipótesis nula es la no existencia de comportamiento ARCH. Si, para “p” retardos se detecta significatividad de los coeficientes de la regresión del primer test o, en otras palabras, se rechaza la hipótesis nula de que todos ellos son iguales a cero y se puede afirmar que el estadístico del test LM toma un cierto valor con una confiabilidad mayor a un criterio predefinido, entonces diremos que estamos frente a un comportamiento ARCH.

Engle, Bollerslev y Nelson (1994)¹⁷, comentan que al utilizar el test LM cuando se rechaza la hipótesis nula, no necesariamente se están observando efectos ARCH. También consideran que hay otros test asintóticamente equiva-

¹⁵ Véase Engle, R. (1982). (11)

¹⁶ De su sigla en inglés: *Autorregresive Conticonal Heterocedaskicity*

lentes que deben ser tenidos en cuenta sobre los regresores. En 1991 Lee¹⁸ demostró que el test LM también puede ser utilizado para detectar la presencia de comportamiento GARCH¹⁹ (modelo que se explicará más adelante). Dos años mas tarde, en 1993, Lee y King²⁰ “señalaron que el problema de testeo de presencia de ARCH y GARCH era de un test a una cola (*one-sided test*) y que el test LM fallaba en esos casos por lo que dedujeron el test de puntuación LMMP (*locally most mean powerful*) para detectar la presencia de ARCH y GARCH en un modelo de regresión lineal”.

2.2.2 Procesos representados por ARCH

El nombre de la representación ARCH surge de la expresión presentada anteriormente. Esta incluye la idea de que la varianza del proceso y_t en cada momento del tiempo cambia (heterocedasticidad) y depende de las realizaciones de los períodos anteriores (condicionada autorregresiva) como puede verse a continuación $\sigma_t^2 = E(\varepsilon_t^2 / F_{t-1}) = \omega + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2$, lo que puede ser escrito como: $\sigma_t^2 = \omega + \alpha_q(B) \varepsilon_t^2$

Con lo que, nuestro modelo ARMA-ARCH es descripto según el siguiente sistema de ecuaciones:

$$\begin{cases} \Phi(B)y_t = \Theta(B)\varepsilon_t \\ \varepsilon_t = u_t \sigma_t \end{cases} \quad \text{donde } u_t \text{ es un ruido blanco con media cero y varianza uno.}$$

¹⁷ Véase Bollerslev, T. Engle, R., Nelson, D. (1994). (5),

¹⁸ Véase Lee, J. H. H. (1991). (15)

¹⁹ *Generalized Autoregressive Conditional Heteroskedasticity*

²⁰ Véase Lee, J. H. and King, M. L. (1994). (16)

Podemos comprobar que los coeficientes de la representación ARCH deben ser todos positivos para asegurar que la predicción de la varianza condicionada sea positiva. Por lo tanto, surge la condición de que en la representación se debe verificar que $w > 0 \wedge \alpha_j \geq 0 \quad \forall j = 1, 2, \dots, m$

Por otro lado, puede demostrarse, que la expresión de la varianza no condicionada es $\lim_{k \rightarrow +\infty} E(\varepsilon_t^2 \mid F_{t-k}) = \frac{\omega}{1 - \sum_{i=1}^p \alpha_i}$. Con el objetivo de obtener una

varianza finita y positiva, se impone una segunda condición a los coeficientes de la representación ARCH: $\sum_{i=1}^p \alpha_i < 1$

Los modelos que se verán a continuación tienen la característica de que pueden ser expresados como un $ARCH(\infty)$. Por ello, pueden ser considerados como una clase en donde se encuentran el GARCH, el IGARCH y el FI-GARCH y sus variaciones.

2.2.3 Procesos representados por GARCH

Bollerslev en 1986²¹ propone la generalización de la representación ARCH. La generalización de Bollerslev puede especificarse de dos formas. Por un lado, haciendo explícito el modelo ARMA que representará el comportamiento de los residuos al cuadrado y por otra haciendo explícita la cantidad de términos de varianza condicionada y de residuos al cuadrado. En el caso de la

²¹ Véase Bollerslev, T., (1986). (4)

segunda, tendremos $\sigma_t^2 = \bar{\omega} + \beta_q(B)\sigma_t^2 + \alpha_p(B)\varepsilon_t^2$, que, en términos de un modelo ARMA tomaría la siguiente forma:

$$\varepsilon_t^2 = \bar{\omega} + [\alpha_p(B) - \beta_q(B)]\varepsilon_t^2 + [1 - \beta_q(B)]w_t$$

que puede escribirse resumidamente como $ARMA(\text{Max}[p,q], p)$ sobre los residuos al cuadrado. Adicionalmente, la expresión en términos de $ARCH(\infty)$ es:

$$\sigma_t^2 = \omega + \frac{\alpha_p(B)}{[1 - \beta_q(B)]}\varepsilon_t^2 = \omega + \lambda(B)\varepsilon_t^2$$

Se deduce que la condición para que el proceso tenga varianza finita, o sea, que sea estacionario en las covarianzas es $\sum_{i=1}^{\text{MAX}[p,q]} \alpha_i + \beta_i < 1$. Cabe aclarar

que si, por ejemplo, $q > p$ tenemos un $ARMA(p,q)$ y la condición se podría escribir $\sum_{i=1}^p \alpha_i + \sum_{i=1}^q \beta_i < 1$. Por último, en cuanto a la función de autocovarianzas de

un $GARCH(p,q)$, puede demostrarse que vale

$$\gamma_k = \sum_{i=1}^{\text{MAX}[p,q]} (\alpha_i + \beta_i) \gamma_{k-i} \quad k \geq q+1.$$

Por lo que, un proceso representado por un modelo $GARCH(p,q)$ es estacionario en las covarianzas. Además, su función de autocorrelación decae en forma exponencial y, por lo tanto, es un proceso de memoria corta.

2.2.4 Procesos representados por IGARCH

Engle y Bollerslev presentan en 1986²² el modelo IGARCH cuyo objetivo es alargar la memoria de la representación GARCH. Sin embargo, el objetivo no se logró y la memoria de este tipo de procesos decae geométricamente. Para lograr el objetivo de memoria larga se impuso, por analogía a los modelos de representación de la media, que la suma de los coeficientes del modelo GARCH sea 1. Así, el modelo IGARCH(p,q):

$$\left[1 - \alpha_p(B) - \beta_q(B)\right] \varepsilon_t^2 = \bar{\omega} + \left[1 - \beta_q(B)\right] w_t$$

donde $\sum_{i=1}^p \alpha_i + \sum_{i=1}^q \beta_i = 1$, o en la notación introducida antes, $\sum_{i=1}^{MAX[p,q]} \alpha_i + \beta_i = 1$ y

$\bar{\omega} = \left[1 - \beta_p(B)\right] \omega$. Este proceso puede escribirse de acuerdo a su representa-

ción ARCH(∞): $\sigma_t^2 = \omega + \frac{\alpha_p(B)}{1 - \beta_q(B)} \varepsilon_t^2 = \omega + \lambda(B)(1 - B) \varepsilon_t^2$

De esta expresión pueden obtenerse dos conclusiones muy importantes. Por un lado, que la varianza no condicionada no existe. El denominador de la expresión:

$$\begin{aligned} \sigma^2 = E(\varepsilon_t^2) &= \frac{\bar{\omega}}{1 - (\alpha_1 + \beta_1) - (\alpha_2 + \beta_2) - \dots - (\alpha_{MAX[p,q]} + \beta_{MAX[p,q]})} = \\ &= \frac{\bar{\omega}}{1 - \left(\sum_{i=1}^{MAX[p,q]} \alpha_i + \beta_i \right)} \end{aligned}$$

²² Véase Engle, R., Bollerslev, T. (1986). (10)

se anula, por la condición antes impuesta, lo que significaría una varianza no condicionada infinita. Esto último es imposible e implica que la representación IGARCH no es estacionaria en las autocovarianzas.

Por otro lado, como puede verse en la representación $ARCH(\infty)$, se está considerando la hipótesis de que existe una tendencia en los residuos al cuadrado y, por lo tanto, se introduce esta tendencia en la varianza condicionada esperada.

Consideremos ahora un IGARCH(1,1). La representación en función de la varianza condicionada puede escribirse $\sigma_t^2 = \bar{\omega} + \alpha_1 \varepsilon_{t-1}^2 + (1 - \alpha_1) \sigma_{t-1}^2$, de donde se deduce, que la representación $ARCH(\infty)$ es:

$$\sigma_t^2 = \omega + \frac{\alpha_1 B}{1 - (1 - \alpha_1) B} \varepsilon_t^2 = \omega + \alpha_1 \sum_{i=1}^{\infty} (1 - \alpha_1)^{i-1} \varepsilon_{t-i}^2$$

Llegamos a que su memoria es de decrecimiento geométrico. Esto último fue presentado por Ding y Ganger en 1996²³ con la deducción de la relación entre las autocovarianzas de este modelo: $\rho_k = \frac{1}{3}(1 + 2\alpha)(1 + 2\alpha^2)^{-k/2}$

Por último, puede obtenerse otra relación que ayuda a explicar la presencia de memoria corta en este tipo de modelos y nos ayudará a introducir el concepto de persistencia. La varianza condicionada esperada en $t + k$ dada la información (filtración) en el momento t se obtiene partiendo de:

$$\sigma_t^2 = \bar{\omega} + \alpha_1 \varepsilon_{t-1}^2 + (1 - \alpha_1) \sigma_{t-1}^2$$

Recordando que $\varepsilon_t = u_t \sigma_t$ y que $u_t \sim N(0,1)$, podemos sustituir $\sigma_{t+1}^2 = \bar{\omega} + \alpha_1 u_t^2 \sigma_t^2 + (1 - \alpha_1) \sigma_t^2$. Aplicando el operador esperanza matemática miembro a miembro: $E(\sigma_{t+1}^2 | F_t) = \bar{\omega} + \sigma_t^2 = \bar{\omega} + [\bar{\omega} + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2]$

Repitiendo el procedimiento se llega a que: $E(\sigma_{t+k}^2 | F_t) = \omega k + \sigma_t^2$

Como puede verse, la varianza condicionada tiene una tendencia positiva con pendiente ω y depende del valor que tomó la varianza condicionada al momento t . Esta representación tiene persistencia. Esto no implica que el proceso tenga memoria larga. Ya que, como se ha visto, en este caso las autocorrelaciones decaen en forma geométrica.

Estamos en condiciones de decir que, a pesar de que las expresiones del IGARCH(p,q) son indicadores naturales de la varianza condicionada, dependiendo de los valores que toma la varianza en períodos anteriores, estas no son expresiones de la varianza condicionada. O sea, no la representan. Por lo que, la expresión de $E(\sigma_{t+k}^2 | F_t)$ no tiene ningún significado en el terreno de los modelos para representar la varianza.

2.2.5 Procesos representados por FIGARCH

Por último, dentro de nuestra clase ARCH(∞) tenemos los FIGARCH. Estos modelos son una generalización del caso anterior en donde el índice de

²³ Véase Ding, Z., Granger, C.W.J., (1996). (8)

integración se encuentra entre 0 y 1. Baillie, Bollerslev y Mikkelsen en 1996²⁴ describen la representación FIGARCH(p,d,q) como:

$$\psi(B)(1-B)^d \varepsilon_t^2 = \bar{\omega} + [1 - \beta(B)]w_t$$

donde $\psi(B)$ es un polinomio de operadores. También puede ser escrita en términos de la varianza condicionada:

$$\sigma_t^2 = \bar{\omega} + [1 - \beta(B)]\varepsilon_t^2 - \psi(B)(1-B)^d \varepsilon_t^2 + \beta(B)\sigma_t^2$$

Obsérvese que, a diferencia de los modelos ARFIMA, la constante no es multiplicada por el factor $(1-B)^d$.

La representación como un ARCH(∞) infinito se expresa en la forma:

$$\sigma_t^2 = \omega + \left(1 - \frac{\psi(B)(1-B)^d}{1 - \beta(B)}\right)\varepsilon_t^2 = \omega + [1 - \lambda(B)(1-B)^d]\varepsilon_t^2$$

donde $z_t = (1-B)^d \varepsilon_t^2$ es un proceso estocástico integrado fraccionalmente con $0 \leq d \leq 1$ y el factor de integración tiene la forma ya mencionada en la secciones anteriores.

Vale la pena hacer dos consideraciones al respecto. El valor de $d = 1$ se corresponde con el caso de IGARCH y para $d = 0$ estamos frente a un GARCH. Pero no debe interpretarse que este modelo es un caso intermedio a los otros

²⁴ Véase Baillie, R. T., Bollerslev, T. , Mikkelsen, H. O., (1996). (2)

dos. La intuición diría que al incrementarse el valor de d desde el cero hasta el 1, la memoria del proceso cambia de un GARCH a un IGARCH. Esto no es así. Se puede demostrar que el modelo FIGARCH incrementa su memoria de tipo hiperbólico a medida que $d \rightarrow 0$.

Tomemos un FIGARCH(0,d,0). Su representación ARCH(∞) sería:

$$\sigma_t^2 = \omega + \left[1 - (1-L)^d\right] \varepsilon_t^2 = \omega + \sum_{i=1}^{\infty} \varphi_i \varepsilon_{t-i}^2$$

Utilizando la aproximación de Stirling podemos ver que los coeficientes decaen en forma hiperbólica: $\lim_{s \rightarrow +\infty} \varphi_s = \lim_{s \rightarrow +\infty} \frac{\Gamma(s-d)}{\Gamma(s+1)\Gamma(-d)} \cong \frac{s^{-d-1}}{\Gamma(-d)}$.

Chung en 1999²⁵ menciona algunas otras diferencias entre la definición del modelo ARFIMA(p,d,q) y el FIGARCH(p,d,q). “Primero, notamos que el modelo ARFIMA(p,0,q) coincide con el ARMA(p,q) pero que el FIGARCH(p,0,q), no coincide con el modelo GARCH(p,q). Segundo, por extensión del análisis sobre los modelos IGARCH, BBM/BM²⁶ argumentaron que el modelo FIGARCH, que no es débilmente estacionario, puede ser estrictamente estacionario y ergódico para $0 \leq d < 1$ ”. Por lo tanto, los intervalos de los coeficientes de integración son distintos. Mientras que en los modelos para la media condicionada debe ser menores que 0,5, en los modelos de la varianza condicionada puede ser mayor que 0,5, “lo cual implica que el grado de persistencia en estos últimos es mayor que en los modelos de media condicionada. Por último, mien-

²⁵ Véase Chung, C. (1999). (6)

²⁶ Notación del autor para referirse a Billie, Bollerslev y Mikkelsen.

tras que no hay restricciones de signos en los modelos para la media condicionada, los parámetros del FIGARCH están sujetos a restricciones adicionales para asegurar que las varianzas condicionadas resultantes sean todas no negativas”.

En el mismo trabajo, Chung critica la parametrización del modelo FIGARCH. Como se dijo, el parámetro ω no se multiplica por el factor $(1-B)^d$. A través de la fórmula de varianza no condicionada podemos deducir una relación entre la varianza no condicionada y el parámetro ω . Para ello partimos del GARCH(p,q), de donde dedujimos que la varianza no condicionada es $\sigma^2 [1 - \alpha(B) - \beta(B)] = \bar{\omega}$. Entonces, podemos reescribir el GARCH(p,q) $[1 - \alpha(B) - \beta(B)](\varepsilon_t^2 - \sigma_t^2) = [1 - \beta(B)]w_t$. Si, a su vez, redefinimos el modelo FIGARCH(p,d,q) como $\psi(B)(1-B)^d(\varepsilon_t^2 - \sigma_t^2) = [1 - \beta(B)]w_t$, por comparación, tenemos que $\bar{\omega} = \psi(B)(1-B)^d \sigma^2$.

Aquí debemos aclarar que el parámetro σ^2 es la varianza no condicionada del modelo GARCH(p,q) lo cual no significa que sea la varianza no condicionada de la representación FIGARCH(p,d,q). Es utilizada en esta demostración por la razón que se presenta a continuación. La última igualdad se puede escribir: $\bar{\omega} = \psi(1) \sum_{i=0}^{\infty} \varphi_i \sigma^2$ donde se sabe que $\psi(1) > 0$ y $\sigma^2 > 0$ por ser la varianza no condicionada de un modelo GARCH(p,q) la cual ya ha sido mencionado que es finita y positiva. Queda por definir el intervalo en el que se defi-

ne el polinomio $\sum_{i=0}^{\infty} \varphi_i$. La aproximación de Stirling para “i” suficientemente

grande es $\sum_{i=0}^{k-1} \varphi_i \cong \frac{k^{-d}}{\Gamma(1-d)}$

Si tomamos límite para “k” tendiendo a infinito $\lim_{k \rightarrow \infty} \sum_{i=0}^{k-1} \varphi_i = 0$, se llega a la

conclusión de que $\bar{\omega} = 0$. Este resultado presenta un problema dado que en la estimación se detectan valores de $\bar{\omega}$ mayores a cero. Por ello, surge un problema que la literatura especializada no ha terminado de resolver que es qué significado darle a la constante $\bar{\omega}$ cuando resulta significativa.


Adicionalmente a la crítica de Chung, Davidson en 2003²⁷ hace notar que el problema de interpretación del modelo IGARCH también aparece en este caso. Volvemos al modelo FIGARCH(0,d,0). Su representación en función de la varianza no condicionada es $\sigma_t^2 = \omega + \left[1 - (1-L)^d\right] \varepsilon_t^2$. En la cual, se puede utilizar la igualdad $\sigma_t^2 = \varepsilon_t^2 - w_t$ para llegar a que $(1-B)^d \varepsilon_t^2 = \omega + w_t$.

Esta ecuación parece representar el proceso ε_t^2 como un proceso integrado fraccionalmente de la media condicionada. Sin embargo, dado que la varianza del FIGARCH es infinita, los momentos segundos no existen y por lo tanto no se puede suponer que $E(w_t) = 0$.

²⁷ Véase Davidson, J. (2003). (7)

3. Aplicación al índice de la Bolsa de Comercio de Buenos Aires

A fines de ilustrar la aplicación de un modelo ARFIMA (p, d, q) consideramos la serie de rendimientos diarios del índice de la Bolsa de Comercio de Buenos Aires entre el 2 de Enero de 1991 y el 16 de Mayo de 2006, reuniendo una serie cronológica compuesta por 4009 valores. Es importante mencionar que, a fines de contemplar los días en los que no hay operaciones, se han tomado como representativos los valores del índice del día anterior (por lo que el rendimiento es nulo para esos días).



Para la modelización, consideramos la siguiente hipótesis: la persistencia en la serie de los rendimientos logarítmicos de la fuente mencionada es significativa y, por lo tanto, admite


una representación ARFIMA(p, d, q)-FIGARCH(p, d, q). Para ello, realizamos los tests correspondientes en el orden propuesto en el presente trabajo. Esta hipótesis de representación ARFIMA(p, d, q)-FIGARCH(p, d, q) implica testar inicialmente la presencia de memoria larga (en el sentido de que la autocorrelación decae en forma hiperbólica) en la serie de tiempo analizada y luego hacer lo propio sobre los residuos al cuadrado. Al mismo tiempo, el uso de este tipo de modelos implica que se está buscando un “rendimiento de equilibrio”.

A su vez, tomamos en cuenta los estudios con respecto a los rendimientos diarios. Cabe destacar que la literatura al respecto coincide en que la distribución de los rendimientos tiende a ser leptocúrtica con respecto a la Normal, que

la volatilidad se presenta en “clusters” y que la variación negativa del precio tiende a aumentar la volatilidad mientras que una variación positiva tiende a disminuirla. Cuando decimos que “la volatilidad se presenta en clusters” nos referimos a que en una serie de rendimientos diarios es común encontrarse con períodos de tiempo (dígase más de un día) de alta volatilidad y períodos de tiempo de baja volatilidad como se señalará en los gráficos presentados a continuación. Esto da soporte a la hipótesis de comportamiento FIGARCH(p,d,q). Adicionalmente, varios trabajos demuestran que la serie de rendimientos logarítmicos tiende a ser incorrelacionada en la mayoría de las observaciones. Estas consideraciones también justifican la hipótesis.


En este punto debemos hacer una consideración metodológica acerca de la frecuencia de muestreo. Puede ser demostrado que los modelos GARCH no pueden ser temporariamente agregados. Esto significa que un GARCH que fue estimado a partir de información diaria no puede ser utilizado para representar información semanal o mensual. Hay regularidades bien definidas que indican que cuanto más alta la frecuencia de muestreo, mayores son los efectos GARCH. Los datos semanales suelen presentarlos pero no son comunes en datos mensuales para los que suelen detectarse efectos GARCH pero que normalmente se deben a cambios estructurales en varianza no condicionada. Por todo ello, hemos decidido trabajar con datos diarios.

Las características de la serie analizada se resumen en la siguiente tabla:



En primer término evaluamos la hipótesis de que la media del proceso sea cero a través del test t. El resultado fue el rechazo de la hipótesis, con un *p-value* de 0.006. Por ello,

nuestra representación ARFIMA(p,d,q) contendría un término independiente.



Asimismo, consideramos el comportamiento de su función de autocorrelaciones, siendo esta de la forma:

Comenzamos analizando el estadístico “Q” de

Box, Pierce y Ljung para 200 lags. El valor del estadístico Q resultó ser 370,42, con un *p-value* de aproximadamente cero, para una χ^2 con 200 grados de libertad, siendo rechazados todos los estadísticos intermedios. Con ello, encontramos que la autocorrelación era significativa. Posteriormente, se continuó con la detección de raíces unitarias a través del test aumentado de Dickey y Fuller rechazando la hipótesis nula de existencia de raíz unitaria.


A continuación se analizó el correlograma presentado anteriormente buscando la posibilidad de representar el decrecimiento de la función de autocorrelaciones a través de una función hiperbólica. Encontramos que esto no era posible dado que el R^2 del ajustamiento era de 0,06923 (para 200 lags) y las autocorrelaciones eran tanto positivas como negativas. Sin embargo, dado que este procedimiento es puramente empírico, se continuó con los demás tests expuestos de forma de testear memoria larga en la serie.

Con el test del Rango Escalado Modificado se obtuvo el valor de 138,93 y del estadístico igual a 2,1943 que es mayor que el valor crítico 1,862 al 95% de confiabilidad con lo que se puede asegurar que el proceso no es un *random walk*. A su vez, el Rango Escalado toma un valor de 156,60 lo cual implica que el coeficiente de Hurst es de 0,61 indicando persistencia en la serie.


Esto nos lleva directamente a estimar el parámetro que indica la diferenciación de la serie a través del estimador GPH. La estimación de “d” obtenida utilizando el programa R es 0,154 cuyo desvío asintótico es 0,09012672. Con esto, podemos afirmar que la serie tiene un orden de diferenciación fraccionario positivo con un 90% de confiabilidad. Este valor de 0,154 es el utilizado para diferenciar fraccionalmente la serie y encontrar la representación ARMA(p,q) del proceso diferenciado.

Una vez diferenciada la serie, obtenemos los siguientes estimadores de las medidas más importantes del proceso en el cuadro que se presenta.

Nuevamente, realizamos el test para comprobar si la media puede ser considerada nula (de valor cero) y aceptamos la hipótesis



con una confiabilidad del 95%. Con lo cual, nuestro modelo de representación



de la media no tendrá término independiente. Mediante el análisis del correlograma de la serie diferenciada (cuadro a la izquierda de este párrafo) proponemos como modelo del proceso que representa los

rendimientos logarítmicos diarios un ARFIMA(2;0,154;0) de la siguiente forma:

$$(1 - \phi_2 B^2) \cdot (1 - B)^{0,154} y_t = \varepsilon_t \quad \text{cuyo coeficiente tomó el valor } \phi_2 = -0,0874$$

con desvío 0,0157.

A continuación se realizó el test del multiplicador de Lagrange o test LM para detectar la presencia de comportamiento ARCH o GARCH en el comportamiento de la serie. Para distintos lags (2,5,7,9,15) se hicieron las regresiones sobre los residuos al cuadrado y se calcularon los coeficientes de determinación o R^2 para llevar adelante el test. Se encontró que los estadísticos eran significativos para todos los lags lo que nos autorizó a buscar una representación ARFIMA-GARCH para el proceso en cuestión.

Como se dijo, se suele afirmar que un GARCH(1,1) representa suficientemente bien el comportamiento de una serie. Basándonos en esta afirmación, buscamos la representación ARFIMA(2;0,154;0)-GARCH(1,1) obteniendo los siguientes resultados:

Coef.	D.E.	Estadístico z	p-value
ϕ_2			
-0,087367	0,016374	-5,335570	0,0000
Ecuación de la Varianza			
$\bar{\omega}$			
8,00E-06	8,31E-07	9,635278	0,0000
α_1			
0,119548	0,005531	21,61456	

0,0000
β_1
0,864167
0,005269
164,0240
0,0000
R cuadrado ajustado
0,007759
D.E. var. dep.
0,020735
D.E. regresión
0,020655
Akaike info criterion
-5,285388
Suma de res. al cuad.
1,706862
Schwarz criterion
-5,279100
Log-verosimilitud
10587,99
Durbin-Watson
2,027354


Cuadro resumen de los resultados de ajustar un modelos AR-FIMA(2;0.154;0)-GARCH(1,1) a la serie de rendimientos logarítmicos.

A pesar de que era de esperarse que la autocorrelación entre los residuos al cuadrado fuese no significativa con la sola implementación de un modelo GARCH(1,1), ese no fue el resultado obtenido. Por el contrario, la autocorrelación apareció como significativa y, por lo tanto, debió suponerse que existía algún componente adicional que no esta teniéndose en cuenta en el ámbito de la varianza condicional.

Dado que se observaba un decrecimiento lento de la autocorrelación de los residuos al cuadrado se supuso que podría tenerse un mejor resultado con la integración fraccionaria de los residuos al cuadrado. Esta suposición incluso se encontraba justificada dado que el estadístico “Q” tomaba valores muy altos

para *lags* muy bajos y aumentaba fuertemente con el incremento de los *lags*. A ello se le debe agregar que las autocorrelaciones eran todas de signo positivo y de valor altos en los primeros 200 *lags*.

Se analizó el correlograma intentando representar el decrecimiento de la función de autocorrelaciones a través de una función hiperbólica como se hizo antes. El R^2 del ajustamiento fue de 0,6166 (para 100 *lags*) y las autocorrelaciones eran positivas. Con este resultado, se continuó con los demás tests expuestos de forma de testear la persistencia en la serie.



Con el test del Rango Escalado Modificado se obtuvo el valor de 154,74 y del estadístico igual a 2,4451 que es mayor que el valor crítico 1,862 al 95% de confiabilidad con lo que se puede asegurar que el proceso no es un *random walk*. A su vez, el Rango Escalado toma un valor de 225,50 lo cual implica que el coeficiente de Hurst es de 0,65 indicando persistencia en la serie.

La estimación de “d” obtenida es 0,01153437 cuyo desvío es 0,06998. En este caso, no podemos afirmar que la serie posea un orden de diferenciación fraccionario positivo.

La consecuencia del estudio que realizamos sobre la serie de los rendimientos logarítmicos del Índice de la Bolsa de Comercio de Buenos Aires es que debe tenerse siempre en cuenta la persistencia en la serie que se analiza antes de encontrar su representación. En nuestro caso, tanto la media como la varianza condicional presentaron comportamientos de tipo fraccionario que se evidenció a través del coeficiente de Hurst en ambos casos y de la forma de las autocorrelaciones en el caso de la varianza condicionada. En esta última, el efecto de la integración fraccionaria es la persistencia a lo largo del tiempo de los “shocks” que se producen en un momento del tiempo produciendo que se observe una relación significativa entre los residuos al cuadrado de diferentes momentos del tiempo.

Resta entonces comentar que la hipótesis que planteamos al inicio fue corroborada dados los valores de los estadísticos de prueba antes expuestos. Es de destacar que el índice de integración del proceso asociado a la varianza condicional es menor que el de la media, lo cual significa que hay mayor persistencia.

4. Comentarios finales

En el presente trabajo se estudió en forma teórica las representaciones de la media condicionada y la varianza condicionada de procesos estocásticos unidimensionales, buscando destacar el caso de los procesos integrados fraccionariamente. Partimos de los modelos lineales en donde se modela la media condicionada a partir del propio pasado estableciendo las condiciones que de-

be satisfacer una representación para ser estacionaria. Luego, se ha mostrado la existencia de distintos modelos que se ajustan a los distintos comportamientos que, en la realidad, se verifica que se presentan en las series cronológicas.

Los procesos de orden de diferenciación fraccionario constituyen el cuerpo principal del presente escrito y se han introducido con la representación ARFIMA. Ya considerando un mayor grado de complejidad, se presentan los modelos no lineales que presentan heterocedasticidad (su varianza depende del tiempo). Análogamente a como se hizo en los modelos lineales, se parte de la modelización tradicional y luego se ilustran las sucesivas alternativas que fueron desarrollándose a lo largo del tiempo, exponiendo las últimas discusiones acerca de la modelización de la varianza condicionada.

El estudio de los modelos ARFIMA permite ampliar las posibilidades al momento de estudiar el comportamiento de un proceso estocástico partiendo de la observación de una serie cronológica. Sin embargo, con ello no se han resuelto las innumerables alternativas existentes dentro de lo que es el comportamiento de los procesos de memoria larga.

Una de las alternativas propuestas para la consideración de los modelos de memoria larga es atribuible a Parke (1999)²⁸. El modelo denominado *Error Duration*. Según éste, el mecanismo que determina el estado de la variable en el momento t surge de la combinación de “shocks” aleatorios que tienen, cada uno de ellos también, duraciones aleatorias. Si bien no nos detendremos en la descripción del modelo, es importante notar que, a pesar de que los aborda

²⁸ Véase Parker, W. R. (1999). (22)

desde una perspectiva distinta, incluye al tratamiento de los procesos de integración fraccionaria (que presentan un bajo porcentaje de shocks de larga duración).

Mientras que la teoría de la modelización de la media condicionada parece estar terminada. La teoría de los modelos no lineales aún sigue evolucionando. Muchos modelos quedaron fuera de la exposición. Por ejemplo, el LM-ARCH, el LM-GARCH, el EGARCH, el FIEGARCH y otras modificaciones del modelo GARCH. Algunas de las modificaciones pueden consultarse en Arce-Borda de 2003²⁹.

Bibliografía

1. Arce Borda, R. (2003) “20 años de modelos ARCH: Una visión de conjunto de las distintas variantes de la familia”.
2. Baillie, R. T., Bollerslev, T. , Mikkelsen, H. O., (1996), “Fractionally integrated generalized autoregressive conditional heteroskedasticity”, *Journal of Econometrics*, 74, 3–30.
3. Banerjee, A., Urga, G. (2005), “Modelling structural breaks, long memory and stock market volatility”, *Journal of Econometrics* , 129, pp. 1-34.
4. Bollerslev, T., (1986), “Generalized autoregressive conditional heteroskedasticity”, *Journal of Econometrics*, 31, 307–327.
5. Bollerslev, T. Engle, R., Nelson, D. (1994) “Arch Models”, *Handbook of Econometrics*, Vol. IV.
6. Chung, C. (1999) “Estimating the fractionally integrated GARCH model”, Institute of Economics, Academia Sinica, Taiwan.
7. Davidson, J. (2003) “Moment and Memory Properties of Linear Conditional Heteroscedasticity Models, and a New Model”, Cardiff University.

²⁹ Véase Arce Borda, R. (2003). (1)

8. Ding, Z., Granger, C.W.J., (1996), "Modelling volatility persistence of speculative returns: a new approach", *Journal of econometrics* , 73, pp. 185-215.
9. Dufour, J., Khalaf, L., Bernard, J-T., Genest, I. (2002) "Finite sample test for ARCH effects and variance change-points in linear regressions", Université de Montréal, Canadá.
10. Engle, R., Bollerslev, T., (1986), "Modelling the persistence of conditional variances", *Econometric reviews* , 5, pp 1-50.
11. Engle, R.F., (1982), "Autoregressive conditional heteroskedasticity with estimates of the variance of U.K. inflation", *Econometrica*, 50, pp. 987-1008.
12. Ferrara, L, Guégan, D. (1999) "Forecasting Financial Time Series with Generalized Long Memory Processes", Université Paris, Francia.
13. Hurst, H.E. (1951) "Long-term storage capacity of reservoirs", *Trans. Am. Soc. Civil Eng.* 116: 770-880.
14. Landro, A. H., Gonzalez, M. (2006), "Elementos de la econometría de los fenómenos dinámicos", Universidad de Buenos Aires, Argentina.
15. Lee, J. H. (1991), 'A Lagrange multiplier test for GARCH models', *Economics Letters* 37, 265–271.
16. Lee, J. H., King, M. L. (1993), 'A locally most mean powerful based score test for arch and garch regression disturbances', *Journal of Business and Economic Statistics* 11, 17–27. Correction 12 (1994), 139.
17. Lo, A. (1989) "Long-term memory in stock market prices", Massachusetts Institute of Technology (MIT), Working Paper No. 3014-89-EFA, EEUU.
18. Lombardi, M. y Gallo, G. (2005), "Processi a memoria lunga e fractionally integrated GARCH", Dipartimento di Statistica "G. Parenti", Università degli Studi di Firenze, Italia.
19. Maheu, J. (2002) "Can GARCH Models capture the Long-Range Dependence in Financial Market Volatility?", Dept. of Economics, University of Toronto, Canada.
20. Mandelbrot, B., Van Ness, J. W., (1968) "Fractional Brownian motions, fractional noises and applications. *SIAM Review* 10, pp. 422-437.
21. Newey, W. K., West, K. D. (1987) "A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix", *Econometrica*, 55, 703-708.
22. Parke, W.R., (1999), "What is fractional integration?", *Review of economics and statistics* , 81, pp. 632-638.

23. Pérez, A. y Ruiz, E. (2001) "Modelos de memoria larga para series económicas y financieras", Departamento de Estadística y Econometría de la Universidad Carlos III de Madrid, Madrid.
24. Robinson, P. M. (1995) "Gaussian semiparametric estimation of long-range dependence", *The Annals of Statistics*, 23:1630--1661.
25. Rossi, E. (2004) "Lecture notes on GARCH models", University of Pavia.
26. Soofi, A., Wang, S., Zhang, Y. (2006) "Testing for long memory in the Asian Foreign Exchange Rates", *Journal of System Sci. and Complexity*, nº 19, pp. 182-190.
27. Tieslau, M. A., Schmidt, R. and Baillie, R. T., (1996) "A Minimum Distance Estimator for Long-Memory Time Series," *Journal of Econometrics*, 71(1-2): 249-264.
28. Trevisan, E. (2000) "Estimacao do parámetro "d" em modelos ARFIMA", Departamento de Estatística, Universidade Federal de Santa Maria, Brasil.
29. Urga, G. (2005) "ARFIMA(p,d,q) and FIGARCH models", CEA@Cass.