

ESTADÍSTICA ACTUARIAL TEORÍA Y APLICACIONES

José María Sarabia Alegría
Departamento de Economía
Universidad de Cantabria

Emilio Gómez Déniz
Departamento de Métodos Cuantitativos en Economía y Gestión
Universidad de Las Palmas de Gran Canaria

Francisco José Vázquez Polo
Departamento de Métodos Cuantitativos en Economía y Gestión
Universidad de Las Palmas de Gran Canaria



Madrid – México – Santafé de Bogotá – Buenos Aires – Caracas – Lima
Montevideo – San Juan – San José – Santiago – São Paulo – White Plains

Datos de catalogación bibliográfica

José María Sarabia Alegría, Emilio Gómez Déniz y
Francisco José Vázquez Polo
Estadística actuarial
PEARSON EDUCACIÓN, S.A. Madrid, 2007

ISBN 10: 84-205-5028-0
ISBN 13: 978-84-205-5028-2
Materia: 519.2

Formato: 17 x 24

Páginas: 600

Todos los derechos reservados.

Queda prohibida, salvo excepción prevista en la Ley, cualquier forma de reproducción, distribución, comunicación pública y transformación de esta obra sin contar con autorización de los titulares de propiedad intelectual. La infracción de los derechos mencionados puede ser constitutiva de delito contra la propiedad intelectual (arts. 270 y sgts. Código Penal).

DERECHOS RESERVADOS

© 2007 PEARSON EDUCACIÓN S.A.
C/ Ribera del Loira, 28
28042 Madrid (España)

José María Sarabia Alegría, Emilio Gómez Déniz y Francisco José Vázquez Polo
Estadística actuarial

ISBN 10: 84-205-5028-0
ISBN 13: 978-84-205-5028-2
Depósito Legal: M. 37.045-2006

Equipo editorial:

Editor: Alberto Cañizal

Técnico editorial: Elena Bazaco

Equipo de producción:

Director: José Antonio Clares

Técnico: Diego Marín

Diseño de cubierta: Equipo de diseño de PEARSON EDUCACIÓN, S.A.

Impreso por: Closas-Orcoven, S. L.

IMPRESO EN ESPAÑA – PRINTED IN SPAIN

A Corito, José María y Belén (JMS)

A Estela, Alberto y Alicia (EGD)

A mi familia (FJVP)

Índice general

1. Estadística Actuarial	1
1.1. Introducción	1
1.2. Breve historia de la estadística actuarial	4
1.3. Fuentes de información	8
2. Probabilidad	11
2.1. Introducción	11
2.2. Experimentos, espacio muestral y sucesos	11
2.2.1. Relaciones y operaciones con sucesos	12
2.3. Definición de probabilidad	14
2.3.1. Consecuencias de los axiomas	14
2.3.2. Fórmula de Laplace	16
2.4. Probabilidad condicionada	16
2.5. La regla del producto	17
2.6. Independencia de sucesos	17
2.7. Teorema de las probabilidades totales y teorema de Bayes	20
2.8. Problemas propuestos	22
3. Variables Aleatorias Unidimensionales	25
3.1. Introducción	25
3.2. Función de distribución de una variable aleatoria	26
3.3. Variables aleatorias discretas	29
3.4. Variables aleatorias continuas	30
3.5. Variables aleatorias mixtas	32
3.6. Características de las variables aleatorias	33
3.6.1. Esperanza matemática de una variable aleatoria	33
3.6.2. Varianza, desviación típica y momentos	36
3.6.3. Teorema de Markov y desigualdad de Chebyshev	39
3.6.4. Medidas de forma de una variable aleatoria	40
3.6.5. Cuantil de orden p y moda de una variable aleatoria	41
3.7. Transformaciones de variables aleatorias	42

3.8. Problemas propuestos	44
4. Variables Aleatorias Multidimensionales	47
4.1. Introducción	47
4.2. Variables aleatorias bidimensionales	47
4.2.1. Variable aleatoria bidimensional. Función de distribución bi- dimensional	47
4.2.2. Funciones de distribución marginales	48
4.2.3. Variables aleatorias bidimensionales discretas	49
4.2.4. Variables aleatorias bidimensionales continuas	50
4.2.5. Distribuciones condicionadas	52
4.2.6. Independencia de variables aleatorias	53
4.3. Momentos multivariantes	53
4.3.1. Covarianza y coeficiente de correlación lineal	54
4.4. Momentos condicionales	57
4.4.1. Esperanza condicionada	57
4.4.2. Varianza condicionada	59
4.5. Transformaciones de variables aleatorias	60
4.5.1. Caso discreto	60
4.5.2. Caso continuo	61
4.6. Problemas propuestos	65
5. Cantidades Aleatorias de uso en Estadística Actuarial	67
5.1. Introducción	67
5.2. Funciones de supervivencia y de azar	67
5.3. Vida residual media	71
5.4. Distribución estacionaria de renovación	72
5.5. Funciones generatriz, característica y generatriz de momentos	73
5.5.1. Función generatriz	74
5.5.2. Función característica	77
5.5.3. Función generatriz de momentos	79
5.5.4. Relaciones entre las tres funciones	82
5.5.5. Cumulantes y función generatriz de cumulantes	82
5.6. Transformaciones útiles en reaseguros	83
5.6.1. Transformación stop-loss	83
5.6.2. Variable límite de pérdida	85
5.6.3. Otras transformaciones	86
5.7. Mezclas de distribuciones	87
5.8. Estadísticos de orden	88
5.8.1. Distribuciones de extremos	38
5.8.2. Distribución de un estadístico de orden	89
5.9. Problemas propuestos	90

6. Distribuciones de tipo Discreto	93
6.1. Introducción	93
6.2. Distribución uniforme discreta	93
6.2.1. Convoluciones	94
6.3. Distribución de Bernoulli	95
6.4. Distribución binomial	96
6.4.1. Representación	96
6.4.2. Funciones generatriz y característica	97
6.4.3. Momentos	97
6.4.4. Convoluciones	98
6.4.5. Otras propiedades	98
6.5. Distribución de Poisson	99
6.5.1. Funciones generatriz y característica	101
6.5.2. Momentos	101
6.5.3. Límite de la distribución binomial	102
6.5.4. Convoluciones	103
6.5.5. Otras propiedades	103
6.6. Distribución hipergeométrica	105
6.7. Distribución geométrica o de Pascal	106
6.7.1. Funciones generatriz y característica	106
6.7.2. Momentos	107
6.7.3. Otras propiedades	107
6.8. Distribución binomial negativa	109
6.8.1. Funciones generatriz y característica	110
6.8.2. Momentos	110
6.8.3. Convoluciones	111
6.8.4. Distribuciones límites	111
6.8.5. Otras propiedades	111
6.9. Distribución logarítmica	113
6.10. Distribución multinomial	114
6.11. Sistemas de distribuciones	114
6.11.1. La clase de distribuciones $(a, b, 0)$	114
6.11.2. La clase de distribuciones $(a, b, 1)$	115
6.12. Distribuciones compuestas	116
6.13. Problemas propuestos	117
7. Distribuciones de tipo Continuo	119
7.1. Introducción	119
7.2. Distribución uniforme	120
7.2.1. Funciones característica y de momentos	120
7.2.2. La transformación integral	121
7.3. Distribución beta de primera especie	123
7.3.1. Transformaciones y relaciones	123

7.3.2. Características	124
7.3.3. Distribución beta con cuatro parámetros	125
7.4. Distribución normal	126
7.4.1. Características	129
7.4.2. Convoluciones	131
7.4.3. El teorema central del límite	132
7.5. Distribución log-normal	134
7.5.1. Momentos	135
7.5.2. Reproductividad	136
7.5.3. Distribución log-normal con tres parámetros	137
7.6. Distribuciones de Pareto	138
7.6.1. Génesis de las distribuciones de Pareto	139
7.6.2. Características	140
7.7. Distribución de Pareto generalizada	142
7.7.1. Características	144
7.8. Distribución inversa Gaussiana	145
7.8.1. Momentos	147
7.8.2. Convoluciones y distribuciones en el muestreo	147
7.9. Distribución exponencial	148
7.9.1. Características	148
7.10. Distribución gamma	151
7.10.1. Características	151
7.10.2. Convoluciones	152
7.10.3. Extensiones de la distribución gamma	153
7.11. Distribuciones de extremos	154
7.11.1. Distribución de Gumbel	154
7.11.2. Distribución de Weibull	157
7.11.3. Distribución de Fréchet	158
7.12. Distribuciones de Benktander	160
7.13. Distribuciones para la duración de una vida	161
7.13.1. Distribución de Gompertz	162
7.13.2. Distribución de Makeham	162
7.14. Distribuciones relacionadas con la normal	163
7.14.1. Distribución chi-cuadrado de Pearson	163
7.14.2. Distribución t de Student	164
7.14.3. Distribución F de Snedecor	165
7.15. Problemas propuestos	166
8. Inferencia Estadística	169
8.1. Introducción	169
8.2. Estimación puntual	169
8.3. Estimadores insesgados	171
8.4. Comparación de estimadores	172

8.5. Estimadores consistentes	176
8.6. Estimadores suficientes	179
8.7. Métodos de estimación	181
8.7.1. Método de los momentos	181
8.7.2. Estimadores de máxima verosimilitud	182
8.7.3. El delta método	190
8.7.4. Estimación eficiente de la varianza	191
8.8. Estimación por intervalos de confianza	194
8.9. Contraste de hipótesis	197
8.9.1. Contrastes unilaterales y bilaterales	203
8.9.2. Razón de verosimilitudes	207
8.10. Problemas propuestos	215
9. Estimación, Selección y Validación de Modelos	219
9.1. Introducción	219
9.2. Estimación de la distribución de Poisson	219
9.3. Estimación de la distribución binomial negativa	220
9.3.1. Estimadores de momentos	220
9.3.2. Estimadores de máxima verosimilitud	221
9.4. Estimación de la distribución logarítmica	222
9.5. Estimación de la distribución log-normal	223
9.5.1. Estimadores de momentos	223
9.5.2. Estimadores de máxima verosimilitud	224
9.6. Estimación de la distribución gamma	225
9.6.1. Estimadores de momentos	225
9.6.2. Estimadores de máxima verosimilitud	226
9.7. Estimación de la distribución Pareto tipo I	227
9.7.1. Estimadores de mínimos cuadrados	228
9.7.2. Estimadores de momentos	228
9.7.3. Estimadores de máxima verosimilitud	229
9.7.4. Estimadores por el método de los percentiles	230
9.7.5. Estimación con σ conocido	231
9.8. Distribución de Pareto tipo II	232
9.8.1. Estimadores de momentos	232
9.8.2. Estimadores de máxima verosimilitud	233
9.9. Estimación de la distribución inversa Gaussiana	233
9.9.1. Estimadores de momentos	234
9.9.2. Estimadores de máxima verosimilitud	234
9.10. Estimación de las distribuciones de extremos	234
9.10.1. Estimación de la distribución de Weibull	235
9.10.2. Estimación de la distribución de Gumbel	236
9.11. Selección y validación de modelos	237
9.12. Problemas propuestos	248

10. Elementos de Estadística Bayesiana	253
10.1. Introducción a la estadística bayesiana	253
10.2. Teorema de Bayes para el caso discreto y continuo	255
10.2.1. Uso secuencial del teorema de Bayes	263
10.2.2. La distribución predictiva	264
10.3. Estimación bayesiana puntual: intervalos y test de hipótesis	265
10.3.1. Estimación puntual	265
10.3.2. Intervalos bayesianos de credibilidad	266
10.3.3. Tests de hipótesis bayesianos	268
10.4. Inferencia bayesiana y teoría de la decisión	275
10.4.1. Funciones de pérdidas en estadística actuarial	276
10.4.2. Estimadores puntuales bayesianos	277
10.4.3. Tests de hipótesis	279
10.5. Problemas propuestos	281
11. Inferencia Bayesiana	283
11.1. Especificación de densidades a priori	283
11.1.1. Familias conjugadas	286
11.1.2. Densidades a priori no informativas	300
11.1.3. Críticas a la elicitación a priori	303
11.2. Análisis bayesiano para datos normales	304
11.2.1. Caso de media desconocida y varianza conocida	304
11.2.2. Caso de media conocida y varianza desconocida	309
11.2.3. Caso de media y varianza desconocida	310
11.2.4. Caso no informativo	311
11.3. Análisis bayesiano de datos binarios	314
11.3.1. Datos binarios en el caso discreto	315
11.3.2. Datos binarios en el caso continuo	318
11.3.3. Comparación de dos proporciones	331
11.4. Aspectos computacionales	336
11.4.1. Métodos de Monte Carlo	337
11.4.2. Métodos de Monte Carlo y Cadenas de Markov (MCMC)	341
11.4.3. Un modelo jerárquico para datos de frecuencia de reclamaciones con WinBUGS	347
11.4.4. Un modelo para la distribución predictiva para cantidades reclamadas con datos de reaseguros con WinBUGS	354
11.5. Problemas propuestos	358
12. Tarificación	363
12.1. Introducción	363
12.2. Principios de cálculo de prima	363
12.2.1. Propiedades	364
12.3. Prima de riesgo, colectiva y Bayes	366

12.4. La teoría de la credibilidad	377
12.4.1. Credibilidad total	378
12.4.2. Credibilidad parcial	380
12.4.3. Credibilidad e inferencia bayesiana	381
12.4.4. Modelo de Bühlmann de distribución libre	383
12.5. Sistemas bonus-malus	391
12.5.1. Cálculo de primas bonus-malus. Método bayesiano	392
12.5.2. Penalización de las sobrecargas	394
12.5.3. Método markoviano	400
12.6. Reaseguros	401
12.6.1. Reaseguro proporcional	402
12.6.2. Reaseguro excess loss	403
12.6.3. Reaseguro stop-loss	409
12.6.4. Otras formas de reaseguro	410
12.6.5. Franquicias	410
12.7. Problemas propuestos	411
13. Modelos de Riesgo Colectivo e Individual	413
13.1. Introducción	413
13.2. Modelo de riesgo colectivo	413
13.2.1. Resultados generales	415
13.2.2. Algunos modelos específicos	419
13.2.3. Fórmula de recursión de Panjer	424
13.2.4. Otras fórmulas de recursión	436
13.2.5. Aproximación de la cantidad total reclamada	438
13.2.6. Tarificación bajo el modelo colectivo compuesto	449
13.3. Modelo de riesgo individual	453
13.3.1. Cálculo directo mediante convolución	455
13.3.2. Fórmula de recursión de De Pril	456
13.3.3. Cálculo aproximado mediante el modelo colectivo	463
13.4. Problemas propuestos	465
14. El modelo IBNR	469
14.1. Introducción y conceptos básicos	469
14.2. El modelo log-normal	470
14.3. Un modelo más general	476
15. Teoría de la Ruina	487
15.1. Introducción	487
15.2. Proceso de riesgo	488
15.3. El problema de la ruina	488
15.3.1. Ruina con horizonte infinito	491
15.3.2. Ruina con horizonte finito	491

15.4. La probabilidad de supervivencia	491
15.5. Coeficiente de ajuste y desigualdad de Lundberg	495
15.6. Cálculo exacto y aproximado de la probabilidad de ruina. Cotas	497
15.6.1. Cálculo exacto de la probabilidad de ruina	497
15.6.2. Cálculo aproximado de la probabilidad de ruina	499
15.6.3. Cotas inferior y superior de la probabilidad de ruina	500
15.7. Problemas propuestos	505
A. Breve manual de FirstBayes	507
A.1. Presentación	507
A.2. Contenido	507
A.3. Instalación	508
A.4. Iniciando FirstBayes	508
A.5. Tratamiento de los datos	510
A.6. Cargar datos	510
A.7. Crear una nueva base de datos	511
A.8. APL data entry	512
A.9. Distribuciones	512
A.10. Algunas distribuciones	513
A.10.1. Distribución beta	513
A.10.2. Distribución binomial	513
A.10.3. Distribución gamma	513
A.10.4. Distribución normal	514
A.10.5. Distribución Poisson	514
A.11. Mezclas	515
A.12. Los seis análisis	516
A.13. Análisis beta-binomial	517
A.13.1. Datos	518
A.13.2. Incorporación de información a priori	519
A.13.3. Distribución a posteriori	521
A.14. Análisis gamma-Poisson	523
A.14.1. Datos	523
A.14.2. Incorporación de información a priori	525
A.14.3. Distribución a posteriori	525
A.15. Análisis normal con varianza conocida	526
A.15.1. Datos	527
A.15.2. Incorporación de información a priori	528
A.15.3. Distribución a posteriori	529

B. Breve manual de WinBUGS	531
B.1. Presentación	531
B.2. Especificando el modelo: distribución a priori y verosimilitud	532
B.3. Inferencia sobre una proporción	533
B.4. Ejecutando el modelo	534
B.5. Obteniendo la distribución a posteriori	537
B.6. Dos tasas de fallo, diferencia de tasas, riesgo relativo y odds ratio	542
B.7. Función <i>for</i>	546
B.8. Entrada de datos	547
B.8.1. Datos en forma de tablas	548
B.8.2. Importar datos de Excel	548
B.9. Datos normales y validez del modelo	548
B.10. Programación en Doodle	556
B.11. Recursos adicionales	561
Bibliografía	563
Índice	573

Capítulo 1

Estadística Actuarial

1.1. Introducción

La *Estadística o Matemática Actuarial* es la ciencia que proporciona las herramientas necesarias para el estudio de ciertas actividades económicas que llevan a cabo las compañías de seguros. Estas actividades aparecen generalmente ligadas al término *riesgo*, habitual en los escenarios actuariales. Por riesgo entendemos cualquier suceso que pueda ocurrir y que suponga una pérdida, generalmente cuantificable en términos económicos. Los profesionales que se dedican a esta tarea reciben el nombre de *actuarios*, personas especializadas en cálculos matemáticos y que tienen conocimientos estadísticos, económicos, jurídicos y financieros para determinar las tarifas de las aseguradoras o fijar las primas de un seguro.

La clasificación más simple de seguros es la que distingue entre *seguros no vida y seguros vida*. Los primeros, denominados también seguros generales, cubren la práctica totalidad de los seguros que habitualmente se contratan: seguro de automóviles, de accidentes, contra incendios, contra robos, hogar, etc. Por otro lado, un contrato de seguro de vida se establece entre una empresa aseguradora y una persona, el asegurado, bajo el que éste se compromete a hacer uno o más pagos de primas a la compañía mientras que ésta se compromete a pagar a la muerte del aquél una suma fija al o a los beneficiarios designados por el mismo.

Se denomina *asegurado* a la persona física o jurídica titular del bien o interés asegurado que está expuesto al riesgo. Generalmente el asegurado firma el contrato con el *asegurador*, aunque bien puede ser una persona distinta del beneficiario, que sería en este caso el *tomador del seguro*. Como contrapartida, el asegurador es la entidad que se encarga de dar cobertura al asegurado ante la imprevisión de riesgos que supongan una pérdida. Los riesgos en ocasiones se manifiestan en la forma de un siniestro. En este texto se hablará indistintamente de siniestro o reclamación, aunque en la práctica pudiera ocurrir un siniestro sin que se dé parte

del mismo a la compañía aseguradora (ver Artís et al., 1999, 2002). Esta situación, por otro lado habitual en ciertos ramos de seguros, será obviada en este texto. Por tanto, un siniestro es un suceso que produce un daño previsto en el contrato de seguro y que da lugar al cumplimiento de las obligaciones contraídas por la aseguradora mediante la reposición del bien o la indemnización al asegurado. El asegurador, dependiendo del contrato del seguro, asume la obligación del pago de la indemnización, cantidad que debe pagar una aseguradora si se produce un siniestro, o de realizar determinadas prestaciones. La relación entre el asegurado y el asegurador se establece por medio del *contrato de seguro*, documento por el que el asegurador se encarga de cubrir riesgos ajenos mediante el cobro de un precio denominado *prima*. El contrato se formaliza a través de la póliza, documento o documentos en el que se recogen los acuerdos entre el asegurado y la compañía de seguros. En el mismo deben constar por escrito el riesgo que se cubre, la suma asegurada, el importe de la prima, etc.

Las herramientas estadísticas necesarias para abordar los seguros vida son más sencillas que las necesarias para abordar los seguros no vida. Aunque la muerte es un suceso seguro, es incierto el momento en que se producirá, dependiendo de elementos como el sexo, edad, factores genéticos o hereditarios, estado de salud, forma de vida, guerras, etc. En líneas generales este tipo de seguros se fundamenta sobre la base de las tablas de mortalidad, resumen de los registros de vida de un grupo representativo de individuos suficientemente grande. En este texto no hacemos hincapié en este tipo de seguros, salvo cuando se trate el modelo de riesgo individual. Bajo una póliza de seguro no vida, sin embargo, los factores que influyen en el acontecimiento de un suceso contra el cual un bien puede asegurarse pueden ser múltiples y diversos. Por ejemplo, en el seguro de automóviles el acontecimiento de un siniestro puede obedecer a causas como la edad del conductor, antigüedad del vehículo, cilindrada del mismo, etc. En cualquiera de los casos, el asegurado paga una cantidad de dinero, la prima de seguro al asegurador, la compañía de seguros, y desde ese instante comienza la *cobertura* sobre el bien asegurado. Visto de esta forma el negocio del seguro no difiere, en principio, de cualquier otro tipo de negocio. La empresa aseguradora vende un producto, la seguridad, a cambio de un precio que es la prima. El producto que se comercializa, la seguridad, se garantiza a todos los clientes, aunque la entrega sólo se efectúa a una parte de los clientes. El tiempo juega además a favor del asegurador, ya que las indemnizaciones se reparten, posponiéndose y dando lugar, entretanto, a un montante de ahorro que forman las provisiones técnicas o reservas. Luego, desde un punto de vista financiero, el tomador de una póliza de seguros es el prestamista que proporciona el crédito al asegurador para que fabrique el producto (la seguridad), convirtiéndose el asegurador en un colocador de los fondos que no se consumen periódicamente de entre todos aquellos que le han sido prestados.

Sin embargo en el negocio del seguro aparecen incertidumbres para el asegurador que no suelen aparecer en otro tipo de negocio. Generalmente son de dos

tipos: el número de reclamaciones o siniestros y la cuantía de las mismas.

La estructura del texto es la siguiente. En los capítulos 2 al 10 se introducen las herramientas estadísticas básicas necesarias en estadística actuarial. En los capítulos 10 y 11 se estudiarán las herramientas estadísticas bayesianas, que juegan un papel destacado en el cálculo de primas de seguros.

Lo ideal, cuando se va a elaborar un procedimiento de cálculo de prima es trabajar con las variables aleatorias del número de reclamaciones y de la cuantía de las mismas para obtener lo que se denomina un *modelo compuesto*. Este será el objetivo de estudio del capítulo 13 en el que también se abordará el modelo de riesgo individual, igualmente aplicable a las carteras de seguros de vida. Puesto que no siempre resulta sencillo modelizar el riesgo conjugando ambas variables, en muchas ocasiones se trabaja bajo un *modelo no compuesto*, en el que las primas se calculan sólo utilizando la variable aleatoria número de reclamaciones o cuantía de las mismas. Este modelo, así como los distintos procedimientos de cálculo de prima existentes son objeto de estudio del capítulo 12, donde también se hace hincapié en el atractivo campo de la teoría de la *credibilidad*, así como en diversas modalidades de *reaseguro*. Un reaseguro no es más que el seguro de las compañías de seguros, de modo que si ven afectado su negocio por el volumen de primas contratadas, asegurarán parte de las mismas en otra compañía de seguros (reaseguradora).

El capítulo 14 está dedicado al modelo IBNR, donde consideraremos un amplio espectro de situaciones de reservas que pueden ajustarse a este modelo: reservas para reclamaciones pendientes, reservas para reclamaciones conocidas por la compañía pero no completamente pagadas, etc., y que estudiaremos desde una perspectiva bayesiana.

El negocio del seguro proporciona a la aseguradora unas reservas que se generan entre el momento del cobro de las primas y el pago de la indemnizaciones, y que habitualmente invierten. Sin embargo, pudiera darse el caso de que las indemnizaciones a pagar fueran mayores que las reservas existentes. Esta situación llevaría, por supuesto, a la insolvencia de la aseguradora. Por eso no es de extrañar que la estadística actuarial se ocupe también de estudiar cuándo puede ocurrir esto dadas las reservas iniciales con las que parte, las primas que va cobrando y las indemnizaciones que va pagando. Nos ocuparemos de este problema en el capítulo 15, en el que se estudiará la probabilidad de insolvencia o ruina de una compañía de seguros, dados los elementos anteriores. La teoría de la ruina o teoría del riesgo, iniciada por la escuela finlandesa de la mano de Lundberg a principios del siglo XX, trata este tipo de problemas, siendo una de las ramas de la estadística actuarial en la que más se ha trabajado en los últimos años. Una de las razones de este desarrollo ha sido la difusión en las últimas décadas de herramientas matemáticas y computacionales que han proporcionado la solución de problemas que antes, si estos elementos, eran imposibles de abordar.

Finalmente, hemos incluido dos apéndices de introducción a los paquetes informáticos que hemos utilizado en esta obra: FirstBayes y WinBUGS. Estos dos

apéndices resultan de mucha utilidad para la resolución de los ejemplos y ejercicios del texto, y constituyen sendos manuales introductorios de estos programas.

FirstBayes es un programa muy simple que es recomendado como ayuda al conocimiento y entendimiento de los métodos bayesianos. Este software es gratuito y puede obtenerse en:

<http://www.firstbayes.co.uk>

Estamos asistiendo a un importante desarrollo del análisis bayesiano gracias a la combinación de los procedimientos de simulación y cadenas de Markov (habitualmente denominadas metodologías MCMC) para la resolución de algunos problemas de mediana y gran complejidad. El trabajo pionero de Gelfand y Smith (1990) en el que se recuperan los trabajos de cadenas de Markov y métodos Monte Carlo de principios de 1950 y se redescubren los artículos de Metropolis y Hasting escritos en el ámbito de la física, así como el despegue en capacidad de cálculo y rapidez que hoy día puede presentar cualquier PC, han contribuido de manera directa a la existencia de gran número de artículos relacionados con modelos complejos, jerárquicos, no-paramétricos, etc. que pueden ser abordados desde una perspectiva bayesiana.

Hoy día el software libre disponible y de uso más universal es WinBUGS (Spiegelhalter et al., 2005) que consiste en un poderoso programa para llevar a cabo simulaciones MCMC. En aquellas situaciones en las que lo necesitemos será utilizado en este libro y se ha acompañado de un breve manual de usuario que aparece en el Apéndice B. Este programa ha contribuido al crecimiento de las aplicaciones bayesianas y puede ser obtenido gratuitamente en la dirección web:

<http://www.mrc-bsu.cam.ac.uk/bugs/>

Este libro está dedicado a la estadística actuarial de los seguros generales, con algunas referencias a los seguros de vida. Son numerosos los textos existentes dedicados a esta materia en lengua inglesa, existiendo muy pocos en español. Con esta obra se pretende cubrir este hueco aportando al mismo los elementos fundamentales de la estadística actuarial moderna.

1.2. Breve historia de la estadística actuarial

En esta sección haremos un breve recorrido histórico de los orígenes de la ciencia actuarial así como del camino que ha tomado esta disciplina y que le ha llevado a ser una de las más importantes dentro de las ciencias económicas y empresariales. Nos limitaremos sólo a comentar aquéllos aspectos de la estadística actuarial que están en relación con los temas tratados en este texto. El lector interesado en más información puede consultar el trabajo de Haberman (1996) o la dirección web

<http://www1.fee.uva.nl/ke/act/history.htm>

en la que hay una gran variedad de artículos históricos sobre la ciencia actuarial y la estadística así como un amplio catálogo que incluye la biografía de los autores más importantes en estadística y en las ciencias actuariales.

La ciencia actuarial, junto con los fundamentos estadísticos que vienen acompañadas, tiene un origen relativamente reciente, aunque el hecho de asegurarse frente a sucesos inciertos y que puedan dar lugar a pérdidas económicas es tan antiguo casi como la civilización moderna. Los primeros acuerdos sobre pagos que pudiéramos equiparar con primas de seguros que se tienen constancia, se remontan a la Grecia antigua. Existen citas de Demóstenes (alrededor de 300 a.c.) relacionadas con la seguridad del transporte marítimo de un cargamento de vino para prevenirse contra la estación de tormentas. Aunque la verdadera póliza de la que se tiene referencia data de 1350 cuando un transporte de trigo desde Sicilia a Túnez se aseguró por 300 florines con una prima del 18 por ciento para cubrir el retraso en la entrega.

La expansión cada vez mayor del transporte marítimo así como del mundo conocido trajo consigo un incremento en las relaciones comerciales y por tanto un aumento de la necesidad de asegurarse ante hechos inesperados.

El concepto de pensión, tal y como lo conocemos hoy en día, es aún más antiguo, existiendo referencias incluso en la Biblia. Cosa que ocurre también con la mayoría de los mecanismos actuariales existentes para salvaguardarse ante el riesgo. El primer contrato de reaseguro del que se tiene constancia data de 1370 cuando el asegurador Guilano Grillo contrató con Goffredo Benaira y Martino Sacco reasegurar parte del viaje que un barco debía realizar desde el puerto de Génova hasta el de Brujas. Según consta, Grillo ofreció asumir el riesgo del viaje hasta el puerto de Cádiz y transferir a Benaira y Sacco el riesgo que suponía el resto del trayecto. El desarrollo del reaseguro, en términos más parecidos a los actuales, se manifestó en los seguros contra incendios, de forma paralela a la revolución industrial, con la aparición de grandes infraestructuras fabriles que exigían, en caso de siniestros, grandes cantidades de indemnización. De hecho, es en 1846 cuando aparece la primera compañía de reaseguro en Alemania, la compañía de reaseguro de Colonia. A partir de aquí y con la llegada de la primera guerra mundial se extendió el negocio reasegurador. También fruto del desarrollo industrial y los nuevos medios de transporte surgen otros tipos de seguros destinados a cubrir otras nuevas eventualidades.

Sin embargo, hay que remontarse hasta el siglo XVII para encontrar lo que puede considerarse el primer documento de índole actuarial. Se trata de una memoria elaborada por Jan de Witt (que contaba con un cargo equivalente a lo que hoy en día sería Primer Ministro) en 1671 en Holanda, en la que se incluye un procedimiento para calcular anualidades vitalicias (anualidad cuyo pago continúa mientras el rentista viva) con las que pretendía sufragar los gastos de un enfrentamiento contra Francia.

Dos décadas más tarde, el astrónomo y uno de los primeros actuarios, Edmond Halley, elabora en 1693 un documento, publicado por la Royal Society, de nacimientos y muertes, incluyendo la edad, clasificados por sexo, en la ciudad de Wroclaw (Breslau), entonces alemana y hoy polaca, para el cálculo de tablas de mortalidad que permitiesen calcular anualidades vitalicias. El trabajo original de Edmond Halley puede encontrarse en Heywood (1985). Aunque este trabajo fue precedido durante las dos décadas anteriores por otros trabajos similares, puede considerarse como el punto de partida de la moderna ciencia actuarial.

Posteriormente, Leibniz y De Moivre se ocuparon de ajustar fórmulas matemáticas para las curvas de mortalidad empírica. Por aquella época, Nicholas Bernoulli proporcionó el primer documento en el que aparecía el concepto de esperanza de vida. Como nota curiosa, merece destacarse que en 1709 en su tesis doctoral, considera problemas de probabilidad relacionados con los seguros marítimos.

Como ocurre en el comienzo de muchas disciplinas relacionadas con las matemáticas, es indudable que el trabajo que se destaca es sólo aquél que ha tenido una mayor repercusión, aunque venga acompañando de la labor de otros investigadores, muchos de ellos matemáticos. Así, merecen destacarse los nombres de Abraham de Moivre, Leonhard Euler, Carl Friedrich Gauss, Thomas Simpson, William Morgan, Joshua Milne, Benjamin Gompertz, Charles Babbage, y otros tantos que se ocuparon también del cálculo de anualidades vitalicias o de los seguros de vida.

Al igual que la invención del cálculo produjo el avance de las ciencias físicas y económicas, el desarrollo experimentado por la teoría de la probabilidad y la estadística matemática desde finales del siglo XIX hizo posible un desarrollo paralelo de la estadística actuarial que podía dedicarse ahora a otros menesteres que no fueran solamente el cálculo de anualidades vitalicias. El desarrollo del negocio del seguro vida y de no vida que se produjo a finales del siglo XIX, llevó al nacimiento en norteamérica del *Institute of Actuaries* en 1848 y la *Faculty of Actuaries* en 1856, dando lugar a la primera publicación actuarial, *Journal of the Transactions*. Fue la época en que comenzó a impartirse enseñanza dedicada exclusivamente a la disciplina actuarial y en la que nació la profesión de actuario. En 1914 aparece los documentos actuariales publicados por la *Casualty Actuarial Society* en la forma de *proceedings*, que aún continúa.

La ciencia actuarial, tal y como la conocemos hoy día, tiene un origen reciente a principios del siglo XX, con los trabajos de la escuela finlandesa sobre la teoría del riesgo. Fue en 1909 cuando Filip Lundberg utiliza por vez primera el proceso de Poisson compuesto, desarrollado posteriormente por Harald Cramér a comienzo de la década de los 30 y otros autores suecos. A él se debe el moderno tratamiento de la teoría del riesgo colectivo tal y como se le conoce hoy en día, sin hacer referencia al riesgo individual. La importancia y originalidad del trabajo de Lundberg radica en el hecho de hacer uso por vez primera en el campo actuarial de la herramienta

de los procesos estocásticos. Calcula por vez primera la distribución de la cantidad total reclamada mediante convoluciones, estudia el reaseguro, así como el impacto de las reservas iniciales de la aseguradora sobre la solvencia de la misma, la ruina o supervivencia de la compañía aseguradora. En este terreno, introduce el concepto de coeficiente de ajuste y establece una cota superior a la probabilidad de ruina que hoy en día continúa utilizándose y sigue siendo fuente de investigaciones.

También de principios del siglo XX es el origen de la teoría de la credibilidad, una de las áreas más estudiadas de la estadística actuarial y que trata de medir la importancia que ha de tener la información de un individuo o contrato frente a la información del colectivo (la cartera de seguros) en relación a la prima que debe satisfacer. De ahí que con esta teoría se pretende estimar las primas de seguros a medida que se va obteniendo la experiencia de reclamaciones. Partiendo de ideas de Albert Whitney y Albert H. Mowbray basadas en argumentos heurísticos, Arthur L. Bailey, L.H. Longley-Cook, A.L. Mayerson, Hans Bühlmann, Erwin Straub y William S. Jewell, entre otros, se encargaron posteriormente de proporcionar a esta teoría un fundamento matemático que ha hecho de la misma una de las ramas más atractivas y estudiadas de la ciencia actuarial. Una de las principales aplicaciones de dicha teoría se presenta en el seguro de automóviles, en el que la prima inicial se va transformando sucesivamente a medida que se incorpora la información de la siniestralidad. Son los denominados *sistemas de tarificación bonus-malus*. Se parte de un nivel x neutro, de modo que para niveles superiores a x el asegurado entra en la escala *malus* y para niveles inferiores a x el asegurado entra en la escala *bonus*. Con este sistema el asegurado puede ver bonificada o penalizada su prima particular dependiendo de su propia experiencia de reclamaciones.

A finales de la década de los años 50 del siglo XX la ciencia actuarial había ya alcanzado la mayoría de edad. Era una disciplina autónoma y generadora de multitud de resultados estadísticos no sólo aplicable al terreno actuarial sino a otro tipo de materias relacionadas. Sin embargo, carecía de un medio de difusión propio similar a los existentes en otros campos científicos. De ahí que en 1957 se reuniese, en su decimoquinta sesión en New York, el Congreso Internacional de Actuarios (Congresos ASTIN) y en el que se culminó una dura labor de muchos años llevada a cabo por actuarios para la constitución de una revista dedicada exclusivamente a los seguros no vida. Este fue el comienzo de la revista *Astin Bulletin*, que vio aparecer su primer número en 1958. Esta publicación periódica fue el antecedente de otras prestigiosas publicaciones que han ido apareciendo, algunos de los cuales se recogen en la siguiente sección, y que ha dado lugar a la estadística actuarial, que abarca hoy en día mucho más de las iniciales tablas de mortalidad y anualidades vitalicias y que se confunde en muchas ocasiones con la matemática de las finanzas y la economía. Para hacernos una idea de la extensión que ocupa al día de hoy toda la materia actuarial, se ha concentrado todo el conocimiento actuarial en tres volúmenes de considerable grosor, en la Enciclopedia de las Ciencias Actuariales (*Encyclopedia of Actuarial Science*, John Wiley & Sons, 2004).

1.3. Fuentes de información

Las principales aportaciones a la estadística actuarial están recogidas en las siguientes publicaciones que se han catalogado de acuerdo a dos categorías (Colquitt, 2003):

- Revistas de riesgo y seguros.
 - Journal of Risk and Insurance.
 - Journal of Risk and Uncertainty.
 - Journal of Insurance Regulation.
 - Geneva Papers on Risk and Insurance Issues and Practice.
 - CPCU Journal.
 - Geneva Papers on Risk and Insurance Theory.
 - Journal of Financial Services Professionals.
 - Journal of Insurance Issues.
 - Benefits Quarterly.
 - Risk Management and Insurance Review.
- Revistas actuariales.
 - Insurance: Mathematics and Economics.
 - Astin Bulletin.
 - Scandinavian Actuarial Journal.
 - British Actuarial Journal. Convertido en The Annals of Actuarial Science.
 - North American Actuarial Journal.
 - Journal of Actuarial Practice.

Otras revistas de índole actuarial que caen fuera del catálogo de Colquitt (2003) son:

- Academic Actuary.
- Actuarial Research Clearing House.
- Asian-Pacific Risk and Insurance Association.
- Australian Actuarial Journal.

1.3. Fuentes de información

- Belgian Actuarial Bulletin.
- Demography and Population Studies.
- JIA-TFA volumes 1939–1994.
- Proceedings of the Casualty Actuarial Society.
- South African Actuarial Journal.
- The Actuary.
- The Future Actuary.

Algunas revistas de estadística teórica y aplicada que han publicado trabajos relacionados con temas actuariales son:

- Anales del Instituto de Actuarios Españoles.
- Annals of Mathematical Statistics.
- Communications in Statistics: Theory and Methods.
- Estadística Española.
- Estudios de Economía Aplicada.
- Journal of Applied Mathematics.
- Journal of Applied Probability.
- Journal of Applied Statistics.
- Journal of Econometrics.
- Journal of Statistical Planning and Inference.
- Journal of the American Statistical Association.
- Journal of the Royal Statistical Society.
- Statistics and Probability Letters.
- Statistical Methodology.
- Test.
- The Annals of Probability.

- Transactions of the American Mathematical Society.

Los principales congresos internacionales sobre la materia son:

- Actuarial and Financial Mathematics Day.
- Actuarial Research Conference.
- Brazilian Conference on Statistical Modelling in Insurance and Finance.
- Conference in Actuarial Science & Finance on Samos.
- Congresos ASTIN. Actuarial Studies in Non-Life Insurance.
- International Congress on Insurance: Mathematics and Economics.

Finalmente, incluimos algunas páginas web de interés:

- <http://actuarialrecruiter.com>
- <http://www.actuaries.org/>
- <http://www.actuaries.org.uk/>
- <http://www.aria.org/rts>
- <http://www.afshapiro.com/guestlecturer.html>
- <http://www.casact.org/>
- <http://www.city.ac.uk/actstat/dept/actlynx.html>
- <http://www.inese.es/>
- http://www.lviv-actuaries.org/en_links
- <http://www.ma.hw.ac.uk/~andrewc/amshome/actpages.html>
- <http://www.math.ucalgary.ca/~scollnik/balducci/ari.aotw.html>
- <http://www.soa.org/>
- <http://www1.fee.uva.nl/ke/act/actuariallinks.htm>

Capítulo 2

Probabilidad

2.1. Introducción

La probabilidad es la herramienta básica de la estadística actuarial. En este capítulo estudiaremos los conceptos básicos del cálculo de probabilidades. Comenzaremos con el concepto de probabilidad y la definición axiomática de Kolmogorov. Tras estudiar las consecuencias de los axiomas, veremos la regla de Laplace, que permite calcular probabilidades bajo la hipótesis de equiprobabilidad de los sucesos elementales. Continuaremos con los conceptos de probabilidad condicionada e independencia entre sucesos. El tema finaliza con dos importantes resultados sobre probabilidades como son el teorema de las probabilidades totales y el teorema de Bayes de especial aplicación en estadística actuarial.

2.2. Experimentos, espacio muestral y sucesos

Un experimento es un modo de obtener observaciones. Los experimentos se dividen en deterministas y aleatorios.

Definición 2.1 Se denomina *experimento determinista* al que al realizarse en idénticas condiciones, da siempre lugar al mismo resultado, y por tanto se puede predecir. Por el contrario, se denomina *experimento aleatorio* al que puede dar lugar a resultados diferentes, bajo las mismas condiciones experimentales.

A todo experimento aleatorio le asociamos un conjunto llamado espacio muestral, que denotaremos por Ω .

Definición 2.2 Se denomina *espacio muestral*, al conjunto de todos los posibles resultados asociados a un experimento aleatorio:

$$\Omega = \{w_1, w_2, \dots, w_n, \dots\}.$$

A los elementos w_k se les llama sucesos elementales y a los subconjuntos de Ω sucesos, los cuales representaremos mediante letras mayúsculas. El conjunto partes de Ω , $\mathcal{P}(\Omega)$, (conjunto compuesto por todos los conjuntos formados a partir de elementos de Ω), representa el conjunto de todos los sucesos asociados a un fenómeno aleatorio:

$$\mathcal{P}(\Omega) = \{\emptyset, \Omega, w_1, w_2, \dots, w_n, \{w_1, w_2\}, \dots\}.$$

Al conjunto vacío $\emptyset$ se le llama suceso imposible, y al total Ω suceso seguro.

2.2.1. Relaciones y operaciones con sucesos

A partir de un experimento aleatorio, podemos plantearnos diversas relaciones y operaciones con los sucesos que lo forman. Las dos relaciones más habituales entre sucesos son la inclusión y la igualdad.

- **Inclusión.** Se dice que un suceso A está contenido en otro B (representado mediante el símbolo $\subset$), si cualquier suceso elemental de A , lo está en B , es decir:

$$A \subset B \text{ si } \forall w \in A \Rightarrow w \in B.$$

- **Igualdad.** Dos sucesos son iguales si se verifica la doble inclusión entre ellos:

$$A = B \text{ si } A \subset B \text{ y } B \subset A.$$

Las principales operaciones con sucesos son la unión, la intersección, el complementario, la diferencia y la diferencia simétrica.

- **Unión.** El suceso unión está formado por la agrupación de los sucesos elementales de A y B :

$$A \cup B = \{w : w \in A \text{ ó } w \in B\}.$$

- **Intersección.** El suceso intersección de dos está formado por los sucesos elementales comunes a ambos sucesos:

$$A \cap B = AB = \{w : w \in A \text{ y } w \in B\}.$$

- **Complementario.** El suceso complementario de A lo forman los elementos del espacio muestral, que no pertenecen al suceso A :

$$A^c = \{w : w \notin A\}.$$

- **Diferencia.** El suceso diferencia de dos sucesos A y B , lo forman los elementos de A no comunes con B :

$$A - B = \{w : w \in A \text{ y } w \notin B\} = A \cap B^c = AB^c.$$

- **Diferencia simétrica.** La diferencia simétrica de dos sucesos lo forman los sucesos elementales no comunes de ambos:

$$A \Delta B = (A \cup B) - A \cap B = (A \cap B^c) \cup (A^c \cap B) = AB^c \cup A^c B.$$

Resultan de interés algunas leyes que relacionan las operaciones vistas, como son las leyes conmutativas, asociativas, distributivas y las leyes de De Morgan.

- **Leyes conmutativas:**

$$A \cup B = B \cup A,$$

$$A \cap B = B \cap A.$$

- **Leyes asociativas:**

$$A \cup (B \cap C) = (A \cup B) \cap C,$$

$$A \cap (B \cup C) = (A \cap B) \cup C.$$

- **Leyes distributivas:**

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

- **Leyes de De Morgan:**

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

Todas estas leyes se generalizan al caso de más de dos sucesos.

Los siguientes resultados permiten descomponer el espacio muestral en sucesos disjuntos y son útiles en el cálculo práctico de probabilidades. Comenzamos con una definición.

Definición 2.3 Se dice que dos sucesos A y B son disjuntos, incompatibles o mutuamente excluyentes, si no tiene elementos en común, es decir, si $A \cap B = \emptyset$.

Veamos cómo se descompone el espacio muestral en uniones disjuntas a partir de uno, dos o más sucesos. En primer lugar resulta claro que: $\Omega = A \cup A^c$. Ahora, con dos sucesos:

$$\Omega = \Omega \cap \Omega = (A \cup A^c) \cap (B \cup B^c) = AB \cup AB^c \cup A^c B \cup A^c B^c.$$

En el caso de tres sucesos A , B y C , el espacio muestral se descompone en ocho sucesos disjuntos dos a dos:

$$\begin{aligned} \Omega &= \Omega \cap \Omega \cap \Omega \\ &= (A \cup A^c) \cap (B \cup B^c) \cap (C \cup C^c) \\ &= AB^c C^c \cup ABC^c \cup ABC \cup ACB^c \cup B A^c C^c \cup B C A^c \cup C A^c B^c \cup A^c B^c C^c. \end{aligned}$$

2.3. Definición de probabilidad

La probabilidad proporciona una medida acerca de la ocurrencia de un suceso. Formalmente se trabaja con la definición axiomática propuesta por Kolmogorov.

Definición 2.4 Sea Ω un espacio muestral asociado a un experimento aleatorio. Una aplicación:

$$\begin{aligned} \Pr: \mathcal{P}(\Omega) &\rightarrow [0, 1] \\ A &\mapsto \Pr(A) \end{aligned}$$

que a cada suceso A le asigna un número real $\Pr(A)$ entre cero y uno es una probabilidad, si verifica los siguientes axiomas:

1. $\Pr(A) \geq 0$.
2. $\Pr(\Omega) = 1$.
3. Si $A_1, \dots, A_n$ son sucesos incompatibles dos a dos ($A_i \cap A_j = \emptyset$, $i \neq j$), entonces:

$$\Pr\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n \Pr(A_k).$$

Los tres axiomas de la probabilidad corresponden a propiedades heredadas de la frecuencia relativa.

Definición 2.5 Un espacio probabilístico es una pareja $(\Omega, \Pr)$ donde Ω es un espacio muestral y $\Pr$ una probabilidad definida sobre partes de Ω .

2.3.1. Consecuencias de los axiomas

A partir de los axiomas de la probabilidad se obtienen las siguientes consecuencias.

Teorema 2.1 Se verifican las siguientes propiedades:

1. La probabilidad del complementario de un suceso es:

$$\Pr(A^c) = 1 - \Pr(A).$$

2. La probabilidad del suceso imposible es cero:

$$\Pr(\emptyset) = 0.$$

3. Si $A \subset B$ entonces:

$$\begin{aligned} \Pr(A) &\leq \Pr(B), \\ \Pr(B - A) &= \Pr(B) - \Pr(A). \end{aligned}$$

2.3. Definición de probabilidad

4. La probabilidad de la unión de dos sucesos (no necesariamente disjuntos) viene dada por:

$$\Pr(A \cup B) = \Pr(A) + \Pr(B) - \Pr(A \cap B).$$

5. Si A, B y C son tres sucesos cualesquiera se verifica:

$$\Pr(A \cup B \cup C) = \Pr(A) + \Pr(B) + \Pr(C) - \Pr(AB) - \Pr(AC) - \Pr(BC) + \Pr(ABC).$$

Demostración:

1. Si escribimos: $\Omega = A \cup A^c \Rightarrow \Pr(\Omega) = \Pr(A) + \Pr(A^c) \Rightarrow 1 = \Pr(A) + \Pr(A^c)$.
2. Puesto que $\emptyset = \Omega^c \Rightarrow \Pr(\emptyset) = \Pr(\Omega^c) = 1 - \Pr(\Omega) = 0$.
3. Al verificarse $A \subset B$, entonces $B = A \cup (B - A)$, y se trata de una unión disjunta. Tomando probabilidades tenemos: $\Pr(B) = \Pr(A) + \Pr(B - A)$, de donde se siguen los resultados.
4. Se verifica que $A \cup B = A \cup (B - A) = A \cup BA^c$ y $B = BA \cup BA^c$ y se trata de dos uniones disjuntas. Tomando probabilidades tenemos que:

$$\begin{aligned} \Pr(A \cup B) &= \Pr(A) + \Pr(BA^c), \\ \Pr(B) &= \Pr(BA) + \Pr(BA^c). \end{aligned}$$

Restando miembro a miembro se sigue el resultado.

5. Escribiendo $\Pr((A \cup B) \cup C)$ y usando la consecuencia anterior, se obtiene el resultado.

La última de las propiedades se puede generalizar a la unión de n sucesos y recibe el nombre de principio de inclusión-exclusión:

$$\Pr(A_1 \cup \dots \cup A_n) = \sum_{k=1}^n \Pr(A_k) - \sum_{1 \leq k_1 < k_2 \leq n} \Pr(A_{k_1} A_{k_2}) + \dots + (-1)^{n+1} \Pr(A_1 \dots A_n).$$

El siguiente resultado, conocido como **la desigualdad de Bonferroni**, permite obtener cotas para la probabilidad anterior:

$$\sum_{k=1}^n \Pr(A_k) - \sum_{k_1 < k_2} \Pr(A_{k_1} A_{k_2}) \leq \Pr(A_1 \cup \dots \cup A_n) \leq \sum_{k=1}^n \Pr(A_k).$$

2.3.2. Fórmula de Laplace

La fórmula de Laplace es una regla práctica que permite calcular probabilidades en espacios probabilísticos que cumplen la hipótesis de equiprobabilidad. Supongamos un espacio muestral finito $\Omega = \{w_1, w_2, \dots, w_n\}$, donde los sucesos elementales son equiprobables, es decir $\Pr(w_i) = \Pr(w_j)$, $i \neq j$. Entonces si $A \subset \Omega$, la fórmula:

$$\Pr(A) = \frac{\text{Número de elementos de } A}{\text{Número de elementos de } \Omega} = \frac{\text{Casos favorables}}{\text{Casos posibles}},$$

define una probabilidad.

2.4. Probabilidad condicionada

En algunas ocasiones, a la hora de calcular la probabilidad de un suceso, ésta puede variar si se recibe una información adicional que nos lleva a corregir la probabilidad original. Supongamos que se lanza un dado y queremos calcular la probabilidad de que salga un 6. Si representemos por A este suceso, se verifica que:

$$\Pr(A) = \frac{1}{6}.$$

Sin embargo, si alguien que ha visto el resultado de la tirada nos informa que ha salido un número par, suceso que representamos por B , nuestra afirmación sobre $\Pr(A)$ será otra. De este modo, a la hora de calcular la probabilidad de A por la regla de Laplace, los casos posibles se habrán reducido considerablemente, y nuestro espacio muestral se restringe al de los números pares. Por tanto:

$$\Pr(A|B) = \frac{1}{3} = \frac{\Pr(AB)}{\Pr(B)}.$$

Definición 2.6 Sea $(\Omega, \Pr)$ un espacio probabilístico y B un suceso tal que $\Pr(B) > 0$. Llamaremos probabilidad del suceso A condicionada por B (sabiendo que ha ocurrido el suceso B) a la expresión:

$$\Pr(A|B) = \frac{\Pr(A \cap B)}{\Pr(B)}. \quad (2.1)$$

El siguiente resultado prueba que la fórmula (2.1) cumple los axiomas de la probabilidad.

Teorema 2.2 Sea $(\Omega, \Pr)$ un espacio probabilístico y B un suceso tal que $\Pr(B) > 0$. La aplicación definida por la fórmula de la probabilidad condicionada:

$$\Pr(\cdot|B) : \mathcal{P}(\Omega) \rightarrow [0, 1]$$

$$A \mapsto \Pr(A|B) = \frac{\Pr(A \cap B)}{\Pr(B)},$$

es una probabilidad genuina.

2.5. La regla del producto

A la hora de entender una probabilidad condicionada, el suceso condicionante B , hay que verlo como un suceso que ha ocurrido, y que nos permitirá recalcular la probabilidad de A . Por otro lado, al ser la probabilidad condicionada una nueva probabilidad, podemos aplicar todas las consecuencias de los axiomas de la probabilidad, por ejemplo:

$$\begin{aligned} \Pr(A^c|B) &= 1 - \Pr(A|B) \\ \Pr(A_1 \cup A_2|B) &= \Pr(A_1|B) + \Pr(A_2|B) - \Pr(A_1 A_2|B). \end{aligned}$$

Al calcular una probabilidad condicionada pueden darse tres posibles situaciones, que dan lugar a tres posibles interpretaciones:

$$\begin{aligned} \Pr(A|B) &> \Pr(A) &\implies B \text{ informa positivamente sobre } A, \\ \Pr(A|B) &< \Pr(A) &\implies B \text{ informa negativamente sobre } A, \\ \Pr(A|B) &= \Pr(A) &\implies B \text{ es independiente de } A. \end{aligned}$$

2.5. La regla del producto

Si en la expresión de la probabilidad condicionada se despeja la probabilidad de la intersección de los dos sucesos se verifica la siguiente fórmula, llamada regla del producto:

$$\Pr(AB) = \Pr(A) \Pr(B|A),$$

mediante la cual la probabilidad de que ocurran simultáneamente A y B es igual a la probabilidad de que ocurra A , por la probabilidad de que ocurra B , dado que ha ocurrido A . Esta fórmula tiene especial utilidad cuando los sucesos ocurren de forma secuencial en el tiempo, de modo que el resultado de un suceso depende del resultado obtenido por el suceso anterior. Para el caso de n sucesos tenemos el siguiente teorema.

Teorema 2.3 Sean $A_1, A_2, \dots, A_n$ sucesos tales que $\Pr(\bigcap_{i=1}^n A_i) > 0$. Se verifica entonces que,

$$\Pr(A_1 A_2 \cdots A_n) = \Pr(A_1) \Pr(A_2|A_1) \Pr(A_3|A_1 A_2) \cdots \Pr(A_n|A_1 A_2 \cdots A_{n-1}).$$

Demostración: Desarrollando la parte derecha de la igualdad se simplifican todas las probabilidades excepto $\Pr(A_1 \cdots A_n)$, y se obtiene el resultado. ■

2.6. Independencia de sucesos

Dos sucesos A y B se dice que son independientes si la ocurrencia de uno de ellos no influye en la ocurrencia del otro. Tenemos la siguiente definición.

Definición 2.7 Se dice que dos sucesos A y B son independientes, si se verifica una de las siguientes condiciones equivalentes:

$$\begin{aligned}\Pr(A|B) &= \Pr(A), \\ \Pr(B|A) &= \Pr(B), \\ \Pr(AB) &= \Pr(A)\Pr(B).\end{aligned}$$

De las tres condiciones consideradas, las dos primeras son las más intuitivas, puesto que expresan que los sucesos A y B son independientes si la ocurrencia de uno de ellos no influye en la ocurrencia del otro. La tercera de las condiciones no es tan fácil de interpretar, sin embargo es la más utilizada para probar analíticamente la independencia de dos sucesos.

Teorema 2.4 Si A y B son sucesos independientes, se verifica que:

1. A es independiente de B^c ,
2. A^c es independiente de B ,
3. A^c es independiente de B^c .

Demostración:

1. Basta probar que $\Pr(B^c|A) = \Pr(B^c)$. Efectivamente:

$$\Pr(B^c|A) = 1 - \Pr(B|A) = 1 - \Pr(B) = \Pr(B^c).$$

2. Igual que el apartado anterior cambiando los papeles de A y B .
3. Veamos que $\Pr(A^c B^c) = \Pr(A^c)\Pr(B^c)$:

$$\begin{aligned}\Pr(A^c B^c) &= 1 - \Pr(A \cup B) \\ &= 1 - \Pr(A) - \Pr(B) + \Pr(A)\Pr(B) \\ &= (1 - \Pr(A))(1 - \Pr(B)) \\ &= \Pr(A^c)\Pr(B^c).\end{aligned}$$

El concepto de independencia puede extenderse a más de dos sucesos.

Definición 2.8 Los sucesos $A_1, A_2, \dots, A_n$ se dice que son independientes si para cada $1 \leq i_1 < \dots < i_k \leq n$ se verifica,

$$\Pr(A_{i_1} \cap \dots \cap A_{i_k}) = \Pr(A_{i_1}) \dots \Pr(A_{i_k}).$$

2.6. Independencia de sucesos

En particular, tres sucesos A, B, C son mutuamente independientes o simplemente independientes, si se verifican las condiciones:

$$\begin{aligned}\Pr(AB) &= \Pr(A)\Pr(B), \\ \Pr(AC) &= \Pr(A)\Pr(C), \\ \Pr(BC) &= \Pr(B)\Pr(C), \\ \Pr(ABC) &= \Pr(A)\Pr(B)\Pr(C).\end{aligned}$$

Las tres primeras condiciones expresan la independencia de dos cualesquiera de ellos, mientras que la cuarta condición indica que la ocurrencia simultánea de dos de ellos, no debe influir en el tercero. Pueden existir tres sucesos independientes dos a dos, pero no independientes entre sí, al fallar la cuarta condición.

Ejemplo 2.1 En una determinada población, la probabilidad que una persona padezca la enfermedad A es 0,2 mientras que la probabilidad de que padezca la enfermedad B es 0,3 independientemente de la enfermedad A . Se elige de la población una persona al azar. Obtener la probabilidad de que padezca:

1. Sólo la enfermedad A .
2. Ninguna de las dos enfermedades.
3. Una de las dos enfermedades, pero no las dos.

Solución:

1. Se trata de calcular $\Pr(AB^c)$:

$$\begin{aligned}\Pr(AB^c) &= \Pr(A)\Pr(B^c) \\ &= \Pr(A)(1 - \Pr(B)) \\ &= 0,2 \cdot 0,7 = 0,14 = 14\%,\end{aligned}$$

puesto que A y B son independientes.

2. Se trata del suceso intersección de los complementarios:

$$\begin{aligned}\Pr(A^c B^c) &= \Pr(A^c)\Pr(B^c) \\ &= (1 - \Pr(A))(1 - \Pr(B)) \\ &= 0,8 \cdot 0,7 = 0,56 = 56\%.\end{aligned}$$

3. El suceso exactamente una de las dos enfermedades viene dado por:

$$AB^c \cup A^c B = A \Delta B,$$

que es la diferencia simétrica. Al verificarse $AB \subset A \cup B$, se tiene que:

$$\begin{aligned}\Pr(A \Delta B) &= \Pr((A \cup B) - AB) = \Pr(A \cup B) - \Pr(AB) \\ &= \Pr(A) + \Pr(B) - 2\Pr(AB) = 0,2 + 0,3 - 2 \cdot 0,2 \cdot 0,3 \\ &= 0,38 = 38\%.\end{aligned}$$

◇

2.7. Teorema de las probabilidades totales y teorema de Bayes

El siguiente teorema permite obtener la probabilidad de un suceso, cuando se conocen las probabilidades condicionadas de dicho suceso por medio de un conjunto de sucesos que forman una partición. Es el llamado teorema de las probabilidades totales.

Teorema 2.5 (Teorema de las probabilidades totales) Sea $(\Omega, \Pr)$ un espacio probabilístico y $\{B_i\}$, $i = 1, 2, \dots, n$ sucesos que forman una partición de Ω , es decir $\Omega = \bigcup_{i=1}^n B_i$ y $B_i \cap B_j = \emptyset$, $\forall i \neq j$. Entonces, si A es un suceso cualquiera se verifica:

$$\Pr(A) = \sum_{k=1}^n \Pr(AB_k) = \sum_{k=1}^n \Pr(A|B_k) \Pr(B_k). \quad (2.2)$$

Demostración: Usando la definición de partición:

$$\Pr(A) = \Pr(A \cap \Omega) = \Pr(A \cap (\bigcup_{k=1}^n B_k)) = \Pr(\bigcup_{k=1}^n (A \cap B_k)) = \sum_{k=1}^n \Pr(A \cap B_k),$$

puesto que los sucesos B_k son disjuntos dos a dos. La expresión final se obtiene usando la definición de probabilidad condicionada. ■

El siguiente resultado es conocido como el teorema de Bayes.

Teorema 2.6 (Teorema de Bayes) Sea $(\Omega, \Pr)$ un espacio probabilístico y $\{B_i\}$, $i = 1, 2, \dots, n$ sucesos que forman una partición de Ω , es decir $\Omega = \bigcup_{i=1}^n B_i$ y $B_i \cap B_j = \emptyset$, $\forall i \neq j$. Entonces, si A es un suceso cualquiera con $\Pr(A) > 0$, se verifica que:

$$\Pr(B_i|A) = \frac{\Pr(A|B_i) \Pr(B_i)}{\sum_{k=1}^n \Pr(A|B_k) \Pr(B_k)}, \quad (2.3)$$

para $i = 1, 2, \dots, n$.

Demostración: Por la definición de probabilidad condicionada y por la regla del producto tenemos:

$$\Pr(B_i|A) = \frac{\Pr(A \cap B_i)}{\Pr(A)} = \frac{\Pr(A|B_i) \Pr(B_i)}{\Pr(A)}.$$

Ahora, si a $\Pr(A)$ se le aplica el teorema de las probabilidades totales dado en (2.2) se obtiene el resultado. ■

El teorema de Bayes es igualmente válido en el caso de una partición infinita de Ω .

Ejemplo 2.2 Una compañía de seguros de automóviles divide a sus asegurados en dos grupos G_1 y G_2 en proporciones p y $1-p$ respectivamente, donde $0 < p < 1$. La probabilidad de que un asegurado del primer grupo tenga un accidente es r_1 , mientras que esa probabilidad es r_2 para un asegurado del segundo grupo, donde $0 < r_i < 1$, $i = 1, 2$. La probabilidad de que un individuo del grupo $i = 1, 2$ tenga un primer accidente es independiente de la que tenga un segundo accidente. Se elige al azar un asegurado de la compañía. Se pide:

1. Probabilidad de que tenga un primer accidente.
2. Si el asegurado ha tenido un primer accidente, hallar la probabilidad de que pertenezca al primer grupo.
3. Suponiendo que este asegurado ha tenido un primer accidente, hallar la probabilidad de que tenga un segundo accidente. Probar que esta probabilidad es siempre mayor que la de tener un primer accidente.

Solución:

1. Representamos por A_1 el suceso tener un primer accidente. La probabilidad de tener un accidente depende del grupo de pertenencia. Por el teorema de las probabilidades totales,

$$\begin{aligned}\Pr(A_1) &= \Pr(A_1 \cap G_1) + \Pr(A_1 \cap G_2) \\ &= \Pr(A_1|G_1) \Pr(G_1) + \Pr(A_1|G_2) \Pr(G_2) \\ &= r_1 p + r_2 (1-p).\end{aligned}$$

2. Se trata de calcular $\Pr(G_1|A_1)$. Por el teorema de Bayes,

$$\Pr(G_1|A_1) = \frac{\Pr(A_1 \cap G_1)}{\Pr(A_1)} = \frac{\Pr(A_1|G_1) \Pr(G_1)}{\Pr(A_1)} = \frac{r_1 p}{r_1 p + r_2 (1-p)}.$$

3. Se trata de calcular la siguiente probabilidad:

$$\Pr(A_2|A_1) = \frac{\Pr(A_1 \cap A_2)}{\Pr(A_1)},$$

donde A_2 representa el suceso tener un segundo accidente. Para el cálculo de la probabilidad del numerador condicionamos por el grupo de pertenencia:

$$\Pr(A_1 \cap A_2) = \Pr(A_1 \cap A_2|G_1) \Pr(G_1) + \Pr(A_1 \cap A_2|G_2) \Pr(G_2),$$

puesto que $\Pr(A_1 \cap A_2|G_i) = r_i^2$, $i = 1, 2$, se tiene que:

$$\Pr(A_2|A_1) = \frac{r_1^2 p + r_2^2 (1-p)}{r_1 p + r_2 (1-p)}.$$

Se verifica que $\Pr(A_2|A_1) \geq \Pr(A_1)$ puesto que:

$$\begin{aligned} \Pr(A_2|A_1) \geq \Pr(A_1) &\iff r_1^2 p + r_2^2 (1-p) \geq (r_1 p + r_2 (1-p))^2 \\ &\iff r_1^2 + r_2^2 \geq 2r_1 r_2 \iff (r_1 - r_2)^2 \geq 0. \end{aligned}$$

Notar que A_1 y A_2 son condicionalmente independientes dado el grupo de pertenencia, pero en general no son independientes.

◇

2.8. Problemas propuestos

- Sean A y B sucesos tales que $\Pr(A \Delta B) = 0$. Probar que necesariamente $\Pr(A) = \Pr(B)$.
- Una compañía de seguros de automóviles clasifica a sus asegurados en cuatro grupos de edad. La siguiente tabla recoge la proporción de asegurados dentro de cada grupo de edad, junto con la probabilidad de tener un accidente.

Grupo de edad	Proporción de asegurados	Probabilidad de accidente
18 - 25	0,10	0,07
25 - 45	0,40	0,04
45 - 60	0,30	0,02
+60	0,20	0,05

Se elige al azar un asegurado de la compañía.

- a) Probabilidad de que tenga un accidente.

2.8. Problemas propuestos

- b) El asegurado ha tenido un accidente. Obtener las probabilidades de que pertenezca a cada uno de los grupos. Representar gráficamente estas probabilidades, junto con las probabilidades de pertenencia a cada grupo.
3. A una reunión internacional de estadística actuarial acuden n personas, de las que n_1 hablan inglés, n_2 hablan francés y el resto hablan los dos idiomas. Si se eligen dos congresistas al azar, probar que la probabilidad de que se entiendan es:
- $$\frac{n(n-1) - 2n_1 n_2}{n(n-1)}.$$
4. Estudiar los casos en que los sucesos A_1 y A_2 definidos en el ejemplo 2.2 son independientes.
5. Una compañía de seguros de automóviles trabaja con cuatro modelos de autos: M_1 , M_2 , M_3 y M_4 . Con la información disponible se ha elaborado la siguiente tabla.

Modelo	Proporción de vehículos	Probabilidad de accidente
M_1	0,27	0,03
M_2	0,17	0,02
M_3	0,35	0,05
M_4	0,21	0,04

Un automóvil de uno de los modelos M_2 , M_3 y M_4 ha tenido un accidente. Hallar la probabilidad de que el modelo que ha tenido el accidente haya sido el M_3 .

Capítulo 3

Variables Aleatorias Unidimensionales

3.1. Introducción

Las variables aleatorias son el principal instrumento para modelizar los fenómenos aleatorios de la estadística actuarial. Una variable aleatoria es un valor numérico asociado al resultado de un experimento aleatorio. Ejemplos de variables aleatorias son el número de accidentes en que incurre un asegurado, el número de caras que se obtienen al lanzar diez monedas, la distribución del coste de un accidente, etc. Los diferentes tipos de variables aleatorias se corresponden con los diferentes tipos de datos: existen variables discretas, continuas y mixtas, que a su vez pueden ser unidimensionales, bidimensionales o n -dimensionales, dependiendo que se observe una, dos o n características. Toda variable aleatoria tiene asociada dos tipos de funciones: la función de distribución y la función de densidad, que se corresponden con el polígono de frecuencias acumuladas y el histograma, respectivamente, estudiados en estadística descriptiva. En este tema estudiaremos las variables aleatorias unidimensionales junto con sus diferentes características.

Definición 3.1 Sea (Ω, Pr) un espacio probabilístico asociado a un experimento aleatorio. Una aplicación $X : \Omega \longrightarrow \mathbb{R}$ que a cada suceso elemental le asocia un número real, es una variable aleatoria si para cualquier valor de x el conjunto $\{w : -\infty < X(w) \leq x\}$, es un suceso.

3.2. Función de distribución de una variable aleatoria

La función de distribución de una variable aleatoria permite conocer cómo se reparte la probabilidad sobre los valores que toma la variable.

Definición 3.2 La función de distribución asociada a una variable aleatoria es una función que a cada número real x le asocia la probabilidad de que la variable tome valores menores o iguales que x . Se define como:

$$F(x) = \Pr(w / -\infty < X(w) \leq x) = \Pr(-\infty < X \leq x) = \Pr(X \leq x), \quad (3.1)$$

donde $x \in \mathbb{R}$.

La función de distribución representa la probabilidad acumulada hasta el punto x . Veamos un ejemplo de función de distribución.

Ejemplo 3.1 Consideremos el experimento consistente en lanzar dos veces una moneda y la variable aleatoria X número de caras obtenidas. Obtener su función de distribución.

Solución: Si C representa obtener cara y Z obtener cruz, el espacio muestral es $\Omega = \{CC, CZ, ZC, ZZ\}$. La variable X toma tres valores: 0, 1 y 2. La función de probabilidad es:

$$\Pr(X = 0) = \Pr(ZZ) = \Pr(Z) \Pr(Z) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4},$$

$$\Pr(X = 1) = \Pr(CZ) + \Pr(ZC) = \Pr(C) \Pr(Z) + \Pr(Z) \Pr(C) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2},$$

$$\Pr(X = 2) = \Pr(CC) = \Pr(C) \Pr(C) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Aplicando la definición 3.1 a las probabilidades anteriores obtenemos:

$$F(x) = \Pr(X \leq x) = \begin{cases} 0 & \text{si } x < 0, \\ 1/4 & \text{si } 0 \leq x < 1, \\ 3/4 & \text{si } 1 \leq x < 2, \\ 1 & \text{si } x \geq 2, \end{cases} \quad (3.2)$$

La función (3.2) es una función escalonada, y corresponde a una variable aleatoria de tipo discreto. La figura 3.1 representa la función de distribución. $\diamond$

Toda función de distribución satisface ciertas propiedades. El siguiente resultado caracteriza a las funciones de distribución.

3.2. Función de distribución de una variable aleatoria




Figura 3.1: Función de distribución asociada al lanzamiento de dos monedas

Teorema 3.1 La función $F(x)$ es una función de distribución si y sólo si satisface las siguientes cuatro condiciones:

1. $F(x)$ es una función monótona no decreciente: si $x_1 \leq x_2$ entonces $F(x_1) \leq F(x_2)$.
2. Se verifica que $F(-\infty) = 0$, es decir $\lim_{x \rightarrow -\infty} F(x) = 0$.
3. Se verifica que $F(\infty) = 1$, es decir $\lim_{x \rightarrow \infty} F(x) = 1$.
4. $F(x)$ es continua por la derecha: $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$.

La función de distribución permite calcular diversos tipos de probabilidades de la variable aleatoria. Si representemos:

$$F(a-) = \lim_{x \rightarrow a-} F(x) = \Pr(X < a),$$

se verifica que:

- $\Pr(X \leq b) = F(b),$
- $\Pr(a < X \leq b) = F(b) - F(a),$
- $\Pr(X < b) = F(b-),$
- $\Pr(a < X < b) = F(b-) - F(a).$

Ejemplo 3.2 Un ejemplo de función de distribución es:

$$F(x) = \frac{1}{1 + e^{-x}}, \quad -\infty < x < \infty. \quad (3.3)$$

La función $F(x)$ se conoce como función de distribución *logística*. Probar que se trata de una función de distribución genuina.

Solución: Veamos que (3.3) satisface las condiciones del teorema 3.1. Derivando $F(x)$:

$$\frac{d}{dx} F(x) = \frac{e^{-x}}{(1 + e^{-x})^2} > 0,$$

de donde $F(x)$ es creciente. Por otro lado:

$$\lim_{x \rightarrow -\infty} F(x) = \frac{1}{1 + e^{\infty}} = 0,$$

y

$$\lim_{x \rightarrow \infty} F(x) = \frac{1}{1 + e^{-\infty}} = 1.$$

Finalmente, $F(x)$ no sólo es continua por la derecha, sino que es continua en todo $x \in \mathbb{R}$, lo que prueba que (3.3) es una función de distribución genuina. El gráfico de $F(x)$ aparece en la figura 3.2.




Figura 3.2: Función de distribución logística

◇

Existen tres tipos de variables aleatorias que corresponden a tres tipos de función de distribución. Los ejemplos de funciones de distribución (3.2) y (3.3) corresponden, respectivamente, a variables aleatorias de tipo discreto y continuo. Las variables aleatorias mixtas tienen una parte discreta y una parte continua. Pasamos al estudio de los tres tipos de variables aleatorias.

3.3. Variables aleatorias discretas

Definición 3.3 Una variable aleatoria X se dice que es discreta si el conjunto de valores que toma con probabilidad no nula es finito o infinito numerable.

Supongamos que $X = \{x_1, \dots, x_n, \dots\}$ representan los valores que toma la variable aleatoria.

Definición 3.4 La probabilidad con que la variable toma cada uno de los posibles valores:

$$\Pr(X_1 = x_1), \dots, \Pr(X_n = x_n), \dots \quad (3.4)$$

se le denomina función de densidad discreta o función de cuantía.

A (3.4) la llamaremos función de densidad discreta, función de cuantía o simplemente función de probabilidad. Esta función verifica dos propiedades:

1. $0 \leq \Pr(X = x_i) \leq 1$, $i = 1, 2, \dots$
2. $\sum_{i=1}^{\infty} \Pr(X = x_i) = 1$.

A partir de la función de densidad se puede obtener fácilmente la función de distribución, sin más que acumular las correspondientes probabilidades:

$$F(x) = \Pr(X \leq x) = \sum_{\{x_i: x_i \leq x\}} \Pr(X = x_i).$$

Recíprocamente, se puede obtener la función de densidad a partir de la función de distribución sin más que restar la función de distribución de dos valores consecutivos:

$$\Pr(X = x_i) = \Pr(X \leq x_i) - \Pr(X \leq x_{i-1}) = F(x_i) - F(x_{i-1}).$$

La representación gráfica de una función de distribución discreta es una función escalonada, donde los saltos se producen en los valores que toma la variable.

Ejemplo 3.3 La demanda diaria de un producto es una variable aleatoria de tipo discreto con función de densidad:

$$\Pr(X = x) = \frac{x+1}{15}, \quad x = 0, 1, 2, 3, 4. \quad (3.5)$$

Probar que (3.5) es una función de densidad genuina y hallar $\Pr(X \geq 2)$.

Solución: Puesto que $0 \leq \Pr(X = x) \leq 1$ y:

$$\sum_{x=0}^4 \Pr(X = x) = 1,$$

se trata de una función de densidad genuina. Ahora:

$$\Pr(X \geq 2) = \sum_{x=2}^4 \Pr(X = x) = \frac{3}{15} + \frac{4}{15} + \frac{5}{15} = \frac{12}{15} = \frac{4}{5}.$$

◇

3.4. Variables aleatorias continuas

Definición 3.5 Una variable aleatoria se dice que es continua si puede tomar (con probabilidad no nula) los infinitos valores de un intervalo.

Para este tipo de variables, la función de distribución se puede expresar como la integral de una determinada función $f(x)$, llamada *función de densidad*, de modo que:

$$F(x) = \Pr(X \leq x) = \int_{-\infty}^x f(t)dt.$$

Esta función de densidad representa el histograma ideal de la variable, cuando disponemos de una gran cantidad de datos y el número de clases es grande. Utilizando el teorema fundamental del cálculo, si $f(x)$ es continua, tenemos la relación:

$$\frac{d}{dx} F(x) = f(x).$$

Definición 3.6 La función de densidad $f_X(x)$ de una variable aleatoria continua X es la función que satisface la relación:

$$F_X(x) = \int_{-\infty}^x f_X(t)dt, \text{ para todo } x.$$

Para que una función $f_X(x)$ sea la función de densidad de una variable aleatoria continua sólo hacen falta dos condiciones.

Teorema 3.2 Una función $f_X(x)$ es una función de densidad de una variable aleatoria continua X si y sólo si:

1. Es no negativa:

$$f_X(x) \geq 0, \forall x \in \mathbb{R}. \quad (3.6)$$

3.4. Variables aleatorias continuas

2. La integral en toda la recta es igual a la unidad:

$$\int_{-\infty}^{\infty} f_X(x)dx = 1. \quad (3.7)$$

Un aspecto importante de las variables aleatorias continuas es que la probabilidad de un valor individual es siempre cero, es decir, si X es una variable aleatoria continua:

$$\Pr(X = x) = 0,$$

y por tanto:

$$\Pr(a \leq X \leq b) = \Pr(a < X \leq b) = \Pr(a \leq X < b) = \Pr(a < X < b).$$

En variables aleatorias continuas sólo tiene sentido calcular las probabilidades de intervalos de valores. Para el cálculo de probabilidades podemos usar tanto la función de densidad como la función de distribución. La relación entre las dos funciones es muy sencilla. La función de distribución es la integral de la función de densidad y la función de densidad es la derivada de la función de distribución:

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x f_X(t)dt, \\ f_X(x) &= \frac{d}{dx} F_X(x). \end{aligned}$$

La función de densidad en el caso continuo *no representa una probabilidad*, si bien admite una interpretación en términos probabilísticos. Si escribimos:

$$\begin{aligned} f_X(x) = \frac{d}{dx} F_X(x) &= \lim_{h \rightarrow 0} \frac{F_X(x+h) - F_X(x)}{h} \\ &= \lim_{h \rightarrow 0} \frac{\Pr(X \leq x+h) - \Pr(X \leq x)}{h} \\ &= \lim_{h \rightarrow 0} \frac{\Pr(x < X \leq x+h)}{h}, \end{aligned}$$

de donde podemos interpretar la función de densidad de una variable continua como la cantidad de probabilidad por unidad de intervalo infinitesimal.

Las siguientes fórmulas permiten calcular probabilidades de variables continuas por medio de la función de distribución o la función de densidad:

$$\begin{aligned} \Pr(a < X \leq b) &= F_X(b) - F_X(a) = \int_a^b f_X(x)dx, \\ \Pr(X > a) &= 1 - \Pr(X \leq a) = 1 - F_X(a) = \int_a^{\infty} f_X(x)dx, \\ \Pr(X \leq b) &= F_X(b) = \int_{-\infty}^b f_X(x)dx = 1 - \int_b^{\infty} f_X(x)dx. \end{aligned}$$

3.5. Variables aleatorias mixtas

Una variable aleatoria X tiene una distribución mixta si tiene una parte continua y otra discreta. Es decir, existe función $f(\cdot)$ y un conjunto de números reales x_i con probabilidades $\Pr(X = x_i) > 0$, $i \geq 1$ tales que para cada $A \subset \mathbb{R}$ se verifica,

$$\Pr(X \in A) = \int_A f(x)dx + \sum_{x_i \in A} \Pr(X = x_i).$$

Las variables aleatorias de tipo mixto surgen de modo natural en seguros generales. Veamos el siguiente ejemplo

Ejemplo 3.4 Supongamos que la variable aleatoria X representa las pérdidas de un asegurado. La compañía aseguradora impone un deducible de d y un beneficio límite de m . En consecuencia, la cantidad a pagar por las pérdidas X es,

$$Y = g(X) = \begin{cases} 0 & \text{si } 0 \leq X \leq d, \\ X - d & \text{si } d < X \leq m, \\ m - d & \text{si } X > m. \end{cases}$$

Obtener la distribución de Y .

Solución: Es claro que si X tiene una distribución de tipo continuo, entonces $Y = g(X)$ es de tipo mixto. La función de distribución de Y es,

$$F_Y(y) = \Pr(Y \leq y) = \begin{cases} 0 & \text{si } y < 0, \\ F_X(y + d) & \text{si } 0 \leq y < m - d, \\ 1 & \text{si } y \geq m - d, \end{cases}$$

donde F_X es la función de distribución de las pérdidas X . La parte continua de la Y tiene función de densidad,

$$f_Y(y) = \begin{cases} f_X(y + d) & \text{si } 0 < y < m - d, \\ 0 & \text{en otro caso,} \end{cases}$$

donde f_X representa la función de densidad de la X , mientras que la parte discreta de Y tiene función de probabilidad,

$$f_Y(y) = \begin{cases} F_X(d) & \text{si } y = 0, \\ 1 - F_X(m-) & \text{si } y = m - d, \\ 0 & \text{en otro caso.} \end{cases}$$

◇

Ejemplo 3.5 La función de distribución de una variable aleatoria mixta viene dada por,

$$F(x) = \Pr(X \leq x) = \begin{cases} 0 & \text{si } x < 0, \\ \frac{2(x+1)}{10} & \text{si } 0 \leq x < 1, \\ \frac{(x-1)^2 + 7}{10} & \text{si } 1 \leq x < 2, \\ 1 & \text{si } x \geq 2. \end{cases}$$

3.6. Características de las variables aleatorias

1. Obtener $\Pr(X = 0)$, $\Pr(X = 1)$ y $\Pr(X = 2)$.
2. Identificar la parte discreta y la parte continua de la función de distribución.

Solución:

1. Notar que la función de distribución no es continua en $x = 0, 1$ y 2 . Tenemos que:

$$\begin{aligned} \Pr(X = 0) &= F(0) - F(0-) = \frac{2}{10} - 0 = \frac{2}{10}, \\ \Pr(X = 1) &= F(1) - F(1-) = \frac{7}{10} - \frac{4}{10} = \frac{3}{10}, \\ \Pr(X = 2) &= F(2) - F(2-) = 1 - \frac{8}{10} = \frac{2}{10}. \end{aligned}$$

2. La parte discreta es la obtenida en el apartado anterior. La parte continua se obtiene derivando $F(x)$:

$$f(x) = \begin{cases} \frac{2}{10} & \text{si } 0 \leq x < 1, \\ \frac{2(x-1)}{10} & \text{si } 1 \leq x < 2, \\ 0 & \text{si en otro caso.} \end{cases}$$

Se trata de una función de densidad genuina puesto que:

$$\begin{aligned} \sum_x \Pr(X = x) + \int_{-\infty}^{\infty} f(x)dx &= \sum_{x=0}^2 \Pr(X = x) + \int_0^1 \frac{2}{10} dx + \int_1^2 \frac{2(x-1)}{10} dx \\ &= \frac{2}{10} + \frac{3}{10} + \frac{2}{10} + \frac{2}{10} + \frac{1}{10} \\ &= 1. \end{aligned}$$

◇

3.6. Características de las variables aleatorias

3.6.1. Esperanza matemática de una variable aleatoria

Definición 3.7 Sea X una variable aleatoria discreta que toma los valores $X = \{x_1, x_2, \dots\}$ con probabilidades $\Pr(X = x_i)$, $i = 1, 2, \dots$. Llamaremos media, esperanza matemática o valor esperado de X , a la cantidad:

$$\mu_X = E(X) = \sum_{i=1}^{\infty} x_i \Pr(X = x_i),$$

siempre que la serie anterior sea absolutamente convergente. Si X es una variable aleatoria continua con función de densidad $f_X(x)$, la media, esperanza matemática o valor esperado se define como:

$$\mu_X = E(X) = \int_{-\infty}^{\infty} x f_X(x) dx,$$

siempre que el valor de la integral sea finito.

La esperanza matemática de una variable aleatoria X de tipo mixto es,

$$\mu_X = E(X) = \int x f(x) dx + \sum x_i \cdot \Pr(X = x_i),$$

que corresponde a obtener la media de la parte discreta y de la parte continua.

La esperanza de una variable se suele representar mediante la letra griega μ . El siguiente resultado permite obtener la esperanza matemática por medio de la función de distribución

Teorema 3.3 Sea X una variable aleatoria continua y positiva con función de distribución $F_X(x)$ y media finita. Entonces, la esperanza matemática se puede obtener de forma alternativa por medio de la expresión:

$$E(X) = \int_0^{\infty} [1 - F_X(x)] dx. \quad (3.8)$$

Demostración: Integrando por partes: $u = 1 - F_X(x)$, $dv = dx$:

$$E(X) = [x(1 - F_X(x))]_0^{\infty} + \int_0^{\infty} x f_X(x) dx,$$

de donde se sigue la expresión. ■

Ejemplo 3.6 Se considera una variable aleatoria de tipo exponencial con función de distribución:

$$F(x) = 1 - \exp(-x/\lambda), \text{ si } x \geq 0$$

y $F(x) = 0$ si $x < 0$, donde $\lambda > 0$. Obtener μ_X .

Solución: Utilizando (3.8), la media se obtiene como:

$$E(X) = \int_0^{\infty} [1 - F_X(x)] dx = \int_0^{\infty} e^{-x/\lambda} dx = \lambda.$$

◇

En el caso general, si g es una transformación de X se verifica que:

$$E[g(X)] = \sum_{i=1}^{\infty} g(x_i) \Pr(X = x_i),$$

y en el caso continuo:

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

Cuando la serie o la integral que definen la esperanza son divergentes, es decir, con valor infinito, se dice que la variable X no tiene esperanza, o que X no presenta una regularidad media. Algunas propiedades de la esperanza matemática se presentan en el siguiente teorema.

Teorema 3.4 La esperanza matemática cumple las siguientes propiedades:

1. La media es el centro de gravedad de la variable:

$$E(X - E(X)) = 0.$$

2. La media es un operador lineal:

$$\begin{aligned} E(a + bX) &= a + bE(X), \\ E(g_1(X) + g_2(X)) &= E(g_1(X)) + E(g_2(X)). \end{aligned}$$

3. Si $a \leq g(x) \leq b$, para todo x , entonces $a \leq E(g(X)) \leq b$.

4. Si X es una variable aleatoria simétrica respecto de c (es decir, su función de densidad verifica $f(x+c) = f(c-x)$, para cualquier valor de x) entonces: $E(X) = c$, siempre que exista la correspondiente serie o integral.

Ejemplo 3.7 Sea X variable aleatoria continua de tipo exponencial con función de densidad:

$$f(x) = \frac{1}{\lambda} e^{-x/\lambda}, \quad x \geq 0$$

y $f(x) = 0$ en otro caso. Obtener $E(X)$.

Solución: Veamos que $E(X) = \lambda$.

$$\begin{aligned} E(X) &= \int_0^{\infty} \frac{1}{\lambda} x e^{-x/\lambda} dx = \int_0^{\infty} \frac{1}{\lambda} \lambda t e^{-t} \lambda dt \\ &= \lambda \int_0^{\infty} t e^{-t} dt = \lambda \Gamma(2) \\ &= \lambda, \end{aligned}$$

tras realizar el cambio de variable $x/\lambda = t$, $dx/\lambda = dt$, y donde

$$\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt, \quad (3.9)$$

con $x > 0$, representa la función gamma.

◇

Ejemplo 3.8 Se considera la variable aleatoria continua con función de densidad $f(x) = 1/x^2$ si $x > 1$. Obtener, si es posible, $E(X)$.

Solución: Veamos que la esperanza vale infinito:

$$E(X) = \int_1^{\infty} \frac{x}{x^2} dx = \int_1^{\infty} \frac{1}{x} dx = [\ln(x)]_1^{\infty} = \infty.$$

◇

3.6.2. Varianza, desviación típica y momentos

La varianza de una variable aleatoria es una medida de dispersión y permite estudiar la representatividad de la media.

Definición 3.8 Sea X una variable aleatoria con esperanza μ_X .

- Se define la varianza de X como la esperanza del cuadrado de la diferencia entre la variable y su esperanza. Se representa por σ_X^2 o $\text{Var}(X)$:

$$\sigma_X^2 = \text{Var}(X) = E(X - \mu_X)^2. \quad (3.10)$$

Una expresión alternativa de (3.10) es:

$$\sigma_X^2 = E(X^2) - \mu_X^2. \quad (3.11)$$

- La desviación típica es la raíz cuadrada positiva de la varianza, y se representa por σ_X .

La expresión (3.11) se obtiene directamente de (3.10) puesto que:

$$\begin{aligned} E(X - \mu_X)^2 &= E(X^2 - 2X\mu_X + \mu_X^2) \\ &= E(X^2) - 2\mu_X E(X) + \mu_X^2 \\ &= E(X^2) - \mu_X^2. \end{aligned}$$

El siguiente resultado prueba algunas propiedades importantes de la varianza y la desviación típica.

3.6. Características de las variables aleatorias

Teorema 3.5 Se verifican las siguientes propiedades:

- La varianza es siempre no negativa, $\text{Var}(X) \geq 0$. Además:

$$\text{Var}(X) = 0 \iff X = c \text{ con } c \text{ constante.}$$

- Si definimos la variable:

$$Y = a + bX,$$

entonces:

$$\begin{aligned} \text{Var}(Y) &= b^2 \cdot \text{Var}(X), \\ \sigma_Y &= |b| \cdot \sigma_X. \end{aligned}$$

- Si X es una variable aleatoria con media μ_X y varianza σ_X^2 y definimos la variable tipificada como:

$$Z = \frac{X - \mu_X}{\sigma_X},$$

se verifica que:

$$E(Z) = 0, \text{ y } \text{Var}(Z) = 1.$$

Demostración: Veamos la prueba de la segunda propiedad:

$$\begin{aligned} \text{Var}(a + bX) &= E(a + bX - E(a + bX))^2 \\ &= E(a + bX - a - bE(X))^2 \\ &= E(bX - bE(X))^2 \\ &= b^2 E(X - E(X))^2 \\ &= b^2 \text{Var}(X). \end{aligned}$$

La prueba del resto de los resultados se propone como ejercicio. ■

Ejemplo 3.9 El salario de un comercial de seguros consta de una cantidad anual fija de 12 mil euros más una cantidad variable igual al 10% del valor de las realizadas. Las ventas anuales son aleatorias, con una media de 150 mil euros y una desviación típica de 40 mil. Hallar la media y la desviación típica de los ingresos anuales.

Solución: Los ingresos anuales vienen dados por (en miles de euros):

$$Y = 12 + 0,1 \cdot X,$$

donde X es una variable aleatoria tal que $\mu_X = 150$ y $\sigma_X = 40$. Usando las propiedades antes vistas:

$$\begin{aligned} \mu_Y &= 12 + 0,1 \cdot \mu_X = 12 + 0,1 \cdot 150 = 27, \\ \sigma_Y &= 0,1 \cdot \sigma_X = 0,1 \cdot 40 = 4. \end{aligned}$$

◇

Ejemplo 3.10 Sea X variable aleatoria continua de tipo exponencial con función de densidad: $f(x) = (1/\lambda)e^{-x/\lambda}$ si $x \geq 0$ y $f(x) = 0$ si $x < 0$. Obtener $\text{Var}(X)$.

Solución: Veamos que $\text{Var}(X) = \lambda^2$. Comenzamos calculando $E(X^2)$:

$$\begin{aligned} E(X^2) &= \int_0^{\infty} \frac{1}{\lambda} x^2 e^{-x/\lambda} dx = \int_0^{\infty} \frac{1}{\lambda} \lambda^2 t^2 e^{-t} \lambda dt \\ &= \lambda^2 \int_0^{\infty} t^2 e^{-t} dt = \lambda^2 \Gamma(3) \\ &= 2\lambda^2 \end{aligned}$$

de donde: $\text{Var}(X) = E(X^2) - \mu^2 = 2\lambda^2 - \lambda^2 = \lambda^2$. Hemos realizado nuevamente el cambio de variable $x/\lambda = t$.

◇

Definición 3.9 Dada una variable aleatoria X , se denomina momento de orden r con respecto al origen (o momento de orden r no centrado) a la cantidad:

$$\alpha_r = E(X^r), \quad r = 1, 2, \dots \quad (3.12)$$

Se denomina momento central del orden r (o momento de orden r) con respecto a la media μ :

$$\mu_r = E(X - \mu_X)^r, \quad r = 1, 2, \dots$$

Según estas definiciones, la esperanza matemática es el primer momento respecto del origen:

$$\alpha_1 = E(X) = \mu_X,$$

y la varianza es el momento de orden dos respecto de la media:

$$\mu_2 = E(X - \mu_X)^2 = \sigma_X^2.$$

Nótese que siempre $\mu_1 = 0$. Los momentos centrales respecto de la media se pueden obtener a partir de los momentos respecto del origen por medio de la fórmula:

$$\mu_r = E(X - \mu_X)^r = \sum_{k=0}^r (-1)^k \binom{r}{k} \alpha_{r-k} \mu_X^k, \quad r = 1, 2, \dots$$

Ejemplo 3.11 Obtener los momentos respecto del origen de la variable aleatoria continua con función de densidad:

$$f_X(x) = 2x, \quad \text{si } 0 < x < 1,$$

y $f_X(x) = 0$ en otro caso.

3.6. Características de las variables aleatorias

Solución: Usando la definición (3.12) para una variable aleatoria continua tenemos que:

$$\alpha_r = E(X^r) = \int_0^1 2x^{r+1} dx = \frac{2}{r+2}, \quad r = 1, 2, \dots$$

En particular:

$$\mu_X = \alpha_1 = \frac{2}{3}.$$

◇

3.6.3. Teorema de Markov y desigualdad de Chebyshev

Dada una variable aleatoria X con media μ y desviación típica σ , los intervalos centrados en μ de amplitud $2k\sigma$ con $k > 0$, concentran una gran parte de la probabilidad de la variable. Los siguientes resultados permiten obtener cotas para estas probabilidades.

Teorema 3.6 (Teorema de Markov) Sea X una variable aleatoria positiva y r, ϵ constantes positivas. Se verifica entonces que:

$$\Pr(X \geq \epsilon) \leq \frac{E(X^r)}{\epsilon^r}. \quad (3.13)$$

Demostración: Probaremos el resultado en el caso continuo:

$$\begin{aligned} E(X^r) &= \int_{-\infty}^{\infty} x^r f_X(x) dx = \int_{x \geq \epsilon} x^r f_X(x) dx + \int_{x < \epsilon} x^r f_X(x) dx \\ &\geq \int_{x \geq \epsilon} x^r f_X(x) dx \geq \int_{x \geq \epsilon} \epsilon^r f_X(x) dx \\ &= \epsilon^r \int_{x \geq \epsilon} f_X(x) dx = \epsilon^r \Pr(X \geq \epsilon), \end{aligned}$$

de donde se sigue el resultado. ▮

Teorema 3.7 (Desigualdad de Chebyshev) Sea X una variable aleatoria con media μ y varianza σ^2 finita. Entonces, para cada $\epsilon > 0$ se tiene que:

$$\Pr(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2},$$

Además, para cada $k > 0$, se verifica que:

$$\Pr(\mu - k\sigma < X < \mu + k\sigma) \geq 1 - \frac{1}{k^2}. \quad (3.14)$$

Demostración: Al escribir la desigualdad de Markov (3.13) en términos de la variable $|X - \mu|$ con $r = 2$, resulta la desigualdad de Chebyshev:

$$\Pr(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

Haciendo $\varepsilon = k\sigma$, donde $k > 0$, obtenemos la relación:

$$\Pr(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2},$$

y mediante complementarios:

$$\Pr(\mu - k\sigma < X < \mu + k\sigma) \geq 1 - \frac{1}{k^2},$$

puesto que $|X - \mu| < k\sigma$ equivale a $-k\sigma < X - \mu < k\sigma$.

Por medio de la desigualdad de Chebyshev (3.14) haciendo $k = 2$, podemos afirmar que para una variable aleatoria X con media μ_X y desviación típica σ_X , el intervalo:

$$(\mu_X - 2\sigma_X, \mu_X + 2\sigma_X),$$

contiene al menos el 75 % de la probabilidad, y haciendo $k = 3$ el intervalo

$$(\mu_X - 3\sigma_X, \mu_X + 3\sigma_X),$$

contiene al menos 88,9 % del total de la probabilidad.

3.6.4. Medidas de forma de una variable aleatoria

Las medidas de forma de una variable aleatoria aportan información sobre el aspecto de la función de densidad.

Definición 3.10 Se denominan coeficientes de asimetría y curtosis a las cantidades:

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{E(X - \mu)^3}{[E(X - \mu)^2]^{3/2}},$$

y

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3 = \frac{E(X - \mu)^4}{[E(X - \mu)^2]^2} - 3.$$

La interpretación de estos dos coeficientes es la siguiente. Si una variable aleatoria es simétrica, entonces $\gamma_1 = 0$. Distribuciones con $\gamma_1 > 0$ se dice que presentan *asimetría positiva*, y distribuciones con $\gamma_1 < 0$ *asimetría negativa*. La distribución normal verifica que $\gamma_2 = 0$. Distribuciones de este tipo se las denomina *mesocúrticas*; si $\gamma_2 > 0$ se las denomina *leptocúrticas* y si $\gamma_2 < 0$ *platicúrticas*. Ambos coeficientes son invariantes frente a cambios de origen y de escala.

3.6. Características de las variables aleatorias

3.6.5. Cuantil de orden p y moda de una variable aleatoria

Definición 3.11 El cuantil de orden p es aquel valor de la distribución que deja a la izquierda una probabilidad acumulada de p .

El p -cuantil x_p verifica la relación:

$$\Pr(X < x_p) \leq p \leq \Pr(X \leq x_p).$$

De este modo, si F es una función de distribución continua, el p -cuantil x_p se obtiene fácilmente como la solución en x_p de la ecuación:

$$F(x_p) = p,$$

es decir, $x_p = F^{-1}(p)$, donde F^{-1} es la función inversa de la F .

Definición 3.12 Los cuartiles son los p -cuantiles de órdenes 0,25; 0,5 (mediana) y 0,75.

Definición 3.13 La moda de una variable aleatoria corresponde al valor de máxima probabilidad.

La moda no tiene porqué existir y puede no ser única. En el caso discreto la moda corresponde al valor o valores con mayor probabilidad. En el caso continuo, la moda se obtiene calculando el máximo de la función de densidad. Si X es una variable aleatoria continua con función de densidad $f_X(x)$ derivable, entonces la moda x_0 , se puede obtener como la solución de la ecuación $f'_X(x_0) = 0$, y comprobando que $f''_X(x_0) < 0$.

Ejemplo 3.12 Hallar la moda de la variable aleatoria continua X con función de densidad:

$$f_X(x) = xe^{-x}, \quad x > 0$$

y $f_X(x) = 0$ si $x < 0$.

Solución: La derivada primera de $f_X(x)$ es:

$$f'_X(x) = e^{-x} - xe^{-x}.$$

Igualando a cero y resolviendo obtenemos que $x = 1$. Veamos que este valor corresponde a un máximo y por tanto es la moda. Efectivamente:

$$f''_X(x) = -2e^{-x} + xe^{-x}; \quad f''_X(1) = -e^{-1} < 0.$$

◇

3.7. Transformaciones de variables aleatorias

Sea X una variable aleatoria discreta que toma los valores $\{x_1, \dots, x_n, \dots\}$ con probabilidades $\Pr(X = x_i)$, $i = 1, 2, \dots$. Si definimos la nueva variable:

$$Y = g(X),$$

estamos interesados en la obtención de su función de densidad. Como paso previo calculamos los nuevos valores que toma la variable Y :

$$y_1 = g(x_1), \dots, y_n = g(x_n), \dots$$

y, a continuación, determinamos la probabilidad de cada uno de estos valores:

$$\Pr(Y = y_i) = \Pr(x_i : g(x_i) = y_i) = \sum_I \Pr(X = x_i),$$

donde $I = \{x_i : g(x_i) = y_i\}$.

El siguiente teorema proporciona la función de distribución de la variable transformada a partir de la función de distribución de la variable original.

Teorema 3.8 Sea X una variable aleatoria con función de distribución $F_X(x)$. Sea $Y = g(X)$ una transformación de X .

(a) Si g es una función creciente en el soporte de X , entonces:

$$F_Y(y) = F_X(g^{-1}(y)).$$

(b) Si g es una función decreciente en el soporte de X y X es una variable aleatoria continua:

$$F_Y(y) = 1 - F_X(g^{-1}(y)).$$

Demostración: Si suponemos que g es creciente, su función de distribución es:

$$F_Y(y) = \Pr(Y \leq y) = \Pr(g(X) \leq y) = \Pr(X \leq g^{-1}(y)) = F_X(g^{-1}(y)).$$

Ahora, si g es monótona decreciente, la función de distribución es (suponiendo X continua):

$$\begin{aligned} F_Y(y) &= \Pr(Y \leq y) = \Pr(g(X) \leq y) \\ &= \Pr(X \geq g^{-1}(y)) = 1 - \Pr(X < g^{-1}(y)) \\ &= 1 - F_X(g^{-1}(y)). \end{aligned}$$

El resultado que presentamos a continuación permite obtener la función de densidad de la variable transformada en el caso de variables aleatorias continuas.

3.7. Transformaciones de variables aleatorias

Teorema 3.9 Sea X una variable aleatoria continua con función de densidad $f_X(x)$ e $Y = g(X)$, donde g es una función monótona. Supongamos que $f_X(x)$ es continua en el soporte de X y que $g^{-1}(y)$ tiene derivada continua. Entonces la función de densidad de Y es:

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|. \quad (3.15)$$

Demostración: Por del teorema 3.3 y la regla de la cadena obtenemos:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \begin{cases} f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y) & \text{si } g \text{ es creciente,} \\ -f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y) & \text{si } g \text{ es decreciente,} \end{cases}$$

y estas dos fórmulas pueden escribirse de una forma compacta como (3.15). ▢

Ejemplo 3.13 Consideremos una variable aleatoria de tipo continuo X con función de densidad:

$$f_X(x) = e^{-x}, \quad x \geq 0,$$

y $f_X(x) = 0$ si $x < 0$. Hallar la función de densidad de las nuevas variables aleatorias:

$$1. Y = 5 + X,$$

$$2. Y = \log(X).$$

Solución:

1. Al tratarse de transformaciones monótonas en el dominio de la variable $x \geq 0$ aplicaremos la fórmula (3.15). La transformación $y = 5 + x$ es monótona creciente, y la inversa es $x = y - 5$. Por tanto:

$$f_Y(y) = f_X(y - 5) \left| \frac{d}{dy} (y - 5) \right| = e^{-(y-5)}, \quad \text{si } y > 5.$$

2. La transformación $y = \log(x)$ es monótona creciente, puesto que $d \log x / dx = 1/x > 0$ si $x > 0$. La transformación inversa es $x = e^y$. Aplicando nuevamente (3.15) tenemos:

$$f_Y(y) = f_X(e^y) |e^y| = \exp(y - e^y), \quad \text{si } -\infty < y < \infty.$$

3.8. Problemas propuestos

1. Sea X una variable aleatoria continua no negativa con función de distribución $F(x)$.

a) Probar que,

$$E(X^2) = 2 \int_0^{\infty} x[1 - F(x)]dx.$$

b) Si $r = 1, 2, \dots$ entonces,

$$E(X^r) = \int_0^{\infty} rx^{r-1}[1 - F(x)]dx.$$

- c) Usando los resultados de a) y b) obtener $E(X^r)$ para una variable aleatoria con función de distribución $F(x) = 1 - x^{-\alpha}$ si $x > 1$, donde $\alpha > 0$.
2. Una compañía de seguros conoce que la distribución del coste de un determinado siniestro se distribuye según una variable aleatoria continua con función de densidad:

$$f(x) = \frac{k}{(1+x)^3}, \quad 0 < x < \infty$$

y $f(x) = 0$ si $x < 0$.

- a) Hallar el valor de k .
- b) Obtener la función de distribución. Probabilidad que el coste de un siniestro sea mayor que 1.
- c) Hallar los cuartiles del coste del siniestro.
- d) Coste medio del siniestro.
3. Obtener los cuartiles de la variables aleatoria exponencial cuya función de distribución viene definida por,

$$F(x) = 1 - e^{-x}, \quad \text{si } x > 0$$

y $F(x) = 0$ si $x < 0$. Obtener los coeficientes de asimetría y curtosis.

4. El período de garantía de un electrodoméstico es de 5 años, de modo que si falla por primera vez durante ese período será reemplazado por uno nuevo. Se supone que el tiempo de vida X (en años) de dicho electrodoméstico tiene como función de densidad $f(x) = 1/6$ si $0 < x < 6$. Hallar la media y la desviación típica del tiempo de vida de la máquina hasta que ocurre el primer fallo.

3.8. Problemas propuestos

5. El número de reclamaciones que recibe una compañía de seguros sobre un determinado siniestro es una variable aleatoria discreta con función de cuantía dada en la tabla adjunta.

- a) Media μ y desviación típica σ del número de reclamaciones.
- b) Hallar la probabilidad de los sucesos $|X - \mu| \geq 2\sigma$ y $|X - \mu| \geq 3\sigma$ exactamente y de modo aproximado haciendo uso de la desigualdad de Chebyshev.

X	0	1	2	3	4	5	6
$\Pr(X = x)$	0,12	0,35	0,21	0,16	0,09	0,05	0,02

Capítulo 4

Variables Aleatorias Multidimensionales

4.1. Introducción

En este tema estudiaremos las variables aleatorias multidimensionales, donde ahora se miden dos o más características, como pueden ser las pérdidas de dos o más riesgos relacionados o la distribución del número de reclamaciones en dos años. Centraremos nuestro estudio principalmente en las variables aleatorias bidimensionales, si bien las propiedades se pueden extender inmediatamente a más de dos dimensiones.

4.2. Variables aleatorias bidimensionales

4.2.1. Variable aleatoria bidimensional. Función de distribución bidimensional

Definición 4.1 Consideremos un espacio probabilístico $(\Omega, \Pr)$. Una aplicación $(X, Y) : \Omega \rightarrow \mathbb{R}^2$ se dice que es una variable aleatoria bidimensional si el conjunto $\{w / -\infty < X(w) \leq x, -\infty < Y(w) \leq y\}$ es un suceso.

Al igual que en el caso de una dimensión la función de distribución bidimensional, o distribución conjunta del par (X, Y) , permite conocer cómo se reparte la probabilidad sobre los valores que toma la variable aleatoria.

Definición 4.2 Se define la función de distribución conjunta de una variable aleatoria bidimensional como:

$$F(x, y) = \Pr(-\infty < X \leq x, -\infty < Y \leq y) = \Pr(X \leq x, Y \leq y). \quad (4.1)$$

Dicha función representa la probabilidad acumulada hasta el punto (x, y) . El siguiente resultado señala las propiedades de una función de distribución.

Teorema 4.1 Una función de distribución bidimensional definida en (4.1) verifica las siguientes propiedades,

1. $F(x, y)$ es monótona no decreciente en cada argumento:

$$\text{si } x_1 \leq x_2 \Rightarrow F(x_1, y) \leq F(x_2, y),$$

$$\text{si } y_1 \leq y_2 \Rightarrow F(x, y_1) \leq F(x, y_2).$$

2. $F(x, y)$ es acotada: $0 \leq F(x, y) \leq 1, \forall (x, y)$.

3. Se verifica:

$$\lim_{x \rightarrow -\infty} F(x, y) = \lim_{y \rightarrow -\infty} F(x, y) = 0,$$

$$\lim_{x, y \rightarrow \infty} F(x, y) = 1.$$

4. $F(x, y)$ es continua por la derecha en cada argumento:

$$\lim_{x \rightarrow x_0^+} F(x, y) = F(x_0, y), \quad \lim_{y \rightarrow y_0^+} F(x, y) = F(x, y_0).$$

5. La probabilidad sobre rectángulos es siempre no negativa:

$$\Pr(x_1 < X \leq x_2, y_1 < Y \leq y_2)$$

$$= F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) \geq 0.$$

4.2.2. Funciones de distribución marginales

Definición 4.3 A las funciones de distribución unidimensionales de X e Y deducidas de la función de distribución conjunta, se las denomina distribuciones marginales y se dice que X e Y son las variables aleatorias marginales.

Las correspondientes funciones de distribución se obtienen a través de la función de distribución conjunta calculando los siguientes límites:

$$F_X(x) = \lim_{y \rightarrow \infty} F(x, y), \quad (4.2)$$

$$F_Y(y) = \lim_{x \rightarrow \infty} F(x, y). \quad (4.3)$$

Ejemplo 4.1 Se considera la función de distribución bidimensional:

$$F(x, y) = 1 - e^{-x} - e^{-y} + e^{-x-y-xy/3}, \quad x, y > 0.$$

Se pide:

4.2. Variables aleatorias bidimensionales

1. Hallar las funciones de distribución marginales.

2. Calcular $\Pr(X \leq 1, Y \leq 2)$.

Solución:

1. Usando (4.2) si $x > 0$:

$$F_X(x) = \lim_{y \rightarrow \infty} F(x, y) = 1 - e^{-x},$$

y de forma análoga se obtiene que $F_Y(y) = 1 - e^{-y}$ si $y > 0$.

2. $\Pr(X \leq 1, Y \leq 2) = F(1, 2) = 0,5223 = 52,23\%$.

4.2.3. Variables aleatorias bidimensionales discretas

Definición 4.4 Una variable aleatoria (X, Y) se dice que es discreta si el conjunto de valores que toma es finito o infinito numerable.

Escribimos $(X, Y) = \{(x_1, y_1), \dots, (x_n, y_n), \dots\}$ La función que nos indica la probabilidad de cada uno de los valores:

$$\Pr(X = x_i, Y = y_j),$$

se denomina función de densidad conjunta (discreta). Las relaciones entre la función de densidad y la función de distribución son:

$$F(x, y) = \Pr(X \leq x, Y \leq y) = \sum_S \Pr(X = x_i, Y = y_j),$$

siendo $S = \{(x_i, y_j) / x_i \leq x, y_j \leq y\}$. Por otro lado:

$$\Pr(X = x_i, Y = y_j) = F(x_{i-1}, y_{j-1}) - F(x_{i-1}, y_j) - F(x_i, y_{j-1}) + F(x_i, y_j).$$

Para la obtención de las funciones de densidad (o probabilidad) marginales basta con acumular probabilidades en la otra variable:

$$\Pr(X = x_i) = \sum_j \Pr(X = x_i, Y = y_j),$$

$$\Pr(Y = y_j) = \sum_i \Pr(X = x_i, Y = y_j).$$

4.2.4. Variables aleatorias bidimensionales continuas

Definición 4.5 Se denomina variable aleatoria bidimensional continua aquella variable cuyos componentes son variables aleatorias unidimensionales continuas.

Definición 4.6 La función de densidad conjunta de una variable aleatoria bidimensional continua (X, Y) es una función $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ verificando dos condiciones:

1. Se trata de una función no negativa: $f(x, y) \geq 0, \forall (x, y) \in \mathbb{R}^2$,
2. La integral doble en todo el plano es uno:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1. \quad (4.4)$$

La función de distribución bidimensional se puede expresar como la integral doble de la función de densidad conjunta del par (X, Y) :

$$F(x, y) = \Pr(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) ds dt.$$

Las relaciones entre función de densidad y función de distribución son:

$$\begin{aligned} F(x, y) &= \int_{-\infty}^x \int_{-\infty}^y f(s, t) ds dt, \\ f(x, y) &= \frac{\partial^2 F(x, y)}{\partial x \partial y} = \frac{\partial^2 F(x, y)}{\partial y \partial x}. \end{aligned}$$

Las funciones de densidad marginales se pueden obtener a partir de la función de densidad conjunta calculando las siguientes integrales:

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} f(x, y) dy, \\ f_Y(y) &= \int_{-\infty}^{\infty} f(x, y) dx. \end{aligned}$$

Para el cálculo de probabilidades podemos utilizar la función de distribución o la función de densidad:

$$\Pr(a < X \leq b, c < Y \leq d) = \begin{cases} F(a, c) - F(a, d) - F(b, c) + F(b, d), \\ \int_c^d \left[\int_a^b f(x, y) dx \right] dy = \int_a^b \left[\int_c^d f(x, y) dy \right] dx. \end{cases}$$

En general, si $D \subset \mathbb{R}^2$ se verifica que,

$$\Pr((X, Y) \in D) = \iint_D f_{X,Y}(x, y) dx dy. \quad (4.5)$$

4.2. Variables aleatorias bidimensionales

Ejemplo 4.2 La variable (X, Y) representa el beneficio diario de dos valores de bolsa. La función de densidad conjunta es:

$$f(x, y) = k(x + y), \text{ si } 0 < x < 1, 0 < y < 2$$

y $f(x, y) = 0$ en otro caso.

1. Hallar el valor de k .
2. Funciones de densidad marginales. ¿Son X e Y variables aleatorias independientes?
3. Calcular: $\Pr(0 < X < \frac{1}{2}, 0 < Y < 1)$.

Solución:

1. El valor de k se obtiene por medio de la integral doble:

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = \int_0^1 \left(\int_0^2 k(x + y) dy \right) dx = 3k$$

de donde $k = \frac{1}{3}$.

2. Función de densidad marginal de la X . Si $0 < x < 1$:

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \int_0^2 k(x + y) dy = \frac{1}{3}(2 + 2x)$$

y $f_X(x) = 0$ en otro caso. Ahora, si $0 < y < 2$:

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \int_0^1 k(x + y) dx = \frac{1}{3} \left(\frac{1}{2} + y \right)$$

y $f_Y(y) = 0$ en otro caso. Las variables X e Y no son independientes (sección 4.2.6) puesto que $f(x, y) \neq f_X(x)f_Y(y)$.

3. Se tiene que:

$$\Pr\left(0 < X < \frac{1}{2}, 0 < Y < 1\right) = \int_0^{1/2} \left(\int_0^1 k(x + y) dy \right) dx = \frac{1}{8}.$$

4.2.5. Distribuciones condicionadas

Dada una variable aleatoria bidimensional, las distribuciones condicionadas permiten estudiar el comportamiento de una variable cuando se fija un valor de la otra. Distinguiremos los casos discreto y continuo. Sea (X, Y) variable bidimensional discreta, con función de densidad $\Pr(X = x, Y = y)$. Sea $Y = y_j$ un valor de Y con probabilidad no nula.

Definición 4.7 Se denomina función de densidad de X condicionada por el valor $Y = y_j$ ($\Pr(Y = y_j) \neq 0$) a:

$$\Pr(X = x_i | Y = y_j) = \frac{\Pr(X = x_i, Y = y_j)}{\Pr(Y = y_j)}.$$

La función de densidad condicionada es una densidad univariada, y existen tantas densidades condicionadas como posibles valores del condicionante. De modo análogo se define la función de densidad de Y dado $X = x_i$ ($\Pr(X = x_i) \neq 0$):

$$\Pr(Y = y_j | X = x_i) = \frac{\Pr(X = x_i, Y = y_j)}{\Pr(X = x_i)}.$$

Veamos el caso continuo. Sea (X, Y) variable aleatoria bidimensional continua con función de densidad conjunta $f_{X,Y}(x, y)$ y función de distribución conjunta $F_{X,Y}(x, y)$. En el caso de variables continuas se define la función de distribución condicionada como:

$$\begin{aligned} F_{X|Y}(x|y) &= \Pr(X \leq x | Y = y) \\ &= \lim_{h \rightarrow 0} \Pr(X \leq x | y < Y \leq y + h) \\ &= \frac{\frac{\partial}{\partial y} F_{X,Y}(x, y)}{f_Y(y)}. \end{aligned}$$

Derivando esta expresión respecto x obtenemos la definición en términos de la función densidad.

Definición 4.8 Se define la función de densidad condicionada de X dada $Y = y$ por:

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Téngase en cuenta que esta función de densidad condicionada es función de x , y el valor de y juega el papel de una constante, puesto que es un valor conocido. De un modo análogo la función de densidad de Y condicionada por $X = x$ viene definida por:

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

4.3. Momentos multivariantes

4.2.6. Independencia de variables aleatorias

Al igual que en sucesos, se define la independencia de variables aleatorias. Sea (X, Y) una variable aleatoria bidimensional. Se dice que X e Y son variables aleatorias independientes si:

$$\Pr(X \in A, Y \in B) = \Pr(X \in A) \Pr(Y \in B),$$

donde $A, B \subset \mathbb{R}$. Los siguientes resultados permiten verificar la independencia de dos variables aleatorias:

1. Sea (X, Y) una variable aleatoria bidimensional. Las variables X e Y son independientes, si y sólo si:

$$F_{X,Y}(x, y) = F_X(x) F_Y(y), \quad \forall (x, y) \in \mathbb{R}^2.$$

Se verifica un resultado análogo, si lo que conocemos son las funciones de densidad.

2. Sea (X, Y) una variable aleatoria bidimensional. Las variables X e Y son independientes, si y sólo si:

Caso discreto:

$$\Pr(X = x_i, Y = y_j) = \Pr(X = x_i) \Pr(Y = y_j), \quad \forall (x_i, y_j).$$

Caso continuo:

$$f_{X,Y}(x, y) = f_X(x) f_Y(y), \quad \forall (x, y) \in \mathbb{R}^2.$$

4.3. Momentos multivariantes

A partir de una variable bidimensional (X, Y) con función de densidad $f_{X,Y}(x, y)$, definimos en el caso continuo:

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f_{X,Y}(x, y) dx dy,$$

y en el caso discreto:

$$E[g(X, Y)] = \sum_{i,j} g(x_i, y_j) \Pr(X = x_i, Y = y_j).$$

Un caso importante es $E(XY)$ que en los casos continuo y discreto viene definida por:

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{X,Y}(x, y) dx dy,$$

$$E(XY) = \sum_{i,j} x_i y_j \Pr(X = x_i, Y = y_j),$$

respectivamente.

Teorema 4.2 Sea (X, Y) variable aleatoria bidimensional. Si X e Y son variables aleatorias independientes, entonces,

$$E(XY) = E(X)E(Y).$$

El recíproco de este resultado no es cierto: es posible encontrar variables aleatorias tales que $E(XY) = E(X)E(Y)$, sin ser independientes.

Demostración: Veamos la prueba en el caso continuo:

$$\begin{aligned} E(XY) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_{X,Y}(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_X(x) f_Y(y) dx dy \\ &= \left(\int_{-\infty}^{\infty} x f_X(x) dx \right) \left(\int_{-\infty}^{\infty} y f_Y(y) dy \right) \\ &= E(X)E(Y). \end{aligned}$$

El caso discreto es análogo sin más que sustituir el operador integral por el sumatorio. ■

4.3.1. Covarianza y coeficiente de correlación lineal

La covarianza y el coeficiente de correlación lineal permiten estudiar el grado de dependencia lineal entre dos variables aleatorias.

Definición 4.9 Se define la covarianza como:

$$\sigma_{XY} = \text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)], \quad (4.6)$$

donde $\mu_X = E(X)$ y $\mu_Y = E(Y)$.

El siguiente resultado muestra una expresión simple de la covarianza.

Teorema 4.3 Dadas dos variables aleatorias X e Y , la covarianza se puede escribir como:

$$\sigma_{XY} = \text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Demostración: Desarrollando la expresión (4.6):

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y) \\ &= E(XY) - \mu_X \mu_Y - \mu_X \mu_Y + \mu_X \mu_Y \\ &= E(XY) - \mu_X \mu_Y. \end{aligned}$$

En el caso de independencia la covarianza de dos variables es cero. ■

Teorema 4.4 Si X e Y son variables aleatorias independientes: $\text{Cov}(X, Y) = 0$.

Demostración: Al ser X e Y independientes, por el teorema 4.2: $E(XY) = E(X)E(Y)$, de donde se sigue el resultado. ■

El siguiente resultado permite obtener la varianza de la suma de variables aleatorias dependientes.

Teorema 4.5 Si a y b son números reales, se verifica que:

$$\text{Var}(aX \pm bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) \pm 2ab \text{Cov}(X, Y). \quad (4.7)$$

Si X e Y son variables aleatorias independientes entonces:

$$\text{Var}(aX \pm bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y). \quad (4.8)$$

En el caso de la suma de n variable aleatorias se verifica que,

$$\text{Var}\left(\sum_{k=1}^n a_k X_k\right) = \sum_{k=1}^n a_k^2 \text{Var}(X_k) + 2a_i a_j \sum_{i < j} \text{Cov}(X_i, X_j), \quad (4.9)$$

donde la suma de las covarianzas desaparece en el caso que las n variables aleatorias sean independientes dos a dos.

Demostración: La media de $aX + bY$ es $E(aX + bY) = aE(X) + bE(Y) = a\mu_X + b\mu_Y$. Por tanto:

$$\begin{aligned} \text{Var}(aX + bY) &= E[(aX + bY) - (a\mu_X + b\mu_Y)]^2 \\ &= E[a(X - \mu_X) + b(Y - \mu_Y)]^2 \\ &= E[a^2(X - \mu_X)^2 + b^2(Y - \mu_Y)^2 + 2ab(X - \mu_X)(Y - \mu_Y)] \\ &= a^2 E(X - \mu_X)^2 + b^2 E(Y - \mu_Y)^2 + 2ab E[(X - \mu_X)(Y - \mu_Y)] \\ &= a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y). \end{aligned}$$

La prueba de la fórmula de $\text{Var}(aX - bY)$ es similar. Si X e Y son independientes $\text{Cov}(X, Y) = 0$, de donde se sigue el resultado. ■

Algunas propiedades de la covarianza aparecen en el siguiente teorema.

Teorema 4.6 (Propiedades de la covarianza) Dadas las variables aleatorias $X, Y, X_1, \dots, X_n, Y_1, \dots, Y_m$ y los números reales $a_1, \dots, a_n$ y $b_1, \dots, b_m$ se verifican las siguientes propiedades:

$$\begin{aligned} \text{Cov}(X, Y) &= \text{Cov}(Y, X), \\ \text{Cov}(X, X) &= \text{Var}(X), \\ \text{Cov}(a_1 + b_1 X, a_2 + b_2 Y) &= b_1 b_2 \text{Cov}(X, Y), \\ \text{Cov}(X, Y_1 + Y_2) &= \text{Cov}(X, Y_1) + \text{Cov}(X, Y_2), \end{aligned}$$

$$\begin{aligned} \text{Cov}\left(X, \sum_{i=1}^n Y_i\right) &= \sum_{i=1}^n \text{Cov}(X, Y_i), \\ \text{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) &= \sum_{i=1}^n \sum_{j=1}^m \text{Cov}(X_i, Y_j), \\ \text{Cov}\left(\sum_{i=1}^n a_i X_i, \sum_{j=1}^m b_j Y_j\right) &= \sum_{i=1}^n \sum_{j=1}^m a_i b_j \text{Cov}(X_i, Y_j). \end{aligned}$$

El coeficiente de correlación lineal permite estudiar el grado de dependencia lineal existente entre dos variables aleatorias X e Y y no tiene dimensión.

Definición 4.10 El coeficiente de correlación lineal entre dos variables aleatorias X e Y viene definido por:

$$\rho = \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \cdot \sigma_Y}.$$

Teorema 4.7 Se verifican las siguientes propiedades:

1. $-1 \leq \rho \leq 1$. Además $\rho = \pm 1 \iff Y = a \pm bX$.
2. $\rho(a + bX, c + dY) = \text{signo}(bd)\rho(X, Y)$.
3. Si X e Y son variables aleatorias independientes, entonces $\rho(X, Y) = 0$. El recíproco no es cierto.

Demostración: Consideremos la función $g(t)$ definida como:

$$g(t) = E[(X - \mu_X)t + (Y - \mu_Y)]^2 \geq 0.$$

Desarrollando esta expresión tenemos:

$$g(t) = t^2 \sigma_X^2 + 2t \text{Cov}(X, Y) + \sigma_Y^2 \geq 0.$$

Si elegimos $t = -\text{Cov}(X, Y)/\sigma_X^2$ obtenemos que:

$$[\text{Cov}(X, Y)]^2 \leq \sigma_X^2 \sigma_Y^2 \Rightarrow -1 \leq \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \rho(X, Y) \leq 1.$$

Si X e Y son independientes $\text{Cov}(X, Y) = 0$, de donde $\rho(X, Y) = 0$. ■

Ejemplo 4.3 Se desean invertir 2 mil euros en acciones y 3 mil euros en bonos, cuyas tasas de rendimiento X e Y respectivamente, son aleatorias. El rendimiento total de la inversión es por tanto, $T = 2X + 3Y$. Se conoce que X tiene media $\mu_X = 0,12$ y varianza $\sigma_X^2 = 0,25$, y para Y la media es $\mu_Y = 0,1$ y la varianza $\sigma_Y^2 = 0,04$. Hallar la media y la varianza del rendimiento total suponiendo que X e Y son variables aleatorias dependientes con coeficiente de correlación $\rho_{X,Y} = 0,7$.

4.4. Momentos condicionales

57

Solución: El rendimiento medio es:

$$E(T) = E(2X + 3Y) = 2 \cdot \mu_X + 3 \cdot \mu_Y = 2 \cdot 0,12 + 3 \cdot 0,1 = 0,54.$$

Aplicando la fórmula (4.7) la varianza del rendimiento es,

$$\begin{aligned} \text{Var}(T) &= \text{Var}(2X + 3Y) = 2^2 \cdot \sigma_X^2 + 3^2 \cdot \sigma_Y^2 + 2 \cdot \text{Cov}(2X, 3Y) \\ &= 2^2 \cdot \sigma_X^2 + 3^2 \cdot \sigma_Y^2 + 2 \cdot 2 \cdot 3 \cdot \sigma_X \cdot \sigma_Y \cdot \rho_{X,Y} \\ &= 2^2 \cdot 0,25 + 3^2 \cdot 0,04 + 2 \cdot 2 \cdot 3 \cdot 0,5 \cdot 0,2 \cdot 0,7 = 2,2. \end{aligned}$$

◇

4.4. Momentos condicionales

4.4.1. Esperanza condicionada

Dada la variable aleatoria bidimensional discreta (X, Y) , se define la esperanza condicionada de X dado $Y = y$, y de Y dado $X = x$ como:

$$\begin{aligned} E(X|Y = y) &= \sum_{i=1}^{\infty} x_i \Pr(X = x_i | Y = y), \\ E(Y|X = x) &= \sum_{i=1}^{\infty} y_i \Pr(Y = y_i | X = x), \end{aligned}$$

y en el caso de variables aleatorias continuas:

$$\begin{aligned} E(X|Y = y) &= \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx, \\ E(Y|X = x) &= \int_{-\infty}^{\infty} y f_{Y|X}(y|x) dy. \end{aligned}$$

En el caso general, si g es una transformación cualquiera se verifica que:

$$E[g(X)|Y = y] = \sum_{i=1}^{\infty} g(x_i) \Pr(X = x_i | Y = y),$$

y para variables continuas:

$$E[g(X)|Y = y] = \int_{-\infty}^{\infty} g(x) f_{X|Y}(x|y) dx.$$

La esperanza condicionada admite una doble interpretación. Si el valor del condicionante se considera fijo, representa una constante: la media de X , para un valor

preestablecido de la Y , que corresponde a la interpretación habitual. Por otro lado, si se considera el valor del condicionante variable, la esperanza condicionada es una nueva variable aleatoria definida a partir de la variable que se condiciona. Las propiedades de la esperanza matemática se conservan en el caso condicional. Sin embargo, el hecho de poder interpretarse como una variable aleatoria la dotan de algunas propiedades especiales, que señalamos a continuación. Estas propiedades presuponen la existencia de todos los momentos involucrados.

Teorema 4.8 Se verifican las siguientes propiedades:

1. Si $g_1 = g_1(X, Y)$ y $g_2 = g_2(X, Y)$ y a y b son números reales:

$$E(ag_1 + bg_2|X = x) = aE(g_1|X = x) + bE(g_2|X = x).$$

2. $E[g_1(X)g_2(X, Y)|X = x] = g_1(x)E[g_2(X, Y)|X = x]$, es decir, las funciones de la variable que se condiciona, juegan el papel de constantes en la esperanza condicionada.

3. Si X e Y son variables aleatorias independientes se verifica que:

$$E(X|Y = y) = E(X), \quad \forall y,$$

$$E(Y|X = x) = E(Y), \quad \forall x.$$

Teorema 4.9 (Regla de la Esperanza Iterada) Para variables aleatorias X e Y , suponiendo que las esperanzas existen, se verifica que:

$$E[E(X|Y)] = E(X),$$

$$E[E(Y|X)] = E(Y).$$

Más en general, se verifica que:

$$E[E(h(X, Y)|Y)] = E[h(X, Y)].$$

Demostración: Probaremos el primero de los resultados en el caso continuo:

$$\begin{aligned} E[E(X|Y)] &= \int E(X|Y = y)f_Y(y)dy \\ &= \int \int xf_{X|Y}(x|y)dx f_Y(y)dy \\ &= \int x \int f_{X|Y}(x|y)f_Y(y)dy dx \\ &= \int xf_X(x)dx \\ &= E(X). \end{aligned}$$

El resto de las igualdades se prueba de manera análoga.

4.4.2. Varianza condicionada

De un modo similar al caso incondicional, la varianza condicionada de X dada $Y = y$ viene definida por,

$$\text{Var}(X|Y) = E\{[X - E(X|Y)]^2|Y\}. \quad (4.10)$$

La primera propiedad se deduce de la definición (4.10) y establece que,

$$\text{Var}(X|Y) = E(X^2|Y) - [E(X|Y)]^2. \quad (4.11)$$

La siguiente propiedad relaciona la varianza incondicional de la variable X , con los momentos de las variables condicionales.

Teorema 4.10 Para variables aleatorias X e Y se verifica que:

$$\text{Var}(X) = E[\text{Var}(X|Y)] + \text{Var}[E(X|Y)]. \quad (4.12)$$

Demostración: Vamos a desarrollar cada uno de los sumandos de la parte derecha de (4.12). Usando (4.11) se verifica que,

$$\begin{aligned} E[\text{Var}(X|Y)] &= E[E(X^2|Y) - [E(X|Y)]^2] \\ &= E[E(X^2|Y)] - E\{[E(X|Y)]^2\} \\ &= E(X^2) - E\{[E(X|Y)]^2\} \end{aligned}$$

Por otro lado, aplicando la definición de varianza,

$$\begin{aligned} \text{Var}[E(X|Y)] &= E\{[E(X|Y)]^2\} - \{E[E(X|Y)]\}^2 \\ &= E\{[E(X|Y)]^2\} - [E(X)]^2 \end{aligned}$$

Finalmente, sumando las dos expresiones obtenemos (4.12). $\square$

La fórmula (4.12) expresa que la varianza incondicional se puede escribir como la suma de dos componentes: la esperanza de la varianza condicional más la varianza de la esperanza condicional.

Ejemplo 4.4 Las ventas X de una empresa dependen condicionalmente del gasto en publicidad Y , de modo que:

$$X|Y = y \sim \mathcal{N}(y + 1, 2^2).$$

Se supone que el gasto en publicidad es a su vez otra variable normal $\mathcal{N}(4, 5^2)$. Hallar la media y la varianza incondicional de la variable ventas.

Solución: Si $X \sim \mathcal{N}(\mu, \sigma^2)$ entonces $E(X) = \mu$ y $\text{Var}(X) = \sigma^2$, en consecuencia $E(X|Y = y) = y + 1$ y $\text{Var}(X|Y = y) = 4$. Ahora, según las fórmulas que relacionan los momentos condicionales con los absolutos:

$$E(X) = E[E(X|Y)] = E(Y + 1) = E(Y) + 1 = 4 + 1 = 5.$$

$$\text{Var}(X) = E[\text{Var}(X|Y)] + \text{Var}[E(X|Y)] = E(4) + \text{Var}(Y + 1) = 4 + 25 = 29.$$

4.5. Transformaciones de variables aleatorias

4.5.1. Caso discreto

Sea (X, Y) una variable bidimensional discreta, de la que conocemos su función de densidad bidimensional, y queremos obtener la densidad de la nueva variable unidimensional:

$$U = U(X, Y).$$

Una vez calculados los valores que toma la nueva variable U , la probabilidad de cada valor viene dada por:

$$\Pr(U = u_{ij}) = \Pr((x_i, y_j) : u(x_i, y_j) = u_{ij}) = \sum_I \Pr(X = x_i, Y = y_j), \quad (4.13)$$

donde $I = \{(x_i, y_j) : u(x_i, y_j) = u_{ij}\}$.

Veamos el caso de la suma de variables aleatorias discretas.

Teorema 4.11 Sea (X, Y) una variable aleatoria bidimensional discreta con función de densidad conjunta $\Pr(X = x, Y = y)$. Entonces, la función de densidad de la variable aleatoria suma $Z = X + Y$ es,

$$\Pr(Z = z) = \sum_x \Pr(X = x, Y = z - x). \quad (4.14)$$

Si además X e Y son variables aleatorias independientes entonces,

$$\Pr(Z = z) = \sum_x \Pr(X = x) \Pr(Y = z - x). \quad (4.15)$$

Cuando X e Y toman únicamente valores no negativos entonces,

$$\Pr(Z = z) = \sum_{x=0}^z \Pr(X = x) \Pr(Y = z - x). \quad (4.16)$$

Demostración: Por la fórmula general (4.13),

$$\begin{aligned} \Pr(Z = z) = \Pr(X + Y = z) &= \sum_{\{x, y: x+y=z\}} \Pr(X = x, Y = y) \\ &= \sum_x \Pr(X = x, Y = z - x) \end{aligned}$$

y se obtiene (4.14). Si X e Y son variables aleatorias independientes $\Pr(X = x, Y = y) = \Pr(X = x) \Pr(Y = y)$ y se obtiene (4.15). En el caso de que ambas variables sean no negativas se obtiene la fórmula (4.16). ■

4.5.2. Caso continuo

Supongamos una variable bidimensional continua (X, Y) con función de densidad conjunta $f_{X,Y}(x, y)$. Consideremos una nueva variable (U, V) donde,

$$\begin{cases} U = U(X, Y), \\ V = V(X, Y), \end{cases} \quad (4.17)$$

son transformaciones biunívocas de $\mathbb{R}^2$ en $\mathbb{R}^2$, es decir, existe la transformación inversa sobre el recorrido de la transformación:

$$X = X(U, V); \quad Y = Y(U, V),$$

que suponemos continuas y diferenciables. Se supone también que las derivadas parciales de la transformación existen y son continuas y el jacobiano de la transformación es no nulo:

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix} = \frac{\partial x}{\partial u} \cdot \frac{\partial y}{\partial v} - \frac{\partial x}{\partial v} \cdot \frac{\partial y}{\partial u} \neq 0.$$

Se verifica el siguiente resultado.

Teorema 4.12 (Teorema del cambio de variable) Bajo las hipótesis anteriores, la función de densidad conjunta de la nueva variable (U, V) definida en (4.17) viene dada por,

$$f_{U,V}(u, v) = f_{X,Y}(x(u, v), y(u, v)) \cdot |J|. \quad (4.18)$$

Veamos algunos ejemplos.

Ejemplo 4.5 Sean X e Y variables aleatorias exponenciales que representan las pérdidas de dos siniestros independientes y vienen descritas por las funciones de densidad:

$$f_X(x) = e^{-x}, \quad x \geq 0, \quad f_Y(y) = e^{-y}, \quad y \geq 0.$$

Probar que la función de densidad de la variable aleatoria pérdida total $U = X + Y$ viene dada por,

$$f_U(u) = ue^{-u}, \quad \text{si } u \geq 0$$

y $f_U(u) = 0$ si $u < 0$.

Solución: El método que se debe usar consiste en construir una nueva variable bidimensional, de modo que una de las marginales sea la variable de interés. A continuación no hay más que obtener la correspondiente marginal. La función de densidad conjunta es:

$$f_{X,Y}(x, y) = f_X(x) f_Y(y) = e^{-(x+y)}, \quad \text{si } x, y > 0,$$

por la independencia de ambas variables. Ahora definimos la transformación,

$$\begin{cases} U = X + Y & ; X = U - V, \\ V = Y & ; Y = V, \end{cases}$$

con jacobiano,

$$J = \begin{vmatrix} 1 & -1 \\ 0 & 1 \end{vmatrix} = 1.$$

Usando la fórmula (4.18), la función de densidad conjunta de las nuevas variables es,

$$f_{U,V}(u, v) = f_{X,Y}(u - v, v) = e^{-u}.$$

El nuevo dominio es $0 < v < u < \infty$. La densidad de U es la función de densidad marginal de (U, V) :

$$f_U(u) = \int_{-\infty}^{\infty} f_{U,V}(u, v) dv = \int_0^u e^{-v} dv = ue^{-u}.$$

◇

Ejemplo 4.6 Las variables aleatorias X e Y miden las pérdidas de dos siniestros que se pueden considerar como independientes. Supongamos que las correspondientes funciones de densidad vienen dadas por:

$$f_X(x) = \frac{1}{x^2}, \quad x \geq 1; \quad f_Y(y) = \frac{1}{y^2}, \quad y \geq 1.$$

Si la variable $U = \sqrt{XY}$ representa la media geométrica de las dos pérdidas, probar que la función de densidad de U es,

$$f_U(u) = \frac{4 \log(u)}{u^3}, \quad u \geq 1,$$

y $f_U(u) = 0$ si $u < 1$.

Solución: Puesto que X e Y son variables aleatorias independientes, se tiene que:

$$f_{X,Y}(x, y) = f_X(x)f_Y(y) = \frac{1}{x^2 y^2}, \quad \text{si } x, y \geq 1.$$

A continuación, definimos otra variable V que nos permita despejar unívocamente X e Y en función de U y V . Entonces:

$$\begin{cases} U = \sqrt{XY} & ; X = \frac{u^2}{v}, \\ V = Y & ; Y = v. \end{cases}$$

4.5. Transformaciones de variables aleatorias

El jacobiano de la transformación viene dado por:

$$J = \begin{vmatrix} \frac{2u}{v} & -\frac{u^2}{v^2} \\ 0 & 1 \end{vmatrix} = \frac{2u}{v},$$

y $|J| = \frac{2u}{v}$, dado que U y V son variables aleatorias positivas. Por tanto, aplicando (4.18) tenemos,

$$f_{U,V}(u, v) = f_{X,Y}\left(\frac{u^2}{v}, v\right) \cdot \frac{2u}{v} = \frac{2}{u^3 v}.$$

Puesto que x e y son siempre mayores que 1, resulta evidente que la función de densidad anterior será válida en el dominio $1 \leq v \leq u^2 < \infty$. Por último, la marginal de U vendrá dada por:

$$f_U(u) = \int_1^{u^2} \frac{2}{u^3 v} dv = \frac{2}{u^3} \log(u^2) = \frac{4}{u^3} \log(u),$$

siempre que u sea mayor o igual que 1, y $f_U(u) = 0$ en otro caso.

◇

El siguiente resultado permite obtener la función de densidad de la suma de variables aleatorias bajo diversos supuestos.

Teorema 4.13 Si la variable aleatoria continua (X, Y) tiene como función de densidad conjunta $f(x, y)$, la función de densidad de la suma $Z = X + Y$ viene dada por,

$$f_Z(z) = \int_{-\infty}^{\infty} f(x, z-x) dx. \quad (4.19)$$

Si X e Y son variables aleatorias independientes entonces,

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx. \quad (4.20)$$

Si X e Y son no negativas e independientes, entonces,

$$f_Z(z) = \int_0^z f_X(x) f_Y(z-x) dx. \quad (4.21)$$

Demostración: Comenzaremos obteniendo la función de distribución de la Z ,

$$\begin{aligned} F_Z(z) = \Pr(Z \leq z) &= \int \int_{x+y \leq z} f(x, y) dx dy \\ &= \int_{x=-\infty}^{\infty} \int_{y=-\infty}^{z-x} f(x, y) dy dx. \end{aligned}$$

Derivando respecto z y aplicando el teorema fundamental del cálculo, obtenemos

$$f_z(z) = \int_{-\infty}^{\infty} f(x, z-x) dx,$$

como queríamos probar. Las fórmulas (4.20) y (4.21) se obtiene a partir de (4.19). ■

Teorema 4.14 Si la variable continua (X, Y) tiene como función de densidad conjunta $f(x, y)$ y considerando las variables $U = X - Y$, $V = XY$, y $W = X/Y$ con $\Pr(Y = 0) = 0$, entonces las funciones de densidad de estas variables aleatorias vienen dadas por:

1.

$$f_U(u) = \int_{-\infty}^{\infty} f(u+y, y) dy,$$

2.

$$f_V(v) = \int_{-\infty}^{\infty} f(x, \frac{v}{x}) \frac{1}{|x|} dx,$$

3.

$$f_W(w) = \int_{-\infty}^{\infty} f(xw, x) |x| dx,$$

respectivamente. Además, si X e Y son independientes entonces,

1.

$$f_U(u) = \int_{-\infty}^{\infty} f_X(u+y) f_Y(y) dy,$$

2.

$$f_V(v) = \int_{-\infty}^{\infty} f_X(x) f_Y(\frac{v}{x}) \frac{1}{|x|} dx,$$

3.

$$f_W(w) = \int_{-\infty}^{\infty} f_X(xw) f_Y(x) |x| dx.$$

Demostración: La demostración es análoga al caso $Z = X + Y$ utilizando las transformaciones que definen a U , V y W , respectivamente y utilizando el teorema 4.12. ■

4.6. Problemas propuestos

1. La variable bidimensional (X, Y) representa el número de reclamaciones de un tipo de siniestro durante dos años. La función de densidad conjunta es,

$$\Pr(X = x, Y = y) = k 2^{x+y+xy}, \text{ si } x, y = 0, 1, 2, 3, 4.$$

- a) Hallar el valor de k .
- b) Hallar las funciones de densidad marginales de X e Y así como las medias y varianzas.
- c) Hallar $E(Y|X)$. Obtener $E(Y)$ a partir de la expresión anterior.
- d) Hallar el coeficiente de correlación lineal del número de reclamaciones en los dos años.

2. Para las siguientes funciones de densidad bidimensionales continuas, hallar el valor de la constante de normalización k y estudiar la independencia entre X e Y :

$$a) f_{X,Y}(x, y) = k(x^4 + y^4), \quad 0 < x < 1, \quad 0 < y < 1.$$

$$b) f_{X,Y}(x, y) = kxy, \quad 0 < x < 2, \quad 0 < y < 3.$$

$$c) f_{X,Y}(x, y) = ke^{-(x+y)}, \quad 0 < y < x < \infty.$$

3. Sean X e Y variables aleatorias independientes con funciones de densidad,

$$f_X(x) = e^{-x}, \quad x > 0; \quad f_Y(y) = e^{-y}, \quad y > 0.$$

Probar que la función de densidad de la variable cociente $Z = X/Y$ viene dada por:

$$f_Z(z) = \frac{1}{(1+z)^2}, \quad \text{si } z > 0.$$

4. Una firma comercial distribuye dos tipos de productos A y B de modo que las cuotas de mercados de los dos productos se pueden representar por medio de la función de densidad conjunta:

$$f(x, y) = k(x^2 + y) \text{ si } 0 \leq x, y \leq 1; \quad f(x, y) = 0 \text{ en otro caso,}$$

donde X se refiere a la cuota de A e Y a la de B.

- a) Hallar el valor de k .
- b) Probabilidad de que la cuota de mercado del producto A sea mayor que 0,5.
- c) Probabilidad que la cuota de A esté entre 0,5 y 0,6 y la de B entre 0,2 y 0,3.

- d) Probabilidad que la cuota de A sea mayor que la de B.
5. Se considera el conjunto de familias con 5 hijos y la variable aleatoria (X, Y) donde X representa el número de chicos e Y el de chicas.
- a) Hallar el coeficiente de correlación lineal entre X e Y .
- b) Curva de regresión de Y sobre X .
6. Para la variable aleatoria (X, Y) con función de densidad:

$$f(x, y) = xe^{-x(1+y)}, \quad x > 0, y > 0,$$

probar que: $E(X|Y = y) = 2/(1 + y)$ y $\text{Var}(X|Y = y) = 2/(1 + y)^2$.

Capítulo 5

Cantidades Aleatorias de uso en Estadística Actuarial

5.1. Introducción

En este tema estudiaremos una serie de funciones y transformaciones que genéricamente denominamos cantidades aleatorias de uso en estadística actuarial.

5.2. Funciones de supervivencia y de azar

Consideremos una variable aleatoria X continua y no negativa con función de distribución $F_X(x)$ y función de densidad $f_X(x)$.

Definición 5.1 La función,

$$S_X(x) = \Pr(X > x) = 1 - F_X(x) \quad (5.1)$$

se denomina función de supervivencia.

La función $S_X(x)$ recibe el nombre de función de supervivencia porque proporciona la probabilidad de que un individuo sobreviva más que x o que una variable de pérdida X exceda el valor x .

Definición 5.2 Se denomina función de azar a la cantidad:

$$r_X(x) = \frac{f_X(x)}{\Pr(X > x)} = \frac{f_X(x)}{1 - F_X(x)} \quad (5.2)$$

La función de azar recibe el nombre de tasa de fallo en fiabilidad y fuerza de mortalidad en seguros de vida. Aunque en estadística actuarial a menudo se trabaja con variables no negativas, la definición 5.2 es válida para cualquier tipo de variable.

Ejemplo 5.1 Obtener la función de azar de la variable aleatoria continua con función de distribución,

$$F(x) = \frac{1}{2} \left(1 + \frac{x}{\sqrt{2+x^2}} \right), \quad -\infty < x < \infty.$$

Solución: La función de densidad es,

$$f(x) = \frac{d}{dx} F(x) = \frac{1}{(2+x^2)^{3/2}},$$

de donde la función de azar es,

$$r(x) = \frac{f(x)}{1-F(x)} = \frac{2}{(2+x^2)(\sqrt{2+x^2}-x)}, \quad -\infty < x < \infty.$$

◇

Ejemplo 5.2 Consideremos una variable aleatoria tipo Weibull con función de distribución ($\beta > 0$),

$$F_X(x) = 1 - \exp(-x^\beta), \quad x > 0$$

y $F_X(x) = 0$ si $x < 0$. Obtener su función de azar.

Solución: La función de densidad viene dada por:

$$f_X(x) = \beta x^{\beta-1} \exp(-x^\beta), \quad x > 0.$$

La función de azar es,

$$r_X(x) = \frac{f_X(x)}{1-F_X(x)} = \frac{\beta x^{\beta-1} \exp(-x^\beta)}{\exp(-x^\beta)} = \beta x^{\beta-1}.$$

Por tanto la función de azar $r_X(x)$ es creciente, constante o decreciente dependiendo que $\beta > 1$, $\beta = 1$ o $\beta < 1$, respectivamente. Las gráficas de estas funciones de azar aparecen representadas en la figura 5.1.

◇

Supongamos ahora que X representa el tiempo de vida de un elemento. Entonces, la función de azar se puede interpretar como la probabilidad de que el




Figura 5.1: Funciones de azar de la distribución Weibull con $\beta = 1/2, 1/3, 1, 2, 3$ y 4

elemento sobreviva después del momento x , sabiendo que ha sobrevivido hasta el momento x . En efecto:

$$\begin{aligned} r_X(x) &= \lim_{\delta \rightarrow 0} \frac{\Pr(x < X \leq x + \delta | X > x)}{\delta} \\ &= \lim_{\delta \rightarrow 0} \frac{\frac{F_X(x+\delta) - F_X(x)}{\delta}}{1 - F_X(x)} = \frac{\frac{d}{dx} F_X(x)}{1 - F_X(x)} \\ &= \frac{f_X(x)}{1 - F_X(x)}. \end{aligned}$$

Por tanto, la función de azar se puede interpretar como la probabilidad instantánea de fallo dado que el elemento ha sobrevivido hasta el instante x .

A partir de la definición (5.1) se cumple que,

$$f_X(x) = r_X(x) S_X(x), \quad (5.3)$$

es decir, la función de densidad es el producto de la función de azar por la función de supervivencia. Existe una correspondencia uno a uno entre función de distribución y función de supervivencia.

Teorema 5.1 Sea X una variable aleatoria continua con función de azar $r_X(x)$. Entonces, la función de distribución viene dada por,

$$F_X(x) = 1 - \exp \left[- \int_{-\infty}^x r_X(t) dt \right]. \quad (5.4)$$

Demostración: Para probar este resultado calculamos la derivada del logaritmo de la función de supervivencia:

$$\frac{d}{dx} \log[1 - F_X(x)] = \frac{-f_X(x)}{1 - F_X(x)} = -r_X(x),$$

e integrando desde $-\infty$ hasta x tenemos que:

$$\log[1 - F_X(x)] = - \int_{-\infty}^x r_X(t) dt,$$

que da lugar a (5.4). ■

A partir de la relación entre $F_X(x)$ y $r_X(x)$ dada en (5.4) se puede obtener unívocamente una a partir de la otra. Usando la expresión (5.1) y (5.4) obtenemos la relación entre función de supervivencia y función de azar:

$$S_X(x) = \exp \left[- \int_{-\infty}^x r_X(t) dt \right].$$

Ejemplo 5.3 Una variable aleatoria X no negativa tiene como función de azar,

$$r(x) = \lambda + 2c\lambda^2 x, \quad x \geq 0$$

y $r(x) = 0$ si $x < 0$, donde $\lambda > 0$ y $c \geq 0$. Obtener la función de distribución de X .

Solución: Integrando la función de azar obtenemos,

$$\int_0^x r(t) dt = \lambda x + c(\lambda x)^2.$$

Usando (5.4) obtenemos,

$$F(x) = 1 - \exp[-\lambda x - c(\lambda x)^2], \quad x \geq 0,$$

y $F(x) = 0$ si $x < 0$.

◇

5.3. Vida residual media

Sea X una variable aleatoria no negativa de tipo continuo con función de distribución $F(\cdot)$. Supongamos que la media $\mu_X = E(X)$ es finita y no nula. Definimos a continuación la variable aleatoria vida residual.

Definición 5.3 Se denomina vida residual de X y se denota por X_t , a la variable aleatoria que representa el tiempo de vida restante del individuo, sabiendo que ha sobrevivido hasta t , es decir,

$$X_t = \{X - t | X > t\}, \quad t > 0.$$

La función de distribución de la variable vida residual viene dada por:

$$\begin{aligned} F_{X_t}(x) &= \Pr(X_t \leq x) = \Pr(X - t \leq x | X > t) \\ &= \frac{\Pr(t < X \leq x + t)}{\Pr(X > t)} \\ &= 1 - \frac{S(x + t)}{S(t)}, \quad x \geq 0. \end{aligned}$$

A continuación definimos la vida residual media de X como la esperanza matemática de la vida residual.

Definición 5.4 Se denomina vida residual media de la variable X , y la denotaremos por $e_X(\cdot)$, a la esperanza matemática de la variable aleatoria vida residual,

$$e_X(t) = E(X_t) = E(X - t | X > t) = \int_0^\infty \frac{S(x + t)}{S(t)} dx = \frac{1}{S(t)} \int_t^\infty S(x) dx, \quad (5.5)$$

para $t \geq 0$ siempre que $S(x) > 0$ y $e_X(t) = 0$ para los valores t tales que $S(t) = 0$.

Observemos que hemos hecho uso de la fórmula de la esperanza matemática en términos de la función de distribución. La vida residual media permite estudiar el peso de la cola de la distribución. La función vida residual media viene determinada por la función de distribución como prueba (5.5). Por otro lado, la función de distribución se puede expresar en términos de la función vida residual media como veremos en la sección siguiente.

El siguiente resultado establece una relación entre la vida residual media y la función de azar.

Teorema 5.2 Sea X una variable aleatoria continua con vida residual media $e(x)$ y función de supervivencia $S(x)$. Entonces, la función de azar viene dada por,

$$r(x) = -\frac{S'(x)}{S(x)} = \frac{1 + e'(x)}{e(x)}. \quad (5.6)$$

Demostración: Se verifica que $S(x) \cdot e(x) = \int_x^\infty S(t)dt$. Derivando,

$$S(x)e'(x) + S'(x)e(x) = -S(x),$$

dividiendo todo por $S(x)$ y teniendo en cuenta que $r(x) = -S'(x)/S(x)$ obtenemos,

$$e'(x) - r(x)e(x) = -1,$$

de donde se sigue el resultado. ■

Ejemplo 5.4 La función de distribución del coste de un siniestro tiene como función de distribución,

$$F(x) = 1 - \frac{1}{x^\alpha}, \quad x > 1$$

y $F(x) = 0$ si $x < 1$. Obtener la función de azar y la vida residual media.

Solución: La función de densidad de X es: $f(x) = \frac{dF(x)}{dx} = \alpha x^{-(\alpha+1)}$, de donde la función de azar es,

$$r(x) = \frac{f(x)}{1 - F(x)} = \frac{\alpha x^{-(\alpha+1)}}{x^{-\alpha}} = \frac{\alpha}{x}, \quad x > 1.$$

Usando la expresión (5.5), la vida residual media es,

$$e(x) = \frac{\int_x^\infty S(t)dt}{S(x)} = \frac{\int_x^\infty t^{-\alpha}dt}{x^{-\alpha}} = \frac{x}{\alpha - 1}, \quad x > 1.$$

Usando (5.6) podemos obtener también la función de azar a partir de la vida residual media,

$$r(x) = \frac{1 + e'(x)}{e(x)} = \frac{1 + \frac{1}{\alpha-1}}{\frac{x}{\alpha-1}} = \frac{\alpha}{x}, \quad x > 1.$$

◇

5.4. Distribución estacionaria de renovación

La siguiente distribución de probabilidad juega un papel importante en la teoría de la ruina en tiempo continuo.

Definición 5.5 Sea X una variable aleatoria continua no negativa. Se denomina variable aleatoria estacionaria de renovación X_e a la variable con función de densidad:

$$f_{X_e}(x) = \frac{S_X(x)}{E(X)}, \quad x \geq 0. \quad (5.7)$$

5.5. Funciones generatriz, característica y generatriz de momentos

La expresión (5.7) define una función de densidad genuina, puesto que si X es no negativa entonces:

$$E(X) = \int_0^\infty S_X(x)dx \implies 1 = \int_0^\infty \frac{S_X(x)}{E(X)}dx,$$

de donde se sigue el resultado. La función de supervivencia de X_e es:

$$S_{X_e}(x) = \int_x^\infty f_{X_e}(x)dx = \frac{\int_x^\infty S_X(t)dt}{E(X)}, \quad x \geq 0.$$

La función de azar de la distribución estacionaria es:

$$r_{X_e}(x) = \frac{f_{X_e}(x)}{S_{X_e}(x)} = \frac{S_X(x)}{\int_x^\infty S_X(t)dt} = \frac{1}{e_X(x)}.$$

Por tanto, la inversa de la función de azar de la distribución estacionaria es la vida residual media.

Por medio de estos resultados podemos probar el teorema de inversión de la vida residual media.

Teorema 5.3 Sea X una variable aleatoria no negativa con función vida residual media $e_X(x)$. Entonces, la función de distribución se puede obtener como:

$$F_X(x) = 1 - \frac{e_X(0)}{e_X(x)} \exp \left[- \int_0^x \frac{1}{e_X(t)} dt \right].$$

Demostración: Por el resultado (5.3) aplicado a la distribución estacionaria tenemos:

$$f_{X_e}(x) = r_{X_e}(x)S_{X_e}(x) = r_{X_e}(x) \exp \left[- \int_0^x r_{X_e}(t)dt \right],$$

lo que equivale a:

$$S_X(x) = \frac{e_X(0)}{e_X(x)} \exp \left[- \int_0^x \frac{1}{e_X(t)} dt \right],$$

puesto que $e_X(0) = E(X)$, de donde se sigue el resultado. ■

5.5. Funciones generatriz, característica y generatriz de momentos

En este apartado presentamos tres funciones que son útiles para obtener probabilidades o momentos de las variables aleatorias de una manera sencilla y unificada. Estas funciones permiten en muchos casos identificar la distribución de la variable aleatoria bajo estudio, y permiten además obtener la distribución de algunas variables de especial interés en estadística actuarial, como son las convoluciones y las sumas de un número aleatorio de variables aleatorias.

5.5.1. Función generatriz

Esta función se utiliza para variables aleatorias discretas.

Definición 5.6 Sea X una variable aleatoria discreta que toma los valores $0, 1, 2, \dots$ con probabilidades $p_n = \Pr(X = n)$, $n = 0, 1, 2, \dots$. Se denomina función generatriz de probabilidad o simplemente función generatriz de X a la expresión:

$$P_X(s) = E(s^X) = \sum_{n=0}^{\infty} p_n s^n. \quad (5.8)$$

La función generatriz existe al menos para $-1 \leq s \leq 1$.

Algunas propiedades importantes aparecen en el siguiente teorema.

Teorema 5.4 La función generatriz verifica las siguientes propiedades:

- $P(1) = 1$.
- Para $|s| < 1$ existen las derivadas de $P(s)$ de cualquier orden.
- Para valores $0 \leq s < 1$, $P(s)$ y todas sus derivadas $P^{(k)}(s)$, $k = 1, 2, \dots$ son funciones no negativas, crecientes y convexas.
- La función generatriz determina unívocamente las probabilidades $p_n = \Pr(X = n)$ de la variable aleatoria de modo que se verifican las siguientes relaciones:

$$p_0 = P(0),$$

$$p_n = \frac{P^{(n)}(0)}{n!}, \quad n = 1, 2, \dots$$

- Los momentos factoriales de la variable aleatoria se obtienen de la función generatriz por medio de la relación:

$$f_r = E[X(X-1)\cdots(X-r+1)] = E[(X)_r] = P^{(r)}(1). \quad (5.9)$$

Por tanto, se verifica que:

$$f_1 = E(X) = P'(1), \quad f_2 = E(X^2) - E(X) = P''(1),$$

de donde:

$$\text{Var}(X) = P''(1) + P'(1) - [P'(1)]^2.$$

Demostración: Para ver que a partir de la función generatriz se obtienen las probabilidades hacemos:

$$\begin{aligned} P^{(n)}(s) &= E\left(\frac{d^n}{ds^n} s^X\right) = E[X(X-1)\cdots(X-n+1)s^{X-n}] \\ &= \sum_{k=n}^{\infty} k(k-1)\cdots(k-n+1)s^{k-n}p_k, \end{aligned}$$

de donde:

$$P^{(n)}(0) = n!p_n \Rightarrow p_n = \frac{P^{(n)}(0)}{n!}.$$

En la práctica es habitual que las compañías de seguros aseguren grupos de personas, cobrando interés la variable que mide la cantidad reclamada por estos grupos de personas, lo que nos lleva a trabajar con sumas de variables aleatorias. El siguiente resultado permite obtener la función generatriz de la suma de variables discretas y de la suma de un número aleatorio de variables aleatorias.

Teorema 5.5 Se verifican los siguientes resultados:

- (a) Sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes con funciones generatrices $P_k(t)$, $k = 1, 2, \dots, n$. Entonces, la función generatriz de la variable suma:

$$S_n = X_1 + X_2 + \dots + X_n,$$

viene dada por:

$$P_{S_n}(t) = \prod_{k=1}^n P_k(t).$$

- (b) Sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes e igualmente distribuidas con función generatriz común $P_X(s)$ y sea $N = \{0, 1, 2, \dots\}$ una variable aleatoria discreta con función generatriz $P_N(s)$ que es independiente de las X . Entonces, la función generatriz de la variable suma:

$$S_N = X_1 + X_2 + \dots + X_N,$$

es:

$$P_{S_N}(t) = P_N[P_X(t)]. \quad (5.10)$$

Demostración: Para la demostración del resultado (a) usaremos el hecho de que la esperanza del producto de variables aleatorias independientes es el producto de las esperanzas:

$$\begin{aligned} P_{S_n}(t) &= E(t^{X_1+\dots+X_n}) = E(t^{X_1} \dots t^{X_n}) \\ &= \prod_{k=1}^n E(t^{X_k}) = \prod_{k=1}^n P_k(t). \end{aligned}$$

La prueba del resultado (b) es la siguiente. La variable S_N es discreta y si $N = 0$ la suma es igual a cero. Por la propiedad de la esperanza condicionada:

$$P_{S_N}(t) = E(t^{S_N}) = E[E(t^{S_N}|N)].$$

A continuación, condicionando por $N = n$:

$$\begin{aligned} E(t^{S_N} | N = n) &= E(t^{X_1 + X_2 + \dots + X_n}) \\ &= [P_X(t)]^n, \end{aligned}$$

por la independencia de las variables. Por tanto:

$$E(t^{S_N} | N) = [P_X(t)]^N,$$

de donde:

$$\begin{aligned} E(t^{S_N}) &= E\{[P_X(t)]^N\} \\ &= \sum_{n=0}^{\infty} [P_X(t)]^n \Pr(N = n) \\ &= P_N[P_X(t)]. \end{aligned}$$

En el caso de que las variables X y N sean de tipo discreto, la ley de probabilidad de S_N se puede obtener fácilmente escribiendo la función generatriz de S_N en potencias de t . Veamos el siguiente ejemplo.

Ejemplo 5.5 La cartera de N clientes de una compañía de seguros se distribuye de acuerdo con la ley de probabilidad:

$$\Pr(N = 1) = \frac{1}{4}, \quad \Pr(N = 2) = \frac{1}{2}, \quad \Pr(N = 3) = \frac{1}{4}.$$

Cada cliente puede no reclamar cantidad alguna, lo que ocurre con probabilidad $1/4$, o bien reclamar una unidad con probabilidad $3/4$, de modo que la función de densidad del coste es:

$$\Pr(X_i = 0) = \frac{1}{4}, \quad \Pr(X_i = 1) = \frac{3}{4}.$$

Obtener la distribución de probabilidad del coste total S_N .

Solución: La función generatriz de N es:

$$P_N(t) = E(t^N) = \frac{1}{4} (1 + 2t^2 + t^3),$$

mientras que la función generatriz de X_i es:

$$P_X(t) = E(t^{X_i}) = \frac{1}{4} (1 + 3t).$$

Haciendo uso de la fórmula (5.10), la función generatriz de S_N es:

$$P_N[P_X(t)] = \frac{25}{256} + \frac{105t}{256} + \frac{99t^2}{256} + \frac{27t^3}{256}.$$

Por tanto, la función de probabilidad de S_N es:

$$\Pr(S_N = 0) = \frac{25}{256}, \quad \Pr(S_N = 1) = \frac{105}{256}, \quad \Pr(S_N = 2) = \frac{99}{256}, \quad \Pr(S_N = 3) = \frac{27}{256}.$$

5.5.2. Función característica

La función característica es un potente instrumento probabilístico para el estudio de las propiedades de las variables aleatorias.

Definición 5.7 La función característica $\varphi_X(t)$ de una variable aleatoria X se define como:

$$\varphi_X(t) = E(e^{itX}) = E(\cos tX) + iE(\sin tX),$$

donde $t \in \mathbb{R}$, $i = \sqrt{-1}$, y $\sin(\cdot)$ y $\cos(\cdot)$ representan la función seno y coseno, respectivamente.

Se trata por tanto de una función compleja de variable real. Si X es de tipo discreto y toma valores $\{x_1, x_2, \dots\}$ la función característica viene dada por:

$$\begin{aligned} \varphi_X(t) &= \sum_k e^{itx_k} \Pr(X = x_k) \\ &= \sum_k \cos(tx_k) \Pr(X = x_k) + i \sum_k \sin(tx_k) \Pr(X = x_k). \end{aligned}$$

Para una variable aleatoria continua con función de densidad $f_X(x)$, la función característica se obtiene como:

$$\begin{aligned} \varphi_X(t) &= \int_{-\infty}^{\infty} e^{itx} f_X(x) dx \\ &= \int_{-\infty}^{\infty} \cos(tx) f_X(x) dx + i \int_{-\infty}^{\infty} \sin(tx) f_X(x) dx. \end{aligned}$$

Algunas propiedades importantes de la función característica se obtienen en el siguiente teorema.

Teorema 5.6 La función característica cumple las siguientes propiedades:

- (a) $\varphi_X(0) = 1$ y $|\varphi_X(t)| \leq 1$.
- (b) $\varphi_X(t)$ es uniformemente continua.
- (c) La función característica $\varphi_X(t)$ determina unívocamente la distribución de la correspondiente variable aleatoria X .

- (d) Si la variable aleatoria X tiene como función característica $\varphi_X(t)$, la variable $Y = a + bX$ tiene como función característica:

$$\varphi_Y(t) = e^{iat} \varphi_X(bt).$$

- (e) Si el momento de orden r , $\alpha_r = E(X^r)$ existe, entonces $\varphi_X(t)$ tiene derivada de orden r , $\varphi_X^{(r)}(t)$ y además:

$$\alpha_r = E(X^r) = \frac{\varphi_X^{(r)}(0)}{i^r}.$$

En consecuencia:

$$\begin{aligned}\alpha_1 &= E(X) = \frac{\varphi_X'(0)}{i}, \\ \alpha_2 &= E(X^2) = -\varphi_X''(0).\end{aligned}$$

Si $E(X^r)$ existe, entonces $\varphi_X(t)$ se puede escribir como:

$$\varphi_X(t) = \sum_{k=0}^r \alpha_k \frac{(it)^k}{k!} + O(t^r),$$

donde $O(x)$ denota una cantidad tal que $\frac{O(x)}{x} \rightarrow 0$ cuando $x \rightarrow 0$.

El siguiente teorema es similar al teorema 5.5 pero para funciones características.

Teorema 5.7 Se verifican los siguientes resultados:

- (a) Sean $X_1, \dots, X_n$ variables aleatorias independientes con funciones características $\varphi_k(t)$, $k = 1, \dots, n$. Entonces, la función generatriz de la variable suma:

$$S_n = X_1 + \dots + X_n,$$

viene dada por:

$$\varphi_{S_n}(t) = \prod_{k=1}^n \varphi_k(t).$$

- (b) Sean $X_1, \dots, X_n$ variables aleatorias independientes e igualmente distribuidas con función característica común $\varphi_X(s)$ y sea $N = \{0, 1, 2, \dots\}$ una variable aleatoria discreta con función generatriz $P_N(s)$ independiente de las X . Entonces, la función característica de la variable suma:

$$S_N = X_1 + \dots + X_N,$$

es:

$$\varphi_{S_N}(t) = P_N[\varphi_X(t)].$$

Teoremas de Inversión de la Función Característica

En este apartado veremos el teorema fundamental de la función característica, llamado teorema de inversión, que establece que la función característica determina unívocamente la función de distribución de una variable aleatoria. Específicamente, se cumple que:

$$F_X(x) - F_X(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \frac{1 - e^{-itx}}{it} \varphi_X(t) dt. \quad (5.11)$$

Además, si $F_X(x)$ es continua en todo punto y $dF_X(x)/dx = f_X(x)$, se verifica que:

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi_X(t) dt. \quad (5.12)$$

Una forma alternativa de escribir (5.11) evitando $F_X(0)$ es:

$$F_X(x) = \frac{1}{2} + \frac{1}{2\pi} \int_0^{\infty} \frac{e^{itx} \varphi_X(-t) - e^{-itx} \varphi_X(t)}{it} dt. \quad (5.13)$$

Por otro lado, si $f_X(x)$ existe, podemos derivar (5.11) bajo el signo integral, para obtener (5.12) (la integral converge uniformemente). Si derivamos (5.13), obtenemos:

$$f_X(x) = \frac{1}{2\pi} \int_0^{\infty} [e^{itx} \varphi_X(-t) + e^{-itx} \varphi_X(t)] dt.$$

En el caso especial que la variable X sea de tipo discreto y tome únicamente valores enteros, se verifica que:

$$\Pr(X = k) = \frac{1}{2\pi} \int_{-\pi}^{\pi} e^{-ikt} \varphi_X(t) dt.$$

5.5.3. Función generatriz de momentos

La función generatriz de momentos es otra función asociada a la variable aleatoria y que es de uso habitual en estadística actuarial. Como su propio nombre indica, se usa para obtener los momentos de la distribución y también para caracterizar a la variable. Desde el punto de vista matemático, es una función algo menos potente que la función característica como veremos a continuación.

Definición 5.8 Sea X una variable aleatoria. Se denomina función generatriz de momentos de X y se representa por $M_X(t)$ a la función:

$$M_X(t) = E(e^{tX}),$$

siempre que la esperanza matemática exista para cualquier valor de t en un entorno de $t = 0$.

Si $M_X(t) = E(e^{tX})$ existe para t en algún entorno del 0, entonces $E|X|^n < \infty$ para todo $n \geq 1$. Para variables aleatoria discretas, la función generatriz se puede obtener como:

$$M_X(t) = \sum_x e^{tx} \Pr(X = x),$$

mientras que en el caso continuo hay que hallar:

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx.$$

El siguiente resultado muestra algunas propiedades básicas de la función generatriz de momentos.

Teorema 5.3 *Se verifican las siguientes propiedades:*

▪ Si X tiene función generatriz de momentos $M_X(t)$, entonces:

$$E(X^n) = M_X^{(n)}(0),$$

donde:

$$M_X^{(n)}(0) = \frac{d^n}{dt^n} M_X(t)|_{t=0}.$$

▪ La función generatriz de momentos de X es $M_X(t)$, la función generatriz de $Y = a + bX$ es:

$$M_Y(t) = e^{at} M_X(bt).$$

El siguiente ejemplo muestra dos variables aleatorias distintas con los mismos momentos $\{E(X^r), r = 0, 1, 2, \dots\}$. Por tanto, y en general, una distribución no viene caracterizada por la sucesión de los momentos.

Ejemplo 5.6 Consideremos dos variables aleatorias X e Y con las siguientes funciones de densidad:

$$\begin{aligned} f_X(x) &= \frac{1}{x\sqrt{2\pi}} e^{-(\log x)^2/2}, \quad x \geq 0, \\ f_Y(y) &= f_X(y)[1 + \sin(2\pi \log y)], \quad y \geq 0. \end{aligned}$$

Obtener sus momentos.

Solución: La variable aleatoria X recibe el nombre de distribución log-normal y será estudiada en el capítulo 7. Se verifica que: $E(X^r) = e^{r^2/2}$, $r = 0, 1, \dots$ Para la segunda variable:

$$E(Y^r) = \int_0^{\infty} y^r f_X(y)[1 + \sin(2\pi \log y)] dy$$




Figura 5.2: Dos funciones de densidad diferentes con el mismo conjunto de momentos

$$\begin{aligned} &= E(X^r) + \int_0^{\infty} y^r f_X(y) \sin(2\pi \log y) dy \\ &= E(X^r) + \frac{1}{\sqrt{2\pi}} e^{r^2/2} \int_{-\infty}^{\infty} e^{-t^2/2} \sin(2\pi t) dt \\ &= E(X^r). \end{aligned}$$

Para obtener la última integral se ha realizado el cambio $z = \log y - r$ y un nuevo cambio de origen, lo que lleva a que el valor de la integral sea 0, puesto que se trata de la integral de una función par en un intervalo simétrico. La figura 5.2 muestra las gráficas de las funciones de densidad de X e Y .

El problema de la unicidad de los momentos no ocurre en variables aleatorias con soporte acotado. Afortunadamente, si la función generatriz de momentos existe en un entorno del cero, la distribución está unívocamente determinada por la sucesión de momentos, independientemente de que el soporte sea acotado o no. El siguiente teorema prueba cómo caracterizar una distribución a partir de los momentos.

Teorema 5.9 Sean X e Y variables aleatorias con funciones de distribución $F_X(x)$ y $F_Y(y)$, donde todos los momentos existen.

(a) Si F_X y F_Y tienen soporte acotado, entonces $F_X(u) = F_Y(u)$ para todo valor de u si y sólo si $E(X^r) = E(Y^r)$, para valores $r = 0, 1, 2, \dots$

(b) Si las funciones generatrices de momentos existen y $M_X(t) = M_Y(t)$ para todo t en un entorno de 0, entonces $F_X(u) = F_Y(u)$ para todo valor de u .

5.5.4. Relaciones entre las tres funciones

Las tres funciones vistas anteriormente están relacionadas, y siempre que existan se pueden obtener conociendo una de ellas. Concretamente, si para una variable aleatoria X las funciones $P_X(t)$, $\varphi_X(t)$ y $M_X(t)$ existen, entonces:

$$M_X(t) = P_X(e^t) = \varphi_X(-it), \quad (5.14)$$

$$\varphi_X(t) = M_X(it) = P_X(e^{it}), \quad (5.15)$$

además

$$P_X(t) = \varphi_X(-i \log t). \quad (5.16)$$

5.5.5. Cumulantes y función generatriz de cumulantes

A continuación incluimos otra función que da lugar a los llamados cumulantes e indirectamente a los momentos de la variable.

Definición 5.9 Si la función:

$$\kappa_X(t) = \log E(e^{tX}) = \log M_X(t)$$

se puede desarrollar en potencias de t de la forma:

$$\kappa_X(t) = \sum_{r=1}^{\infty} \frac{\kappa_r t^r}{r!}, \quad (5.17)$$

entonces se la denomina función generatriz de cumulantes κ_r , y a las cantidades $\{\kappa_r, r = 1, 2, \dots\}$ se les denomina cumulantes.

Observemos que (5.17) no contiene término en t^0 . Veamos un ejemplo.

Ejemplo 5.7 Para X una variable aleatoria de Poisson, obtener sus cumulantes.

Solución: Tenemos que para una variable aleatoria tipo Poisson: $M_X(t) = \exp\{\lambda(e^t - 1)\}$, de donde:

$$\log M_X(t) = \log[\exp\{\lambda(e^t - 1)\}] = \lambda(e^t - 1) = \sum_{r=1}^{\infty} \frac{\lambda t^r}{r!}.$$

En consecuencia $\kappa_r = \lambda$ para $r = 1, 2, \dots$

◇

5.6. Transformaciones útiles en reaseguros

Se verifica que:

$$\kappa_{X+b}(t) = bt + \kappa_X(t),$$

de donde para $r \geq 2$ los coeficientes de $t^r/r!$ de $\kappa_{X+b}(t)$ y $\kappa_X(t)$ son los mismos y por tanto para $r \geq 2$ los cumulantes de X coinciden con los cumulantes de la variable $X + b$. Si escribimos $b = -\mu_X$, los cumulantes κ_r son funciones de los momentos centrales, y se verifica que:

$$\kappa_1 = \mu,$$

$$\kappa_2 = \mu_2,$$

$$\kappa_3 = \mu_3,$$

$$\kappa_4 = \mu_4 - 3\mu_2^2.$$

El siguiente resultado establece que el cumulante de una suma es igual a la suma de los cumulantes en el caso de independencia.

Teorema 5.10 Sean $X_1, \dots, X_n$ variables aleatorias independientes y sea $S = \sum_{i=1}^n X_i$. Entonces, se verifica que:

$$\kappa_{S_n}(t) = \sum_{i=1}^n \kappa_{X_i}(t),$$

y por tanto:

$$\kappa_r \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \kappa_r(X_i), \quad r = 1, 2, \dots$$

5.6. Transformaciones útiles en reaseguros

En este apartado estudiaremos algunas transformaciones de variables aleatorias de aplicación en reaseguros, que se tratarán en el capítulo 12. La variable aleatoria X representa la la cantidad reclamada, y suponemos que X es no negativa y que tiene como función de distribución $F_X(x)$.

5.6.1. Transformación stop-loss

Definición 5.10 Supongamos que la variable aleatoria X representa una pérdida y por tanto es no negativa. Sea d un número real positivo que llamaremos retención. Se denomina transformación stop-loss de X a:

$$(X - d)_+ = \max\{X - d, 0\} = \begin{cases} X - d & \text{si } X > d, \\ 0 & \text{si } X \leq d. \end{cases}$$

Definimos a continuación la prima neta en un contrato de reaseguro de tipo stop-loss.

Definición 5.11 Se define la cantidad $\pi_X(d)$ como la esperanza matemática de la variable stop-loss $(X - d)_+$,

$$\pi_X(d) = E[(X - d)_+], \quad d \geq 0.$$

A $\pi_X(d)$ la llamaremos posteriormente prima neta del reaseguro. La existencia de π_X presupone que $\mu_X < \infty$. Obviamente si $d = 0$, $\pi_X(0) = \mu_X$.

Si la variable aleatoria X es de tipo discreto con función de probabilidad $p_k = \Pr(X = x_k)$, $k = 0, 1, 2, \dots$ entonces:

$$\pi_X(d) = E[(X - d)_+] = \sum_{\{x_k > d\}} (x_k - d)p_k.$$

Si ahora X es continua con función de densidad $f_X(x)$, entonces:

$$\pi_X(d) = E[(X - d)_+] = \int_d^\infty (x - d)f_X(x)dx.$$

Si queremos calcular los momentos de orden superior a uno de la variable $(X - d)_+$ aplicamos las fórmulas usuales. Por ejemplo, si X es de tipo continuo,

$$E[(X - d)_+^k] = \int_d^\infty (x - d)^k f_X(x)dx.$$

Para el cálculo práctico de $\pi_X(d)$ conviene tener en cuenta las siguientes fórmulas:

▪ Caso discreto:

$$\pi_X(d) = E(X - d)_+ = \mu_X - d - \sum_{\{x_k \leq d\}} x_k p_k + d \sum_{\{x_k \leq d\}} p_k.$$

▪ Caso continuo:

$$\pi_X(d) = E(X - d)_+ = \mu_X - d - \int_0^d x f_X(x)dx + d \int_0^d f_X(x)dx.$$

Una fórmula alternativa para el cálculo de $\pi_X(d)$ es:

$$\pi_X(d) = E[(X - d)_+] = \int_d^\infty [1 - F_X(x)]dx, \quad d \geq 0. \quad (5.18)$$

Finalmente, nótese que:

$$\pi'_X(d) = F_X(d) - 1,$$

lo que en ocasiones puede ayudar al cálculo de la prima neta.

Ejemplo 5.8 La distribución de las pérdidas X de un tipo de accidente se puede modelizar por medio de una variable aleatoria continua de tipo exponencial con función de distribución:

$$F_X(x) = 1 - e^{-x/\sigma}, \quad x \geq 0$$

y $F_X(x) = 0$ si $x < 0$, donde $E(X) = \sigma$. Obtener $\pi_X(d)$, para $d > 0$.

Solución: Usando (5.18) el valor medio de la transformación stop-loss es,

$$\pi_X(d) = E[(X - d)_+] = \int_d^\infty [1 - F_X(x)]dx = \int_d^\infty e^{-x/\sigma} dx = \sigma e^{-d/\sigma}.$$

◇

5.6.2. Variable límite de pérdida

Sea X la pérdida en que ha incurrido un asegurado, y supongamos que la póliza de su seguro sólo cubre hasta un límite de u . Por tanto, la cantidad que paga la compañía al asegurado es,

$$\min\{X, u\} = X \wedge u.$$

donde $\min\{X, u\}$ significa el menor valor de entre X y u . Esto nos conduce a la siguiente definición.

Definición 5.12 Se denomina variable límite de pérdida X a:

$$X \wedge u = \min\{X, u\} = \begin{cases} X & \text{si } X < u \\ u & \text{si } X \geq u. \end{cases}$$

Se denomina valor límite de pérdida esperado a la esperanza matemática de la variable límite de pérdida, es decir $E(X \wedge u)$.

La variable límite de de pérdida es en realidad una variable censurada por la derecha. Si observamos que,

$$X = (X \wedge d) + (X - d)_+,$$

entonces

$$E(X) = E(X \wedge d) + E(X - d)_+.$$

Esto significa que comprando una póliza con un límite de d (un seguro) y otra con un deducible de d , es equivalente a comprar toda la cobertura del riesgo. Para el cálculo del valor límite de pérdida esperado y en general para los momentos de $X \wedge u$ se usan las siguientes fórmulas,

■ Caso discreto,

$$E[(X \wedge u)^k] = \sum_{x_i \leq u} x_i^k \Pr(X = x_i) + u^k [1 - F_X(u)].$$

■ Caso continuo,

$$E[(X \wedge u)^k] = \int_{-\infty}^u x^k f_X(x) dx + u^k [1 - F_X(u)].$$

En particular, en el caso continuo:

$$E(X \wedge u) = \int_{-\infty}^u x f_X(x) dx + u [1 - F_X(u)]. \quad (5.19)$$

A partir de (5.19) se puede deducir una fórmula alternativa en términos de las funciones de distribución y supervivencia, que viene dada por:

$$E(X \wedge u) = - \int_{-\infty}^0 F_X(x) dx + \int_0^u S_X(x) dx. \quad (5.20)$$

Ejemplo 5.9 Obtener el valor límite de pérdida esperado, suponiendo una distribución de pérdidas de tipo exponencial con función de distribución $F(x) = 1 - e^{-x/\sigma}$, $x > 0$.

Solución: Puesto que se trata de una variable aleatoria no negativa, (5.20) se reduce a,

$$E(X \wedge u) = \int_0^u S_X(x) dx = \int_0^u e^{-x/\sigma} dx = \sigma(1 - e^{-u/\sigma}).$$

◇

5.6.3. Otras transformaciones

Los siguientes resultados permiten obtener las funciones de densidad y distribución de las transformaciones de escala y de las potencias. Comenzamos por la transformación de escala, que permite incluir el efecto inflación de una variable monetaria.

Teorema 5.11 Sea X una variable aleatoria continua con función de distribución F_X y función de densidad f_X . Entonces, la variable aleatoria $Y = aX$, donde $a > 0$, tiene respectivamente como funciones de distribución y de densidad,

$$\begin{aligned} F_Y(y) &= F_X\left(\frac{y}{a}\right), \\ f_Y(y) &= \frac{1}{a} f_X\left(\frac{y}{a}\right). \end{aligned}$$

5.7. Mezclas de distribuciones

El siguiente resultado se refiere a la transformación potencial

Teorema 5.12 Sea X una variable aleatoria continua no negativa con función de distribución F_X y función de densidad f_X . Entonces, la variable aleatoria $Y = X^a$, donde $a > 0$, tiene respectivamente como funciones de distribución y de densidad,

$$\begin{aligned} F_Y(y) &= F_X(y^{1/a}), \\ f_Y(y) &= \frac{1}{a} y^{1/a-1} f_X(y^{1/a}). \end{aligned}$$

Si $a < 0$, las funciones anteriores vienen dadas por,

$$\begin{aligned} F_Y(y) &= 1 - F_X(y^{1/a}), \\ f_Y(y) &= -\frac{1}{a} y^{1/a-1} f_X(y^{1/a}). \end{aligned}$$

Si $a = -1$, la transformación $Y = \frac{1}{X}$ se denomina transformación inversa.

5.7. Mezclas de distribuciones

Consideremos una variable aleatoria X que representa una distribución de pérdidas y cuya función de distribución F depende de un parámetro θ . Supongamos que todos los sucesos de pérdidas son el resultado de una realización de la variable aleatoria X , pero que el parámetro θ puede variar de un suceso a otro. Por ejemplo, si la variable X representa las pérdidas por accidentes de automóvil, dichas pérdidas pueden depender de la antigüedad del vehículo o bien de la experiencia del conductor. Esto significa que la función de distribución de la X está condicionada por el valor de θ . Puesto que θ es también aleatorio, esto nos lleva a tener que especificar una distribución de probabilidad (discreta o continua) para θ . La distribución que se obtiene de este modo se dice que es una mezcla de distribuciones o una mixturas de distribuciones.

Teorema 5.13 Sea X una variable aleatoria con función de distribución $F_{X|\Theta}(x|\theta)$ y función de densidad $f_{X|\Theta}(x|\theta)$, donde θ es un parámetro. Supongamos que θ es la realización de una variable aleatoria continua Θ con función de densidad $f_{\Theta}(\theta)$. Entonces, la distribución incondicional de X tiene como función de densidad y función de distribución,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X|\Theta}(x|\theta) f_{\Theta}(\theta) d\theta, \quad (5.21)$$

$$F_X(x) = \int_{-\infty}^{\infty} F_{X|\Theta}(x|\theta) f_{\Theta}(\theta) d\theta, \quad (5.22)$$

respectivamente.

Demostración: La función de densidad conjunta de (X, Θ) se puede escribir como,

$$f_{X, \Theta}(x, \theta) = f_{X|\Theta}(x|\theta)f_{\Theta}(\theta),$$

y la función de densidad marginal de X se obtiene integrando la densidad conjunta. ■

Los momentos de la distribución X se pueden obtener a partir de los momentos condicionales por medio de la fórmula,

$$E(X^r) = E_{\Theta} [E(X^r|\Theta)].$$

5.8. Estadísticos de orden

Partimos de n variables aleatorias independientes e igualmente distribuidas $X_1, \dots, X_n$ con función de distribución común $F(x)$ y función de densidad $f(x)$. Si ordenamos de menor a mayor las n variables

$$X_{1:n} \leq X_{2:n} \leq \dots \leq X_{n:n},$$

se dice que $X_{r:n}$ es el estadístico de orden r , y $X_{1:n}$ $X_{n:n}$ los extremos, mínimo y máximo, respectivamente. Vamos a obtener las funciones de distribución y de densidad de estos estadísticos.

5.8.1. Distribuciones de extremos

Las funciones de distribución y de densidad del mínimo vienen dadas respectivamente por,

$$F_{X_{1:n}}(x) = 1 - [1 - F(x)]^n, \quad (5.23)$$

$$f_{X_{1:n}}(x) = n[1 - F(x)]^{n-1}f(x). \quad (5.24)$$

Efectivamente,

$$\begin{aligned} F_{X_{1:n}}(x) &= \Pr(X_{1:n} \leq x) = 1 - \Pr(X_{1:n} > x) \\ &= 1 - \Pr(X_1 > x, \dots, X_n > x) \\ &= 1 - \Pr(X_1 > x) \cdots \Pr(X_n > x) \\ &= 1 - [1 - F(x)]^n, \end{aligned}$$

y la función de densidad,

$$f_{X_{1:n}}(x) = \frac{d}{dx} F_{X_{1:n}}(x) = n[1 - F(x)]^{n-1}f(x).$$

5.8. Estadísticos de orden

Para el caso del máximo de las n variables, las funciones de distribución y de densidad vienen dadas por,

$$F_{X_{n:n}}(x) = [F(x)]^n, \quad (5.25)$$

$$f_{X_{n:n}}(x) = n[F(x)]^{n-1}f(x). \quad (5.26)$$

Para obtener estos resultados hacemos,

$$\begin{aligned} F_{X_{n:n}}(x) &= \Pr(X_{n:n} \leq x) \\ &= \Pr(X_1 \leq x, \dots, X_n \leq x) \\ &= \Pr(X_1 \leq x) \cdots \Pr(X_n \leq x) \\ &= [F(x)]^n, \end{aligned}$$

y la función de densidad,

$$f_{X_{n:n}}(x) = \frac{d}{dx} F_{X_{n:n}}(x) = n[F(x)]^{n-1}f(x).$$

5.8.2. Distribución de un estadístico de orden

La función de distribución del r -ésimo estadístico de orden es,

$$\begin{aligned} F_{X_{r:n}}(x) &= \Pr(X_{r:n} \leq x) \\ &= \Pr(\text{al menos } r \text{ de los } X_i \text{ son menores o iguales que } x) \\ &= \sum_{i=r}^n \binom{n}{i} F^i(x) [1 - F(x)]^{n-i}, \end{aligned} \quad (5.27)$$

donde los términos dentro del sumatorio son la probabilidad binomial de que exactamente i de los $X_1, \dots, X_n$ sean menores o iguales que x . Usando la relación entre las sumas de probabilidades binomiales y la función beta incompleta, la fórmula (5.27) se puede expresar como,

$$F_{X_{r:n}}(x) = I_{F(x)}(r, n - r + 1),$$

donde $I_p(a, b)$ es la función beta incompleta definida por,

$$I_p(a, b) = \frac{\int_0^p t^{a-1} (1-t)^{b-1} dt}{B(a, b)}.$$

La función de densidad del estadístico de orden r es,

$$\begin{aligned} f_{X_{r:n}}(x) &= \frac{1}{B(r, n - r + 1)} \frac{d}{dx} \int_0^{F(x)} t^{r-1} (1-t)^{n-r} dt \\ &= \frac{1}{B(r, n - r + 1)} F^{r-1}(x) [1 - F(x)]^{n-r} f(x). \end{aligned} \quad (5.28)$$

Haciendo $r = 1$ en (5.28) obtenemos la función de densidad del mínimo (5.24) y haciendo $r = n$ la función de densidad del máximo (5.26).

Ejemplo 5.10 Un seguro cubre pérdidas a viviendas por inundaciones. Supongamos que la cantidad reclamada es una variable aleatoria X con función de densidad,

$$f(x) = \frac{4}{x^5}, \quad x > 1,$$

y $f(x) = 0$ si $x < 1$. Se realizan cuatro reclamaciones de este tipo. Obtener la función de densidad de la máxima cantidad reclamada y el valor medio reclamado.

Solución: La función de distribución de un valor X individual es,

$$F(x) = \int_1^x \frac{4}{t^5} dt = 1 - \frac{1}{x^4}, \quad x > 1.$$

Puesto que se trata de la función de densidad del máximo de $n = 4$ variables, usando (5.26), la función de densidad es,

$$f_{X_{4:4}}(x) = 4[F(x)]^3 f(x) = 4 \left(1 - \frac{1}{x^4}\right)^3 \frac{4}{x^5} = \frac{16(x^4 - 1)^3}{x^{17}},$$

si $x > 1$ y 0 en otro caso. El valor medio es,

$$E(X_{4:4}) = \int_1^\infty \frac{16x(x^4 - 1)^3}{x^{17}} dx = 1,7732.$$

◇

5.9. Problemas propuestos

1. La variable aleatoria X representa una distribución de pérdidas y tiene como función de azar (Greenwich, 1992),

$$r(x) = \frac{ax}{b^2 + x^2}, \quad x \geq 0,$$

donde $a, b > 0$.

- a) Probar que $r(x)$ tiene un máximo.
- b) Probar que la función de distribución de X viene dada por,

$$F(x) = 1 - \frac{1}{(1 + x^2/b^2)^{a/2}}, \quad x \geq 0.$$

5.9. Problemas propuestos

2. Sea X una variable aleatoria discreta con función generatriz de probabilidad $P(s) = \exp[5(s-1)]$.

- a) Demostrar que la varianza de X es 5.
- b) Por medio de $P(s)$, calcular $\Pr(X = 2)$.

3. Para una variable aleatoria de tipo exponencial con función de densidad,

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0$$

y $f(x) = 0$ si $x < 0$, probar que el cumulante de orden r , κ_r viene dado por,

$$\kappa_r = \frac{(r-1)!}{\theta^r}, \quad r = 1, 2, \dots$$

4. La función de distribución de la cantidad reclamada de un siniestro es:

$$F(x) = 1 - e^{-(x-5)}, \quad \text{si } x \geq 5,$$

y $F(x) = 0$ si $x < 5$. Se dispone de los datos de reclamaciones correspondientes a 10 siniestros que se pueden considerar como independientes.

- a) Funciones de distribución y de densidad de la menor y la mayor cantidad reclamada. Obtener las medias y las varianzas.
- b) Función de distribución y de densidad de la k -ésima cantidad reclamada, donde $k = 1, \dots, 10$.

5. Supongamos una distribución de pérdidas es de tipo log-normal con función de densidad,

$$f(x; \mu, \sigma) = \frac{1}{x\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{\log x - \mu}{\sigma} \right)^2 \right\}, \quad x > 0,$$

donde $\sigma > 0$ y $\mu \in \mathbb{R}$. Probar que la prima neta viene dada por,

$$\pi_X(d) = E[(X-d)_+] = \exp(\mu + \sigma^2/2) \Phi(d_1) - d\Phi(d_2),$$

donde:

$$d_1 = \frac{\mu + \sigma^2 - \log d}{\sigma}, \quad d_2 = d_1 - \sigma$$

y $\Phi(\cdot)$ denota la función de distribución de la variable normal estándar.

6. Se lanzan n dados. Hallar la media y la varianza de la variable aleatoria puntuación total obtenida. Misma cuestión si se lanzan un número aleatorio N de dados, de modo que $\Pr(N = k) = 1/n$, donde $k = 1, 2, \dots, n$.

Capítulo 6

Distribuciones de tipo Discreto

6.1. Introducción

En este tema nos ocuparemos de las principales distribuciones de probabilidad de tipo discreto. Este tipo de distribuciones se usan principalmente para modelizar el número de reclamaciones de una cartera de seguros. Estudiaremos diversas distribuciones que podemos clasificar como distribuciones clásicas, sistemas de distribuciones y distribuciones compuestas.

Las distribuciones clásicas incluyen a las distribuciones uniforme discreta, de Bernoulli, binomial, de Poisson, hipergeométrica, geométrica o de Pascal, binomial negativa, logarítmica y multinomial. Los sistemas de distribuciones incluyen a las clases $(a, b, 0)$ y $(a, b, 1)$. Las distribuciones compuestas se usarán en el modelo de riesgo colectivo en el capítulo 13.

Estudiaremos cuál es el origen de cada distribución, las correspondientes funciones de probabilidad, los momentos y las propiedades que se consideren más importantes en cada caso. El libro Johnson, Kemp y Kotz (2005) es un texto clásico sobre distribuciones discretas.

6.2. Distribución uniforme discreta

La distribución uniforme discreta asigna la misma probabilidad a cada valor de un conjunto discreto. En ocasiones recibe el nombre de distribución discreta rectangular.

Definición 6.1 *Una variable aleatoria X sigue una distribución uniforme discreta*

si la función de densidad viene dada por,

$$\Pr(X = x) = \frac{1}{n+1}, \quad x = 0, 1, 2, \dots, n. \quad (6.1)$$

La distribución uniforme discreta es simétrica respecto $n/2$. La función generatriz de (6.1) es,

$$G(z) = \frac{1}{n+1}(1 + z + z^2 + \dots + z^n) = \frac{1 - z^{n+1}}{(n+1)(1-z)}. \quad (6.2)$$

Los momentos respecto del origen vienen dados por,

$$E(X^k) = \sum_{j=1}^n \frac{j^k}{n+1}, \quad k = 1, 2, \dots$$

Los cuatro primeros momentos respecto de la media son:

$$\begin{aligned} E(X) = \mu &= \frac{n}{2}, \\ E(X - \mu)^2 &= \frac{n(n+2)}{12}, \\ E(X - \mu)^3 &= 0, \\ E(X - \mu)^4 &= \frac{n(n+2)(3n^2 + 6n - 4)}{240}. \end{aligned}$$

6.2.1. Convoluciones

Consideremos k variables aleatorias independientes $X_1, \dots, X_k$ con función de probabilidad como en (6.1). Si $S = X_1 + \dots + X_k$ es la suma de las k variables, y teniendo en cuenta (6.2) la función generatriz de S es,

$$P_S(z) = [P_X(z)]^k = \frac{(1 - z^{n+1})^k}{(n+1)^k(1-z)^k} = \sum_{j=0}^{nk} \frac{c_j(k, n+1)z^j}{(n+1)^k},$$

donde $c_j(k; n+1)$ vienen dados por,

$$c_j(k; n+1) = \sum_{i=0}^{[j/(n+1)]} (-1)^i \binom{j - ni - i + k - 1}{k-1} \binom{k}{i},$$

donde $[x]$ es el mayor entero menor o igual que x . Esta distribución ha sido recientemente estudiada por Ericksen (2002). La función de probabilidad de S viene por tanto dada por,

$$\Pr(S = j) = \frac{c_j(k; n+1)}{(n+1)^k}, \quad j = 0, 1, \dots, nk.$$

6.3. Distribución de Bernoulli

La variable aleatoria de Bernoulli surge en situaciones donde tenemos un experimento aleatorio con dos posibles resultados: éxito o fracaso. La probabilidad de éxito es p y la probabilidad de fracaso es $1 - p = q$, con $0 \leq p \leq 1$. Este tipo de experimento aleatorio se denomina *ensayo o experimento de Bernoulli*. Definimos entonces la variable aleatoria de Bernoulli.

Definición 6.2 La variable aleatoria:

$$X = \{\text{Número de éxitos en un ensayo de tipo Bernoulli}\},$$

se la denomina variable de Bernoulli, y se denota por $X \sim \text{Be}(p)$.

Una variable de Bernoulli toma dos valores, 0 y 1, y la función de densidad es:

$$\Pr(X = 1) = p, \quad \Pr(X = 0) = 1 - p = q,$$

o de forma abreviada:

$$\Pr(X = x) = p^x(1-p)^{1-x}, \quad x = 0, 1.$$

El momento de orden k respecto del origen es,

$$E(X^k) = 0^k \cdot \Pr(X = 0) + 1^k \cdot \Pr(X = 1) = p.$$

Las expresiones de la media y la varianza son:

$$E(X) = p, \quad \text{Var}(X) = p(1-p).$$

Los momentos anteriores también pueden obtenerse por medio de la función generatriz, que viene dada por,

$$P_X(s) = E(s^X) = 1 - p + ps.$$

Ejemplo 6.1 Un agente de seguros realiza visitas a domicilio para vender seguros de vida. El resultado de una visita se clasifica como éxito si vende un seguro, lo que ocurre con probabilidad 0,2 y fracaso si no lo vende. Modelizar como un experimento de Bernoulli.

Solución: La variable aleatoria:

$$X = \begin{cases} 1 & \text{si vende el seguro,} \\ 0 & \text{otro caso,} \end{cases}$$

es de tipo Bernoulli, con probabilidad de éxito $p = 0,2$. La función de densidad es:

$$\Pr(X = x) = 0,2^x(1-0,2)^{1-x}, \quad x = 0, 1.$$

La media y varianza de X son respectivamente: $\mu = p = 0,2$ y $\sigma^2 = p(1-p) = 0,16$.

◇

6.4. Distribución binomial

Supongamos que se realizan n experimentos de tipo Bernoulli verificando las siguientes condiciones:

1. Los experimentos son idénticos, es decir, la probabilidad de éxito p es la misma en todos los ensayos.
2. Los experimentos son independientes, es decir, el resultado de un experimento no influye en el resultado de los otros.

Bajo estas condiciones se define la distribución binomial.

Definición 6.3 Se realizan n ensayos de Bernoulli independientes, con probabilidad de éxito igual a p . A la variable aleatoria:

$$X = \{\text{Número de éxitos en los } n \text{ ensayos}\},$$

se le denomina binomial, y la correspondiente distribución, distribución binomial.

Se representa por $X \sim B(n, p)$. La función de probabilidad es:

$$\Pr(X = x) = \binom{n}{x} p^x (1-p)^{n-x}, \text{ si } x = 0, 1, \dots, n. \quad (6.3)$$

Los valores que toma la variable están comprendidos entre 0 y n . Si se obtienen x éxitos, significa que se obtienen $n - x$ fracasos. Por tanto, puesto que los experimentos son idénticos e independientes, la probabilidad de x éxitos y $n - x$ fracasos es:

$$p^x (1-p)^{n-x}.$$

Ahora, el número de formas de obtener x éxitos (y $n - x$ fracasos) en n ensayos se obtiene por la fórmula de las permutaciones con repetición:

$$PR_{x, n-x}^n = \frac{n!}{x!(n-x)!} = \binom{n}{x},$$

lo que da lugar a la ley de probabilidad (6.3). El nombre de distribución binomial procede de que las probabilidades se pueden obtener a partir del desarrollo del binomio de Newton $(p + q)^n = 1$.

6.4.1. Representación

A partir de la definición de la distribución binomial se deduce que se puede representar como suma de variables de Bernoulli. Si $Z_1, \dots, Z_n$ son variables aleatorias independientes e igualmente distribuidas $Be(p)$, entonces la variable suma $X = Z_1 + \dots + Z_n$ se distribuye según una binomial, es decir:

$$X = Z_1 + Z_2 + \dots + Z_n \sim B(n, p). \quad (6.4)$$

6.4. Distribución binomial

Por medio de esta propiedad se deducen fácilmente muchas propiedades de la distribución binomial.

6.4.2. Funciones generatriz y característica

Sea $X \sim B(n, p)$. Usando la representación (6.4) y teniendo en cuenta que las Z_i son independientes de tipo Bernoulli, la función generatriz es,

$$\begin{aligned} P_X(s) &= E(s^X) = E(s^{Z_1+Z_2+\dots+Z_n}) = E(s^{Z_1})E(s^{Z_2})\dots E(s^{Z_n}) \\ &= [P_Z(s)]^n = (1-p+ps)^n, \end{aligned}$$

puesto que las Z_i tienen como función generatriz $P_Z(s) = 1-p+ps$. La función característica viene dada por,

$$\varphi_X(t) = P_X(e^{it}) = (1-p+pe^{it})^n.$$

6.4.3. Momentos

Si $X \sim B(n, p)$ es una distribución binomial, la media y la varianza son:

$$\begin{aligned} E(X) &= np, \\ \text{Var}(X) &= np(1-p). \end{aligned}$$

Para probar este resultado basta tener nuevamente en cuenta la propiedad (6.4) de donde se obtiene que:

$$E(X) = E(Z_1 + \dots + Z_n) = E(Z_1) + \dots + E(Z_n) = p + \dots + p = np,$$

y para la varianza:

$$\begin{aligned} \text{Var}(X) &= \text{Var}(Z_1 + \dots + Z_n) = \text{Var}(Z_1) + \dots + \text{Var}(Z_n) \\ &= p(1-p) + \dots + p(1-p) = np(1-p). \end{aligned}$$

Notar que $E(X) > \text{Var}(X)$ y por tanto la variable cumple la propiedad de sub-dispersión (media mayor que varianza). Los momentos factoriales son:

$$P_X^{(r)}(1) = E[X(X-1)\dots(X-r+1)] = n(n-1)\dots(n-r+1)p^r, \quad r = 1, 2, \dots$$

y en particular:

$$\begin{aligned} E(X) &= np, \\ E[X(X-1)] &= n(n-1)p^2, \\ E[X(X-1)(X-2)] &= n(n-1)(n-2)p^3, \\ E[X(X-1)(X-2)(X-3)] &= n(n-1)(n-2)(n-3)p^4. \end{aligned}$$

A partir de las expresiones anteriores se obtienen los coeficientes de asimetría y curtosis de una distribución binomial, que vienen dados por,

$$\gamma_1 = \frac{1-2p}{\sqrt{np(1-p)}},$$

$$\gamma_2 = \frac{1-6p(1-p)}{np(1-p)}.$$

A partir de γ_1 se deduce que la distribución binomial es simétrica si $p = 1/2$, asimétrica positiva si $p < 1/2$ y asimétrica negativa si $p > 1/2$. Por otro lado, si llamamos $p_a = (1 - 1/\sqrt{3})/2$ y $p_b = (1 + 1/\sqrt{3})/2$, la binomial es mesocúrtica cuando $p = p_a$ ó $p = p_b$, platocúrtica cuando $p \in (p_a, p_b)$ y leptocúrtica si p está fuera del intervalo $[p_a, p_b]$.

6.4.4. Convoluciones

La suma de variables aleatorias binomiales independientes con la misma probabilidad de éxito p es de nuevo una distribución binomial, donde el número de ensayos es la suma del número de ensayos de las componentes. Se cumple el siguiente resultado.

Teorema 6.1 Si $X_1, \dots, X_m$ son variables aleatorias independientes tales que:

$$X_1 \sim B(n_1, p), \dots, X_m \sim B(n_m, p),$$

entonces:

$$X_1 + \dots + X_m \sim B(n_1 + \dots + n_m, p).$$

Demostración: Mediante funciones generatrices,

$$\begin{aligned} P_{X_1 + \dots + X_m}(s) &= E(s^{X_1 + X_2 + \dots + X_m}) = E(s^{X_1})E(s^{X_2}) \dots E(s^{X_m}) \\ &= (1 - p + ps)^{n_1} (1 - p + ps)^{n_2} \dots (1 - p + ps)^{n_m} \\ &= (1 - p + ps)^{n_1 + \dots + n_m}, \end{aligned}$$

que es la función generatriz de una variable $B(n_1 + \dots + n_m, p)$ lo que prueba el resultado. ■

6.4.5. Otras propiedades

Destacamos las siguientes propiedades de la distribución binomial:

- La moda la constituyen aquellos valores de la variable tales que:

$$p(n+1) - 1 \leq \text{Moda} \leq p(n+1).$$

Una distribución binomial puede ser unimodal o bimodal.

6.5. Distribución de Poisson

- Si $X \sim B(n, p)$, $Y \sim B(n, 1-p)$, entonces $\Pr(X = x) = \Pr(Y = n - x)$.

La figura 6.1 muestra algunos ejemplos de las funciones de probabilidad de una distribución binomial.

Ejemplo 6.2 La probabilidad de que un agente de seguros venda una póliza tras una visita es 0,25. Considerando que los resultados de las visitas son independientes y que la probabilidad de que se produzca la venta se mantiene constante, calcular la probabilidad de que este agente obtenga al menos una venta en las 5 próximas visitas.

Solución: El resultado de una visita (venta o no venta) puede considerarse como una variable aleatoria de Bernoulli con $p = 0,25$. Puesto que los resultados de las visitas son independientes, la variable aleatoria:

$$X = \{\text{Número de ventas}\} \sim B(n = 5, p = 0,25),$$

sigue una distribución binomial con función de densidad:

$$\Pr(X = x) = \binom{5}{x} 0,25^x (1 - 0,25)^{5-x}, \quad x = 0, 1, 2, 3, 4, 5.$$

La probabilidad de que obtenga al menos una venta en las próximas cinco visitas es:

$$\Pr(X \geq 1) = 1 - \Pr(X < 1) = 1 - \Pr(X = 0) = 1 - 0,75^5 = 0,7627.$$

◇

6.5. Distribución de Poisson

La distribución de Poisson surge de modo natural en muchos contextos. Por ejemplo, surge como límite de la distribución binomial cuando el número de ensayos es grande y la probabilidad de éxito pequeña. Puede obtenerse además como límite de variables aleatorias de tipo binomial negativa e hipergeométrica. Por otro lado se usa como modelo de probabilidad para la ocurrencia de sucesos raros. Supongamos que X representa el número de ocurrencias de un suceso por unidad de tiempo o de espacio. Por ejemplo:

- Número de reclamaciones anuales de una cartera de seguros.
- Número semanal de accidentes de tráfico en un punto de una carretera.
- Número de pedidos semanales de un artículo que recibe una empresa.




Figura 6.1: Funciones de probabilidad de distribuciones binomiales $B(n, p)$ con $n = 5$ y $p = 0, 2; 0, 3; 0, 5$ y $0, 7$

El experimento consiste en contar el número de veces que ocurre un suceso durante un intervalo de duración t . El intervalo puede ser temporal o espacial. Para obtener la ley de probabilidad de X establecemos las siguientes hipótesis:

1. La probabilidad de ocurrencia de un suceso simple en un intervalo pequeño d es proporcional a su duración, es decir, $p = cd$, donde c es una constante positiva.
2. La probabilidad de ocurrencia de dos o más sucesos en el mismo intervalo es despreciable.
3. El número de ocurrencias en un intervalo es independiente del número de ocurrencias en otros intervalos disjuntos.
4. El número de sucesos que ocurren en dos intervalos de la misma duración tiene la misma distribución de probabilidad.

Dividimos el intervalo t en n subintervalos de duración $d = t/n$. Por las hipótesis realizadas podemos pensar en los n subintervalos como n ensayos independientes e idénticos tipo Bernoulli $X_1, \dots, X_n$ con $\Pr(X_i = 1) = p$, $i = 1, \dots, n$. Ahora,

6.5. Distribución de Poisson

$X = \sum_{i=1}^n X_i$ sigue una distribución binomial con parámetros n y $p = ct/n$. Para garantizar que no ocurra más de un suceso simple en un subintervalo d , el intervalo se puede subdividir en un gran número de intervalos. Por tanto, queremos obtener la función de probabilidad de X cuando $n \rightarrow \infty$. Como probaremos más adelante se verifica que:

$$\lim_{n \rightarrow \infty} \binom{n}{x} p^x (1-p)^{n-x} = \frac{e^{-ct} (ct)^x}{x!}, \quad x = 0, 1, \dots$$

Llamando $\lambda = ct$ obtenemos:

$$\Pr(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, \dots; \lambda > 0.$$

Definición 6.4 Se dice que una variable aleatoria X sigue una distribución de Poisson y se representa por $X \sim \mathcal{P}(\lambda)$, si su función de densidad viene dada por:

$$\Pr(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, \dots$$

siendo λ un parámetro positivo.

La figura 6.2 muestra algunos ejemplos de las funciones de probabilidad de una distribución tipo Poisson.

6.5.1. Funciones generatriz y característica

Consideremos una variable Poisson $X \sim \mathcal{P}(\lambda)$. La función generatriz de X se obtiene del siguiente modo:

$$\begin{aligned} P_X(s) = E(s^X) &= \sum_{n=0}^{\infty} s^n \frac{e^{-\lambda} \lambda^n}{n!} \\ &= e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda s)^n}{n!} = e^{\lambda(s-1)}. \end{aligned} \quad (6.5)$$

En consecuencia, la función característica toma la forma,

$$\varphi_X(t) = E(e^{itX}) = P_X(e^{it}) = \exp[\lambda(e^{it} - 1)]. \quad (6.6)$$

6.5.2. Momentos

A partir de la expresión de la función generatriz (6.5) se obtienen los momentos factoriales. Se verifica:

$$E[X(X-1) \cdots (X-k+1)] = P_X^{(k)}(1) = \lambda^k, \quad k = 1, 2, \dots$$

y por tanto:

$$E(X) = \lambda, \quad (6.7)$$

$$E[X(X-1)] = \lambda^2, \quad (6.8)$$

$$E[X(X-1)(X-2)] = \lambda^3, \quad (6.9)$$

$$E[X(X-1)(X-2)(X-3)] = \lambda^4. \quad (6.10)$$

La varianza vendrá dada por:

$$\text{Var}(X) = E[X(X-1)] + E[X] - E^2[X] = \lambda^2 + \lambda - \lambda^2 = \lambda,$$

y por tanto la distribución de Poisson cumple que

$$E(X) = \text{Var}(X) = \lambda.$$

A partir de (6.7)-(6.10) se obtienen los coeficientes de asimetría y curtosis:

$$\gamma_1 = \frac{1}{\sqrt{\lambda}},$$

$$\gamma_2 = \frac{1}{\lambda}.$$

En consecuencia, la distribución de Poisson es asimétrica positiva y leptocúrtica para cualquier valor de λ .

6.5.3. Límite de la distribución binomial

Como antes señalamos, si $X \sim \mathcal{B}(n, p)$, n tiende a infinito, p a cero y el producto $\lambda = np$ permanece constante, la distribución binomial tiende a la variable de Poisson con parámetro $\lambda = np$:

$$\Pr(X = x) = \binom{n}{x} p^x (1-p)^{n-x} \simeq \frac{e^{-\lambda} \lambda^x}{x!},$$

recomendado si $p < 0,1$ y $np \leq 10$.

Teorema 6.2 El límite de la distribución binomial es la distribución de Poisson, cuando n tiende a ∞ , p tiende a cero y el producto $\lambda = np$ permanece constante.

Demostración: Puesto que $\lambda = np$ constante, entonces $p = \lambda/n$. Sustituyendo y calculando el límite cuando n tiende a infinito,

$$\begin{aligned} \lim_{n \rightarrow \infty} \Pr(X = x) &= \lim_{n \rightarrow \infty} \binom{n}{x} p^x (1-p)^{n-x} = \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \frac{\lambda^x}{x!} \cdot \lim_{n \rightarrow \infty} \frac{n(n-1) \cdots (n-x+1)}{n^x} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-x} \\ &= \frac{e^{-\lambda} \lambda^x}{x!}. \end{aligned}$$

6.5. Distribución de Poisson

6.5.4. Convoluciones

La distribución de Poisson es reproductiva respecto del parámetro λ , es decir la suma de variables de Poisson independientes es de nuevo una variable aleatoria de Poisson.

Teorema 6.3 Sean $X_i \sim \mathcal{P}(\lambda_i)$, $i = 1, 2, \dots, n$ variables aleatorias independientes tipo Poisson. Entonces la variable aleatoria suma $X_1 + X_2 + \dots + X_n$ es nuevamente tipo Poisson, es decir,

$$X_1 + X_2 + \dots + X_n \sim \mathcal{P}(\lambda_1 + \lambda_2 + \dots + \lambda_n).$$

Demostración: Mediante funciones generatrices:

$$P_{X_1 + \dots + X_n}(s) = P_{X_1}(s) \cdots P_{X_n}(s) = e^{(\lambda_1 + \dots + \lambda_n)(s-1)}$$

y por tanto $X_1 + \dots + X_n \sim \mathcal{P}(\lambda_1 + \dots + \lambda_n)$.

6.5.5. Otras propiedades

El siguiente resultado permite clasificar el número de reclamaciones que recibe la compañía de seguros respecto de alguna variable cualitativa que divida a los asegurados en dos o más grupos. Presentamos el caso de dos grupos.

Teorema 6.4 Consideremos una variable aleatoria $N \sim \mathcal{P}(\lambda)$ que representa el número total de reclamaciones. Supongamos que cada reclamación se puede clasificar en dos grupos (E y F), de modo que condicionalmente tenemos que $X|N = n \sim \mathcal{B}(n, p)$ donde las probabilidades de pertenencia a cada grupo son $\Pr(E) = p$ y $\Pr(F) = 1 - p$. Entonces, la distribución incondicional de X es nuevamente de tipo Poisson, de modo que,

$$X \sim \mathcal{P}(\lambda p). \quad (6.11)$$

Demostración: Puesto que $X|N = n \sim \mathcal{B}(n, p)$ y $N \sim \mathcal{P}(\lambda)$ para obtener la probabilidad incondicional de X aplicamos el teorema de las probabilidades totales,

$$\begin{aligned} \Pr(X = k) &= \sum_{n=0}^{\infty} \Pr(X = k|N = n) \Pr(N = n) = \sum_{n=0}^{\infty} \binom{n}{k} p^k (1-p)^{n-k} \frac{e^{-\lambda} \lambda^n}{n!} \\ &= \frac{e^{-\lambda} \lambda^k p^k}{k!} \sum_{n=k}^{\infty} \frac{(\lambda(1-p))^{n-k}}{(n-k)!} = \frac{e^{-\lambda} \lambda^k p^k}{k!} e^{\lambda(1-p)} = \frac{e^{-\lambda p} (\lambda p)^k}{k!}, \end{aligned}$$

de donde se obtiene (6.11).




Figura 6.2: Funciones de probabilidad de distribuciones de Poisson $\mathcal{P}(\lambda)$ con $\lambda = 1, 2, 5$ y 7

Ejemplo 6.3 Una compañía de seguros dispone de una cartera de 4000 pólizas. El siniestro que cubre tiene una probabilidad de ocurrencia del 1 por mil. La indemnización por cada siniestro es de 7000 euros. Se pide:

1. Probabilidad que ocurran menos de 2 siniestros.
2. Probabilidad que ocurran al menos 3 siniestros.
3. Esperanza matemática de la indemnización.

Solución:

1. Se supone que los siniestros ocurren de un modo independiente con la misma probabilidad para cada uno de los asegurados, por tanto:

$$X = \{\text{Número de siniestros}\} \sim B(n = 4000, p = 0,001).$$

Puesto que n es grande y p pequeño, usamos la aproximación de Poisson:

$$X \approx \mathcal{P}(\lambda), \text{ donde } \lambda = np = 4.$$

Por tanto: $\Pr(X < 2) = \Pr(X = 0) + \Pr(X = 1) = e^{-4} + 4e^{-4} = 0,0916 = 9,16\%$.

6.6. Distribución hipergeométrica

2. Calculamos la probabilidad mediante complementarios:

$$\begin{aligned} \Pr(X \geq 3) &= 1 - \Pr(X < 3) \\ &= 1 - \Pr(X = 0) - \Pr(X = 1) - \Pr(X = 2) = 0,762 = 76,2\% \end{aligned}$$

3. $\text{IND} = 7000 \cdot X \Rightarrow E(\text{IND}) = 7000 \cdot E(X) = 28000.$

◇

6.6. Distribución hipergeométrica

La distribución hipergeométrica corresponde a un esquema de muestreo con reemplazamiento.

Definición 6.5 Supongamos el siguiente esquema de muestreo. Una urna contiene dos tipos de bolas, blancas y negras en cantidades N_1 y N_2 respectivamente, que hacen un total de N . Se realizan n extracciones sin reemplazamiento. La variable:

$$X = \{\text{Número de bolas blancas obtenidas en la muestra}\},$$

se dice que sigue una distribución hipergeométrica de parámetros N , N_1 y n .

La función de densidad viene dada por:

$$\Pr(X = k) = \frac{\binom{N_1}{k} \times \binom{N_2}{n-k}}{\binom{N}{n}},$$

para valores $\max\{0, n - N_2\} \leq k \leq \min\{n, N_1\}$. La media y la varianza vienen dadas por:

$$E(X) = np; \text{ Var}(X) = npq \frac{N-n}{N-1},$$

siendo:

$$p = \frac{N_1}{N}, \quad q = 1 - p = \frac{N_2}{N}.$$

La distribución hipergeométrica puede aproximarse mediante una binomial, cuando $N, N_1 \rightarrow \infty$ y el término N_1/N permanece constante:

$$\Pr(X = k) = \frac{\binom{N_1}{k} \times \binom{N_2}{n-k}}{\binom{N}{n}} \simeq \binom{n}{k} p^k (1-p)^{n-k},$$

donde,

$$p = \frac{N_1}{N}.$$

Se recomienda utilizar esta aproximación si:

$$N > 50, \text{ y } \frac{n}{N} \leq 0,1.$$

La aproximación anterior expresa la idea de que en poblaciones grandes, el muestreo con reemplazamiento es equivalente al muestreo sin reemplazamiento.

6.7. Distribución geométrica o de Pascal

Se realizan ensayos independientes de Bernoulli con probabilidad de éxito igual a p . Se define la variable aleatoria:

$$X = \{\text{Número de fracasos antes del primer éxito}\}. \quad (6.12)$$

La función de densidad de (6.12) es:

$$\begin{aligned} \Pr(X = k) &= \Pr(\overbrace{F \cdots F}^k \cdot E) = \Pr(F) \cdots \Pr(F) \cdot \Pr(E) \\ &= \overbrace{(1-p) \cdots (1-p)}^k \cdot p \\ &= (1-p)^k p, \quad k = 0, 1, 2, \dots \end{aligned}$$

Tenemos la siguiente definición.

Definición 6.6 Se dice que una variable aleatoria X sigue una distribución geométrica o de Pascal si la función de probabilidad viene dada por,

$$\Pr(X = k) = p(1-p)^k, \quad k = 0, 1, 2, \dots \quad (6.13)$$

donde $0 < p < 1$, y representaremos $X \sim Ge(p)$. Una segunda parametrización muy utilizada es,

$$\Pr(X = k) = \frac{1}{1+\beta} \left(\frac{\beta}{1+\beta} \right)^k, \quad k = 0, 1, 2, \dots \quad (6.14)$$

donde ahora $\beta > 0$. En este caso $X \sim Ge(p = 1/(1+\beta))$.

Las expresiones de la función de probabilidad (6.13) y (6.14) son equivalentes y se obtienen una a partir de la otra por la parametrización $p = 1/(1+\beta)$. Esta última parametrización presenta la ventaja de que β representa la media de la distribución. La figura 6.3 muestra algunos ejemplos de las funciones de probabilidad de una distribución geométrica del tipo (6.13).

6.7.1. Funciones generatriz y característica

La función generatriz de (6.13) es:

$$P_X(s) = E(s^X) = \sum_{k=0}^{\infty} s^k p(1-p)^k = \frac{p}{1-(1-p)s}, \quad \text{si } |s| < 1/(1-p), \quad (6.15)$$

y la función característica:

$$\varphi_X(t) = E(e^{itX}) = P_X(e^{it}) = \frac{p}{1-(1-p)e^{it}}.$$

6.7. Distribución geométrica o de Pascal

Para el caso de la parametrización (6.14) estas funciones se convierten en:

$$\begin{aligned} P_X(s) &= \frac{1}{1-\beta(s-1)}, \quad |s| < (1+\beta)/\beta, \\ \varphi_X(t) &= \frac{1}{1-\beta(e^{it}-1)}. \end{aligned}$$

6.7.2. Momentos

La función generatriz (6.15) tiene una forma sencilla, que permite obtener una expresión cerrada para los momentos factoriales. Mediante derivación sucesiva se obtiene que:

$$E[X(X-1)\cdots(X-k+1)] = P_X^{(k)}(1) = \frac{k!(1-p)^k}{p^k}, \quad k = 1, 2, \dots$$

y por tanto:

$$\begin{aligned} E(X) &= \frac{1-p}{p}, \\ E[X(X-1)] &= \frac{2(1-p)^2}{p^2}, \end{aligned}$$

de donde:

$$\text{Var}(X) = E[X(X-1)] + E(X) - E^2(X) = \frac{1-p}{p^2}.$$

Para el caso de la parametrización (6.14) la media y la varianza son respectivamente:

$$\begin{aligned} E(X) &= \beta, \\ \text{Var}(X) &= \beta(1+\beta). \end{aligned}$$

6.7.3. Otras propiedades

La distribución geométrica verifica la siguiente propiedad de pérdida de memoria. Si $X \sim Ge(p)$ con función de probabilidad (6.13) se verifica que:

$$\Pr(X \geq n+m | X \geq m) = \Pr(X \geq n)$$

para valores $n, m = 0, 1, 2, \dots$

Una definición alternativa de distribución geométrica es la siguiente. Se realizan ensayos independientes de Bernoulli con probabilidad de éxito igual a p . A la variable aleatoria:

$$X = \{\text{Número de ensayos necesarios para obtener el primer éxito}\}, \quad (6.16)$$

se le denomina también variable geométrica o de Pascal. La función de densidad comienza a contar en uno y es:

$$\Pr(X = k) = p(1 - p)^{k-1}, \quad k = 1, 2, \dots$$

La media y la varianza son respectivamente:

$$E(X) = \frac{1}{p}, \quad \text{Var}(X) = \frac{1-p}{p^2}.$$

Ejemplo 6.4 La probabilidad de que un comercial sin experiencia venda una póliza en un domicilio es 0,05. Suponiendo que las ventas entre domicilios son independientes y como máximo de una unidad, calcular la probabilidad de que venda su primera póliza en la quinta visita. Obtener el número medio de domicilios a los que debe acudir para realizar la primera venta.

Solución: La variable $X = \{\text{Núm. de domicilios para conseguir la primera venta}\}$, sigue una distribución geométrica del tipo (6.16) con parámetro $p = 0,05$. Por tanto:

$$\Pr(X = 5) = 0,05(1 - 0,05)^{5-1} = 0,0407 = 4,07\%.$$

El número medio de domicilios a los que debe acudir para realizar la primera venta viene dado por:

$$E(X) = \frac{1}{p} = \frac{1}{0,05} = 20 \text{ domicilios.}$$

◇




Figura 6.3: Funciones de probabilidad de distribuciones geométricas del tipo (6.13) con $p = 0,3$ y $p = 0,5$

6.8. Distribución binomial negativa

La variable aleatoria binomial negativa es una generalización de la distribución geométrica. Supongamos ahora que se realizan ensayos independientes de Bernoulli con probabilidad de éxito p . Definimos la variable aleatoria:

$$X = \{\text{Número de fracasos antes del } r\text{-ésimo éxito}\}. \quad (6.17)$$

La función de densidad de (6.17) es:

$$\Pr(X = k) = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, 2, \dots$$

Efectivamente, para que el fracaso k ocurra antes del éxito r , debemos tener $k+r$ ensayos, donde el último debe ser éxito. El número de formas de obtener k fracasos y $r-1$ éxitos en $k+r-1$ ensayos se obtiene de la fórmula de las permutaciones con repetición:

$$PR_{k,r-1}^{k+r-1} = \frac{(k+r-1)!}{k!(r-1)!} = \binom{k+r-1}{k}.$$

Finalmente, multiplicando esta última expresión por $(1-p)^k p^r$ obtenemos la función de densidad. Introducimos la siguiente definición.

Definición 6.7 Una variable aleatoria X sigue una distribución binomial negativa si la función de probabilidad viene dada por,

$$\Pr(X = k) = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, 2, \dots \quad (6.18)$$

donde $0 < p < 1$, $r > 0$, y representaremos $X \sim \mathcal{BN}(r, p)$. Una segunda parametrización muy utilizada es,

$$\Pr(X = k) = \binom{k+r-1}{k} \left(\frac{1}{1+\beta}\right)^r \left(\frac{\beta}{1+\beta}\right)^k, \quad k = 0, 1, 2, \dots \quad (6.19)$$

donde ahora $\beta > 0$ y $r > 0$. En este último caso representaremos $X \sim \mathcal{BN}(r, p = 1/(1+\beta))$.

El nombre de distribución binomial negativa viene del hecho de que la probabilidad puede obtenerse del desarrollo en serie con potencia negativa de $p = 1 - q$,

$$p^{-r} = (1-q)^{-r} = \sum_{k=0}^{\infty} \binom{k+r-1}{k} q^k. \quad (6.20)$$

El parámetro r no tiene porqué ser un entero, sino que basta con $r > 0$.

6.8.1. Funciones generatriz y característica

A partir de la identidad (6.20) se obtiene la función generatriz de (6.18) que es:

$$P_X(s) = E(s^X) = \frac{p^r}{[1 - (1-p)s]^r}, \quad \text{si } |s| < 1/(1-p), \quad (6.21)$$

y la función característica:

$$\varphi_X(t) = E(e^{itX}) = P_X(e^{it}) = \frac{p^r}{[1 - (1-p)e^{it}]^r}. \quad (6.22)$$

Para el caso de la parametrización (6.19) estas funciones se convierten en:

$$P_X(s) = \frac{1}{[1 - \beta(s-1)]^r}, \quad |s| < (1+\beta)/\beta, \quad (6.23)$$

$$\varphi_X(t) = \frac{1}{[1 - \beta(e^{it} - 1)]^r}. \quad (6.24)$$

6.8.2. Momentos

Usando (6.21) obtenemos el momento factorial positivo de orden k :

$$\begin{aligned} E[X(X-1)\cdots(X-k+1)] &= P_X^{(k)}(1) \\ &= r(r+1)\cdots(r+k-1) \left(\frac{1-p}{p}\right)^k, \\ &= \frac{\Gamma(r+k)}{\Gamma(r)} \left(\frac{1-p}{p}\right)^k, \end{aligned}$$

donde $\Gamma(\cdot)$ representa la función gamma definida en (3.9). En particular, los cuatro primeros momentos factoriales de la distribución geométrica son:

$$\begin{aligned} E(X) &= \frac{r(1-p)}{p}, \\ E[X(X-1)] &= \frac{r(r+1)(1-p)^2}{p^2}, \\ E[X(X-1)(X-2)] &= \frac{r(r+1)(r+2)(1-p)^3}{p^3}, \\ E[X(X-1)(X-2)(X-3)] &= \frac{r(r+1)(r+2)(r+3)(1-p)^4}{p^4}. \end{aligned}$$

La media y la varianza de (6.18) son respectivamente:

$$\begin{aligned} E(X) &= \frac{r(1-p)}{p}, \\ \text{Var}(X) &= \frac{r(1-p)}{p^2}, \end{aligned}$$

6.8. Distribución binomial negativa

mientras que la media y varianza para la parametrización (6.19) se reducen a:

$$\begin{aligned} E(X) &= r\beta, \\ \text{Var}(X) &= r\beta(1+\beta). \end{aligned}$$

En relación a las medidas de forma, el coeficiente de asimetría es:

$$\gamma_1 = \frac{2-p}{\sqrt{r(1-p)}},$$

y por tanto se trata de una distribución asimétrica positiva. La curtosis es:

$$\gamma_2 = \frac{1}{r} \left(6 + \frac{p^2}{1-p} \right),$$

y por tanto es una distribución leptocúrtica. Si $r \rightarrow \infty$ entonces γ_1 y γ_2 tienden a cero.

6.8.3. Convoluciones

Si $X_1 \sim \mathcal{BN}(r_1, p), \dots, X_n \sim \mathcal{BN}(r_n, p)$ son variables aleatorias independientes, entonces $X_1 + \dots + X_n$ es de nuevo binomial negativa con parámetros $r_1 + \dots + r_n$ y p .

6.8.4. Distribuciones límites

Si $\lambda > 0$, consideremos la variable aleatoria $X_r \sim \mathcal{BN}(r, p = 1/(1+\beta))$ donde $\beta = \lambda/r$. Veamos que el límite de X_r cuando r tiende a infinito es una variable aleatoria tipo Poisson. Usando (6.23), la función generatriz de X_r es,

$$P_{X_r}(s) = \frac{1}{[1 - \beta(s-1)]^r} = \frac{1}{[1 - \frac{\lambda}{r}(s-1)]^r} = \left[1 - \frac{\lambda}{r}(s-1) \right]^{-r}.$$

El límite cuando r tiende a infinito es,

$$\lim_{r \rightarrow \infty} P_{X_r}(s) = \lim_{r \rightarrow \infty} \left[1 - \frac{\lambda}{r}(s-1) \right]^{-r} = e^{\lambda(s-1)},$$

que es la función generatriz de una variable aleatoria de Poisson de media λ .

6.8.5. Otras propiedades

Una propiedad importante de la distribución binomial negativa es que puede obtenerse como una mezcla de una distribución de Poisson, suponiendo que la media no se mantiene constante. Tenemos el siguiente resultado.

Teorema 6.5 Supongamos que el número de accidentes N de una cartera de clientes sigue una distribución de Poisson N con media λ . Supongamos que la media λ muestra la variabilidad de la cartera representada con una función de densidad continua de tipo gamma, de modo que podemos establecer el modelo,

$$N|\lambda \sim \mathcal{P}(\lambda), \quad (6.25)$$

$$\lambda \sim \mathcal{G}(\alpha, \theta). \quad (6.26)$$

Entonces, la distribución incondicional N del número de accidentes es de tipo binomial negativa, de modo que,

$$N \sim \mathcal{BN}(\alpha, p = 1/(1 + \theta)). \quad (6.27)$$

Demostración: Se trata de una mezcla de distribuciones como en la sección 5.7. En este caso $f_\lambda(\lambda)$ representa la función de densidad de una variable aleatoria gamma que aparece definida en (7.37). Usando la fórmula (5.21), la marginal de N es:

$$\begin{aligned} \Pr(N = k) &= \int_0^\infty f_{N|\lambda}(k) f_\lambda(\lambda) d\lambda \\ &= \int_0^\infty \frac{e^{-\lambda} \lambda^k}{k!} \cdot \frac{\lambda^{\alpha-1} e^{-\lambda/\theta}}{\theta^\alpha \Gamma(\alpha)} d\lambda \\ &= \binom{k + \alpha - 1}{k} \left(\frac{1}{1 + \theta} \right)^\alpha \left(\frac{\theta}{1 + \theta} \right)^k \end{aligned}$$

de donde se sigue el resultado. ■

Haciendo uso de la representación (6.25)-(6.26) podemos probar que la distribución binomial negativa es sobredispersa, es decir, la varianza es siempre mayor que la media. La media de N es,

$$E(N) = E[E(N|\lambda)] = E(\lambda).$$

La varianza es,

$$\text{Var}(N) = E[\text{Var}(N|\lambda)] + \text{Var}[E(N|\lambda)] = E(\lambda) + \text{Var}(\lambda) > E(\lambda),$$

donde se ha utilizado el hecho que en la distribución de Poisson la media y la varianza coinciden.

Una variante de la distribución binomial negativa se obtiene del siguiente modo. Supongamos que se realizan ensayos independientes de Bernoulli con probabilidad de éxito p . Consideremos la variable aleatoria:

$$X = \{\text{Número de ensayos necesarios para obtener el } r\text{-ésimo éxito}\}, \quad (6.28)$$

6.9. Distribución logarítmica

113

La función de densidad de (6.28) es:

$$\Pr(X = x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \dots \quad (6.29)$$

La media y la varianza de (6.29) son:

$$E(X) = \frac{r}{p}, \quad \text{Var}(X) = \frac{r(1-p)}{p^2}.$$

6.9. Distribución logarítmica

Definición 6.8 Una variable aleatoria X sigue una distribución logarítmica si su función de probabilidad viene dada por,

$$\Pr(X = k) = -\frac{1}{\log(1-\theta)} \cdot \frac{\theta^k}{k}, \quad k = 1, 2, \dots \quad (6.30)$$

donde $0 < \theta < 1$.

Observemos que la distribución logarítmica no tiene probabilidad en 0. Las probabilidades $\Pr(X = k)$ son siempre decrecientes en k . La función generatriz viene dada por,

$$P_X(s) = E(s^X) = \frac{\log(1-\theta s)}{\log(1-\theta)}, \quad (6.31)$$

mientras que la función característica es:

$$\varphi_X(t) = P_X(e^{it}) = \frac{\log(1-\theta e^{it})}{\log(1-\theta)}.$$

La media y la varianza de la distribución logarítmica son:

$$\begin{aligned} E(X) &= \frac{a\theta}{1-\theta}, \\ \text{Var}(X) &= \frac{a\theta(1-a\theta)}{(1-\theta)^2} = \mu \left(\frac{1}{1-\theta} - \mu \right), \end{aligned}$$

donde $a = -1/\log(1-\theta)$ y $\mu = E(X)$. Estas dos expresiones se obtienen a partir de la función generatriz o la función característica. La distribución logarítmica se ha usado para modelizar el número de individuos de una especie.

6.10. Distribución multinomial

La distribución multinomial es una generalización de la distribución binomial, suponiendo que ahora son posibles más de dos resultados por ensayo. Este tipo de distribuciones son importantes en las aplicaciones, puesto que surgen como las distribuciones de probabilidad de las frecuencias en repeticiones independientes de un experimento con k posibles resultados. Supongamos que tenemos una partición del espacio muestral en sucesos A_i , $i = 1, 2, \dots, k$ cuyas probabilidades teóricas son $\Pr(A_i) = p_i \geq 0$, $i = 1, 2, \dots, k$ y $\sum_{i=1}^k p_i = 1$. Se realizan n ensayos independientes, siendo x_i las frecuencias con que se presenta el resultado A_i , donde $\sum_{i=1}^k x_i = n$. Consideremos las variables aleatorias definidas por ($i = 1, 2, \dots, k$):

$$X_i = \{\text{número de sucesos del tipo } A_i \text{ presentados en los } n \text{ ensayos}\}.$$

Se verifica entonces que la función de densidad conjunta de las k variables $(X_1, \dots, X_k)$ viene dada por:

$$\Pr(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k},$$

donde: $x_1 + \dots + x_k = n$ y $p_1 + \dots + p_k = 1$.

Se dice entonces que $\underline{X} = (X_1, \dots, X_k)$ sigue una distribución multinomial y se representa por $\underline{X} \sim \text{Mult}(n, p_1, \dots, p_k)$. Si $k = 2$ obtenemos la distribución binomial. El nombre de distribución multinomial proviene de que las probabilidades se pueden obtener mediante el desarrollo de la fórmula multinomial $1 = (p_1 + \dots + p_k)^n$. Todas las distribuciones marginales de cualquier dimensión son de nuevo distribuciones multinomiales. Las medias y varianzas son:

$$E(X_i) = np_i, \quad \text{Var}(X_i) = np_i(1 - p_i), \quad i = 1, \dots, k$$

respectivamente. La covarianza de cada pareja (X_i, X_j) con $i \neq j$ es:

$$\text{Cov}(X_i, X_j) = -np_i(1 - p_j), \quad \text{si } i \neq j.$$

6.11. Sistemas de distribuciones

6.11.1. La clase de distribuciones $(a, b, 0)$

Definición 6.9 Sea X una variable aleatoria discreta no negativa con función de probabilidad $p_k = \Pr(X = k)$, $k = 0, 1, 2, \dots$. Se dice que X pertenece a la clase de distribuciones $(a, b, 0)$ si cumple la condición,

$$p_k = \left(a + \frac{b}{k}\right) p_{k-1}, \quad k = 1, 2, \dots \quad (6.32)$$

con $p_0 > 0$.

6.11. Sistemas de distribuciones

Observemos que la clase de distribuciones $(a, b, 0)$ viene determinada por la probabilidad del 0, p_0 y por las constantes a y b . Las distribuciones binomial, Poisson, geométrica y binomial negativa son las únicas distribuciones de esta clase. La tabla 6.1 presenta estas distribuciones en términos de la terna (a, b, p_0) .

Tabla 6.1: Distribuciones de la clase $(a, b, 0)$.

Distribución	a	b	p_0
Binomial	$-\frac{p}{1-p}$	$(n+1)\frac{p}{1-p}$	$(1-p)^n$
Poisson	0	λ	$e^{-\lambda}$
Geométrica	$\frac{\beta}{1+\beta}$	0	$\frac{1}{1+\beta}$
Binomial Negativa	$\frac{\beta}{1+\beta}$	$(r-1)\frac{\beta}{1+\beta}$	$\frac{1}{(1+\beta)^r}$

La clase de distribuciones $(a, b, 0)$ presenta dos ventajas principales. En primer lugar las probabilidades de las distribuciones pertenecientes a esta clase se pueden evaluar fácilmente de forma recursiva por medio de (6.32). Por otro lado existe una fórmula de recurrencia probada por Panjer (1981) que permite evaluar la distribución de la cantidad total reclamada, cuando el número de reclamaciones pertenece a esta clase y la cantidad reclamada es una variable aleatoria que puede ser tanto de tipo discreto como continuo. Está fórmula será estudiada en el capítulo 13.

6.11.2. La clase de distribuciones $(a, b, 1)$

Sundt y Jewell (1981) extendieron las ideas anteriores a una clase de distribuciones similar a (6.32).

Definición 6.10 Sea X una variable aleatoria discreta con función de probabilidad $p_k = \Pr(X = k)$, $k = 1, 2, \dots$. Se dice que X pertenece a la clase de distribuciones $(a, b, 1)$ si se cumple la condición,

$$p_k = \left(a + \frac{b}{k}\right) p_{k-1}, \quad k = 2, 3, \dots \quad (6.33)$$

con $p_1 > 0$.

La clase de distribuciones $(a, b, 1)$ viene determinada por las constantes a , b y la probabilidad en 1, p_1 . Esta clase también se la conoce como distribución de Sundt-Jewell. La clase $(a, b, 1)$ contiene a la clase $(a, b, 0)$ y las correspondientes versiones truncadas en 0 y modificadas en 0. Por distribución modificada en 0 se

entiende una distribución con un valor arbitrario de p_0 y que verifique la relación (6.32) excepto para $k = 1$.

6.12. Distribuciones compuestas

Las distribuciones compuestas son una clase de distribuciones muy amplia que permite modelizar una gran variedad de situaciones en estadística actuarial.

Definición 6.11 Se dice que una variable aleatoria S se distribuye según una distribución compuesta, si la función generatriz de momentos se puede escribir como,

$$P_S(z) = P_N[P_X(z)], \quad (6.34)$$

donde P_N y P_X son dos funciones generatrices.

A la variable aleatoria N con función generatriz $P_N(\cdot)$ se la llama distribución *primaria* mientras que a la variable aleatoria X con función generatriz $P_X(\cdot)$ se la llama distribución *secundaria*. Según vimos en el capítulo anterior, las distribuciones compuestas surgen de un modo natural como la distribución de la variable aleatoria,

$$S_N = X_1 + \dots + X_N.$$

La función de probabilidad de este tipo de variables se puede obtener como:

$$g_k = \sum_{n=0}^{\infty} p_n f_k^{*n},$$

donde $g_k = \Pr(S = k)$, $p_n = \Pr(N = n)$, $f_n = \Pr(X_i = n)$ y f_k^{*n} , $k = 0, 1, 2, \dots$ es la convolución n -ésima de X_i . Veamos un ejemplo de distribución compuesta.

Ejemplo 6.5 Consideremos una distribución compuesta S cuya distribución primaria es de tipo Poisson $N \sim \mathcal{P}(\lambda)$, y la distribución secundaria es de tipo logarítmico con función de probabilidad (6.30) y función generatriz (6.31). Probar que la distribución compuesta S es una binomial negativa $\mathcal{BN}(r, p)$ donde $r = -\lambda / \ln(1 - \theta)$ y $p = 1 - \theta$.

Solución: Puesto que $P_N(z) = \exp\{\lambda(z - 1)\}$, usando (6.34) tenemos que,

$$\begin{aligned} P_S(z) &= \exp\{\lambda[P_X(z) - 1]\} \\ &= \exp\left\{\lambda\left[\frac{\ln(1 - \theta z)}{\ln(1 - \theta)} - 1\right]\right\} \\ &= \exp\left\{\frac{\lambda}{\ln(1 - \theta)} \ln\left(\frac{1 - \theta z}{1 - \theta}\right)\right\} \\ &= \left[\frac{1 - \theta}{1 - (1 - \theta)z}\right]^{-\lambda / \ln(1 - \theta)} \end{aligned}$$

6.13. Problemas propuestos

que coincide con la función generatriz de una binomial negativa con los parámetros antes señalados.

Los momentos de una distribución compuesta se obtienen fácilmente por medio de la función generatriz, como probaremos más adelante. La media y la varianza vienen dadas por:

$$\begin{aligned} E(S) &= E(N)E(X), \\ \text{Var}(S) &= E(N)\text{Var}(X) + E^2(X)\text{Var}(N). \end{aligned}$$

Un caso importante de distribución compuesta ocurre cuando la distribución primaria es de tipo Poisson, que estudiaremos en el capítulo 13.

6.13. Problemas propuestos

- En una ciudad el 30 por ciento de los hogares están asegurados contra incendios. Con objeto de conocer en detalle una determinada zona, una compañía de seguros selecciona 8 hogares al azar. Se pide:
 - Número de hogares que se espera posean seguro contra incendios.
 - Probabilidad de que alguno de los hogares esté asegurado.
 - Probabilidad que al menos dos hogares estén asegurados.
- Se lanza 5 veces una moneda. Probabilidad de obtener más de 3 caras.
- Se lanza un dado 5 veces. Probabilidad de obtener 3 ases, 1 cinco y 1 seis.
- Sean X_1 y X_2 variables aleatorias independientes tipo Poisson con medias λ_1 y λ_2 , respectivamente. Probar que si $n = 0, 1, 2, \dots$ y $m = 0, 1, \dots, n$ entonces,

$$\Pr(X_1 = m | X_1 + X_2 = n) = \binom{n}{m} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2}\right)^m \left(\frac{\lambda_2}{\lambda_1 + \lambda_2}\right)^{n-m},$$

y por tanto la distribución de X_1 condicionada por $X_1 + X_2 = n$ es binomial $B(n, \lambda_1 / (\lambda_1 + \lambda_2))$.

- Las pérdidas en u.m. asociadas a un siniestro se pueden representar mediante una variable aleatoria con función de distribución:

$$F(x) = 1 - \frac{8}{x^3}, \quad \text{si } x > 2,$$

y $F(x) = 0$ si $x < 2$. Sean X_1 , X_2 y X_3 variables aleatorias independientes que representan las pérdidas de tres siniestros de ese tipo. Hallar la probabilidad de que al menos 2 de las 3 pérdidas sean superiores a 3 u.m.

6. Un actuario ha observado que la probabilidad de tener dos accidentes es 3 veces la probabilidad de tener un accidente. Si la distribución del número de accidentes es una variable aleatoria tipo Poisson, se pide:
 - a) Número medio de accidentes.
 - b) Probabilidad de tener más de dos accidentes.
7. Una variable aleatoria siguen una distribución de Neyman tipo A si $X \sim \mathcal{P}(\phi Z)$, donde $Z \sim \mathcal{P}(\lambda)$, siendo ϕ y λ constantes positivas. Se pide:
 - a) Probar que se trata de una distribución compuesta.
 - b) Obtener una expresión para la función de cuantía.
 - c) Hallar la media y la varianza de la distribución de Neyman tipo A.

Capítulo 7

Distribuciones de tipo Continuo

7.1. Introducción

Continuando con los modelos de distribuciones de probabilidad, pasamos al estudio de las principales distribuciones de tipo continuo. Los actuarios usan las distribuciones de tipo continuo para modelizar diversos fenómenos aleatorios, como por ejemplo la distribución de un conjunto de datos de pérdidas o la distribución de supervivencia de un individuo.

Comenzaremos estudiando tres distribuciones clásicas de amplia aplicación en estadística como son la distribución uniforme, la distribución beta de primera especie y la distribución normal. Seguiremos con el estudio de cinco distribuciones que habitualmente se utilizan como modelos para datos de pérdidas: la distribución log-normal, las distribuciones de Pareto (de tipo I, II y generalizada), la inversa Gaussiana, la exponencial y la gamma. Continuaremos con las tres distribuciones clásicas de extremos: las distribuciones de Gumbel, Weibull y Fréchet. Seguiremos con las distribuciones de Benktander y las distribuciones para la duración de una vida, que incluyen a las distribuciones de Gompertz y de Makeham. Terminaremos con las tres distribuciones que aparecen en el muestreo de la distribución normal.

Algunos textos más avanzados sobre teoría y aplicaciones de distribuciones probabilísticas continuas son Arnold, Castillo y Sarabia (1992 y 1999); Balakrishnan y Nevzorov (2003); Castillo, Hadi, Balakrishnan y Sarabia (2005), Johnson, Kotz y Balakrishnan (1994, 1995) y Kleiber y Kotz (2003).

7.2. Distribución uniforme

La distribución uniforme es la más sencilla de todas las distribuciones continuas además de ser una de las más importantes, puesto que toda variable aleatoria se puede relacionar con una distribución uniforme en el intervalo $(0, 1)$.

Definición 7.1 Se dice que una variable aleatoria sigue una distribución uniforme en el intervalo (a, b) y se denota por $X \sim \mathcal{U}(a, b)$, si su función de densidad es constante en dicho intervalo, es decir,

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b, \quad (7.1)$$

y $f(x) = 0$ en otro caso.

La función de distribución de una distribución $\mathcal{U}(a, b)$ es,

$$F(x) = \begin{cases} 0 & \text{si } x < a, \\ \frac{x-a}{b-a} & \text{si } a \leq x < b, \\ 1 & \text{si } x \geq b. \end{cases}$$

Un caso particular importante es la distribución uniforme en el intervalo $[0, 1]$, que se obtiene haciendo $a = 0$ y $b = 1$ en (7.1). La función de densidad de una $\mathcal{U}(0, 1)$ es,

$$f(x) = 1, \quad 0 \leq x \leq 1,$$

y la función de distribución,

$$F(x) = \begin{cases} 0 & \text{si } x < 0, \\ x & \text{si } 0 \leq x < 1, \\ 1 & \text{si } x \geq 1. \end{cases} \quad (7.2)$$

7.2.1. Funciones característica y de momentos

Si $X \sim \mathcal{U}(a, b)$ la función característica es,

$$\varphi_X(t) = E(e^{itX}) = \frac{1}{b-a} \int_a^b e^{itx} dx = \frac{e^{itb} - e^{ita}}{(b-a)it}.$$

En particular, si $X \sim \mathcal{U}(0, 1)$ tenemos,

$$\varphi_X(t) = \frac{e^{it} - 1}{it}.$$

Si $r > 0$ se verifica que,

$$\alpha_r = E(X^r) = \int_a^b x^r \frac{1}{b-a} dx = \frac{b^{r+1} - a^{r+1}}{(r+1)(b-a)}. \quad (7.3)$$

7.2. Distribución uniforme

Los momentos centrales respecto de la media son,

$$\beta_r = E(X - \mu_X)^r = \frac{(b-a)^r [1 - (-1)^{r+1}]}{(r+1)2^{r+1}}, \quad r = 1, 2, \dots \quad (7.4)$$

Usando (7.3) y (7.4), la media y varianza de una distribución $\mathcal{U}(a, b)$ son,

$$E(X) = \frac{a+b}{2}, \quad (7.5)$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}, \quad (7.6)$$

respectivamente. El coeficiente de asimetría γ_1 de una distribución uniforme es igual a cero, puesto que se trata de una distribución simétrica. El coeficiente de curtosis es $\gamma_2 = 9/5 - 3 = -1, 2$ y por tanto estamos ante una distribución platécúrtica. La figura 7.1 representa la función de densidad y la función de distribución de una variable aleatoria uniforme en el intervalo $(0, 1)$.

Ejemplo 7.1 El tiempo que una ambulancia tarda en acudir al lugar donde se ha producido un accidente sigue una distribución uniforme entre 0 y 10 minutos. Calcular la probabilidad de que una ambulancia tarde más de 8 minutos. Calcular el tiempo medio de espera.

Solución: Se trata de una distribución $\mathcal{U}(0, 10)$ con función de distribución,

$$F(x) = \begin{cases} 0 & \text{si } x < 0, \\ \frac{x}{10} & \text{si } 0 \leq x < 10, \\ 1 & \text{si } x \geq 10. \end{cases}$$

La probabilidad de que tarde más de 8 minutos es:

$$\Pr(X > 8) = 1 - \Pr(X \leq 8) = 1 - F(8) = 1 - \frac{8}{10} = 0,2.$$

El tiempo medio de espera es: $\mu = E(X) = \frac{0+10}{2} = 5$ minutos. $\diamond$

7.2.2. La transformación integral

Cualquier variable aleatoria se puede relacionar con la distribución uniforme $\mathcal{U}(0, 1)$ por un cambio de variable simple. Se verifica el siguiente resultado.

Teorema 7.1 (Transformación integral) Sea X una variable aleatoria continua con función de distribución $F(x)$. Entonces la nueva variable: $U = F(X)$ se distribuye según una variable uniforme en el intervalo $[0, 1]$ con función de distribución (7.2).

Demostración: Definimos la función de distribución inversa de F como,

$$F^{-1}(u) = \inf\{x : F(x) \geq u\}.$$

Notar que $F(F^{-1}(x)) = x$ si $0 < x < 1$. Veamos que si $0 \leq u \leq 1$, $F_U(u) = u$. En efecto:

$$\begin{aligned} F_U(u) &= \Pr(U \leq u) \\ &= \Pr(F(X) \leq u) \\ &= \Pr(X \leq F^{-1}(u)) \\ &= F(F^{-1}(u)) = u. \end{aligned}$$

Este resultado es la base para la simulación de variables aleatorias. Si X es una variable aleatoria con función de distribución F y U es una variable aleatoria uniforme en $(0, 1)$, entonces,

$$X = F^{-1}(U). \quad (7.7)$$

Por tanto, para obtener de una muestra de X , basta con disponer de una muestra de la uniforme $(0, 1)$ y aplicar la transformación (7.7).

Ejemplo 7.2 Una compañía aseguradora conoce que la distribución de pérdidas de un determinado siniestro es una variable aleatoria continua X con función de distribución,

$$F(x) = 1 - \exp\{-(x-1)/2\}^3, \quad x > 1,$$

y $F(x) = 0$ si $x < 1$.

1. A partir de una distribución $U \sim \mathcal{U}(0, 1)$, encontrar una transformación que permita obtener la X .
2. Usando la muestra de la uniforme en $(0, 1)$: 0,215; 0,492; 0,783 simular una muestra de tres valores de las pérdidas.

Solución:

1. Usando el teorema 7.1, se trata de despejar la X en la relación $F(X) = U$. De esta manera se obtiene,

$$X = 1 + 2[-\log(1 - U)]^{1/3}.$$

2. Usando la transformación anterior se obtienen los valores simulados: 2,246; 2,2756 y 3,304.

◇




Figura 7.1: Función de densidad (izquierda) y función de distribución (derecha) de la variable aleatoria uniforme $\mathcal{U}(0, 1)$

7.3. Distribución beta de primera especie

La distribución beta de primera especie se utiliza en estadística para modelizar variables que representan proporciones.

Definición 7.2 Una variable aleatoria X sigue una distribución beta de primera especie si su función de densidad viene dada por:

$$f(x) = \frac{1}{B(p, q)} x^{p-1} (1-x)^{q-1}, \quad 0 < x < 1,$$

donde $p, q > 0$ y $B(p, q)$ representa la función beta. Representaremos $X \sim \text{Be}(p, q)$.

La función beta viene definida por,

$$B(x, y) = \int_0^1 t^{x-1} (1-t)^{y-1} dt = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)},$$

donde $x, y > 0$, siendo $\Gamma(\cdot)$ la función gamma definida en (3.9). Los dos parámetros de los que depende la función de densidad cubren un gran abanico de formas funcionales, lo que hace que la variable sea enormemente flexible para el ajuste de datos.

7.3.1. Transformaciones y relaciones

Si $X \sim \text{Be}(p, q)$, entonces,

$$1 - X \sim \text{Be}(q, p).$$

Veamos la relación entre las distribuciones binomial y beta. Si $X \sim \mathcal{B}(n, p)$ entonces,

$$\Pr(X \geq m) = \sum_{k=m}^n \binom{n}{k} p^k (1-p)^{n-k}$$

$$\begin{aligned}
 &= \frac{n!}{(m-1)!(n-m)!} \int_0^p x^{m-1}(1-x)^{n-m} dx \\
 &= \Pr(Y \leq p)
 \end{aligned}$$

donde $Y \sim \text{Be}(m, n-m+1)$.

7.3.2. Características

Si $p > 1$ y $q > 1$ la distribución beta es unimodal y su valor máximo se alcanza en,

$$x_0 = \frac{p-1}{p+q-2},$$

y además la función de densidad tiene forma de campana. Si $p < 1$ y $q < 1$, la función de densidad tiene forma de U, y además tiende a infinito cuando $x \rightarrow 0$ y $x \rightarrow 1$. Si $p < 1$ o bien $q < 1$, la función de densidad tiende a infinito cuando $x \rightarrow 0$ o cuando $x \rightarrow 1$. Las figuras 7.2 y 7.3 muestran la función de densidad de diversas distribuciones beta simétricas y asimétricas. El siguiente resultado permite obtener los momentos.

Teorema 7.2 Si $X \sim \text{Be}(p, q)$ y $r > -p$, entonces:

$$E(X^r) = \frac{\Gamma(p+r)\Gamma(p+q)}{\Gamma(p+q+r)\Gamma(p)}. \quad (7.8)$$

Demostración: Hacemos uso de las funciones gamma y beta y de sus propiedades. La esperanza matemática es,

$$\begin{aligned}
 E(X^r) &= \frac{1}{B(p, q)} \int_0^1 x^{p+r-1}(1-x)^{q-1} dx \\
 &= \frac{B(p+r, q)}{B(p, q)} \\
 &= \frac{\Gamma(p+r)\Gamma(q)}{\Gamma(p+q+r)} \cdot \frac{\Gamma(p+q)}{\Gamma(p)\Gamma(q)} \\
 &= \frac{\Gamma(p+r)\Gamma(p+q)}{\Gamma(p+q+r)\Gamma(p)}.
 \end{aligned}$$

Para obtener la media hacemos $r = 1$ en (7.8),

$$E(X) = \frac{\Gamma(p+1)\Gamma(p+q)}{\Gamma(p+q+1)\Gamma(p)} = \frac{p\Gamma(p)\Gamma(p+q)}{(p+q)\Gamma(p+q)\Gamma(p)} = \frac{p}{p+q}.$$

7.3. Distribución beta de primera especie

Sustituyendo $r = 2$ en (7.8) obtenemos el momento de orden 2 respecto del origen,

$$\begin{aligned}
 E(X^2) &= \frac{\Gamma(p+2)\Gamma(p+q)}{\Gamma(p+q+2)\Gamma(p)} \\
 &= \frac{p(p+1)\Gamma(p)\Gamma(p+q)}{(p+q)(p+q+1)\Gamma(p+q)\Gamma(p)} \\
 &= \frac{p(p+1)}{(p+q)(p+q+1)}.
 \end{aligned}$$

La varianza de la distribución beta es,

$$\text{Var}(X) = E(X^2) - E^2(X) = \frac{pq}{(p+q)^2(p+q+1)}.$$

Los coeficientes de asimetría y curtosis son,

$$\begin{aligned}
 \gamma_1 &= \frac{2(q-p)}{p+q+2} \sqrt{\frac{p+q+1}{pq}}, \\
 \gamma_2 &= \frac{6(p-q)^2(p+q+1)}{pq(p+q+2)(p+q+3)} - \frac{6}{p+q+3}.
 \end{aligned}$$

Si $p = q$, la distribución beta es simétrica y por tanto $\gamma_1 = 0$. Si $q > p$, entonces $\gamma_1 > 0$ y es asimétrica positiva. En el caso $q < p$ la distribución es asimétrica negativa. Finalmente, la distribución puede ser mesocúrtica, platocúrtica y leptocúrtica.

7.3.3. Distribución beta con cuatro parámetros

La distribución beta con cuatro parámetros permite modelizar datos que se encuentren en un intervalo finito (a, b) , $a < b$.

Definición 7.3 Si $Z \sim \text{Be}(p, q)$, se denomina distribución beta con cuatro parámetros a la nueva variable aleatoria,

$$X = a + (b-a)Z, \quad (7.9)$$

donde a y b son números reales con $a < b$.

El soporte de X es obviamente el intervalo (a, b) . La función de densidad es,

$$f_X(x) = f_Z\left(\frac{x-a}{b-a}\right) \frac{1}{b-a} = \frac{(x-a)^{p-1}(b-x)^{q-1}}{(b-a)^{p+q-1}B(p, q)}, \quad a < x < b.$$




Figura 7.2: Funciones de densidad de las distribuciones beta simétricas con parámetros $p = q = 1/4, 1/2, 3/4, 1, 2, 4$, y 8

7.4. Distribución normal

Una de las distribuciones más importantes en probabilidad y estadística es la distribución *normal*, también llamada distribución *gaussiana* o *campana de Gauss*. Supongamos una variable aleatoria X que es la suma de n variables aleatorias independientes e igualmente distribuidas $X_1, \dots, X_n$. Entonces, por el llamado *teorema central del límite*, X es asintóticamente (es decir, cuando $n \rightarrow \infty$) una distribución normal. La distribución normal también surge en otros muchos casos cuando los sumandos son dependientes entre sí.

Definición 7.4 Se dice que una variable aleatoria X sigue una distribución normal de parámetros μ y σ^2 , y se escribe $X \sim N(\mu, \sigma^2)$, si su función de densidad viene dada por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}, \quad -\infty < x < \infty, \quad (7.10)$$

donde μ y σ^2 son constantes que representan respectivamente la media y la varianza.

La función de densidad (7.10) es simétrica respecto de μ , es decir:

$$f(\mu - x) = f(\mu + x), \quad \forall x \in \mathbb{R},$$

7.4. Distribución normal




Figura 7.3: Funciones de densidad de distribuciones beta asimétricas con parámetros $(p, q) = (2, 3), (2, 5)$ y $(6, 2)$

y de tipo campaniforme (de ahí el nombre de *campana de Gauss*), lo que hace que μ sea además la mediana y la moda de la distribución. La función de densidad presenta puntos de inflexión en $x = \mu \pm \sigma$. El efecto de los parámetros μ y σ sobre la función de densidad y la función de distribución puede verse en las figuras 7.4 a 7.6. La figura 7.4 representa las funciones de densidad y de distribución de tres variables de tipo normal con diferentes medias y desviaciones típicas. La figura 7.5 representa cinco variables normales con diferentes medias e idéntica desviación típica. La función de densidad se va desplazando con la media. La figura 7.6 muestra cinco variables normales con la misma media y diferentes desviaciones típicas. En este caso la función de densidad se hace más o menos dispersa con σ . La distribución normal tipificada que ahora definimos juega un importante papel en la teoría.

Definición 7.5 Se denomina *distribución normal tipificada* o *estandarizada* a una distribución normal con media 0 y desviación típica 1.

La distribución normal tipificada se representa por $Z \sim N(0, 1)$, y su función de densidad es:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}, \quad -\infty < z < \infty. \quad (7.11)$$

La importancia de la normal tipificada radica en que cualquier distribución normal se puede reducir a una tipificada. Se verifica que:




Figura 7.4: Funciones de densidad de las distribuciones normales $\mathcal{N}(0, 1)$, $\mathcal{N}(1, 1/4)$ y $\mathcal{N}(2, 4)$

- Si $X \sim \mathcal{N}(\mu, \sigma^2)$, entonces: $Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$, y recíprocamente:
- Si $Z \sim \mathcal{N}(0, 1)$, entonces: $\mu + \sigma Z \sim \mathcal{N}(\mu, \sigma^2)$.

La función de distribución de una $\mathcal{N}(0, 1)$ se encuentra tabulada y sus valores pueden obtenerse con la ayuda de una hoja de cálculo o software estadístico y se representa por $\Phi(z)$:

$$\Phi(z) = \Pr(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt. \quad (7.12)$$

Al ser la $\mathcal{N}(0, 1)$ simétrica respecto del cero se verifica:

$$\Phi(-z) = 1 - \Phi(z),$$

lo que permite calcular fácilmente probabilidades para valores negativos. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, la variable aleatoria:

$$Z = \frac{X - \mu}{\sigma},$$




Figura 7.5: Funciones de densidad de las distribuciones normales $\mathcal{N}(\mu, 1)$, con $\mu = -2, -1, 0, 1, 2$

es la variable tipificada con distribución $\mathcal{N}(0, 1)$. El principal interés de este resultado es el cálculo de probabilidades. Por ejemplo:

$$\Pr(X \leq x) = \Pr\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = \Pr\left(Z \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right),$$

donde $\Phi(z)$ es la función de distribución de una normal estándar definida en (7.12). El cálculo de otro tipo de probabilidades se realiza tipificando la variable:

$$\Pr(X \leq a) = \Phi\left(\frac{a - \mu}{\sigma}\right),$$

$$\Pr(X > a) = 1 - \Phi\left(\frac{a - \mu}{\sigma}\right),$$

$$\Pr(a < X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right).$$

7.4.1. Características

El siguiente resultado proporciona la función característica de una distribución normal.




Figura 7.6: Funciones de densidad de las distribuciones normales $\mathcal{N}(0, \sigma^2)$, con $\sigma^2 = 1/3, 1/2, 1, 2, 3$

Teorema 7.3 Si $Z \sim \mathcal{N}(0, 1)$ su función característica viene dada por,

$$\varphi_Z(t) = e^{-t^2/2}.$$

En general, si $X \sim \mathcal{N}(\mu, \sigma^2)$ entonces,

$$\varphi_X(t) = \exp\left(it\mu - \frac{\sigma^2 t^2}{2}\right). \quad (7.13)$$

Demostración: Si $Z \sim \mathcal{N}(0, 1)$, entonces

$$\begin{aligned} \varphi_Z(t) = E(e^{itZ}) &= \int_{-\infty}^{\infty} e^{itz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz \\ &= e^{(it)^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-it)^2/2} dz \\ &= e^{-t^2/2}. \end{aligned}$$

Para la segunda parte, si $Z \sim \mathcal{N}(0, 1)$ entonces $X = \mu + \sigma Z \sim \mathcal{N}(\mu, \sigma^2)$. Por tanto:

$$\varphi_X(t) = \varphi_{\mu+\sigma Z} = e^{it\mu} \varphi_Z(\sigma t) = e^{it\mu} e^{-t^2 \sigma^2/2},$$

7.4. Distribución normal

131

de donde se obtiene el resultado.

Al tratarse de una distribución simétrica, si $X \sim \mathcal{N}(0, 1)$, los momentos de orden impar respecto del origen son cero:

$$E(X^{2n+1}) = 0, \quad n = 0, 1, 2, \dots$$

Los momentos de orden par respecto del origen son:

$$E(X^{2n}) = \frac{(2n)!}{2^n n!}, \quad n = 1, 2, \dots$$

7.4.2. Convoluciones

Teorema 7.4 Las transformaciones lineales de variables normales siguen siendo normales. Específicamente, si

$$X \sim \mathcal{N}(\mu, \sigma^2),$$

y a y b son constantes, entonces:

$$Y = a + bX \sim \mathcal{N}(a + b\mu, b^2\sigma^2).$$

Demostración: Es inmediata usando la función característica.

Además, la suma de variables aleatorias normales independientes es nuevamente una variable aleatoria normal, donde los parámetros se obtienen calculando la media y la varianza de la variable suma.

Teorema 7.5 Si:

$$X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), \dots, X_n \sim \mathcal{N}(\mu_n, \sigma_n^2),$$

son variables aleatorias normales independientes y $a_1, \dots, a_n$ son constantes, entonces:

$$a_1 X_1 + \dots + a_n X_n \sim \mathcal{N}(a_1 \mu_1 + \dots + a_n \mu_n, a_1^2 \sigma_1^2 + \dots + a_n^2 \sigma_n^2).$$

Por tanto, cualquier combinación lineal de variables aleatorias normales independientes es de nuevo una variable aleatoria normal.

Demostración: La prueba es directa, haciendo uso de la función característica (7.13).

Ejemplo 7.3 Si $X \sim \mathcal{N}(\mu, \sigma^2)$ probar que:

$$\begin{aligned} \Pr(\mu - \sigma < X < \mu + \sigma) &= 0,6826 = 68,26\%, \\ \Pr(\mu - 2\sigma < X < \mu + 2\sigma) &= 0,9545 = 95,45\%, \\ \Pr(\mu - 3\sigma < X < \mu + 3\sigma) &= 0,9973 = 99,73\%. \end{aligned}$$

Solución: Si $k = 1, 2, 3$ se verifica:

$$\begin{aligned}\Pr(\mu - k\sigma < X < \mu + k\sigma) &= \Pr(X < \mu + k\sigma) - \Pr(X < \mu - k\sigma) \\ &= \Pr\left(\frac{X - \mu}{\sigma} < k\right) - \Pr\left(\frac{X - \mu}{\sigma} < -k\right) \\ &= \Phi(k) - \Phi(-k) \\ &= 2\Phi(k) - 1.\end{aligned}$$

Al ser $\Phi(1) = 0,8413$, $\Phi(2) = 0,97725$, y $\Phi(3) = 0,99865$, se obtienen las probabilidades.

◇

7.4.3. El teorema central del límite

Comenzamos definiendo la convergencia en distribución de variables aleatorias.

Definición 7.6 Una sucesión de variables aleatorias $X_1, X_2, \dots$ converge en distribución a una variable aleatoria X si

$$\lim_{n \rightarrow \infty} \Pr(X_n \leq x) = \Pr(X \leq x),$$

en todos los puntos x donde $F_X(x) = \Pr(X \leq x)$ es continua. La convergencia en distribución se denota como $X_n \xrightarrow{D} X$.

El teorema central del límite nos indica cómo se comportan las sumas de variables aleatorias independientes e igualmente distribuidas (i.i.d.) no necesariamente normales. Si tenemos n variables aleatorias i.i.d. con media μ y varianza σ^2 entonces,

$$\begin{aligned}E\left(\sum_{i=1}^n X_i\right) &= \sum_{i=1}^n E(X_i) = n\mu, \\ \text{Var}\left(\sum_{i=1}^n X_i\right) &= \sum_{i=1}^n \text{Var}(X_i) = n\sigma^2.\end{aligned}$$

El teorema central del límite dice que para valores grandes de n la variable aleatoria:

$$\frac{\sum_{i=1}^n X_i - E(\sum_{i=1}^n X_i)}{\sqrt{\text{Var}(\sum_{i=1}^n X_i)}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

sigue aproximadamente una distribución $\mathcal{N}(0, 1)$.

Teorema 7.6 (Teorema central del límite de Lindeberg-Lévy) Consideremos una sucesión $X_1, X_2, \dots, X_n$ de variables aleatorias i.i.d. con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2 > 0$ finita. Entonces,

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} \mathcal{N}(0, \sigma^2)$$

7.4. Distribución normal

o lo que es equivalente:

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{D} \mathcal{N}(0, 1).$$

Demostración: Mediante funciones características:

$$\varphi_n(t) = E(e^{it\bar{X}/\sqrt{n}}) = \varphi(t/\sqrt{n})^n = \left[\varphi(0) + \frac{t}{\sqrt{n}}\varphi'(0) + \frac{t^2}{2n}\varphi''(0) + \dots \right]^n,$$

donde $\varphi(0) = 1$, $\varphi'(0) = iE(X)$ y $\varphi''(0) = i^2E(X^2) = -\sigma^2$. Por tanto cuando $n \rightarrow \infty$:

$$\varphi_n(t) = \left[1 - \frac{t^2\sigma^2}{2n} + o(t^2) \right]^n \rightarrow e^{-t^2\sigma^2/2},$$

que es la función característica de una variable normal.

El teorema de Moivre-Laplace permite aproximar una distribución binomial por medio de una distribución normal.

Teorema 7.7 (Teorema de Moivre-Laplace) Sea X una variable aleatoria binomial con parámetros n y p . Entonces, la función de distribución de la variable aleatoria:

$$Z = \frac{X - np}{\sqrt{np(1-p)}} \quad (7.14)$$

converge en distribución a la distribución normal estándar cuando $n \rightarrow \infty$.

La importancia de este resultado es que permite calcular de un modo simple la probabilidad de que el número de éxitos esté dentro de un intervalo dado. Por ejemplo, si queremos calcular la probabilidad de que el número de éxitos esté comprendido entre a y b usando el resultado (7.14) tenemos:

$$\begin{aligned}\Pr(a \leq X \leq b) &= \Pr\left(\frac{a - np}{\sqrt{np(1-p)}} \leq \frac{X - np}{\sqrt{np(1-p)}} \leq \frac{b - np}{\sqrt{np(1-p)}}\right) \\ &\approx \Pr\left(\frac{a - np}{\sqrt{np(1-p)}} \leq Z \leq \frac{b - np}{\sqrt{np(1-p)}}\right) \\ &= \Phi\left(\frac{b - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - np}{\sqrt{np(1-p)}}\right).\end{aligned}$$

Si el número de ensayos es moderado puede obtenerse una mejora a esta aproximación. Estamos aproximando una distribución discreta que únicamente toma valores enteros mediante una distribución continua que únicamente toma valores en un intervalo. Para conseguir una mejora, se aplica la llamada *corrección por continuidad*, que se obtiene reemplazando a y b por $a - 0,5$ y $b + 0,5$, respectivamente. Se verifica entonces que:

$$\Pr(a \leq X \leq b) \approx \Pr\left(\frac{a - 0,5 - np}{\sqrt{np(1-p)}} \leq Z \leq \frac{b + 0,5 - np}{\sqrt{np(1-p)}}\right).$$

Ejemplo 7.4 El coste medio de un siniestro es de 500 euros con una desviación típica de 400 euros. Obtener la probabilidad de que el coste total de 70 siniestros de este tipo supere la cantidad de 42000 euros.

Solución: Sean $X_1, \dots, X_{70}$ los 70 costes, donde $\mu = 500$ y $\sigma = 400$. Tenemos que calcular $\Pr(\sum_{i=1}^{70} X_i > 42000)$. Por el teorema central del límite:

$$\sum_{i=1}^n X_i \approx \mathcal{N}(n\mu, n\sigma^2).$$

En nuestro caso: $n = 70$, $n\mu = 35000$ y $n\sigma^2 = 70 \cdot 400^2$. Por tanto:

$$\Pr\left(\sum_{i=1}^{70} X_i > 42000\right) \approx 1 - \Pr\left(Z \leq \frac{42000 - 35000}{400\sqrt{70}}\right) = 0,018.$$

No se ha ajustado la distribución por continuidad por tratarse de una aproximación a una variable de tipo continuo. $\diamond$

7.5. Distribución log-normal

La distribución log-normal es uno de los modelos más utilizados para ajustar datos relativos al coste de un siniestro.

Definición 7.7 Se dice que una variable aleatoria X sigue una distribución log-normal si su logaritmo es normal, es decir si:

$$\log(X) \sim \mathcal{N}(\mu, \sigma^2). \quad (7.15)$$

Si X sigue una distribución log-normal se representa por $X \sim \mathcal{LN}(\mu, \sigma^2)$.

Las funciones de distribución y de densidad de una distribución log-normal $X \sim \mathcal{LN}(\mu, \sigma^2)$ vienen dadas, respectivamente, por:

$$F(x) = \Phi\left(\frac{\log x - \mu}{\sigma}\right), \quad x > 0, \quad (7.16)$$

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{\log x - \mu}{\sigma}\right)^2\right\}, \quad x > 0. \quad (7.17)$$

Para obtener (7.16) hacemos uso de la definición (7.15),

$$\begin{aligned} F(x) &= \Pr(X \leq x) = \Pr(\log X \leq \log x) \\ &= \Pr\left(\frac{\log X - \mu}{\sigma} \leq \frac{\log x - \mu}{\sigma}\right) \\ &= \Phi\left(\frac{\log x - \mu}{\sigma}\right), \end{aligned}$$

7.5. Distribución log-normal

donde $\Phi(z)$ representa la función de distribución de una normal estándar, definida en (7.12). La función de densidad se obtiene derivando la función de distribución,

$$f(x) = \frac{d}{dx} F(x) = \frac{1}{\sigma x} \phi\left(\frac{\log x - \mu}{\sigma}\right),$$

de donde se obtiene (7.17). La figura 7.7 muestra las funciones densidad de varias distribuciones log-normales.

Podemos obtener una relación sencilla comenzando con la distribución normal: si $U \sim \mathcal{N}(\mu, \sigma^2)$, entonces $X = \exp(U) \sim \mathcal{LN}(\mu, \sigma^2)$. Nótese que ahora el parámetro $\lambda = e^\mu$ es un parámetro de escala mientras que σ es un parámetro de forma.

7.5.1. Momentos

El siguiente resultado proporciona los momentos de una distribución log-normal.

Teorema 7.8 Si $X \sim \mathcal{LN}(\mu, \sigma^2)$, entonces:

$$E(X^k) = \exp\left(k\mu + \frac{k^2\sigma^2}{2}\right), \quad k = 1, 2, \dots$$

La media y la varianza son, respectivamente:

$$\begin{aligned} E(X) &= \exp\left(\mu + \frac{\sigma^2}{2}\right), \\ \text{Var}(X) &= \exp(2\mu + \sigma^2)[\exp(\sigma^2) - 1]. \end{aligned}$$

Demostración: Si $U \sim \mathcal{N}(\mu, \sigma^2)$, $X = e^U \sim \mathcal{LN}(\mu, \sigma^2)$ de donde:

$$E(X^k) = E(e^{kU}) = M_U(k) = \exp\left(k\mu + \frac{k^2\sigma^2}{2}\right),$$

donde $M_U(\cdot)$ es la función generatriz de momentos de una normal $\mathcal{N}(\mu, \sigma^2)$. $\blacksquare$

El coeficiente de variación de la distribución log-normal es:

$$\text{CV}(X) = \frac{\sigma_X}{\mu_X} = \sqrt{e^{\sigma^2} - 1}.$$

A partir de (7.16) se obtiene el cuantil de orden p ,

$$x_p = \exp(\mu + z_p\sigma),$$

donde z_p representa el cuantil de orden p de una variable normal $Z \sim \mathcal{N}(0, 1)$, es decir, $\Pr(Z \leq z_p) = p$. En particular, la mediana es:

$$x_{0,5} = \exp(\mu + z_{0,5}\sigma) = e^\mu.$$

El valor de la moda es,

$$M_o = \exp(\mu - \sigma^2).$$

Si definimos $w^2 = \exp(\sigma^2) - 1$, los coeficientes de asimetría y curtosis son:

$$\begin{aligned}\gamma_1 &= w^3 + 3w > 0, \\ \gamma_2 &= w^8 + 6w^6 + 15w^4 + 16w^2 > 0,\end{aligned}$$

de donde se trata de una distribución asimétrica y leptocúrtica. Cuando $\sigma \rightarrow 0$ tenemos que $w \rightarrow 0$ y $\gamma_1 \rightarrow 0$ y $\gamma_2 \rightarrow 0$.




Figura 7.7: Funciones de densidad de las distribuciones log-normales con $\mu = 0$ y $\sigma = 0, 2; 0, 3; 0, 5, 1$ y $1,5$ (de derecha a izquierda)

7.5.2. Reproductividad

La distribución log-normal presenta la siguiente propiedad de reproductividad.

Teorema 7.9 Sean $X_1 \sim \mathcal{LN}(\mu_1, \sigma_1^2), \dots, X_m \sim \mathcal{LN}(\mu_m, \sigma_m^2)$ distribuciones log-normales independientes. Entonces, si $a_i, b_i, i = 1, 2, \dots, m$ son números reales, la variable aleatoria,

$$T = \prod_{i=1}^m a_i X_i^{b_i} \sim \mathcal{LN}(\mu_T, \sigma_T^2),$$

7.5. Distribución log-normal

donde,

$$\mu_T = \sum_{i=1}^m \log(a_i) + \sum_{i=1}^m b_i \mu_i; \quad \sigma_T^2 = \sum_{i=1}^m b_i^2 \sigma_i^2.$$

Demostración: Si $X_i \sim \mathcal{LN}(\mu_i, \sigma_i^2)$ entonces $\log X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ y $\log a_i + b_i \log X_i \sim \mathcal{N}(\log a_i + b_i \mu_i, b_i^2 \sigma_i^2)$, $i = 1, 2, \dots, m$. Ahora, puesto que $\log X_i$ son variables aleatorias normales independientes tenemos que,

$$\sum_{i=1}^m (\log a_i + b_i \log X_i) \sim \mathcal{N}\left(\sum_{i=1}^m (\log a_i + b_i \mu_i), \sum_{i=1}^m b_i^2 \sigma_i^2\right),$$

de donde $\log T \sim \mathcal{N}(\mu_T, \sigma_T^2)$ y por tanto $T \sim \mathcal{LN}(\mu_T, \sigma_T^2)$. ■

7.5.3. Distribución log-normal con tres parámetros

En estadística actuarial algunas variables no dan lugar a valores por debajo de un límite δ , de modo que la variable aleatoria sólo está definida para valores $x > \delta$. El límite δ representa un parámetro de localización, que puede incorporarse al modelo log-normal básico, dando lugar a una distribución con tres parámetros. La función de densidad es ahora,

$$f(x) = \frac{1}{(x - \delta)\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2}\left(\frac{\log(x - \delta) - \mu}{\sigma}\right)^2\right\}, \quad x > \delta \quad (7.18)$$

donde $\sigma > 0$ y $-\infty < \delta < \infty$. La función de distribución de (7.18) es ahora,

$$F(x) = \Phi\left(\frac{\log(x - \delta) - \mu}{\sigma}\right).$$

La media de (7.18) es,

$$E(X) = \delta + \exp\left(\mu + \frac{\sigma^2}{2}\right),$$

mientras que la varianza coincide con la del modelo con dos parámetros. El cuantil de orden p ($0 < p < 1$) es,

$$x_p = \delta + \exp(\mu + z_p \sigma),$$

mientras que el coeficiente de variación se convierte en,

$$CV(X) = \frac{\sigma_X}{\mu_X} = \frac{\exp(\mu + \frac{\sigma^2}{2})\sqrt{e^{\sigma^2} - 1}}{\delta + \exp(\mu + \frac{\sigma^2}{2})}.$$

7.6. Distribuciones de Pareto

La distribución de Pareto en todas sus variedades ha sido ampliamente estudiada y aplicada en la literatura económica y actuarial por sus buenas propiedades. El libro de Arnold (1983) es una de las referencias clásicas sobre las distribuciones de Pareto en todos sus aspectos. Desde el punto de vista actuarial, el ajuste de la cola de una distribución (es decir, el cálculo de la probabilidad de que se produzca una pérdida grande) es un aspecto clave. La función de densidad de la distribución de Pareto converge a cero mucho más lentamente que la distribución log-normal. Por tanto, resulta mucho más seguro utilizarla para determinar las primas de un reaseguro en los tramos de grandes siniestros.

Existen diversas clasificaciones de las distribuciones de Pareto. Una de las más ampliamente utilizada es la jerarquía propuesta por Arnold (1983), donde se comienza por la distribución clásica y se van obteniendo hasta cuatro modelos anidados. Aquí nos interesaremos por dos tipos de distribuciones de Pareto: la distribución de Pareto clásica o Pareto tipo I y la distribución de Pareto tipo II, que se corresponden con las distribuciones de Pareto I y II establecidas por Arnold. Comenzamos definiendo estas dos distribuciones.

Definición 7.8 Una variable aleatoria X sigue una distribución clásica de Pareto, si la función de distribución viene dada por:

$$F(x) = 1 - \left(\frac{x}{\sigma}\right)^{-\alpha}, \quad x \geq \sigma > 0, \quad (7.19)$$

y $F(x) = 0$ si $x < \sigma$, donde $\alpha > 0$ es un parámetro de forma y σ un parámetro de escala. Representaremos $X \sim \text{PaI}(\alpha, \sigma)$.

La función de densidad es:

$$f(x) = \frac{d}{dx}F(x) = \frac{\alpha\sigma^\alpha}{x^{\alpha+1}}, \quad x \geq \sigma > 0$$

y $f(x) = 0$ si $x < \sigma$.

Definición 7.9 Una variable aleatoria X sigue una distribución de Pareto tipo II si la función de distribución viene dada por:

$$F(x) = 1 - \frac{1}{(1 + x/\sigma)^\alpha}, \quad x > 0 \quad (7.20)$$

y $F(x) = 0$ si $x < 0$, donde $\alpha > 0$ es un parámetro de forma y σ un parámetro de escala. Representaremos $X \sim \text{PaII}(\alpha, \sigma)$.

La relación entre las dos distribuciones es muy simple: si $X \sim \text{PaI}(\alpha, \sigma)$, entonces $X - \sigma \sim \text{PaII}(\alpha, \sigma)$. La distribución Pareto I es útil cuando sólo se

dispone de observaciones individuales por encima de un límite o deducible. La distribución de Pareto II es útil cuando disponemos de todas las observaciones de una cartera. La figura 7.8 muestra la función de densidad de la distribución de Pareto tipo I según diversos valores de α .

La siguiente transformación relaciona la beta con la distribución clásica de Pareto. Si $X \sim \text{Be}(p, q = 1)$, entonces,

$$\frac{1}{X} \sim \text{PaI}(p, \sigma = 1).$$

7.6.1. Génesis de las distribuciones de Pareto

En este apartado estudiaremos el origen de las distribuciones de Pareto. Desde el punto de vista de la estadística de los seguros, una forma de obtener la distribución de Pareto I es como la distribución de pérdidas por incendios (Shpilberg, 1977).

Teorema 7.10 Supongamos que la duración de un incendio T presenta una tasa de mortalidad constante e igual a $\alpha > 0$, de modo que $r_T(t) = \alpha$, para todo $t > 0$. Supongamos además que la distribución del daño X está relacionada con el tiempo de duración del incendio, de modo que,

$$X = \sigma \exp(kT), \quad (7.21)$$

para valores $\sigma, k > 0$. Entonces, la distribución del daño X es una variable aleatoria de Pareto tipo I con parámetros σ y α/k .

Demostración: Si $r_T(t) = \alpha$ es inmediato probar que se trata de una distribución de tipo exponencial, ver sección 7.9, con media α^{-1} , en notación $\mathcal{E}(\alpha)$. A continuación, haciendo uso del teorema del cambio de variable con (7.21) obtenemos el resultado. ■

La distribución de Pareto II se obtiene como una mezcla de la distribución exponencial. Comenzamos suponiendo que la distribución de las pérdidas es de tipo exponencial de media θ^{-1} . Sin embargo, imaginemos que los valores de θ cambian de una pérdida a otra, posiblemente debido al hecho de que proceden de distintas fuentes de variación: diferentes tipos de vehículos o de conductores, diferentes países etc.

Teorema 7.11 Supongamos que la distribución de las pérdidas es condicionalmente de tipo exponencial,

$$X|\Theta \sim \mathcal{E}(1/\Theta), \quad (7.22)$$

con función de distribución $1 - e^{-\theta x}$, si $x > 0$. Supongamos que el valor del parámetro θ varía de acuerdo con una distribución gamma, $\theta \sim \mathcal{G}(\alpha, 1/\sigma)$. Entonces, la distribución incondicional de las pérdidas es de tipo Pareto II con parámetros α y σ .




Figura 7.8: Funciones de densidad de la distribución de Pareto tipo I con $\sigma = 1$ y $\alpha = 0.5, 1, 1.5, 2$ y 3

Demostración: Se trata de una mezcla de distribuciones como en la sección 5.7. Tenemos que $F(x|\theta) = 1 - e^{-\theta x}$. Por medio de la fórmula (5.22) y haciendo uso de (7.22), la función de distribución incondicional de la variable aleatoria X es,

$$\begin{aligned} F_X(x) &= \int_0^\infty F_{X|\Theta}(x|\theta) f_\Theta(\theta) d\theta \\ &= \int_0^\infty (1 - e^{-\theta x}) \frac{\sigma^\alpha \theta^{\alpha-1} e^{-\sigma\theta}}{\Gamma(\alpha)} d\theta \\ &= 1 - \int_0^\infty \frac{\sigma^\alpha \theta^{\alpha-1} e^{-\theta(x+\sigma)}}{\Gamma(\alpha)} d\theta \\ &= 1 - \frac{1}{(1+x/\sigma)^\alpha}, \end{aligned}$$

que es la función de distribución de una Pareto tipo II. ■

Notar que la distribución de Pareto tiene una cola más pesada que la distribución exponencial, es decir, se acerca más lentamente a infinito.

7.6.2. Características

Los momentos de las distribuciones de Pareto vienen dados en el siguiente teorema.

7.6. Distribuciones de Pareto

Teorema 7.12 Los momentos de las distribuciones de Pareto son:

■ Si X sigue una distribución de Pareto tipo I,

$$E(X^r) = \frac{\alpha \sigma^r}{\alpha - r}, \quad \alpha > r. \quad (7.23)$$

■ Si X sigue una distribución de Pareto tipo II,

$$E(X^r) = \frac{\Gamma(\alpha - r) \Gamma(r + 1) \sigma^r}{\Gamma(\alpha)}, \quad \alpha > r. \quad (7.24)$$

Demostración: Si $k < \alpha$ tenemos que:

$$E(X^r) = \int_0^\infty \frac{\alpha \sigma^\alpha}{x^{\alpha-r+1}} dx = \frac{\alpha \sigma^r}{\alpha - r}.$$

La integral se ha resuelto identificando el integrando como el núcleo de la función de densidad de una distribución de Pareto con parámetro de forma $\alpha - r > 0$ y parámetro de escala σ . Si $\alpha \leq k$ nótese que la integral diverge. Para la Pareto II:

$$E(X^r) = \int_0^\infty \frac{\alpha \sigma^{-1} x^r}{(1 + x/\sigma)^{\alpha+1}} dx = \alpha \sigma^r B(\alpha - r, r + 1)$$

si $\alpha > r$. Se ha realizado el cambio de variable $t = 1/(1 + x/\sigma)$. Desarrollando la expresión anterior se obtiene (7.24). ■

A partir de la expresión (7.23) se obtiene la media de la Pareto I,

$$E(X) = \frac{\alpha \sigma}{\alpha - 1}, \quad \alpha > 1.$$

La varianza de la distribución Pareto I y II es,

$$\text{Var}(X) = \frac{\alpha \sigma^2}{\alpha(\alpha - 1)^2(\alpha - 2)}, \quad \alpha > 2.$$

Los coeficientes de asimetría y curtosis son:

$$\begin{aligned} \gamma_1 &= 2 \cdot \frac{\alpha + 1}{\alpha - 3} \sqrt{1 - \frac{2}{\alpha}}, \quad \alpha > 3, \\ \gamma_2 &= \frac{6(\alpha^3 + \alpha^2 - 6\alpha - 2)}{\alpha(\alpha - 3)(\alpha - 4)}, \quad \alpha > 4. \end{aligned}$$

Se verifica que $\gamma_1 \rightarrow 2$ y $\gamma_2 \rightarrow 6$ cuando $\alpha \rightarrow \infty$. La tabla 7.1 presenta estas dos distribuciones de Pareto junto con sus principales características. La tabla 7.2 muestra valores indicativos del parámetro α según el tipo de pérdida.

Tabla 7.1: Comparación de las distribuciones de Pareto tipo I y II.

	Pareto tipo I, $\mathcal{P}aI(\alpha, \sigma)$	Pareto tipo II, $\mathcal{P}aII(\alpha, \sigma)$
Función de distribución	$1 - \left(\frac{x}{\sigma}\right)^{-\alpha}, x > \sigma$	$1 - \frac{1}{(1+x/\sigma)^\alpha}, x > 0$
Función de densidad	$\frac{\alpha\sigma^\alpha}{x^{\alpha+1}}, x > \sigma$	$\frac{\alpha\sigma^{-1}}{(1+x/\sigma)^{\alpha+1}}, x > 0$
Función de azar	$\frac{\alpha}{x}, x > \sigma$	$\frac{\alpha}{1+x/\sigma}, x > 0$
Vida residual media ($\alpha > 1$)	$\frac{x}{\alpha-1}, x > \sigma$	$\frac{x+\sigma}{\alpha-1}, x > 0$
Media ($\alpha > 1$)	$\frac{\alpha\sigma}{\alpha-1}$	$\frac{\sigma}{\alpha-1}$
Varianza ($\alpha > 2$)	$\frac{\alpha\sigma^2}{(\alpha-1)^2(\alpha-2)}$	$\frac{\sigma^2}{(\alpha-1)^2(\alpha-2)}$
$E[(X-d)_+]$ ($\alpha > 1$)	$\frac{\sigma^\alpha}{(\alpha-1)d^{\alpha-1}}$	$\frac{\sigma^\alpha}{(\alpha-1)(\sigma+d)^{\alpha-1}}$
$E[X \wedge d]$ ($\alpha > 1$)	$\frac{\sigma}{\alpha-1} \left[\alpha - \left(\frac{\sigma}{d}\right)^{\alpha-1} \right]$	$\frac{\sigma}{\alpha-1} \left[1 - \left(\frac{\sigma}{\sigma+d}\right)^{\alpha-1} \right]$

Tabla 7.2: Valores aproximados del parámetro α .

Distribución de pérdida	Valor aproximado de α
Terremotos y tormentas	1,0
Incendios	2,0
Incendios en industrias	1,5
Responsabilidad general	1,8
Responsabilidad general automóviles	2,5
Daños en el trabajo	2,0

7.7. Distribución de Pareto generalizada

La distribución de los valores máximos o mínimos de determinados fenómenos naturales (altura de olas, velocidad de vientos, temperaturas, riadas etc.) son de especial interés en las aplicaciones prácticas de estadística actuarial.

El método tradicional para analizar valores extremos se basa en las distribuciones límites de extremos (o en la distribución generalizada de extremos) originalmente introducidas por Fisher and Tippet (1928).

7.7. Distribución de Pareto generalizada

El uso de estas distribuciones es apropiado cuando los datos consisten de un conjunto de valores máximos. Sin embargo, este procedimiento es a veces criticado por el hecho de que se pierde parte de la información contenida en la muestra. Este problema se puede resolver considerando un conjunto de los valores más grandes o bien considerando aquellos valores que se encuentran por encima de un límite o valor deducible. La diferencia entre estos valores y el límite se denominan *excedencias* por encima de ese límite. En esta situación, la distribución que conviene utilizar es la llamada distribución de Pareto generalizada.

Definición 7.10 Se dice que una variable aleatoria X sigue una distribución de Pareto generalizada si su función de distribución viene dada por,

$$F(x; k, \sigma) = \begin{cases} 1 - \left(1 - \frac{kx}{\sigma}\right)^{1/k}, & k \neq 0, \\ 1 - \exp(-x/\sigma), & k = 0, \end{cases} \quad (7.25)$$

donde $\sigma > 0$ es un parámetro de escala y k un parámetro de forma. Representaremos $X \sim \mathcal{P}G(k, \sigma)$.

El rango de la distribución es $0 < x < \infty$ si $k \leq 0$ y $0 < x < \sigma/k$ cuando $k > 0$. El caso $k = 0$, que es la distribución exponencial, es la distribución límite cuando $k \rightarrow 0$. La distribución de Pareto generalizada (DPG) es una generalización de la distribución de Pareto. Los siguientes valores del parámetro k son de especial interés:

- Si $k = 0$ la DPG se reduce a la distribución exponencial con media σ .
- Si $k = 1$ la DPG se convierte en la distribución uniforme $\mathcal{U}(0, \sigma)$.
- Si $k < 0$ la DPG se reduce a la distribución de Pareto.
- Si $k \leq -\frac{1}{2}$ la DPG presenta $\text{Var}(X) = \infty$. De hecho, el momento central de orden r existe sólo cuando $k > -1/r$.

La función de densidad de la DPG es,

$$f(x; k, \sigma) = \begin{cases} \frac{1}{\sigma} \left(1 - \frac{kx}{\sigma}\right)^{1/k-1}, & k \neq 0, \\ \sigma^{-1} \exp(-x/\sigma), & k = 0. \end{cases}$$

El siguiente resultado justifica los comentarios vistos en la introducción.

Teorema 7.13 Sea X una distribución de pérdidas tipo Pareto generalizada. Entonces, la distribución de las excedencias por encima de un deducible d es de nuevo una distribución Pareto Generalizada con parámetros k y $\sigma - kd$.

Demostración: Si $X \sim \mathcal{PG}(k, \sigma)$, se trata de obtener la distribución de la variable aleatoria $X - d$ condicionada por el suceso $X > d$:

$$\begin{aligned} \Pr(X - d \leq x | X > d) &= \frac{\Pr(d < X \leq x + d)}{\Pr(X > d)} \\ &= \frac{F(x + d; k, \sigma) - F(d; k, \sigma)}{1 - F(d; k, \sigma)} \\ &= \frac{(1 - kd/\sigma)^{1/k} - (1 - k(x + d)/\sigma)^{1/k}}{(1 - kd/\sigma)^{1/k}} \\ &= 1 - (1 - kx/(\sigma - kd))^{1/k} \end{aligned}$$

que es una distribución Pareto generalizada $\mathcal{PG}(k, \sigma - kd)$. ■

El siguiente resultado relaciona la distribución de Pareto generalizada con la distribución de extremos generalizada.

Teorema 7.14 Sea N una variable aleatoria de Poisson que representa el número de reclamaciones de una cartera. Supongamos que las pérdidas asociadas a las reclamaciones son variables aleatorias independientes e igualmente distribuidas $X_1, \dots, X_N$ del tipo Pareto generalizada $\mathcal{PG}(k, \sigma)$. Entonces, la distribución de la variable $\max\{X_1, \dots, X_N\}$ es de tipo de extremos generalizada, de modo que,

$$\Pr(\max\{X_1, \dots, X_N\} \leq x) = \exp \left[-\lambda \left(1 - \frac{kx}{\sigma} \right)^{1/k} \right].$$

7.7.1. Características

La función de azar $r(x) = f(x)/[1 - F(x)]$ de la DPG es,

$$r(x) = \frac{1}{\sigma - kx},$$

que es una función monótona en x , decreciente si $k < 0$, constante si $k = 0$ y creciente si $k > 0$. Para el cálculo de los momentos es más conveniente trabajar con la variable aleatoria $1 - kX/\sigma$. Se verifica que,

$$E \left(1 - \frac{kX}{\sigma} \right)^r = \frac{1}{1 + rk}, \quad \text{si } 1 + rk > 0. \quad (7.26)$$

A partir de (7.26) se obtienen la media y la varianza que vienen dadas por,

$$\begin{aligned} E(X) &= \frac{\sigma}{1 + k}, \\ \text{Var}(X) &= \frac{\sigma^2}{(1 + k)^2(1 + 2k)}. \end{aligned}$$

7.8. Distribución inversa Gaussiana

Los coeficientes de asimetría y curtosis vienen dados por,

$$\begin{aligned} \gamma_1 &= \frac{2(1 - k)\sqrt{1 + 2k}}{1 + 3k}, \\ \gamma_2 &= \frac{3(1 + 2k)(3 - k + 2k^2)}{(1 + 3k)(1 + 4k)} - 3. \end{aligned}$$

Si $k > -1$, $d > 0$ y $\sigma - kd > 0$, la vida residual media de una distribución $X \sim \mathcal{PG}(k, \sigma)$ es,

$$e_X(d) = E(X - d | X > d) = \frac{\sigma - kd}{1 + k}.$$

En consecuencia, si la DPG se ajusta a un conjunto de datos, la nube de puntos $(x_i, e_X(x_i))$ se debe encontrar sobre una recta de pendiente $-k/(1 + k)$ y ordenada en el origen $\sigma/(1 + k)$.

7.8. Distribución inversa Gaussiana

La distribución inversa Gaussiana o distribución de Wald se ha convertido en una de las distribuciones más utilizadas para ajustar datos relativos al coste de los siniestros, dadas sus buenas propiedades. La distribución inversa Gaussiana posee unas propiedades muy parecidas a las de la distribución normal. Existen diversas parametrizaciones de esta distribución. Aquí presentaremos la más usada con dos parámetros para posteriormente incluir una versión con tres parámetros.

Definición 7.11 Una variable aleatoria X sigue una distribución inversa Gaussiana con parámetros μ y λ y representaremos $X \sim \mathcal{IG}(\mu, \lambda)$, si su función de densidad viene dada por,

$$f(x) = \sqrt{\frac{\lambda}{2\pi x^3}} \exp \left\{ -\frac{\lambda}{2\mu^2 x} (x - \mu)^2 \right\}, \quad x > 0, \quad (7.27)$$

donde $\lambda, \mu > 0$.

Se trata de una distribución asimétrica positiva y unimodal. La función de distribución puede expresarse en términos de la función de distribución $\Phi(\cdot)$ de una normal estándar y viene dada por,

$$F(x) = \Phi \left(\sqrt{\frac{\lambda}{x}} \left(\frac{x}{\mu} - 1 \right) \right) + e^{2\lambda/\mu} \Phi \left(-\sqrt{\frac{\lambda}{x}} \left(\frac{x}{\mu} + 1 \right) \right), \quad x > 0.$$

La figura 7.9 muestra la función de densidad de diversas variables aleatorias inversa Gaussiana.

Demostración: Probaremos (7.32) mediante funciones características:

$$\begin{aligned}\varphi_S(t) &= [\varphi_{X_i}(t)]^n = \exp \left\{ \frac{n\lambda}{\mu} \left(1 - \sqrt{1 - \frac{2i\mu^2 t}{\lambda}} \right) \right\} \\ &= \exp \left\{ \frac{n^2\lambda}{n\mu} \left(1 - \sqrt{1 - \frac{2i(n\mu)^2 t}{n^2\lambda}} \right) \right\}\end{aligned}$$

de donde se sigue el resultado. La prueba de (7.33) es inmediata teniendo en cuenta que $\bar{X} = S/n$ y usando (7.31). ■

7.9. Distribución exponencial

La distribución exponencial tiene especial aplicación en fiabilidad de sistemas, en variables que representan tiempo de vida de componentes con pequeño desgaste, según indica la propiedad de *pérdida de memoria*.

Definición 7.12 Una variable aleatoria es de tipo exponencial si su función de densidad viene dada por ($\sigma > 0$):

$$f(x) = \begin{cases} \frac{1}{\sigma} e^{-x/\sigma} & \text{si } x \geq 0, \\ 0 & \text{si } x < 0, \end{cases} \quad (7.34)$$

y se representa por $X \sim \mathcal{E}(\sigma)$.

La función de distribución viene dada por:

$$F(x) = 1 - \exp(-x/\sigma), \quad x \geq 0 \quad (7.35)$$

y $F(x) = 0$ si $x < 0$. Las gráficas de las funciones de densidad y de distribución de varias exponenciales aparecen en la figura 7.10.

7.9.1. Características

La función generatriz de momentos de una exponencial es,

$$M_X(t) = E(e^{tX}) = \int_0^\infty \frac{1}{\sigma} e^{-x(\sigma^{-1}-t)} dx = \frac{1}{1-\sigma t}, \quad t < 1/\sigma,$$

y la función característica,

$$\varphi_X(t) = E(e^{itX}) = M_X(it) = \frac{1}{1-i\sigma t}. \quad (7.36)$$

7.9. Distribución exponencial




Figura 7.10: Funciones de densidad de las distribuciones exponenciales con parámetros $\sigma = 1/2, 1$ y 2

El momento de orden r es,

$$E(X^r) = \Gamma(r+1)\sigma^r, \quad r+1 > 0$$

y en particular, los momentos respecto del origen son,

$$\alpha_r = E(X^r) = \sigma^r \cdot r!, \quad r = 1, 2, \dots$$

La media y la varianza de la distribución exponencial son,

$$\begin{aligned}E(X) &= \sigma, \\ \text{Var}(X) &= \sigma^2.\end{aligned}$$

La distribución exponencial es asimétrica positiva ($\gamma_1 = 2$) y leptocúrtica ($\gamma_3 = 6$). Por otro lado, es la única distribución continua con soporte sobre los números reales positivos que verifica la propiedad de *pérdida de memoria*:

$$\Pr(X > s+t | X > s) = \Pr(X > t),$$

donde s y t son números reales positivos. En efecto, si $X \sim \mathcal{E}(\sigma)$ y $s, t > 0$:

$$\Pr(X > s+t | X > s) = \frac{\Pr(X > s+t, X > s)}{P(X > s)}$$

$$\begin{aligned}
&= \frac{\Pr(X > s+t)}{\Pr(X > s)} \\
&= \frac{\exp(-(s+t)/\sigma)}{\exp(-s/\sigma)} \\
&= \exp(-t/\sigma) \\
&= \Pr(X > t).
\end{aligned}$$

La tabla 7.3 muestra diversas características importantes de la distribución exponencial.

Tabla 7.3: Características de la distribución exponencial

	Exponencial $\mathcal{E}(\sigma)$
Función de distribución	$1 - e^{-x/\sigma}, x > 0$
Función de densidad	$(1/\sigma)e^{-x/\sigma}, x > 0$
Función de azar	$\frac{1}{\sigma}$
Vida residual media	σ
Media	σ
Varianza	σ^2
$E[(X-d)_+]$	$\sigma(1 - e^{-d/\sigma})$
$E(X \wedge d)$	$\sigma e^{-d/\sigma}$

Ejemplo 7.5 El tiempo que un paciente tarda en ser atendido en un centro de salud sigue una distribución exponencial de media quince minutos. Calcular la probabilidad de que un paciente tarde en ser atendido más de 30 minutos.

Solución: Sea X el tiempo de espera de un paciente hasta ser atendido. Puesto que esta variable sigue una distribución exponencial con media 15 minutos, entonces:

$$E(X) = \sigma = 15,$$

y la función de distribución viene dada por:

$$F(x) = 1 - \exp(-x/15), x \geq 0.$$

La probabilidad pedida es:

$$\Pr(X > 30) = 1 - F(30) = \exp(-2) = 0,1353 = 13,53\%.$$

◇

7.10. Distribución gamma

La distribución gamma es una de las distribuciones más utilizadas en estadística actuarial cuando se dispone de un conjunto de datos positivos, unimodales y con asimetría positiva.

Definición 7.13 Se dice que una variable aleatoria X sigue una distribución gamma de parámetros α y σ , y se representa por $X \sim \mathcal{G}(\alpha, \sigma)$, si su función de densidad viene dada por:

$$f(x) = \begin{cases} \frac{x^{\alpha-1} e^{-x/\sigma}}{\sigma^\alpha \Gamma(\alpha)} & \text{si } x \geq 0 \\ 0 & \text{si } x < 0, \end{cases} \quad (7.37)$$

donde α, σ son números reales positivos.

El parámetro α es un parámetro de forma, mientras que σ es un parámetro de escala. La distribución gamma contiene algunos casos importantes de distribuciones:

- Si α es un entero positivo se obtiene la distribución de *Erlang*.
- Si $\alpha = 1$ se obtiene la distribución exponencial.
- Si $\sigma = 2$ y $\alpha = \nu/2$, entonces $\mathcal{G}(\nu/2, 2) = \chi_\nu^2$ y se obtiene una distribución chi-cuadrado con ν grados de libertad.
- Si $\alpha \rightarrow \infty$ la distribución gamma tiende a la normal.

La figura 7.11 representa diversas funciones de densidad y de distribución de variables aleatorias tipo gamma. Además, si $k > 0$ y $X \sim \mathcal{G}(\alpha, \sigma)$ entonces $kX \sim \mathcal{G}(\alpha, k\sigma)$.

7.10.1. Características

Si $X \sim \mathcal{G}(\alpha, \sigma)$, la función generatriz de momentos es,

$$M_X(t) = E(e^{tX}) = \int_0^\infty \frac{x^{\alpha-1} e^{-x(\sigma^{-1}-t)}}{\sigma^\alpha \Gamma(\alpha)} dx = \frac{1}{(1-\sigma t)^\alpha}, \quad t < 1/\sigma,$$

y la función característica,

$$\varphi_X(t) = E(e^{itX}) = M_X(it) = \frac{1}{(1-i\sigma t)^\alpha}. \quad (7.38)$$

Los momentos de la distribución gamma son,

$$E(X^r) = \frac{\Gamma(r+\alpha)\sigma^r}{\Gamma(\alpha)}, \quad r > -\alpha,$$

de donde se deducen la media y la varianza,

$$\begin{aligned} E(X) &= \alpha\sigma, \\ \text{Var}(X) &= \alpha\sigma^2. \end{aligned}$$

Los coeficientes de asimetría y curtosis son,

$$\gamma_1 = \frac{2}{\sqrt{\alpha}}, \quad \gamma_2 = \frac{6}{\alpha}.$$

Estos coeficientes ponen de manifiesto que la distribución gamma es asimétrica positiva y leptocúrtica para cualquier valor de α . Los cumulantes son,

$$\kappa_r = \alpha\sigma^r(r-1)!$$

La moda de la distribución gamma es $(\alpha - 1) \cdot \sigma$, siempre que $\alpha \geq 1$.




Figura 7.11: Funciones de densidad de las distribuciones gamma con parámetros $\alpha = 1/2, 3, 5, 7$ y 9 con $\sigma = 1$

7.10.2. Convolutiones

La suma de variables gamma independientes con igual parámetro de escala σ , es de nuevo una variable aleatoria de tipo gamma.

7.10. Distribución gamma

Teorema 7.16 Si $X_i \sim \mathcal{G}(\alpha_i, \sigma)$, $i = 1, 2, \dots, n$ son variables aleatorias gamma independientes, entonces la variables suma es de nuevo tipo gamma,

$$\sum_{i=1}^n X_i \sim \mathcal{G}\left(\sum_{i=1}^n \alpha_i, \sigma\right).$$

Demostración: Mediante funciones características, haciendo uso de (7.38):

$$\varphi_{\sum_{j=1}^n X_j}(t) = \prod_{j=1}^n \varphi_{X_j}(t) = \prod_{j=1}^n \frac{1}{(1 - i\sigma t)^{\alpha_j}} = \frac{1}{(1 - i\sigma t)^{\sum_{j=1}^n \alpha_j}},$$

de donde se sigue el resultado. ■

La distribución gamma surge de modo natural como la distribución del tiempo de espera hasta la ocurrencia del suceso n -ésimo en un proceso de Poisson.

Teorema 7.17 Supongamos que la variable:

$$N = \{\text{Número de clientes que acuden a un establecimiento en } (0, t)\},$$

sigue una distribución de Poisson de parámetro λt , es decir,

$$\Pr(N = n) = \frac{e^{-\lambda t} (\lambda t)^n}{n!}, \quad n = 0, 1, \dots$$

Entonces la variable T_n , tiempo de espera hasta la llegada del n -ésimo cliente sigue una distribución gamma $\mathcal{G}(n, \lambda^{-1})$.

7.10.3. Extensiones de la distribución gamma

La siguiente distribución es una generalización de la distribución gamma.

Definición 7.14 Una variable aleatoria X sigue una distribución gamma generalizada si su función de densidad viene dada por,

$$f(x) = \frac{a}{\sigma^{ap} \Gamma(p)} x^{ap-1} e^{-(x/\sigma)^a}, \quad x > 0, \quad (7.39)$$

y $f(x) = 0$ si $x < 0$. Representaremos $X \sim \mathcal{GG}(a, p, \sigma)$.

Si $a = 1$ en (7.39) obtenemos la distribución gamma clásica. La figura 7.12 muestra diversas funciones de densidad de variables aleatorias gamma generalizadas.




Figura 7.12: Funciones de densidad gamma generalizada con $\sigma = 1$, $p = 3$ y $a = 1; 1.5; 2; 2.5$ y 3

7.11. Distribuciones de extremos

Las distribuciones de extremos surgen como límite de las distribuciones del máximo y del mínimo (convenientemente normalizadas) de variables aleatorias independientes e igualmente distribuidas. En cada uno de los problemas, máximos o mínimos, sólo son posibles tres tipos de distribuciones límites: Gumbel, Weibull y Fréchet.

7.11.1. Distribución de Gumbel

La distribución de Gumbel aparece frecuentemente en problemas prácticos cuando se observan datos de valores máximos. Esta distribución aparece como límite del máximo de distribuciones limitadas o ilimitadas en la cola izquierda.

Definición 7.15 Una variable aleatoria sigue una distribución de Gumbel si su función de distribución viene dada por,

$$F(x) = \exp \left[-\exp \left(-\frac{x - \mu}{\sigma} \right) \right], \quad -\infty < x < \infty, \quad (7.40)$$

donde $\mu \in \mathbb{R}$ es un parámetro de localización y $\sigma > 0$ un parámetro de escala.

7.11. Distribuciones de extremos

La función de distribución de la variable reducida $Z = \frac{X - \mu}{\sigma}$ es:

$$F(z) = \exp[-\exp(-z)],$$

con función de densidad,

$$f(z) = \exp[-z - \exp(-z)], \quad -\infty < z < \infty.$$

La figura 7.13 muestra la función de densidad de la variable aleatoria Gumbel reducida. La función característica de una variable Gumbel reducida es,

$$\begin{aligned} \varphi_Z(t) = E(e^{itZ}) &= \int_{-\infty}^{\infty} e^{itz} e^{-z} e^{-e^{-z}} dz \\ &= \int_0^{\infty} u^{-it} e^{-u} du \\ &= \Gamma(1 - it), \end{aligned}$$

tras hacer el cambio de variables $u = e^{-z}$. Haciendo uso de las propiedades ya estudiadas de la función característica se deduce que,

$$E(Z^r) = (-1)^r \Gamma^{(r)}(1), \quad r = 1, 2, \dots$$

Ahora, teniendo en cuenta que $\Gamma(1) = 1$, $\psi(1) = -\gamma = -0.5722\dots$ (constante de Euler) y $\psi'(1) = \pi^2/6$ obtenemos:

$$E(Z) = -\Gamma'(1) = -\psi(1) = \gamma,$$

mientras que:

$$\begin{aligned} E(Z^2) &= \Gamma''(1) = \psi'(1)\Gamma(1) + \psi(1)\Gamma'(1) \\ &= \psi'(1) + \psi^2(1) = \pi^2/6 + \gamma^2, \end{aligned}$$

de donde,

$$\text{Var}(Z) = \frac{\pi^2}{6}.$$


La tabla 7.4 muestra las principales características de la distribución de Gumbel y de su versión para mínimos.

Ejemplo 7.6 Las variables aleatorias $X_1, \dots, X_n$ representan los valores de n pérdidas independientes de tipo exponencial con media uno. Obtener la distribución asintótica cuando $n \rightarrow \infty$ de la variable,

$$Y_n = \max\{X_1, \dots, X_n\} - \log n = X_{n:n} - \log n, \quad n = 1, 2, \dots$$

Tabla 7.4: Principales características de las distribuciones tipo Gumbel.

	Gumbel (valores máximos)	Gumbel (valores mínimos)
F. de dist.	$F(x) = \exp \left[-\exp \left(-\frac{x-\mu}{\sigma} \right) \right]$	$F(x) = 1 - \exp \left[-\exp \left(\frac{x-\mu}{\sigma} \right) \right]$
Media	$\mu + 0,57722\sigma$	$\mu - 0,57722\sigma$
Mediana	$\mu + 0,3665\sigma$	$\mu - 0,3665\sigma$
Moda	μ	μ
Varianza	$\frac{\pi^2 \sigma^2}{6}$	$\frac{\pi^2 \sigma^2}{6}$

Figura 7.13: Función de densidad Gumbel reducida con $\mu = 0$ y $\sigma = 1$

Solución: La función de distribución de Y_n es,

$$\begin{aligned}
 F_{Y_n}(y) &= \Pr(Y_n \leq y) = \Pr(\max\{X_1, \dots, X_n\} - \log n \leq y) \\
 &= [F_X(y + \log n)]^n \\
 &= \left[1 - e^{-(y + \log n)} \right]^n \\
 &= \left(1 - \frac{1}{n} e^{-y} \right)^n.
 \end{aligned}$$

7.11. Distribuciones de extremos

Calculando el límite cuando $n \rightarrow \infty$ obtenemos,

$$\lim_{n \rightarrow \infty} F_{Y_n}(y) = \exp(-e^{-y}),$$

que es la función de distribución de una variable aleatoria tipo Gumbel reducida. $\diamond$

7.11.2. Distribución de Weibull

La distribución de Weibull es el segundo tipo de distribuciones de extremos. Aparece frecuentemente en problemas prácticos cuando se observan datos de valores mínimos. Esta distribución se obtiene como límite del mínimo de muestras independientes procedentes de distribuciones limitadas en la cola izquierda.

Definición 7.16 Una variable aleatoria sigue una distribución de tipo Weibull si su función de distribución viene dada por,

$$F(x) = 1 - \exp \left[- \left(\frac{x - \mu}{\sigma} \right)^\alpha \right], \quad x \geq \mu, \quad (7.41)$$

donde $\mu \in \mathbb{R}$ es un parámetro de localización, $\sigma > 0$ un parámetro de escala y $\alpha > 0$ el parámetro de forma de la distribución

La distribución de Weibull contiene como caso particular dos distribuciones importantes:

- Si $\alpha = 1$ se obtiene la distribución exponencial con parámetros de localización y escala
- Si $\alpha = 2$, $\mu = 0$ y $\sigma = \tilde{\sigma}\sqrt{2}$ se obtiene la distribución de Rayleigh con función de distribución,

$$F_R(x) = 1 - \exp \left[-\frac{1}{2} \left(\frac{x}{\tilde{\sigma}} \right)^2 \right], \quad x > 0.$$

Para el cálculo de los momentos consideramos la variable aleatoria reducida $Z = (X - \mu)/\sigma$ con función de densidad,

$$f_Z(z) = \alpha z^{\alpha-1} e^{-z^\alpha}, \quad z > 0.$$


El momento del orden r es,

$$E(Z^r) = \int_0^\infty \alpha z^{\alpha+r-1} e^{-z^\alpha} dz = \Gamma \left(1 + \frac{r}{\alpha} \right), \quad 1 + r/\alpha > 0.$$

La figura 7.14 muestra la función de densidad de diversas variables aleatorias tipo Weibull. La tabla 7.5 muestra las principales características de la distribución de Weibull y de su versión para máximos.

Tabla 7.5: Principales características de las distribuciones tipo Weibull

	Weibull (valores máximos)	Weibull (valores mínimos)
F. de dist.	$F(x) = \exp \left[- \left(\frac{\mu - x}{\sigma} \right)^\alpha \right], x \leq \mu$	$F(x) = 1 - \exp \left[- \left(\frac{x - \mu}{\sigma} \right)^\alpha \right]$
Media	$\mu - \sigma \Gamma \left(1 + \frac{1}{\alpha} \right)$	$\mu + \sigma \Gamma \left(1 + \frac{1}{\alpha} \right)$
Mediana	$\mu - \sigma \cdot 0,693^{1/\alpha}$	$\mu + \sigma \cdot 0,693^{1/\alpha}$
Moda	$\mu - \sigma \left(\frac{\alpha-1}{\alpha} \right)^{1/\alpha}, \alpha > 1$ $\mu, \alpha \leq 1$	$\mu + \sigma \left(\frac{\alpha-1}{\alpha} \right)^{1/\alpha}, \alpha > 1$ $\mu, \alpha \leq 1$
Varianza	$\sigma^2 \left[\Gamma \left(1 + \frac{2}{\alpha} \right) - \Gamma^2 \left(1 + \frac{1}{\alpha} \right) \right]$	$\sigma^2 \left[\Gamma \left(1 + \frac{2}{\alpha} \right) - \Gamma^2 \left(1 + \frac{1}{\alpha} \right) \right]$

Figura 7.14: Función de densidad Weibull reducida con $\mu = 0$, $\sigma = 1$ y $\alpha = 0,5; 1; 1,5, 2, 3$ y 4

7.11.3. Distribución de Fréchet

La distribución de Fréchet es el tercer tipo de distribuciones de extremos. Surge en problemas cuando se observan datos de valores máximos. Esta distribución aparece como límite del máximo de muestras independientes procedentes de distribuciones

ilimitadas en la cola izquierda.

Definición 7.17 Una variable aleatoria sigue una distribución de tipo Fréchet si su función de distribución viene dada por,

$$F(x) = \exp \left[- \left(\frac{\sigma}{x - \mu} \right)^\alpha \right], x \geq \mu \quad (7.42)$$

donde $\mu \in \mathbb{R}$ es un parámetro de localización, $\sigma > 0$ de escala y $\alpha > 0$ el parámetro de forma de la distribución.

Los momentos de la variable reducida $Z = (X - \mu)/\sigma$ son:

$$E(Z^r) = \Gamma \left(1 - \frac{r}{\alpha} \right), r < \alpha.$$

La figura 7.15 muestra la función de densidad de diversas variables aleatorias tipo Fréchet. Finalmente, la tabla 7.6 muestra las principales características de la distribución de Fréchet y de su versión para mínimos.

Ejemplo 7.7 Las variables aleatorias $X_1, \dots, X_n$ representan n pérdidas independientes procedentes de una Pareto I con función de distribución,

$$F_X(x) = 1 - x^{-1/\alpha}, x > 1.$$

Obtener la distribución asintótica cuando $n \rightarrow \infty$ de la variable aleatoria,

$$Y_n = \frac{\max\{X_1, \dots, X_n\}}{n^\alpha}, n = 1, 2, \dots$$

Solución: La función de distribución de Y_n es,

$$\begin{aligned} F_{Y_n}(y) &= \Pr(Y_n \leq y) = \Pr(\max\{X_1, \dots, X_n\}/n^\alpha \leq y) \\ &= [F_X(y n^\alpha)]^n \\ &= \left(1 - \frac{1}{n y^{1/\alpha}} \right)^n. \end{aligned}$$

El límite cuando $n \rightarrow \infty$ es,

$$\lim_{n \rightarrow \infty} F_{Y_n}(y) = \exp(-y^{-1/\alpha}), y > 0,$$

que es la función de distribución de una variable aleatoria tipo Fréchet reducida. $\diamond$

Tabla 7.6: Principales características de las distribuciones tipo Fréchet. Para la existencia de la media $\alpha > 1$ y para la varianza $\alpha > 2$

	Fréchet (valores máximos)	Fréchet (valores mínimos)
F. de dist.	$F(x) = \exp \left[- \left(\frac{\sigma}{x - \mu} \right)^\alpha \right]$	$F(x) = 1 - \exp \left[- \left(\frac{\sigma}{\mu - x} \right)^\alpha \right], x \leq \mu$
Media	$\mu + \sigma \Gamma \left(1 - \frac{1}{\alpha} \right)$	$\mu - \sigma \Gamma \left(1 - \frac{1}{\alpha} \right)$
Mediana	$\mu + \sigma \cdot 0,693^{-1/\alpha}$	$\mu - \sigma \cdot 0,693^{-1/\alpha}$
Moda	$\left(1 + \frac{1}{\alpha} \right)^{-1/\alpha} \sigma \left(1 + \frac{1}{\alpha} \right)^{1/\alpha} + \mu$	$\left(1 + \frac{1}{\alpha} \right)^{-1/\alpha} \sigma \left(1 + \frac{1}{\alpha} \right)^{1/\alpha} - \mu$
Varianza	$\sigma^2 \left[\Gamma \left(1 - \frac{2}{\alpha} \right) - \Gamma^2 \left(1 - \frac{1}{\alpha} \right) \right]$	$\sigma^2 \left[\Gamma \left(1 - \frac{2}{\alpha} \right) - \Gamma^2 \left(1 - \frac{1}{\alpha} \right) \right]$




Figura 7.15: Función de densidad Fréchet reducida con $\mu = 0$, $\sigma = 1$ y $\alpha = 0,5; 1; 2,5$ y 10

7.12. Distribuciones de Benktander

Las distribuciones de Benktander (Benktander y Segerdahl, 1960; Benktander, 1970) responden a la idea de encontrar una distribución cuya vida residual media se

7.13. Distribuciones para la duración de una vida

encuentre entre las vidas residuales medias de las distribuciones exponencial (para la cual $e(x) = \lambda$ si $x > 0$) y de Pareto (cuya vida residual media es $e(x) = x/(\alpha-1)$, $x \geq \sigma$).

Definición 7.18 Se definen las distribuciones de Benktander como,

▪ Benktander tipo I ($a > 0$, $0 < b \leq 1$, $\sigma > 0$):

$$F_I(x) = \begin{cases} 1 - \left(\frac{x}{\sigma} \right)^{-(1-b)} \exp \left[-\frac{a}{b} (x^b - \sigma^b) \right] & \text{si } x \geq \sigma, \\ 0 & \text{si } x < \sigma. \end{cases}$$

▪ Benktander tipo II ($a > 0$, $b \geq 0$, $\sigma > 0$):

$$F_{II}(x) = \begin{cases} 1 - \frac{a + 2b \log x}{a + 2b \log \sigma} \left(\frac{x}{\sigma} \right)^{-a-1} \exp \left[-b (\log^2 x - \log^2 \sigma) \right] & \text{si } x \geq \sigma, \\ 0 & \text{si } x < \sigma. \end{cases}$$

Las distribuciones de Benktander tienen como vida residual media:

$$e_I(x) = \frac{x}{a + 2b \log x}, \quad a > 0; b \geq 0,$$

y

$$e_{II}(x) = \frac{x^{1-b}}{a}, \quad a > 0; 0 < b \leq 1,$$

respectivamente. Las medias de estas distribuciones son,

$$E(X) = \frac{(1 + a + 2b \log \sigma) \sigma}{a + 2b \log \sigma},$$

$$E(X) = \sigma \left(1 + \frac{1}{a \sigma^b} \right),$$

respectivamente. En la práctica la distribución Benktander tipo I es similar a la distribución log-normal, mientras que la distribución Benktander tipo II está cercana a la distribución de Weibull.

7.13. Distribuciones para la duración de una vida

La duración de la vida humana es un proceso complejo y se han propuesto diversas distribuciones para su modelización. Aquí presentamos dos de las más importantes.

7.13.1. Distribución de Gompertz

La siguiente distribución fue propuesta por Benjamin Gompertz para ajustar tablas de mortalidad.

Definición 7.19 Una variable aleatoria X sigue una distribución de Gompertz si su función de distribución viene dada por,

$$F(x; b, c) = 1 - \exp \left[-\frac{b}{c} (e^{cx} - 1) \right], \quad x > 0, \quad (7.43)$$

donde $b, c > 0$.

La función de densidad de la distribución de Gompertz es,

$$f(x; b, c) = be^{cx} \exp \left[-\frac{b}{c} (e^{cx} - 1) \right], \quad x > 0$$

de donde la función de azar es,

$$r(x) = \frac{f(x)}{1 - F(x)} = be^{cx}.$$

7.13.2. Distribución de Makeham

La distribución de Makeham es una generalización de la de Gompertz.

Definición 7.20 Una variable aleatoria X sigue una distribución de Makeham si la función de distribución viene dada por,

$$F(x; a, b, c) = 1 - \exp \left[-ax - \frac{b}{c} (e^{cx} - 1) \right], \quad x > 0, \quad (7.44)$$

donde $a \geq 0$ y $b, c > 0$.

Si hacemos $a = 0$ en (7.44) obtenemos (7.43). La función de densidad de la distribución de Makeham es,

$$f(x; a, b, c) = (a + be^{cx}) \exp \left[-ax - \frac{b}{c} (e^{cx} - 1) \right], \quad x > 0$$

mientras que la función de azar,

$$r(x) = \frac{f(x)}{1 - F(x)} = a + be^{cx}.$$

7.14. Distribuciones relacionadas con la normal

Las distribuciones chi-cuadrado de Pearson, t de Student y $\mathcal{F}$ de Snedecor se obtienen a partir de la distribución normal, y se utilizarán en los temas de inferencia estadística.

7.14.1. Distribución chi-cuadrado de Pearson

Definición 7.21 (Distribución chi-cuadrado de Pearson) Supongamos n variables $\mathcal{N}(0, 1)$ independientes. A la distribución de la variable suma de los cuadrados:

$$X_1^2 + \dots + X_n^2 \sim \chi_n^2,$$

se le denomina chi-cuadrado con n grados de libertad.

Algunas propiedades y aplicaciones son:

- Recurriendo a las funciones de densidad, se puede probar que:

$$\chi_n^2 \sim \mathcal{G}(n/2, 2).$$

- Si $X \sim \chi_n^2$ la media y la varianza vienen dadas por:

$$E(X) = n, \quad \text{Var}(X) = 2n,$$

mientras que coeficientes de asimetría y curtosis son:

$$\gamma_1 = \frac{2\sqrt{2}}{\sqrt{n}}, \quad \gamma_2 = \frac{12}{n}.$$

La figura 7.16 representa las funciones de densidad de variables aleatorias tipo chi-cuadrado.

- La distribución chi-cuadrado es reproductiva respecto del parámetro n . Si tenemos r variables independientes:

$$X_1 \sim \chi_{n_1}^2, \dots, X_r \sim \chi_{n_r}^2$$

entonces:

$$X_1 + \dots + X_r \sim \chi_{n_1 + \dots + n_r}^2.$$

- Para valores de $n > 30$ se usa la siguiente aproximación a la normal:

$$\sqrt{2\chi_n^2} \approx \mathcal{N}(\sqrt{2n-1}, 1).$$

Algunas aplicaciones de esta distribución son: inferencia de la varianza y desviación típica de una población normal, contrastes de bondad de ajuste, estudio de la independencia y homogeneidad en tablas de contingencia, análisis de la varianza, etc.




Figura 7.16: Funciones de densidad de la distribución chi-cuadrado con $n = 1, 2, 5$ y 10 grados de libertad

7.14.2. Distribución t de Student

Definición 7.22 (Distribución t de Student) Sean $X \sim \mathcal{N}(0, 1)$ y $Y \sim \chi_n^2$ independientes. La variable aleatoria:

$$\frac{X}{\sqrt{Y/n}},$$

se denomina *distribución t de Student con n grados de libertad*.

Si X sigue una distribución t de Student con n grados de libertad escribiremos $X \sim t_n$. La función de densidad de una variable t de Student es:

$$f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad -\infty < t < \infty. \quad (7.45)$$

A continuación destacamos algunas propiedades y aplicaciones:

- La distribución t de Student es simétrica respecto del origen (figura 7.17):

$$\Pr(t_n > x) = \Pr(t_n \leq -x), \quad \forall x.$$

7.14. Distribuciones relacionadas con la normal

- Si $X \sim t_n$, la media y la varianza son:

$$E(X) = 0, \text{ si } n > 1, \quad \text{Var}(X) = \frac{n}{n-2}, \text{ si } n > 2,$$

y los coeficientes de asimetría y curtosis son:

$$\gamma_1 = 0 \quad (n > 3), \quad \gamma_2 = \frac{6}{n-4} \quad (n > 4).$$

- Para valores de $n > 30$ se verifica la siguiente aproximación:

$$t_n \approx \mathcal{N}(0, 1).$$

Sus aplicaciones más importantes son en inferencia sobre la media de una población normal con varianza desconocida, en muestras de tamaño pequeño ($n \leq 30$).




Figura 7.17: Funciones de densidad de la distribución t de Student con $n = 1, 2, 5$ y 10 grados de libertad

7.14.3. Distribución $\mathcal{F}$ de Snedecor

Definición 7.23 (Distribución $\mathcal{F}$ de Snedecor) Consideremos dos variables aleatorias chi-cuadrado independientes con n y m grados de libertad, $X \sim \chi_n^2$, $Y \sim \chi_m^2$. La distribución de la variable:

$$\frac{X/n}{Y/m} \sim \mathcal{F}_{n,m},$$

se le denomina $\mathcal{F}$ de Snedecor con n y m grados de libertad.

- Si $X \sim \mathcal{F}_{n,m}$, la media y la varianza son:

$$E(X) = \frac{m}{m-2}, \text{ si } m > 2, \quad \text{Var}(X) = \frac{2m^2(n+m-2)}{n(m-4)(m-2)^2}, \text{ si } m > 4.$$

- Por medio de la definición de la distribución $\mathcal{F}_{n,m}$ se verifica la siguiente propiedad, de especial utilidad en el cálculo de probabilidades:

$$\Pr(\mathcal{F}_{n,m} \leq x) = 1 - \Pr(\mathcal{F}_{m,n} \leq \frac{1}{x}).$$

En términos de percentiles se tiene la relación:

$$\mathcal{F}_{n,m;\alpha} = \frac{1}{\mathcal{F}_{m,n;1-\alpha}}.$$

La distribución $\mathcal{F}$ de Snedecor, tiene diversas aplicaciones, en especial en la inferencia del cociente de varianzas en poblaciones normales y en el análisis de la varianza.

7.15. Problemas propuestos

1. Sean $X_n \sim \mathcal{P}(n)$ variables aleatorias tipo Poisson con parámetro $\lambda_n = n$, $n = 1, 2, \dots$. Se considera la sucesión de variables aleatorias tipificadas,

$$Z_n = \frac{X_n - E(X_n)}{\sqrt{\text{Var}(X_n)}} = \frac{X_n - n}{\sqrt{n}}.$$

Si $\varphi_{Z_n}(t)$ representa la función característica de Z_n , probar que para t fijo,

$$\varphi_{Z_n}(t) \rightarrow e^{-t^2/2}$$

cuando $n \rightarrow \infty$, y por tanto se verifica la convergencia a la distribución normal $\mathcal{N}(0, 1)$.

2. Obtener los momentos de la distribución beta con cuatro parámetros definida en (7.9).
3. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, se verifica que:

$$\log \varphi_X(t) = i\mu t - \frac{\sigma^2 t^2}{2}.$$

A partir de este resultado, probar que los cumulantes de una distribución normal son $\kappa_1 = \mu$, $\kappa_2 = \sigma^2$ y $\kappa_r = 0$ si $r = 3, 4, \dots$

7.15. Problemas propuestos

4. Sea $X \sim \mathcal{GG}(a, p, \sigma)$ una distribución gamma generalizada con función de densidad (7.39).

- a) Probar que:

$$E(X^r) = \frac{\Gamma(p+r/a)\sigma^r}{\Gamma(p)}.$$

- b) Probar que la moda viene dada por:

$$\text{Moda}(X) = \sigma(p-1/a)^{1/a},$$

si $ap > 1$. En el caso que $ap < 1$, $\lim_{x \rightarrow 0} f(x) = \infty$.

5. Probar que la media armónica $x_h = [E(X^{-1})]^{-1}$ de la distribución de Pareto tipo I viene dada por:

$$x_h = \sigma(1 + \alpha^{-1}).$$

6. La distribución de las pérdidas de un siniestro sigue una distribución de Gumbel estándar con función de distribución $F(x) = \exp(-e^{-x})$ si $-\infty < x < \infty$. Se dispone de una muestra de n pérdidas $X_1, \dots, X_n$ y se considera el máximo de todas ellas $X_{n:n} = \max\{X_1, \dots, X_n\}$.

- a) Obtener la función de distribución del máximo $X_{n:n}$.
- b) Probar que el máximo tiene la misma función de distribución que la variable $X + \log n$.

7. Una variable aleatoria X sigue una distribución de Burr tipo XII si su función de distribución viene dada por,

$$F(x) = 1 - \frac{1}{(1 + x^c)^k}, \quad x > 0,$$

y $F(x) = 0$ si $x < 0$, donde c y k son constantes positivas. Probar las siguientes propiedades:

- a) Si $Z \sim \mathcal{PII}(k, 1)$, entonces $X = Z^{1/c}$ se distribuye según una Burr tipo XII.
- b) Si $r < ck$,

$$E(X^r) = kB(r/c + 1, k - r/c),$$

donde $B(\cdot, \cdot)$ representa la función beta.

- c) La distribución Burr tipo XII es unimodal en $x_0 = [(c-1)/(ck+1)]^{1/c}$ si $c > 1$ y con forma de L si $c \leq 1$.
- d) La distribución de Burr tipo XII se puede obtener como una mezcla de una Weibull con función de distribución $F(x; \lambda) = 1 - e^{-\lambda x^c}$, $x > 0$, suponiendo que $\lambda \sim \mathcal{G}(k, 1)$.

Capítulo 8

Inferencia Estadística

8.1. Introducción

En este tema estudiaremos cómo los modelos de distribuciones teóricas vistas en los capítulos anteriores se utilizan para realizar inferencias de naturaleza estadística sobre el coste de los siniestros y la frecuencia de la siniestralidad, entre otras cantidades de interés en el ámbito actuarial. Realizaremos inferencia estadística paramétrica desde una perspectiva clásica. Esto significa que la población viene descrita a través de una función de distribución de probabilidad conocida, dependiente de un conjunto de parámetros desconocidos que se desean estimar. A menudo estos parámetros recogen características de interés de la población como pueden ser la media o la varianza. Por otro lado, toda la información disponible para la estimación de estos parámetros es la contenida en la muestra, de modo que no existe información a priori para la estimación del modelo, como puede ser la obtenida por medio de la experiencia. Comenzaremos con el problema de la estimación puntual, para continuar con el estudio de las propiedades deseables que debe cumplir un estimador, y seguir con los diferentes métodos para la construcción de estimadores. Terminaremos con algunas ideas sobre contraste de hipótesis.

8.2. Estimación puntual

La población viene especificada a través de una familia paramétrica de funciones de densidad de modo que,

$$\{f(x; \theta), \theta \in \Theta\}.$$

Los elementos del problema son:

- La función de densidad de la población $f(x; \theta)$, que es conocida salvo un vector de parámetros desconocidos θ que se desean estimar.

- El vector de parámetros θ . Son cantidades desconocidas y se estiman a partir de los datos.
- El espacio paramétrico: Θ . Son los posibles valores que pueden tomar los parámetros.

Para el cálculo o estimación de θ se dispone de una muestra aleatoria simple de observaciones $X_1, X_2, \dots, X_n$ procedente de la población de referencia.

Definición 8.1 Supongamos una población especificada a través de una familia paramétrica de funciones de densidad $\{f(x; \theta), \theta \in \Theta\}$ y una muestra aleatoria simple de observaciones $X_1, X_2, \dots, X_n$ procedente de la población. El problema de la estimación puntual consiste en elegir un valor del parámetro a partir de los datos de la muestra.

El instrumento básico en el proceso de estimación lo constituye los estimadores.

Definición 8.2 Supongamos una población $\{f(x; \theta), \theta \in \Theta\}$ y una muestra aleatoria simple $X_1, \dots, X_n$ procedente de esa población. Se denomina estimador del parámetro θ a cualquier función de las observaciones con llegada en el espacio paramétrico, es decir,

$$\hat{\theta} = \hat{\theta}(X_1, \dots, X_n) \in \Theta.$$

Veamos algunos ejemplos.

Ejemplo 8.1 Se desea estimar el coste de un siniestro. Una posible elección para la distribución de los costes es una distribución de tipo log-normal $\mathcal{LN}(\mu, \sigma^2)$. Obtener el espacio paramétrico.

Solución: El espacio paramétrico es $(\mu, \sigma) \in \mathbb{R} \times \mathbb{R}^+$.

Ejemplo 8.2 Una cantidad de interés es el número de siniestros que ocurren en una determinada cartera, que se supone sigue una distribución de Poisson $\mathcal{P}(\lambda)$. Obtener el espacio paramétrico.

Solución: El espacio paramétrico es $\lambda \in (0, \infty)$.

Ejemplo 8.3 Se quiere estimar la proporción de accidentes con heridos graves. La población viene definida por medio de una variable de Bernoulli de parámetro p , donde éxito es que existan heridos graves (lo que ocurre con probabilidad p) y fracaso que no existan (lo que ocurre con probabilidad $1 - p$). Obtener el espacio paramétrico.

Solución: El espacio paramétrico es $p \in (0, 1)$.

8.3. Estimadores insesgados

Cuando construimos un estimador una primera propiedad que se exige es que los errores de estimación, por término medio, se cancelen unos con otros. Esto nos lleva a la definición de estimador insesgado y sesgo de un estimador.

Definición 8.3 (Estimador insesgado y sesgo de un estimador) Un estimador $\hat{\theta}$ del parámetro θ se dice que es insesgado, si por término medio su valor coincide con el del parámetro, es decir,

$$E(\hat{\theta}) = \theta, \quad \forall \theta \in \Theta.$$

En otro caso se dice que $\hat{\theta}$ es un estimador sesgado. Se define el sesgo de un estimador como,

$$\text{sesgo}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

El sesgo de un estimador será positivo o negativo dependiendo que el estimador sobreestime o subestime el parámetro. Un sesgo de estimación diferente de cero supone un error sistemático o permanente en la estimación.

Definición 8.4 Se dice que un estimador $\hat{\theta}$ es asintóticamente insesgado si al aumentar el tamaño de muestra se convierte en insesgado, es decir si,

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta.$$

Ejemplo 8.4 Supongamos una muestra aleatoria simple $X_1, \dots, X_n$ procedente de una población con $E(X) = \mu$, el parámetro de interés. Probar que la media muestral es siempre un estimador insesgado del parámetro media poblacional μ , es decir,

$$E(\bar{X}) = E(\bar{X}) = \mu.$$

Solución: Veamos la prueba de este resultado,

$$\begin{aligned} E(\bar{X}) &= E\left[\frac{1}{n}(X_1 + \dots + X_n)\right] \\ &= \frac{1}{n}[E(X_1) + \dots + E(X_n)] \\ &= \frac{1}{n}(\mu + \dots + \mu) = \frac{1}{n} \cdot n\mu \\ &= \mu. \end{aligned}$$

Ejemplo 8.5 Supongamos ahora que estamos interesados en la estimación del parámetro varianza de la población $\text{Var}(X) = \sigma^2$, a partir de una muestra de observaciones. Un estimador natural es la varianza muestral, $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$. Probar que:

$$E(S^2) = \frac{n-1}{n} \sigma^2$$

y por tanto S^2 no es insesgado de σ^2 .

Solución: Partimos de la expresión:

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

Si dividimos por n , la descomposición anterior indica que la varianza de los datos respecto de su verdadera media es igual a la suma de la varianza muestral más la diferencia entre la media muestral y la media verdadera elevada al cuadrado. Tomando esperanzas tenemos:

$$E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] = E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] + nE[(\bar{X} - \mu)^2];$$

es decir,

$$n\sigma^2 = E(nS^2) + nE[(\bar{X} - \mu)^2],$$

y como $E[(\bar{X} - \mu)^2] = \text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ se tiene que:

$$E(S^2) = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \cdot \sigma^2.$$

Observemos que el sesgo del estimador varianza muestral es negativo. Sin embargo es fácil obtener un estimador insesgado haciendo,

$$E \left(\frac{n}{n-1} S^2 \right) = \sigma^2.$$

A la cantidad $S_{n-1}^2 = \frac{n}{n-1} S^2$ se la denomina varianza corregida o cuasivarianza muestral. $\diamond$

8.4. Comparación de estimadores

En la práctica podemos tener varios estimadores insesgados, y debemos disponer de algún criterio que permita elegir uno de ellos. Parece razonable elegir aquel estimador que presente menor dispersión en torno al parámetro, es decir, aquel estimador con menor varianza. Comenzamos definiendo el error estándar de un estimador

8.4. Comparación de estimadores

Definición 8.5 La desviación típica de un estimador $\hat{\theta}$ se denomina error estándar del estimador:

$$\sigma_{\hat{\theta}} = \sqrt{\text{Var}(\hat{\theta})}.$$

Ejemplo 8.6 En una población con media μ y varianza σ^2 obtener el error estándar del estimador media muestral $\hat{\mu} = \bar{X}$.

Solución: Se verifica que,

$$\begin{aligned} \text{Var}(\bar{X}) &= \text{Var} \left[\frac{1}{n} (X_1 + \dots + X_n) \right] = \frac{1}{n^2} \text{Var}(X_1 + \dots + X_n) \\ &= \frac{1}{n^2} [\text{Var}(X_1) + \dots + \text{Var}(X_n)] \\ &= \frac{1}{n^2} (\sigma^2 + \dots + \sigma^2) \\ &= \frac{\sigma^2}{n}. \end{aligned}$$

El error estándar de la media es por tanto,

$$\sigma_{\bar{\mu}} = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}.$$

La eficiencia relativa permite comparar y elegir dos estimadores insesgados. $\diamond$

Definición 8.6 Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ estimadores insesgados respecto del parámetro θ . Entonces:

1. Se dice que $\hat{\theta}_1$ es más eficiente que $\hat{\theta}_2$ si $\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2)$.
2. Se define la eficiencia relativa de un estimador con respecto a otro como el cociente de las varianzas:

$$\text{Eficiencia relativa} = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}.$$

Ejemplo 8.7 Consideremos una muestra de tamaño 4 de una población normal $\mathcal{N}(\mu, \sigma^2)$, donde se desea estimar la media. Para ello se consideran los estimadores:

$$\begin{aligned} \hat{\mu}_1 &= \frac{1}{4} (X_1 + X_2 + X_3 + X_4), \\ \hat{\mu}_2 &= \frac{1}{2} X_1 + \frac{1}{4} X_2 + \frac{1}{8} (X_3 + X_4). \end{aligned}$$

1. Probar que se trata de estimadores insesgados. Hallar la varianza.
2. Hallar la eficiencia relativa.
3. ¿Cuál de los dos estimadores es preferible para la estimación de μ ?

Solución:

1. El estimador $\hat{\mu}_1$ es la media muestral y sabemos que la media de la media muestral es la media poblacional y que la varianza de la media muestral es la varianza poblacional dividida por el número de datos, por tanto:

$$E(\hat{\mu}_1) = \mu, \quad \text{Var}(\hat{\mu}_1) = \frac{\sigma^2}{4} = \frac{8}{32}\sigma^2.$$

Para el segundo de los estimadores:

$$E(\hat{\mu}_2) = \frac{1}{2}E(X_1) + \frac{1}{4}E(X_2) + \frac{1}{8}(E(X_3) + E(X_4)) = \frac{1}{2}\mu + \frac{1}{4}\mu + \frac{1}{8}(\mu + \mu) = \mu.$$

La varianza es:

$$\begin{aligned} \text{Var}(\hat{\mu}_2) &= \frac{1}{4}\text{Var}(X_1) + \frac{1}{16}\text{Var}(X_2) + \frac{1}{64}(\text{Var}(X_3) + \text{Var}(X_4)) \\ &= \frac{1}{4}\sigma^2 + \frac{1}{16}\sigma^2 + \frac{1}{64}(\sigma^2 + \sigma^2) = \frac{11}{32}\sigma^2. \end{aligned}$$

2. Eficiencia relativa:

$$\frac{\text{Var}(\hat{\mu}_1)}{\text{Var}(\hat{\mu}_2)} = \frac{8\sigma^2}{32} \cdot \frac{32}{11 \cdot \sigma^2} = \frac{8}{11}.$$

3. Puesto que $\text{Var}(\hat{\mu}_1) < \text{Var}(\hat{\mu}_2)$, el estimador $\hat{\mu}_1$ es preferible a $\hat{\mu}_2$.

El error cuadrático medio (ECM) permite comparar dos estimadores no necesariamente insesgados. El ECM mide la desviación cuadrática media entre el estimador y el parámetro.

Definición 8.7 Se define el error cuadrático medio de un estimador $\hat{\theta}$ respecto de un parámetro θ como,

$$ECM(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

En el caso que se trabaje con estimadores insesgados, el ECM coincide con la varianza del estimador.

Teorema 8.1 Se verifica la siguiente descomposición,

$$ECM(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{sesgo}(\hat{\theta})]^2.$$

Demostración: Sumando y restando la esperanza del estimador y desarrollando el cuadrado se tiene que,

$$\begin{aligned} ECM(\hat{\theta}) &= E[(\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)]^2 \\ &= E(\hat{\theta} - E\hat{\theta})^2 + (E\hat{\theta} - \theta)^2 + 2(E\hat{\theta} - \theta)E(\hat{\theta} - E\hat{\theta}). \end{aligned}$$

El primer término es la varianza, el segundo el sesgo al cuadrado y el tercero vale cero.

Ejemplo 8.8 A partir de una muestra de tamaño 3 procedente de una población de Bernoulli de parámetro p , se consideran los estimadores:

$$\begin{aligned} \hat{p}_1 &= \frac{X_1 + X_2 + X_3}{3}, \\ \hat{p}_2 &= \frac{X_1 + X_2 + 1}{3}, \\ \hat{p}_3 &= \frac{X_1 + X_2 + 2X_3}{4}. \end{aligned}$$

1. Hallar el sesgo, la varianza y el error cuadrático medio de los tres estimadores.
2. ¿Cuál de los tres estimadores es preferible?
3. Si para la selección de estimadores exigimos que sea insesgados, ¿cuál es ahora preferible?

Solución:

1. El primer estimador es la media aritmética y por tanto:

$$\begin{aligned} E(\hat{p}_1) &= E(\bar{X}) = \mu = p, \\ \text{Var}(\hat{p}_1) &= \text{Var}(\bar{X}) = \frac{\sigma^2}{3} = \frac{p(1-p)}{3}, \end{aligned}$$

en consecuencia: $\text{sesgo}(\hat{p}_1) = 0$ y $ECM(\hat{p}_1) = \frac{pq}{3}$. Para el segundo de los estimadores:

$$\begin{aligned} E(\hat{p}_2) &= E\left(\frac{X_1 + X_2 + 1}{3}\right) = \frac{E(X_1) + E(X_2) + 1}{3} = \frac{2p + 1}{3}, \\ \text{Var}(\hat{p}_2) &= \frac{\text{Var}(X_1) + \text{Var}(X_2)}{9} = \frac{2p(1-p)}{9}, \end{aligned}$$

por tanto:

$$\begin{aligned} \text{sesgo}(\hat{p}_2) &= \frac{2p + 1}{3} - p = \frac{1-p}{3}, \\ ECM(\hat{p}_2) &= \frac{2p(1-p)}{9} + \frac{(1-p)^2}{9} = \frac{1-p^2}{9}. \end{aligned}$$

Para el tercer estimador:

$$E(\hat{p}_3) = \frac{p + p + 2p}{4} = p,$$

$$\text{Var}(\hat{p}_3) = \frac{\text{Var}(X_1) + \text{Var}(X_2) + 4\text{Var}(X_3)}{16} = \frac{3p(1-p)}{8},$$

de donde sesgo($\hat{p}_3$) = 0 y ECM($\hat{p}_3$) = $\frac{3p(1-p)}{8}$.

2. Si $0 \leq p \leq \frac{1}{2}$, $\hat{p}_1$ es preferible y si $\frac{1}{2} \leq p \leq 1$, $\hat{p}_2$ es preferible. Por tanto, ninguno de los tres es preferible en el rango $[0, 1]$.
3. Si exigimos la condición de insesgadez, entonces $\hat{p}_1$ es preferible uniformemente a $\hat{p}_3$, es decir, para todo valor $p \in [0, 1]$.

◇

8.5. Estimadores consistentes

La propiedad de consistencia es una propiedad de grandes muestras. Un estimador es consistente si a medida que aumenta el tamaño de muestra el valor del estimador se va acercando al verdadero valor del parámetro desconocido.

Definición 8.8 (Estimador Consistente) Un estimador $\hat{\theta}_n$ se dice que es consistente respecto del parámetro θ si converge en probabilidad hacia dicho parámetro,

$$\lim_{n \rightarrow \infty} \Pr(|\hat{\theta}_n - \theta| \leq \varepsilon) = 1, \quad \forall \varepsilon > 0. \quad (8.1)$$

La definición (8.1) equivale a la convergencia en probabilidad. La propiedad de consistencia de un estimador se representa por $\hat{\theta}_n \xrightarrow{P} \theta$ o bien por $\text{plim} \hat{\theta}_n = \theta$. El siguiente teorema permite probar fácilmente la propiedad de consistencia.

Teorema 8.2 Sea $\hat{\theta}_n$ un estimador de θ verificando las siguientes condiciones,

- (1) Es insesgado o asintóticamente insesgado, es decir:

$$E(\hat{\theta}_n) = \theta, \quad \text{o bien} \quad \lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta.$$

- (2) La varianza tiende a cero al aumentar el tamaño de muestra:

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0.$$

Entonces $\hat{\theta}_n$ es un estimador consistente del parámetro θ .

8.5. Estimadores consistentes

Demostración: Aplicando la desigualdad de Markov (teorema 3.6) se tiene que,

$$\Pr(|\hat{\theta}_n - \theta| > \varepsilon) \leq \frac{E(\hat{\theta}_n - \theta)^2}{\varepsilon^2} = \frac{\text{Var}(\hat{\theta}_n) + [\text{sesgo}(\hat{\theta}_n)]^2}{\varepsilon^2}.$$

Tomando límites cuando n tiende a ∞ se sigue el resultado. ▀

Veamos dos ejemplos relevantes.

Ejemplo 8.9 Supongamos una población $f(x; \theta)$ donde la media poblacional es μ y la varianza σ^2 finita. Probar que el estimador media muestral $\hat{\mu} = \bar{X}$ es un estimador consistente de la media poblacional.

Solución: Al tratarse de un estimador insesgado con varianza $\frac{\sigma^2}{n}$, que tiende a cero cuando el tamaño de muestra tiende a infinito, se deduce la consistencia haciendo uso del teorema 8.2.

◇

Ejemplo 8.10 La varianza y cuasi-varianza muestral son estimadores consistentes de la varianza poblacional.

El siguiente teorema establece la invarianza de un estimador consistente frente a transformaciones continuas.

Teorema 8.3 (Teorema de Slutsky) Si $\hat{\theta}_n \xrightarrow{P} \theta$, y $g(\cdot)$ es una función continua, entonces,

$$g(\hat{\theta}_n) \xrightarrow{P} g(\theta).$$

Ejemplo 8.11 Para modelizar los costes de un tipo de siniestro un actuario utiliza una distribución de tipo uniforme $U(0, \theta)$ con función de densidad,

$$f(x; \theta) = \frac{1}{\theta}, \quad 0 < x < \theta,$$

y $f(x; \theta) = 0$, donde θ es un parámetro positivo. Se dispone de una muestra $X_1, \dots, X_n$ del coste de n siniestros.

1. Se considera el estimador $\hat{\theta}_1 = 2\bar{X}$. Probar que es un estimador insesgado y calcular su varianza. Probar que es un estimador consistente.
2. Como estimador alternativo se considera el valor máximo de la muestra,

$$X_{n:n} = \max\{X_1, \dots, X_n\}.$$

Probar que se trata de un estimador sesgado pero consistente.

3. Obtener un estimador insesgado del tipo $\hat{\theta}_2 = cX_{n:n}$, donde c es una constante a determinar. Calcular la varianza de este nuevo estimador y obtener la eficiencia relativa. ¿Cuál de los dos estimadores es preferible?

Solución:

1. Puesto que $X \sim \mathcal{U}(0, \theta)$ se verifica que la media y la varianza son $\mu_X = \theta/2$ y $\sigma_X^2 = \theta^2/12$, respectivamente (fórmulas (7.5) y (7.6)). Entonces,

$$E(\hat{\theta}_1) = 2E(\bar{X}) = 2\mu_X = 2 \cdot \frac{\theta}{2} = \theta,$$

de donde se trata de un estimador insesgado. La varianza es,

$$\text{Var}(\hat{\theta}_1) = 4\text{Var}(\bar{X}) = 4 \cdot \frac{\sigma_X^2}{n} = \frac{\theta^2}{3n}.$$

Puesto que $\hat{\theta}_1$ es un estimador insesgado y $\text{Var}(\hat{\theta}_1) \rightarrow 0$ cuando $n \rightarrow \infty$, por el teorema 8.2 se trata de un estimador consistente.

2. Para obtener la media y varianza de $X_{n:n}$ necesitamos su función de densidad, que viene dada por (fórmula (5.26)):

$$f_{X_{n:n}}(x) = n[F(x)]^{n-1}f(x) = n\left(\frac{x}{\theta}\right)^{n-1} \frac{1}{\theta} = \frac{nx^{n-1}}{\theta^n}, \quad 0 < x < \theta.$$

La media de $X_{n:n}$ es entonces:

$$E(X_{n:n}) = \int_0^\theta \frac{nx^n}{\theta^n} dx = \frac{n\theta}{n+1} \neq \theta,$$

y se trata por tanto de un estimador sesgado. El momento de orden dos respecto del origen es,

$$E(X_{n:n}^2) = \int_0^\theta \frac{nx^{n+1}}{\theta^n} dx = \frac{n\theta^2}{n+2}$$

y la varianza es por tanto,

$$\text{Var}(X_{n:n}) = E(X_{n:n}^2) - [E(X_{n:n})]^2 = \frac{n\theta^2}{(n+2)(n+1)^2}.$$

Al verificarse que $E(X_{n:n}) \rightarrow \theta$ cuando $n \rightarrow \infty$, el máximo es un estimador asintóticamente insesgado y puesto que $\text{Var}(X_{n:n}) \rightarrow 0$ cuando $n \rightarrow \infty$, se trata de un estimador consistente por el teorema 8.2.

3. Es inmediato probar que,

$$\hat{\theta}_2 = \frac{n+1}{n} X_{n:n},$$

es un estimador insesgado. La varianza es,

$$\text{Var}(\hat{\theta}_2) = \frac{(n+1)^2}{n^2} \text{Var}(X_{n:n}) = \frac{\theta^2}{n(n+2)}.$$

El estimador $\hat{\theta}_2$ es nuevamente consistente. La eficiencia relativa es,

$$\frac{\text{Var}(\hat{\theta}_1)}{\text{Var}(\hat{\theta}_2)} = \frac{\theta^2}{3n} \cdot \frac{n(n+2)}{\theta^2} = \frac{n+2}{3} > 1,$$

si $n > 2$, de donde $\hat{\theta}_2$ es preferible al ser un estimador insesgado y con menor varianza que $\hat{\theta}_1$.

◇

8.6. Estimadores suficientes

Cuando se elige un estimador para estimar un parámetro, toda la información de la muestra se resume en un único valor. Por tanto, puede ocurrir que estemos perdiendo parte de la información contenida en la muestra. La idea de un estimador suficiente para la estimación de un parámetro θ , es un estimador que en cierto sentido capture toda la información que sobre θ contiene la muestra. En lo que sigue, utilizaremos la notación $\underline{X}$ para hacer referencia a toda la muestra, es decir, $\underline{X} = (X_1, \dots, X_n)$. Análogamente, $\underline{x} = (x_1, \dots, x_n)$ representa el vector de toda la observación muestral. Utilizaremos también la notación $\mathbf{X}$ y $\mathbf{x}$ para hacer referencia a $\underline{X}$ y $\underline{x}$.

Definición 8.9 (Estimador suficiente) Un estimador $\hat{\theta} = \hat{\theta}(\underline{X})$ se dice que es suficiente para la estimación del parámetro θ , si la distribución condicional de la muestra $\underline{X}$ dado $\hat{\theta}(\underline{X})$ no depende de θ .

Teorema 8.4 (Criterio de factorización de Fisher) Sea $f(\underline{x}; \theta)$ la función de densidad de la muestra. El estimador $\hat{\theta} = \hat{\theta}(\underline{X})$ es suficiente para la estimación de θ si y sólo si existen funciones g y h tales que,

$$f(\underline{x}; \theta) = g(\underline{x})h(\hat{\theta}(\underline{x}), \theta),$$

con g una función no negativa que sólo depende de $\underline{x}$ y h una función no negativa que depende de $\hat{\theta}$ y θ .

El teorema expresa que un estimador es suficiente para estimar θ si la función de densidad conjunta se puede escribir como producto de dos funciones, una función que depende sólo de la muestra, y otra que depende del parámetro únicamente a través del estimador suficiente.

Ejemplo 3.12 (Distribución exponencial) Elegimos una muestra de tamaño n procedente de una población exponencial con función de densidad: $f(x; \theta) = (1/\theta)e^{-x/\theta}$. Probar que el estimador $\hat{\theta} = \sum_{i=1}^n x_i$ es suficiente.

Solución: Para ello calculamos la función de densidad conjunta de la muestra:

$$\begin{aligned} f(x_1, \dots, x_n; \theta) &= f(x_1; \theta) \cdots f(x_n; \theta) \\ &= \frac{1}{\theta} e^{-x_1/\theta} \cdots \frac{1}{\theta} e^{-x_n/\theta} \\ &= \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum_{i=1}^n x_i} \\ &= g(\underline{x}) h\left(\sum_{i=1}^n x_i, \theta\right). \end{aligned}$$

con $g(\underline{x}) = 1$ y $h(\hat{\theta}, \theta) = \exp(-\hat{\theta}/\theta)\theta^{-n}$. $\diamond$

Ejemplo 3.13 (Distribución de Poisson) Supongamos ahora una muestra procedente de una población tipo Poisson. Obtener un estadístico suficiente para λ .

Solución: Veamos que:

$$\hat{\lambda} = \sum_{i=1}^n x_i,$$

es un estimador suficiente. La función de densidad de la muestra es:

$$\begin{aligned} \Pr(X_1 = x_1, \dots, X_n = x_n) &= \Pr(X_1 = x_1) \cdots \Pr(X_n = x_n) \\ &= \frac{e^{-\lambda} \lambda^{x_1}}{x_1!} \cdots \frac{e^{-\lambda} \lambda^{x_n}}{x_n!} \\ &= \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \\ &= g(\underline{x}) h\left(\sum_{i=1}^n x_i, \lambda\right). \end{aligned}$$

Luego $\hat{\lambda} = \sum_{i=1}^n x_i$ es suficiente. $\diamond$

De los dos ejemplos anteriores podemos deducir que el estadístico suficiente no es único. En efecto, para el caso exponencial si consideramos $\hat{\theta}_2 = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, resulta que $\bar{x}$ es también suficiente eligiendo $h(\hat{\theta}, \theta) = h(n\hat{\theta}_2, \theta)$, y lo mismo ocurre con el caso de Poisson.

8.7. Métodos de estimación

En esta sección estudiaremos diversos métodos para la construcción de estimadores. El primero de los métodos se conoce como método de los momentos y responde a la idea de identificar características poblacionales con características muestrales. Históricamente fué uno de los primeros métodos propuestos. A continuación estudiaremos el método de máxima verosimilitud. El método de máxima verosimilitud es uno de los métodos de estimación más ampliamente utilizado y para un gran número de poblaciones proporciona estimadores eficientes y asintóticamente normales.

8.7.1. Método de los momentos

Según hemos comentado este método de estimación responde a la idea de expresar los parámetros del modelo en función de los momentos de la población, para a continuación sustituirlos por sus correspondientes muestrales. Supongamos que la población $f(x; \theta)$ depende de un total de k -parámetros desconocidos de modo que $\theta = (\theta_1, \dots, \theta_k)$. Denotamos los momentos de la población como,

$$\alpha_j(\theta) = E(X^j), \quad j = 1, 2, \dots, k.$$

Para la estimación de θ se dispone de una muestra aleatoria simple $X_1, \dots, X_n$ de tamaño n .

Definición 8.10 Un estimador de momentos de $\theta = (\theta_1, \dots, \theta_k)$ es cualquier solución del sistema de ecuaciones,

$$\alpha_j(\theta) = \frac{1}{n} \sum_{i=1}^n X_i^j, \quad j = 1, 2, \dots, k. \quad (8.2)$$

En la práctica se pueden utilizar también potencias negativas, o incluso momentos de otro tipo de estadísticos no potenciales, como por ejemplo los momentos de los estadísticos de orden.

Ejemplo 8.14 La población de los coste es de tipo exponencial con función de densidad $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $x > 0$ y queremos estimar θ por el método de los momentos.

Solución: Puesto que $E(X) = \theta$, usando (8.2) obtenemos el estimador,

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i. \quad \diamond$$

Ejemplo 8.15 Supongamos que el coste es de tipo log-normal $\mathcal{LN}(\mu, \sigma_0^2)$, donde σ_0^2 es conocido y se quiere estimar μ por el método de los momentos.

Solución: Usando (8.2) y la media de la distribución log-normal, se trata de resolver en μ la ecuación,

$$E(X) = e^{\mu + \sigma_0^2/2} = \frac{1}{n} \sum_{i=1}^n X_i,$$

cuya solución da lugar al estimador de momentos,

$$\hat{\mu} = \log \left(\frac{1}{n} \sum_{i=1}^n X_i \right) - \frac{\sigma_0^2}{2}.$$

◇

Ejemplo 8.16 Supongamos que los costes siguen una distribución uniforme $\mathcal{U}(a, b)$ donde $a < b$. Obtener los estimadores por el método de los momentos.

Solución: Para obtener estimadores de momentos tenemos que resolver en los parámetros (a, b) el sistema:

$$\begin{aligned} E(X) &= \frac{a+b}{2} = \bar{X}, \\ \text{Var}(X) &= \frac{(b-a)^2}{12} = S_X^2, \end{aligned}$$

donde $\bar{X}$ y S_X^2 representa la media y varianza muestral, respectivamente. Resolviendo el sistema anterior obtenemos los estimadores,

$$\begin{aligned} \hat{a} &= \bar{X} - \sqrt{3}S_X, \\ \hat{b} &= \bar{X} + \sqrt{3}S_X. \end{aligned}$$

◇

Siempre que los correspondientes momentos de la población existan, los estimadores de momentos son consistentes. Estos estimadores son insesgados, suponiendo una relación de tipo lineal entre momentos y parámetros.

8.7.2. Estimadores de máxima verosimilitud

Este método de estimación responde a la idea de elegir los valores de los parámetros que hacen máxima la probabilidad de la muestra observada. Consideremos una población dependiente de k parámetros y una muestra de observaciones de tamaño n procedente de esa población.

Definición 8.11 Se denomina función de verosimilitud a la función:

$$L(\theta; x_1, \dots, x_n) = f(x_1, \dots, x_n; \theta) = f(x_1; \theta) \cdots f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta). \quad (8.3)$$

En consecuencia, la función de verosimilitud equivale a la función de densidad de la muestra, pero ahora vista como función del parámetro.

Definición 8.12 Se denomina estimador de máxima verosimilitud (EMV) $\hat{\theta}$ al valor del parámetro que hace máxima la función de verosimilitud:

$$L(\hat{\theta}; x_1, \dots, x_n) = \sup_{\theta \in \Theta} L(\theta; x_1, \dots, x_n).$$

El cálculo del estimador de máxima verosimilitud se reduce a calcular el máximo de la función de verosimilitud vista como función de los parámetros. Dada la monotonía de la función logaritmo, a efectos prácticos se suele trabajar con el logaritmo de la función de verosimilitud:

$$\ell(\theta) = \log L(\theta; x_1, \dots, x_n) = \sum_{i=1}^n \log f(x_i; \theta),$$

y si la función anterior es derivable, el máximo debe satisfacer las siguientes ecuaciones, denominadas ecuaciones de verosimilitud:

$$\frac{\partial \ell(\theta)}{\partial \theta_i} = 0, \quad i = 1, \dots, k.$$

Información

El concepto de información (tanto observada como esperada) está relacionado con la eficiencia del estimador, de modo que a mayor información más precisión en el estimador. Sea $f(x; \theta)$ un modelo paramétrico y,

$$\ell(\theta) = \log f(x; \theta)$$

el logaritmo de la función de verosimilitud basada en una muestra de tamaño uno.

Definición 8.13 En un modelo con logaritmo de la función de verosimilitud $\ell(\theta)$ se denomina cantidad de información esperada a,

$$J(\theta) = -\frac{\partial^2 \ell(\theta)}{\partial \theta^2}.$$

Si tenemos disponible una muestra de n observaciones la cantidad de información observada es,

$$J(\theta) = -\frac{\partial^2 \ell(\theta)}{\partial \theta^2} = -\frac{\partial^2}{\partial \theta^2} \sum_{i=1}^n \log f(x_i; \theta) = -\sum_{i=1}^n \frac{\partial^2 \log f(x_i; \theta)}{\partial \theta^2},$$

puesto que,

$$\ell(\theta) = \log f(x_1, \dots, x_n; \theta) = \log \prod_{i=1}^n f(x_i; \theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Antes que el experimento o la observación sea realizada no tenemos datos y por tanto no podemos obtener la cantidad de información observada. En este caso se recurre a la cantidad de información esperada de Fisher.

Definición 8.14 En un modelo con logaritmo de la función de verosimilitud $\ell(\theta)$ se denomina cantidad de información esperada de Fisher a,

$$I(\theta) = E \left(\frac{\partial \ell(\theta)}{\partial \theta} \right)^2 = -E \left(\frac{\partial^2 \ell(\theta)}{\partial \theta^2} \right).$$

Si disponemos de un total de n observaciones tenemos que,

$$I_n(\theta) = nI(\theta),$$

donde $I_n(\cdot)$ significa que la definición se aplica sobre una verosimilitud con n observaciones. Obviamente se verifica que,

$$I(\theta) = E[J(\theta)].$$

Si el vector tiene k componentes $\theta = (\theta_1, \dots, \theta_k)$ entonces $J(\theta)$ e $I(\theta)$ son matrices $k \times k$ con componentes,

$$j_{rs} = -\frac{\partial^2 \ell(\theta)}{\partial \theta_r \partial \theta_s},$$

y

$$i_{rs} = -E \left(\frac{\partial^2 \ell(\theta)}{\partial \theta_r \partial \theta_s} \right),$$

respectivamente, con $r, s \in \{1, \dots, k\}$.

Ejemplo 8.17 Supongamos un modelo exponencial,

$$f(x; \sigma) = \frac{1}{\sigma} e^{-x/\sigma}, \quad x > 0,$$

donde $\sigma > 0$. Obtener las cantidades $I(\sigma)$ y $J(\sigma)$.

Solución: El logaritmo de la función de verosimilitud es,

$$\ell(\sigma) = -\log \sigma - \frac{x}{\sigma}.$$

La cantidad de información observada es,

$$J(\sigma) = -\frac{\partial^2 \ell(\sigma)}{\partial \sigma^2} = -\frac{1}{\sigma^2} + \frac{2x}{\sigma^3}.$$

Para obtener la cantidad de información esperada de Fisher calculamos la esperanza matemática de $J(\sigma)$:

$$I(\sigma) = E[J(\sigma)] = E \left(-\frac{1}{\sigma^2} + \frac{2X}{\sigma^3} \right) = -\frac{1}{\sigma^2} + \frac{2}{\sigma^3} E(X) = \frac{1}{\sigma^2},$$

puesto que $E(X) = \sigma$.

◇

Ejemplo 8.18 Obtener las cantidades $I(\sigma)$ y $J(\sigma)$ para un modelo de Poisson $\mathcal{P}(\lambda)$ con $\lambda > 0$.

Solución: El logaritmo de la función de verosimilitud es,

$$\ell(\lambda) = \log \Pr(X = x) = -\lambda + x \log \lambda - \log x!$$

La información observada es,

$$J(\lambda) = -\frac{\partial^2 \ell(\lambda)}{\partial \lambda^2} = \frac{x}{\lambda^2}.$$

La cantidad de información esperada es,

$$I(\lambda) = E[J(\lambda)] = \frac{1}{\lambda^2} E(X) = \frac{1}{\lambda},$$

puesto que en la distribución de Poisson $E(X) = \lambda$.

◇

Propiedades de los estimadores de máxima verosimilitud

Una de las ventajas de los estimadores de máxima verosimilitud es que para la mayoría de las distribuciones de uso práctico, es posible obtener fácilmente los correspondientes estimadores puntuales, junto con sus errores estándar e intervalos de confianza. Se cumple el siguiente resultado.

Teorema 8.5 Sea $X_1, \dots, X_n$ una muestra de observaciones procedente de una población con función de densidad $f(x; \theta)$, donde θ es de dimensión k . Si $\hat{\theta}$ es el estimador de máxima verosimilitud de θ , entonces bajo ciertas condiciones de regularidad se verifica que cuando $n \rightarrow \infty$,

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{D} \mathcal{N}_k(0; I(\theta)^{-1}), \quad (8.4)$$

donde $\mathcal{N}_k$ es la función de densidad de una normal k -dimensional y $I(\theta)^{-1}$ la inversa de la matriz de información esperada de Fisher.

El resultado anterior establece que para tamaños de muestra grandes y en poblaciones verificando determinadas condiciones de regularidad, el estimador de máxima verosimilitud es insesgado, consistente, normal y eficiente (la varianza alcanza la cota de Cramér-Rao). El resultado anterior permite además obtener intervalos de confianza aproximados para los parámetros del modelo. Por medio de las distribuciones marginales de $\hat{\theta}$ en (8.4) se verifica que,

$$\hat{\theta}_r \approx \mathcal{N}(\theta_r, \psi_{rr}), \quad r = 1, 2, \dots, k$$

donde ψ_{rr} es el elemento (r, r) de $I(\theta)^{-1}$ evaluado en el estimador de máxima verosimilitud. Un intervalo de confianza aproximado (cuando $n \rightarrow \infty$) para θ_r es,

$$\hat{\theta}_r \pm z_{1-\alpha/2} \sqrt{\psi_{rr}},$$

o bien

$$\hat{\theta}_r \pm z_{1-\alpha/2} \sqrt{\hat{\psi}_{rr}},$$

donde $\hat{\psi}_{rr}$ es el elemento (r, r) de $J(\hat{\theta})^{-1}$ evaluado en el estimador de máxima verosimilitud. Si la población posee un estadístico suficiente y existe el EMV del correspondiente parámetro, entonces éste es siempre función del estadístico suficiente. Se verifica también el llamado principio o propiedad de invarianza: si $\hat{\theta}$ es el EMV del parámetro θ , entonces $h(\hat{\theta})$ es el EMV del parámetro $h(\theta)$.

Ejemplo 8.19 Probar que el estimador de máxima verosimilitud del parámetro λ de una distribución de Poisson es la media aritmética.

Solución: La función de verosimilitud es:

$$\begin{aligned} L(\lambda) &= \Pr(X_1 = x_1, \dots, X_n = x_n) \\ &= \Pr(X_1 = x_1) \cdots \Pr(X_n = x_n) \\ &= \frac{e^{-\lambda} \lambda^{x_1}}{x_1!} \cdots \frac{e^{-\lambda} \lambda^{x_n}}{x_n!} \\ &= \frac{e^{-n\lambda} \lambda^{n\bar{x}}}{\prod_{i=1}^n x_i!}. \end{aligned}$$

El logaritmo de la función de verosimilitud es:

$$\ell(\lambda) = \log L(\lambda) = -n\lambda + n\bar{x} \log(\lambda) - \log \left(\prod_{i=1}^n x_i! \right).$$

Derivando respecto λ e igualando a cero obtenemos:

$$\frac{\partial \ell(\lambda)}{\partial \lambda} = -n + \frac{n\bar{x}}{\lambda} = 0,$$

de donde:

$$\hat{\lambda} = \bar{x},$$

que corresponde a un máximo puesto que:

$$\frac{\partial^2 \ell(\lambda)}{\partial \lambda^2} = -\frac{n\bar{x}}{\lambda^2} < 0.$$

◇

Ejemplo 8.20 Hallar los estimadores de máxima verosimilitud de la media μ y la desviación típica σ de una población normal.

Solución: La función de densidad de la población es:

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}.$$

Para una muestra genérica de tamaño n , la función de verosimilitud viene dada por:

$$\begin{aligned} L(\mu, \sigma) &= f(x_1; \mu, \sigma) \cdots f(x_n; \mu, \sigma) \\ &= \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x_1 - \mu}{\sigma} \right)^2 \right\} \cdots \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x_n - \mu}{\sigma} \right)^2 \right\} \\ &= \frac{1}{\sigma^n (2\pi)^{n/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2 \right\}. \end{aligned}$$

El logaritmo de la función de verosimilitud es:

$$\ell(\mu, \sigma) = \log L(\mu, \sigma) = -n \log(\sigma) - \frac{n}{2} \log(2\pi) - \frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2.$$

Derivando respecto de los dos parámetros obtenemos el sistema:

$$\begin{aligned}\frac{\partial \ell(\mu, \sigma)}{\partial \mu} &= \frac{2}{2\sigma^2} \sum_{k=1}^n (x_k - \mu) = 0, \\ \frac{\partial \ell(\mu, \sigma)}{\partial \sigma} &= -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{k=1}^n (x_k - \mu)^2 = 0.\end{aligned}$$

Si nos fijamos en la primera ecuación:

$$\sum_{k=1}^n (x_k - \mu) = 0 \Rightarrow \sum_{k=1}^n x_k - n\mu = 0,$$

por tanto,

$$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k = \bar{x},$$

y sustituyendo en la segunda:

$$-\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{k=1}^n (x_k - \bar{x})^2 = 0,$$

de donde,

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2} = S_X.$$

Se propone como ejercicio el comprobar que estos valores corresponden a un máximo.

◇

Estimación de máxima verosimilitud con datos agrupados

En ocasiones los datos no están disponibles en forma de valores individuales, sino que aparecen agrupados en intervalos. En este caso es posible obtener los estimadores de máxima verosimilitud de los parámetros, si bien las ecuaciones de verosimilitud son más complejas. Supongamos que los intervalos vienen dados por $(a_{j-1}, a_j]$, $j = 1, 2, \dots, r$ y n_j , $j = 1, 2, \dots, r$ es la frecuencia de observaciones en el intervalo j , con $\sum_{j=1}^r n_j = n$. La función de verosimilitud es,

$$L(\theta) = \prod_{j=1}^r [F(a_j; \theta) - F(a_{j-1}; \theta)]^{n_j}, \quad (8.5)$$

8.7. Métodos de estimación

cuyo logaritmo es,

$$\ell(\theta) = \sum_{j=1}^r n_j \log[F(a_j; \theta) - F(a_{j-1}; \theta)]. \quad (8.6)$$

Finalmente, se resuelve el sistema de ecuaciones,

$$\frac{\partial \ell(\theta)}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k.$$

Ejemplo 8.21 Supongamos que el coste de un siniestro se distribuye según una distribución exponencial $F(x; \theta) = 1 - e^{-x/\theta}$, $x > 0$ y los datos están agrupados en dos intervalos $(0, a]$ y $(a, \infty]$ con frecuencias por intervalo n_1 y n_2 , de modo que $n_1 + n_2 = n$. Obtener el estimador de máxima verosimilitud de θ .

Solución: Según (8.5), la función de verosimilitud es ($r = 2$),

$$\begin{aligned}L(\theta) &= [F(a; \theta) - F(0; \theta)]^{n_1} [F(\infty; \theta) - F(a; \theta)]^{n_2} \\ &= [1 - e^{-a/\theta}]^{n_1} \cdot [e^{-a/\theta}]^{n_2} \\ &= [1 - e^{-a/\theta}]^{n_1} e^{-an_2/\theta}.\end{aligned}$$

El logaritmo de la función de verosimilitud (fórmula (8.6)) es,

$$\ell(\theta) = n_1 \log(1 - e^{-a/\theta}) - \frac{an_2}{\theta}.$$

La ecuación de verosimilitud es,

$$\frac{\partial \ell(\theta)}{\partial \theta} = -\frac{n_1 a}{\theta^2} \cdot \frac{e^{-a/\theta}}{1 - e^{-a/\theta}} + \frac{an_2}{\theta^2} = 0.$$

Despejando θ obtenemos el estimador de máxima verosimilitud de θ que viene dado por,

$$\hat{\theta} = \frac{a}{\log(n/n_2)}.$$

◇

Cálculo de los estimadores de máxima verosimilitud

En los ejemplos vistos anteriormente podemos encontrar el estimador de máxima verosimilitud analíticamente. Sin embargo, en otras ocasiones debemos recurrir a métodos numéricos. Veamos el método de Newton-Raphson. Si desarrollamos en serie la derivada primera del logaritmo de la verosimilitud en un entorno de θ_j obtenemos,

$$0 = \ell(\hat{\theta}) \approx \ell'(\theta_j) + (\hat{\theta} - \theta_j) \ell''(\theta_j),$$

donde $\hat{\theta}$ es el estimador de máxima verosimilitud de θ . Despejando $\hat{\theta}$ obtenemos,

$$\hat{\theta} \approx \theta_j - \frac{\ell'(\theta_j)}{\ell''(\theta_j)}.$$

La fórmula anterior sugiere el siguiente esquema iterativo,

$$\hat{\theta}_{j+1} = \theta_j - \frac{\ell'(\theta_j)}{\ell''(\theta_j)}.$$

En el caso de k -parámetros $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ tenemos la fórmula,

$$\hat{\theta}_{j+1} = \theta_j - H^{-1} \ell'(\theta_j),$$

donde $\ell'(\theta_j)$ es el vector de derivadas primeras y H es la matriz de derivadas segundas del logaritmo de la verosimilitud.

8.7.3. El delta método

El *delta método* es un procedimiento estadístico que permite obtener la distribución asintótica de un estimador, y por tanto estimar la matriz de varianzas-covarianzas de dicho estimador.

El delta método necesita dos ingredientes: una variable aleatoria o estimador T_n cuya distribución dependa de θ (la cantidad a estimar) y una distribución asintótica. Veamos el caso escalar.

Teorema 8.6 Sea T_n una sucesión de variables aleatorias (estimadores) y θ un número real (parámetro de interés) tal que cuando $n \rightarrow \infty$ se verifica,

$$\sqrt{n}(T_n - \theta) \xrightarrow{D} \mathcal{N}(0, \sigma^2). \quad (8.7)$$

Entonces, si $g(\theta)$ es una función diferenciable tal que $g'(\theta) \neq 0$, se verifica que, cuando $n \rightarrow \infty$

$$\sqrt{n}(g(T_n) - g(\theta)) \xrightarrow{D} \mathcal{N}(0, \sigma^2 [g'(\theta)]^2). \quad (8.8)$$

Ejemplo 8.22 El número de reclamaciones que recibe una compañía de seguros sigue una distribución de Poisson $\mathcal{P}(\lambda)$ donde $\lambda > 0$. Se dispone de una muestra de n reclamaciones $X_1, \dots, X_n$.

1. Hallar el estimador de máxima verosimilitud de la cantidad $g(\lambda)$ al menos una reclamación.
2. Obtener la distribución asintótica de $g(\lambda)$ por medio del delta método. ¿Cuál es la varianza asintótica del estimador?

Solución:

8.7. Métodos de estimación

1. El estimador de máxima verosimilitud de λ es $\hat{\lambda} = \bar{X}$. La cantidad de interés es $g(\lambda) = \Pr(X \geq 1) = 1 - e^{-\lambda}$. Por la propiedad de invarianza el estimador de máxima verosimilitud de $g(\lambda)$ es $g(\hat{\lambda}) = 1 - e^{-\bar{X}}$.
2. Por el teorema central del límite tenemos que,

$$\sqrt{n}(\bar{X} - \lambda) \xrightarrow{D} \mathcal{N}(0, \lambda). \quad (8.9)$$

Se verifica que $g'(\lambda) = e^{-\lambda} \neq 0$. Si a la expresión (8.9) le aplicamos (8.8) obtenemos que cuando $n \rightarrow \infty$

$$\sqrt{n}(g(\bar{X}) - g(\lambda)) \xrightarrow{D} \mathcal{N}(0, \lambda e^{-2\lambda}).$$

La varianza asintótica de $g(\hat{\lambda})$ viene dada por,

$$\text{Var}[g(\hat{\lambda})] \doteq \frac{\lambda e^{-2\lambda}}{n}.$$

◇

8.7.4. Estimación eficiente de la varianza

En este apartado vamos a ver algunos resultados que nos indican cómo obtener estimadores con la menor varianza posible. Comenzamos con la definición de estimador insesgado de varianza mínima.

Definición 8.15 (Estimador insesgado uniforme de varianza mínima) Un estimador $\hat{\theta}^*$ se dice que es insesgado uniforme de varianza mínima si verifica las siguientes condiciones:

- a) Es insesgado: $E(\hat{\theta}^*) = \theta, \forall \theta \in \Theta$,
- b) Posee la menor varianza dentro de la clase de los estimadores insesgados, es decir si $\hat{\theta}$ es estimador insesgado de θ , entonces,

$$\text{Var}(\hat{\theta}^*) \leq \text{Var}(\hat{\theta}), \forall \hat{\theta}.$$

El siguiente resultado proporciona una cota para la varianza de un estimador insesgado.

Teorema 8.7 (Cota de Cramér-Rao) Sea $\hat{\theta}_n$ un estimador insesgado del parámetro $g(\theta)$, es decir, $E(\hat{\theta}_n) = g(\theta)$. Entonces, bajo condiciones generales sobre la población, se verifica la siguiente cota para la varianza del estimador,

$$\text{Var}(\hat{\theta}_n) \geq \frac{[g'(\theta)]^2}{I_n(\theta)} = \frac{[g'(\theta)]^2}{nI(\theta)}.$$

Definición 8.16 (Estimador eficiente) Un estimador $\hat{\theta}_n$ se dice que es eficiente respecto del parámetro $g(\theta)$ si su varianza alcanza la cota de Cramér-Rao, es decir si,

$$\text{Var}(\hat{\theta}_n) = \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

Un estimador eficiente es de mínima varianza, pero no todo estimador de mínima varianza es eficiente, puesto que puede no tener sentido obtener la cota de Cramér-Rao al no ser la población regular.

Definición 8.17 Una familia de funciones de densidad se dice que es completa si,

$$E[T(X)] = 0 \quad \forall \theta \in \Theta \implies T(X) = 0.$$

Un estadístico se dice que es completo si la familia de distribuciones que induce es completa. El siguiente resultado se conoce con el nombre de *teorema de Rao-Blackwell*:

Teorema 8.3 (Teorema de Rao-Blackwell) Sea T un estadístico suficiente y $G(\underline{X})$ un estimador insesgado de $g(\theta)$. Entonces el estimador esperanza condicional:

$$E[G(\underline{X})|T],$$

es un estimador insesgado de $g(\theta)$ y preferible al estimador $G(\underline{X})$, en el sentido:

$$\text{Var}[E(G(\underline{X})|T)] \leq \text{Var}[G(\underline{X})], \quad \forall \theta \in \Theta.$$

El siguiente resultado es el *teorema de Lehmann-Scheffé*.

Teorema 8.9 (Teorema de Lehmann-Scheffé) Sea T un estadístico suficiente y completo, y supongamos que $G(\underline{X})$ es un estimador insesgado de $g(\theta)$. Entonces el estimador:

$$E[G(\underline{X})|T],$$

es el estimador insesgado uniforme de varianza mínima para $g(\theta)$.

Mediante este resultado un estimador insesgado que sea función de un estadístico completo es uniforme de mínima varianza.

Ejemplo 8.23 Se desea estimar las pérdidas de un tipo de accidente. Para ello se recoge una muestra de n pérdidas $X_1, \dots, X_n$. Se supone que la población de la que proceden los datos es de tipo exponencial con función de distribución,

$$F(x; \theta) = 1 - e^{-x/\theta}, \quad x \geq 0$$

y $F(x; \theta) = 0$ si $x < 0$, donde $\theta > 0$.

1. Hallar el estimador de máxima verosimilitud de θ . Probar que dicho estimador es insesgado y calcular su varianza. Deducir la consistencia.
2. Probar que el estimador anterior es suficiente y eficiente.
3. Se desea estimar la probabilidad de que el una pérdida sea mayor que 100 u.m. Hallar el estimador máximo verosímil de esta probabilidad. Obtener una cota para la varianza de los estimadores insesgados de esta probabilidad.

Solución:

1. La función de densidad de la población es $(d/d\theta)F(x; \theta) = (1/\theta)e^{-x/\theta}$. La función de verosimilitud y su logaritmo son:

$$L(\theta) = f(X_1; \theta) \cdots f(X_n; \theta) = \frac{1}{\theta^n} \exp\left(-\frac{1}{\theta} \sum_{k=1}^n X_k\right),$$

$$\ell(\theta) = \log L(\theta) = -n \log(\theta) - \frac{1}{\theta} \sum_{k=1}^n X_k.$$

Para obtener el máximo calculamos la primera derivada y la igualamos a cero,

$$\frac{\partial \ell(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{k=1}^n X_k = 0 \implies \theta = \frac{1}{n} \sum_{k=1}^n X_k,$$

que es la media muestral de las observaciones. Veamos que es insesgado y calculemos su varianza. Al tratarse de la media muestral:

$$E(\hat{\theta}) = E(\bar{X}) = E(X) = \theta,$$

$$\text{Var}(\hat{\theta}) = \text{Var}(\bar{X}) = \frac{\text{Var}(X)}{n} = \frac{\theta^2}{n}.$$

puesto que la esperanza de la media muestral es la media poblacional y la varianza de la media muestral es la varianza poblacional dividida por n . El EMV es consistente al ser insesgado con varianza que tiende a 0 cuando n tiende a infinito.

2. La suficiencia ha sido probada en el ejemplo 8.12. Para probar que es eficiente veamos que la varianza del estimador coincide con la cota de Cramér-Rao. En el ejemplo 8.17 hemos probado que la cantidad de información esperada de Fisher es:

$$I(\theta) = \frac{1}{\theta^2}.$$

Por tanto, si T es cualquier estimador insesgado de $g(\theta) = \theta$ se verifica que:

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)} = \frac{1}{\frac{n}{\theta^2}} = \frac{\theta^2}{n},$$

que coincide con la varianza del EMV, y por tanto es eficiente y en consecuencia uniforme de mínima varianza.

3. La cantidad a estimar es $p_{100} = \Pr(X > 100) = 1 - F(100) = e^{-100/\theta}$. Por el principio de invarianza:

$$\hat{p}_{100} = e^{-100/\hat{\theta}} = e^{-100/\bar{X}}.$$

Mediante la cota de Cramér-Rao, si T es cualquier estimador insesgado de $g(\theta) = e^{-100/\theta}$ se tiene que:

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)} = \frac{(\frac{100}{\theta^2} e^{-100/\theta})^2}{\frac{n}{\theta^2}} = \frac{100^2 \exp(-200/\theta)}{n\theta^2}.$$

◇

8.8. Estimación por intervalos de confianza

Consideremos una población descrita a través de una función de densidad dependiente de un parámetro θ , $\{f(x; \theta), \theta \in \Theta\}$ y una muestra aleatoria simple $\underline{X} = (X_1, \dots, X_n)$ procedente de esa población.

Definición 8.18 Se dice que $(T_1(\underline{X}), T_2(\underline{X}))$ es un intervalo de confianza para θ al nivel de confianza $1 - \alpha$ si:

$$\Pr(T_1(\underline{X}) \leq \theta \leq T_2(\underline{X})) \geq 1 - \alpha, \quad \forall \theta \in \Theta.$$

Los extremos del intervalo se pueden considerar como estimadores por exceso y por defecto del parámetro. La probabilidad $1 - \alpha$ se le denomina *nivel de confianza* y al término α *error*. Los valores que se eligen para el error suelen ser 0,05 y 0,01 y por tanto los niveles de confianza usuales son 0,95 y 0,99, respectivamente.

El método del pivote es uno de los métodos habituales para construir intervalos de confianza exactos.

Definición 8.19 Se dice que $T(\underline{X}, \theta)$ es una función pivot si verifica tres condiciones:

- Es estrictamente monótona respecto del parámetro θ .
- Es posible despejar θ .
- Su distribución de probabilidad no depende de θ .

8.8. Estimación por intervalos de confianza

Para la obtención de un intervalo de confianza y una vez disponible una función pivot, se elige un nivel de confianza, y se calculan dos constantes λ_1 y λ_2 tales que:

$$\Pr(\lambda_1 \leq T(\underline{X}, \theta) \leq \lambda_2) = 1 - \alpha.$$

Notar que λ_i , $i = 1, 2$ dependen únicamente del error y no del parámetro. A continuación si se despeja el valor de θ en las dos desigualdades obtenemos un intervalo de confianza para θ .

Ejemplo 8.24 Sea $X_1, \dots, X_n$ una muestra aleatoria simple procedente de una población normal $\mathcal{N}(\mu, \sigma^2)$, donde la varianza σ^2 es conocida. Probar que:

$$\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right), \quad (8.10)$$

es un intervalo de confianza para μ al nivel de confianza $1 - \alpha$, donde $z_{1-\alpha/2}$ representa el percentil de orden $1 - \alpha/2$ de una distribución $\mathcal{N}(0, 1)$, es decir $\Phi(z_{1-\alpha/2}) = 1 - \alpha/2$.

Solución: Puesto que $X_i \sim \mathcal{N}(\mu, \sigma^2)$, se sigue que $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$, de donde tipificando:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1). \quad (8.11)$$

La expresión (8.11) es una función pivot, puesto que es monótona respecto μ , es posible despejar este parámetro y su distribución es $\mathcal{N}(0, 1)$ que no depende de μ . Ahora, puesto que la distribución $\mathcal{N}(0, 1)$ es simétrica respecto del 0, busquemos una constante a tal que:

$$\Pr\left(-a \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq a\right) = 1 - \alpha, \quad (8.12)$$

y por tanto el valor a verifica:

$$\Pr(Z \leq a) = 1 - \frac{\alpha}{2},$$

de donde $a = z_{1-\alpha/2}$. Ahora, si en (8.12) despejamos μ se obtiene:

$$\Pr\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha,$$

que es el intervalo de confianza para μ . ◇

La precisión de un intervalo de confianza viene asociada a su longitud, de modo que los intervalos más precisos son los de menor longitud. La longitud del intervalo (8.10) es:

$$\frac{2z_{1-\frac{\alpha}{2}} \sigma}{\sqrt{n}}.$$

Por tanto, la longitud del intervalo depende del nivel de confianza $1 - \alpha$, de la desviación típica de la población σ y del tamaño de muestra n . Notar que el punto medio del intervalo es $\bar{X}$, que es el estimador puntual de μ . El intervalo de confianza (8.10) es igualmente aplicable a cualquier tipo de población (con varianza σ^2 conocida), siempre que el tamaño de muestra sea grande ($n > 30$) y la media exista. Cómo se puede ver, al aumentar el tamaño de muestra, se obtiene un intervalo más preciso.

Veamos el intervalo de confianza para la media en el caso de que el tamaño de muestra sea pequeño y la varianza de la población desconocida.

Ejemplo 8.25 Sea $X_1, \dots, X_n$ una muestra aleatoria simple procedente de una población normal $N(\mu, \sigma^2)$, donde μ y σ^2 son parámetros desconocidos. Probar que entonces:

$$\left(\bar{X} - t_{n-1; \frac{\alpha}{2}} \frac{S}{\sqrt{n-1}}, \bar{X} + t_{n-1; \frac{\alpha}{2}} \frac{S}{\sqrt{n-1}} \right),$$

es un intervalo de confianza para μ al nivel de confianza $1 - \alpha$, donde $t_{n; \alpha}$ es un valor tal que $\Pr(t_n \geq t_{n; \alpha}) = \alpha$, siendo t_n la distribución t de Student con n grados de libertad.

Solución: Partimos de una muestra $X_i \sim N(\mu, \sigma^2)$, $i = 1, 2, \dots, n$ y los dos parámetros son desconocidos. La distribución de la media muestral es normal $\bar{X} \sim N(\mu, \sigma^2/n)$ y la de la varianza $nS^2/\sigma^2 \sim \chi_{n-1}^2$ y se trata de estadísticos independientes. Construimos el estadístico:

$$\frac{\bar{X} - \mu}{S/\sqrt{n-1}} \sim t_{n-1},$$

que se distribuye como una t de Student con $n - 1$ grados de libertad y su distribución no depende de σ , sólo de μ . Por tanto disponemos de una función pivot para la estimación por intervalo de μ . Ahora, puesto que la distribución de la t de Student es simétrica respecto del 0, buscamos una constante a verificando:

$$\Pr\left(-a \leq \frac{\bar{X} - \mu}{S/\sqrt{n-1}} \leq a\right) = 1 - \alpha, \quad (8.13)$$

de donde la constante $a = t_{n-1; \alpha/2}$ es tal que:

$$\Pr(t_{n-1} \geq t_{n-1; \alpha/2}) = \frac{\alpha}{2}.$$

Finalmente, despejando μ en (8.13), obtenemos el resultado. $\diamond$

En el caso de tamaños muestrales grandes ($n > 30$), tenemos el intervalo de confianza:

$$\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{S}{\sqrt{n-1}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{S}{\sqrt{n-1}} \right), \quad (8.14)$$

donde S representa la desviación típica muestral. Este intervalo de confianza se puede aplicar como aproximación a cualquier población, no necesariamente normal, siempre que el tamaño de muestra sea grande ($n > 30$) y la media poblacional exista.

8.9. Contraste de hipótesis

Otra de las situaciones prácticas en el análisis de datos, consiste en la confirmación o no (en términos probabilísticos) de ciertas conjeturas que puedan hacerse sobre los parámetros de las distribuciones o directamente sobre los modelos que generan los datos. La herramienta estadística para este tipo de análisis lo constituye los contrastes o test de hipótesis.

Supongamos que disponemos de una muestra aleatoria simple $X = (X_1, \dots, X_n)$ procedente de una población especificada en forma paramétrica por una familia de densidades $\{f(x; \theta) : \theta \in \Theta\}$. Hablaremos de una hipótesis paramétrica para hacer referencia a una afirmación acerca del parámetro desconocido $\theta \in \Theta$. Pues bien, en un contraste o test de hipótesis paramétrico, existen dos hipótesis:

$$H_0 : \theta \in \Theta_0,$$

denominada *hipótesis nula* y

$$H_1 : \theta \in \Theta_1,$$

denominada *hipótesis alternativa*, donde Θ_0 y Θ_1 son dos subconjuntos del espacio paramétrico, tales que: $\Theta_0 \cup \Theta_1 = \Theta$, y $\Theta_0 \cap \Theta_1 = \emptyset$.

De forma resumida denotaremos por $H_0 : \theta \in \Theta_0$ vs $H_1 : \theta \in \Theta_1$, a un test de hipótesis genérico. En función de los conjuntos Θ_0 y Θ_1 , existen diversos tipos de contrastes. Así por ejemplo, si Θ_0 (equivalentemente, Θ_1) contiene un sólo elemento, $\Theta_0 = \{\theta_0\}$, hablaremos de hipótesis nula simple (equivalentemente, hipótesis alternativa simple, para el caso $\Theta_1 = \{\theta_1\}$). Observemos que para el caso de hipótesis nula simple frente a alternativa simple la distribución poblacional queda perfectamente especificada bajo cualquiera de las hipótesis. En caso contrario, se habla de hipótesis compuestas. El problema del contraste de hipótesis consiste en una regla de decisión que permita rechazar la hipótesis nula a la luz de los datos observados. La regla de decisión se hace por medio de la región crítica.

Definición 8.20 (Región crítica) Se denomina *región crítica* a un subconjunto C de modo que si $x \in C$, rechazaremos la hipótesis nula H_0 y aceptaremos H_1 y si $x \notin C$, no se rechaza la hipótesis nula H_0 .

Existen dos tipos de errores que pueden cometerse cuando se sigue un procedimiento como el descrito anteriormente, conocidos como *error tipo I* y *error tipo II*. Las posibles situaciones que se presentan en un contraste aparecen resumidas en la tabla 8.1.

Tabla 8.1: Situaciones en un contraste de hipótesis

	Situación real	
	H_0 es cierta	H_0 es falsa
No se rechaza H_0	Decisión correcta	Error tipo II
Se rechaza H_0	Error tipo I	Decisión correcta

El error tipo I es el que se comete cuando se rechaza H_0 siendo cierta y su probabilidad vendrá dada por

$$\Pr(\text{error tipo I}) = \Pr(\text{rechazar } H_0 | H_0 \text{ cierta}) = \Pr(X \in C | H_0) = \alpha,$$

y el error tipo II es el que se comete al aceptar H_0 cuando es falsa, siendo su probabilidad asociada

$$\Pr(\text{error tipo II}) = \Pr(\text{aceptar } H_0 | H_0 \text{ falsa}) = \Pr(X \notin C | H_1) = \beta.$$

En consecuencia, se deben considerar regiones críticas con ambas probabilidades de error cercanas a cero. Sin embargo, esta situación no es posible y lo que se hace es limitar la probabilidad de error tipo I a una cantidad pequeña asignada previamente (habitualmente: 0,05; 0,01 ó 0,001) y construir un procedimiento de contraste que tenga la menor probabilidad de error tipo II. Observemos que estas probabilidades tendrán un valor único para el caso de hipótesis nula y alternativa simple, y que serán funciones del parámetro θ en el caso compuesto. Reformulando el problema en los términos anteriores, introducimos los siguientes conceptos.

Definición 8.21 (Potencia de un test) La función potencia de un test con región crítica C , para el contraste $H_0 : \theta \in \Theta_0$ vs $H_1 : \theta \in \Theta_1$, es la función que a cada valor de $\theta \in \Theta$ le hace corresponder el valor de la probabilidad de rechazar H_0 , $\Pr(C|\theta)$.

Definición 8.22 (Nivel de significación) El nivel de significación o tamaño de un test de hipótesis con región crítica C , para el contraste $H_0 : \theta \in \Theta_0$ vs $H_1 : \theta \in \Theta_1$, es la probabilidad máxima de cometer un error tipo I, es decir, el valor

$$\alpha = \max_{\theta \in \Theta_0} \Pr(C|\theta).$$

Observemos pues que con estas definiciones interesarán contrastes cuya región crítica tenga un nivel de significación pequeño y potencia grande. Fijado un nivel de significación, existirán una gran variedad de regiones críticas para el contraste. Nos interesará aquella de mayor potencia (Rohatgi, 1976) cuando $\theta \in \Theta_1$. En definitiva, un problema central en los contrastes de hipótesis es la construcción de

regiones críticas. En general, vemos que un test es cualquier función que asigna un valor entre 0 y 1 (interpretado como la probabilidad de rechazar H_0) a cada uno de los resultados x del espacio muestral. A continuación presentamos el lema de Neyman-Pearson (1933) que identifica el procedimiento para la construcción un test más potente en el caso de hipótesis nula simple frente a alternativa simple, es decir:

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta = \theta_1, \quad (8.15)$$

donde denotaremos por $f_0(x)$ y $f_1(x)$ a las verosimilitudes bajo cada una de las hipótesis.

Teorema 8.10 (Lema de Neyman-Pearson)

1. Cualquier test $\psi(x)$ definido de la forma

$$\psi(x) = \begin{cases} 1, & \text{si } f_1(x) > k f_0(x), \\ \gamma(x), & \text{si } f_1(x) = k f_0(x), \\ 0, & \text{si } f_1(x) < k f_0(x), \end{cases} \quad (8.16)$$

para algún $k \geq 0$ y $0 \leq \gamma(x) \leq 1$, es el más potente de su tamaño para el contraste de hipótesis nula simple frente a alternativa simple propuesto en (8.15). Además si $k = \infty$, entonces el test más potente de tamaño 0 viene dado por

$$\psi(x) = \begin{cases} 1, & \text{si } f_0(x) = 0, \\ 0, & \text{si } f_0(x) > 0, \end{cases} \quad (8.17)$$

denominado test no aleatorizado, pues acepta o rechaza la hipótesis nula con probabilidad 1 ó 0 respectivamente.

2. Dado $0 \leq \alpha \leq 1$, existe un test de la forma dada en (8.16) ó en (8.17) con $\gamma(x) = \gamma$ (constante) con tamaño α .

Además, si la familia de verosimilitudes admite un estadístico suficiente T , entonces el test de Neyman-Pearson puede escribirse en función de dicho estadístico T .

Ejemplo 8.26 Deseamos conocer la proporción ϕ de asegurados de una cartera que presentarán alguna reclamación a lo largo del presente año. Para ello se observa una muestra aleatoria simple $X_1, \dots, X_n$ de una distribución $B(1, \phi)$, es decir Bernoulli de parámetro ϕ . Realizar el contraste

$$H_0 : \phi = \phi_0 \text{ vs } \phi = \phi_1.$$

Aplicarlo al caso particular, $n = 10$, $\phi_0 = \frac{1}{2}$, $\phi_1 = \frac{3}{4}$.

Solución: De acuerdo al lema de Neyman-Pearson, debemos calcular el cociente $f_1(x)/f_0(x)$:

$$\frac{f_1(x)}{f_0(x)} = \frac{\phi_1^{n\bar{x}}(1-\phi_1)^{n-n\bar{x}}}{\phi_0^{n\bar{x}}(1-\phi_0)^{n-n\bar{x}}} = \left(\frac{\phi_1}{\phi_0}\right)^{n\bar{x}} \left(\frac{1-\phi_1}{1-\phi_0}\right)^{n-n\bar{x}},$$

siendo $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ la media muestral. Ahora bien, podemos considerar que $\phi_1 > \phi_0$ (el razonamiento es análogo para el caso $\phi_1 < \phi_0$) y en tal situación tenemos que el cociente $\lambda(x) = f_1(x)/f_0(x)$ es función creciente del argumento $n\bar{x}$ o equivalentemente del estadístico $\sum_{i=1}^n x_i$, y en consecuencia el test de tamaño α más potente tendrá la expresión,

$$\psi(x) = \begin{cases} 1, & \text{si } \sum_{i=1}^n x_i > k, \\ \gamma, & \text{si } \sum_{i=1}^n x_i = k, \\ 0, & \text{en otro caso.} \end{cases} \quad (8.18)$$

Los valores k y γ los determinaremos de la relación

$$\alpha = \Pr\left(\sum_{i=1}^n X_i > k | \phi_0\right) + \gamma \Pr\left(\sum_{i=1}^n X_i = k | \phi_0\right). \quad (8.19)$$

Ahora bien, para el caso que nos ocupa $\sum_{i=1}^n X_i \sim \mathcal{B}(n, \phi)$, y la expresión (8.19) puede escribirse como

$$\alpha = \sum_{i=k+1}^n \binom{n}{i} \phi_0^i (1-\phi_0)^{n-i} + \gamma \binom{n}{k} \phi_0^k (1-\phi_0)^{n-k} \quad (8.20)$$

Para el caso $\phi_0 > \phi_1$, el test es análogo:

$$\psi(x) = \begin{cases} 1, & \text{si } \sum_{i=1}^n x_i < k, \\ \gamma, & \text{si } \sum_{i=1}^n x_i = k, \\ 0, & \text{en otro caso.} \end{cases}$$

Para el caso propuesto, $n = 10$, $\phi_0 = 1/2$ y $\phi_1 = 3/4$, la relación (8.20) resulta

$$0,05 = \sum_{i=k+1}^{10} \binom{10}{i} \left(\frac{1}{2}\right)^{10} + \gamma \binom{10}{k} \left(\frac{1}{2}\right)^{10}$$

de donde deduciremos los valores de k y γ a través de las tablas de la distribución Binomial o de cualquier hoja de cálculo o software estadístico. Para el caso que nos ocupa en este ejemplo hemos utilizado Excel. En este caso se obtiene $k = 8$ y $\gamma = 0,89$ y por tanto el test rechazará $H_0 : \phi = 1/2$ cuando $\sum_{i=1}^{10} x_i > 8$ y no rechazará H_0 cuando sea menor o igual que 7. Rechazará también H_0 con probabilidad 0,89 cuando $\sum_{i=1}^{10} x_i = 8$.

Observemos que el procedimiento es muy intuitivo (en ambos casos, $\phi_1 > \phi_0$ ó $\phi_1 < \phi_0$), en el sentido de que sólo tenderemos a rechazar la hipótesis nula en favor de la alternativa cuando exista una clara evidencia en contra. $\diamond$

Ejemplo 8.27 Las cantidades reclamadas por una empresa aseguradora se distribuyen según una normal de media μ y varianza σ^2 . Observada una muestra aleatoria simple de tamaño n , deseamos realizar el contraste

$$H_0 : \mu = \mu_0, \sigma^2 = \sigma_0^2 \text{ vs } H_1 : \mu = \mu_1, \sigma^2 = \sigma_0^2.$$

Específicamente, para $\alpha = 0,05$ contrastar:

$$H_0 : \mu = 18, \sigma^2 = 2 \text{ vs } H_1 : \mu = 20, \sigma^2 = 2,$$

para los datos: 18,06; 17,33; 21,13; 17,98; 17,12; 16,11; 20,29; 15,95; 18,00; 17,58.

Solución: En primer lugar, al tratarse de una distribución continua tendremos un test no aleatorizado y de acuerdo al lema de Neyman-Pearson para un test de máxima potencia tendremos que realizar las comparaciones entre $f_1(x)$ y $f_0(x)$. En este caso el cociente será del tipo

$$\frac{\exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_1)^2\right\}}{\exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_0)^2\right\}} > k,$$

o equivalentemente

$$-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_1)^2 > \log k - \frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_0)^2. \quad (8.21)$$

Desarrollando (8.21) tenemos

$$(\mu_1 - \mu_0) \sum_{i=1}^n x_i + n(\mu_0^2 - \mu_1^2) > 2\sigma_0^2 \log k. \quad (8.22)$$

Si ahora suponemos que $\mu_1 > \mu_0$ se tiene que (8.22) equivale a $\bar{x} > c$, siendo c una constante a deducir que depende de $\sigma_0^2, \mu_0, \mu_1, n$ y k . Por tanto la región crítica del test será $C = \{\bar{x} > c\}$. El valor c se deduce entonces de

$$\alpha = \Pr\left(Z > \frac{c - \mu_0}{\sigma_0/\sqrt{n}}\right),$$

donde $Z \sim \mathcal{N}(0, 1)$, (ya que $\bar{X} \sim \mathcal{N}(\mu, \sigma_0/\sqrt{n})$). En general, se tiene que el valor de c se deduce de las tablas teniendo en cuenta la igualdad

$$c = \mu_0 + z_\alpha \frac{\sigma_0}{\sqrt{n}}.$$

Para el caso particular $n = 10$, $\mu_0 = 18$, $\mu_1 = 20$ y $\sigma_0^2 = 2$, tenemos $\bar{x} = 17,955$. Además el valor de c será $c = 18 + z_\alpha \sqrt{0,2} = 18,7356$, deducido de las tablas de la distribución normal estándar donde $z_{0,95} = 1,645$. En consecuencia, puesto que $\bar{x} < c$, no rechazamos la hipótesis nula.

Dado un nivel de significación o tamaño para el test, el procedimiento de Neyman-Pearson construye el test de mayor potencia con dicho nivel α . En ocasiones, este hecho de disponer de un nivel prefijado (0,05; 0,01 ó 0,001 habitualmente) ha sido criticado pues puede ocurrir, en la práctica, que un test de hipótesis sea rechazado a un nivel α_1 dado y aceptado con otro nivel $\alpha_2 < \alpha_1$. De hecho, un test estadístico $\psi(x)$ (equivalentemente su estadístico T asociado) se construye teniendo siempre presente que la distribución en el muestreo de T (bajo la hipótesis nula) $f(T|H_0)$ debe ser conocida y, en caso de que H_0 sea compuesta, la misma para todos los valores $\theta \in \Theta_0$. Además valores grandes de T nos indicarán evidencia contra H_0 . Surge así el concepto de p -valor.

Definición 8.23 (p -valor) *Observado $x = (x_1, \dots, x_n)$, denominaremos p -valor para un test de hipótesis dado, a la probabilidad (condicionada a H_0) de que en repetidas muestras, el valor del estadístico T sea mayor que el valor observado $t(x)$, esto es:*

$$p = \int_{t(x)}^{\infty} f(t|H_0) dt. \quad (8.23)$$

Observemos por tanto, que valores pequeños para p podemos interpretarlos como una fuerte evidencia para rechazar H_0 . Hoy día la mayoría de los paquetes informáticos para el análisis estadístico de datos presentan este valor para cada uno de los tests más usuales. Así el resultado de un caso particular, puede venir expresado en términos del p -valor obtenido, derivándose entonces todos los niveles de significación para los que H_0 debe ser rechazada. Se rechazará la hipótesis nula si el p -valor es menor o igual al nivel de significación adoptado por el experimentador.

Ejemplo 8.28 (Continuación ejemplo 8.26) Para el caso del ejemplo 8.26 encontrar el p -valor asociado a las observaciones muestrales dadas.

Solución: Puesto que bajo la hipótesis nula $T(X) = \sum_{i=1}^n X_i \sim \mathcal{B}(n, \phi_0)$ debemos calcular $\sum_{j=t(x)}^n \Pr(T = j)$, cantidad que se deducirá de las tablas de una distribución $\mathcal{B}(10, 1/2)$. Por ejemplo, si observamos 6 reclamaciones el p -valor se deducirá de la expresión: $\Pr(T \geq 6)$, obtenida de la distribución binomial bajo la hipótesis nula. En concreto, en este caso vale 0,37695. Luego para $\alpha = 0,37695$ sería el nivel de significación más pequeño que nos hubiera permitido rechazar la hipótesis nula. Vemos que con los tamaños usuales (0,05; 0,01; 0,001) la hipótesis nula no se rechaza.

Ejemplo 8.29 (Continuación ejemplo 8.27) Para el caso del ejemplo 8.27 encontrar el p -valor asociado a las observaciones muestrales dadas.

Solución: Puesto que bajo la hipótesis nula $T(X) = \bar{X} \sim \mathcal{N}(18, 1/5)$ debemos calcular

$$p\text{-valor} = \int_{17,955}^{\infty} \phi(t) dt = 0,54007,$$

donde $\phi(t)$ es la densidad de una distribución Normal con media 18 y varianza $1/5$ o equivalentemente $Z = \sqrt{5}(T - 18) \sim \mathcal{N}(0, 1)$, y cuyo valor 0,54007 puede deducirse de las tablas de la normal. En definitiva, $\alpha = 0,54007$ sería el nivel de significación más pequeño que nos hubiera permitido rechazar la hipótesis nula.

8.9.1. Contrastes unilaterales y bilaterales

En la práctica, junto con las hipótesis simples suelen darse situaciones como las siguientes: $H_0 : \theta \leq \theta_0$ vs $H_1 : \theta > \theta_0$, o bien $H_0 : \theta \geq \theta_0$ vs $H_1 : \theta < \theta_0$, o cualquier otra variante similar, así como contrastes del tipo $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$. Hablamos de contrastes unilaterales en la primera situación y de contrastes bilaterales en la segunda. En estas situaciones la solución dada en el lema de Neyman-Pearson tan sólo es posible en algunas situaciones particulares como veremos a continuación, ya que en general no podemos definir un test o contraste uniformemente más potente como vemos en el siguiente ejemplo.

Ejemplo 8.30 (No existencia de un contraste uniformemente más potente) Supongamos que $x = (x_1, \dots, x_n)$ constituye una muestra aleatoria simple de una población $\mathcal{N}(\mu, 1)$. En tal caso, la región crítica definida por $C_1 = \{x : \bar{x} - \mu_0 > \frac{1,282}{\sqrt{n}}\}$ define un test uniformemente más potente para el contraste $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$, con nivel de significación $\alpha = 0,10$. Análogamente, la región $C_2 = \{x : \mu_0 - \bar{x} > \frac{1,282}{\sqrt{n}}\}$ define un test uniformemente más potente para el contraste $H_0 : \mu \geq \mu_0$ vs $H_1 : \mu < \mu_0$, con el mismo nivel de significación. En consecuencia, y puesto que las regiones críticas son diferentes, se sigue que no existe un test uniformemente más potente para el contraste $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$, para esta situación.

El ejemplo 8.30 muestra que en general no existe un test bilateral para esta situación. En consecuencia, se necesita de propiedades adicionales para asegurar la existencia. Entre ellas, podemos destacar la propiedad de *insesgadez*. Un test ψ se dice insesgado si su función potencia para valores del parámetro bajo la hipótesis nula, $\theta \in \Theta_0$ es siempre menor que para valores del parámetro bajo la hipótesis alternativa, $\theta \in \Theta_1$. Es decir, si para cualquier $(\theta_0, \theta_1) \in \Theta_0 \times \Theta_1$, se tiene que: $\Pr(C_\psi|\theta_0) \leq \Pr(C_\psi|\theta_1)$.

Otra de las propiedades deseables para asegurar las buenas propiedades de un test es que su razón de verosimilitud sea monótona.

Definición 8.24 Diremos que una población muestral $f(x; \theta)$ tiene razón de verosimilitud monótona, si existe un estadístico T tal que, para cada $\theta < \theta'$ fijos, se tiene que el cociente de verosimilitudes

$$\frac{f(x; \theta')}{f(x; \theta)}$$

es función creciente del estadístico $T(x)$. Definiendo el cociente anterior como $+\infty$ cuando $f(x; \theta)$ sea nulo y $f(x; \theta')$ positivo.

Una gran parte de las distribuciones más usuales tienen razón de verosimilitud monótona. En particular, toda la familia de distribuciones exponencial uniparamétrica

$$f(x; \theta) = c(\theta)h(x) \exp[q(\theta)T(x)], \quad (8.24)$$

con $q(\theta)$ una función monótona, es monótona pues

$$\frac{f(x; \theta')}{f(x; \theta)} = \frac{c(\theta')}{c(\theta)} = \exp[(q(\theta') - q(\theta))T(x)],$$

es función creciente de T en caso de que q sea creciente y decreciente en T en caso de que q también lo sea. Para los casos de razón de verosimilitud monótona existe un resultado análogo al lema de Neyman-Pearson conocido como teorema de Karlin-Rubin.

Teorema 8.11 (Teorema de Karlin-Rubin) En las condiciones de razón de verosimilitud monótona en el estadístico $T(x)$ y cada valor de $\alpha \in (0, 1)$, para el contraste $H_0: \theta \leq \theta_0$ vs $H_1: \theta > \theta_0$ se tiene que cualquier test de la forma

$$\psi(x) = \begin{cases} 1, & \text{si } T(x) > c, \\ \gamma, & \text{si } T(x) = c, \\ 0, & \text{si } T(x) < c, \end{cases} \quad (8.25)$$

es un test de tamaño α y uniformemente de máxima potencia (con función potencia no decreciente). Además, intercambiando las desigualdades, este resultado proporciona una solución análoga al contraste dual $H_0: \theta \geq \theta_0$ vs $H_1: \theta < \theta_0$.

Ejemplo 8.31 Supongamos que el número de reclamaciones para una póliza cualquiera de una cartera dada, sigue una distribución de Poisson de parámetro λ y con una muestra aleatoria simple de tamaño n deseamos construir un test de hipótesis para el contraste: $H_0: \lambda \geq \lambda_0$ vs $H_1: \lambda < \lambda_0$. Aplicario al caso particular, $n = 10$, $\alpha = 0,05$ y $\lambda_0 = 4$ y reclamaciones observadas: 3, 7, 4, 4, 7, 1, 5, 5, 6, 2.

Solución: La familia de distribuciones Poisson tiene como razón de verosimilitud:

$$\frac{f(x; \lambda_2)}{f(x; \lambda_1)} = \exp[n(\lambda_1 - \lambda_2)] \left(\frac{\lambda_2}{\lambda_1}\right)^{T(x)},$$

siendo $T(x)$ el estadístico suficiente $\sum_{i=1}^n x_i$. Este cociente es una función creciente de T y por tanto estamos en las condiciones del teorema 8.11 y los tests de máxima potencia para el contraste propuesto tendrán la forma:

$$\psi(x) = \begin{cases} 1, & \text{si } T < c, \\ \gamma, & \text{si } T = c, \\ 0, & \text{si } T > c. \end{cases}$$

Las constantes c y γ se determinarán del tamaño de test α y de la relación $E_{\lambda_0}(\psi) = \alpha$. En este caso tendremos

$$\alpha = \exp(-n\lambda_0) \sum_{i=1}^{c-1} \frac{(n\lambda_0)^i}{i!} + \gamma \exp(-n\lambda_0) \frac{(n\lambda_0)^c}{c!}.$$

Para el caso particular que nos ocupa, se obtiene $c = 30$ y $\gamma = 0,39$, es decir,

$$\psi(x) = \begin{cases} 1, & \text{si } T < 30, \\ 0,39, & \text{si } T = 30, \\ 0, & \text{si } T > 30. \end{cases}$$

En este caso $T = \sum_{i=1}^{10} x_i = 44 > 30$ y por tanto no rechazamos la hipótesis nula. El p -valor es: $p = \Pr(T > 44) = 0,28372$.

El caso de las hipótesis bilaterales es algo más complicado. Recordemos que en el ejemplo 8.30 hemos visto que no siempre existe el test uniformemente más potente. En general para contrastes de hipótesis bilaterales del tipo:

$$H_0: \theta = \theta_0 \text{ vs } \theta \neq \theta_0,$$

o bien

$$H_0: \theta \in [\theta_1, \theta_2] \text{ vs } \theta \notin [\theta_1, \theta_2],$$

debemos recurrir a seleccionar aquel test más potente dentro de los insesgados.

Definición 8.25 (Test de hipótesis insesgado) Un test ψ de tamaño α , para el contraste $H_0: \theta \in \Theta_0$ vs $H_1: \theta \in \Theta_1$, se dice insesgado si para cualquier $\theta \in \Theta_1$ cumple que $\beta(\theta) = E_\theta(\psi) \geq \alpha$.

Esta definición de test insesgado viene a decir que para tales tests, la probabilidad de rechazar H_0 cuando es falsa es mayor que la de rechazarla cuando es cierta. En tal situación y para una familia de distribuciones exponenciales uniparamétricas puede probarse (Lehmann, 1986) que es posible construir un test de hipótesis de forma parecida a la dada en el lema de Neyman-Pearson.

Teorema 8.12 (Teorema de Lehmann) Para el caso de poblaciones muestral de tipo exponencial uniparamétrica como en (8.24) y para cada $\alpha \in (0, 1)$, consideremos un test bilateral del tipo:

$$H_0 : \theta \in \Theta_0 \text{ vs } H_1 : \theta \in \Theta_1.$$

En tal caso, existe un test de tamaño α , insesgado y uniformemente más potente de la forma

$$\psi(x) = \begin{cases} 1, & \text{si } T(x) < c_1 \text{ ó } T(x) > c_2, \\ \gamma_1 & \text{si } T(x) = c_1, \\ \gamma_2 & \text{si } T(x) = c_2, \\ 0 & \text{si } c_1 < T(x) < c_2, \end{cases} \quad (8.26)$$

donde las constantes c_1, c_2, γ_1 y γ_2 se obtienen de las igualdades:

$$E_{\theta_1}(\psi) = \alpha \quad \text{y} \quad E_{\theta_2}(\psi) = \alpha,$$

para el caso $H_0 : \theta \in [\theta_1, \theta_2]$ ó bien

$$E_{\theta_0}(\psi) = \alpha \quad \text{y} \quad E_{\theta_0}(\psi T) = \alpha E_{\theta_0}(T),$$

para el caso $H_0 : \theta = \theta_0$. Además todos los tests de la forma dada en (8.26) verificando las condiciones anteriores tienen la misma función de potencia. Por último, si la distribución del estadístico T es continua, no es necesario incluir las alternativas correspondientes a los sucesos de probabilidad nula: $\{T = c_1\}$ y $\{T = c_2\}$.

Ejemplo 8.32 (Continuación ejemplo 8.31) En el caso del ejemplo 8.31 realizar el contraste $H_0 : \lambda = 4$ vs $H_1 : \lambda \neq 4$.

Solución: Bajo la hipótesis nula $\lambda = 4$, T tiene distribución $\mathcal{P}(n\lambda_0) = \mathcal{P}(40)$, luego $\Pr(T = i) = \exp(-40) \frac{40^i}{i!}$ y $E_{\lambda=4}(T) = 40$. Así pues las condiciones para deducir c_1, c_2, γ_1 y γ_2 son:

$$0,05 = \sum_{i < c_1, i > c_2} \exp(-40) \frac{40^i}{i!} + \gamma_1 \exp(-40) \frac{40^{c_1}}{c_1!} + \gamma_2 \exp(-40) \frac{40^{c_2}}{c_2!},$$

$$2 = \sum_{i < c_1, i > c_2} i \exp(-40) \frac{40^i}{i!} + \gamma_1 c_1 \exp(-40) \frac{40^{c_1}}{c_1!} + \gamma_2 c_2 \exp(-40) \frac{40^{c_2}}{c_2!}.$$

Cualesquiera valores que cumplan estas condiciones, proporcionan un test insesgado uniformemente más potente. En el caso particular de este ejemplo, se deduce que $c_1 = 28, c_2 = 53, \gamma_1 = 0,7908$ y $\gamma_2 = 0,3865$. En este caso además, como $T = 44 \in (28, 53)$, no rechazaremos la hipótesis nula para un tamaño $\alpha = 0,05$. $\diamond$

8.9.2. Razón de verosimilitudes

Como hemos visto anteriormente el diseño de contrastes de máxima potencia no siempre es posible. A partir del procedimiento de Neyman-Pearson para hipótesis nula simple frente alternativa simple los demás procedimientos intentan en la medida de lo posible proporcionar métodos similares. En muchas situaciones prácticas necesitaremos de algún procedimiento de contraste de aplicación general. De entre estos métodos, el más importante es el conocido como *test de razón de verosimilitudes* que para el caso de hipótesis nula simple frente alternativa simple coincide con el procedimiento de Neyman-Pearson. El test de razón de verosimilitudes está diseñado para aquellas situaciones genéricas de espacio paramétrico $\Theta \subset \mathbb{R}^k (k \geq 1)$ en que deseemos realizar el contraste

$$H_0 : \theta \in \Theta_0 \text{ vs } H_1 : \theta \in \Theta_1 = \Theta - \Theta_0. \quad (8.27)$$

Definición 8.26 (Razón de verosimilitudes) Observada una muestra aleatoria simple $x = (x_1, \dots, x_n)$ de una población $f(x|\theta)$. Se denomina razón de verosimilitudes para el contraste dado en (8.27) al cociente

$$\lambda(x) = \frac{\sup_{\theta \in \Theta_0} f(x; \theta)}{\sup_{\theta \in \Theta} f(x; \theta)},$$

donde $f(x; \theta) = \prod_{i=1}^n f(x_i; \theta)$ es la función de verosimilitud.

Definición 8.27 (Test de razón de verosimilitudes) Un test de razón de verosimilitudes para el contraste en (8.27) es aquél que tiene como región crítica a $C = \{x : \lambda(x) < k\}$, es decir que rechaza H_0 cuando el cociente dado por $\lambda(x)$ toma valores menores que un valor crítico k .

La constante k se determina con el nivel de significación α que deseemos alcanzar, es decir

$$\sup_{\theta \in \Theta_0} E_{\theta}(\psi) = \sup_{\theta \in \Theta_0} \Pr(C|\theta) = \alpha.$$

Si la distribución de λ es continua es claro que se alcanza cualquier tamaño α , sin embargo, si la distribución de λ es discreta el valor exacto de α puede no alcanzarse. Esto no es problema, puesto que en general el contraste puede ser aleatorizado mediante la función test

$$\psi(x) = \begin{cases} 1, & \text{si } \lambda(x) < k, \\ \gamma, & \text{si } \lambda(x) = k, \\ 0, & \text{si } \lambda(x) > k. \end{cases}$$

La idea del contraste basado en la razón de verosimilitudes es muy intuitiva. Dada una muestra observada x , $f(x; \theta)$ representa el grado de bondad que el parámetro

θ otorga a los resultados observados. El numerador del cociente de verosimilitudes representa la "mejor explicación" de la muestra observada bajo la hipótesis nula (dicho de otra forma, la mayor verosimilitud que los datos aportan a la hipótesis nula), mientras que el denominador representa el mismo valor pero entre todos los valores posibles del parámetro.

Además las cantidades utilizadas coinciden con las verosimilitudes cuando el valor del parámetro coincide con los estimadores de máxima verosimilitud con espacios paramétricos, Θ_0 y Θ , respectivamente. Es decir: $\lambda(x) = f(x; \hat{\theta}_0)/f(x; \hat{\theta})$, siendo $\hat{\theta}_0$ y $\hat{\theta}$ los estimadores de máxima verosimilitud sobre Θ_0 y Θ , respectivamente. De esta forma, si $f(x; \hat{\theta}_0)$ es mucho menor que $f(x; \hat{\theta})$ esto indicaría que la explicación de los resultados, bajo la hipótesis de que H_0 es cierta, es mucho peor que la explicación sin esa restricción y por tanto, parece razonable rechazar H_0 . En caso contrario, esto es si $f(x; \hat{\theta}_0)$ está muy próximo a $f(x; \hat{\theta})$, entonces no tendríamos razones suficientes para rechazar H_0 pues ello no mejoraría la verosimilitud de las observaciones de forma clara.

Observemos además que para el caso de hipótesis nula simple frente a alternativa simple el test de razón de verosimilitudes coincide con el de Neyman-Pearson. En efecto, el cociente de verosimilitudes tendrá la expresión

$$\lambda(x) = \frac{f(x; \hat{\theta}_0)}{\max\{f(x; \hat{\theta}_0), f(x; \hat{\theta}_1)\}},$$

y por tanto, la comparación $\lambda < k$ (con $k < 1$) es equivalente a la comparación $f(x; \hat{\theta}_1)/f(x; \hat{\theta}_0) > c$ ($c = \frac{1}{k}$) que necesitamos en el lema de Neyman-Pearson.

Ejemplo 8.33 (Continuación ejemplo 8.26) Supongamos el caso del ejemplo 8.26 y que para una muestra de tamaño $n = 10$ se han observado 6 reclamaciones, deseamos realizar el contraste

$$H_0 : \phi \leq \frac{1}{2} \text{ vs } \phi > \frac{1}{2}.$$

Solución: Desarrollaremos el procedimiento de razón de verosimilitudes para un tamaño muestral n y un valor ϕ_0 , general. En primer lugar, observemos que $\Theta = [0, 1]$, $\Theta_0 = [0, \phi_0]$. Además, haciendo $T = \sum_{i=1}^n x_i$ (número total de reclamaciones en este caso), tenemos que la verosimilitud puede escribirse en términos de T ,

$$f(x; \phi) = f(T; \phi) = \phi^T (1 - \phi)^{n-T},$$

y por tanto, el estimador de máxima verosimilitud sobre $[0, 1]$ es $\hat{\phi} = \frac{T}{n} = \bar{x}$, y

$$\sup_{\phi \in [0, 1]} f(T; \phi) = \left(\frac{T}{n}\right)^T \left(1 - \frac{T}{n}\right)^{n-T}.$$

8.9. Contraste de hipótesis

Además la verosimilitud es función creciente para $\phi \in (0, \frac{T}{n})$ y decreciente en $(\frac{T}{n}, 1)$ y por tanto el estimador de máxima verosimilitud bajo la hipótesis nula será $\hat{\phi}_0 = \phi_0$, si $\frac{T}{n} > \phi_0$ ó $\frac{T}{n}$ si $\frac{T}{n} \leq \phi_0$. Por tanto la razón de verosimilitudes valdrá:

$$\lambda(x) = \begin{cases} \frac{\phi_0^T (1 - \phi_0)^{n-T}}{(T/n)^T (1 - T/n)^{n-T}} & \text{si } \frac{T}{n} > \phi_0, \\ 1, & \text{si } \frac{T}{n} \leq \phi_0. \end{cases}$$

Ahora bien, como $\log \lambda$ es una función decreciente en T tenemos que la desigualdad $\lambda < k$ es equivalente a $T > k'$, por tanto el test de razón de verosimilitudes (de tamaño α) tiene la forma

$$\psi(x) = \begin{cases} 1, & \text{si } T > k', \\ \gamma, & \text{si } T = k', \\ 0, & \text{si } T < k', \end{cases}$$

donde k' y γ se deducen del tamaño α mediante la relación

$$\Pr(T > k' | \phi_0) + \gamma \Pr(T = k' | \phi_0) = \alpha,$$

deducidos dichos valores del hecho de que bajo la hipótesis nula $T \sim \mathcal{B}(n, \phi_0)$. Para el caso particular, $n = 10$, $\phi_0 = 1/2$, buscaremos en la tabla de una distribución $\mathcal{B}(10, 1/2)$, donde para, por ejemplo, un tamaño $\alpha = 0,05$ se obtiene $k' = 7$ y $\gamma = 0,04$. Como en nuestro ejemplo $T = 6$, no rechazamos la hipótesis nula de que $\phi \leq 1/2$.

◇

Ejemplo 8.34 Las cantidades reclamadas por una compañía aseguradora se distribuyen según una normal $\mathcal{N}(\mu, \sigma^2)$, con σ^2 desconocida. Construir el test de razón de verosimilitudes para una muestra aleatoria simple de tamaño n con un nivel de significación α , para el contraste

$$H_0 : \mu = \mu_0 \text{ vs } H_1 : \mu \neq \mu_0.$$

Con los datos del ejemplo 8.27 realizar el contraste $H_0 : \mu = 18$ vs $\mu \neq 18$.

Solución: Ya conocemos que para una muestra aleatoria simple de una población normal con ambos parámetros desconocidos, los estimadores de máxima verosimilitud son $\hat{\mu} = \bar{x}$ y $\hat{\sigma}^2 = (1/n) \sum_{i=1}^n (x_i - \bar{x})^2$. Por tanto, $\sup_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+} f(x; \mu, \sigma^2) = (2\pi\hat{\sigma}^2)^{-n/2} e^{-n/2}$. Por otro lado, bajo la hipótesis nula $\hat{\sigma}_0^2 = (1/n) \sum_{i=1}^n (x_i - \mu_0)^2$, y en consecuencia $\sup_{(\mu, \sigma^2) \in \Theta_0} f(x; \mu, \sigma^2) = (2\pi\hat{\sigma}_0^2)^{-n/2} e^{-n/2}$. Finalmente, la razón de verosimilitudes es:

$$\lambda(x) = \left(\frac{s^2}{\hat{\sigma}_0^2}\right)^{n/2} = \left(1 + \frac{(\bar{x} - \mu_0)^2}{s^2}\right)^{-n/2}.$$

Ahora, como $\lambda(x)$ es función decreciente de $\frac{n(\bar{x}-\mu_0)^2}{\sum_{i=1}^n (x_i-\bar{x})^2}$ se tiene que rechazar H_0 cuando $\lambda(x) < k$ equivale a rechazar H_0 cuando:

$$\left| \frac{\sqrt{n}(\bar{x} - \mu_0)}{s} \right| > k'',$$

donde $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$. El estadístico $t(X) = \frac{\sqrt{n}(\bar{X} - \mu_0)}{s}$ sigue una distribución t de Student con $n-1$ grados de libertad, bajo la hipótesis nula $H_0: \mu = \mu_0$, y $t(X)$ tiene distribución Student no central con $n-1$ grados de libertad y parámetro de no centralidad $\frac{\mu - \mu_0}{\sigma}$ bajo la hipótesis alternativa $H_1: \mu \neq \mu_0$. Elegiremos por tanto $k'' = t_{n-1, \alpha/2}$ de acuerdo a la distribución de $t(X)$ bajo la hipótesis nula. Para el caso particular del ejemplo 8.27 tenemos, $n = 10$, $\bar{x} = 17,955$; $s = 1,6397$; $t(x) = 0,0868$ y $t_{9,0,025} = 2,262$, y no se rechaza la hipótesis nula. El p -valor para este caso se obtiene de:

$$p\text{-valor} = \Pr(|t_{n-1}| > |t_{obs}|) = \Pr(|t_9| > 0,0868) = 0,93272.$$

◇

Existen una gran variedad de situaciones donde es posible obtener test fáciles de obtener mediante este procedimiento de razón de verosimilitudes. Presentamos a continuación dos de los más usuales en la práctica: los t -tests y los test basados en la chi-cuadrado. El procedimiento es el mismo siempre, se trata de construir la razón de verosimilitudes y luego estudiar su monotonía para ver si una región crítica construida con la razón de verosimilitudes es equivalente a otra construida con el estadístico para el que la razón es monótona, del que conozcamos su distribución muestral.

Supongamos que deseamos realizar contrastes sobre un población Normal, $N(\mu, \sigma^2)$ y como usualmente consideramos $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ y $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$, la siguiente tabla resume los procedimientos de razón de verosimilitudes para cada una de las situaciones posibles (Rohatgi, 1976) donde se considera $t(x) = z_{obs} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ ó $t(x) = t_{obs} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$, según el caso con varianza conocida o desconocida, respectivamente.

Para el caso de tests de hipótesis para la varianza de poblaciones normales, como usualmente, denominaremos por χ_m^2 a la distribución chi-cuadrado centrada con m grados de libertad y denotaremos por $t(x) = \chi_{obs}^2 = \sum_{i=1}^n (x_i - \mu)^2 / \sigma_0^2$ o bien $\chi_{obs}^{2*} = (n-1) \frac{s^2}{\sigma_0^2}$, para el caso μ conocida o desconocida, respectivamente.

Existen otros muchos más tests que pueden obtenerse mediante este procedimiento, sin embargo, en todos ellos siempre será necesario encontrar la distribución en el muestreo del cociente de verosimilitudes o del estadístico del que es razón monótona, y esto en la práctica no siempre es posible. En tales situaciones, será conveniente disponer de resultados que nos encuentren de manera aproximada la distribución asintótica (es decir para tamaños muestrales grandes) del estadístico utilizado para el contraste. En algunos casos particulares basta con recurrir a

Tabla 8.2: Test de hipótesis para la media de poblaciones normales (p -valor entre paréntesis)

H_0	H_1	σ^2 conocida	σ^2 desconocida
		Rechazar H_0 al nivel α si	
$\mu \leq \mu_0$	$\mu > \mu_0$	$\bar{x} \geq \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha$ ($p\text{-valor} = \Pr(Z > z_{obs})$)	$\bar{x} \geq \mu_0 + \frac{s}{\sqrt{n}} t_{n-1, \alpha}$ ($p\text{-valor} = \Pr(t_{n-1} > t_{obs})$)
$\mu \geq \mu_0$	$\mu < \mu_0$	$\bar{x} \leq \mu_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha}$ ($p\text{-valor} = \Pr(Z < z_{obs})$)	$\bar{x} \leq \mu_0 + \frac{s}{\sqrt{n}} t_{n-1, 1-\alpha}$ ($p\text{-valor} = \Pr(t_{n-1} < t_{obs})$)
$\mu = \mu_0$	$\mu \neq \mu_0$	$ \bar{x} - \mu_0 \geq \frac{\sigma}{\sqrt{n}} z_{\alpha/2}$ ($p\text{-valor} = 2 \cdot \Pr(Z > z_{obs})$)	$ \bar{x} - \mu_0 \geq \frac{s}{\sqrt{n}} t_{n-1, \alpha/2}$ ($p\text{-valor} = 2 \cdot \Pr(t_{n-1} > t_{obs})$)

Tabla 8.3: Test de hipótesis para la varianza de poblaciones normales (p -valor entre paréntesis)

H_0	H_1	μ conocida	μ desconocida
		Rechazar H_0 al nivel α si	
$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$	$\sum_{i=1}^n (x_i - \mu)^2 \leq \chi_{n, 1-\alpha}^2 \cdot \sigma_0^2$ ($p\text{-valor} = \Pr(\chi_n^2 < \chi_{obs}^2)$)	$s^2 \leq \frac{\sigma_0^2}{n-1} \cdot \chi_{n-1, 1-\alpha}^2$ ($p\text{-valor} = \Pr(\chi_{n-1}^2 < \chi_{obs}^{2*})$)
$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$	$\sum_{i=1}^n (x_i - \mu)^2 \geq \chi_{n, \alpha}^2 \cdot \sigma_0^2$ ($p\text{-valor} = \Pr(\chi_n^2 > \chi_{obs}^2)$)	$s^2 \geq \frac{\sigma_0^2}{n-1} \cdot \chi_{n-1, \alpha}^2$ ($p\text{-valor} = \Pr(\chi_{n-1}^2 > \chi_{obs}^{2*})$)
$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\sum_{i=1}^n (x_i - \mu)^2 \leq \chi_{n, 1-\alpha/2}^2 \cdot \sigma_0^2$ ó $\sum_{i=1}^n (x_i - \mu)^2 \geq \chi_{n, \alpha/2}^2 \cdot \sigma_0^2$	$s^2 \leq \frac{\sigma_0^2}{n-1} \cdot \chi_{n-1, 1-\alpha/2}^2$ ó $s^2 \geq \frac{\sigma_0^2}{n-1} \cdot \chi_{n-1, \alpha/2}^2$

resultados asintóticos. Por ejemplo, en el caso de distribuciones Binomiales conocemos que el teorema de Moivre-Laplace nos asegura que cuando n tiende a infinito, la variable aleatoria $(X - np)/\sqrt{np(1-p)}$ se comporta como una distribución

$\mathcal{N}(0, 1)$. En tal caso, si disponemos de una muestra aleatoria simple $X_1, \dots, X_n$ del tipo $\mathcal{B}(1, \phi)$, tendremos que $n\bar{X} \sim \mathcal{B}(n, \phi)$ y por tanto, asintóticamente

$$\frac{n\bar{X} - n\phi}{\sqrt{n\phi(1-\phi)}} \approx \mathcal{N}(0, 1), \quad (8.28)$$

lo que permite obtener una región crítica para los distintos contrastes que podamos plantear sobre ϕ . En concreto (z_p es el percentil p de una normal estándar):

1. $H_0 : \phi = \phi_0$ vs $H_1 : \phi \neq \phi_0$. Región crítica:

$$C = \left\{ x : |\bar{x} - \phi_0| > z_{1-\alpha/2} \sqrt{\frac{\phi_0(1-\phi_0)}{n}} \right\}, \quad (8.29)$$

2. $H_0 : \phi \leq \phi_0$ vs $H_1 : \phi > \phi_0$. Región crítica:

$$C = \left\{ x : \bar{x} - \phi_0 > z_{1-\alpha} \sqrt{\frac{\phi_0(1-\phi_0)}{n}} \right\}, \quad (8.30)$$

3. $H_0 : \phi \geq \phi_0$ vs $H_1 : \phi < \phi_0$. Región crítica:

$$C = \left\{ x : \bar{x} - \phi_0 < -z_{1-\alpha} \sqrt{\frac{\phi_0(1-\phi_0)}{n}} \right\}, \quad (8.31)$$

Ejemplo 8.35 Como en el ejemplo 8.26, supongamos que deseamos conocer la proporción ϕ de asegurados de una cartera que presentará alguna reclamación a lo largo del presente año. Supongamos que en una muestra de $n = 10$ asegurados 6 han presentado reclamación y deseamos contrastar $H_0 : \phi = \phi_0$ vs $\phi \neq 1/2$, con un nivel de significación $\alpha = 0,05$.

Solución: En primer lugar, debemos notar que el contraste planteado corresponde a un test bilateral que puede ser resuelto mediante el teorema de Lehmann (teorema 8.12). Sin embargo, utilizando la anterior aproximación procederemos de forma mucho más inmediata. En efecto, de (8.29) tendremos que $z_{1-0,05/2} = 1,96$ y $\frac{1/4}{10} = \frac{1}{40}$, en consecuencia $z_{1-\alpha/2} \sqrt{\frac{\phi_0(1-\phi_0)}{n}} = 0,31$. Por tanto la región crítica viene definida por $|\bar{x} - 1/2| > 0,31$. En este caso $|\bar{x} - 1/2| = 0,1$, de donde no se rechaza la hipótesis nula $H_0 : \phi = 1/2$.

Ejemplo 8.36 (Continuación ejemplo 8.32) Realizar el test del ejemplo 8.32 utilizando la distribución asintótica de $T(X) = \sum_{i=1}^n X_i = n\bar{X}$.

8.9. Contraste de hipótesis

Solución: En efecto, para la distribución de Poisson con parámetro λ , por el teorema central del límite tendremos que cuando $n \rightarrow \infty$:

$$\frac{n\bar{X} - n\lambda}{\sqrt{n\lambda}} = \frac{\bar{X} - \lambda}{\sqrt{\lambda/n}} \approx Z \sim \mathcal{N}(0, 1).$$

Tenemos la región crítica:

$$C = \left\{ x : |\bar{x} - \lambda_0| > z_{1-\alpha/2} \sqrt{\frac{\lambda_0}{n}} \right\}.$$

Para el caso propuesto en este ejemplo, $n = 10$, $\lambda_0 = 4$, $\bar{x} = 4,4$, $z_{1-0,05/2} = 1,96$ y la región crítica viene definida por $|\bar{x} - 4| > 1,2396$. Al ser $|\bar{x} - 4| = 0,4$ no rechazamos la hipótesis nula.

No siempre es posible encontrar una aproximación normal como ocurre en los ejemplos anteriores. Sin embargo, es posible utilizar el siguiente resultado también asintótico que permite aproximar la distribución de la razón de verosimilitudes y por tanto permitirá construir una región crítica en cualquier situación para tamaños muestrales suficientemente grandes. Este resultado necesita de unas condiciones generales. Sea Θ un intervalo abierto de $\mathbb{R}$ y $f(x; \theta)$ la función de densidad poblacional que verifica:

1. Existe

$$\frac{\partial^3 \log f(x; \theta)}{\partial \theta^3}, \quad (8.32)$$

cuyo valor absoluto está acotado por una función $\kappa(x)$ que verifica: $E_\theta [\kappa(X)] \leq c$, para alguna constante c .

2.

$$E_\theta \left[\frac{\partial \log f(X; \theta)}{\partial \theta} \right] = 0, \quad E_\theta \left[\frac{1}{f(X; \theta)} \frac{\partial^2 f(X; \theta)}{\partial \theta^2} \right] = 0 \quad (8.33)$$

3.

$$i(\theta) = E_\theta \left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta} \right)^2 \right] > 0. \quad (8.34)$$

Teorema 8.13 Supongamos una población con verosimilitud $f(x; \theta)$ dependiente de un parámetro $\theta \in \mathbb{R}^k$ y deseamos realizar el contraste de la hipótesis nula dada por

$$\Theta_0 = \{ \theta \in \Theta : \theta_i = g_i(\omega_1, \dots, \omega_q) \text{ con } (\omega_1, \dots, \omega_q) \in \Omega \},$$

siendo Ω un abierto de $\mathbb{R}^q$ y g_i funciones con derivadas parciales de orden 1 continuas (es decir, la hipótesis nula indica q restricciones sobre el parámetro θ). Si se verifican las condiciones (8.32)-(8.34), entonces para cada $\theta \in \Theta_0$ se tiene que la distribución asintótica (límite en distribución) de $-2 \log \lambda(X)$ es χ^2 con $k - q$ grados de libertad.

La región crítica se define teniendo en cuenta que,

$$-2 \log \lambda(X) = 2 \log f(X; \hat{\theta}) - 2 \log f(X; \hat{\theta}_0) \approx \chi^2_{k-q}.$$

Ejemplo 8.37 (Test de Barlett) Este test permite contrastar la hipótesis nula de igualdad de varianzas en poblaciones normales cuando todos los parámetros son desconocidos. Supongamos que una compañía aseguradora tiene dos filiales y desea contrastar si existen diferencias significativas en la variabilidad de las cuantías reclamadas por sus asegurados en una misma cartera. Los datos observados para cada filial se muestran en el siguiente cuadro:

Filial 1	Filial 2
18,08	17,16
17,06	19,93
22,43	18,11
17,97	17,87
16,75	20,21
15,33	15,67
21,25	19,01
15,10	19,04
18,00	19,34
17,41	16,37
	14,96
	18,69
	19,58
	18,47
	18,89

Suponiendo que la distribución de las cuantías reclamadas es $\mathcal{N}(\mu_i, \sigma_i^2)$ ($i = 1, 2$), contrastar con nivel de significación $\alpha = 0,05$ la hipótesis nula de que ambas filiales tienen la misma variabilidad: $H_0 : \sigma_1 = \sigma_2$, frente a la alternativa de que son diferentes.

Solución: En el caso de dos poblaciones, el contraste coincide con el test clásico basado en la $\mathcal{F}$ de Snedecor. El problema se resuelve de manera general para el caso de k poblaciones, donde tendremos k distribuciones $\mathcal{N}(\mu_i, \sigma_i^2)$ con todos los parámetros desconocidos y se trata de contrastar la hipótesis nula $H_0 : \sigma_1 = \dots = \sigma_k$ frente a la alternativa de que al menos dos son diferentes. La verosimilitud asociada a las muestras aleatorias simples tomadas de cada población será

$$f(x; \mu, \sigma^2) = (2\pi)^{-n/2} \left(\prod_{i=1}^k \sigma_i^{-n_i} \right) \exp \left\{ -\frac{1}{2} \sum_{i=1}^k \frac{1}{\sigma_i^2} \left[\sum_{j=1}^{n_i} (x_{ij} - \mu_i)^2 \right] \right\}, \quad (8.35)$$

8.10. Problemas propuestos

215

donde para cada población $i = 1, \dots, k$ se han observado n_i datos x_{ij} , $j = 1, \dots, n_i$ y $n = \sum_{i=1}^k n_i$ es el número total de observaciones. Los estimadores de máxima verosimilitud globales y bajo la hipótesis nula valen respectivamente: $\hat{\mu}_i = \bar{x}_i$ y $\hat{\sigma}_i^2 = s_i^2$ con verosimilitud asociada

$$(2\pi)^{-n/2} \left(\prod_{i=1}^k s_i^{-n_i} \right) \exp \left(-\frac{n}{2} \right), \quad (8.36)$$

y, para la hipótesis nula, $\hat{\mu}_i = \bar{x}_i$ y $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^k n_i s_i^2$ con verosimilitud asociada

$$(2\pi)^{-n/2} \hat{\sigma}^{-n} \exp \left(-\frac{n}{2} \right). \quad (8.37)$$

De (8.36) y (8.37) se deduce que la razón de verosimilitudes vale $\lambda(x) = \prod_{i=1}^k s_i^{n_i} / \hat{\sigma}^n$ y por tanto:

$$-2 \log \lambda(x) = 2n \log \hat{\sigma} - 2 \sum_{i=1}^k n_i \log s_i.$$

El espacio paramétrico tiene dimensión $2k$ (cada población tiene dos parámetros desconocidos y son k poblaciones) y bajo la hipótesis nula son $k+1$ parámetros (k medias y 1 varianza común), luego $-2 \log \lambda$ tiene distribución asintótica χ^2 con $2k - (k+1) = k-1$ grados de libertad. La región crítica del test de razón de verosimilitudes viene dada por: $C = \{x : -2 \log \lambda(x) > \chi^2_{k-1, \alpha}\}$. Para el caso de las filiales del ejemplo, tenemos $k = 2$, $n_1 = 10$, $n_2 = 15$ y $\bar{x}_1 = 17,9386$; $\bar{x}_2 = 18,2215$, $s_1^2 = 5,3872$, $s_2^2 = 2,4121$ luego $\hat{\sigma}^2 = \frac{n_1 s_1^2 + n_2 s_2^2}{35} = 3,6021$; de donde $-2 \log \lambda(x) = \chi^2_{obs} = 14,7785$, valor que comparado con el valor de una χ^2 con 1 grado de libertad, $\chi^2_{1,0,05} = 3,841$, nos conduce a rechazar la hipótesis nula de igualdad de varianzas.

◇

8.10. Problemas propuestos

- Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ estimadores insesgados de un parámetro θ .
 - Probar que $\tilde{\theta} = \lambda \hat{\theta}_1 + (1-\lambda) \hat{\theta}_2$, donde $0 \leq \lambda \leq 1$ es un nuevo estimador insesgado de θ .
 - Calcular la varianza de $\tilde{\theta}$.
- Para un modelo paramétrico regular $f(x; \theta)$ demostrar que,

$$E[\ell(\theta)] = 0,$$

donde $\ell(\theta)$ representa el logaritmo de la función de verosimilitud.

3. Se han registrado los costes máximos de un siniestro a lo largo de n años, los cuales representamos por $X_1, \dots, X_n$. Se supone que dichos costes proceden de una población tipo Gumbel con función de distribución,

$$F(x; \theta) = \exp\{-\exp[-(x - \theta)]\}, \quad -\infty < x < \infty$$

donde θ es un parámetro a estimar.

- a) Probar que $\sum_{i=1}^n e^{-X_i}$ es un estadístico suficiente para la estimación de θ .
- b) Probar que el estimador de máxima verosimilitud de θ es,

$$\hat{\theta} = -\log \left(\frac{\sum_{i=1}^n e^{-X_i}}{n} \right).$$

- c) Obtener la distribución asintótica del estimador de máxima verosimilitud.

4. El ejemplo 8.35 puede extenderse al caso de comparación de proporciones en más de una población para tamaños muestrales grandes y bajo la hipótesis de independencia entre las muestras. Veamos el caso de dos poblaciones. Supongamos que $X_1, \dots, X_{n_1}$ constituye una muestra aleatoria simple de una población $B(1, \phi_1)$ y que $Y_1, \dots, Y_{n_2}$ es una muestra aleatoria simple de una población $B(1, \phi_2)$ y que el actuario está interesado en comparar las cantidades ϕ_1 y ϕ_2 . Si denotamos por $\bar{\phi} = \frac{n_1 \bar{x} + n_2 \bar{y}}{n_1 + n_2}$, probar que para cada uno de los contrastes que se proponen las regiones críticas (asintóticas mediante la distribución normal) son las siguientes:

- a) Contraste $H_0 : \phi_1 = \phi_2$ vs $H_1 : \phi_1 \neq \phi_2$, región crítica:

$$C = \left\{ |\bar{x} - \bar{y}| > z_{1-\alpha/2} \sqrt{\bar{\phi}(1-\bar{\phi}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \right\}.$$

- b) Contraste $H_0 : \phi_1 \leq \phi_2$ vs $H_1 : \phi_1 > \phi_2$, región crítica:

$$C = \left\{ \bar{x} - \bar{y} > z_{1-\alpha} \sqrt{\bar{\phi}(1-\bar{\phi}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \right\}.$$

- c) Contraste $H_0 : \phi_1 \geq \phi_2$ vs $H_1 : \phi_1 < \phi_2$, región crítica:

$$C = \left\{ \bar{x} - \bar{y} < -z_{1-\alpha} \sqrt{\bar{\phi}(1-\bar{\phi}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \right\}.$$

5. Supongamos que una empresa aseguradora dispone de dos filiales y desea contrastar si el porcentaje de reclamaciones recibidas en cada filial puede considerarse iguales o si tenemos evidencia de que en una de ellas es mayor que en otra. Los datos observados son: $n_1 = 30$ con 14 reclamaciones en la filial 1 y $n_2 = 40$ con 24 reclamaciones para la filial 2. Contrastar la hipótesis de igualdad de proporciones entre las filiales con tamaño, $\alpha = 0,05$.

Capítulo 9

Estimación, Selección y Validación de Modelos

9.1. Introducción

En este capítulo nos ocuparemos de la estimación, selección y validación de los modelos probabilísticos introducidos en los capítulos 6 y 7.

9.2. Estimación de la distribución de Poisson

Como ya vimos en el capítulo 6, la distribución de Poisson es una de las distribuciones que habitualmente se utiliza para el ajuste de datos relativos al número de reclamaciones. La función de probabilidad es,

$$\Pr(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots \quad (9.1)$$

con $\lambda > 0$. Partimos de una muestra aleatoria simple de tamaño n , $X_1, \dots, X_n$ procedente de (9.1). La función de verosimilitud es,

$$L(\lambda; \underline{X}) = \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n X_i}}{\prod_{i=1}^n X_i!}.$$

El estadístico $\sum_{i=1}^n X_i$ es suficiente minimal y completo para la estimación de λ . El estimador de máxima verosimilitud de λ es la media muestral,

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i, \quad (9.2)$$

y se trata de un estimador insesgado puesto que $E(\hat{\lambda}) = E(\bar{X}) = \mu_X = \lambda$. La varianza del estimador es,

$$\text{Var}(\hat{\lambda}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{\text{Var}(X)}{n} = \frac{\lambda}{n}.$$

Esta varianza coincide con la cota de Cramér-Rao, y por tanto $\hat{\lambda}$ es eficiente además de ser el estimador insesgado uniforme de varianza mínima de λ .

En ocasiones interesa estimar las probabilidades individuales de Poisson $g(\lambda) = \Pr(X = x) = e^{-\lambda} \lambda^x / x!$. El estimador insesgado de varianza mínima de $g(\lambda)$ es (Glasser, 1962),

$$\hat{g}(\lambda) = \binom{n\hat{\lambda}}{x} \left(\frac{1}{n}\right)^x \left(1 - \frac{1}{n}\right)^{n\hat{\lambda}-x}. \quad (9.3)$$

Una cantidad de interés en estadística actuarial es la probabilidad de que ocurra al menos un siniestro,

$$h(\lambda) = \Pr(X \geq 1) = 1 - \Pr(X = 0) = 1 - e^{-\lambda}.$$

Usando (9.3), el estimador insesgado uniforme de varianza mínima de $h(\lambda)$ es,

$$\hat{h}(\lambda) = 1 - \left(1 - \frac{1}{n}\right)^{n\hat{\lambda}}.$$

La varianza de este estimador es $e^{-2\lambda}(e^{\lambda/n} - 1)$.

9.3. Estimación de la distribución binomial negativa

Vamos a obtener estimadores de la distribución binomial negativa $BN(r, p)$ con función de probabilidad,

$$\Pr(X = x) = \binom{x+r-1}{x} p^r (1-p)^x, \quad x = 0, 1, 2, \dots \quad (9.4)$$

donde $0 < p < 1$ y $r > 0$. Comenzamos obteniendo los estimadores de momentos.

9.3.1. Estimadores de momentos

Como ya hemos visto previamente, la media y varianza de (9.4) son $E(X) = r(1-p)/p$ y $\text{Var}(X) = r(1-p)/p^2$, respectivamente. Despejando p y r y sustituyendo

9.3. Estimación de la distribución binomial negativa

los momentos poblacionales por los muestrales obtenemos los estimadores,

$$\hat{p} = \frac{\bar{X}}{S_X^2}, \quad (9.5)$$

$$\hat{r} = \frac{(\bar{X})^2}{S_X^2 - \bar{X}}, \quad (9.6)$$

donde $\bar{X}$ y S_X^2 representan, respectivamente, la media y varianza muestral. Se trata de estimadores consistentes.

9.3.2. Estimadores de máxima verosimilitud

Puesto que el parámetro r no es necesariamente un entero, vamos a comenzar obteniendo una representación de la probabilidad (9.4) en términos de la función gamma. Se verifica que,

$$\binom{x+r-1}{x} = \frac{(x+r-1)!}{x!(r-1)!} = \frac{\Gamma(x+r)}{\Gamma(r)\Gamma(x+1)}. \quad (9.7)$$

A partir de una muestra aleatoria simple de tamaño n procedente de (9.4) y teniendo en cuenta (9.7) el logaritmo de la función de verosimilitud es,

$$\begin{aligned} \ell(p, r) &= \sum_{i=1}^n \log \Gamma(X_i + r) - n \log \Gamma(r) - \sum_{i=1}^n \log \Gamma(X_i + 1) \\ &\quad + nr \log p + \sum_{i=1}^n X_i \log(1-p). \end{aligned}$$

Derivando parcialmente esta función respecto de p y r e igualando a cero estas derivadas, se obtienen las ecuaciones de verosimilitud,

$$\hat{p} = \frac{\hat{r}}{\bar{X} + \hat{r}}, \quad (9.8)$$

$$\log \hat{p} = \psi(\hat{r}) - \frac{1}{n} \sum_{i=1}^n \psi(X_i + \hat{r}), \quad (9.9)$$

donde $\psi(\cdot)$ representa la función digamma, que viene definida por,

$$\psi(z) = \frac{d}{dz} \log \Gamma(z) = \frac{\Gamma'(z)}{\Gamma(z)}. \quad (9.10)$$

Sustituyendo el valor de $\hat{p}$ de (9.8) en (9.9) se obtiene la ecuación en $\hat{r}$:

$$\log \hat{r} - \log(\bar{X} + \hat{r}) - \psi(\hat{r}) + \frac{1}{n} \sum_{i=1}^n \psi(X_i + \hat{r}) = 0. \quad (9.11)$$

La raíz de (9.11) proporciona el estimador de máxima verosimilitud de r , que puede encontrarse sin dificultad usando algún programa informático. Para obtener las varianzas de los estimadores hacemos uso de la matriz de información observada, que viene dada por,

$$J(p, r) = \begin{bmatrix} \frac{nr}{p^2(1-p)} & -\frac{n}{p} \\ -\frac{n}{p} & n\psi'(r) - \sum_{i=1}^n \psi'(x_i + r) \end{bmatrix}.$$

Finalmente, si $H = J^{-1}$ es la matriz inversa de J con elementos $H = \{h_{ij}\}$, $i, j = 1, 2$ las varianzas asintóticas de p y r son:

$$\begin{aligned} \text{Var}(\hat{p}) &\doteq h_{11}, \\ \text{Var}(\hat{r}) &\doteq h_{22}. \end{aligned}$$

9.4. Estimación de la distribución logarítmica

Veamos el problema de estimar el parámetro θ de una distribución logarítmica con función de probabilidad,

$$\Pr(X = x) = c(\theta) \frac{\theta^x}{x}, \quad x = 1, 2, \dots$$

donde $c(\theta) = -[\log(1 - \theta)]^{-1}$ y $0 < \theta < 1$. El logaritmo de la función de verosimilitud es,

$$\ell(\theta; \underline{X}) = n \log c(\theta) + \sum_{i=1}^n X_i \log \theta - \log \prod_{i=1}^n X_i. \quad (9.12)$$

La derivada primera de (9.12) es,

$$\frac{\partial \ell(\theta)}{\partial \theta} = n \frac{\partial \log c(\theta)}{\partial \theta} + \frac{1}{\theta} \sum_{i=1}^n X_i.$$

Igualando a cero la función anterior, obtenemos que el estimador de máxima verosimilitud $\hat{\theta}$ viene dado por,

$$\frac{1}{n} \sum_{i=1}^n X_i = -\frac{\hat{\theta}}{(1 - \hat{\theta}) \log(1 - \hat{\theta})}. \quad (9.13)$$

La ecuación anterior siempre tiene solución única y se debe resolver numéricamente. Con objeto de facilitar el cálculo de este estimador, la tabla 9.1 recoge valores representativos de la función $h(\theta) = -\theta/[(1 - \theta) \log(1 - \theta)]$. Para el cálculo del estimador no hay más que obtener la media muestral y buscar el valor más cercano

de $h(\theta)$ en la tabla. El estimador de máxima verosimilitud será el correspondiente valor de θ . Si el valor de la media no aparece en la tabla, el estimador de θ se puede obtener interpolando o de forma más precisa resolviendo (9.13). La varianza asintótica del estimador viene dada por,

$$\text{Var}(\hat{\theta}) \doteq -\frac{(1 - \theta)^2 \theta \log^2(1 - \theta)}{n[\theta + \log(1 - \theta)]}. \quad (9.14)$$

El estimador de momentos coincide con el de máxima verosimilitud.

Ejemplo 9.1 Durante un año, 150 pólizas de una cartera de alto riesgo dieron lugar a una media de 1,3 siniestros por asegurados y el número de siniestros declarados siempre es mayor o igual que 1. Ajustar los datos a una distribución logarítmica, y obtener un intervalo de confianza para θ al 95 %. Estimar la probabilidad de que un asegurado declare dos siniestros en un año.

Solución: Puesto que $\bar{x} = 1,3$, consultando la tabla 9.1, vemos que $\hat{\theta} = 0,4$. Usando (9.14), el intervalo de confianza para θ al 95 % es,

$$(\hat{\theta} \pm 1,96 \cdot \hat{\sigma}_{\hat{\theta}}) = (0,3068; 0,4932).$$

La probabilidad de declarar dos siniestros es,

$$\Pr(X = 2) = c(0,4) \frac{0,4^2}{2} = 0,1566.$$

◇

9.5. Estimación de la distribución log-normal

Disponemos de una muestra del coste de n siniestros $X_1, \dots, X_n$, que suponemos se distribuyen según una ley log-normal $\mathcal{LN}(\mu, \sigma^2)$ con función de densidad

$$f(x; \mu, \sigma^2) = \frac{1}{x\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{\log x - \mu}{\sigma} \right)^2 \right\}, \quad x > 0. \quad (9.15)$$

Veamos diversos estimadores para los parámetros de esta distribución.

9.5.1. Estimadores de momentos

Comenzamos suponiendo que para la estimación de μ y σ^2 disponemos únicamente de la media y la varianza muestrales $\bar{X}$ y S_X^2 . Por medio de la fórmula del coeficiente de variación es fácil obtener un estimador de momentos para σ^2 que viene dado por,

$$\hat{\sigma}^2 = \log \left[1 + \frac{S_X^2}{(\bar{X})^2} \right].$$

Tabla 9.1: Valores representativos de la función $h(\theta) = -\frac{\theta}{(1-\theta)\log(1-\theta)}$ para la estimación de máxima verosimilitud del parámetro θ de la distribución logarítmica

θ	$h(\theta)$	θ	$h(\theta)$	θ	$h(\theta)$	θ	$h(\theta)$	θ	$h(\theta)$
0,01	1,0050	0,21	1,1277	0,41	1,3170	0,61	1,6611	0,81	2,5670
0,02	1,0102	0,22	1,1352	0,42	1,3294	0,62	1,6862	0,82	2,6566
0,03	1,0154	0,23	1,1429	0,43	1,3420	0,63	1,7125	0,83	2,7553
0,04	1,0207	0,24	1,1507	0,44	1,3551	0,64	1,7401	0,84	2,8648
0,05	1,0261	0,25	1,1587	0,45	1,3686	0,65	1,7690	0,85	2,9870
0,06	1,0316	0,26	1,1669	0,46	1,3825	0,66	1,7994	0,86	3,1244
0,07	1,0372	0,27	1,1752	0,47	1,3968	0,67	1,8313	0,87	3,2802
0,08	1,0429	0,28	1,1838	0,48	1,4116	0,68	1,8650	0,88	3,4587
0,09	1,0487	0,29	1,1926	0,49	1,4269	0,69	1,9005	0,89	3,6656
0,10	1,0546	0,30	1,2016	0,50	1,4427	0,70	1,9380	0,90	3,9087
0,11	1,0606	0,31	1,2108	0,51	1,4591	0,71	1,9778	0,91	4,1991
0,12	1,0667	0,32	1,2202	0,52	1,4760	0,72	2,0200	0,92	4,5531
0,13	1,0730	0,33	1,2299	0,53	1,4935	0,73	2,0649	0,93	4,9960
0,14	1,0794	0,34	1,2398	0,54	1,5117	0,74	2,1128	0,94	5,5686
0,15	1,0858	0,35	1,2500	0,55	1,5306	0,75	2,1640	0,95	6,3424
0,16	1,0925	0,36	1,2604	0,56	1,5503	0,76	2,2189	0,96	7,4560
0,17	1,0992	0,37	1,2711	0,57	1,5706	0,77	2,2779	0,97	9,2208
0,18	1,1061	0,38	1,2821	0,58	1,5919	0,78	2,3416	0,98	12,5255
0,19	1,1132	0,39	1,2934	0,59	1,6140	0,79	2,4105	0,99	21,4976
0,20	1,1204	0,40	1,3051	0,60	1,6370	0,80	2,4853	0,999	144,6201

A continuación, usando la fórmula de la media de la distribución log-normal obtenemos la segunda fórmula que nos permite estimar μ :

$$\hat{\mu} = \log \bar{X} - \frac{\hat{\sigma}^2}{2}.$$

A pesar de tratarse de estimadores consistentes, la eficiencia es baja y sólo deberían utilizarse cuando no existe más información que la de los dos primeros momentos.

9.5.2. Estimadores de máxima verosimilitud

Su similitud con la distribución normal hace que la estimación máximo verosímil no presente dificultades. La función de verosimilitud basada en una muestra de n observaciones es,

$$L(\mu, \sigma^2; \underline{X}) = \sigma^{-n} (2\pi)^{-n/2} \left(\prod_{i=1}^n X_i^{-1} \right) \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \left(\frac{\log X_i - \mu}{\sigma} \right)^2 \right\}.$$

9.6. Estimación de la distribución gamma

Los estimadores de máxima verosimilitud son,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \log X_i, \quad (9.16)$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (\log X_i - \hat{\mu})^2. \quad (9.17)$$

La matriz de información de Fisher basada en n observaciones es,

$$I(\mu, \sigma^2) = \begin{bmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^2} \end{bmatrix}.$$

Por tanto, la distribución log-normal con la parametrización (9.15) da lugar a parámetros ortogonales (es decir, con covarianza asintótica igual a cero). El estimador de μ es insesgado y de varianza mínima. El estimador insesgado uniforme de varianza mínima de σ^2 es,

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (\log X_i - \hat{\mu})^2.$$

Si queremos estimar una función de los dos parámetros $g(\mu, \sigma^2)$, por el principio de invarianza el estimador de máxima verosimilitud es $g(\hat{\mu}, \hat{\sigma}^2)$ con varianza asintótica,

$$\text{Var}[g(\hat{\mu}, \hat{\sigma}^2)] = \left(\frac{\partial g}{\partial \mu} \right)^2 \frac{\sigma^2}{n} + \left(\frac{\partial g}{\partial \sigma^2} \right)^2 \frac{2\sigma^4}{n},$$

puesto que se trata de parámetros ortogonales.

9.6. Estimación de la distribución gamma

Supongamos elegida una muestra aleatoria simple $X_1, \dots, X_n$ procedente de una distribución gamma $\mathcal{G}(\alpha, \sigma)$ con función de densidad,

$$f(x; \alpha, \sigma) = \frac{1}{\sigma^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\sigma}, \quad x > 0, \quad (9.18)$$

donde $\alpha, \sigma > 0$.

9.6.1. Estimadores de momentos

Para la estimación de α y σ usaremos la media y varianza que vienen dadas por,

$$E(X) = \alpha\sigma, \quad (9.19)$$

$$\text{Var}(X) = \alpha\sigma^2. \quad (9.20)$$

Si en (9.19)-(9.20) despejamos σ obtenemos $\sigma = \text{Var}(X)/E(X)$, de donde $\alpha = E^2(X)/\text{Var}(X)$. Sustituyendo los momentos poblacionales por las versiones muestrales se obtienen los estimadores de momentos,

$$\hat{\alpha} = \frac{(\bar{X})^2}{S_X^2},$$

$$\hat{\sigma} = \frac{S_X^2}{\bar{X}},$$

donde $\bar{X}$ y S_X^2 representan, respectivamente, la media y varianza muestral. Se trata de estimadores consistentes.

9.6.2. Estimadores de máxima verosimilitud

La función de verosimilitud de (9.18) viene dada por,

$$L(\alpha, \sigma; \underline{X}) = \frac{1}{\sigma^{n\alpha} [\Gamma(\alpha)]^n} \left(\prod_{i=1}^n X_i \right)^{\alpha-1} \exp \left(- \sum_{i=1}^n X_i / \sigma \right).$$

Observemos que $(\prod_{i=1}^n X_i, \sum_{i=1}^n X_i)$ son estadísticos suficientes para la estimación de (α, σ) y por tanto contienen toda la información de la muestra. El logaritmo de la función de verosimilitud es,

$$\ell(\alpha, \sigma) = -n\alpha \log \sigma - n \log \Gamma(\alpha) + (\alpha - 1) \sum_{i=1}^n \log X_i - \frac{1}{\sigma} \sum_{i=1}^n X_i. \quad (9.21)$$

Las ecuaciones de verosimilitud vienen dadas por,

$$\frac{1}{n} \sum_{i=1}^n \log X_i = \log \sigma + \psi(\alpha),$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \alpha \sigma,$$

donde $\psi(\cdot)$ representa la función digamma definida en (9.10). Si despejamos σ en la segunda ecuación y la sustituimos en la primera obtenemos la ecuación,

$$\log(\bar{X}/G) = \log \alpha - \psi(\alpha),$$

que únicamente depende de α y donde $G = (\prod_{i=1}^n X_i)^{1/n}$ es la media geométrica. El lado derecho de esta ecuación es decreciente en α y por tanto tiene solución única, que se obtiene fácilmente mediante un algoritmo iterativo (como el de

9.7. Estimación de la distribución Pareto tipo I

Newton-Raphson). Una vez obtenido el estimador de α , el estimador de σ viene dado por,

$$\hat{\sigma} = \frac{\bar{X}}{\hat{\alpha}}.$$

Si calculamos las derivadas segundas de (9.21) y tomamos esperanzas, obtenemos la matriz de información de Fisher, que viene dada por (basada en una muestra de tamaño n):

$$I(\alpha, \sigma) = n \begin{bmatrix} \psi'(\alpha) & 1/\sigma \\ 1/\sigma & \alpha/\sigma^2 \end{bmatrix}.$$

Mediante esta matriz, las varianzas y covarianzas asintóticas de los estimadores de máxima verosimilitud de α y σ vienen dadas por,

$$\text{Var}(\hat{\alpha}) \doteq \frac{\alpha}{n[\alpha\psi'(\alpha) - 1]},$$

$$\text{Var}(\hat{\sigma}) \doteq \frac{\sigma^2\psi'(\alpha)}{n[\alpha\psi'(\alpha) - 1]},$$

$$\text{Cov}(\hat{\alpha}, \hat{\sigma}) \doteq \frac{-\sigma}{n[\alpha\psi'(\alpha) - 1]}.$$

Si queremos estimar una cantidad $g(\alpha, \sigma)$ que depende de los dos parámetros, el estimador de máxima verosimilitud viene dado por,

$$\hat{g}(\alpha, \sigma) = g(\hat{\alpha}, \hat{\sigma}).$$

Usando el delta-método, la varianza asintótica de g se obtiene mediante la fórmula,

$$\text{Var}[\hat{g}(\alpha, \sigma)] = \left(\frac{\partial g}{\partial \alpha} \right)^2 \text{Var}(\hat{\alpha}) + \left(\frac{\partial g}{\partial \sigma} \right)^2 \text{Var}(\hat{\sigma}) + 2 \left(\frac{\partial g}{\partial \alpha} \right) \left(\frac{\partial g}{\partial \sigma} \right) \text{Cov}(\hat{\alpha}, \hat{\sigma}),$$

donde las derivadas parciales se evalúan en los estimadores de máxima verosimilitud.

9.7. Estimación de la distribución Pareto tipo I

Supongamos elegida una muestra aleatoria simple $X_1, \dots, X_n$ procedente de una población de Pareto tipo I, $Pal(\alpha, \sigma)$ con función de distribución,

$$F(x; \alpha, \sigma) = 1 - \left(\frac{x}{\sigma} \right)^{-\alpha}, \quad x \geq \sigma, \quad (9.22)$$

y función de densidad

$$f(x; \alpha, \sigma) = \alpha \sigma^\alpha x^{-(\alpha+1)}, \quad x \geq \sigma, \quad (9.23)$$

donde $\alpha, \sigma > 0$.

9.7.1. Estimadores de mínimos cuadrados

Los estimadores de mínimos cuadrados se basan en el hecho de que el logaritmo de la función de supervivencia es lineal en α , es decir,

$$\log[1 - F(x)] = \alpha \log \sigma - \alpha \log x.$$

Ahora, aplicando el criterio de mínimos cuadrados, el estimador de α viene dado por,

$$\hat{\alpha} = \frac{-\frac{1}{n} \sum_{i=1}^n \log X_i \log[1 - F(X_i)] + \left(\frac{1}{n} \sum_{i=1}^n \log X_i\right) \left(\frac{1}{n} \sum_{i=1}^n \log[1 - F(X_i)]\right)}{\frac{1}{n} \sum_{i=1}^n (\log X_i)^2 - \left(\frac{1}{n} \sum_{i=1}^n \log X_i\right)^2},$$

mientras que el estimador de σ es,

$$\hat{\sigma} = \exp \left\{ \frac{1}{n\hat{\alpha}} \sum_{i=1}^n \log[1 - F(X_i)] + \frac{1}{n} \sum_{i=1}^n \log X_i \right\}.$$

Se trata de estimadores consistentes.

9.7.2. Estimadores de momentos

Para la estimación de momentos de α y σ usaremos la media de la muestra junto con la media de la distribución del mínimo. Si $\alpha > 1$, entonces $E(X) = \alpha\sigma/(\alpha-1)$ y despejando α es esta ecuación y sustituyendo la media poblacional por la muestral, obtenemos una estimación de α ,

$$\hat{\alpha} = \frac{\bar{X}}{\bar{X} - \hat{\sigma}}. \quad (9.24)$$

Para obtener una segunda ecuación puesto que $X_{1:n} = \min\{X_1, \dots, X_n\}$ se distribuye según una $\text{PaI}(\alpha n, \sigma)$, tenemos que $E(X_{1:n}) = \alpha n \sigma / (\alpha n - 1)$. Si despejamos σ en esta relación obtenemos,

$$\hat{\sigma} = \frac{(\hat{\alpha} n - 1) X_{1:n}}{\hat{\alpha} n}. \quad (9.25)$$

Finalmente, si sustituimos (9.25) en (9.24) obtenemos el estimador,

$$\hat{\alpha} = \frac{n\bar{X} - X_{1:n}}{n(\bar{X} - X_{1:n})}. \quad (9.26)$$

Los estimadores de momentos son por tanto (9.25) y (9.26) que son estimadores consistentes.

9.7. Estimación de la distribución Pareto tipo I

9.7.3. Estimadores de máxima verosimilitud

La función de verosimilitud correspondiente a (9.23) toma la forma,

$$L(\alpha, \sigma; \underline{X}) = \alpha^n \sigma^{n\alpha} \left(\prod_{i=1}^n X_i \right)^{-(\alpha+1)}, \quad \sigma \leq X_{1:n},$$

donde $X_{1:n} = \min\{X_1, \dots, X_n\}$ es el valor mínimo de la muestra. El estadístico suficiente, minimal y completo para (α, σ) es $(\prod_{i=1}^n X_i, X_{1:n})$. Para obtener el máximo consideramos el logaritmo de la función de verosimilitud que viene dado por,

$$\ell(\alpha, \sigma) = n \log \alpha + n\alpha \log \sigma - (\alpha + 1) \sum_{i=1}^n \log X_i,$$

si $\sigma \leq X_{1:n}$. Si α es fijo, la función anterior alcanza el máximo cuando σ es igual a $X_{1:n}$. A continuación, derivando respecto a α , igualando a cero y despejando obtenemos el valor de α que hace máxima la verosimilitud. Por tanto, los estimadores de máxima verosimilitud son,

$$\begin{aligned} \hat{\alpha} &= \left[\frac{1}{n} \sum_{i=1}^n \log(X_i / X_{1:n}) \right]^{-1}, \\ \hat{\sigma} &= X_{1:n}. \end{aligned}$$

Los estimadores de máxima verosimilitud son consistentes y fuertemente consistentes (es decir, se verifica la convergencia casi-seguro), puesto que,

$$X_{1:n} \xrightarrow{c.s.} \sigma,$$

y por la ley fuerte de los grandes números,

$$\frac{1}{n} \sum_{i=1}^n \log X_i \xrightarrow{c.s.} \log \sigma + 1/\alpha.$$

Para obtener las propiedades de estos estimadores necesitamos sus distribuciones en el muestreo. Se verifica que,

$$\frac{2\hat{\alpha}n}{\hat{\alpha}} \sim \chi_{2n-2}^2, \quad (9.27)$$

$$\hat{\sigma} \sim \text{PaI}(n\hat{\alpha}, \sigma). \quad (9.28)$$

Usando (9.27) un intervalo de confianza para α con un nivel de confianza de $1 - \alpha'$ ($0 < \alpha' < 1$) viene dado por,

$$\left(\frac{\hat{\alpha} \chi_{2n-2; \alpha'/2}^2}{2n}, \frac{\hat{\alpha} \chi_{2n-2; 1-\alpha'/2}^2}{2n} \right),$$

donde $\chi^2_{m;p}$ es el percentil de orden p de una distribución chi-cuadrado con m grados de libertad. Se cumple que $\hat{\alpha}$ y $\hat{\sigma}$ son variables aleatorias independientes (Malik, 1970). A partir de (9.27)-(9.28) se verifica que,

$$\begin{aligned} E(\hat{\alpha}) &= \frac{\alpha n}{n-2}, \\ \text{Var}(\hat{\alpha}) &= \frac{\alpha^2 n^2}{(n-2)^2(n-3)}, \\ E(\hat{\sigma}) &= \sigma \left(1 - \frac{1}{\alpha n}\right)^{-1}, \\ \text{Var}(\hat{\sigma}) &= \frac{n\alpha\sigma^2}{(n\alpha-1)^2(n\alpha-2)}. \end{aligned}$$

Es evidente que se trata de estimadores sesgados y consistentes. Por ejemplo, el estimador de σ siempre sobre-estima el parámetro. La versión insesgada de $\hat{\alpha}$ es,

$$\hat{\alpha}_{EMVI} = \left(1 - \frac{2}{n}\right) \hat{\alpha}, \quad (9.29)$$

con varianza,

$$\text{Var}(\hat{\alpha}_{EMVI}) = \frac{\alpha^2}{n-3}.$$

Ahora, la versión insesgada de $\hat{\sigma}$ es,

$$\hat{\sigma}_{EMVI} = \left[1 - \frac{1}{(n-1)\hat{\alpha}}\right] \hat{\sigma}, \quad (9.30)$$

con varianza ($n > 2/\alpha$),

$$\text{Var}(\hat{\sigma}_{EMVI}) = \frac{\sigma^2}{\alpha(n-1)(n\alpha-2)}.$$

Finalmente, puesto que (9.29) y (9.30) son estimadores insesgados y función de los estimadores de máxima verosimilitud que son completos, se trata por tanto de los estimadores insesgados uniformes de varianza mínima.

9.7.4. Estimadores por el método de los percentiles

Supongamos que disponemos de dos percentiles x_{p_1} y x_{p_2} con $0 < p_1 < p_2 < 1$ de la distribución de Pareto tipo I, o bien los calculamos a partir de los datos por medio de la función de distribución empírica. Los estimadores de α y σ son la solución de las ecuaciones,

$$F(x_{p_I}; \hat{\alpha}, \hat{\sigma}) = p_I, \quad I \in \{1, 2\}, \quad (9.31)$$

9.7. Estimación de la distribución Pareto tipo I

donde $F(\cdot; \alpha, \sigma)$ viene definida por (9.22). Resolviendo (9.31) obtenemos los estimadores,

$$\hat{\alpha} = \frac{\log(1-p_2) - \log(1-p_1)}{\log x_{p_1} - \log x_{p_2}}, \quad (9.32)$$

$$\hat{\sigma} = x_{p_1}(1-p_1)^{1/\hat{\alpha}}. \quad (9.33)$$

Ejemplo 9.2 Se ha elegido una muestra de reclamaciones de una cartera cuya distribución es de tipo Pareto I. Se sabe que el 10 por ciento de las reclamaciones excede los 1000 euros, mientras que el 80 por ciento excede los 200 euros. Obtener los estimadores de α y σ por el método de los percentiles. Estimar la proporción de siniestros de la cartera cuya cuantía supera los 1800 euros.

Solución: Disponemos de los percentiles de orden $p_1 = 0,2$ y $p_2 = 0,9$. Usando (9.32) y (9.33) tenemos,

$$\hat{\alpha} = \frac{\log(1-0,9) - \log(1-0,2)}{\log 200 - \log 1000} = 1,2920,$$

$$\hat{\sigma} = 200 \cdot (1-0,2)^{1/\hat{\alpha}} = 168,277.$$

La estimación de la probabilidad es,

$$\Pr(X > 1800) = \left(\frac{1800}{\hat{\sigma}}\right)^{-\hat{\alpha}} = 0,0468.$$

◇

9.7.5. Estimación con σ conocido

Para terminar la estimación de la distribución de Pareto I veamos el caso en que el parámetro de escala σ es conocido. En este caso el estimador de máxima verosimilitud es,

$$\hat{\alpha} = \left[\frac{1}{n} \sum_{i=1}^n \log(X_i/\sigma) \right]^{-1}, \quad (9.34)$$

y se trata de un estimador suficiente y completo. Se verifica que,

$$\frac{2n\alpha}{\hat{\alpha}} \sim \chi^2_{2n},$$

lo que permite obtener la media, varianza y estimadores por intervalo para el parámetro α . Se verifica que,

$$\left(\frac{\hat{\alpha} \chi^2_{2n; \alpha'/2}}{2n}, \frac{\hat{\alpha} \chi^2_{2n; 1-\alpha'/2}}{2n} \right),$$

es un intervalo de confianza para α de nivel $1 - \alpha'$, con $0 < \alpha' < 1$, donde $\chi^2_{m;p}$ es el percentil de orden p de una distribución chi-cuadrado con m grados de libertad. Se cumple que,

$$\begin{aligned} E(\hat{\alpha}) &= \frac{n\alpha}{n-1}, \\ \text{Var}(\hat{\alpha}) &= \frac{n^2\alpha^2}{(n-1)^2(n-2)}. \end{aligned}$$

El estimador de máxima verosimilitud es nuevamente sesgado. La versión insesgada de este estimador es,

$$\hat{\alpha}_{IMV} = \left(1 - \frac{1}{n}\right) \hat{\alpha}, \quad (9.35)$$

con varianza,

$$\text{Var}(\hat{\alpha}_{IMV}) = \frac{\alpha^2}{n-2}.$$

Puesto que (9.35) es insesgado y función de (9.34), se trata del estimador insesgado uniforme de varianza mínima de α .

9.8. Distribución de Pareto tipo II

La distribución de Pareto tipo II con función de distribución,

$$F(x; \alpha, \sigma) = 1 - \frac{1}{(1 + x/\sigma)^\alpha}, \quad x > 0, \quad (9.36)$$

es de uso habitual en estadística actuarial. Veamos cómo se estiman los parámetros α y σ por el método de los momentos y por máxima verosimilitud.

9.8.1. Estimadores de momentos

Los estimadores de momentos se obtienen igualando los dos primeros momentos muestrales a los correspondientes teóricos ($\alpha > 2$),

$$\begin{aligned} m_1 &= \frac{1}{n} \sum_{i=1}^n X_i = \frac{\sigma}{\alpha-1}, \\ m_2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{2\sigma^2}{(\alpha-1)(\alpha-2)}. \end{aligned}$$

La solución de este sistema de dos ecuaciones da lugar a los estimadores,

$$\hat{\alpha} = \frac{2(m_2 - m_1^2)}{m_2 - 2m_1^2}, \quad (9.37)$$

$$\hat{\sigma} = \frac{m_1 m_2}{m_2 - 2m_1^2}, \quad (9.38)$$

9.9. Estimación de la distribución inversa Gaussiana

válidos siempre que $m_2 > 2m_1^2$.

9.8.2. Estimadores de máxima verosimilitud

La función de verosimilitud de (9.36) basada en una muestra de n datos es,

$$L(\alpha, \sigma; \underline{X}) = \alpha^n \sigma^{-n} \prod_{i=1}^n (1 + X_i/\sigma)^{-(\alpha+1)}.$$

Los estimadores de máxima verosimilitud se obtienen resolviendo el sistema de ecuaciones,

$$\begin{aligned} \hat{\alpha}^{-1} &= \frac{1}{n} \sum_{i=1}^n \log(1 + X_i/\hat{\sigma}), \\ \hat{\sigma} &= \frac{\hat{\alpha} + 1}{n} \sum_{i=1}^n \frac{X_i}{1 + X_i/\hat{\sigma}}. \end{aligned}$$

La solución de estas ecuaciones se puede obtener fácilmente mediante aproximaciones sucesivas, comenzando con los estimadores de momentos dados en (9.37) y (9.38). La distribución de Pareto es una familia regular, de donde los estimadores de máxima verosimilitud son asintóticamente normales con distribución asintótica,

$$\sqrt{n}((\hat{\alpha}, \hat{\sigma}) - (\alpha, \sigma)) \xrightarrow{D} \mathcal{N}_2(\underline{0}, I^{-1}(\alpha, \sigma)),$$

con $\underline{0} = (0, 0)'$ y donde la matriz de información de Fisher es,

$$I(\alpha, \sigma) = \begin{bmatrix} \frac{1}{\alpha^2} & -\frac{1}{(\alpha+1)\sigma} \\ -\frac{1}{(\alpha+1)\sigma} & \frac{\alpha}{(\alpha+2)\sigma^2} \end{bmatrix}.$$

9.9. Estimación de la distribución inversa Gaussiana

Para la estimación de la distribución inversa Gaussiana resulta más conveniente usar la parametrización $\mathcal{IG}(\mu, \phi\mu)$ con función de densidad

$$f(x; \mu, \phi) = \left(\frac{\mu\phi}{2\pi x^3}\right)^{1/2} e^{\phi} \exp\left\{-\frac{1}{2}\phi\left(\frac{x}{\mu} + \frac{\mu}{x}\right)\right\}, \quad x > 0. \quad (9.39)$$

Si X tiene como función de densidad (9.39) entonces $E(X) = \mu$ y $\text{Var}(X) = \mu^2/\phi$.

9.9.1. Estimadores de momentos

Usando los dos primeros momentos muestrales se obtienen los estimadores de momentos,

$$\begin{aligned}\hat{\mu} &= \bar{X}, \\ \hat{\phi} &= \frac{(\bar{X})^2}{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.\end{aligned}$$

Observemos que $1/\hat{\phi}$ es el cuadrado del coeficiente de variación. La varianza de $\hat{\mu}$ es,

$$\text{Var}(\hat{\mu}) = \frac{\mu^2/\phi}{n}, \quad (9.40)$$

que es exacta, mientras que la varianza asintótica de $\hat{\phi}$ es,

$$\text{Var}(\hat{\phi}) \doteq \frac{10\phi^2 + 19\phi}{n}.$$

9.9.2. Estimadores de máxima verosimilitud

A partir de una muestra de n observaciones, los estimadores de máxima verosimilitud de μ y ϕ son,

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}, \quad (9.41)$$

$$\hat{\phi} = \frac{1}{\frac{1}{n^2} \sum_{i=1}^n X_i \sum_{i=1}^n X_i^{-1} - 1}. \quad (9.42)$$

La varianza de (9.41) es (9.40) mientras que la varianza asintótica de (9.42) es:

$$\text{Var}(\hat{\phi}) \doteq \frac{2\phi^2 + \phi}{n},$$

y $\text{Corr}(\hat{\mu}, \hat{\phi}) \doteq -(1 + 2\phi^2)^{-1/2}$.

9.10. Estimación de las distribuciones de extremos

La estimación general de las distribuciones de extremos (tanto en las versiones para valores mínimos como para máximos) requieren un tratamiento que está fuera

del alcance de este texto. Nos ocuparemos de la estimación con observaciones completas de las distribuciones de Weibull y de Gumbel, por su mayor aplicación en datos de pérdidas. Un estudio general de estas distribuciones puede encontrarse en Castillo, Hadi, Balakrishnan y Sarabia (2005) y Johnson, Kotz y Balakrishnan (1994 y 1995).

9.10.1. Estimación de la distribución de Weibull

Supongamos disponibles n observaciones procedentes de una distribución de Weibull con función de distribución,

$$F(x; \alpha, \sigma) = 1 - \exp[-(x/\sigma)^\alpha], \quad x > 0,$$

con $\alpha, \sigma > 0$. El estimador de momentos de α puede obtenerse como solución de la ecuación,

$$\frac{S_X^2}{(\bar{X})^2} = \frac{\Gamma(1 + 2/\alpha)}{\Gamma(1 + 1/\alpha)} - 1. \quad (9.43)$$

Puesto que σ es una parámetro de escala, se ha utilizado el coeficiente de variación. Una vez obtenido el estimador de α , el estimador de momentos de σ es,

$$\hat{\sigma} = \frac{\bar{X}}{\Gamma(1 + 1/\hat{\alpha})}. \quad (9.44)$$

Los estimadores (9.43) y (9.44) sólo deben usarse cuando no se dispone de más información que los dos primeros momentos o también como valores iniciales para el cálculo de los estimadores de máxima verosimilitud. La función de verosimilitud basada en una muestra completa de n observaciones es,

$$L(\alpha, \sigma; \underline{X}) = \alpha^n \sigma^{-n\alpha} \left(\prod_{i=1}^n X_i^{\alpha-1} \right) \exp \left(-\sigma^{-\alpha} \sum_{i=1}^n X_i^\alpha \right).$$

Los estimadores de máxima verosimilitud de α y σ satisfacen las ecuaciones,

$$\hat{\sigma} = \left(\frac{1}{n} \sum_{i=1}^n X_i^{\hat{\alpha}} \right)^{1/\hat{\alpha}}, \quad (9.45)$$

y

$$\frac{1}{\hat{\alpha}} - \frac{\sum_{i=1}^n X_i^{\hat{\alpha}} \log X_i}{\sum_{i=1}^n X_i^{\hat{\alpha}}} + \frac{1}{n} \sum_{i=1}^n \log X_i = 0. \quad (9.46)$$

Una vez obtenido el estimador de α resolviendo (9.46), se sustituye en (9.45) para obtener el estimador de σ . Si los estimadores de máxima verosimilitud son

regulares, las varianzas y correlaciones asintóticas vienen dadas por (Dubey, 1965),

$$\begin{aligned} n\text{Var}(\hat{\alpha}) &\doteq \frac{6\alpha^2}{\pi^2} = 0,608\alpha, \\ n\text{Var}(\hat{\sigma}) &\doteq 1,109 \left(\frac{\sigma}{\alpha}\right)^2, \\ \text{Corr}(\hat{\alpha}, \hat{\sigma}) &\doteq 0,313. \end{aligned}$$

donde n debe ser grande.

9.10.2. Estimación de la distribución de Gumbel

Veamos la estimación de los parámetros de una distribución de Gumbel (en la versión para máximos) con función de distribución,

$$F(x; \mu, \sigma) = \exp \left[-\exp \left(-\frac{x - \mu}{\sigma} \right) \right], \quad -\infty < x < \infty,$$

con $\sigma > 0$ y $\mu \in \mathbb{R}$. Usando las expresiones de la media y varianza de la población, se obtienen los estimadores de momentos:

$$\begin{aligned} \hat{\mu} &= \bar{X} - \gamma \hat{\sigma}, \\ \hat{\sigma} &= \frac{\sqrt{6}}{\pi} S_X, \end{aligned}$$

donde $\gamma = 0,57722 \dots$ es la constante de Euler. Las varianzas asintóticas de estos estimadores son (Tiago de Oliveira, 1963):

$$\begin{aligned} \text{Var}(\hat{\mu}) &\doteq \frac{1,1678\sigma^2}{n}, \\ \text{Var}(\hat{\sigma}) &\doteq \frac{1,1\sigma^2}{n}. \end{aligned}$$

La función de verosimilitud de una muestra de n observaciones es,

$$L(\mu, \sigma; \underline{X}) = \sigma^{-n} \exp \left[-\sum_{i=1}^n \frac{X_i - \mu}{\sigma} - \sum_{i=1}^n \exp \left(-\frac{X_i - \mu}{\sigma} \right) \right].$$

Los estimadores de máxima verosimilitud verifican las ecuaciones,

$$\hat{\mu} = -\hat{\sigma} \log \left(\frac{1}{n} \sum_{i=1}^n e^{-X_i/\hat{\sigma}} \right) \quad (9.47)$$

$$\hat{\sigma} = \bar{X} - \frac{\sum_{i=1}^n X_i e^{-X_i/\hat{\sigma}}}{\sum_{i=1}^n e^{-X_i/\hat{\sigma}}}. \quad (9.48)$$

y

En primer lugar se tiene que resolver (9.48) mediante algún método iterativo. Una vez obtenido el estimador de σ , se sustituye en (9.47) y se tiene el estimador de μ . Las varianzas asintóticas de $\hat{\mu}$ y $\hat{\sigma}$ vienen dadas por las cotas de Cramér-Rao, que son:

$$\begin{aligned} \frac{[1 + 6(1 - \gamma)^2/\pi^2]\sigma^2}{n} &= \frac{1,10867\sigma^2}{n}, \\ \frac{6\sigma^2/\pi^2}{n} &= \frac{0,60793\sigma^2}{n}, \end{aligned}$$

respectivamente.

9.11. Selección y validación de modelos

Los tests de hipótesis constituyen una importante herramienta para la selección y validación de los distintos modelos que puedan ajustar bien los datos disponibles. Resulta interesante disponer de herramientas que nos permitan seleccionar algún modelo de entre aquellos válidos bajo algún criterio. Habitualmente, suele construirse un ranking de todos aquellos modelos que ajustan bien y entonces seleccionar aquel que ocupa el primer puesto.

En primer lugar, el caso de la aceptabilidad de un modelo dado, o sea, su validación como modelo que representa de manera adecuada los datos observados, puede ser expresado en términos de un test de hipótesis:

$$H_0 : f(x) = f(x; \theta) \quad \exists \theta \in \Theta \quad \text{vs} \quad H_1 : f(x) \neq f(x; \theta) \quad \forall \theta \in \Theta,$$

donde $f(x)$ es la densidad poblacional y $f(x; \theta)$ es la densidad seleccionada de una familia paramétrica de densidades.

Para la situación anterior suele ser habitual, en primer lugar, realizar un análisis descriptivo de los datos y además pueden obtenerse algunas aproximaciones de carácter exploratorio que pueden resultar de gran utilidad. De entre los más conocidos, destacamos los gráficos $Q-Q$ "plot" (gráfico cuantil-cuantil) y $P-P$ "plot" (gráfico probabilidad-probabilidad).

Supongamos que disponemos de una muestra $x_1, \dots, x_n$ de una población con función de distribución $F(x; \theta)$, y consideremos la muestra ordenada $x_{1:n} \leq x_{2:n} \leq \dots \leq x_{n:n}$ y los puntos $p_{i:n} = \frac{i}{n+1}$, $i = 1, \dots, n$. Sea $F(x; \hat{\theta})$ la función de distribución evaluada en un estimador obtenido a partir de la muestra $\mathbf{x} = (x_1, \dots, x_n)$, de tal forma que $F^{-1}(p_{i:n}; \hat{\theta})$ es el cuantil estimado que se corresponde con el estadístico de orden i , $x_{i:n}$.

Definición 9.1 (Gráfico $Q-Q$) Denominaremos gráfico $Q-Q$ a la gráfica resultante de representar los pares $(x_{i:n}, F^{-1}(p_{i:n}; \hat{\theta}))$, $i = 1, \dots, n$.

El gráfico $Q-Q$ muestra los cuantiles observados y los estimados de tal forma que si el modelo se ajusta correctamente a los datos, la nube de puntos representada deberá estar situada sobre la diagonal del rectángulo $[F(p_{1:n}; \hat{\theta}), F(p_{n:n}; \hat{\theta})] \times [x_{1:n}, x_{n:n}]$, que es el espacio de representación de la gráfica $Q-Q$.

Definición 9.2 (Gráfico $P-P$) Denominaremos gráfico $P-P$ a la gráfica resultante de representar los pares $(x_{i:n}, F(x_{i:n}; \hat{\theta}))$, $i = 1, \dots, n$.

En el caso del gráfico $P-P$ si el modelo se ajusta correctamente a los datos, la nube de puntos representada deberá estar situada sobre la diagonal del cuadrado $[0, 1] \times [0, 1]$.

Ejemplo 9.3 (Continuación ejemplo 8.37) Realizar una inspección gráfica del ajuste de los datos del ejemplo 8.37 para cada una de las filiales para unas distribuciones normales cuyos parámetros son los estimadores de máxima verosimilitud.

Solución: Los estimadores de máxima verosimilitud para cada una de las filiales son: $\mu_1 = 17,9386$; $\sigma_1^2 = 4,8485$; $\mu_2 = 18,2215$ y $\sigma_2^2 = 2,2513$. A continuación debemos ordenar cada una de las series de datos para cada filial y compararlos con los cuantiles estimados mediante máxima verosimilitud.




Figura 9.1: Gráficas $Q-Q$ y $P-P$ para la filial 1 en el ejemplo 8.37

La figura 9.1 ha sido obtenida comparando los estadísticos ordenados de la muestra para la filial 1 y sus correspondientes estimados de una población normal $N(17,9386; 4,8485)$. Análogamente para la filial 2 (ver figura 9.2) con una población $N(18,2215; 2,2513)$ para este caso.




Figura 9.2: Gráficas $Q-Q$ y $P-P$ para la filial 2 en el ejemplo 8.37

Ejemplo 9.4 Se dispone de los datos de 10 pérdidas procedentes de una distribución tipo Weibull,

1,360 1,524 1,951 2,225 2,367 2,672 3,246 3,817 4,250 4,970.

Obtener los estimadores de α y σ por el método de máxima verosimilitud. Estudiar la adecuación del modelo por medio de las gráficas $P-P$ y $Q-Q$. Estimar la proporción de pérdidas mayores de 3,5.

Solución: Usando las fórmulas (9.45) y (9.46) obtenemos los estimadores puntuales: $\hat{\alpha} = 2,151$ y $\hat{\sigma} = 3,024$. Los gráficos $P-P$ y $Q-Q$ (figura 9.3) muestran una razonable adecuación al modelo Weibull. La estimación de la probabilidad pedida es,

$$\Pr(X > 3,5) = \exp \left[- \left(\frac{3,5}{3,024} \right)^{2,151} \right] = 0,2542.$$

Por tanto, un 25,42 por ciento de las pérdidas serán superiores a 3,5.

Existen otros procedimientos que también pueden ser utilizados como análisis exploratorio del conjunto de datos obtenidos. Uno de los más utilizados consiste en representar gráficamente el histograma obtenido para los datos observados y




Figura 9.3: Gráficos $P - P$ y $Q - Q$ para los datos de pérdidas tipo Weibull

superponer sobre él la densidad (o distribución) correspondiente a los parámetros estimados (por máxima verosimilitud, por ejemplo) con estos datos. Junto con estos procedimientos informales es claro que un procedimiento formal debe también acompañarse. Dentro de este ámbito, el procedimiento de contraste más utilizado para la validación de un modelo es el test χ^2 de bondad de ajuste. Este test trata de decidir a la luz de los datos observados si puede considerarse que la distribución poblacional sigue una distribución determinada. Ahora bien, este tipo de tests también puede utilizarse para analizar si varias muestras provienen o no de la misma población, en cuyo caso podrán utilizarse conjuntamente para hacer inferencias (estos tests se conocen como contrastes de homogeneidad). Paralelamente, también pueden utilizarse para el caso de que se observen dos o más características poblacionales y decidir sobre su independencia.

En general, los tests basados en la χ^2 requieren que los datos estén agrupados en intervalos (lo que no significa que las estimaciones deban hacerse necesariamente con los datos agrupados) para medir el número de observaciones que caen en cada intervalo. Básicamente el método consiste en descomponer el soporte de la distribución en k subconjuntos: $A_1, \dots, A_k$ y contar las observaciones en cada uno de los subconjuntos que pertenezcan, para a continuación comparar las frecuencias observadas de cada A_i con las que le corresponderían de acuerdo a la hipótesis nula. Si denominamos por p_i^0 la probabilidad de cada A_i ($i = 1, \dots, k$) bajo la hipótesis nula $H_0: F = F_0$ y p_i la probabilidad que la verdadera distribución F asigna a cada A_i , tendremos que la variable aleatoria $N = (N_1, \dots, N_k)$ que mide

9.11. Selección y validación de modelos

el número de observaciones muestrales en cada uno de los subconjuntos A_i 's sigue una distribución multinomial con parámetros n y $p = (p_1, \dots, p_k)$. Tenemos el siguiente resultado (Rohatgi, 1976, p. 447).

Teorema 9.1 Sea $(N_1, \dots, N_k)$ una distribución multinomial con parámetros $n, p_1, \dots, p_k$, entonces la variable aleatoria:

$$U = \sum_{i=1}^k \frac{(N_i - np_i)^2}{np_i}$$

se distribuye asintóticamente según una distribución χ^2 con $k-1$ grados de libertad, cuando $n \rightarrow \infty$.

El teorema 9.1 permite contrastar el ajuste de unos datos a una distribución dada, usando los siguientes resultados que son consecuencias del teorema anterior.

Teorema 9.2 Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una población X , y consideremos $H_0: X \sim F$ donde la forma funcional F es completamente conocida. Consideremos una colección de subconjuntos disjuntos $A_1, \dots, A_k$ que constituyen una partición del soporte de X . Sea $p_i = \Pr(X \in A_i)$, $i = 1, \dots, k$ y supongamos que $p_i > 0$, para cada i . Sea N_j el número de X_i 's que cae en A_j ($j = 1, \dots, k$; $i = 1, \dots, n$). Entonces, la distribución conjunta de N es multinomial de parámetros n y $p = (p_1, \dots, p_k)$.

Teorema 9.3 Sea $H_0: X \sim F(\cdot; \theta)$ con $\theta = (\theta_1, \dots, \theta_r)$ desconocido. Consideremos $X_1, \dots, X_n$ una muestra aleatoria simple de la población X y $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_r)$, el vector formado por los estimadores de máxima verosimilitud de cada parámetro θ_i . Sea $A_1, \dots, A_k$ una partición del soporte de X , y denotemos por

$$\hat{p}_i = \Pr(X \in A_i; \hat{\theta}),$$

a las probabilidades de cada A_i asociadas a la distribución $F(\cdot; \hat{\theta})$. Sea N_j el número de X_i 's que cae en A_j ($j = 1, \dots, k$; $i = 1, \dots, n$). Entonces, la variable aleatoria

$$U = \sum_{i=1}^k \frac{(N_i - n\hat{p}_i)^2}{n\hat{p}_i}$$

sigue una distribución χ^2 con $k - r - 1$ grados de libertad, cuando $n \rightarrow \infty$.

Demostración: La demostración del teorema 9.3 y algunas condiciones de regularidad requeridas a la distribución pueden verse en Cramér (1946), p. 426.

Para un contraste $H_0: X \sim F$, con F completamente especificada, para un tamaño muestral n suficientemente grande, rechazaremos H_0 si

$$U_{obs} = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} > \chi_{k-1, \alpha}^2$$

con un nivel de significación fijado, α .

Del mismo modo, si la hipótesis nula es $H_0 : X \sim F(\cdot; \theta)$ donde $F(\cdot; \theta)$ es conocida excepto el parámetro θ , entonces rechazaremos H_0 si

$$U_{obs} = \sum_{i=1}^k \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i} > \chi_{k-r-1, \alpha}^2 \quad (9.49)$$

donde r es el número de parámetros estimados (por máxima verosimilitud, por ejemplo).

El tamaño muestral n hará la aproximación más o menos buena en función de los valores de las probabilidades p_i . Usualmente suele considerarse que $n \cdot p_i \geq 5$, para cada $i = 1, \dots, k$, lo cual suele utilizarse para construir los conjuntos A_i que debemos elegirlos de manera que $np_i^0 \geq 5$. Además y dado que el test no distingue entre distribuciones F_0 que asignen la misma probabilidad a los A_i , es también aconsejable que $k \geq 5$. De esta última condición se deduce que algún $p_i^0 \leq \frac{1}{5}$, y por tanto $n \geq 25$, es un tamaño mínimo deseable en la práctica.

Ejemplo 9.5 La tabla 9.2 expone los datos de reclamaciones para una cartera de seguro de automóviles en Zaire, extraída de Denuit (1997). Se pide:

1. La media y la varianza de los datos, indicando si existe sobredispersión.
2. Ajustar, utilizando el método de máxima verosimilitud, una distribución de Poisson y una distribución binomial negativa.
3. Estudiar la bondad del ajuste mediante el test χ^2 con tamaño 5%.

Tabla 9.2: Número de reclamaciones observadas y ajustadas

Nº de Reclamaciones	Asegurados
0	3719
1	232
2	38
3	7
4	3
5	1
6	0

Solución:

1. La media y la varianza son 0,0865 y 0,12, respectivamente. Puesto que la varianza es mayor que la media se deduce que los datos son sobredispersos. Esta es una situación típica en el ramo de seguro de automóviles.
2. Para la distribución de Poisson de parámetro $\theta > 0$ se tiene que el estimador máximo verosímil del parámetro viene dado por (9.2) y por tanto: $\hat{\theta} = \bar{x} = 0,0865$. Para la distribución binomial negativa con parámetros $r > 0, 0 < p < 1$ hay que resolver para $\hat{r}$ la ecuación (9.11). Esta ecuación puede resolverse de modo sencillo utilizando la instrucción FindRoot[$w == 0, \{\hat{r}, \hat{r}_0\}$] del programa Mathematica, donde w es el primer término de la ecuación (9.11) y $\hat{r}_0$ es un punto de partida para el que puede tomarse los estimadores de momentos (9.5)-(9.6). En el ejemplo, k toma los valores desde 0 hasta 6, mientras que $n_0 = 3719, n_1 = 232$ etc. Una vez resuelta la ecuación (9.11) el estimador de p es (9.8). Las frecuencias esperadas para ambos modelos, así como los valores de $\hat{r}$ y $\hat{p}$, se muestran en la tabla 9.3.
3. Usaremos el teorema 9.3 donde se han agrupado celdas. Utilizando la expresión (9.49) para cada modelo obtienen las columnas de la tabla 9.3. En el caso del modelo de Poisson la χ^2 vale 347,47 y 1,23 para la binomial negativa. El valor crítico de la χ^2 con 2 grados de libertad es $\chi_{2,0,05}^2 = 5,99$. En consecuencia, elegimos como modelos el correspondiente a la distribución binomial negativa y rechazaremos el modelo Poisson.

Ejemplo 9.6 Los datos que aparecen en la tabla 9.4 corresponden a 237 pagos por responsabilidad a pólizas de seguros con un límite monetario de 300000. Contratar la hipótesis nula de que un modelo log-normal es adecuado para los datos. (Klugman et al. 1998)

Solución: Los estimadores de máxima verosimilitud de los parámetros de la log-normal vienen dados por (9.16) y (9.17) que en este caso son: $\hat{\mu} = 9,29376$ y $\hat{\sigma} = 1,62713$. Se trata de contrastar si la población que ha generado estos datos es $\mathcal{LN}(\hat{\mu}, \hat{\sigma}^2)$. Con el objeto de cumplir los requerimientos mínimos en los tamaños muestrales agruparemos los dos últimos intervalos. Los resultados obtenidos pueden verse en la tabla 9.5 (extraído de Klugman et al., 1998).

Entonces:

$$U_{obs} = \sum_{i=1}^{12} \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i} = \frac{(41 - 39,75)^2}{39,75} + \dots + \frac{(7 - 6,79)^2}{6,79} = 4,51.$$

El valor crítico al 5% en una distribución χ^2 con $k - r - 1 = 12 - 2 - 1 = 9$ grados de libertad es 16,92 y por tanto aceptaremos la hipótesis nula de que la

Tabla 9.3: Número de reclamaciones observadas y ajustadas

Nº de Reclamaciones	Nº de Asegurados	Poisson	Binomial negativa
0	3719	3668,54	3719,22
1	232	317,329	229,901
2	38	13,7245	39,9106
3	7	0,39572	8,4156
4	3	0,00855	1,9313
5	1	0,00015	0,4648
6	0	0	0,1153
Total	4000	4000	4000
Parámetros		$\hat{\theta} = 0,0865$	$\hat{r} = 0,2166$ $\hat{p} = 0,714616$
χ^2		347,47	1,23
Grados de libertad		4 - 1 - 1 = 2	5 - 2 - 1 = 2
p-valor		0%	54,06%
Logaritmo de la función de verosimilitud		-1246,08	-1183,55

Tabla 9.4: Datos de pólizas de seguros

Pago	Número observado	Media
0 - 2500	41	1389
2500 - 7500	48	4661
7500 - 12500	24	9991
12500 - 17500	18	15482
17500 - 22500	15	20232
22500 - 32500	14	26616
32500 - 47500	16	40278
47500 - 67500	12	56414
67500 - 87500	6	74985
87500 - 125000	11	106851
125000 - 225000	5	184735
225000 - 300000	4	264025
> 300000	3	300000

distribución log-normal ajusta los datos. De hecho el p-valor vale 0,3748 lo que implica que dicha hipótesis nula no se rechaza.

Tabla 9.5: Valores ajustados

Intervalo	Frecuencia	
	observada	esperada
0 - 2500	41	39,75
2500 - 7500	48	49,17
7500 - 12500	24	27,00
12500 - 17500	18	17,55
17500 - 22500	15	12,48
22500 - 32500	14	16,70
32500 - 47500	16	14,77
47500 - 67500	12	11,18
67500 - 87500	6	6,71
87500 - 125000	11	7,22
125000 - 225000	5	7,68
225000 -	7	6,79

Ejemplo 9.7 Supongamos que el número accidentes de tráfico ocurridos en una población son clasificados en 9 zonas distintas que se obtienen de cuadricular el plano de una ciudad en dichas 9 partes. Los resultados observados por una compañía aseguradora, para 60 accidentes, son los siguientes:

7	3	8
9	11	5
4	7	6

La compañía desea contrastar si los accidentes se distribuyen aleatoriamente o bien existen zonas especialmente peligrosas en dicha ciudad.

Solución: Si tuviera distribución uniforme (lo que se corresponde a la hipótesis nula de distribución aleatoria) cada zona tendría probabilidad $\frac{1}{9}$ de tener un accidente, y por tanto el número esperado de accidentes en cada zona es $\frac{60}{9} = 6,33$. Entonces

$$U_{obs} = \sum_{i=1}^9 \frac{(n_i - np_i)^2}{np_i} = \frac{(7 - 6,33)^2}{6,33} + \dots + \frac{(6 - 6,33)^2}{6,33} = 7,5.$$

Bajo la hipótesis nula de que la distribución de los accidentes es uniforme en la ciudad, U tiene una distribución asintótica χ^2 con $k - r - 1 = 9 - 0 - 1$. No hemos estimado ningún parámetro pues la hipótesis nula indica que la distribución está totalmente especificada. El p-valor asociado a U_{obs} es 0,48 y por tanto no

rechazaremos la hipótesis nula de que los accidentes se distribuyen al azar por la ciudad.

Si deseamos seleccionar un modelo que represente adecuadamente la población objeto de estudio disponemos de varias herramientas para ello. Básicamente, debemos asignar un valor numérico a cada modelo asignado mediante algún criterio y consecuentemente seleccionar aquel modelo con mayor puntuación. Entre otras muchas, las herramientas más usuales a las que nos referimos son:

1. Valor de la función de verosimilitud. Criterio: seleccionar el modelo con mayor valor. Este criterio es equivalente al de seleccionar el de menor valor respecto a $-\log f(x; \theta)$, es decir, el de menor valor del logaritmo de la verosimilitud cambiado de signo (en muchos paquetes informáticos estos valores vienen expresados abreviadamente como NLL, Negative LogLikelihood)
2. Valor del estadístico en el test χ^2 de bondad de ajuste. Criterio: seleccionar el de menor valor.
3. p -valor en el test χ^2 de bondad de ajuste. Criterio: seleccionar el de mayor valor.

A estos criterios (además de otros existentes) debemos añadir además el criterio de parsimonia por el cual siempre son preferibles modelos más simples a modelos más complejos, puesto que resultan más fáciles de entender y de utilizar.

Ejemplo 9.8 Con los datos del ejemplo 9.6, Klugman et al. (1998) han ajustado una serie de modelos por máxima verosimilitud. Un extracto de los mejor ajustados se muestra en el siguiente cuadro donde aparecen los modelos, los valores NLL, los valores del estadístico χ^2 y sus grados de libertad (g.l.) y sus p -valores. Usando esta información seleccionar el mejor modelo de acuerdo a su p -valor. (Klugman et al., 1998, p. 128).

Tabla 9.6: Distintos modelos ajustados a los datos del ejemplo 9.6

Modelo	Núm. parámetros	NLL	χ^2	g.l.	p -valor
Log-normal	2	498,29	4,51	9	0,8744
Pareto	2	499,31	6,37	9	0,7028
Pareto inversa	2	500,09	7,52	9	0,5831
Pareto generalizada	3	498,62	5,00	8	0,7580
Burr	3	498,41	4,79	8	0,7793
Burr Inversa	3	499,01	5,33	8	0,7222

Solución: Es claro que el modelo log-normal es el preferido puesto que presenta mayor p -valor. El siguiente modelo sería el de distribución tipo Burr, sin embargo, este modelo tiene 3 parámetros y frente al de Pareto con un p -valor alto (lo suficientemente alto como para no rechazar la hipótesis nula con un nivel de significación usual) que tiene 2 parámetros, podríamos plantear seleccionar este último debido a su mayor sencillez.

El test de razón de verosimilitudes también puede ser utilizado para la selección de modelos en la situación particular de que un modelo sea un caso particular de otro (modelos anidados). La hipótesis nula es que el modelo más simple es apropiado y la alternativa que lo es el más complejo. Utilizaremos por tanto el valor $-2 \log \lambda(x)$ para comparar con el valor crítico de una distribución χ^2 con tantos grados de libertad como la diferencia entre el número de parámetros de los modelos.

Existen varios procedimientos que corrigen el hecho anterior de que los modelos deban ser casos especiales unos de otros para que la razón de verosimilitudes pueda aplicarse de manera formal. El más utilizado es el criterio Bayesiano de Schwartz (SBC abreviadamente). El procedimiento SBC permite comparar todos los modelos y básicamente consiste en tomar los valores de la verosimilitud y entonces ajustar su valor de modo que se tenga en cuenta el tamaño muestral y el número de parámetros del modelo. En concreto el valor del SBC consiste en restarle al logaritmo de la verosimilitud la cantidad $r \log \left(\frac{n}{2\pi} \right)$, donde r es el número de parámetros estimados en el modelo y n el tamaño muestral. Al igual que en el caso del valor NLL el criterio será seleccionar el modelo con menor SBC.

Ejemplo 9.9 Para los datos de la tabla 9.6, seleccionar el mejor modelo de acuerdo al criterio SBC.

Solución: Para el caso que nos ocupa, como $n = 217$ tendremos que la penalización que sufrirá el logaritmo de la verosimilitud en cada modelo será de $r \log \left(\frac{217}{2\pi} \right) = 3,542r$. Luego los valores del SBC para los modelos log-normal y Burr serán:

$$SBC_{LN} = 498,29 + 3,542 \cdot 2 = 505,37,$$

$$SBC_{Burr} = 498,41 + 3,542 \cdot 3 = 509,04.$$

En consecuencia, el modelo log-normal es el preferido.

En general, todos los procedimientos de selección de modelos de este tipo corresponden a un mismo planteamiento. En efecto, la esperanza del logaritmo de la verosimilitud

$$E \{ \log f(x; \theta) \} = \int_{\mathcal{X}} f(x; \theta) \log f(x; \theta) dx,$$

es la entropía (con signo negativo) de la densidad muestral $f(x; \theta)$. Bajo condiciones de regularidad generales, puede probarse que $\log f(x; \hat{\theta})/n$ converge con

probabilidad 1 a dicha esperanza cuando $n \rightarrow \infty$. Este hecho introduce la entropía como un criterio de cantidad de información asociada a $\hat{\theta}$, de tal forma que $\hat{\theta}$ minimiza la falta o "desorden" de información sobre el modelo de muestreo asumido. De esta forma, si conocemos que nuestro modelo muestral f pertenece a una familia $\mathcal{F}$, entonces elegiremos $f \in \mathcal{F}$ que maximice la cantidad

$$\text{GIC} = \text{Criterio General de Información} = \log f(x; \hat{\theta}) - \frac{\alpha r}{2},$$

donde por tanto $\alpha/2$ actúa como una penalización por parámetro del modelo. Distintas elecciones de α producen distintos criterios: $\alpha = 2$ (Akaike, 1978) y $\alpha = \log\left(\frac{n}{2\pi}\right)$ (Schwartz, 1978):

$$\text{AIC} = \text{Criterio de Información de Akaike} = \log f(x; \hat{\theta}) - r,$$

$$\text{BIC} = \text{Criterio Bayesiano de Información} = \log f(x; \hat{\theta}) - \frac{r}{2} \log\left(\frac{n}{2\pi}\right).$$

Ejemplo 9.10 Con los datos de la tabla 9.6, seleccionar el mejor modelo de acuerdo a los criterios AIC y BIC.

Solución: La tabla 9.7 muestra los resultados. Bajo cualquier criterio el modelo log-normal vuelve a ser el preferido.

◇

Tabla 9.7: Criterios AIC y BIC para los datos de la tabla 9.6

Modelo	r	AIC	BIC
Log-normal	2	500,29	501,832
Burr	3	501,41	503,723

9.12. Problemas propuestos

1. Un actuario quiere estimar el coste medio de los siniestros de los clientes de una cartera de seguros. Para ello dispone de una muestra del coste de n siniestros $X_1, \dots, X_n$. El actuario supone que las variables X_i , $i = 1, 2, \dots, n$ son de tipo log-normal $\mathcal{LN}(\mu, \sigma^2)$, y por su experiencia previa establece que $\sigma^2 = \sigma_0^2$ es una cantidad fija y conocida.

- a) Probar que el estimador de máxima verosimilitud del coste medio m es,

$$\hat{m} = \exp\left(\frac{1}{n} \sum_{i=1}^n \log X_i + \frac{\sigma_0^2}{2}\right).$$

9.12. Problemas propuestos

- b) Probar que,

$$\begin{aligned} E(\hat{m}) &= m e^{\sigma_0^2/2n}, \\ \text{Var}(\hat{m}) &= m^2 e^{\sigma_0^2/n} (e^{\sigma_0^2/n} - 1), \end{aligned}$$

y concluir que $\hat{m}$ es un estimador consistente y sesgado. Obtener el error cuadrático medio de $\hat{m}$ y hallar una versión insesgada.

- c) Hallar el estimador de máxima verosimilitud del coste mínimo correspondiente al diez por ciento de los clientes con mayores costes por siniestro.
2. A partir de los datos de n pérdidas un actuario quiere estimar la pérdida mínima correspondiente al 5 por ciento de las mayores pérdidas. Se supone que las pérdidas proceden de una distribución de Gumbel de parámetros μ y σ .

- a) Probar que el estimador de máxima verosimilitud de esa cantidad es,

$$\hat{\mu}_{EMV} - \log[-\log(0,05)]\hat{\sigma}_{EMV}.$$

- b) Probar que la varianza asintótica es,

$$\frac{\sigma^2}{n} \left[1 + \frac{6}{\pi^2} \{1 - \gamma - \log[-\log(0,05)]\} \right].$$

3. Una compañía de seguros médicos quiere estimar la proporción de asegurados que han hecho uso de las ayudas para tratamientos dentales durante los último ocho años. Para ello sólo dispone de los datos aislados de estas proporciones durante dicho período,

$$0,245 \quad 0,312 \quad 0,276 \quad 0,301 \quad 0,328 \quad 0,265 \quad 0,326 \quad 0,352$$

Se puede suponer que los datos proceden de una distribución beta con parámetros a y b .

- a) Si tenemos una muestra de n proporciones, probar que los estimadores de momentos de a y b son,

$$\begin{aligned} \hat{a} &= \frac{m_1^2 - m_1 m_2}{m_2 - m_1^3}, \\ \hat{b} &= \frac{m_1 - m_2}{m_2 - m_1^3} - \hat{a}. \end{aligned}$$

donde $m_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, $k = 1, 2$.

- b) Obtener los estimadores puntuales de a y b y hallar una estimador de la probabilidad de que más del 40 por ciento de los asegurados utilice este tipo de ayudas.
4. Supongamos como en el ejemplo 9.6 que el límite monetario está fijado en 500000 y que la tabla de pagos es la siguiente:

Pago	Número
0 - 2500	101
2500 - 7500	132
7500 - 12500	61
12500 - 17500	50
17500 - 22500	29
22500 - 32500	50
32500 - 47500	28
47500 - 67500	40
67500 - 87500	22
87500 - 125000	27
125000 - 175000	19
175000 - 225000	6
225000 - 325000	10
325000 - 500000	4
> 500000	5

Realizar una gráfica $Q-Q$ para un modelo log-normal con media y varianza estimada por máxima verosimilitud.

5. Para el ejercicio anterior realizar un contraste de bondad de ajuste χ^2 con tamaño $\alpha = 0,1$ sobre un ajuste log-normal.
6. Idem al anterior pero para un modelo Pareto con dos parámetros.
7. En los ejercicios anteriores seleccionar el modelo más adecuado de acuerdo a los criterios NLL, AIC y BIC.
8. Supongamos que para el ajuste de unas observaciones sobre cuantías abonadas por una compañía aseguradora para una cierta cartera se ha conjeturado una distribución de Pareto con parámetros $\alpha = 2$ y $\theta = 1000$. Observada una muestra aleatoria simple con 10 observaciones se tienen 4 observaciones en el rango 0 - 250, 2 en el rango 250 - 500, 3 en el rango 500 - 1000 y 1 mayor de 1000. Construir un test χ^2 de bondad de ajuste con nivel de significación $\alpha = 0,05$.
9. La tabla siguiente contiene las observaciones para muestra aleatoria simple de tamaño $n = 500$.

Cantidades reclamadas (en millones de euros)	Número observado
0 - 3	90
3 - 7,5	90
7,5 - 15	163
15 - 40	125
> 40	75

La estimación máximo verosímil para los parámetros de un modelo de Pareto con dos parámetros es $\hat{\alpha} = 3,5$ y $\hat{\theta} = 50$. Encontrar el p -valor para un test χ^2 de bondad de ajuste a un modelo Pareto con dos parámetros. ¿Cuál es el mayor nivel de significación al que aceptaríamos la hipótesis nula?

10. Los datos de la siguiente tabla corresponden al número de reclamaciones abonadas por una compañía para un seguro de daños para automóviles con un límite superior de cuantía registrados en función de ella de acuerdo a unos determinados intervalos (adaptado de Klugman et al., 1998). Suponiendo en todos los casos un modelo con distribución de Weibull y utilizando el método de máxima verosimilitud para la estimación, se pide:
- Estimar los parámetros de una distribución Weibull centrada ($\mu = 0$) para cada uno de los casos de límites propuestos.
 - Supongamos que las distribuciones Weibull centradas aplicables a cada caso límite tienen el mismo valor de parámetro α pero diferentes valores de σ . Estimar los valores de α global y los diferentes de σ .
 - Usar el test del cociente de verosimilitudes para decidir cuál de los dos modelos es más apropiado.
 - Idem al anterior utilizando los criterios SBC y BIC.

Rango	Límite				
	5000	10000	25000	50000	100000
0-250	1230	415	660	950	4119
250-500	612	187	268	424	2047
500-1000	546	136	311	377	2031
1000-3000	756	256	452	605	3440
3000-5000	226				
5000-	491				
3000-8000		142	214	337	1905
6000-8000		38	77	103	602
8000-10000		25			
10000-		77			
3000-11000			59	99	507
11000-14000			33	28	255
14000-19000			28	61	298
29000-23000			19	30	139
23000-25000			6		
25000-			63		
23000-30000				27	240
30000-40000				14	131
40000-50000				16	
50000-				45	
40000-55000					166
55000-70000					74
70000-100000					119
100000-					139
Total	3861	1276	2190	3116	16212

Capítulo 10

Elementos de Estadística Bayesiana

En este capítulo se estudian los conceptos básicos en los que se fundamenta la estadística bayesiana, de gran utilidad en estadística actuarial.

10.1. Introducción a la estadística bayesiana

Con objeto de entender los beneficios y limitaciones de esta metodología, debemos primero entender las diferencias básicas entre la estadística clásica y la bayesiana.

La perspectiva clásica o frecuentista y la bayesiana están fundamentadas en diferentes nociones de probabilidad. De acuerdo con la perspectiva frecuentista, sólo los sucesos susceptibles de ser repetidos tienen probabilidad. En la perspectiva bayesiana, la probabilidad describe incertidumbre, en un sentido amplio del término. Un suceso puede ser incierto por el hecho de ser intrínsecamente impredecible, es decir, por estar sujeto a variabilidad aleatoria, como por ejemplo la pérdida asociada a un siniestro. También puede ser incierto por el hecho de que tengamos un conocimiento imperfecto sobre el mismo, como por ejemplo, la respuesta media a un medicamento entre todos los pacientes de la población. La perspectiva frecuentista únicamente reconoce el primer tipo de incertidumbre, mientras que la aproximación bayesiana considera ambos tipos de incertidumbre.

Por tanto, desde una perspectiva frecuentista, la probabilidad se define como una frecuencia relativa de un suceso que se repite un número elevado de veces. Esta es la definición más usada en los cursos básicos de estadística, ilustrada con ejemplos tan habituales como el lanzamiento un número elevado de veces de una moneda. Por tanto este método está basado firmemente en una definición de la probabilidad basada en conteo, razón por la cual se denomina método "frecuentista". La estadística bayesiana, en cambio, está basada en la interpretación de

la probabilidad como el grado personal de creencia. Aunque puede parecer un concepto un tanto ambiguo, lo cierto es que la estadística bayesiana permite el desarrollo de un número amplio de análisis de forma satisfactoria.

La necesidad de esta interpretación de la probabilidad queda de manifiesto cuando observamos la cantidad de sucesos de los que tratamos de extraer probabilidades que no pueden ser interpretados desde un punto de vista frecuentista. Un primer ejemplo es la probabilidad asociada a una hipótesis. Una hipótesis puede ser cierta o falsa, pero no podemos considerar una repetición del estudio como si se tratase del lanzamiento de una moneda. Otros ejemplos evidentes son la probabilidad de que llueva mañana o la probabilidad de padecer una determinada enfermedad. Mañana es un único día, con unas condiciones meteorológicas propias y distintas a las de cualquier otro día. Por otro lado, cada persona posee unas condiciones genéticas y de estilo de vida que lo distinguen de cualquier otra persona.

A pesar de que se trata de sucesos únicos, no nos resulta extraño pensar que dichos sucesos poseen cierta probabilidad. La mayoría de los sucesos y variables de interés real para los científicos son sucesos únicos, por lo que la interpretación frecuentista de la probabilidad no es capaz de acomodarse al concepto intuitivo de probabilidad.

Planteemos el siguiente ejemplo ilustrativo. Supongamos que lanzo una moneda al aire y observo el resultado, cara o cruz, pero no lo revelo. ¿Cuál dirías que es la probabilidad de que haya salido cara? La mayoría de las personas dirían que un 50 %. Este resultado concuerda con el concepto de probabilidad bayesiano. El resultado del lanzamiento de la moneda es incierto para todos, menos para mí que he visto el resultado. Esta incertidumbre puede expresarse a través de una probabilidad. Desde un punto de vista frecuentista, no podemos asignar una probabilidad al resultado ya observado de la moneda ya que no es una variable aleatoria.

Los métodos estadísticos están generalmente formulados con el objetivo de realizar inferencia sobre parámetros desconocidos. Por tanto, los parámetros representan valores desconocidos y generalmente corresponden con propiedades de la población en estudio. Cualquier cuestión de interés en el análisis puede ser expresada como una cuestión sobre la valor de estos parámetros. Los parámetros son específicos de cada problema, y generalmente, no están sujetos a variabilidad aleatoria. Así, la estadística frecuentista no suele reconocer los parámetros como variables aleatorias. Se trata por tanto de valores fijos aunque desconocidos, por lo que no podemos asignar probabilidades a sus valores. Por contra, la estadística bayesiana sí permite asignar probabilidades a los parámetros por el simple hecho de que son desconocidos.

10.2. Teorema de Bayes para el caso discreto y continuo

Como vimos en la sección 2.7 del capítulo 2, el teorema de Bayes es uno de los resultados básicos de la teoría de la probabilidad. En esta sección estudiaremos su interpretación como mecanismo de aprendizaje sobre cantidades desconocidas. En su versión más elemental podemos escribirlo como

$$\Pr(A|B) = \frac{\Pr(A) \cdot \Pr(B|A)}{\Pr(B)},$$

para dos sucesos A y B con $\Pr(B) > 0$. Veamos un ejemplo de aplicación del teorema de Bayes, pero que ahora lo interpretaremos de manera diferente a la usual y que permitirá introducir gran parte de la nueva nomenclatura.

Ejemplo 10.1 Supongamos el caso de una compañía aseguradora que, como cada año, desea realizar una inspección de facturas por cobrar de cada una de sus tres filiales F_1 , F_2 y F_3 . De situaciones históricas se conoce que el 20 % de las facturas provienen de F_1 , el 30 % de F_2 y el 50 % de F_3 . Supongamos también que el 1 % de las emitidas por F_1 son defectuosas, el 2 % de F_2 son defectuosas y de F_3 lo son el 3 %. Supongamos ahora que en la sede central se recogen todas las facturas y que existe un cierto descontento con el director de F_3 . El volumen de facturas es tan grande que se opta por seleccionar aleatoriamente un conjunto de ellas. Elegimos al azar una y resulta ser defectuosa. Siempre que haya una posibilidad mayor del 50 % de que provenga de F_3 su director será cesado. Indicar si se cesará o no al director de la tercera filial.

Solución: Definimos:

A_i : "la factura seleccionada proviene de F_i " ($i = 1, 2, 3$)

y

B : "la factura seleccionada contiene error."

Se trata pues de calcular $\Pr(A_3|B)$. Los resultados aparecen tabulados en la tabla 10.1.

En este ejemplo aparecen una serie de elementos importantes. $\Pr(A_3)$ se denomina *probabilidad a priori o inicial* de que la factura proceda de F_3 (y su valor proviene de la percepción que tenga el investigador sobre el sistema que está inspeccionando, entre otras razones) ya que es la probabilidad de A_3 antes de que se sepa si es o no erróneo. $\Pr(A_3|B)$ se denomina *probabilidad a posteriori o final*, ya que corresponde a la de A_3 una vez que se sabe que es defectuosa. De hecho el teorema de Bayes ha actuado como una "caja negra" que devuelve revisadas las

Tabla 10.1: Cálculos para probabilidades a posteriori de las filiales

Filial	Porcentajes defectuosas	Probabil. iniciales $\Pr(A_i)$	Probabil. de los datos $\Pr(B A_i)$	Producto	Probabil. finales $\Pr(A_i B)$
1	1	0,2	0,01	0,002	0,087
2	2	0,3	0,02	0,006	0,261
3	3	0,5	0,03	0,015	0,652
				0,023	

probabilidades iniciales a la luz de los datos observados. $\Pr(B|A_3)$ es la *verosimilitud* que tiene el suceso B (la factura seleccionada contiene error) sabiendo que procede de la tercera filial. Podemos escribir:

$$\Pr(A_i|B) \propto \Pr(A_i) \times \Pr(B|A_i)$$

es decir,

$$\text{Prob. a posteriori} \propto \text{Prob. a priori} \times \text{información muestral}$$

donde el símbolo $\propto$ indica proporcionalidad, siendo la constante de proporcionalidad la cantidad siguiente que merece especial interés en este ejemplo y que se conoce como *distribución predictiva*:

$$\Pr(B) = \Pr(A_1) \cdot \Pr(B|A_1) + \Pr(A_2) \cdot \Pr(B|A_2) + \Pr(A_3) \cdot \Pr(B|A_3) = 0,023 = 2,3\%.$$

Finalmente, puesto que $\Pr(A_3|B) > 0,5$ el director será cesado.

En consecuencia, el teorema de Bayes es interpretado como un mecanismo de aprendizaje sobre las cantidades de interés. Este hecho pone de manifiesto otro de los aspectos interesantes de este enfoque: el teorema de Bayes puede ser aplicado reiteradas veces. Así, las probabilidades a posteriori obtenidas en una fase pueden ser utilizadas como probabilidades a priori en la siguiente fase, y así sucesivamente. El siguiente ejemplo clarifica este comentario.

Ejemplo 10.2 (Continuación ejemplo 10.1. Uso secuencial) Supongamos ahora que se examina una segunda factura que resulta también ser errónea. Analizar de nuevo la situación del director de la tercera filial.

Solución: Utilizando ahora como probabilidades a priori las obtenidas como a posteriori en la primera fase se tiene:

$$\Pr(A_1|B) = 0,087; \quad \Pr(A_2|B) = 0,261; \quad \Pr(A_3|B) = 0,652.$$

Tabla 10.2: Probabilidades a posteriori de las filiales en la segunda fase

Filial	Porcentajes defectuosas	Probabil. iniciales $\Pr(A_i B)$	Probabil. de los datos $\Pr(B_2 A_i)$	Producto	Probabil. finales $\Pr(A_i B_2)$
1	1	0,087	0,01	0,00087	0,034
2	2	0,261	0,02	0,00522	0,2035
3	3	0,652	0,03	0,01956	0,7625
				0,02565	

Llamando B_2 : "la factura seleccionada en la segunda fase contiene error", los cálculos aparecen en la tabla 10.2.

En consecuencia, la situación ha empeorado aún más para el director de la tercera filial.

El teorema de Bayes permite una interpretación nueva de las probabilidades: el hecho de que éstas son revisables cuando se combinan probabilidades iniciales con la información muestral proporcionada por los datos. Los siguientes ejemplos ilustran el uso de la metodología bayesiana.

Ejemplo 10.3 Antes de formalizar la contratación de una póliza de seguros para los empleados de una entidad médica privada, una compañía aseguradora desea realizar una prueba de detección del virus del sida para cada uno de sus empleados, puesto que los considera un grupo de riesgo para esta enfermedad. La prueba es fiable en el 99 % de los casos. Es decir, si una persona tiene la enfermedad existe una probabilidad de 0,99 de que la prueba de lugar a un resultado positivo (si una persona no tiene la enfermedad existe una probabilidad de 0,01 de que de lugar a un resultado positivo). Datos históricos indican que las posibilidades de padecer la enfermedad son sólo de un 1 por 10000.

Supongamos que se realiza la prueba a un empleado y resulta positiva. ¿cuál es la probabilidad de tener la enfermedad?

Solución: Llamemos H_0 al suceso "tener la enfermedad" e y al suceso "el resultado de la prueba es positivo". Entonces:

$$\begin{aligned} \Pr(H_0|y) &= \frac{\Pr(H_0) \cdot \Pr(y|H_0)}{\Pr(H_0) \cdot \Pr(y|H_0) + \Pr(H_1) \cdot \Pr(y|H_1)} \\ &= \frac{0,0001 \times 0,99}{0,0001 \times 0,99 + 0,9999 \times 0,01} = 0,0098 \approx 0,01. \end{aligned}$$

Esta probabilidad final es aproximadamente 100 veces mayor que la probabilidad inicial (0,0001); sin embargo, es muy diferente de la probabilidad que se podría

pensar en un principio cuando conocemos la fiabilidad del test: 0,99.

◇

Ejemplo 10.4 Supongamos que es conocido que una población contiene un 0,2 % de sus habitantes infectados por un virus y que una persona, seleccionada aleatoriamente de la población, es sometida a un test en un laboratorio. Test del que se conoce que produce un resultado positivo en el 98 % de las personas infectadas (fiabilidad) y un 1 % de resultados positivos en las no infectadas. El resultado obtenido es positivo. Evidentemente, el interés médico está en estudiar las posibilidades que tiene el paciente de tener o no la enfermedad (Bernardo, 2003).

Solución: La información del ejemplo puede escribirse en términos probabilísticos como,

$$\Pr(+|V) = 0,98, \quad \Pr(+|\bar{V}) = 0,01,$$

donde + debe interpretarse como el suceso: “el resultado del test es positivo”. El objetivo por tanto es estudiar la incertidumbre en torno a la presencia o no del virus en el paciente. El suceso de interés será por tanto $V = \text{“tener el virus”}$. Lo que ocurre es que ahora tenemos información procedente del test realizado. Por tanto queremos conocer,

$$\Pr(V|+, S, C) = \Pr(V|+),$$

es decir la probabilidad de que la persona tenga el virus dados el resultado positivo, las suposiciones sobre el mecanismo generador de la información, S y el conocimiento de la prevalencia de la enfermedad en la población, C . El teorema de Bayes permite usar esta información:

$$\begin{aligned} \Pr(V|+) &= \Pr(V) \cdot \frac{\Pr(+|V)}{\Pr(+)} \\ &= 0,002 \cdot \frac{0,98}{0,002 \cdot 0,98 + 0,998 \cdot 0,01} = 0,1641. \end{aligned}$$

Nuevamente observemos cómo actúa el teorema de Bayes (incluso cuando la fiabilidad de la prueba es muy alta). La probabilidad a posteriori de que una persona seleccionada al azar posea la infección será relativamente baja incluso cuando el test resulte positivo. En nuestro caso, en una población en la que la tasa de contagio es del 0,2 %, sólo el 16,42 % de aquellos test positivos de una muestra aleatoria estarán actualmente infectados (es decir, habrá una gran cantidad de falsos positivos).

Resulta también interesante obtener la probabilidad a posteriori de que una persona, cuyo test resultó positivo, esté infectada:

$$\Pr(V|+) = \frac{0,98p}{0,98p + 0,01(1-p)} = \frac{0,98p}{0,97p + 0,01},$$

escrita en función de $p = \Pr(V)$, la probabilidad a priori de que una persona esté infectada (denominada prevalencia de la infección en la población objeto de estudio). La figura 10.1 muestra esta expresión como función de p .




Figura 10.1: Comportamiento de las probabilidades a posteriori en función de las a priori

Como se podía esperar, la probabilidad a posteriori es sólo 0 cuando la a priori es 0 (es decir, cuando es conocido que la población está libre de la infección) y es 1 cuando la probabilidad a priori es 1 (cuando es conocido que la población está infectada universalmente). Es decir, el valor predictivo que cabe atribuir a un resultado positivo de cierta prueba diagnóstica en función de las características intrínsecas de dicha prueba (su sensibilidad y su especificidad) y de la prevalencia de la enfermedad. Así se transforma o modifica la probabilidad a priori, de padecer la enfermedad (representada por su prevalencia) en la probabilidad a posteriori (valor predictivo), una vez observado dicho resultado (positivo) de la prueba diagnóstica. Mientras que la sensibilidad y la especificidad se ubican en el marco de la deducción (probabilidad de un resultado de una prueba, dado que se tiene o no la enfermedad), los valores predictivos son medidas inductivas, que permiten un juicio probabilístico acerca de que el paciente tenga o no la enfermedad a partir de la observación de un resultado concreto de una prueba en ese paciente.

Ejemplo 10.5 (Continuación ejemplo 10.4) Desarrollar gráficamente el mecanismo de aprendizaje del teorema de Bayes.

Solución: En el ejemplo anterior también podemos observar gráficamente (figura 10.2) el proceso de aprendizaje que proporciona la metodología bayesiana, mediante su utilización secuencial. Observemos que los resultados del test sólo pueden ser: positivo o negativo, y por tanto, en cada momento y a la luz del resultado obtenido, nuestra creencia sobre el suceso V (tener el virus) irá modificándose. Por ello, calculando la probabilidad a posteriori de V para un resultado negativo del test, tenemos:

$$\Pr(V|-) = \Pr(V) \cdot \frac{\Pr(-|V)}{\Pr(-)} = \frac{0,02q}{0,02q + 0,98(1-q)},$$

siendo $q = \Pr(\bar{V})$.




Figura 10.2: Proceso de aprendizaje en la metodología bayesiana

Utilizando la bisectriz del cuadrado unidad podemos ir observando cómo van modificándose nuestras creencias a medida que se van incorporando nuevas informaciones, utilizando el mecanismo de aprendizaje bayesiano en el que las informaciones a posteriori de una etapa son las informaciones a priori de la siguiente.

Para un primer resultado positivo en el test, la posición 1 indica la probabilidad a posteriori del enfermo en poseer el virus. Una nueva prueba positiva lo coloca en la posición 2 para su probabilidad de tener la enfermedad. Finalmente, una tercera prueba negativa lleva el conocimiento de la probabilidad a posteriori a la posición 3. Esta probabilidad marcada en la posición 3 actuará como a priori cuando nuevas informaciones muestrales deseen incorporarse.

En general, el análisis estadístico de unos datos observados $\underline{x}$, suele comenzar con una evaluación descriptiva mediante la cual pueda sugerirse algún modelo probabilístico $\{f(\underline{x}|\theta); \theta \in \Theta\}$ que represente, para algún valor (desconocido) de θ , el mecanismo probabilístico que ha generado los datos $\underline{x}$ observados. El paradigma bayesiano establece que es necesario asignar una distribución a priori $\pi(\theta)$ sobre el espacio paramétrico Θ que describa el conocimiento disponible sobre el valor θ antes de haber observado los datos. Se sigue entonces por la teoría de la probabilidad que, si el modelo de probabilidad es correcto, toda la información disponible sobre el valor de θ después de observar $\underline{x}$ estará contenida en la densidad a posteriori $\pi(\theta|\underline{x})$ obtenida mediante:

$$\Pr(\theta_i|\underline{x}) = \frac{f(\underline{x}|\theta_i) \Pr(\theta_i)}{\sum_{j=1}^n f(\underline{x}|\theta_j) \Pr(\theta_j)} \propto f(\underline{x}|\theta_i) \Pr(\theta_i), \quad i = 1, \dots, n, \quad (10.1)$$

$$\pi(\theta|\underline{x}) = \frac{f(\underline{x}|\theta) \pi(\theta)}{\int_{\Theta} f(\underline{x}|\theta) \pi(\theta) d\theta} \propto f(\underline{x}|\theta) \cdot \pi(\theta). \quad (10.2)$$

Las expresiones (10.1) y (10.2) constituyen el teorema de Bayes para el caso discreto y continuo, respectivamente.

Observados unos datos $\underline{x}$, la cantidad que aparece en el denominador (denominada distribución *predictiva*, ya sea en el caso continuo o discreto) es constante y por eso es común escribir el teorema de Bayes en su interpretación como actualización de juicios mediante:

Conocimiento a posteriori $\propto$ Conocimiento a priori $\times$ Información muestral.

Al contrario que en la estadística clásica, los parámetros no son cantidades fijas, si no que se consideran variables aleatorias. Esto no es una descripción de su variabilidad (los parámetros pueden suponerse fijos pero desconocidos) sino que más bien es una descripción de la incertidumbre sobre su verdadero valor.

Los fundamentos de la estadística bayesiana son muy simples. El paradigma bayesiano se basa en el aprendizaje. Así, la misión de los datos es añadir información a nuestros conocimientos y, de esta forma, actualizar nuestras creencias sobre los parámetros de interés y las hipótesis relevantes. Debemos por tanto especificar nuestras creencias anteriores al análisis de los datos, lo que denominamos

como información a priori. Es debido al uso de esta información a priori que la aproximación bayesiana utiliza más información que la aproximación frecuentista.

La información a priori expresa lo que se conoce, acerca de los parámetros de interés antes de observar los datos. Esta información es entonces combinada con los datos para producir la distribución a posteriori, que expresa lo que se conoce de los parámetros de interés tras el análisis de los datos.

El mecanismo matemático a través del cual la información a priori se combina con los datos es el teorema de Bayes. La forma más sencilla de expresar el teorema de Bayes es la siguiente:

*"La distribución a posteriori es proporcional
al producto de la distribución a priori por la verosimilitud"*

o dicho de otra manera: los nuevos juicios sobre el sistema se forman combinando los juicios iniciales (o a priori) con la información muestral de los datos (o verosimilitud).




Figura 10.3: Verosimilitud, densidad a priori, densidad a posteriori y triplot

La figura 10.3 refleja lo descrito anteriormente. En efecto, vemos cómo nuestros nuevos juicios contienen la información de la distribución a priori y los datos. La estimación a posteriori (posterior) es, por tanto, un punto medio entre las creencias

a priori y los datos. De esta forma obtiene estimaciones más precisas que cada información por separado. Esta es una de las ventajas del análisis bayesiano, la posibilidad de hacer uso de más información y obtener así resultados más precisos.

Ejemplo 10.6 Una compañía aseguradora lanza una oferta de un producto entre los clientes de una determinada cartera. Se sabe que la campaña no es efectiva para un 20 % de los clientes que actualmente tienen suscrita dicha póliza. Una nueva campaña ha sido desarrollada y deseamos compararla utilizando una muestra de tamaño $n = 75$. Sea ϕ la tasa de fallos de la nueva campaña. De los 75 clientes, la nueva campaña ha fallado en $y = 60$ casos. Para una a priori $Be(6, 1)$ para ϕ , obtener la distribución a posteriori.

Solución: La verosimilitud asociada será $L(\underline{x}|\phi) \propto \phi^{60} \cdot (1 - \phi)^{15}$, que junto con la a priori seleccionada $\pi(\phi) \propto \phi^5$, proporciona una distribución a posteriori de la forma $\pi(\phi|\underline{x}) \propto L(\underline{x}|\phi)\pi(\phi) \propto \phi^{65}(1 - \phi)^{15}$, que corresponde a una distribución $Be(66, 16)$.

De acuerdo con el método bayesiano, las preguntas sobre los parámetros de interés deben ser resueltas a partir de la distribución a posteriori. Una estimación puntual del parámetro puede ser la moda, la media o la mediana. A partir de la distribución a posteriori podemos obtener, además, la probabilidad de las hipótesis.

Por tanto, si la estadística se ocupa del estudio de la incertidumbre, el método bayesiano proporciona una metodología completa para la inferencia estadística y la toma de decisiones bajo incertidumbre. Esta metodología está coherentemente fundamentada y permite incorporar información inicial relevante al proceso de decisión. El método bayesiano está basado en la interpretación de la probabilidad como una medida condicional de la incertidumbre y por tanto está íntimamente ligado al concepto de probabilidad (Laplace, 1814; de Finetti, 1937, 1974, 1975; Jeffreys, 1961). La inferencia estadística sobre una cantidad de interés viene descrita por la modificación de la incertidumbre sobre su valor que se haga a la luz de la evidencia muestral y a través del teorema de Bayes que actúa como la herramienta necesaria para procesar y convertir creencias iniciales en revisadas.

10.2.1. Uso secuencial del teorema de Bayes

De los ejemplos anteriores hemos podido deducir que uno de los aspectos sobresalientes del método bayesiano es la posibilidad de utilizar secuencialmente el teorema de Bayes, algo así como que "la distribución a posteriori de hoy es la distribución a priori de mañana". En efecto, si tenemos un muestra inicial $\underline{x}$, conocemos que

$$\pi(\theta|\underline{x}) \propto \pi(\theta) \cdot L(\underline{x}|\theta),$$

donde L denota la función de verosimilitud de los datos:

$$L(\underline{x}|\theta) = \prod_{i=1}^n f(x_i|\theta),$$

siendo n el tamaño muestral. Esta notación la utilizaremos en todo lo que sigue. Ahora supongamos que deseamos incorporar un segundo conjunto de observaciones $\mathbf{z}$ independientes e igualmente distribuidas que las primeras observaciones. Entonces:

$$\pi(\theta|\underline{x}, \mathbf{z}) \propto \pi(\theta) \cdot L(\underline{x}, \mathbf{z}|\theta).$$

Ahora bien, la independencia implica que

$$f(y, z|\theta) = f(y|\theta) \cdot f(z|\theta)$$

y por tanto,

$$L(\underline{x}, \mathbf{z}|\theta) \propto L(\underline{x}|\theta) \cdot L(\mathbf{z}|\theta).$$

En consecuencia,

$$\pi(\theta|\underline{x}, \mathbf{z}) \propto \pi(\theta) \cdot L(\underline{x}|\theta) \cdot L(\mathbf{z}|\theta) \propto \pi(\theta|\underline{x}) \cdot L(\mathbf{z}|\theta).$$

Vemos por tanto que la distribución a posteriori de θ dados $\underline{x}$ y $\mathbf{z}$ se obtiene considerando la distribución a posteriori de θ dado $\underline{x}$ como la a priori para el proceso cuando se incorporan los datos $\mathbf{z}$.

10.2.2. La distribución predictiva

Tal y como hemos visto en el enunciado del teorema de Bayes y en los ejemplos desarrollados anteriormente, el factor de proporcionalidad que convierte en igualdad el ajuste del juicio a posteriori mediante la verosimilitud y la a priori es la distribución marginal:

$$p(\underline{x}) = \int_{\Theta} L(\underline{x}|\theta)\pi(\theta)d\theta,$$

en su versión continua. En el caso discreto, basta sustituir el operador integral por el sumatorio.

Definición 10.1 Denominaremos *distribución predictiva a priori* a la distribución de los datos $\underline{x}$ para el modelo de verosimilitud dado por $L(\underline{x}|\theta)$ y la densidad a priori $\pi(\theta)$, definida por

$$p(\underline{x}) = \int_{\Theta} \pi(\theta)L(\underline{x}|\theta)d\theta.$$

Análogamente, para el caso de un nuevo conjunto de observaciones $\mathbf{z}$ independientes de las anteriores, definiremos la *distribución predictiva (a posteriori)* por

$$p(\mathbf{z}|\underline{x}) = \int_{\Theta} L(\mathbf{z}|\theta)\pi(\theta|\underline{x})d\theta.$$

10.3. Estimación bayesiana puntual: intervalos y test de hipótesis

Como hemos visto en las secciones anteriores en el análisis bayesiano son tres los elementos fundamentales. Por un lado el modelo generador de los datos que, en común con la estadística clásica viene determinado por la expresión de la función de verosimilitud $L(\underline{x}|\theta)$. Por otro lado, los juicios iniciales del investigador deben ser expresados en términos de una densidad a priori $\pi(\theta)$ que mejor refleje nuestros conocimientos sobre el parámetro de interés. Finalmente, el mecanismo de aprendizaje que constituye el teorema de Bayes nos permite obtener la densidad a posteriori, $\pi(\theta|\underline{x})$, siendo ésta la función que mejor representa nuestros juicios a la luz de los datos observados. Esta densidad a posteriori es una descripción completa de este conocimiento final y por tanto, en cierto sentido, el análisis podría considerarse que está completo, puesto que conocemos todo el comportamiento del parámetro de interés.

10.3.1. Estimación puntual

Habitualmente tendremos necesidad de resumir todo nuestro conocimiento sobre el parámetro de interés (expresado a través de la distribución a posteriori $\pi(\theta|\underline{x})$) en un único valor, $\hat{\theta}$. En tal caso se utilizan las medidas clásicas de localización: media, mediana y moda. En muchas ocasiones, la distribución a posteriori suele ser unimodal y simétrica y en consecuencia, cualquiera de las tres medidas resulta igualmente idónea como estimador puntual puesto que coinciden en valor. Sin embargo, en otras ocasiones la distribución a posteriori presenta cierta asimetría, lo que hace que la mediana a posteriori sea el estimador puntual bayesiano preferido. Finalmente, si admitimos que la distribución a posteriori del parámetro refleja todo el conocimiento disponible sobre él una vez que hemos observado los datos y necesitamos un valor que concentre todo este conocimiento, parece lógico pensar que debemos utilizar la moda a posteriori como dicho estimador bayesiano, ya que la moda es el valor donde se hace máxima dicha distribución a posteriori y en cierto sentido es donde existe mayor plausibilidad de ocurrencia.

La moda también es conocida como *estimador bayesiano de máxima verosimilitud* debido a lo siguiente. De una manera no rigurosa podríamos enunciarlo así: cuando un investigador no desea incorporar información inicial a su estudio y opta por decidir a la luz única y exclusiva de los resultados muestrales, puede utilizar como densidad a priori una no-informativa del tipo $\pi(\theta) \propto 1$. En tal caso, la distribución a posteriori del parámetro es proporcional a la función de verosimilitud, es decir: $\pi(\theta|\underline{x}) \propto L(\underline{x}|\theta)$, y por tanto los valores máximos de ambas funciones coincidirán.

10.3.2. Intervalos bayesianos de credibilidad

Junto con las medidas de localización es habitual en inferencia estadística aportar información en torno a los intervalos que contienen al parámetro con cierta probabilidad. El equivalente bayesiano a los intervalos de confianza clásicos surge de manera natural y su interpretación no es ambigua puesto que utiliza de manera natural la probabilidad de que el parámetro de interés pertenezca a un determinado intervalo, lo cual es posible dado el carácter aleatorio que suponemos para el parámetro. Construiremos ahora los intervalos bayesianos de credibilidad como alternativa a los intervalos de confianza clásicos. En ocasiones y por abuso de lenguaje también llamaremos intervalos bayesianos de confianza a dichos intervalos.

Definición 10.2 Los puntos a_1 y a_2 definen un intervalo bayesiano de credibilidad con probabilidad $100(1 - \alpha)\%$, si se verifica que

$$\Pr(a_1 \leq \theta \leq a_2 | x) = \int_{a_1}^{a_2} \pi(\theta | x) d\theta \geq 1 - \alpha.$$

Hemos definido el intervalo de credibilidad utilizando la distribución a posteriori. Es posible definir un intervalo (a priori) de credibilidad sin más que sustituir la densidad a posteriori por la a priori.

Una de las principales ventajas de los intervalos bayesianos de credibilidad es que podemos interpretarlos en términos de probabilidad. En efecto, si por ejemplo en una situación particular, encontramos que $\Pr(a_1 \leq \theta \leq a_2 | x) = 0,95$ podremos decir que (una vez observados los datos x) con probabilidad 0,95 el intervalo $[a_1, a_2]$ contiene al verdadero valor del parámetro.

Como vemos esta forma de definir los intervalos de credibilidad no nos asegura su unicidad y básicamente se nos pueden presentar varias situaciones:

1. Intervalos de una cola. En esta situación estaríamos hablando de los cuantiles de la distribución a posteriori. Por ejemplo, para el caso continuo uniparamétrico con $\Theta = (-\infty, \infty)$, un intervalo bayesiano de credibilidad al $100(1 - \alpha)\%$ (de una cola) nos lo proporciona cualquier intervalo (θ^*, ∞) que cumpla $\Pr(\theta > \theta^* | x) = \int_{\theta^*}^{\infty} \pi(\theta | x) d\theta = 1 - \alpha$.
2. Intervalos de dos colas con igual área. Este es el caso habitual en el que consideramos cualquier intervalo (θ_*, θ^*) que cumple que $\Pr(\theta_* \leq \theta \leq \theta^* | x) = 1 - \alpha$ y cada extremo del intervalo verifica que $\Pr(\theta_* < \theta | x) = \frac{\alpha}{2}$ y $\Pr(\theta^* < \theta | x) = \frac{\alpha}{2}$.
3. Intervalos de alta densidad a posteriori (en notación, HPD o también HDI). Cuando la distribución a posteriori es asimétrica puede ocurrir que el intervalo con extremos que tienen igual área no sea el intervalo de menor longitud. Este es el caso del apartado (b) en la figura 10.4. En tal situación el intervalo con extremos con igual área es $[0,8; 6,3]$ mientras el intervalo de menor

longitud incluyendo la misma cantidad de probabilidad es $[0,4; 5,5]$. La misma situación puede ocurrir en el caso de bimodalidad como aparece en el apartado (c) de la figura 10.4




Figura 10.4: Diferentes situaciones para intervalos bayesianos de credibilidad, Spiegelhalter et al. (2004)

Parece por tanto lógico utilizar de entre todos los intervalos aquel que tenga menor longitud.

Definición 10.3 Un conjunto C se dice que es un conjunto de credibilidad de alta densidad con probabilidad $100(1 - \alpha)\%$, en notación, $100(1 - \alpha)\%$ HPD si verifica:

$$1. \Pr(\theta \in C | x) = \int_C \pi(\theta | x) d\theta = 1 - \alpha.$$

2. Dado cualquier otro conjunto C_2 que cumpla la condición anterior, para cualquier $\theta_1 \in C$ y cualquier $\theta_2 \in C_2$ se cumple que $\pi(\theta_1 | x) \geq \pi(\theta_2 | x)$.

En definitiva, un intervalo HPD es aquel intervalo que alcanzando una probabilidad a posteriori dada tiene menor longitud. En ocasiones, un conjunto creíble

HPD puede estar formado por la unión de dos o más intervalos. El siguiente resultado señala condiciones para asegurar la coincidencia entre un intervalo de dos colas y el HPD.

Proposición 10.1 Si la densidad a posteriori $\pi(\theta|\underline{x})$ es unimodal y continua, entonces el intervalo bayesiano de credibilidad con probabilidad $1 - \alpha$ con menor longitud $l = b - a$ es la única solución de:

$$\int_a^b \pi(\theta|\underline{x}) d\theta = 1 - \alpha,$$

$$\pi(a|\underline{x}) = \pi(b|\underline{x}).$$

Este intervalo además coincide con el HPD.

10.3.3. Tests de hipótesis bayesianos

La teoría estadística de los contrastes de hipótesis también admite una formulación bayesiana. Lejos de entrar en polémicas sobre falacias de p -valores y verdaderas interpretaciones de los niveles de significación de los tests clásicos (referencias sobre el tema son Lehmann, 1986; Berger, 1985; Bayarri y Berger, 2000; entre otros) los elementos del análisis bayesiano para contrastes de hipótesis aparecen de manera natural.

La forma más simple de plantear un test de hipótesis para un parámetro desconocido $\theta \in \Theta$ puede ser la siguiente. Supongamos que el espacio paramétrico Θ está particionado en dos conjuntos Θ_0 y Θ_1 tales que: $\Theta_0 \cup \Theta_1 = \Theta$ y $\Theta_0 \cap \Theta_1 = \emptyset$. Normalmente el interés del investigador se centra en conocer si podemos considerar que $H_0 : \theta \in \Theta_0$ (denominada *hipótesis nula*) es cierta (en probabilidad) o por el contrario lo es $H_1 : \theta \in \Theta_1$ (*hipótesis alternativa*). Para ello usaremos un conjunto de observaciones $\mathbf{x} = \underline{x} = (x_1, \dots, x_n)$ muestreadas todas ellas de manera independiente y de la misma distribución $f(\mathbf{x}|\theta)$.

El contraste de hipótesis bayesiano es sencillo: necesitamos calcular las probabilidades a posteriori de cada una de las hipótesis:

$$p_0 = \Pr(H_0 \text{ cierta} | \mathbf{x}) = \Pr(\theta \in \Theta_0 | \mathbf{x}), \quad p_1 = \Pr(H_1 \text{ cierta} | \mathbf{x}) = \Pr(\theta \in \Theta_1 | \mathbf{x})$$

y decidir entre H_0 y H_1 .

Para ello el paradigma bayesiano nos indica que necesitamos disponer de las probabilidades a priori de cada una de las hipótesis:

$$\pi_0 = \Pr(H_0 \text{ cierta}) = \Pr(\theta \in \Theta_0), \quad \pi_1 = \Pr(H_1 \text{ cierta}) = \Pr(\theta \in \Theta_1).$$

Definición 10.4 Se define el "odds" a priori de H_0 frente a H_1 como el cociente $\frac{\pi_0}{\pi_1}$. Análogamente se define el "odds" a posteriori de H_0 frente a H_1 como el cociente $\frac{p_0}{p_1}$.

10.3. Estimación bayesiana puntual: intervalos y test de hipótesis

Obsérvese que el "odds" a priori necesita ser asignado por el investigador mientras que el "odds" a posteriori se obtiene mediante el mecanismo de revisión de juicios que es el teorema de Bayes. La interpretación de estas cantidades es muy sencilla e intuitiva. Valores del "odds" a priori (a posteriori) próximos a 1 indicarán que H_0 es igualmente probable que H_1 a priori (a posteriori) y valores marcadamente mayores que 1 indicarán evidencia a priori (a posteriori) a favor de H_0 frente a H_1 . Inversamente para valores menores que 1.

Resulta también útil el concepto de factor Bayes.

Definición 10.5 Denominaremos factor Bayes en favor de H_0 frente a H_1 al cociente

$$B_{01} = \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{p_0\pi_1}{p_1\pi_0}. \quad (10.3)$$

De la propia definición del factor Bayes se deduce que

$$\frac{p_0}{p_1} = B_{01} \frac{\pi_0}{\pi_1},$$

y por tanto, el factor Bayes B_{01} es la cantidad que multiplicada por el "odds" a priori nos proporciona el "odds" a posteriori. Esencialmente estos son todos los elementos necesarios para el proceso de decisión en un test de hipótesis bayesiano. A continuación estudiaremos las situaciones más habituales y veremos cómo obtener cada una de estas cantidades.

Hipótesis nula simple frente alternativa simple

El problema ahora es el siguiente:

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta = \theta_1.$$

En tal caso, $\pi_i = \Pr(\theta = \theta_i)$, $i = 0, 1$, deben ser asignadas por el investigador y para un modelo de verosimilitud dado, $f(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta)$, tendremos que las probabilidades a posteriori de cada hipótesis se calculan mediante:

$$p_i \propto \pi_i f(\mathbf{x}|\theta_i), \quad i = 0, 1.$$

De esta forma obtenemos que el "odds" a posteriori se deduce de

$$\frac{p_0}{p_1} = \frac{f(\mathbf{x}|\theta_0)}{f(\mathbf{x}|\theta_1)} \cdot \frac{\pi_0}{\pi_1},$$

es decir, para este caso el factor Bayes a favor de H_0 frente a H_1 vale

$$B_{01} = \frac{f(\mathbf{x}|\theta_0)}{f(\mathbf{x}|\theta_1)}.$$

En esta situación el factor Bayes coincide con el cociente de verosimilitudes de H_0 frente a H_1 y por tanto puede ser interpretado como la evidencia que única y exclusivamente aportan los datos x en favor de H_0 frente a H_1 .

Sin embargo, esta interpretación no es tan sencilla cuando las hipótesis no son simples (Lee, 1997). En tal caso el factor Bayes obtenido es un cociente de verosimilitudes medias "ponderadas" por la densidad a priori de θ sobre el soporte que define cada hipótesis. Aún así y por abuso de lenguaje, en la mayoría de las ocasiones, el factor Bayes se interpreta como la evidencia que sólo los datos aportan a la hipótesis nula frente a la alternativa.

Finalmente, observemos que para este caso (y para cualquier otro en el que $\pi_0 + \pi_1 = p_0 + p_1 = 1$) tendremos que

$$p_0 = p_1 B_{01} \frac{\pi_0}{\pi_1} \iff p_0 = (1 - p_0) B_{01} \frac{\pi_0}{1 - \pi_0},$$

es decir,

$$p_0 = \frac{B_{01}}{B_{01} + \frac{1 - \pi_0}{\pi_0}} \iff p_0 = \frac{1}{1 + \frac{1 - \pi_0}{\pi_0} \frac{1}{B_{01}}}. \quad (10.4)$$

Por tanto, si tenemos un factor Bayes "controlado" es posible obtener la probabilidad a posteriori de la hipótesis nula sin más que conocer su probabilidad a priori.

Ejemplo 10.7 Consideremos una población geométrica: $f(x|\theta) = \theta(1-\theta)^x$, $x = 0, 1, 2, \dots$ de la que disponemos de una muestra de tamaño n , $x_1, \dots, x_n$, y deseamos realizar el test: $H_0: \theta = \frac{3}{4}$ vs $H_1: \theta = \frac{1}{2}$. Obtener el factor Bayes B_{01} para una situación no informativa ($\pi_0 = \pi_1 = \frac{1}{2}$) con $n = 21$ y $n\bar{x} = 13$.

Solución: En general para el test propuesto tenemos $\pi_0 = \pi_1 = \frac{1}{2}$, y por tanto las probabilidades a posteriori de las hipótesis se calcularán de la siguiente forma:

$$p_0 \propto \pi_0 \cdot f(x|\theta_0) \propto \frac{1}{2} \theta_0^n (1 - \theta_0)^{n\bar{x}},$$

$$p_1 \propto \pi_1 \cdot f(x|\theta_1) \propto \frac{1}{2} \theta_1^n (1 - \theta_1)^{n\bar{x}},$$

de donde el cociente a posteriori resulta:

$$\frac{p_0}{p_1} = \left(\frac{\theta_0}{\theta_1}\right)^n \cdot \left(\frac{1 - \theta_0}{1 - \theta_1}\right)^{n\bar{x}}.$$

Para el caso que nos ocupa, $\theta_0 = \frac{3}{4}$ y $\theta_1 = \frac{1}{2}$, cuyo valor es $\left(\frac{3/4}{1/2}\right)^{21} \cdot \left(\frac{1/4}{1/2}\right)^{13} = \frac{3^{21}}{2^{34}} = 0,61$.

Ejemplo 10.8 Consideremos $X \sim \mathcal{N}(0, \sigma^2)$ y sea $h = \frac{1}{\sigma^2}$. Supongamos que estamos interesados en el contraste:

$$H_0: h = 1 \text{ vs } H_1: h = \frac{1}{2}.$$

Consideremos una muestra aleatoria simple $X_1, \dots, X_n$ procedente de la población anterior. Para una a priori no informativa para ambas hipótesis, obtener una expresión para el factor Bayes.

Solución: El test planteado es equivalente a $H_0: \sigma^2 = 1$ vs $H_1: \sigma^2 = 2$. El factor Bayes será:

$$B_{01} = \frac{p_0 \pi_1}{p_1 \pi_0} = \frac{f(x_1, \dots, x_n | \sigma^2 = 1)}{f(x_1, \dots, x_n | \sigma^2 = 2)},$$

siendo:

$$f(x_1, \dots, x_n | \sigma^2) = \frac{1}{(2\pi)^{n/2} (\sigma^2)^{n/2}} \exp\left(-\frac{1}{2} \frac{\sum_{i=1}^n x_i^2}{\sigma^2}\right).$$

Luego tendremos:

$$B_{01} = \frac{(\sigma_1^2)^{n/2} \exp\left(-\frac{1}{2} \frac{\sum_{i=1}^n x_i^2}{\sigma_1^2}\right)}{(\sigma_0^2)^{n/2} \exp\left(-\frac{1}{2} \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2}\right)} = \left(\frac{\sigma_1^2}{\sigma_0^2}\right)^{n/2} \exp\left[-\frac{1}{2} \left(\frac{\sigma_1^2 - \sigma_0^2}{\sigma_1^2 \sigma_0^2}\right) \left(\sum_{i=1}^n x_i^2\right)\right].$$

En nuestro caso:

$$B_{01} = 2^{n/2} \exp\left(-\frac{1}{4} \sum_{i=1}^n x_i^2\right).$$

Hipótesis nula compuesta frente a alternativa compuesta

Las situaciones que vamos a estudiar ahora son aquellas que puedan formularse de la siguiente forma,

$$H_0: \theta \in \Theta_0 \text{ vs } H_1: \theta \in \Theta_1.$$

Esta situación contempla tanto los test unilaterales: $H_0: \theta < \theta_0$ vs $H_1: \theta \geq \theta_0$ (en cualquiera de sus posibles formulaciones) como los contrastes del tipo: $H_0: \theta \in (\theta_0, \theta_1)$ vs $H_1: \theta \notin (\theta_0, \theta_1)$, pudiendo ser $\theta_0 = -\infty$ y $\theta_1 = +\infty$.

En cualquiera de las situaciones descritas anteriormente el procedimiento es esencialmente el mismo y está basado en el paradigma bayesiano. Asignada una densidad a priori para θ sobre el espacio paramétrico Θ , cada una de las hipótesis tendrá unas probabilidades a priori de ser ciertas obtenidas mediante

$$\pi_0 = \int_{\Theta_0} \pi(\theta) d\theta, \quad \pi_1 = \int_{\Theta_1} \pi(\theta) d\theta,$$

y observados los datos x con verosimilitud $f(x|\theta)$, cada una de las probabilidades a priori se transformarán en a posteriori mediante el teorema de Bayes ($\pi(\theta|x) \propto f(x|\theta)\pi(\theta)$):

$$p_0 = \Pr(H_0 \text{ cierta } |x) = \Pr(\theta \in \Theta_0 |x) = \int_{\Theta_0} \pi(\theta|x) d\theta, \quad (10.5)$$

$$p_1 = \Pr(H_1 \text{ cierta } |x) = \Pr(\theta \in \Theta_1 |x) = \int_{\Theta_1} \pi(\theta|x) d\theta. \quad (10.6)$$

El factor Bayes ahora se obtiene nuevamente usando la expresión (10.3).

Ejemplo 10.9 Realizar el test de hipótesis $H_0 : \theta \leq \theta_0$ vs $H_1 : \theta > \theta_0$ para el caso de una muestra de tamaño n de una población normal de media θ desconocida y varianza σ^2 conocida usando una densidad a priori no informativa del tipo $\pi(\theta) \propto 1$.

Solución: En primer lugar debemos hacer notar que dicha densidad a priori no es estrictamente una densidad puesto que no integra 1 sobre el espacio paramétrico. Sin embargo, densidades de este tipo pueden incorporarse al análisis siempre que la densidad a posteriori exista. Su interpretación correspondería con una situación en la que el investigador considera igualmente probable cualquier valor a priori del parámetro. La función de verosimilitud es:

$$f(x|\theta) = \prod_{i=1}^n f(x_i|\theta) = (2\pi)^{-n/2} \sigma^{-n} \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \theta)^2}{\sigma^2} \right\}.$$

Combinando con la densidad a priori $\pi(\theta) \propto 1$, obtendremos la densidad a posteriori

$$\pi(\theta|x) \propto \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \theta)^2}{\sigma^2} \right\} \propto \exp \left\{ -\frac{1}{2} \frac{(\theta - \bar{x})^2}{\sigma^2/n} \right\}.$$

En consecuencia la densidad a posteriori es $\mathcal{N}(\bar{x}, \sigma^2/n)$. Por tanto, la probabilidad a posteriori de la hipótesis nula será

$$p_0 = \Pr(\theta \leq \theta_0 |x) = \Pr \left(\frac{n(\theta - \bar{x})}{\sigma^2} \leq \frac{n(\theta_0 - \bar{x})}{\sigma^2} \right) = \Phi \left(\frac{n(\theta_0 - \bar{x})}{\sigma^2} \right). \quad (10.7)$$

Es interesante observar ahora la relación entre el valor de p_0 y el concepto clásico de p -valor para este test de hipótesis. En efecto, desde el punto de vista clásico el p -valor del test viene definido como la probabilidad de observar un valor mayor o igual del observado x cuando $\theta = \theta_0$. Matemáticamente se expresa como:

$$p\text{-valor} = \Pr(\bar{X} \geq \bar{x} | \theta = \theta_0) = 1 - \Phi \left(\frac{n(\bar{x} - \theta_0)}{\sigma^2} \right) = \Phi \left(\frac{n(\theta_0 - \bar{x})}{\sigma^2} \right) = p_0.$$

Por tanto, hemos probado que en el caso de una muestra normal bajo información a priori no informativa, el p -valor coincide con la probabilidad a posteriori de la hipótesis nula. Sólo en estas condiciones es cuando se da la coincidencia.

Hipótesis nula simple frente alternativa compuesta

Construiremos ahora el procedimiento para el contraste de hipótesis del tipo:

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta \neq \theta_0.$$

A diferencia de las situaciones anteriores en este caso la densidad a priori sobre las hipótesis estará definida como una mixtura de distribuciones discreta y continua, respectivamente. Es decir,

$$\pi(\theta) = \begin{cases} \pi_0 & \text{si } \theta = \theta_0, \\ (1 - \pi_0)\pi_1(\theta) & \text{si } \theta \neq \theta_0, \end{cases}$$

siendo $\pi_1(\theta)$ una densidad sobre el espacio $\Theta_1 = \Theta - \{\theta_0\}$. En tal caso, la distribución predictiva necesaria para el cálculo de las probabilidades a posteriori se obtiene por

$$p(x) = \pi_0 f(x|\theta_0) + (1 - \pi_0)p_1(x), \quad (10.8)$$

siendo $p_1(x) = \int_{\{\theta \neq \theta_0\}} \pi_1(\theta) f(x|\theta) d\theta$.

El cálculo de las probabilidades a posteriori es inmediato:

$$\begin{aligned} p_0 &= \Pr(H_0 \text{ cierta } |x) = \frac{\pi_0 f(x|\theta_0)}{p(x)}, \\ p_1 &= \Pr(H_1 \text{ cierta } |x) = \frac{(1 - \pi_0)p_1(x)}{p(x)}. \end{aligned}$$

De donde deducimos que el factor Bayes es:

$$B_{01} = \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{f(x|\theta_0)}{p_1(x)}.$$

Continuamos con el ejemplo anterior 10.9 para poner de manifiesto una de las paradojas más sorprendentes del análisis clásico.

Ejemplo 10.10 (Paradoja de Lindley, 1957) Realizar el test de hipótesis $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$ para el caso de una muestra de tamaño n de una población normal de media θ desconocida y varianza σ^2 conocida usando una densidad a priori mixta del tipo

$$\pi(\theta) = \begin{cases} \pi_0 & \text{si } \theta = \theta_0, \\ (1 - \pi_0)\pi_1(\theta) & \text{si } \theta \neq \theta_0 \end{cases}$$

con $\pi_1(\theta)$ una densidad $\mathcal{N}(\theta_0, \sigma^2)$.

Solución: Utilizaremos como ya es frecuente el estadístico suficiente de la media muestral, $\bar{x}$. Los elementos disponibles son:

$$\begin{aligned}\pi_1(\theta) &= \frac{\sqrt{2\pi}\sigma}{\exp\left\{-\frac{1}{2}\frac{(\theta - \theta_0)^2}{\sigma^2}\right\}}, \\ f(\bar{x}|\theta_0) &= \frac{\sqrt{n}}{\sqrt{2\sigma}} \exp\left\{-\frac{n}{2}\frac{(\bar{x} - \theta_0)^2}{\sigma^2}\right\}, \\ p_1(\bar{x}) &= \int_{\{\theta \neq \theta_0\}} f(\bar{x}|\theta)\pi_1(\theta)d\theta, \quad (10.9)\end{aligned}$$

siendo $f(\bar{x}|\theta)$ la función de densidad de una $\mathcal{N}(\theta, \sigma^2/n)$ y como θ_0 no aporta medida a la integral tendremos que (10.9) vale

$$p_1(\bar{x}) = \sqrt{\frac{n}{n+1}} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\frac{n}{n+1}\frac{(\bar{x} - \theta_0)^2}{\sigma^2}\right\}.$$

De donde se deduce que el "odds" a posteriori es:

$$\frac{p_0}{p_1} = \frac{\pi_0}{1 - \pi_0} \cdot \sqrt{n+1} \cdot \exp\left\{-\frac{n}{n+1}\frac{z^2}{2}\right\},$$

con $z = \frac{\sqrt{n}}{\sigma} \cdot |\bar{x} - \theta_0|$, el estadístico clásico utilizado habitualmente para este tipo de contrastes. El factor Bayes tiene la expresión siguiente:

$$B_{01} = \sqrt{n+1} \cdot \exp\left\{-\frac{n}{n+1}\frac{z^2}{2}\right\}.$$

Observemos por tanto que para un valor de π_0 fijo, $0 < \pi_0 < 1$, se obtiene que para tamaños muestrales grandes $B_{01}(n) \rightarrow \infty$ (cuando $n \rightarrow \infty$). Este hecho influye directamente en las probabilidades a posteriori de las hipótesis. En efecto, la probabilidad a posteriori de la hipótesis nula es (haciendo uso de (10.4)):

$$p_0 = \Pr(H_0 \text{ cierta} | \bar{x}) = \frac{1}{1 + \frac{1 - \pi_0}{\pi_0} \cdot \frac{1}{B_{01}}},$$

y por tanto $p_0(n) \rightarrow 1$ (cuando $n \rightarrow \infty$). Por ejemplo, si para $n = 100$ observamos $z = 1,96$ (lo que implicaría desde el punto de vista clásico el rechazo de H_0 para un nivel de significación del 95%) resultaría para $\pi_0 = \frac{1}{2}$ que p_0 vale 0,6, con lo que el procedimiento clásico rechazaría H_0 con una probabilidad a posteriori de ser cierta del 60%. Para valores de n mayores la situación es más paradójica aún, por ejemplo, para $n = 1000$ se tiene que $p_0 = 0,8$.

◇

En definitiva, la paradoja de Lindley viene a informarnos de que si admitimos que las hipótesis tienen probabilidades a priori será erróneo interpretar el nivel de significación como la probabilidad de que H_0 sea cierta. Cotas para los valores de las probabilidades a posteriori de las hipótesis pueden obtenerse de forma genérica bajo condiciones más generales (Berger, 1985).

10.4. Inferencia bayesiana y teoría de la decisión

El problema de inferencia bayesiana puede ser visto de forma general como un problema de decisión. En tal caso, un nuevo elemento forma parte del problema: la función de pérdidas.

Definición 10.6 Una función de pérdidas $\mathcal{L}(\hat{\theta}, \theta)$ describe la pérdida en la que incurre el investigador cuando utiliza $\hat{\theta}$ como estimador de θ , verdadero valor del parámetro.

Como consecuencia de esta definición, es inmediato definir qué entenderemos por *estimador bayesiano*.

Definición 10.7 El estimador bayesiano de un parámetro para una función de pérdidas dada, es aquel que minimiza la pérdida esperada a posteriori.

El estimador bayesiano de cada situación dependerá de la función de pérdidas elegida.

Un problema estadístico desde el punto de vista de la teoría de la decisión está compuesto por:

1. Un espacio de estados de la naturaleza o espacio paramétrico Θ .
2. Un conjunto de acciones posibles llamadas decisiones, y que se denotan por D .
3. Una función de pérdida:

$$\mathcal{L} : \Theta \times D \rightarrow \mathbb{R}^+.$$

4. Un modelo estadístico $(\mathcal{X}, \mathcal{A}, \mathcal{P})$ donde se puede observar una variable aleatoria cuya distribución depende de los estados de la naturaleza.

Valores "grandes" de $\mathcal{L}(\theta, d)$ indican que d es más incorrecto, mientras que valores "pequeños" indican que d es más correcto. En una función de utilidad hablamos de "ganancias" y no de pérdidas, por lo que la utilidad puede interpretarse simplemente por $-\mathcal{L}(\theta, d)$ (Berger, 1985). Algunas propiedades de las funciones de pérdidas son:

1. $\mathcal{L}(\theta, d) \geq 0$.
2. $\mathcal{L}(\theta, \theta) = 0$.
3. $\mathcal{L}(\theta, d) \leq \mathcal{L}(\theta, d')$, si $|\theta - d| \leq |\theta - d'|$.

En general, en la teoría de la estimación, el espacio de decisiones suele ser un subespacio de $\mathbb{R}^k$. Una función de decisión *no aleatorizada* es una aplicación

$$d: \mathcal{X} \longrightarrow D,$$

que a cada observación le asocia un decisión, y la función de riesgo es:

$$R(\theta, d) = E[\mathcal{L}(\theta, d(X))].$$

El problema central consiste en encontrar funciones de decisión adecuadas. Se dice que d_1 es preferible a d_2 si:

$$R(\theta, d_1) \leq R(\theta, d_2), \forall \theta \in \Theta.$$

En el caso en que hagamos variar ambas variables (θ, d) entonces la desigualdad anterior es sólo preorden parcial, en el sentido de que pueden existir decisiones no comparables, es decir,

$$R(\theta_1, d_1) < R(\theta_1, d_2) \quad \text{y} \quad R(\theta_2, d_1) > R(\theta_2, d_2).$$

Por tanto y en general, no hay decisiones óptimas.

Finalmente, elegida una función de pérdidas, el estimador Bayes (también llamado regla de Bayes) para una distribución a priori π , es la cantidad que minimiza la expresión

$$r(x, d) = \int_{\Theta} \mathcal{L}(\theta, d) \pi(\theta|x) d\theta,$$

para $d \in D$. No es objeto de esta obra hacer un desarrollo completo de toda la teoría de la decisión bayesiana. Obras de referencia son: DeGroot (1970), Berger (1985) y O'Hagan y Forster (2004).

10.4.1. Funciones de pérdidas en estadística actuarial

Algunas funciones de pérdidas utilizadas en la ciencia actuarial se presentan a continuación. En el capítulo 12 dedicado a tarificación se volverá a hablar sobre éstas y algunas otras funciones de pérdida.

Definición 10.8 (Pérdidas absolutas) La función de pérdida absoluta está definida por la expresión:

$$\mathcal{L}(\theta, d) = |\theta - d|.$$

Definición 10.9 (Pérdidas 0-1) La función de pérdida 0-1 está definida por la expresión:

$$\mathcal{L}(\theta, d) = \begin{cases} 0 & \text{si } \theta = d, \\ 1 & \text{si } \theta \neq d \end{cases}$$

10.4. Inferencia bayesiana y teoría de la decisión

Definición 10.10 (Pérdidas bilineales) Para a y b dos constantes positivas, se define la función de pérdidas bilineal como:

$$\mathcal{L}(\theta, d) = \begin{cases} a(\theta - d) & \text{si } d \leq \theta, \\ b(d - \theta) & \text{si } d \geq \theta. \end{cases} \quad (10.10)$$

Definición 10.11 (Pérdidas cuadráticas ponderadas) Una función de pérdidas cuadráticas ponderadas viene definida por la expresión $\mathcal{L}(d, \theta) = w(\theta)(\theta - d)^2$, siendo $w(\theta)$ una función positiva de θ .

Observemos que un caso particular de las pérdidas cuadráticas ponderadas lo constituye el caso de pérdidas cuadráticas sin más que considerar $w(\theta) = 1$. La siguiente función de pérdidas utilizada en problemas de estimación:

$$\mathcal{L}(\theta, d) = \begin{cases} (\theta - d)^2, & d < \theta, \\ K(d - \theta)^2, & d \geq \theta, \end{cases}$$

con $K > 1$, penaliza la sobre-estimación, más que la sub-estimación. En ocasiones también puede considerarse la función

$$\mathcal{L}(\theta, d) = \frac{(d - \theta)^2}{|\theta| + 1},$$

donde se penalizan los errores en la estimación más cuando θ está cerca de cero, que cuando $|\theta|$ es grande.

Definición 10.12 (Pérdidas LINEX) La función LINEX (LINEar EXponential), de carácter asimétrico propuesta por Varian (1975) y usada por Zellner (1986), viene definida por:

$$\mathcal{L}(\theta, d) = \exp\{c(d - \theta)\} - c(d - \theta) - 1. \quad (10.11)$$

Definición 10.13 (Pérdidas exponenciales) Hablaremos de pérdidas exponenciales cuando:

$$\mathcal{L}(\theta, d) = [\exp(c\theta) - \exp(cd)]^2, \quad (10.12)$$

siendo $c > 0$ una constante.

10.4.2. Estimadores puntuales bayesianos

La regla de decisión bayesiana para la estimación puntual de un parámetro consiste por tanto en elegir aquella decisión que minimice la pérdida (a posteriori) esperada. En consecuencia, obtendremos cada una de las decisiones óptimas bajo las principales funciones de pérdidas.

Consideremos el caso de pérdidas cuadrática ponderadas. En este caso la pérdida a posteriori esperada es

$$\begin{aligned} E[w(\theta)(\theta - d)^2 | x] &= \int_{\Theta} w(\theta)(\theta - d)^2 \pi(\theta | x) d\theta \\ &= E[w(\theta)(\theta - d)^2 | x] + [E_w(\theta | x) - d]^2, \quad (10.13) \end{aligned}$$

siendo:

$$E_w(\theta | x) = \frac{\int_{\Theta} w(\theta) \theta \pi(\theta | x) d\theta}{\int_{\Theta} w(\theta) \pi(\theta | x) d\theta}.$$

Por tanto, la expresión (10.13) es mínima cuando su segundo sumando se anula, es decir, debemos elegir $d = E_w(\theta | x)$, es decir, la esperanza a posteriori de $w(\theta)\theta$. Observemos, que como consecuencia de lo anterior tenemos el siguiente teorema.

Teorema 10.1 *El estimador bayesiano bajo pérdidas cuadráticas $\mathcal{L}(\theta, d) = (\theta - d)^2$ es la media a posteriori.*

Consideremos ahora el caso de las pérdidas bilineales dadas en (10.10). En tal caso y denotando por $\Pi(\theta)$ a la distribución asociada a la densidad $\pi(\theta)$, tendremos

$$-E[\mathcal{L}(\theta, d) | x] = ad(1 - \Pi(d | x)) - b\Pi(d | x) - a \int_d^{+\infty} \theta \pi(\theta | x) d\theta + b \int_{-\infty}^d \theta \pi(\theta | x) d\theta.$$

Derivando respecto de d tenemos

$$\begin{aligned} a(1 - \Pi(d | x)) - a d \pi(d | x) - b \Pi(d | x) - b d \pi(d | x) + a d \pi(d | x) \\ + b d \pi(d | x) = a - (a + b) \Pi(d | x). \end{aligned} \quad (10.14)$$

Ahora observemos que la expresión (10.14) vale cero cuando $\Pi(d | x) = \frac{a}{a+b}$, es decir que la decisión óptima (el estimador bayesiano) d coincide con el cuantil de orden $\frac{a}{a+b}$ de la distribución a posteriori.

Observemos que el caso de pérdidas absolutas es un caso particular de pérdidas bilineales con $a = b = 1$. En consecuencia, para pérdidas absolutas el estimador bayesiano coincide con el cuantil 50 % de la distribución a posteriori, es decir, con la mediana a posteriori.

El caso de las pérdidas 0-1 también puede verse dentro de un tipo más general de funciones de pérdidas, para la que la pérdida esperada a posteriori será

$$E[\mathcal{L}(\theta, d) | x] = \int_{|\theta - d| > b} \pi(\theta | x) d\theta = \Pr(|\theta - d| > b), \quad (10.15)$$

y por tanto, la decisión óptima d es el centro del intervalo de longitud $2b$ con mayor probabilidad (a posteriori).

Derivando en (10.15) respecto a d e igualando a cero obtenemos $\pi(d - b | x) = \pi(d + b | x)$, y por tanto los extremos del intervalo óptimo deben tener la misma densidad a posteriori.

En consecuencia, para el caso de pérdidas 0-1 que corresponde con el caso $b = 0$, tendremos que la decisión óptima (el estimador bayesiano) será la moda a posteriori.

Ejemplo 10.11 (Estimador Bayes para pérdidas LINEX) Obtener el estimador puntual bayesiano para el caso de una función de pérdidas tipo LINEX.

Solución: Para una función de pérdidas tipo LINEX la expresión a minimizar es:

$$\int_{\Theta} \exp(c(d - \theta)) \pi(\theta | x) d\theta - c \int_{\Theta} (d - \theta) \pi(\theta | x) d\theta - 1. \quad (10.16)$$

Derivando en (10.16) respecto d e igualando a cero tenemos:

$$c \exp(cd) \int_{\Theta} \exp(-c\theta) \pi(\theta | x) d\theta = c \iff \exp(cd) \int_{\Theta} \exp(-c\theta) \pi(\theta | x) d\theta = 1,$$

de donde se deduce que

$$\exp(cd) = (E\{\exp(-c\theta) | x\})^{-1},$$

y por tanto, el estimador bayesiano de θ es:

$$d = -\frac{1}{c} \log \{E[\exp(-c\theta) | x]\}.$$

◇

10.4.3. Tests de hipótesis

Los tests de hipótesis abordados en la sección 10.3.3 también pueden enmarcarse dentro del contexto más general de la teoría de la decisión disponiendo para ello de una función de pérdidas $\mathcal{L}(\theta, d)$, donde en este caso θ representa las hipótesis a contrastar y la decisión o acción d representará la aceptación o rechazo de una hipótesis.

Consideremos el primer caso de hipótesis nula simple frente alternativa simple. Como en situaciones anteriores, consideremos $L(x | \theta_0)$ y $L(x | \theta_1)$ las verosimilitudes bajo cada una de las hipótesis. Entonces suponiendo que no hay pérdidas para cualquiera de las dos decisiones correctas (aceptar H_i cuando es cierta, $i = 0, 1$), entonces las pérdidas de las decisiones incorrectas serán:

$$A = \mathcal{L}(H_0; \text{rechazar } H_0), \quad B = \mathcal{L}(H_1; \text{aceptar } H_0).$$

Si $\pi_0 = \Pr(H_0 \text{ cierta})$ y $\pi_1 = 1 - \pi_0 = \Pr(H_1 \text{ cierta})$ son las probabilidades a priori de cada hipótesis, entonces las probabilidades a posteriori de cada hipótesis se obtienen de:

$$p_i = \Pr(H_i|x) = \frac{\pi_i L(x|\theta_i)}{\pi_0 L(x|\theta_0) + \pi_1 L(x|\theta_1)}, \quad i = 0, 1.$$

La pérdida media a posteriori será:

$$\mathcal{L}(\text{rechazar } H_0|x) = A \cdot p_0 + 0 \cdot p_1 = \frac{A \cdot \pi_0 \cdot L(x|\theta_0)}{\pi_0 L(x|\theta_0) + \pi_1 L(x|\theta_1)},$$

$$\mathcal{L}(\text{aceptar } H_0|x) = 0 \cdot p_0 + B \cdot p_1 = \frac{B \cdot \pi_1 \cdot L(x|\theta_1)}{\pi_0 L(x|\theta_0) + \pi_1 L(x|\theta_1)},$$

de donde deducimos que el cociente de las pérdidas entre rechazar H_0 frente a aceptarla será:

$$\frac{A \cdot \pi_0 \cdot L(x|\theta_0)}{B \cdot \pi_1 \cdot L(x|\theta_1)}. \quad (10.17)$$

Por tanto, rechazar H_0 es la mejor acción bayesiana cuando el cociente (10.17) sea menor que 1 o equivalentemente:

$$\frac{L(x|\theta_0)}{L(x|\theta_1)} < K = \frac{B\pi_1}{A\pi_0}, \quad (10.18)$$

es decir, cuando el cociente de verosimilitudes sea menor que una cierta cantidad K . Observemos que la expresión (10.18) es análoga a la obtenida para el factor Bayes. En definitiva, hemos probado que para el contraste de hipótesis nula simple frente alternativa simple, el procedimiento bayesiano es análogo a un test de Neyman-Pearson (es el más potente) y recíprocamente, la región de rechazo de Neyman-Pearson $\{x : L(x|\theta_0)/L(x|\theta_1) < K\}$ es un test bayesiano para alguna elección a priori.

Si suponemos ahora que H_0 y H_1 son hipótesis compuestas para el parámetro θ y que las funciones de pérdidas son ahora funciones de θ , esto es:

$$\mathcal{L}(H_0; \text{rechazar } H_0) = a(\theta), \quad \mathcal{L}(H_1; \text{aceptar } H_0) = b(\theta),$$

con a y b funciones no negativas, entonces el procedimiento es análogo al anterior teniendo en cuenta que las pérdidas bayesianas a posteriori valen

$$\mathcal{L}(\text{rechazar } H_0|x) = \int_{\Theta_0} a(\theta) \pi(\theta|x) d\theta,$$

$$\mathcal{L}(\text{aceptar } H_1|x) = \int_{\Theta_1} a(\theta) \pi(\theta|x) d\theta,$$

que coinciden con (10.5) para el caso particular $a(\theta) = b(\theta) = 1$.

10.5. Problemas propuestos

- El responsable de una empresa desea conocer el porcentaje de empleados que está de acuerdo con la prohibición de fumar en el recinto de trabajo y para ello realiza un estudio de donde obtiene el siguiente intervalo de confianza al 95 %, (0,33; 0,45). Esto quiere decir:
 - Si tomamos muchas muestras iguales y calculamos sus respectivos intervalos, aproximadamente el 95 % de ellos contiene a la proporción de empleados que está de acuerdo con la medida.
 - Hay una probabilidad 0,95 de que la proporción de empleados que está de acuerdo con la medida esté comprendida entre el 33 % y el 45 %.

Cada una de estas interpretaciones es correcta bajo una perspectiva probabilista. Comentar cada una ellas y discutir sus posibles debilidades.

- Consideremos el caso de una rueda de reconocimiento o cualquier otra prueba para aportar evidencia sobre la culpabilidad o no de un acusado. Existen N individuos sospechosos de los que uno es el culpable del delito en cuestión. Antes de recibir cualquier evidencia, uno asigna igual probabilidad $1/N$ a cada uno de los sucesos $\{i\} = \{\text{el } i\text{-ésimo miembro es el culpable}\}$, $i = 1, \dots, N$. Llamemos Ω a la información obtenida mediante algún experimento. En pruebas de ADN, Ω puede representar la evidencia de que el demandado tenga una coincidencia plena en la cadena de ADN analizada. Sea ϕ_i la probabilidad de que ha ocurrido Ω , dado $\{i\}$. Se pide:
 - Dado Ω , calcular $\xi_i = \Pr(\{i\}|\Omega)$ y probar que $\xi_i = \frac{\phi_i}{N\bar{\phi}}$, siendo $\bar{\phi}$ la media aritmética de los ϕ_i .
 - Estudiar el comportamiento de las probabilidades a posteriori de cada sospechoso, y deducir cuándo éstas pueden ser mayores que $1/2$.
- Un problema de la comercialización mediante internet de productos de compañías aseguradoras es la elevada tasa de saturación de la red. Supongamos que los tiempos de espera para poder acceder a la página web de un determinado producto se distribuyen exponencialmente:

$$f(x|\theta) = \theta e^{-\theta x}, \quad x > 0$$

siendo $1/\theta$ el tiempo medio (en minutos) de espera. Supongamos que tenemos una muestra de 10 observaciones de esta distribución:

2.80,	5.00,	2.96,	8.69,	8.63
6.70	4.89,	2.17,	3.16,	6.24.

Estimar el tiempo medio de espera mediante el valor más frecuente a posteriori y dar un intervalo bayesiano a posteriori al 95 % suponiendo una densidad a priori del tipo $\pi(\theta) \propto 1$ si $\theta > 0$.

4. Para una muestra de tamaño n , obtener explícitamente la distribución a posteriori y marginal en los siguientes casos:

a) $X|\sigma \sim \mathcal{N}(0, \sigma^2)$, $\frac{1}{\sigma^2} \sim \mathcal{G}(1, 2)$.

b) $X|\lambda \sim \mathcal{P}(\lambda)$, $\lambda \sim \mathcal{G}(2, 1)$.

5. El método estándar de cribado para la detección de una enfermedad falla en un 15 % de los pacientes que actualmente tienen la enfermedad. Un nuevo método ha sido desarrollado y deseamos compararlo utilizando una muestra de tamaño $n = 75$. Sea ϕ la tasa de fallos del nuevo método. Si de los 75 pacientes, el nuevo método ha fallado en $y = 6$ casos, se pide:

a) Para una a priori $Be(1, 6)$ para ϕ , obtener la distribución a posteriori.

b) Obtener la estimación clásica de ϕ y comparar con la media a posteriori de la distribución obtenida anteriormente. Calcular la varianza a posteriori. Obtener también la probabilidad a posteriori de que el nuevo método sea mejor que el estándar.

6. Supongamos que las pérdidas sufridas por una compañía aseguradora respecto a un determinado aseguramiento pueden expresarse de manera adecuada mediante una población exponencial, esto es, $X|\lambda \sim \mathcal{E}(\lambda)$. Para una muestra de tamaño n de esta población construir el test de hipótesis bayesiano para contrastar $H_0 : \lambda = \lambda_0$ vs $H_1 : \lambda = \lambda_1$. Realizar el test anterior si se han observado los datos

7,259; 3,840; 43,041; 6,808; 3,092; 0,949; 29,488; 0,764; 6,942; 4,844.

7. Construir un test bayesiano para una muestra n de Bernoulli con parámetro ϕ para el contraste $H_0 : \phi = \phi_0$ vs $H_1 : \phi = \phi_1$ teniendo en cuenta que:

$$\mathcal{L}(H_0; \text{rechazar } H_0) = 3 \cdot \mathcal{L}(H_1; \text{aceptar } H_0).$$

Capítulo 11

Inferencia Bayesiana

En este capítulo estudiaremos las técnicas de inferencia Bayesiana y sus aplicaciones a diversos problemas prácticos.

11.1. Especificación de densidades a priori

El establecimiento de algunas hipótesis es el paso previo en el proceso de especificación de la distribución a priori. Diferentes expertos pueden interpretar la información a priori de diferente forma. Por ejemplo, un mismo investigador tendrá dificultades en distinguir si la desviación a priori es 0,8 ó 0,75. Incluso cuando el experto conozca con exactitud la información a priori, en ocasiones no podemos convertir esta información en una distribución a priori. Podemos explorar el rango de posibles especificaciones a priori que interpreten de forma razonable la evidencia a priori, permitiendo así cierta imprecisión. Si la decisión a posteriori es insensible a las diferentes distribuciones a priori podemos afirmar que el grado de imprecisión admitida no es preocupante. Esta práctica, también denominada análisis de sensibilidad con respecto a la distribución a priori, es muy común en la práctica de la metodología bayesiana.

La precisión necesaria en la especificación de la distribución a priori depende de la evidencia de los nuevos datos. Así, si poseemos una nueva base de datos de gran tamaño, el efecto de la distribución a priori sobre las conclusiones finales será relativamente pequeño por lo que podemos permitir un menor grado de precisión. Si los nuevos datos no tienen un peso tan relevante, la información a priori tendrá un efecto apreciable, por lo que el análisis de sensibilidad es esencial. Podemos distinguir diferentes tipos de distribuciones a priori:

- **Informativa:** representa el conocimiento a priori acerca de los parámetros de interés.

- *No informativa*: también denominada información de referencia o débil, representa la carencia de conocimiento a priori. El argumento a favor de representar carencia de información a priori es que de esta forma evitamos cualquier crítica sobre la posible subjetividad del proceso. Existen diversas técnicas para encontrar una expresión que represente la carencia de información a priori.
- *Esceptica*: incorpora información contraria a la que se está contrastando. Si a pesar de ello la hipótesis nula se continua aceptando, estaríamos reforzando la decisión.
- *Estructural*: incorpora información sobre la relación entre los parámetros.

El proceso mediante el cual asignamos los conocimientos a priori a distribuciones de probabilidad se denomina *elicitación o asignación*.

Habitualmente se dispone de técnicas para construir densidades a priori para cada uno de los tipos anteriores, aunque básicamente están más centradas en los dos primeros tipos todas ellas basadas en publicaciones de la literatura psicológica (Winkler, 1967, entre otros).

Para el caso informativo, debemos distinguir claramente el caso de espacio paramétrico discreto del continuo. El caso discreto, $\Theta = \{\theta_1, \dots, \theta_n\}$ se resuelve de manera inmediata puesto que el investigador debe asignar, en función de su conocimiento, las probabilidades a priori $\pi_i = \Pr(\theta = \theta_i)$, $i = 1, \dots, n$. Para el caso continuo, $\Theta \subset \mathbb{R}^k$ ($k \geq 1$) el problema de construir una densidad a priori $\pi(\theta)$ es más complicado.

Algunas aproximaciones consisten en discretizar el problema, como es el caso de la *aproximación del histograma*. Cuando Θ es un intervalo de la recta real, esta aproximación consiste en dividir el espacio paramétrico en intervalos, de tal manera que el investigador determina la probabilidad subjetiva de cada intervalo y entonces se construye el histograma de probabilidad. Con este histograma debemos entonces "aproximar" una densidad $\pi(\theta)$. Esta aproximación presenta algunos inconvenientes: ¿cuántos intervalos debemos considerar?, ¿de qué tamaño debe ser cada intervalo?, no conocemos el comportamiento en las colas de las densidades así construidas, etc.

Otra de las aproximaciones se conoce como *aproximación de la verosimilitud relativa*. En este caso se utilizan puntos notables del soporte de la densidad, de tal forma que una vez seleccionados dichos puntos (por ejemplo, los extremos de los anteriores intervalos) se trataría de comparar la verosimilitud o "plausibilidad" de cada punto respecto de otro punto de referencia del soporte (habitualmente el más probable o también, el menos probable), con comparaciones del tipo: "el punto θ_0 es tres veces más probable que θ_1 ". Una vez construidas todas las comparaciones entre los puntos notables, se construye una función que pase por dichos puntos de manera más o menos "suave". Dicha función se normaliza dividiendo por la integral que encierra la curva en el soporte y de esta forma se convierte en una

densidad. Este es uno de los principales inconvenientes de esta técnica y es que no puede utilizarse cuando el espacio paramétrico no sea acotado. Además nada se dice sobre el número de puntos notables necesarios, obviamente cuantos más puntos consideremos más "suave" será la aproximación, pero mayor el grado de complejidad en cuanto a la asignación de comparaciones.

El método más utilizado consiste en suponer que la densidad a priori $\pi(\theta)$ tiene una forma funcional dada (normal, beta, ...) y se trata de elegir aquella densidad que con esta forma funcional mejor represente los juicios del experto.

Por ejemplo, si se supone que el parámetro $\theta \in \mathbb{R}$ y suponemos que la densidad a priori de θ tiene forma funcional $\mathcal{N}(\mu, \sigma^2)$ entonces necesitaremos únicamente asignar los valores de la media y la varianza a priori que mejor representan los juicios del experto. De la misma manera, para $\theta \in (0, 1)$ con una forma funcional $\text{Be}(\alpha, \beta)$ uno puede asignar la media y varianza a priori μ y σ^2 y entonces obtener los valores a priori de α y β mediante las relaciones:

$$\mu = \frac{\alpha}{\alpha + \beta}, \quad \sigma^2 = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

Es decir, supuesta una forma funcional bastará con asignar un conjunto de momentos de la densidad a priori para tenerla totalmente determinada. Desafortunadamente, este método presenta la dificultad de que las colas de una densidad pueden tener un efecto drástico en sus momentos. Por ejemplo, si elegimos una forma funcional para $\theta \in (0, +\infty)$ del tipo $c\theta^{-2}$, esta densidad no tiene momentos. Una alternativa a este método que produce mejores resultados y además resulta más intuitivo de asignar a los expertos consiste en estimar subjetivamente varios cuantiles de la distribución a priori y entonces elegir los parámetros de una forma funcional dada que tenga esos cuantiles.

Ejemplo 11.1 (Berger, 1985) Supongamos $\Theta = \mathbb{R}$ y que adoptamos una forma funcional normal. Subjetivamente se determina que la mediana a priori está localizada en $q_2 = 0$ y que los cuantiles q_1 y q_3 están localizados en -1 y 1 , respectivamente. Se trata de encontrar la densidad con estas asignaciones a priori.

Solución: Al tratarse de una forma funcional normal tenemos que la densidad es simétrica y por tanto media y mediana coinciden. Como la mediana vale $q_2 = 0$, se tiene que la media μ está también localizada en 0 . Además la simetría se da también en los cuantiles q_1 y q_3 . Tomemos por ejemplo el primero y deducimos que $\Pr(Z = \frac{q_1 - \mu}{\sigma} \leq -\frac{1}{\sigma}) = 0,25$, siendo $Z \sim \mathcal{N}(0, 1)$. De las tablas de la normal estándar se deduce inmediatamente que $\sigma^2 = 2,19$. Luego la densidad a priori eliciteda es $\mathcal{N}(0; 2,19)$.

◇

En definitiva, la aproximación de la forma funcional dada es la más utilizada y podemos considerarla como la forma más práctica de modelizar los juicios del experto. Obviamente diferentes formas funcionales pueden ser consideradas, pero una vez decidida la forma funcional sólo necesitamos un número pequeño de

cuantiles para encontrar una elección particular de densidad a priori. A menudo suelen utilizarse conjuntamente tanto la técnica de los momentos como la de los cuantiles.

Ejemplo 11.2 Supongamos que $\theta \in (0, 1)$ representa la proporción de clientes de una cartera de seguros que presenta alguna reclamación a lo largo de un año, y suponemos una forma funcional $Be(\alpha, \beta)$ para la densidad a priori del parámetro. Además conocemos que la media a priori es del 10% y que no esperamos (con probabilidad 0,99) una tasa de reclamaciones mayor del 40% y esta información puede escribirse como $\Pr(\theta > 0,4) = 0,1$. Construir la densidad a priori para estas asignaciones.

Solución: Puesto que suponemos una forma funcional beta, bastará con encontrar los valores de los parámetros α y β que representan esa información a priori. Observemos que la información proporcionada consiste en un momento (la media a priori) y un cuantil (0,4 es el cuantil de nivel 0,99), luego utilizaremos conjuntamente las dos técnicas propuestas anteriormente. De la primera condición tenemos:

$$E(\theta) = \frac{\alpha}{\alpha + \beta} = \frac{1}{10} \iff \beta = 9\alpha.$$

A continuación debemos encontrar aquellos valores que cumpliendo la condición anterior también verifiquen $\Pr(\theta > 0,4) = 0,01$. FirstBayes permite ir probando paulatinamente con valores de α y β hasta encontrar unos valores adecuados. La figura 11.1 muestra una asignación encontrada para esta información a priori: la densidad a priori asignada será una $Be(1, 9)$.

Ejemplo 11.3 En el ejemplo 11.2 consideremos ahora que la información a priori viene dada por la misma media a priori anterior pero que además el experto considera que lo más frecuente a priori es que haya un 7% de reclamaciones, es decir, la moda vale 0,07.

Solución: En este caso el sistema de ecuaciones que debemos resolver viene determinado por las expresiones de la media y moda a priori:

$$E(\theta) = \frac{\alpha}{\alpha + \beta} = \frac{1}{10}, \quad \text{Moda}(\theta) = \frac{\alpha - 1}{\alpha + \beta - 2} = \frac{7}{100}.$$

Resolviendo el sistema obtenemos como solución $\alpha = 2,86$ y $\beta = 25,8$. La figura 11.2 muestra dicha densidad.

11.1.1. Familias conjugadas

En ocasiones la distribución a priori está determinada por el propio estudio. En ese caso es suficiente con conocer el valor a priori para el experto de unos pocos

11.1. Especificación de densidades a priori




Figura 11.1: Densidad a priori elicitada para el ejemplo 11.2




Figura 11.2: Densidad a priori elicitada para el ejemplo 11.3

parámetros. Aunque la elección de la distribución a priori de esta forma es arbitraria y discutible, lo cierto es que cualquier otra distribución a priori que recoja de forma fiel los conocimientos del experto es probable que sea muy similar a la fijada de antemano, por lo que daría lugar a estimaciones parecidas.

Resulta por tanto útil realizar la elección de la distribución a priori siguiendo

los criterios de simplicidad y conveniencia. Matemáticamente, en algunos problemas estadísticos sencillos existe una clase de distribuciones a priori conocidas como *distribuciones conjugadas* que son particularmente recomendables. En primer lugar, porque si la distribución a priori es de la familia conjugada, la distribución a posteriori será también de la misma familia. En segundo lugar, las distribuciones conjugadas son lo suficientemente sencillas como para permitir realizar gran cantidad de inferencia sin necesidad de métodos computacionales complejos. Su asignación se correspondería con la aproximación de una forma funcional dada pero especialmente bien comportada en el cálculo de la distribución a posteriori.

Si para un determinado problema existe una familia a priori conjugada que ajuste de forma correcta la distribución a priori, entonces debemos utilizar el análisis conjugado.

De hecho, en los comienzos de la estadística bayesiana moderna, años 60 y 70, el método bayesiano estaba restringido esencialmente al uso de los modelos conjugados. El desarrollo de técnicas de simulación más avanzadas ha permitido abordar problemas de mayor complejidad.

Definición 11.1 (Familia conjugada) Supongamos que el modelo que genera los datos x viene determinado por la distribución $f(x|\theta)$. Una familia de densidades a priori $\mathcal{F}$ para el parámetro θ , se dice conjugada para el muestreo dado por $f(x|\theta)$ si para cualquier densidad a priori $\pi(\theta) \in \mathcal{F}$ se verifica que la densidad a posteriori $\pi(\theta|x) \propto L(x|\theta)\pi(\theta)$ es también una densidad de la familia $\mathcal{F}$.

Observemos que esta definición de familia conjugada puede ser algo ambigua puesto que si una familia $\mathcal{F}$ es conjugada, entonces dada cualquier $\pi(\theta) \in \mathcal{F}$ se tiene que para otra densidad $g(\theta)$ definida por $g(\theta) = p(\theta)\pi(\theta)$ siendo $q(\theta)$ cualquier función que haga a g densidad, se tiene que la familia $\mathcal{G}$ de densidades proporcionales a las de $\mathcal{F}$ también es conjugada, y entonces podríamos no saber bien a qué nos referimos cuando hablemos de que una familia $\mathcal{F}$ determinada es conjugada. De hecho en muchas ocasiones esta situación más general se le conoce como *familias cerradas bajo muestreo* dado por $f(x|\theta)$ (O'Hagan y Forster, 2004). En la práctica consideraremos familias conjugadas aquellas que aparecen de forma natural en cada una de los procesos de muestreo más habituales.

Ejemplo 11.4 (Muestreo binomial) Probar que la clase de densidades a priori $Be(\alpha, \beta)$ es conjugada para el muestreo binomial.

Solución: En efecto, supongamos que x tiene una distribución binomial de parámetros m y θ , de donde la verosimilitud tiene la expresión $L(x|\theta) \propto \theta^{n\bar{x}}(1-\theta)^{nm-n\bar{x}}$. Si la familia de densidades a priori es beta, entonces una a priori de esta familia tendrá la expresión $\pi(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$. Y por tanto, dada cualquier a priori de esta familia su a posteriori será

$$\pi(\theta|x) \propto \theta^{\alpha+n\bar{x}-1}(1-\theta)^{nm-n\bar{x}+\beta-1} \sim Be(\alpha+n\bar{x}, nm-n\bar{x}+\beta).$$

Ejemplo 11.5 (Muestreo binomial negativa) Probar que la clase de densidades a priori $Be(\alpha, \beta)$ es conjugada para el muestreo mediante una binomial negativa.

Solución: En efecto, supongamos que x tiene una distribución binomial negativa de parámetros r y θ , de donde la verosimilitud tiene la expresión $L(x|\theta) \propto \theta^{nr}(1-\theta)^{n\bar{x}}$. Si la familia de densidades a priori es beta, entonces una a priori de esta familia tendrá la expresión $\pi(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$. Por tanto, dada cualquier a priori de esta familia su a posteriori será

$$\pi(\theta|x) \propto \theta^{\alpha+nr-1}(1-\theta)^{n\bar{x}+\beta-1} \sim Be(\alpha+nr, n\bar{x}+\beta).$$

Ejemplo 11.6 (Muestreo Poisson) Probar que la clase de densidades a priori $G(\alpha, 1/\beta)$ es conjugada para el muestreo de Poisson.

Solución: En efecto, supongamos que los datos x de una muestra de tamaño n tiene una distribución de Poisson de parámetros λ , de donde la verosimilitud tiene la expresión $L(x|\lambda) \propto \lambda^{n\bar{x}} \exp(-n\lambda)$, siendo $\bar{x}$ el estadístico suficiente media muestral $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$. Si la familia de densidades a priori es gamma, entonces una a priori de esta familia tendrá la expresión $\pi(\lambda) \propto \lambda^{\alpha-1} \exp(-\beta\lambda)$. Y por tanto, dada cualquier a priori de esta familia su a posteriori será

$$\pi(\lambda|\bar{x}) \propto \lambda^{n\bar{x}+\alpha-1} \exp(-(n+\beta)\lambda) \sim G(n\bar{x}+\alpha, 1/(n+\beta)).$$

Ejemplo 11.7 (Muestreo Poisson) Probar que la clase de densidades a priori inversa Gaussiana, $IG(\mu, \phi)$, es conjugada para el muestreo de Poisson.

Solución: Si la familia de densidades a priori es inversa Gaussiana con parámetros $\mu > 0$ y $\phi > 0$, entonces una a priori de esta familia tendrá la expresión

$$\pi(\lambda) \propto \lambda^{-3/2} \exp \left\{ -\frac{\lambda}{2\phi} - \frac{\mu^2}{2\phi\lambda} \right\}.$$

Por tanto, dada cualquier a priori de esta familia su a posteriori será

$$\pi(\lambda|x) \propto \lambda^{n\bar{x}-\frac{3}{2}-1} \exp \left[-\frac{\lambda}{2\frac{\phi}{2n\phi+1}} - \frac{\left(\mu\sqrt{\frac{1}{2n\phi+1}} \right)^2}{2\lambda\frac{\phi}{2n\phi+1}} \right],$$

que corresponde a una $IG\left(n\bar{x} - \frac{1}{2}, \mu\sqrt{\frac{1}{2n\phi+1}}, \frac{\phi}{2n\phi+1}\right)$.

Ejemplo 11.8 (Muestreo de datos $\mathcal{G}(\alpha, 1/\beta)$, con α conocida) Probar que la clase de densidades a priori para β del tipo $\mathcal{G}(a, 1/b)$ es conjugada para el muestreo $X \sim \mathcal{G}(\alpha, 1/\beta)$ con $\alpha > 0$ conocida.

Solución: En efecto, si tenemos una muestra de tamaño n de una población $X|\beta \sim \mathcal{G}(\alpha, 1/\beta)$ con $\alpha > 0$ conocida, entonces la verosimilitud será

$$L(x|\beta) \propto \beta^{n\alpha} \exp(-\beta n\bar{x}).$$

Si elegimos una densidad gamma para β tendremos como a posteriori

$$\pi(\beta|x) \propto \beta^{n\alpha} \exp(-\beta n\bar{x}) \beta^{a-1} \exp(-b\beta) \propto \beta^{n\alpha+a-1} \exp(-(n\bar{x}+b)\beta),$$

que corresponde a una densidad $\mathcal{G}(n\alpha + a, 1/(n\bar{x} + b))$.

◇

Ejemplo 11.9 (Muestreo de datos exponenciales) Probar que para el caso de muestreo $X|\lambda \sim \mathcal{E}(\lambda)$, la familia de distribuciones a priori, para λ , $\mathcal{G}(\alpha, 1/\beta)$ es conjugada.

Solución: Tenemos como verosimilitud

$$L(x|\lambda) \propto \lambda^n \exp(-\lambda n\bar{x}),$$

que combinada con una distribución a priori $\mathcal{G}(\alpha, 1/\beta)$ con función de densidad: $\pi(\lambda) \propto \lambda^{\alpha-1} \exp(-\lambda\beta)$, da lugar a la distribución a posteriori

$$\pi(\lambda|x) \propto \lambda^{n+\alpha-1} \exp(-(\beta + n\bar{x})\lambda) \sim \mathcal{G}(n + \alpha, 1/(\beta + n\bar{x})).$$

◇

Ejemplo 11.10 (Muestreo de datos uniformes) Probar que la familia de distribuciones de Pareto I, para un parámetro θ , es conjugada para un muestreo de datos de una distribución uniforme $\mathcal{U}(0, \theta)$.

Solución: Supongamos una muestra de tamaño n donde cada $x_i \sim \mathcal{U}(0, \theta)$, entonces $f(x_i|\theta) = \theta^{-1} I_{(0, \theta)}(x_i)$, siendo $I_A(s)$ la función indicadora sobre un conjunto A que vale 1 si $s \in A$ y 0, en caso contrario. De esta forma, la función de verosimilitud vale

$$L(x|\theta) \propto \theta^{-n} I_{(x_{n:n}, \infty)}(\theta),$$

siendo $x_{n:n}$ el estadístico suficiente definido por $x_{n:n} = \max(x_1, \dots, x_n)$. Consideremos ahora una densidad a priori Pareto I con parámetros a y b , es decir:

$$\pi(\theta) \propto \theta^{-a-1} I_{(b, \infty)}(\theta).$$

Tabla 11.1: Distribuciones a priori conjugadas

Verosimilitud Distribución a priori	Distribución a posteriori
$X \sim \mathcal{P}(\theta)$ $\theta \sim \mathcal{G}(a, 1/b)$	$\mathcal{G}(a + n\bar{x}, 1/(b + n))$
$X \sim \mathcal{P}(\theta)$ $\theta \sim \mathcal{IG}(\mu, \beta)$	$\mathcal{GITG}\left(n\bar{x} - \frac{1}{2}, \mu\sqrt{\frac{1}{2\beta n+1}}, \frac{\beta}{2\beta n+1}\right)$
$X \sim \mathcal{BN}(r, \theta)$ $\theta \sim \mathcal{Be}(a, b)$	$\mathcal{B}(a + nr, b + n\bar{x})$
$X \sim \mathcal{B}(m, \theta)$ $\theta \sim \mathcal{Be}(a, b)$	$\mathcal{Be}(a + n\bar{x}, b + mn - n\bar{x})$
$X \sim \mathcal{G}(\alpha, 1/\theta)$ $\theta \sim \mathcal{G}(a, 1/b)$	$\mathcal{G}(n\alpha + a, 1/(n\bar{x} + b))$
$X \sim \mathcal{N}(\theta, \sigma^2)$ $\theta \sim \mathcal{N}(a, \tau^2)$	$\mathcal{N}\left(\frac{a\sigma^2 + n\bar{x}\tau^2}{\sigma^2 + n\tau^2}, \frac{\sigma^2\tau^2}{\sigma^2 + n\tau^2}\right)$

La densidad a posteriori es

$$\begin{aligned} \pi(\theta|x) &\propto \theta^{-n} I_{(x_{n:n}, \infty)}(\theta) \theta^{-a-1} I_{(b, \infty)}(\theta) \\ &\propto \theta^{-(a+n)-1} I_{(b_M, \infty)}(\theta) \sim \mathcal{PaI}(a + n, b_M), \end{aligned}$$

siendo $b_M = \max\{x_{n:n}, b\}$.

◇

La tabla 11.1 recoge, a modo de resumen, algunas distribuciones a priori conjugadas respecto a una verosimilitud dada. Una análisis bayesiano de la distribución log-normal usando distribuciones conjugadas basadas en especificación condicional aparece en Sarabia et al. (2005). Dos comentarios finales. Por un lado, observemos que todas las densidades a posteriori obtenidas en los ejemplos anteriores pueden ser expresadas en función del estadístico suficiente (si existe) en el muestreo. En efecto, esta es una propiedad general de la densidad a posteriori sea o no conjugada, ya que si t es un estadístico suficiente para una población $f(x|\theta)$, por el teorema de factorización (teorema 8.4) ocurre que la función de verosimilitud cumple que

$$L(x|\theta) \propto L(t|\theta),$$

y por tanto la densidad a posteriori de θ dado x es la misma que dado t ya que

$$\pi(\theta|x) \propto L(x|\theta)\pi(\theta) \propto L(t|\theta)\pi(\theta) \propto \pi(\theta|t).$$

Por otro lado, las familias conjugadas se comportan adecuadamente incluso cuando

Tabla 11.2: Estadísticos descriptivos a priori y a posteriori para el ejemplo 11.11

	Priori $G(2, 1)$	Posteriori $G(80, 1/46)$	Priori Jeffrey	Posteriori $G(78,5, 1/45)$
Media	2	1,7391	—	1,7444
Moda	1	1,7174	—	1,7222
Desv. Típica	1,4142	0,1944	—	0,1968




Figura 11.4: Posteriori para el ejemplo 11.11

$G(\alpha, 1/\beta)$, con $\alpha = 1/2$ y $\beta \rightarrow 0$.

Solución: En este caso no tiene mucho sentido que hablemos de la media, moda y desviación típica a priori ya que hemos supuesto una situación no informativa y por tanto no lo hemos incluido en la tabla de resultados. El análisis a posteriori (ver tabla 11.2) muestra que la situación es análoga al apartado anterior y por tanto podemos decir que la modelización a priori anterior no aporta información al problema y que son los datos los que producen la información a posteriori.

◇

En resumen, en el caso de datos de Poisson, si $\underline{x}|\lambda \sim \mathcal{P}(\lambda)$ y $\lambda \sim G(\alpha, 1/\beta)$ la




Figura 11.5: Triplot para el ejemplo 11.11

distribución a posteriori es (tabla 11.1):

$$\lambda|\underline{x} \sim G(\alpha + n\bar{x}, 1/(\beta + n)).$$

Para la estimación puntual bayesiana las cantidades descriptivas a posteriori más habituales son:

$$E(\lambda|\underline{x}) = \frac{\alpha + n\bar{x}}{\beta + n}, \quad \text{Var}(\lambda|\underline{x}) = \frac{\alpha + n\bar{x}}{(\beta + n)^2} \quad \text{y} \quad \text{Moda}(\lambda|\underline{x}) = \frac{\alpha + n\bar{x} - 1}{\beta + n},$$

y la distribución predictiva de tipo binomial negativa. En efecto, para una nueva observación y podemos usar la expresión $p(y) = f(y|\lambda)\pi(\lambda)/\pi(\lambda|\underline{x})$. Sustituyendo cada elemento por sus expresiones para el caso Poisson-gamma, tenemos

$$p(y) = \left\{ \frac{1}{y!} \exp(-\lambda) \lambda^y \frac{\beta^\alpha}{\Gamma(\alpha)} \exp(-\beta\lambda) \lambda^{\alpha-1} \right\} \left\{ \frac{(\beta+1)^{\alpha+y}}{\Gamma(\alpha+y)} \exp(-(\beta+1)\lambda) \lambda^{\alpha+y} \right\}^{-1},$$

de donde se deduce que:

$$p(y) = \frac{\Gamma(\alpha+y)}{\Gamma(\alpha)\Gamma(y+1)} \left(\frac{\beta}{\beta+1} \right)^\alpha \left(\frac{1}{\beta+1} \right)^y, \quad (11.1)$$

que es la expresión de una binomial negativa del tipo (6.19). La distribución predictiva a posteriori es análoga sin más que reemplazar α por $\alpha + n\bar{x}$ y β por $\beta + n$. Veamos cómo obtener los intervalos bayesianos de credibilidad.

Ejemplo 11.13 (Continuación ejemplo 11.11) Supongamos que estamos interesados en obtener un intervalo de credibilidad al 95 % para el número medio de llegadas a la caja del supermercado.

Solución: Su resolución con FirstBayes es inmediata. Basta con ir a la pestaña correspondiente al HDI y señalar un nivel de probabilidad del 95 % (figura 11.6). Los resultados obtenidos ($\Pr(1,36 \leq \lambda \leq 2,12) = 0,95$) permiten afirmar que con una probabilidad de 0,95 el número medio de llegadas a la caja de dicho supermercado se sitúa entre 1,36 y 2,12.




Figura 11.6: Intervalo de credibilidad al 95 % para λ en el ejemplo 11.11

Ejemplo 11.14 (Distribución predictiva en el ejemplo 11.11) Deseamos conocer el comportamiento de las futuras 10 llegadas para saber si necesitamos abrir una nueva caja.

Solución: Para el caso de las próximas 10 medidas que se hagan, necesitaremos obtener la predictiva para las nuevas 10 observaciones y se obtienen los resultados que aparecen en la figura 11.7. Podemos afirmar que por término medio en las próximas 10 medidas esperamos atender a 17 clientes, y que con una probabilidad del 95 % en los próximos 20 minutos (10 próximas medidas) atenderemos entre 9 y 26 clientes.




Figura 11.7: Medidas predictivas para el número de llegadas en el ejemplo 11.7

Ejemplo 11.15 Una compañía aseguradora supone que el número de reclamaciones en un año sigue una distribución de Poisson de parámetro λ y que este número es independiente de un año a otro. Se observan las reclamaciones de un asegurado durante n años. Se pide:

1. Encontrar una densidad gamma a priori para λ conociendo que la compañía estima como más frecuente 2 reclamaciones al año y que no más de 5 reclamaciones son asumibles en un año.
2. Supongamos que en los últimos 10 años el asegurado presenta el siguiente número de reclamaciones: 4, 0, 1, 2, 3, 0, 0, 1, 1, 0 (introducir estos datos en el FirstBayes como un fichero). Obtener la densidad a posteriori y un intervalo de credibilidad a posteriori al 99 %.
3. Suponiendo que la compañía tiene 500 asegurados en esta cartera y que destina 10 u.m. para cada reclamación, obtener un intervalo al 95 % de previsión de costes para el siguiente año.

Solución: Los cálculos se han obtenido con FirstBayes de manera análoga a los realizados en los ejemplos anteriores. Los datos a priori nos dicen que la moda es 2 reclamaciones y que pensamos que $\Pr(\lambda < 5)$ es un valor alto (próximo a 1). Sabemos que la moda de una densidad gamma $\mathcal{G}(\alpha, 1/\beta)$ es $\frac{\alpha-1}{\beta}$ de donde deducimos

con $\pi_1(\lambda) \sim \mathcal{G}(\alpha, 1/\beta)$,

$$L(\mathbf{x}|\lambda) = \frac{1}{\prod_{i=1}^n (x_i!)} \exp(-n\lambda) \lambda^{n\bar{x}},$$

$$p_1(\mathbf{x}) = \int_0^\infty L(\mathbf{x}|\lambda) \pi_1(\lambda) d\lambda = \frac{1}{\prod_{i=1}^n (x_i!)} \frac{\beta^\alpha}{\Gamma(\alpha)} \frac{\Gamma(n\bar{x} + \alpha)}{(n + \beta)^{\alpha + n\bar{x}}}.$$

El factor Bayes es:

$$B_{01} = \frac{L(\mathbf{x}|\lambda_0)}{p_1(\mathbf{x})} = \frac{\Gamma(\alpha)}{\Gamma(\alpha + n\bar{x})} \exp(-n\lambda_0) \left(\frac{n + \beta}{\beta}\right)^\alpha (\lambda_0(n + \beta))^{n\bar{x}}. \quad (11.4)$$

Ejemplo 11.18 (Continuación ejemplo 11.15) Para el caso del ejemplo 11.15 realizar el contraste:

$$H_0 : \lambda = 2 \text{ vs } H_1 : \lambda \neq 2,$$

con una densidad a priori para la hipótesis alternativa del tipo $\mathcal{G}(2, 1)$.

Solución: Utilizando la expresión del factor Bayes dada en (11.4) obtenemos

$$B_{01} = \frac{\Gamma(2)}{\Gamma(15)} \exp(-20) 11^2 22^{13} = 0,81,$$

o bien $B_{10} = 1,2$, lo cual indica que los datos proporcionan una ligera evidencia en favor de H_1 .

◇

11.1.2. Densidades a priori no informativas

En algunos de los ejemplos desarrollados hemos hecho referencia al uso de densidades no informativas, entendiendo por tales aquellas que consideraban igualmente probable cualquier valor a priori del parámetro.

En el caso continuo de datos binarios, es posible considerar como no informativa la densidad a priori uniforme $\mathcal{U}(0, 1) = \mathcal{Be}(1, 1)$, de modo que esta densidad asigna la misma probabilidad a cualquier valor del parámetro y que por tanto podríamos entender que el experto no tiene información a priori sobre dicho parámetro.

Para el caso de la media de una población normal es posible usar como no informativa la densidad $\pi(\mu) \propto 1$, interpretando dicha densidad como en el caso de una proporción, con la salvedad de que el espacio paramétrico en esta situación es $\mathbb{R}$ y por tanto no acotado y en consecuencia dicha densidad no integra la unidad. Este tipo de densidades reciben el nombre de *impropias*.

En muchas ocasiones las densidades no informativas (sean o no impropias) permiten trabajar como si de una densidad conjugada se tratase sin más que sustituir los parámetros a priori por aquellos que le corresponden a tales densidades

11.1. Especificación de densidades a priori

no informativas. Las densidades no informativas como las anteriores, presentan el problema de que transformaciones del parámetro pueden dar lugar a densidades a priori que sí son informativas. Por ejemplo, si $\theta \sim \mathcal{U}(0, 1)$, entonces $\psi = \log \theta$ tiene una densidad $\pi(\psi) \propto \exp(\psi)$ que no es uniforme. Una solución a este problema lo constituyen las densidades no informativas de tipo Jeffreys.

Definición 11.3 (Densidad a priori no informativa de Jeffreys) Supongamos n observaciones independientes $\mathbf{x} = (x_1, \dots, x_n)$ de una población $f(x|\theta)$, entonces la densidad a priori no informativa de Jeffreys se define como:

$$\pi(\theta) \propto \sqrt{I(\theta|\mathbf{x})},$$

siendo $I(\theta|\mathbf{x})$ la información esperada de Fisher del problema obtenida como

$$I(\theta|\mathbf{x}) = -E \left(\frac{\partial^2 \ell}{\partial \theta^2} \right) = E \left(\frac{\partial \ell}{\partial \theta} \right)^2,$$

con $\ell(\theta|\mathbf{x}) = \log L(\mathbf{x}|\theta)$.

Observemos que para esta densidad así definida se obtiene la propiedad de invarianza deseada. En efecto, supongamos una transformación $\psi = \psi(\theta)$, entonces:

$$\frac{\partial \log L(\psi|\mathbf{x})}{\partial \psi} = \frac{\partial \log L(\theta|\mathbf{x})}{\partial \theta} \cdot \frac{\partial \theta}{\partial \psi}.$$

De tal forma que la información esperada de Fisher para ψ puede escribirse como:

$$I(\psi|\mathbf{x}) = I(\theta|\mathbf{x}) \cdot \left(\frac{\partial \theta}{\partial \psi} \right)^2.$$

De donde se deduce que si tomamos una densidad de Jeffreys para θ resulta que la densidad a priori para una transformación ψ es:

$$\pi(\psi) = \pi(\psi^{-1}(\theta)) \cdot \frac{\partial \theta}{\partial \psi} \propto \sqrt{I(\psi|\mathbf{x})} \cdot \left(\frac{\partial \psi}{\partial \theta} \right)^2 \cdot \frac{\partial \theta}{\partial \psi} \propto \sqrt{I(\psi|\mathbf{x})}.$$

Ejemplo 11.19 (Densidad de Jeffreys para datos binarios) Encontrar la densidad no informativa de Jeffreys para el caso del parámetro de una binomial con tamaño muestral n conocido.

Solución: Dado $\mathbf{x} = (x_1, \dots, x_n)$ con $x_i = 0, 1$ ($i = 1, \dots, n$), tenemos que $\ell(\theta|\mathbf{x}) \propto n\bar{x} \log \theta + (n - n\bar{x}) \log(1 - \theta)$. Por tanto:

$$\frac{\partial \ell}{\partial \theta} = \frac{n\bar{x}}{\theta} - \frac{n - n\bar{x}}{1 - \theta}; \quad \frac{\partial^2 \ell}{\partial \theta^2} = -\frac{n\bar{x}}{\theta^2} - \frac{n - n\bar{x}}{(1 - \theta)^2}.$$

Ahora, puesto que $E(\bar{X}) = \theta$, se obtiene:

$$I(\theta|x) = -E\left(\frac{\partial^2 \ell}{\partial \theta^2}\right) = \frac{n}{\theta(1-\theta)}.$$

En definitiva la densidad a priori de Jeffreys para este caso vale

$$\pi(\theta) \propto \sqrt{I(\theta|x)} \propto \theta^{-1/2}(1-\theta)^{-1/2} \sim \text{Be}(1/2, 1/2).$$

◇

Ejemplo 11.20 (Densidad de Jeffreys para datos de Poisson) Encontrar la densidad no informativa de Jeffreys para el caso del parámetro λ de una población de Poisson.

Solución: Dado $x = (x_1, \dots, x_n)$ con cada $x_i \sim \mathcal{P}(\lambda)$, tendremos que

$$\ell(\lambda|x) \propto -n\lambda + n\bar{x} \log \lambda.$$

Entonces,

$$\frac{\partial \ell}{\partial \lambda} = -n + \frac{n\bar{x}}{\lambda}; \quad \frac{\partial^2 \ell}{\partial \lambda^2} = -\frac{n\bar{x}}{\lambda^2}.$$

Como $E(\bar{X}) = \lambda$, entonces $I(\lambda|x) = \frac{n}{\lambda}$, y por tanto

$$\pi(\lambda) \propto \sqrt{I(\lambda|x)} \propto \lambda^{-1/2}.$$

Observemos que esta densidad a priori de Jeffreys podemos verla como un caso límite de $\mathcal{G}(1/2, 1/\beta)$ con $\beta \rightarrow 0$.

◇

Ejemplo 11.21 (Densidad de Jeffreys para la media de datos normales) Obtener la densidad no informativa de Jeffreys para la media de datos normales con varianza conocida.

Solución: Para $x = (x_1, \dots, x_n)$ con $x_i \sim \mathcal{N}(\mu, \sigma^2)$ y σ^2 conocida, tenemos que

$$\ell(\mu|x) \propto -\frac{1}{2} \frac{n\mu^2 - 2n\bar{x}\mu}{\sigma^2}.$$

Derivando respecto a μ obtenemos

$$\frac{\partial \ell}{\partial \mu} = -\frac{1}{2} \left(\frac{2n}{\sigma^2} \mu - \frac{2n\bar{x}}{\sigma^2} \right), \quad \frac{\partial^2 \ell}{\partial \mu^2} = -\frac{n}{\sigma^2},$$

luego $I(\mu|x) = \frac{n}{\sigma^2} \propto \text{cte.} \propto 1$, ya que n y σ^2 son cantidades conocidas. Por tanto: $\pi(\mu) \propto 1$.

◇

Definición 11.4 (Densidad de Jeffreys para el caso k paramétrico) Para el caso $\theta = (\theta_1, \dots, \theta_k)$ la definición de la densidad a priori de Jeffreys es análoga al caso uniparamétrico atendiendo a la expresión:

$$\pi(\theta) \propto \sqrt{|I(\theta|x)|},$$

siendo $|I(\theta|x)|$ el determinante de la matriz de información de Fisher $I(\theta|x)_{n \times n} = (I_{ij})_{n \times n}$ definida por:

$$I_{ij} = -E\left(\frac{\partial^2 \ell}{\partial \theta_i \partial \theta_j}\right); \quad i, j = 1, \dots, n.$$

Ejemplo 11.22 (Densidad de Jeffreys para datos normales) Encontrar la densidad a priori no informativa de Jeffreys para el caso de datos normales con media y varianza desconocidas.

Solución: Dados $x_1, \dots, x_n \sim \mathcal{N}(\mu, \sigma^2)$, tendremos

$$\ell(\mu, \sigma^2|x) \propto -\frac{n}{2} \log \sigma^2 - \frac{2(\bar{x} - \mu)^2}{\sigma^2}.$$

Derivando parcialmente respecto de cada parámetro se obtiene:

$$\begin{aligned} \frac{\partial \ell}{\partial \mu} &= n \left(\frac{\bar{x} - \mu}{\sigma^2} \right), & \frac{\partial^2 \ell}{\partial \mu^2} &= -\frac{n}{\sigma^2}, & \frac{\partial^2 \ell}{\partial \mu \partial \sigma^2} &= -n \left(\frac{\bar{x} - \mu}{(\sigma^2)^2} \right), \\ \frac{\partial \ell}{\partial \sigma^2} &= -\frac{n}{2} \left(\frac{1}{\sigma^2} - \frac{(\bar{x} - \mu)^2}{(\sigma^2)^2} \right), & \frac{\partial^2 \ell}{\partial (\sigma^2)^2} &= \frac{n}{2} \left(\frac{1}{(\sigma^2)^2} - \frac{(\bar{x} - \mu)^2}{(\sigma^2)^3} \right). \end{aligned}$$

Teniendo en cuenta que $E(\bar{X}) = \mu$, $E(\bar{X} - \mu)^2 = \sigma^2/n$ tenemos que la matriz de información de Fisher vale

$$I(\mu, \sigma^2|x) = \begin{bmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n(n-1)}{2} \frac{1}{(\sigma^2)^3} \end{bmatrix},$$

y su determinante vale $|I(\mu, \sigma^2|x)| = \frac{n(n-1)}{2} (\sigma^2)^{-3}$ de donde deducimos la densidad de Jeffreys: $\pi(\mu, \sigma^2) \propto \sigma^{-3}$.

◇

11.1.3. Críticas a la elicitación a priori

La información a priori es tanto una fortaleza como una debilidad del análisis bayesiano. Por un lado, la incorporación de información a priori facilita el uso de mayor información en el análisis, y por tanto, la obtención de inferencia más robusta. Por otro lado, las mayores críticas que ha recibido el análisis bayesiano se centran en el uso de información a priori.

La crítica más habitual es que la información a priori puede resultar subjetiva, pues dos expertos pueden asignar distintas densidades a priori para un mismo problema. Esto hace que la distribución a posteriori, y la inferencia desarrollada a partir de ella, sea subjetiva. Sin embargo, esta limitación del análisis bayesiano no la invalida, ni desde el punto de vista teórico ni práctico. Desde un punto de vista teórico, la subjetividad no invalida el análisis por el simple hecho de que ningún estudio científico es totalmente objetivo.

Para tal situación, el análisis bayesiano presenta soluciones alternativas. Una de ellas, denominada análisis de robustez global, consiste básicamente en sustituir la densidad a priori eliciteda por toda una clase de densidades a priori que sean compatibles con la información a priori. Todo el proceso de decisión es esencialmente el mismo y por tanto debe estar basado en las medidas a posteriori de interés. La diferencia esencial recae en que ahora en vez de un único valor de interés a posteriori tendremos todo un intervalo de valores, los correspondientes a cada una de las densidades a posteriori deducidas de cada elemento de la clase considerada. Cuando la longitud de dicho intervalo sea pequeña el investigador no debe preocuparse por una densidad a priori en particular puesto que sus decisiones finales no se verán afectadas por la elección de una u otra densidad de la clase. En caso de que la longitud sea grande, el proceso de asignación debe afinarse. Sobre la elección de clases de densidades a priori y cálculo de las medidas de interés en el análisis bayesiano robusto existe hoy día una extensa literatura estadística (Berger, 1984, 1985, 1990, 1994; Sivaganesan, 1991; Sivaganesan y Berger, 1989; Bètro y Gugliemi, 2000; Goutis, 1994; Betrò et al., 1994; Ríos y Ruggeri, 2000, entre muchos otros). En el campo actuarial, el estudio de clases de densidades a priori para la elicitación de los parámetros de interés puede verse con detalle en Gómez-Déniz et al. (2000, 2002ab, 2005 y 2006).

11.2. Análisis bayesiano para datos normales

Otra de las situaciones más frecuentes en la práctica actuarial es aquella en la que los datos procedentes de una población normal.

11.2.1. Caso de media desconocida y varianza conocida

Consideremos una primera situación en la que la varianza σ^2 es conocida y que por tanto, el único parámetro desconocido será la media μ , sobre la que deseamos hacer inferencia. La función de verosimilitud viene dada por:

$$L(x|\mu) \propto \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2} \right\}, \quad (11.5)$$

donde hemos prescindido en términos de proporcionalidad de la parte conocida. El único parámetro a estimar en este modelo será la media de la distribución normal.

11.2. Análisis bayesiano para datos normales

Consideremos para este caso, una densidad a priori para μ del tipo $\mathcal{N}(\mu_0, \sigma_0^2)$:

$$\mu \sim \mathcal{N}(\mu_0, \sigma_0^2) \quad (11.6)$$

con μ_0 y σ_0^2 constantes conocidas.

Teorema 11.1 Para el caso de verosimilitud una normal con varianza σ^2 conocida y con función de densidad a priori $\pi(\mu)$ de tipo $\mathcal{N}(\mu_0, \sigma_0^2)$, se verifica que la densidad a posteriori es de nuevo normal con parámetros a posteriori dados por las fórmulas:

$$E(\mu|x) = \mu_0 \cdot \frac{(\sigma_0^2)^{-1}}{(\sigma_0^2)^{-1} + (\sigma^2/n)^{-1}} + \bar{x} \cdot \frac{(\sigma_1^2)^{-1}}{(\sigma_0^2)^{-1} + (\sigma^2/n)^{-1}}, \quad (11.7)$$

$$\text{Var}(\mu|x) = \frac{1}{(\sigma_0^2)^{-1} + n(\sigma^2)^{-1}}. \quad (11.8)$$

Además la distribución predictiva de una observación futura es de nuevo de tipo normal.

Demostración: En efecto multiplicando la función de verosimilitud (11.5) por la función de densidad de (11.6) obtenemos:

$$\begin{aligned} \pi(\mu|x) &\propto \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2} \right\} \cdot \exp \left\{ -\frac{1}{2} \frac{(\mu - \mu_0)^2}{\sigma_0^2} \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left(\frac{\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2}{\sigma^2} + \frac{\mu^2 - 2\mu\mu_0 + \mu_0^2}{\sigma_0^2} \right) \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \left[\mu^2 \left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) + \mu \left(\frac{n\bar{x}}{\sigma} + \frac{\mu_0}{\sigma_0} \right) \right] \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \frac{(\mu - \mu_1)^2}{\sigma_1^2} \right\}, \end{aligned}$$

donde μ_1 y σ_1^2 vienen definidos por (11.7) y (11.8), respectivamente. Observemos que $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ y por tanto para obtener la distribución predictiva de una nueva observación y sólo tenemos que considerar que $y = (y - \mu) + \mu$ y teniendo en cuenta que ambos sumandos son independientes y que

$$\begin{aligned} y - \mu &\sim \mathcal{N}(0, \sigma^2), \\ \mu &\sim \mathcal{N}(\mu_1, \sigma_1^2) \end{aligned}$$

se tiene que $y \sim \mathcal{N}(\mu_1, \sigma^2 + \sigma_1^2)$.

Si escribimos la relación (11.8) en términos de la precisión (inversa de la varianza) tenemos que la precisión a posteriori verifica la relación:

$$\tau_1 = \tau_0 + n\tau,$$

y por tanto la precisión a posteriori es la suma de las precisiones a priori más n veces la precisión de los datos, que se supone conocida. Para la media a posteriori también podemos deducir que,

$$E(\mu|\bar{x}) = \mu_0 \cdot \frac{\tau_0}{\tau_0 + n\tau} + \bar{x} \cdot \frac{\tau_1}{\tau_0 + n\tau},$$

es decir, la esperanza a posteriori se puede expresar como una media ponderada de la media a priori y la media muestral. Vemos de nuevo que la familia de distribuciones a priori normal bajo muestreo también normal (en el caso de varianza conocida) es una familia conjugada.

Ejemplo 11.23 Una de las cantidades de interés en la estadística actuarial junto con el número de reclamaciones que se reciben, es la cantidad reclamada (o también denominada cuantía de la reclamación). Veamos un ejemplo de esta situación. Supongamos que tratamos de estudiar la cuantía de las reclamaciones en una determinada póliza de un asegurado para una determinada cartera. El investigador supone que dicha cantidad se distribuye de forma normal, con media μ y varianza conocida e igual a 200 euros. Realizar la inferencia bayesiana considerando como densidad a priori para $\mu \sim N(500, 200)$, conocidas las últimas 5 reclamaciones de un determinado cliente: 450, 500, 650, 600 y 550 euros, cada una.

Solución: Puesto que estamos en las condiciones del teorema 11.1 basta con que identifiquemos cada elemento para obtener de forma inmediata la densidad a posteriori. En este caso $n = 5$, $\mu_0 = 500$, $\sigma^2 = 200 = \sigma_0^2$, $\bar{x} = 550$, de donde se deduce que la densidad a posteriori de μ es $N(541,7; 33,33)$. Con esta densidad a posteriori podemos desarrollar toda la inferencia sobre μ . El caso normal-normal es adecuado para la estimación puntual puesto que al tratarse de una distribución simétrica y unimodal, la media la mediana y la moda coinciden. En este caso valen 541,7 (es decir, un estimador bayesiano puntual de la cuantía media de una reclamación para esta cartera es 541,7 euros). Un intervalo bayesiano de credibilidad al 95 % se obtiene fácilmente de cualquier tabla de la distribución normal o bien, utilizando FirstBayes. En la figura 11.8 puede verse el caso de este ejemplo. Sólo debemos considerar ahora que el análisis que haremos es con varianza conocida (Normal sample, known variance en la pestaña de Analyses de FirstBayes) y que en los resultados obtenidos pueden verse en la figura 11.9, de donde vemos que el intervalo bayesiano de credibilidad con probabilidad 0,95 es (530,35; 552,98) lo que podemos interpretar como que con probabilidad 0,95 la cuantía media de una reclamación de dicha cartera está comprendida entre 530,35 y 552,98 euros.

Ejemplo 11.24 (Continuación ejemplo 11.23) Obtener la distribución predictiva de la cuantía de una nueva reclamación.




Figura 11.8: Información a priori para el ejemplo 11.23




Figura 11.9: Cantidades a posteriori para el ejemplo 11.23

Solución: Los resultados del teorema 11.1 indican que la distribución predictiva de una nueva cantidad será $N(541,7; 233,33)$. En la figura 11.10 pueden verse los mismos resultados obtenidos en FirstBayes donde se ha incorporado también un intervalo bayesiano con probabilidad 0,95 para esta futura observación. En este caso, obtenemos que dicho intervalo vale $(511,72; 571,61)$, que interpretaremos de la siguiente manera: con probabilidad 0,95 la cantidad reclamada en una nueva observación estará comprendida entre 511,72 y 571,61 euros.

◇




Figura 11.10: Distribución predictiva para el ejemplo 11.24

Los contrastes bayesianos para esta situación también se realizan de forma sencilla. Para el caso hipótesis nula simple frente alternativa simple $H_0: \mu = \mu_0$ vs $H_1: \mu = \mu_1$, bastará con obtener el "odds" a posteriori mediante

$$\frac{p_0}{p_1} = \frac{\pi_0}{\pi_1} \cdot \frac{f(x|\mu_0)}{f(x|\mu_1)} = \frac{\pi_0}{\pi_1} \cdot \frac{\exp\left(-\frac{1}{2} \frac{\sum_{i=1}^n x_i^2 - 2n\bar{x}\mu_0 + n\mu_0^2}{\sigma^2}\right)}{\exp\left(-\frac{1}{2} \frac{\sum_{i=1}^n x_i^2 - 2n\bar{x}\mu_1 + n\mu_1^2}{\sigma^2}\right)},$$

siendo π_0 y π_1 las probabilidades a priori de cada hipótesis. De aquí deducimos que el factor Bayes vale:

$$B_{01} = \exp\left\{-\frac{1}{2} \frac{n(\mu_0^2 - \mu_1^2) - 2n\bar{x}(\mu_0 - \mu_1)}{\sigma^2}\right\}.$$

Ejemplo 11.25 (Continuación ejemplo 11.23) Supongamos que en el caso del ejemplo 11.23 estamos también interesados en realizar el contraste

$$H_0: \mu \leq 525 \text{ vs } \mu > 525.$$

Solución: El contraste propuesto pasa por calcular los "odds" a priori y posteriori así como el factor Bayes asociados. Cada una de estas cantidades se obtienen directamente de las densidades a priori y a posteriori utilizadas que en este caso son $N(500, 200)$ y $N(541,7, 33,33)$, respectivamente. Las figuras 11.9 y 11.10 contienen las cantidades necesarias:

$$\frac{\pi_0}{\pi_1} = \frac{0,961}{0,339} = 2,835, \quad \frac{p_0}{p_1} = \frac{0,002}{0,998} = 0,002, \quad B_{01} = 0,0007.$$

de donde concluimos que los datos no aportan ninguna evidencia en favor de H_0 .

◇

11.2.2. Caso de media conocida y varianza desconocida

Analizamos ahora el caso en que la media $\mu = \mu_0$ es conocida y σ^2 es el parámetro desconocido de esta situación sobre el que necesitamos hacer inferencia. La función de verosimilitud viene dada por:

$$L(\underline{x}|\sigma^2) \propto (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sigma^2}\right) = (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2} \frac{S_{\mu_0}}{\sigma^2}\right),$$

donde $S_{\mu_0} = \sum_{i=1}^n (x_i - \mu_0)^2$. Como distribución a priori del parámetro σ^2 elegimos una distribución chi-cuadrado inversa de parámetros S_0 y ν_0 (grados de libertad) cuya función de densidad es la siguiente:

$$\pi(\sigma^2) \propto (\sigma^2)^{-\nu_0/2-1} \exp\left(-\frac{S_0}{2\sigma^2}\right). \quad (11.9)$$

La media, varianza y moda de (11.9) vienen dadas respectivamente por las fórmulas:

$$\begin{aligned} E(\sigma^2) &= \frac{S_0}{\nu_0 - 2}, \quad \text{si } \nu_0 > 2, \\ \text{Var}(\sigma^2) &= \frac{2S_0^2}{(\nu_0 - 2)^2(\nu_0 - 4)}, \quad \text{si } \nu_0 > 4, \\ \text{Moda}(\sigma^2) &= \frac{S_0}{\nu_0 + 2}. \end{aligned}$$

Se denota $\sigma^2 \sim \chi^{-2}(S_0, \nu_0)$ y es una distribución a priori conjugada. La distribución a posteriori para σ^2 viene dada por:

$$\sigma^2|\underline{x} \sim \chi^{-2}(S_0 + S_{\mu_0}, \nu_0 + n).$$

11.2.3. Caso de media y varianza desconocida

Veamos el caso donde la media y la varianza son parámetros desconocidos. La función de verosimilitud es:

$$L(x|\mu, \sigma^2) \propto (\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2} \frac{[S + n(\bar{x} - \mu)^2]}{\sigma^2} \right\},$$

siendo $S = \sum_{i=1}^n (x_i - \bar{x})^2$. La especificación de las distribuciones a priori es la siguiente:

$$\begin{aligned} \mu|\sigma^2 &\sim N(\mu_0, \sigma^2/n_0), \\ \sigma^2 &\sim \chi^{-2}(S_0, \nu_0). \end{aligned}$$

Los casos anteriores pueden considerarse casos particulares de esta situación puesto que coinciden con ella bajo el supuesto de que ambos parámetros son independientes y cada uno de ellos conocido, en cada caso. La distribución a priori conjunta será del tipo normal chi-cuadrado inversa.

$$\begin{aligned} \pi(\mu, \sigma^2) &\propto (\sigma^2)^{-(\nu_0+1)/2-1} \exp \left\{ -\frac{1}{2} (S_0 + n_0(\mu - \mu_0)^2)/\tau \right\} \\ &\propto (\sigma^2)^{-(\nu_0+1)/2-1} \exp \left\{ -\frac{1}{2} Q_0(\mu)/\sigma^2 \right\}, \end{aligned}$$

donde $Q_0(\mu)$ es la forma cuadrática

$$Q_0(\mu) = n_0\mu^2 - 2(n_0\mu_0)\mu + (n_0\mu_0^2 + S_0).$$

La distribución a posteriori conjunta se obtiene como combinación de la distribución a priori y la verosimilitud normal

$$\pi(\mu, \sigma^2|x) \propto \pi(\mu, \sigma^2) \cdot \ell(x|\mu, \sigma^2) \propto (\sigma^2)^{-(\nu_1+1)/2-1} \exp \left(-\frac{1}{2} Q_1(\mu)/\sigma^2 \right), \quad (11.10)$$

donde $\nu_1 = \nu_0 + n$ y la expresión cuadrática $Q_1(\mu)$ es:

$$Q_1(\mu) = S_1 + n_1(\mu - \mu_1)^2 = n_1\mu^2 - 2(n_1\mu_1)\mu + (n_1\mu_1^2 + S_1)$$

donde:

$$\begin{aligned} n_1 &= n_0 + n, \\ \mu_1 &= \frac{n_0\mu_0 + n\bar{x}}{n_1}, \end{aligned}$$

$$S_1 = S_0 + S + n_0\mu_0^2 + n\bar{x} - n_1\mu_1^2.$$

Por tanto se muestra como la distribución a posteriori pertenece también la familia normal chi-cuadrado inversa, y por tanto el análisis es también conjugado. De la distribución conjunta a posteriori podemos ahora deducir las distribuciones marginales a posteriori.

11.2. Análisis bayesiano para datos normales

- La distribución condicional a posteriori $\pi(\mu|\sigma^2, x)$. La densidad a posteriori de μ dados σ^2 y x es proporcional a la a posteriori conjunta dada en (11.10) con σ^2 constante,

$$\mu|\sigma^2, x \sim N(\mu_1, \sigma^2/n).$$

- La distribución marginal a posteriori, $\pi(\sigma^2|x)$. La densidad marginal a posteriori de σ^2 dados x se obtiene analíticamente de

$$\pi(\sigma^2|x) = \int_{-\infty}^{\infty} \pi(\mu, \sigma^2|x) d\mu,$$

siendo $\pi(\mu, \sigma^2|x)$ la densidad a posteriori conjunta dada en (11.10). Ahora bien separando los términos en los que no están implicados directamente términos en μ se deduce que dicha distribución a posteriori es $\chi^{-2}(S_1, \nu_0+n)$, obtenido en la sección anterior para el caso de media conocida.

- La distribución marginal a posteriori, $\pi(\mu|x)$. Para la obtención de la densidad marginal a posteriori de μ dado x debemos integrar la densidad conjunta con respecto a σ^2 . De la expresión (11.10) observamos que la marginal será proporcional a

$$\pi(\mu|x) \propto [S_1 + \nu_1(\mu - \mu_1)^2]^{-(\nu_1+1)/2},$$

que corresponde a una distribución t de Student con parámetro de localización $\bar{x}$, parámetro de escala s y ν_1 grados de libertad. En general una variable aleatoria tendrá una distribución t de Student con parámetro de localización μ , parámetro de escala σ y ν grados de libertad, en notación $\theta \sim t_\nu(\mu, \sigma^2)$ si la función de densidad viene dada por:

$$\pi(\theta) = \frac{\Gamma((\nu+1)/2)}{\Gamma(\nu/2)\sigma\sqrt{\nu\pi}} \left[1 + \frac{1}{\nu} \left(\frac{\theta - \mu}{\sigma} \right)^2 \right]^{-(\nu+1)/2}. \quad (11.11)$$

La esperanza matemática de (11.11) es $E(\theta) = \mu$ si $\mu > 1$, la varianza $\text{Var}(\theta) = \nu\sigma^2/(\nu-2)$ si $\nu > 2$ y la moda es igual a μ . Esta distribución puede transformarse en una t de Student con ν_1 grados de libertad definida en (7.14.2) con función de densidad (7.45) considerando la transformación $\frac{\mu - \mu_1}{s_1/\sqrt{n_1}}$, donde $s_1^2 = \frac{S_1}{\nu_1}$ y $n_1 = n_0 + n$.

11.2.4. Caso no informativo

Al igual que en los modelos anteriores, existe la posibilidad de realizar una análisis con datos normales considerando el caso en el que el experto no quiera incorporar conocimiento a priori (porque no lo tenga o porque desee dar todo el peso de su decisión a la información de los datos, o por ambas cosas). La asignación no

informativa para este caso consiste en suponer que μ y σ^2 son independientes y ambas les asignamos las siguientes densidades no informativas:

$$\pi(\mu) \propto 1, \quad \pi(\sigma^2) \propto (\sigma^2)^{-1},$$

de donde se tiene que la densidad a priori conjunta no informativa es

$$\pi(\mu, \sigma^2) \propto \sigma^{-2}.$$

Todo el análisis a posteriori se puede seguir de forma paralela a como se ha realizado anteriormente. En este caso el cálculo puede ser mucho más sencillo si observamos que estamos ante una situación como la descrita anteriormente pero con valores límite de las cantidades siguientes: $\nu_0 = -1$, $n_0 = 0$, $S_0 = 0$ y $Q_0(\mu) = 0$, de donde deducimos automáticamente las densidades a posteriori de los parámetros de interés.

Ejemplo 11.26 (Continuación ejemplo 11.23) Para el caso del ejemplo 11.23 realizar las mismas inferencias para el caso no informativo a priori.

Solución: Los resultados obtenidos anteriormente y teniendo en cuenta que estamos en el caso no informativo, es decir: $\nu_0 = -1$, $n_0 = 0$, $S_0 = 0$ y $Q_0(\mu) = 0$, junto con $n = 5$ y $\bar{x} = 550$ permiten obtener analíticamente todas las distribuciones (marginales) a posteriori y en consecuencia sus medidas de interés. FirstBayes incluye también esta posibilidad mediante el análisis Normal sample, unknown variance de su "pestaña" Analyses. La figura 11.11 muestra los valores obtenidos para los estimadores bayesianos. Como vemos la distribución a posteriori de μ es un t de Student generalizada cuya media (a posteriori) coincide con la mediana y la moda y valen 550 euros. El intervalo bayesiano de credibilidad al 95 % vale (451,81; 648,19) sensiblemente mayor al caso informativo obtenido anteriormente. Finalmente para el contraste de hipótesis $H_0: \mu \leq 525$ vs $\mu > 525$, vemos que el "odds" a posteriori vale

$$\frac{p_0}{p_1} = \frac{0,25931}{0,75069} = 0,3454$$

de donde deducimos que la hipótesis nula debe ser rechazada. A diferencia del caso informativo la distribución a posteriori de μ proporciona cierta probabilidad a valores grandes del parámetro.

La distribución predictiva a posteriori de una observación futura y puede obtenerse como la mixtura

$$p(y|x) = \int \int f(y|\mu, \sigma^2) \pi(\mu, \sigma^2|x) d\mu d\sigma^2, \quad (11.12)$$

donde $f(y|\mu, \sigma^2) \sim \mathcal{N}(\mu, \sigma^2)$ y $\pi(\mu, \sigma^2|x)$ es la densidad a posteriori conjunta obtenida en (11.10). La simulación de esta distribución pasa por generar valores de μ




Figura 11.11: Cantidades a posteriori para el ejemplo 11.23 con media y varianza desconocidas

y σ^2 de la densidad $\pi(\mu, \sigma^2|x)$ para luego generar valores de y de una $\mathcal{N}(\mu, \sigma^2)$. De hecho, la distribución predictiva de y es t de Student con parámetro de localización $\bar{x}$, parámetro de escala $\sqrt{1 + 1/ns}$, con $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ y $n - 1$ grados de libertad, en notación $y \sim t_{n-1}(\bar{x}, \sqrt{1 + 1/ns})$. Esta distribución se obtiene integrando en (11.12) respecto a μ y σ^2 . También podemos identificar este resultado mediante la factorización,

$$f(y|\sigma^2, x) = \int f(y|\mu, \sigma^2, x) \pi(\mu|\sigma^2, x) d\mu.$$

De la expresión anterior se deduce que $y|\sigma^2, x \sim \mathcal{N}(\bar{x}, (1 + \frac{1}{n})\sigma^2)$, que resulta ser la misma distribución que la de μ dados σ^2 y x cambiando el factor de escala.

Ejemplo 11.27 (Continuación ejemplo 11.26) Para el ejemplo 11.26, encontrar un intervalo bayesiano de credibilidad con probabilidad 0,95 para una observación futura sobre la cuantía de una reclamación.

Solución: De (11.12) sabemos que la distribución predictiva de una nueva observación para el caso de datos normales con ambos parámetros desconocidos es una

distribución t de Student con parámetro de localización $\bar{x}$, parámetro de escala $\sqrt{1+1/ns}$ y $n-1$ grados de libertad. Para el caso que nos ocupa tenemos una distribución $t_4(550, 7500)$ (ver figura 11.12).




Figura 11.12: Distribución predictiva para el ejemplo 11.23 con media y varianza desconocidas

El intervalo bayesiano al 95 % es (485,88; 790,52), e indica que con probabilidad 0,95 una próxima reclamación estará comprendida entre 485,88 y 790,52 euros.

11.3. Análisis bayesiano de datos binarios

El parámetro de interés es ahora la probabilidad ϕ de un determinado suceso que se repite un número de veces y cuyo resultado puede ser éxito (al que asignamos el valor 1) o fracaso (al que asignamos el valor 0). Los ensayos se consideran independientes, con la misma probabilidad de éxito. Supongamos que existe un número n de pruebas, de esta forma tendremos una observación x que recoge el número de éxitos. La variable X que recoge el número de éxitos en n ensayos se distribuye según una binomial de parámetros n y ϕ , que denotaremos por $X \sim B(n, \phi)$. La función de verosimilitud es:

$$L(x|\phi) = \binom{n}{x} \phi^x (1-\phi)^{n-x} = \frac{n!}{x!(n-x)!} \phi^x (1-\phi)^{n-x}, \quad x = 0, 1, \dots, n \quad (11.13)$$

11.3. Análisis bayesiano de datos binarios

En la expresión anterior nos interesa sólo la parte que afecta al parámetro y por tanto podemos escribir la verosimilitud utilizando la notación de proporcionalidad como:

$$L(x|\phi) \propto \phi^x (1-\phi)^{n-x}.$$

En el desarrollo de los métodos bayesianos para responder a los problemas de este tipo sobre proporciones, hay dos maneras básicas de construir el conocimiento a priori sobre el parámetro de interés, ϕ . Los métodos discretos en los que se considera que ϕ sólo puede tomar un posible valor de un conjunto finito de valores o los modelos continuos en los que se considera a ϕ valorada de manera continua en el intervalo $(0, 1)$. En cualquiera de ellos, la información a priori debe reflejar la probabilidad que cada uno de los valores del parámetro tiene para el experto.

11.3.1. Datos binarios en el caso discreto

En esta sección presentamos la inferencia sobre proporciones en el caso en que el parámetro venga expresado de forma discreta, es decir, tome un conjunto finito de valores.

Ejemplo 11.28 Una empresa aseguradora desea estimar el porcentaje de morosidad en una determinada cartera de gran dimensión que tiene emitidas 10000 pólizas. El investigador encargado, teniendo en cuenta toda la información disponible y su conocimiento sobre el funcionamiento interno de la empresa, considera que puede evaluar la morosidad mediante la siguiente distribución a priori o inicial de probabilidad asignada a cada porcentaje de morosidad susceptibles de ocurrir (básicamente éstos coinciden con los habidos hasta la fecha y cualquier otro que considere oportuno el investigador), tal y como se indica en la tabla 11.28. El investigador se plantea si en el momento actual puede admitir la misma evaluación o modificarla, y decide obtener una muestra aleatoria de 5 pólizas entre los que encuentra m morosos. Estudiar cómo se procedería para aprender sobre el porcentaje de morosidad de la entidad cuando se observaron $m = 0$ y $m = 1$, respectivamente.

Solución: En primer lugar, la tabla anterior muestra la opinión actual del investigador sobre el sistema que está inspeccionando. De ella se observa que para él lo más frecuente es que el porcentaje de morosidad sea del 2% (0,02) (corresponde con la mayor probabilidad a priori) y que en término medio el porcentaje de morosidad es de $0,01 \times 0,12 + \dots + 0,10 \times 0,01 = 0,0298$, es decir, del 2,98 $\approx$ 3%. Habitualmente para asignar estas probabilidades (a priori) el experto puede tomar dos valores de referencia (más y menos probable, por ejemplo) y a continuación asignar cada una de las probabilidades al resto de los valores mediante comparación con estos valores de referencia.

Ahora necesitamos obtener la probabilidad que cada uno de los datos observados tiene bajo cada uno de los posibles modelos considerados. Realizamos este

Tabla 11.3: Porcentajes de morosidad y probabilidades a priori

Porcentajes de morosidad	Probabilidades (a priori)
0,01	0,12
0,02	0,30
0,03	0,28
0,04	0,15
0,05	0,12
0,06	0,02
0,10	0,01

Tabla 11.4: Cálculo de las verosimilitudes

Porcentajes de morosidad	Probabilidades (a priori)	Verosimilitud $\phi^m(1-\phi)^{n-m}$
0,01	0,12	0,951
0,02	0,30	0,904
0,03	0,28	0,859
0,04	0,15	0,815
0,05	0,12	0,774
0,06	0,02	0,734
0,10	0,01	0,590

ejercicio para el caso $m = 0$ y de forma análoga se hace para cualquier otro resultado observado de entre los seis posibles. En primer lugar, merece la pena observar que para cada valor de ϕ considerado tenemos un modelo de generación de los datos procedentes de la distribución binomial con $n = 5$ y ese valor de ϕ , luego la verosimilitud (información muestral) la podemos obtener sin más que hacer:

$$\text{Verosimilitud} \propto \phi^m \times (1 - \phi)^{n-m} = 0,01^0 \times (1 - 0,01)^5 = 0,99^5 = 0,951.$$

Análogamente se procede con el resto de las cantidades. Los cálculos pueden hacerse de forma automática mediante una hoja de cálculo (tabla 11.4).

El siguiente paso consiste en obtener los productos entre las a priori y las verosimilitudes (ver tabla 11.5).

Observemos que esta nueva columna nos ha permitido obtener la predictiva asociada a la observación $m = 0$. Ahora basta con que dividamos cada elemento de esta última columna por la predictiva para obtener las probabilidades a posteriori

Tabla 11.5: Cálculo de los productos cruzados priori $\times$ verosimilitud

Porcentajes de morosidad	Probabilidades (a priori)	Verosimilitud $\phi^m(1-\phi)^{n-m}$	Prob. $\times$ Veros.
0,01	0,12	0,951	0,114
0,02	0,30	0,904	0,271
0,03	0,28	0,859	0,240
0,04	0,15	0,815	0,122
0,05	0,12	0,774	0,093
0,06	0,02	0,734	0,015
0,10	0,01	0,590	0,006
Predictiva =			0,8615

de cada tasa de morosidad posible (tabla 11.3.1).

Tabla 11.6: Obtención de las probabilidades a posteriori

Porcentajes de morosidad	Probabilidades (a priori)	Verosimilitud $\phi^m(1-\phi)^{n-m}$	Prob. $\times$ Veros.	Posteriori
0,01	0,12	0,951	0,114	0,132
0,02	0,30	0,904	0,271	0,315
0,03	0,28	0,859	0,240	0,279
0,04	0,15	0,815	0,122	0,142
0,05	0,12	0,774	0,093	0,108
0,06	0,02	0,734	0,015	0,017
0,10	0,01	0,590	0,006	0,007

Como vemos finalmente, el investigador y una vez observada la muestra extraída, tiene una nueva opinión sobre el sistema (que no necesariamente tiene que ser distinta a la inicial). En este caso, nuevamente el valor modal está en el 2%, con una media (a posteriori) del $2,48 \approx 2,5\%$ (vemos que la media ahora es ligeramente inferior puesto que la no aparición de morosos ha hecho que nuestra opinión sobre el índice de morosidad ha sido modificada). De hecho, podemos afirmar que con una probabilidad del 96,6% la tasa de morosidad es menor del 5%. Es importante notar que con una muestra como ésta en el análisis clásico la estimación de la tasa de morosidad sería de $\frac{0}{5} = 0\%$. Obviamente la tasa de morosidad debe ser baja, pero desde luego ningún actuario estaría dispuesto a suponer que dicha tasa es nula.



Ejemplo 11.29 (Continuación ejemplo 11.28) Queda propuesto al lector realizar los cálculos para el caso $m = 1$ y comparar los resultados con los anteriores.

11.3.2. Datos binarios en el caso continuo

Consideraremos ahora la situación más realista en la que el parámetro ϕ puede tomar valores comprendidos entre 0 y 1. Para comprender bien esta situación en comparación con la anterior debemos pensar que nos encontramos en un contexto en el que tendríamos infinitos "modelos", uno para cada valor de ϕ y tenemos que $0 \leq \phi \leq 1$. Ahora lo único que nos diferencia del caso discreto son dos cosas fundamentales: la primera es que tendremos que sustituir la distribución de probabilidad a priori discreta por una continua y la segunda, consecuencia de la anterior, es que sustituiremos los sumandos por integrales. Aunque como veremos a continuación los cálculos matemáticos necesarios en este caso son cerrados utilizaremos el software FirstBayes para su realización y visualización gráfica.

El análisis bayesiano básico recomienda utilizar densidades a priori que permitan cálculos exactos, es decir, que sean de fácil manejo matemático y que puedan ser fácilmente asignables por el investigador, como es el caso de la distribución beta. Supongamos que ϕ la proporción de éxitos se distribuye a priori de según una variable aleatoria beta con función de densidad:

$$\pi(\phi) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \phi^{\alpha-1} (1 - \phi)^{\beta-1}, \quad 0 < \phi < 1, \quad \alpha, \beta > 0. \quad (11.14)$$

La distribución beta es suficientemente flexible como para recoger la mayor parte de las posibles creencias del experto. Como vimos en las figuras 7.2 y 7.3 las densidades beta adoptan formas muy distintas para diferentes valores de los parámetros. La densidad a priori beta viene definida por dos parámetros (α y β). Por lo tanto el experto debería ofrecer información acerca de dos momentos de la distribución a priori, por ejemplo media-moda o media-varianza, o cualquier otra combinación (también pueden asignarse valores puntuales de la distribución).

Estimadores bayesianos

Supongamos que se ha observado una muestra aleatoria de n individuos y que se han obtenido s éxitos y $f = n - s$ fallos o fracasos. La función de verosimilitud es:

$$L(\underline{x}|\phi) \propto \phi^s (1 - \phi)^f = \phi^s (1 - \phi)^{n-s}. \quad (11.15)$$

Combinando (11.14) con (11.15) obtenemos que la distribución posterior es,

$$\phi|\underline{x} \sim Be(\alpha + s, \beta + n - s), \quad (11.16)$$

11.3. Análisis bayesiano de datos binarios

que es de nuevo una distribución beta. La inferencia bayesiana para esta situación es inmediata. Los estimadores puntuales más habituales ya sabemos que son la media, mediana y moda dependiendo del tipo de función de pérdida. El estimador Bayes bajo función de pérdida cuadrática es la media a posteriori, es decir:

$$E(\phi|\underline{x}) = \frac{\alpha + s}{\alpha + \beta + n}. \quad (11.17)$$

El cálculo de los intervalos de credibilidad bayesianos con probabilidad $1 - \alpha$ consiste en hallar un intervalo $[a, b]$ de tal forma que la probabilidad (a posteriori) de que dicho intervalo contenga al parámetro es $(1 - \alpha)\%$, esto es

$$\int_a^b \pi(\phi|\underline{x}) d\phi = 1 - \alpha,$$

con $\pi(\phi|\underline{x}) \sim Be(\alpha + s, \beta + n - s)$. Veamos como en el proceso de aprendizaje sobre ϕ la información muestral se ha incorporado de manera inmediata. La fórmula (11.17) se puede escribir como:

$$\frac{\alpha + s}{\alpha + \beta + n} = w \frac{\alpha}{\alpha + \beta} + (1 - w) \frac{s}{n},$$

con $w = \frac{\alpha + \beta}{\alpha + \beta + n}$. La media a posteriori (es decir nuestro juicio actualizado sobre la media) se ha formado como una media ponderada entre la media a priori $\alpha/(\alpha + \beta)$ (media procedente de los juicios del experto) y la media muestral $\frac{s}{n}$ (información proveniente de los datos). Se pone de manifiesto que el estimador bayesiano es un punto medio entre los datos y el juicio inicial. Además esta expresión permite analizar dos situaciones límite:

1. Caso de "no" información muestral: $n = 0$. En tal caso la expresión w vale 1 y por tanto la media a posteriori coincide con la a priori. Obviamente, si no hay información adicional de los datos, los juicios sobre el parámetro coincidirán con los juicios actuales.
2. Caso de "infinita" información muestral: $n \rightarrow \infty$. En este hipotético caso de disponer de toda la información posible de la población, el factor de ponderación w tiende a 0 y por tanto $1 - w$ vale 1, y por tanto la media a posteriori coincide con la media muestral. Es decir, en situaciones en las que el tamaño muestra es grande las estimaciones clásicas (media muestral) y bayesianas (media a posteriori) coinciden.

Veamos el caso no informativo a priori. Supongamos que todo el aprendizaje está basado en la información de los datos. La distribución uniforme estudiada en (7.2) asigna el mismo peso a priori a todos los valores de ϕ entre 0 y 1:

$$\pi(\phi) = 1, \quad 0 < \phi < 1,$$

y $\pi \sim \text{Be}(1, 1) = \mathcal{U}(0, 1)$. En este caso particular, la distribución a posteriori se obtiene como:

$$\pi(\phi|x) \propto \phi^s(1-\phi)^{n-s},$$

que comparando con la densidad beta vemos que se corresponde con una beta de parámetros $s+1$ y $n-s+1$ siendo s el número de éxitos en n pruebas.

En este caso cómo la moda de la distribución a posteriori coincide con la estimación de máxima verosimilitud:

$$\text{Moda} = \frac{s+1-1}{s+1+1+n-s-2} = \frac{s}{n}.$$

Existen otras elecciones de densidades no informativas como la densidad beta de parámetros nulos, $\text{Be}(0, 0)$. La media de la distribución a posteriori empleando esta distribución a priori coincide nuevamente con el estimador de máxima verosimilitud:

$$\text{Media} = \frac{0+s}{0+s+0+n-s} = \frac{s}{n}.$$

La distribución predictiva de una observación futura z viene dada por:

$$\begin{aligned} p(z|x) &= \int_0^1 f(z|\phi)\pi(\phi|x)d\phi \\ &= \binom{n}{z} \frac{\Gamma(\alpha+\beta+n)}{\Gamma(\alpha+s)\Gamma(\beta+n-s)} \int_0^1 \phi^{\alpha+s+z}(1-\phi)^{\beta+n-s-n-z}d\phi \\ &= \binom{n}{z} \frac{\Gamma(\alpha+\beta+n)}{\Gamma(\alpha+s)\Gamma(\beta+n-s)} \frac{\Gamma(\alpha+s+z)\Gamma(\beta+2n-s-z)}{\Gamma(\alpha+\beta+2n)}, \quad (11.18) \end{aligned}$$

expresión que se corresponde con una distribución beta-binomial.

Ejemplo 11.30 Consideremos el caso del ejemplo 11.28 abordado ahora como un problema continuo. Consideremos el caso de $n = 5$ y que no hemos observado impago en ninguna de las pólizas muestreadas. Para la información del experto consideremos la media y moda deducidas del mismo ejemplo que valían respectivamente, 3% y 2%.

Solución: En efecto, en primer lugar tenemos que el parámetro de interés, la tasa de morosidad de la compañía, será un parámetro que varía entre 0 y 1. Debemos construir una densidad a priori beta que refleje correctamente el juicio del actuario sobre el valor medio y modal. Utilizando la relación entre la media y la moda y los valores de los parámetros α y β . En efecto, conocemos que:

$$\text{Media} = \frac{\alpha}{\alpha+\beta} = 0,03,$$

$$\text{Moda} = \frac{\alpha-1}{\alpha+\beta-2} = 0,02.$$

Resolviendo este sistema obtendremos los valores de α y β que se corresponden con los juicios iniciales del experto. La solución es $\alpha = 2,88$ y $\beta = 93,12$. Ahora la aplicación directa de (11.17) permite obtener analíticamente la distribución a posteriori. Tenemos que de una muestra de $n = 5$ pólizas no ha aparecido ningún moroso, es decir $s = 0$, y la distribución a posteriori es una distribución beta $\text{Be}(2,88; 93,12)$.


Ejemplo 11.31 (Resolución del ejemplo 11.30 con FirstBayes) Resolver el ejemplo 11.30 con FirstBayes y obtener gráficas de las cantidades de interés.

Solución: Utilizaremos en este ejemplo el software FirstBayes. Un breve manual del programa puede consultarse en el Apéndice A. Basta entrar en el programa (haciendo doble click) y activar la opción APL data entry en Options. Puesto que se trata de datos binomiales (0 y 1) en el apartado de Analyses iremos a su menú de Binomial sample. Automáticamente nos pedirá en el margen superior derecho que introduzcamos la densidad a priori donde introduciremos el valor 2,88 en parameter p (que es su equivalente a α) y 93,12 en parameter q equivalente a β . En la figura 11.13 podemos ver los valores obtenidos una vez que se pulsa Next.

The screenshot shows the FirstBayes software interface. The 'Prior Distribution Facts' section displays the Beta(2.88, 93.12) distribution. Below this, the 'Basic Summaries' section shows the following values: Mean (0.03), Median (0.026734), Mode(s) (0.02), St. Dev. (0.017321), Variance (0.0003), and Quantiles (0.017208, 0.039343). The 'More summaries' section has fields for Prob., HDI, and %Hd, each followed by an equals sign and a blank space. The 'Parameters' section shows 'Parameter set no.' (1), 'Parameter p' (2.88), 'Parameter q' (93.12), and 'Weight' (1). At the bottom, there are buttons for 'Basic', 'Next', 'Plot', and 'Quit'.

Figura 11.13: Introducción de la densidad $\text{Be}(2,88; 93,12)$

Una gráfica de esta densidad puede obtenerse fácilmente sin más que elegir la opción Plot, como muestra la figura 11.14. Una inspección de la gráfica anterior confirma los valores de la media y moda que habíamos asignado anteriormente. Pero también nos da más información adicional. Por ejemplo, el investigador piensa que es altamente improbable encontrarse con una tasa de morosidad mayor del

Figura 11.14: Gráfica de la densidad $Be(2.88; 93, 12)$

10 % (gráficamente vemos que la densidad se aproxima a cero a partir de 0,10). En definitiva, el investigador considera que toda la tasa de morosidad se encuentra concentrada en valores menores del 10 % (como mucho del 12 % como puede apreciarse gráficamente). Ahora debemos incorporar la información muestral. Aprovecharemos este ejemplo, para realizar también los cálculos mediante FirstBayes pues nos permite realizar muchas más inspecciones de la densidad a posteriori. Para ello, introduciremos los datos para obtener la a posteriori. Para ello debemos ir a la opción Data y pulsando en New podremos introducir nuestros datos (pondremos nombre al nuevo fichero y conviene poner una descripción de qué contiene para futuros accesos a este fichero). Dicho fichero contendrá cinco ceros pues han sido las observaciones obtenidas (conviene grabar el fichero para futuros accesos, para ello pulsar Save). En la figura 11.15 puede apreciarse el proceso realizado.

Ahora volvemos al menú inicial pulsando en Quit. Para obtener la densidad a posteriori sólo nos queda actualizar la densidad a priori. Para ello, si miramos debajo de la a priori que acabamos de definir hay una "pestaña" denominada Data que actualmente está en Null. Si desplegamos esa pestaña podremos ver los ficheros que tenemos disponibles para cargar.

Cargaremos el fichero datos_morosidad (figura 11.15). Realizada esta operación automáticamente en la parte superior izquierda aparece la densidad a posteriori que se obtiene, que es la misma que la obtenida analíticamente. Adicionalmente nos aporta varias de sus medidas descriptivas que son importantes: la media (a posteriori) vale 0,028515 (es decir, del 2,85 %. Lo que ha ocurrido es que al no observar morosidad alguna en dicha muestra la opinión del investigador se ha ses-




Figura 11.15: Introducción de datos para el ejemplo 11.30

gado ligeramente hacia la izquierda tendiendo a ser más próxima a cero, pero no vale cero desde luego que es la estimación que aportaría un clásico). La moda vale 1,9 %, también ligeramente más pequeña que en la situación inicial. Gráficamente podemos ver dicha densidad en la siguiente figura 11.16, en la que hemos insertado simultáneamente la gráfica y los valores obtenidos en la distribución a posteriori.

Ejemplo 11.32 (Continuación ejemplo 11.30) Obtener los estimadores puntuales de ϕ y un intervalo bayesiano de credibilidad con probabilidad 0,95 para el caso del ejemplo 11.30.

Solución: Calcular el intervalo bayesiano de credibilidad al 95 % por ejemplo, es inmediato con FirstBayes además de los estimadores puntuales media, mediana y moda que valen 0,028, 0,025 y 0,019, respectivamente (figura 11.17). Basta ir a la pestaña denominada HDI que aparece debajo de la densidad a posteriori e indicar el nivel de probabilidad deseado, 95 % en nuestro caso.

Como vemos los límites obtenidos son 0,0027 y 0,0608, es decir la tasa de morosidad está comprendida entre el 0,2 % y el 6,1 %, con una probabilidad del 95 %. Ahora nos preguntamos: ¿cuál será la probabilidad de que esta tasa sea mayor del 10 %? Para ello, basta con indicar en la opción Prob. el intervalo del que queremos obtener la probabilidad, en este caso será entre 0,10 y 1. El resultado obtenido (figura 11.18) es 0,001612, es decir, la probabilidad de que la tasa de




Figura 11.16: Densidad a posteriori para la tasa de morosidad

morosidad sea mayor del 10% es 0.002, muy pequeña, puesto que los datos nos han informado de que no había errores en la muestra.

◇

Ejemplo 11.33 Supongamos que una compañía aseguradora desea conocer el porcentaje de asegurados que de una determinada cartera presentarán alguna reclamación a lo largo del presente año. Se han observado $n = 100$ clientes de los cuales 45 han presentado alguna reclamación. Se trata de realizar el contraste:

$$H_0 : \phi = \frac{1}{2} \text{ vs } H_1 : \phi = \frac{2}{3},$$

para una situación a priori no informativa.

Solución: Estamos en una situación de hipótesis nula simple frente alternativa simple y utilizaremos las expresiones de los odds y del factor Bayes. En general el problema se resuelve teniendo en cuenta que si hay s éxitos en una muestra de tamaño n tendremos que:

$$L(s|\phi) = \binom{n}{s} \phi^s (1-\phi)^{n-s}.$$




Figura 11.17: Intervalo bayesiano al 95 % para el ejemplo 11.30

Luego el odds a posteriori vale:

$$\frac{p_0}{p_1} = \frac{\pi_0 \phi_0^s (1-\phi_0)^{n-s}}{\pi_1 \phi_1^s (1-\phi_1)^{n-s}}, \quad (11.19)$$

y el factor Bayes:

$$B_{01} = \left(\frac{\phi_0}{\phi_1} \right)^s \left(\frac{1-\phi_0}{1-\phi_1} \right)^{n-s}. \quad (11.20)$$

Para el caso que nos ocupa $n = 100$, $s = 45$, $\pi_0 = \pi_1 = \frac{1}{2}$, $\phi_0 = \frac{1}{2}$ y $\phi_1 = \frac{2}{3}$ de donde se obtiene que

$$B_{01} = \left(\frac{3}{4} \right)^{45} \left(\frac{3}{2} \right)^{55} = 1155,5$$

que indica que a la luz de los datos la hipótesis nula es 1155,5 veces más creíble que la alternativa. Parece claro que admitiremos que $\phi = \frac{1}{2}$. Observemos que en este caso factor Bayes y "odds" a posteriori coinciden.

◇




Figura 11.18: Probabilidad a posteriori de que la tasa de morosidad sea mayor del 10 % en el ejemplo 11.30

Veamos el caso de hipótesis nula simple frente a alternativa compuesta. Supongamos una verosimilitud binomial de parámetros n y ϕ , en la que deseamos contrastar la hipótesis $H_0: \phi = \phi_0$ vs $H_1: \phi \neq \phi_0$. La información a priori es del tipo:

1. $\Pr(H_0) = \pi_0, \Pr(H_1) = 1 - \pi_0$.
2. La densidad a priori mixta tendrá la forma siguiente ($\pi_1(\phi) \sim \text{Be}(\alpha, \beta)$):

$$\pi(\phi) = \begin{cases} \pi_0 & \text{si } \phi = \phi_0, \\ (1 - \pi_0) \cdot \pi_1(\phi) & \text{si } \phi \neq \phi_0. \end{cases}$$

Siguiendo los mismos pasos que en el ejemplo 10.10 tenemos:

$$f(s|\phi_0) = \binom{n}{s} \phi_0^s (1 - \phi_0)^{n-s}, \quad (11.21)$$

$$p_1(s) = \int_{\{\phi \neq \phi_0\}} f(s|\phi) \pi_1(\phi) d\phi = \binom{n}{s} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha + s)\Gamma(\beta + n - s)}{\Gamma(\alpha + \beta + n)}, \quad (11.22)$$

11.3. Análisis bayesiano de datos binarios

327

luego el "odds" a posteriori vale

$$\frac{p_0}{p_1} = \frac{\pi_0}{1 - \pi_0} (\phi_0^s (1 - \phi_0)^{n-s}) \frac{\Gamma(\alpha)\Gamma(\beta)\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + \beta)\Gamma(\alpha + s)\Gamma(\beta + n - s)}, \quad (11.23)$$

y el factor Bayes tiene la expresión,

$$B_{01} = \phi_0^s (1 - \phi_0)^{n-s} \frac{\Gamma(\alpha)\Gamma(\beta)\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + \beta)\Gamma(\alpha + s)\Gamma(\beta + n - s)}. \quad (11.24)$$

Ejemplo 11.34 (Continuación ejemplo 11.33) Para el caso del ejemplo 11.33 realizar ahora el contraste $H_0: \phi = \frac{1}{2}$ vs $H_1: \phi \neq \frac{1}{2}$

Solución: Usando las expresiones (11.21) y (11.22) y para el caso particular de este ejemplo: $n = 100, s = 45, \pi_0 = \frac{1}{2}$ y suponiendo el caso no informativo $\alpha = \beta = 1$ tendremos que el "odds" a posteriori y el factor Bayes tienen el mismo valor $(\frac{1}{2})^{100} \cdot \frac{\Gamma(102)}{\Gamma(46)\Gamma(56)} = 4.9$. Es decir, la hipótesis nula es casi 5 veces más creíble a posteriori que la alternativa. Observemos que en el caso de hipótesis nula simple frente alternativa simple (ejemplo 11.33) este valor era mayor. Es decir, si tenemos que decidir entre dos posibles valores los datos aportan evidencia muy clara hacia la hipótesis nula. Ahora bien, cuando sólo se trata de una hipótesis nula simple, los datos ofrecen evidencia en favor de H_0 pero no en la magnitud en la que lo hacía en el otro caso.

Para el caso de hipótesis nula y alternativa compuesta el procedimiento es análogo, como ya hemos comentado. En los siguientes ejemplos veremos cómo podemos proceder en estos casos.

Ejemplo 11.35 (Continuación ejemplo 11.30) Volviendo al caso de la inspección de pólizas sin pagar de una compañía aseguradora del ejemplo 11.30, supongamos que el investigador está interesado en contrastar la hipótesis de que la tasa de morosidad es menor del 4 % frente a la hipótesis de que es mayor.

Solución: Se trata del contraste:


$$H_0: 0 \leq \phi \leq 0,04 \quad \text{vs} \quad H_1: \phi > 0,04.$$

Utilizaremos FirstBayes para realizar los cálculos. Cada una de las hipótesis tiene unas probabilidades iniciales de ser cierta (figura 11.19):

$$\pi_0 = \Pr(H_0 \text{ cierta}) = \Pr(0 \leq \phi \leq 0,04) = 0,76.$$

En consecuencia la probabilidad a priori de que la tasa de morosidad sea mayor del 4 % será de $\pi_1 = 0,24$. El "odds" a priori valdrá

$$\frac{\pi_0}{\pi_1} = \frac{0,76}{0,24} = 3,17.$$

Figura 11.19: Probabilidad a priori de H_0 en el ejemplo 11.35


Este cociente señala que a priori la hipótesis nula (la tasa de morosidad es menor del 4%) es 3,17 veces más creíble que la alternativa (es mayor del 4%). Esta relación es una cantidad comprensible por el investigador quien a priori tiene una opinión sobre cada una de las hipótesis (en este caso, aproximadamente tres veces más creíble la primera hipótesis que la segunda). Ahora debemos calcular las probabilidades a posteriori de cada una de las hipótesis. Para ello, volviendo a la ventana correspondiente a la densidad a posteriori indicamos las mismas probabilidades que anteriormente y se obtiene (ver figura 11.20):

$$p_0 = \Pr(H_0 \text{ cierta} \mid \text{datos}) = \Pr(0 \leq p \leq 0,04) = 0,788.$$

La probabilidad a posteriori de H_1 será por tanto de $p_1 = 0,21$. Observemos ahora el "odds" a posteriori:

$$\frac{p_0}{p_1} = \frac{0,79}{0,21} = 3,76.$$

Es decir, una vez incorporada la información muestral, una tasa de morosidad menor del 4% es casi 4 veces más creíble que una tasa mayor. En consecuencia, la decisión del experto puede ser del siguiente tipo: A la luz de los datos, aceptamos

Figura 11.20: Probabilidad a posteriori de H_0 en el ejemplo 11.35

que la tasa de morosidad es menor del 4% con una probabilidad de ser cierta de 0,79 (o equivalentemente, del 79%). Frente a la hipótesis de ser mayor, la hipótesis inicial de morosidad menor del 4% es aproximadamente 4 veces más creíble. El factor Bayes de H_0 frente a H_1 vale

$$B_{01} = \frac{p_0/p_1}{\pi_0/\pi_1} = \frac{0,79/0,21}{0,76/0,24} = 1,19,$$

dicho valor se interpreta diciendo que los datos proporcionan aproximadamente 1,19 veces más credibilidad a la hipótesis nula que a la alternativa. En este caso los datos proporcionan la misma credibilidad a las dos hipótesis.

A modo de resumen, los test de hipótesis se realizan de una manera sencilla. Las hipótesis tendrán unas probabilidades de ser ciertas que se actualizan a la luz de los datos (mediante el teorema de Bayes). El factor Bayes proporciona la evidencia que aportan los datos a la decisión. Finalmente otras de las cantidades de interés en el análisis bayesiano es la distribución predictiva de futuros datos, que es una beta-binomial (fórmula (11.18)). En ocasiones el experto está también interesado en conocer qué puede ocurrir en futuras observaciones. El análisis secuencial por tanto es crucial para este desarrollo y el método bayesiano es adecuado

para esta situación. El problema se resuelve mediante el cálculo de la denominada *distribución predictiva* de una nueva observación z :

$$p(z|x) = \int_0^1 L(z|\phi)\pi(\phi|x)d\phi.$$

Ejemplo 11.36 (Continuación ejemplo 11.30) Supongamos que nuestro investigador está interesado en conocer qué puede esperar de la observación de 4 nuevos contratos en cuanto a su morosidad.




Figura 11.21: Introducción de la distribución predictiva en el ejemplo 11.36

Solución: Mediante FirstBayes el cálculo se puede hacer a través de la pestaña que aparece como Predictive analysis en la opción Show predictive (figura 11.21), indicando el número de nuevas observaciones que deseamos predecir (cuando se trata de más de una observación se obtiene la distribución predictiva del total de las nuevas observaciones). Bastará con que en la opción de Predict sum of se indiquen 4 observaciones y pulsemos en Show predictive

La distribución predictiva obtenida es beta-binomial. Podemos observar que esta distribución tiene una moda de 0 (es decir, que lo más frecuente es que en las futuras 4 observaciones no haya ningún contrato moroso). Del mismo modo,




Figura 11.22: Obtención de la distribución predictiva e intervalo bayesiano de credibilidad al 95 % para dicha predictiva en el ejemplo 11.36

podemos calcular el intervalo bayesiano de credibilidad para la predictiva. En este caso, con una probabilidad de 0,95 dicho intervalo es $[0, 1]$. Es decir, con una probabilidad del 95 % las futuras 4 observaciones presentarán 0 ó 1 contratos morosos (figura 11.22).

Ejemplo 11.37 (Continuación ejemplo 11.36) Realizar el mismo análisis anterior pero considerando que en la muestra de $n = 5$ contratos apareció un moroso, $y = 1$.

11.3.3. Comparación de dos proporciones

Como ya hemos visto, el análisis bayesiano nos permite realizar un estudio detallado sobre proporciones sin más que incorporar nuestros juicios sobre la tasa objeto de interés y la información muestral recogida en forma de éxitos o fracasos. Hay algunas situaciones relativas a proporciones o tasas en las que también el análisis bayesiano puede aportar una buena forma de realizar el aprendizaje sobre dicha tasa. Pensemos, por ejemplo, en el caso de una compañía que posee dos filiales

y quiere comprobar si la tasa de éxitos en una u otra filiar puede considerarse iguales o hay evidencia de que en una es mayor.

Formalmente podemos enunciar el problema de la siguiente forma. Supongamos que observamos dos muestras binomiales de dos poblaciones: $x \sim \mathcal{B}(n_x, \phi_x)$, $y \sim \mathcal{B}(n_y, \phi_y)$. Estamos interesados en la relación entre ϕ_x y ϕ_y , bajo el supuesto de que ambos parámetros son independientes con densidades a priori de tipo beta, $Be(\alpha_x, \beta_x)$ y $Be(\alpha_y, \beta_y)$.

Conocemos ya que la densidad a posterior de cada parámetro será respectivamente $Be(\alpha_x + x, \beta_x + n_x - x)$ y $Be(\alpha_y + y, \beta_y + n_y - y)$. Ahora estamos interesados en comparar las proporciones en cada una de las poblaciones. Habitualmente, esta comparación puede hacer a través de la diferencia $\phi_x - \phi_y$ o bien el cociente $\frac{\phi_x}{\phi_y}$.

Existen varias alternativas bayesianas para resolver este problema. Un primer procedimiento consiste en considerar la reparametrización

$$\lambda_x = \frac{\phi_x}{1 - \phi_x}, \lambda_y = \frac{\phi_y}{1 - \phi_y}, \Lambda_x = \log \lambda_x \text{ y } \Lambda_y = \log \lambda_y.$$

Como puede verse en Lee (2003, p. 152) las siguientes cantidades

$$\frac{1}{2}\Lambda_x + \frac{1}{2}\log\left(\frac{\beta_x + n_x - x}{\alpha_x + x}\right), \quad \frac{1}{2}\Lambda_y + \frac{1}{2}\log\left(\frac{\beta_y + n_y - y}{\alpha_y + y}\right),$$

se distribuyen a posteriori aproximadamente como una distribución normal con parámetros $\log\left(\frac{\alpha_x + x - 1/2}{\beta_x + n_x - x - 1/2}\right)$ y $\frac{1}{\alpha_x + x} + \frac{1}{\beta_x + n_x - x}$, para Λ_x (análogamente para Λ_y sin más que cambiar x por y). Ahora teniendo en cuenta que $\Lambda_x - \Lambda_y = \log\left(\frac{\lambda_x}{\lambda_y}\right)$, tendremos que

$$\Lambda_x = \Lambda_y \iff \frac{\lambda_x}{\lambda_y} = 1 \iff \phi_x = \phi_y. \quad (11.25)$$

De esta última identidad podremos obtener las relaciones entre las proporciones sin más que considerar que las diferencias entre normales independientes es nuevamente una normal: $\mathcal{N}(\mu(x, y), \sigma^2(x, y))$ con:

$$\mu(x, y) = \log\left[\frac{(\alpha_x + x)(\beta_y + n_y - y)}{(\beta_x + n_x - x)(\alpha_y + y)}\right], \quad (11.26)$$

$$\sigma^2(x, y) = \frac{1}{\alpha_x + x} + \frac{1}{\beta_x + n_x - x} + \frac{1}{\alpha_y + y} + \frac{1}{\beta_y + n_y - y}. \quad (11.27)$$

Un segundo procedimiento más simple, y con resultados similares al anterior para tamaños muestrales adecuados es el siguiente. Bastará con aproximar las distribuciones a posteriori de los parámetros de interés por aquellas distribuciones normales que tienen la misma media y varianza que la original distribución beta a posteriori. A continuación y puesto que son independientes, la diferencia entre estos

dos parámetros volverá a ser también normal. Es decir, aproximamos las densidades a posteriori de ϕ_x y ϕ_y mediante las distribuciones $\mathcal{N}(\mu_x, \sigma_x^2)$ y $\mathcal{N}(\mu_y, \sigma_y^2)$, respectivamente, siendo

$$\mu_x = \frac{\alpha_x + x}{\alpha_x + \beta_x + n_x}, \quad \sigma_x^2 = \frac{(\alpha_x + x)(\beta_x + n_x - x)}{(\alpha_x + \beta_x + n_x)^2(\alpha_x + \beta_x + n_x + 1)}, \quad (11.28)$$

$$\mu_y = \frac{\alpha_y + y}{\alpha_y + \beta_y + n_y}, \quad \sigma_y^2 = \frac{(\alpha_y + y)(\beta_y + n_y - y)}{(\alpha_y + \beta_y + n_y)^2(\alpha_y + \beta_y + n_y + 1)}, \quad (11.29)$$

y por tanto, $\phi_x - \phi_y \sim \mathcal{N}(\mu_x - \mu_y, \sigma_x^2 + \sigma_y^2)$.

Ejemplo 11.38 El servicio de estudios de una entidad aseguradora desea conocer si existe o no evidencia sobre el efecto de una campaña publicitaria para la captación de nuevos clientes en determinadas zonas de la ciudad. Existen dos grupos de potenciales clientes a los que se dirige. Para el grupo A, se analizaron 720 individuos de forma aleatoria; de los que 380 aceptaron, y el resto no. En la zona B, fueron analizados 290, de los que 120 eran partidarios. Desarrollar un procedimiento que permita comparar las proporciones de positivos, bajo el supuesto de inexistencia de información a priori.

Solución: La modelización de esta situación podemos hacerla de la siguiente forma. Consideremos ϕ_A la tasa de positivos o éxitos de la zona A y ϕ_B su análogo para la zona B. Para cada una de estas zonas debemos utilizar de acuerdo al enunciado, una a priori no informativa que conocemos que se corresponde con una densidad beta, $Be(1, 1)$, lo que equivale a $\pi(\phi_A) \propto 1$ y $\pi(\phi_B) \propto 1$. La información muestral en cada zona será:

- Zona A: verosimilitud $\propto \phi_A^{380}(1 - \phi_A)^{340}$.
- Zona B: verosimilitud $\propto \phi_B^{120}(1 - \phi_B)^{170}$.

La distribución a posteriori es:

$$\pi(\phi_A | \text{datos}) \propto \pi(\phi_A)L(\phi_A | \text{datos}) \propto \phi_A^{380}(1 - \phi_A)^{340},$$

que se corresponde con una densidad beta $Be(381, 341)$, que puede obtenerse con FirstBayes.

Como vemos (figura 11.23) la tasa de éxito en la zona A podemos estimarla en torno al 52,77%, estando toda la tasa de éxito de la zona A concentrada entre el 46% y 59% con un intervalo bayesiano al 95% de entre 49,1% y 56,4%, es decir, existe una probabilidad del 0,5% de que la tasa de éxito de la campaña en la zona A esté comprendida entre el 49,1% y el 56,4%. Observemos que ahora hemos utilizado FirstBayes directamente desde la opción de Distributions sin pasar por el análisis binomial. Para ello tendríamos que crear un fichero de 720




Figura 11.23: Tasa de éxito en la zona A

registros con 380 unos y 340 ceros y dado que los cálculos para la a posteriori son inmediatos se ha preferido esta opción. Es también interesante observar que la varianza para el parámetro en la zona A puede estimarse por 0,000345.

Para la zona B se procede de forma análoga obteniéndose una densidad a posteriori beta, $Be(121,171)$.

Como vemos (figura 11.24), la tasa de éxito en la zona B podemos estimarla en torno al 41,4%, estando toda la tasa de éxito de la zona B concentrada entre el 32% y 51% con un intervalo bayesiano al 95% de entre 35,8% y 47,1%, es decir, existe una probabilidad del 5% de que la tasa de éxito de la campaña en la zona B esté comprendida entre el 35,8% y el 47,1%. Del mismo modo que anteriormente, observemos que hemos utilizado FirstBayes directamente desde la opción de Distributions sin pasar por el análisis binomial. La varianza para el parámetro en la zona B es 0,000828. Una vez conocidas las tasa de éxito en cada zona, el problema que debemos ahora resolver es ver si hay evidencia de que la tasa de éxito en la zona A es mayor que en la zona B, es decir:

$$\Pr(\phi_A > \phi_B) = \Pr(\phi_A - \phi_B > 0).$$

Se trata de saber cómo se distribuye la diferencia entre ambos parámetros, sabiendo




Figura 11.24: Tasa de éxito en la zona B

que cada uno de ellos se distribuye de acuerdo a una beta. No es un problema sencillo de resolver pues la diferencia de betas no es, en general, otra distribución beta. Sin embargo, existe una manera adecuada de evitar este problema. En efecto, si observamos las densidades a posteriori de cada una de las zonas podemos ver que cada una de ellas se parece o aproxima de manera muy buena a una campana de Gauss, es decir, a una densidad normal. Para realizar la aproximación sustituimos la densidad beta para la zona A por aquella densidad normal que tenga la misma media y varianza que la densidad beta obtenida anteriormente. En este caso, aproximaremos la densidad a posteriori de ϕ_A por una densidad normal, $N(0,5277; 0,000345)$, y lo mismo para la zona B, que en este caso se aproxima por una normal $N(0,414; 0,000828)$. Finalmente, $\phi_A - \phi_B$ se comporta aproximadamente como una normal $N(0,1137; 0,001173)$. La probabilidad de interés es: $\Pr(\phi_A > \phi_B) = 0,999$. Por tanto podemos asegurar con una probabilidad del 99,9% (figura 11.25) que la tasa de éxitos en la zona A es mayor que en la B.




Figura 11.25: Densidad normal que mejor aproxima la diferencia de tasas de éxito entre ambas zonas

11.4. Aspectos computacionales

Tal y como hemos visto a lo largo del capítulo, el aspecto central del análisis bayesiano consiste en el cálculo de las densidades a posteriori, y de las integrales que ello implica. En muchas situaciones a menudo es difícil obtener la distribución a posteriori derivada del teorema de Bayes $\pi(\theta|x) \propto \pi(\theta)L(x|\theta)$, sobre todo el factor de proporcionalidad $\int \pi(\theta)L(x|\theta)d\theta$. El análisis conjugado hemos visto que es una técnica adecuada desde el punto de vista analítico puesto que permite obtener de forma automática la densidad a posteriori. Sin embargo, no siempre podremos adaptarnos a un escenario conjugado.

Surge por tanto, la idea que en ocasiones necesitaremos “buenas” aproximaciones de la densidad a posteriori. Una primera idea de aproximación de la densidad a posteriori puede enunciarse en los términos del siguiente teorema.

Teorema 11.2 *Supongamos que $X_i|\theta \sim f(x_i|\theta)$ i.i.d. y que la densidad a priori para θ es $\pi(\theta)$. Entonces observados $\mathbf{x} = (x_1, \dots, x_n)$, cuando $n \rightarrow \infty$ se tiene que la densidad a posteriori $\pi(\theta|x)$ es:*

1. $\mathcal{N}(E(\theta|x), \text{Var}(\theta|x))$, siempre que existan la media y varianza de la distribu-

ción a posteriori.

2. $\mathcal{N}(\tilde{\theta}, I_1(\tilde{\theta})^{-1})$ siendo $\tilde{\theta}$ la moda de la densidad a posteriori e $I_1(\theta) = -\frac{\partial^2 \log L(\theta|x)}{\partial \theta^2}$.
3. $\mathcal{N}(\hat{\theta}, I_1(\hat{\theta})^{-1})$ siendo $\hat{\theta}$ el estimador de máxima verosimilitud de θ e $I_1(\theta) = -\frac{\partial^2 \log L(\theta|x)}{\partial \theta^2}$.
4. $\mathcal{N}(\hat{\theta}, I_2(\hat{\theta})^{-1})$ siendo $\hat{\theta}$ el estimador de máxima verosimilitud de θ e $I_2(\theta) = -E_x \left(\frac{\partial^2 \log L(\theta|x)}{\partial \theta^2} \right)$.

Debemos tener en cuenta que estas aproximaciones podrán utilizarse cuando el tamaño muestral sea grande y además existan las cantidades requeridas. Aunque todas suelen producir densidades a posteriori muy similares, la primera aproximación es la más utilizada siempre que existan media y varianza. La tercera y segunda son equivalentes bajo distribuciones a priori uniformes. Existen también métodos como el de Laplace (O'Hagan y Forster, 2004; pág. 253) para aproximar directamente cantidades a posteriori que puedan escribirse de la forma

$$E[g(\theta)|x] = \frac{\int g(\theta)L(x|\theta)\pi(\theta)d\theta}{\int L(x|\theta)\pi(\theta)d\theta},$$

para $g(\theta)$ una función positiva, basados en la utilización del polinomio de Taylor de una determinada función h en torno a la moda o el estimador de máxima verosimilitud del problema.

11.4.1. Métodos de Monte Carlo

Para el cálculo de las integrales involucradas en el teorema de Bayes existen numerosas técnicas numéricas de integración, muchas de ellas relacionadas con las técnicas de *Monte Carlo*, cuya versión más simple consiste en aproximar la esperanza de una variable mediante la expresión:

$$\int_a^b f(x)\pi(x)dx \approx \frac{1}{n} \sum_{i=1}^n f(x_i),$$

donde los puntos $x_1, \dots, x_n$ son elegidos independientemente de forma aleatoria de la densidad $\pi(x)$ sobre (a, b) ; cuyo caso más simple ocurre cuando π es la distribución uniforme.

Una extensión inmediata de esta versión es el denominado *muestreo de importancia*. Este método es utilizado cuando deseamos obtener la esperanza matemática

respecto a una densidad $q(x)$ pero resulta que no es fácil generar valores aleatorios de $q(\cdot)$ y sin embargo, sí es posible generar valores x_i de una densidad $\pi(x)$ "muy próxima" a $q(\cdot)$. En tal caso,

$$\int_a^b f(x)q(x)dx = \int_a^b f(x) \left(\frac{q(x)}{\pi(x)} \right) \pi(x)dx \approx \frac{1}{n} \sum_{i=1}^n \frac{f(x_i)q(x_i)}{\pi(x_i)}.$$

Aunque podríamos utilizar cualquier función de importancia q , este método tiene un comportamiento más adecuado cuando $q(\cdot)$ es próxima a la verosimilitud.

Otro método habitualmente utilizado es el de *rechazo*. Este método consiste en muestrear una distribución $g(\theta)$ (a veces denominada *función envolvente*) que verifique: $\pi(\theta)L(x|\theta) < cg(\theta)$, siendo $c > 0$ una constante. El algoritmo de rechazo que genera la muestra de tamaño n consiste en:

Algoritmo 11.1 (Método de rechazo)

1. $i = 1$,
2. Generar $\theta^{(i)}$ de la distribución $g(\cdot)$.
3. Generar $u \sim U(0, 1)$.
4. Si $c \cdot u \cdot g(\theta^{(i)}) < \pi(\theta^{(i)})L(x|\theta^{(i)})$ aceptar $\theta^{(i)}$, en caso contrario rechazar.
5. Continuar hasta completar la muestra.

Ejemplo 11.39 (Continuación ejemplo 11.38) Desarrollaremos ahora el ejemplo 11.38 de comparación de proporciones mediante simulación de los parámetros a posteriori.

Solución: Realizaremos este ejemplo con WinBUGS con objeto de introducir el procedimiento de simulación de este programa. Se recomienda una lectura del Apéndice B a partir de este momento ya que resultará de gran ayuda para la resolución de los ejemplos y ejercicios que aparecerán a partir de este momento. Podemos proceder de dos formas: o bien introducimos el código de acuerdo a las siguientes instrucciones:

```
model;
{
  X ~ dbin(phi.X,n.X)
  Y ~ dbin(phi.Y,n.Y)
  phi.Y ~ dbeta(alpha.Y,beta.Y)
  phi.X ~ dbeta(alpha.X,beta.X)
  Diferencia <- phi.X - phi.Y
  Ratio <- phi.X / phi.Y
}
```

11.4. Aspectos computacionales

```
}
```

```
#Datos
```

```
list(X=380, n.X=720, Y=120, n.Y=290)
```

```
#Parámetros a priori
```

```
list(alpha.X=1, beta.X=1, alpha.Y=1, beta.Y=1)
```

o bien procedemos mediante la introducción de los nodos definidos en el Doodle. Esta opción resulta más cómoda en la práctica. Para ello, primero introducimos la función de verosimilitud del problema (ver figura 11.26).




Figura 11.26: Definición en WinBUGS de la verosimilitud en el ejemplo 11.38

A continuación, la densidad a priori y los nodos lógicos del problema (por este orden) deben ser introducidos. Los nodos lógicos son aquellos que se construyen a partir de los parámetros, en este caso, $\frac{\phi_A}{\phi_B}$ y $\phi_A - \phi_B$ (figuras 11.27 y 11.28). El Doodle completo para este ejemplo aparece en la figura 11.29. Destacar (ver Apéndice B) que los datos y valores iniciales del problema deben incorporarse al modelo gráfico que representa el Doodle. Finalmente deberán generarse las cadenas "burn-in" y definitivas una vez que se haya compilado el modelo. Las densidades a posteriori obtenidas y sus medidas de interés pueden verse en las figuras 11.30 y 11.31, respectivamente. Como podemos observar para el caso de la diferencia de proporciones la estimación de la media a posteriori coincide con la obtenida mediante aproximación de una densidad normal en el ejemplo (11.38). El chequeo de convergencia del método puede verse en las figuras 11.32 y 11.33 que contienen




Figura 11.27: Definición en WinBUGS de las densidades a priori en el ejemplo 11.38




Figura 11.28: Definición en WinBUGS de los nodos lógicos en el ejemplo 11.38

la traza de los valores simulados y los gráficos de autocorrelación.




Figura 11.29: Doodle para el ejemplo 11.38




Figura 11.30: Densidades a posteriori para el ejemplo 11.38

11.4.2. Métodos de Monte Carlo y Cadenas de Markov (MCMC)

El objetivo de los métodos bayesianos computacionales puede resumirse en el cálculo de esperanzas matemáticas del tipo:

$$E[f(X)] = \frac{\int f(x)\pi(x)dx}{\int \pi(x)dx}.$$

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
Diferencia	0.1134	0.03418	1.575E-4	0.04603	0.1135	0.1797	40001	40000
Ratio	1.23	0.1003	4.639E-4	1.1	1.275	1.491	40001	40000
phiX	0.5277	0.01856	8.734E-5	0.4913	0.5277	0.5638	40001	40000
phiY	0.4143	0.02871	1.328E-4	0.3589	0.4141	0.4706	40001	40000

Figura 11.31: Estimaciones a posteriori para el ejemplo 11.38




Figura 11.32: Valores generados de la cadena para el ejemplo 11.38

El método Metropolis-Hastings obtiene el estado de la cadena en el instante $t+1$ muestreando un candidato Y de una distribución candidata $q(\cdot|X_t)$. Esta distribución candidata sólo depende del estado previo X_t y debe cumplir unas condiciones muy genéricas (Roberts, 1996). Un ejemplo muy utilizado para q es la distribución normal multivariante con media X_t y matriz de covarianza fija. Otras elecciones son posibles, pero una cuestión importante a tener en cuenta es que sea fácil de muestrear.

Las condiciones de regularidad impuestas a $q(\cdot|X_t)$ son irreducibilidad y aperiodicidad (Chib y Greenberg, 1995). Irreducibilidad significa que existe una probabilidad positiva de que la cadena alcance cualquier estado (o conjunto de estados)




Figura 11.33: Gráficos de autocorrelaciones para el ejemplo 11.38

partiendo de cualquier estado inicial. La aperiodicidad asegura que la cadena no oscila entre diferentes conjuntos de estados. El punto candidato Y es entonces aceptado como siguiente estado de la cadena con probabilidad

$$\alpha(X_t, Y) = \min \left\{ 1, \frac{\pi(Y)q(X_t|X)}{\pi(X_t)q(Y|X_t)} \right\}.$$

Si el punto Y no es aceptado, entonces la cadena permanece en $X_{t+1} = X_t$. En el caso del muestreo de una densidad a posteriori $\pi(\theta) \propto \pi(\theta)L(x|\theta)$ conocida la densidad condicional $q(\theta^*|\theta)$ que sea fácil de muestrear, el algoritmo Metropolis-Hastings consiste en:

Algoritmo 11.2 (Muestreo Metropolis-Hastings)

1. Asignar un valor inicial $\theta^{(0)}$,
2. $t = 0$,
3. generar $\theta \sim q(\theta|\theta^{(t)})$,
4. definir

$$\alpha(\theta^{(t)}, \theta) = \min \left\{ 1, \frac{L(x|\theta)q(\theta^{(t)}|\theta)}{L(x|\theta^{(t)})q(\theta|\theta)} \right\},$$
5. hacer $\theta^{(t+1)} = \theta$ con probabilidad α ó $\theta^{(t+1)} = \theta^{(t)}$ en caso contrario,
6. $t = t + 1$, e ir al paso 3.

Se demuestra entonces que este algoritmo converge a la distribución estacionaria $\pi(\theta|x)$. Algunos comentarios:

1. Observemos que la distribución de interés aparece en un cociente con lo que la constante de proporcionalidad se cancela.
2. No necesita del conocimiento de las distribuciones condicionadas.
3. En el caso particular en que q sea simétrica en el sentido: $q(X|Y) = q(Y|X)$, entonces tendremos el método original propuesto en Metropolis *et al.* (1953):

$$\alpha(X_t, Y) = \min \left\{ 1, \frac{\pi(Y)}{\pi(X_t)} \right\}.$$

Habitualmente para asegurar la convergencia de una cadena podemos utilizar los diagnósticos formales de convergencia (Cowles y Carlin, 1996), aunque en la práctica la comparación de resultados con distintos valores iniciales acompañados de gráficos para los valores generados y sus medias estimadas, suelen ser un buen test inicial para asegurar la convergencia.

De hecho, la primera parte de la cadena suele contener parte de correlación entre los datos generados, estos datos denominados *burn-in* se desechan y se utiliza el resto de los datos para hacer la inferencia. Supongamos por ejemplo, que deseamos estimar la media a posteriori de θ . Rechazando los valores de la muestra *burn-in* de tamaño m obtendríamos la estimación,

$$E(\theta|x) \approx \frac{1}{n-m} \sum_{t=m+1}^n \theta^{(t)},$$

siendo n el número total de iteraciones. Habitualmente suele utilizarse como valor inicial de la cadena un valor próximo a la moda a posteriori, pues la convergencia suele ser más rápida.

Finalmente, uno de los procedimientos MCMC más utilizados en la práctica habitual es el muestreo de Gibbs. Este procedimiento suele utilizarse en muchas situaciones prácticas donde no se conoce la distribución a posteriori conjunta pero sí es posible muestrear todas las distribuciones condicionadas. De hecho el muestreo de Gibbs puede considerarse como una versión multivariante del *algoritmo de aumento de datos*. Este algoritmo se basa en las siguientes identidades:

$$\pi(\theta|x) = \int_{\mathcal{Z}} \pi(\theta|x, z) L(z|x) dz, \quad f(z|x) = \int_{\Theta} L(z|\theta, x) \pi(\theta|x) d\theta,$$

donde $\pi(\theta|x)$ denota la densidad a posteriori de θ dado x , $f(z|x)$ es la distribución predictiva de una futura observación z dado x y $\pi(\theta|x, z)$ es la densidad condicionada de θ dada los datos aumentados $D = (x, z)$. Si consideramos la ecuación integral

$$g(\theta) = \int_{\Theta} K(\theta, \phi) g(\phi) d\phi, \quad (11.30)$$

con $K(\theta, \phi) = \int_{\mathcal{Z}} \pi(\theta|D) f(z|\phi, x) dz$, resulta que $\pi(\theta|x)$ satisface dicha ecuación y por tanto dado un valor inicial $g_0(\theta)$ podremos encontrar una solución de la ecuación (11.30) mediante el algoritmo iterativo $g_{i+1}(\theta) = (Tg_i)(\theta)$, siendo T el funcional $Ts(\theta) = \int_{\Theta} K(\theta, \phi) s(\phi) d\phi$.

El *muestreo de Gibbs* funciona ahora como un algoritmo de aumento de datos para la siguiente situación. Sea $\theta = (\theta_1, \dots, \theta_k)$ y designemos por θ_{-i} al vector θ salvo su componente i -ésima, esto es $\theta_{-i} = (\theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_k)$ $i = 1, \dots, k$, y estamos interesados en muestrear la distribución a posteriori conjunta $\pi(\theta|x)$. Supongamos que dado x podemos muestrear la distribuciones condicionadas $\pi(\cdot|\theta_{-i}, x)$, entonces el algoritmo de muestreo de Gibbs es el siguiente:

Algoritmo 11.3 (Muestreo de Gibbs)

1. Dar valores iniciales $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_k^{(0)})$.
2. $t = 0$,
3. generar $\theta_1^{(t+1)} \sim \pi(\theta_1|\theta_2^{(t)}, \dots, \theta_k^{(t)}, x)$,
4. generar $\theta_2^{(t+1)} \sim \pi(\theta_2|\theta_1^{(t+1)}, \theta_3^{(t)}, \dots, \theta_k^{(t)}, x)$,
- $\vdots$
5. generar $\theta_k^{(t+1)} \sim \pi(\theta_k|\theta_1^{(t+1)}, \dots, \theta_{k-1}^{(t+1)}, x)$,
6. $t = t + 1$.
7. ir a 3.

Este algoritmo converge a una tasa geométrica en n , siendo n el tamaño de la muestra Gibbs. La literatura existente sobre procedimientos MCMC es muy extensa (Tanner, 1993; Robert y Casella, 1999; Gamerman, 1997; Congdon, 2001; Gelman et al., 2003; entre otros) y el desarrollo que hoy día han tenido los métodos bayesianos son debidos en gran parte al desarrollo de las técnicas MCMC que han hecho posible soslayar el cálculo de la densidad a posteriori "independientemente" de la a priori y verosimilitud consideradas. Al mismo tiempo, la expansión que ha tenido el uso del software WinBUGS ha facilitado que hoy día las aplicaciones del análisis bayesiano estén expandidas en todas las disciplinas científicas, en general, y por supuesto en la estadística actuarial (Scolnik, 1996, 2001). En ocasiones el procedimiento de aumento de datos también puede ocurrir de forma natural introduciendo un nuevo parámetro en el modelo que haga más sencilla la simulación de la a posteriori del "parámetro aumentado" (Tanner y Wong, 1987). En el siguiente ejemplo para cuantía de pérdidas podemos ver de manera expresa este comentario.

Ejemplo 11.40 (Aumento de datos: cantidad reclamada) Deseamos estimar la cantidad reclamada media de una cartera en un año. Las cantidades observadas fueron: 11, 13, 8, 9, 21, 17, 19, 20, 15,5 y 16,8 euros. Suponemos que $x_1, \dots, x_n \sim t_{\alpha_0}(\mu, \sigma^2)$ con $\mu \sim \mathcal{N}(a, b)$ y $h = \frac{1}{\sigma^2} \sim \mathcal{G}(n_0/2, s_0/2)$, tomando como valores iniciales $a = 0$, $b = 0,0001$ y $n_0 = s_0 = 0,001$.

Solución: Se trata de dos parámetros $\theta = (\mu, \sigma^2)$ cuya densidad a posteriori no podemos muestrear. Sin embargo basta con reparametrizar esta distribución como una mezcla de distribuciones normales para conseguir muestrear las condicionadas. En efecto, consideremos $x_i \sim \mathcal{N}(\mu, (\lambda_i h)^{-1})$, donde $h = \frac{1}{\sigma^2}$ es la precisión, y $\lambda_i \sim \mathcal{G}(\alpha_0/2, \alpha_0/2)$, i.i.d ($i = 1, \dots, n$). Con esta reparametrización, se tiene que $f(x_i | \mu, h) \sim t_{\alpha_0}(\mu, h)$, $i = 1, \dots, n$. Y en consecuencia, $\theta = (\mu, \sigma^2) \equiv (\mu, h)$ queda ampliado a $(\theta, \lambda) = (\mu, h, \lambda_1, \dots, \lambda_n)$ con $L(x | \mu, h)$ y $\pi(\mu, h | x)$ las mismas del problema original pero cuyas condicionadas son ahora, $\pi(\mu | h, \lambda, x)$ que es una normal, $\pi(h | \mu, \lambda, x)$ que es gamma y $\pi(\lambda | \mu, h, x)$ que es producto de gammas y por tanto las tres densidades condicionadas son inmediatas de muestrear y podemos aplicar el muestreo Gibbs sin dificultad. La resolución de este modelo con WinBUGS es también inmediata con las consideraciones anteriores. En la figuras 11.34 y 11.35 puede verse la introducción de la función de verosimilitud y de las densidades a priori.

El código WinBUGS es el siguiente:

```
model; {
  for( i in 1 : n ) {
    x[i] ~ dnorm(mu, prec[i])
    prec[i] <- lambda[i] * h
    lambda[i] ~ dgamma(alpha, beta)
  }

  h ~ dgamma(n0, s0)
  mu ~ dnorm(a, b)
}

#Datos

list(x=c(11,13,8,9,21,17,19,20,15.5,16.8), n=10)

#Parámetros a priori

list(a=0, b=0.0001, alpha=0.001, beta=0.001, n0=0.001, s0=0.001)

#Valores iniciales
```




Figura 11.34: Verosimilitud en el ejemplo 11.40

```
list(mu=10, h=1, lambda=c(1,1,1,1,1,1,1,1,1,1))
```

y su correspondiente Doodle pueden verse en las figura 11.36. Los valores utilizados en las densidades a priori del parámetro aumentado son $\alpha = \beta = 0,001$.

Para el caso que nos ocupa de estimación de la cuantía media de una reclamación de la cartera, vemos que la estimación bayesiana (media a posteriori) es $\hat{\mu} = 16,83$. Un intervalo bayesiano de credibilidad al 95 % es (14,41; 19,4). Observamos que este intervalo se configura utilizando el cuantil 2,5 % y el 97,25 % (ver figura 11.37).

◇

11.4.3. Un modelo jerárquico para datos de frecuencia de reclamaciones con WinBUGS

De manera análoga a Scollnik (2000), y con fines ilustrativos de las posibilidades que los métodos MCMC tienen en la práctica actuarial, supongamos el caso de una




Figura 11.35: Densidades a priori en el ejemplo 11.40

compañía aseguradora que tiene una póliza de compensación con una empresa con I grupos diferenciados de trabajadores de los que conoce el número de reclamaciones de cada grupo i en una historia temporal $t = 1, \dots, T$ y también la cantidad de trabajadores en nómina de cada grupo en cada instante. El problema consiste en anticipar el número de reclamaciones en el siguiente año.

Observemos que en general, podemos plantear el problema mediante la modelización siguiente. Sea X_{it} el número de reclamaciones en el grupo $i = 1, \dots, I$ y año t y P_{it} el tamaño del grupo i en el año t , $t = 1, \dots, T$. Como en Scollnik (2000) suponemos que todas las X_{it} son condicionalmente independientes y que

$$X_{it} \sim \mathcal{P}(P_{it}\theta_i), \quad i = 1, \dots, I; t = 1, \dots, T.$$

Los parámetros θ_i denotan el porcentaje de reclamación de cada asegurado dentro de su grupo i . Dados α y β suponemos que las θ_i ($i = 1, \dots, I$) son condicionalmente independientes con

$$\theta_i | \alpha, \beta \sim \mathcal{G}(\alpha, 1/\beta), \quad i = 1, \dots, n.$$




Figura 11.36: Doodle en el ejemplo 11.40

El modelo de distribuciones se corresponde con el siguiente modelo jerárquico:

$$\begin{aligned} \lambda_{it} &= P_{it}\theta_i, \\ X_{it} &\sim \mathcal{P}(\lambda_{it}), \\ \theta_i &\sim \mathcal{G}(\alpha, 1/\beta), \\ \alpha &\sim \mathcal{G}(a_\alpha, 1/b_\alpha), \\ \beta &\sim \mathcal{G}(a_\beta, 1/b_\beta), \\ P_{it} &\sim \mathcal{G}(a_i, 1/b_i), \\ a_i &\sim \mathcal{U}(0, M_a), \\ b_i &\sim \mathcal{U}(0, M_b). \end{aligned}$$

Este modelo permite además incluir la incertidumbre sobre α y β al conside-

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
alpha[1]	181.5	401.1	8.394	0.02296	75.15	1542.0	100001	100000
alpha[2]	1.109	25.34	0.2914	3.2E-7	4.594E-4	1.233	100001	100000
alpha[3]	2.536	44.42	0.2465	3.722E-7	0.001057	4.127	100001	100000
alpha[4]	1.1351	4.432	0.02742	1.625E-7	1.954E-4	0.432	100001	100000
alpha[5]	0.27	10.77	0.07368	1.905E-7	2.533E-4	0.5619	100001	100000
alpha[6]	1.059	27.09	0.1767	7.258E-7	2.282E-4	2.408	100001	100000
alpha[7]	71.93	255.7	1.721	7.558E-5	0.8057	731.2	100001	100000
alpha[8]	5.571	14.24	0.5704	2.843E-6	3.003364	24.09	100001	100000
alpha[9]	4.25	59.53	0.453	1.281E-6	0.001707	3.171	100001	100000
alpha[10]	13.26	110.0	0.2445	6.209E-6	0.002155	27.71	100001	100000
beta[1]	77.68	263.7	1.325	3.482E-5	0.9383	759.6	100001	100000
beta[2]	16.83	1.668	0.02002	1.441	16.66	19.4	100001	100000
beta[3]	82.05	7497.0	49.26	2.746E-5	3.0156	3.1875	100001	100000
beta[4]	254.1	39710.0	156.9	8.832E-5	3.03123	0.5629	100001	100000
beta[5]	0.62329	1.177	0.007505	1.267E-5	3.005803	0.67116	100001	100000
beta[6]	3.717	5847	2.59	1.538E-5	0.007493	3.69337	100001	100000
beta[7]	3.375	230.7	1.398	5.800E-5	0.02701	3.4462	100001	100000
beta[8]	7550.0	25880.0	524.2	0.003477	11.51	43552.0	100001	100000
beta[9]	450.5	17270.6	109.1	2.084E-4	0.00787	3.954	100001	100000
beta[10]	259.5	12250.0	35.78	9.63E-5	0.04737	1.74	100001	100000
beta[11]	910.9	23970.0	147.6	4.817E-4	0.2361	323.7	100001	100000
beta[12]	7650.0	30430.0	494.5	0.003957	12.91	48690.0	100001	100000

Figura 11.37: Medidas a posteriori de los parámetros en el ejemplo 11.40

rarlas también aleatorias. Si ahora denotamos por $X_i = (X_{i1}, \dots, X_{iT})$, $X = (X_1, \dots, X_I)$ y $\theta = (\theta_1, \dots, \theta_I)$, tendremos que de acuerdo al modelo adoptado, la distribución conjunta será

$$f(X, \theta, \alpha, \beta) \propto \left[\prod_{i=1}^I \prod_{t=1}^T f(X_{it} | P_{it} \theta_i) \right] \prod_{i=1}^I \pi(\theta_i | \alpha, \beta) \pi(\alpha) \pi(\beta). \quad (11.31)$$

Una vez observados los datos, la distribución a posteriori será difícil de obtener, sin embargo las distribuciones a posteriori condicionadas resultan fáciles de muestrear dejando así paso al muestreo Gibbs puesto que,

$$\begin{aligned} \pi(\theta_i | X, \theta_{-i}, \alpha, \beta) &\propto \prod_{t=1}^T f(X_{it} | P_{it} \theta_i) \pi(\theta_i | \alpha, \beta) \\ &\propto \theta_i^{\alpha + \sum_{t=1}^T X_{it} - 1} \exp(-(\beta + \sum_{t=1}^T P_{it}) \theta_i) \end{aligned}$$

que es una variable aleatoria $\mathcal{G}(\alpha + \sum_{t=1}^T X_{it}, 1/(\beta + \sum_{t=1}^T P_{it}))$. Por otro lado,

$$\pi(\alpha | X, \theta, \beta) \propto \prod_{i=1}^I \pi(\theta_i | \alpha, \beta) \pi(\alpha) \propto \left(\frac{\beta^\alpha}{\Gamma(\alpha)} \right) \left(\prod_{i=1}^I \theta_i \right)^\alpha \alpha^T \exp(-(T+1)\alpha),$$

y esta distribución es fácil de muestrear pues aún no siendo una densidad estándar, es cóncava en α y el método de rechazo funciona bien en estos casos (Gilks y Wild,

Tabla 11.7: Datos para la frecuencia de reclamaciones en el ejemplo 11.41

Año (t)	Grupo i = 1		Grupo i = 2		Grupo i = 3	
	P _{1t}	X _{1t}	P _{2t}	X _{2t}	P _{3t}	X _{3t}
1	280	9	260	6	—	—
2	320	7	275	4	145	8
3	265	6	240	2	120	3
4	340	13	265	8	105	4
5	—	—	285	—	115	—

1992). Finalmente,

$$\begin{aligned} \pi(\beta | X, \theta, \alpha) &\propto \prod_{i=1}^I \pi(\theta_i | \alpha, \beta) \pi(\beta) \\ &\propto \beta^{I(\alpha+T)} \exp(-(\sum_{i=1}^I \theta_i + 1)\beta). \end{aligned}$$

que es una variable aleatoria $\mathcal{G}(I(\alpha+T)+1, 1/(\sum_{i=1}^I \theta_i + 1))$. Una vez generada la muestra MCMC las cantidades a posteriori se calculan mediante

$$\pi(\theta_i | X) = \int_{\alpha} \int_{\beta} \pi(\theta_i | X, \alpha, \beta) \pi(\alpha, \beta | X) d\beta d\alpha, \quad i = 1, \dots, I. \quad (11.32)$$

Además la distribución predictiva de X_{iT+1} podrá estimarse mediante:

$$\begin{aligned} f(X_{iT+1} | X) &= \int_{\theta_i} f(X_{iT+1} | P_{iT+1} \theta_i) \pi(\theta_i | X) d\theta_i \\ &\approx \frac{1}{n-m} \sum_{j=m+1}^n f(X_{iT+1} | P_{iT+1} \theta_i^{(j)}), \quad i = 1, \dots, I, \end{aligned} \quad (11.33)$$

donde m es el tamaño de la muestra "burn-in" y n de la muestra total MCMC, y donde X_{iT+1} es condicionalmente independiente de X dado θ_i y $f(X_{iT+1} | P_{iT+1} \theta_i) \sim \mathcal{P}(P_{iT+1} \theta_i)$.

Ejemplo 11.41 Describir la frecuencia de reclamaciones para el quinto año en la tabla 11.7.

Solución: Una de las ventajas del análisis bayesiano es que permite tratar algunos de los datos faltantes como nodos estocásticos que podremos estimar. Tan sólo

debemos tener en cuenta que en las expresiones (11.33) y (11.32) no incluiremos estos términos. Es decir,

$$\begin{aligned}\pi(\theta_1|X, \theta_2, \theta_3, \alpha, \beta) &\sim \mathcal{G}\left(\alpha + \sum_{t=1}^4 X_{1t}, 1/(\beta + \sum_{t=1}^4 P_{1t})\right), \\ \pi(\theta_2|X, \theta_1, \theta_3, \alpha, \beta) &\sim \mathcal{G}\left(\alpha + \sum_{t=1}^4 X_{2t}, 1/(\beta + \sum_{t=1}^5 P_{2t})\right), \\ \pi(\theta_3|X, \theta_1, \theta_2, \alpha, \beta) &\sim \mathcal{G}\left(\alpha + \sum_{t=2}^4 X_{3t}, 1/(\beta + \sum_{t=2}^5 P_{3t})\right).\end{aligned}$$

Para el ejemplo que nos ocupa utilizaremos los valores a priori $a_\alpha = 5 = b_\alpha$, $a_\beta = 25$, $b_\beta = 1$. Obviamente otras asignaciones para los parámetros son posibles pero suponemos que el actuario quiere tener valores para la media a priori de los θ_i próximos al 4%, como es el caso con esta asignación. Elegimos $M_a = M_b = 100$. El código WinBUGS para este modelo es el siguiente:

```
model; {
  for( i in 1 : 3 ) {
    for( j in 1 : 5 ) {
      X[i , j] ~ dpois(lambda[i , j])
      lambda[i , j] <- p[i , j] * theta[i]
      p[i , j] ~ dgamma(a[i],b[i])
    }

    theta[i] ~ dgamma(alpha,beta)
    a[i] ~ dunif(min.a,max.a)
    b[i] ~ dunif(min.b,max.b)
  }

  alpha ~ dgamma(a.alpha,b.alpha)
  beta ~ dgamma(a.beta,b.beta)
}

#Datos

list(X=structure(.Data=c(9,7,8,13,NA,6,4,2,8,NA,NA,8,3,4,NA),
  .Dim=c(3,5)), p=structure(.Data=c(280,320,265,340,NA,
  260,275,240,265,285,NA,145,120,105,115), .Dim=c(3,5)))

#Parámetros a priori
list(a.alpha=5, b.alpha=5, a.beta=25, b.beta=1, min.a=0, max.a=100, min.b=0, max.b=100)
```

```
list(a.alpha=5, b.alpha=5, a.beta=25, b.beta=1, min.a=0,
max.a=100, min.b=0, max.b=100)
```

De forma equivalente, su Doodle asociado puede verse en la figura 11.38. En la figura 11.39 aparecen los resultados obtenidos para este modelo en una cadena de $n = 140000$ después de un burn-in de $m = 40000$.




Figura 11.38: Doodle para el modelo del ejemplo 11.41

Las estimaciones de θ_i en cada uno de los grupos $i = 1, 2, 3$ son: 0,0309; 0,0197 y 0,0406 respectivamente, cantidades distintas de las estimadas mediante el enfoque clásico de Bühlmann-Straub (Herzog, 1996) cuyos valores serían: 0,0284; 0,0214

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
X[1,5]	9.361	3.743	0.009961	3.0	9.0	19.0	10001	140000
X[2,5]	5.627	2.966	0.009963	1.0	5.0	12.0	10001	140000
X[3,1]	4.538	2.703	0.007452	1.0	5.0	11.0	10001	140000
X[3,5]	4.698	2.456	0.008755	1.0	4.0	10.0	10001	140000
alpha	91.38	23.44	0.9712	15.22	83.03	97.99	10001	140000
beta	72.15	19.97	0.4457	27.85	75.66	98.93	10001	140000
lambda	57.47	23.72	0.6037	13.67	57.73	97.31	10001	140000
alpha	1.071	0.346	0.0266	0.4937	1.037	1.84	10001	140000
beta	0.2029	0.07694	0.01919	0.04659	0.2087	0.3319	10001	140000
lambda	0.2722	0.07668	0.01702	0.1039	0.2847	0.5333	10001	140000
alpha	0.474	0.158	0.05025	0.1109	0.4748	0.8152	10001	140000
beta	25.85	4.971	0.01357	17.03	25.52	28.48	10001	140000
lambda	6.659	1.405	0.003699	6.129	6.579	11.62	10001	140000
alpha	0.855	1.099	0.04223	0.004	0.805	13.28	10001	140000
beta	3.194	1.33	0.03561	0.801	3.119	11.0	10001	140000
lambda	16.51	1.707	0.00482	7.442	16.42	14.11	10001	140000
alpha	0.352	2.178	0.005894	0.710	0.152	14.2	10001	140000
beta	5.14	1.121	0.002641	3.185	5.659	7.564	10001	140000
lambda	5.437	1.158	0.003095	3.368	5.351	8.0	10001	140000
alpha	4.715	1.055	0.002823	2.94	4.67	6.982	10001	140000
beta	5.239	1.143	0.002896	3.246	5.159	7.709	10001	140000
lambda	5.535	1.223	0.003115	3.451	5.545	8.291	10001	140000
alpha	4.95	1.526	0.004493	2.513	4.795	8.418	10001	140000
beta	5.885	1.478	0.004103	3.354	5.758	9.11	10001	140000
lambda	4.871	1.222	0.003395	2.776	4.772	7.539	10001	140000
alpha	4.293	1.089	0.002971	2.429	4.175	6.597	10001	140000
beta	4.688	1.171	0.003254	2.66	4.573	7.225	10001	140000
lambda	202.6	49.83	0.1441	125.7	298.7	409.1	10001	140000
alpha	121.9	21.24	0.06253	84.43	125.7	167.1	10001	140000
beta	0.03092	0.00592	1.321E-5	0.02189	0.03064	0.0415	10001	140000
lambda	0.01977	0.004312	1.023E-5	0.01225	0.01946	0.02999	10001	140000
alpha	0.0406	0.01010	2.529E-5	0.02313	0.03976	0.06293	10001	140000

Figura 11.39: Resultados de la estimación para el modelo del ejemplo 11.41

y 0,0331; respectivamente. Adicionalmente, los intervalos bayesianos de credibilidad para θ_i , ($i = 1, 2, 3$) al 95 % son: (0,02189; 0,0415), (0,01225; 0,02909) y (0,02313; 0,06283), respectivamente. Las estimaciones de las cantidades $X_{1,5}$, $X_{2,5}$, $X_{3,1}$, $X_{3,5}$ puede hacerse por su medianas cuyos valores son: 9, 5, 5 y 4, respectivamente. Análogamente, para $P_{1,5}$ y $P_{3,1}$ podemos estimarlos por 300 y 121, respectivamente.

◇

11.4.4. Un modelo para la distribución predictiva para cantidades reclamadas con datos de reaseguros con WinBUGS

Uno de los modelos habituales en la práctica actuarial consiste en la predicción de la cantidad total reclamada en una próxima anualidad,

$$S_t = Y_{t,1} + \dots + Y_{t,N_t},$$

donde S_t representa la cantidad reclamada en el periodo t , N_t denota el número de reclamaciones en dicho periodo e $Y_{t,1}, \dots, Y_{t,N_t}$ las cantidades individuales reclamadas. Suponemos que $S_t = 0$ cuando $N_t = 0$, y que las frecuencias y cantidades son variables independientes y que las $Y_{t,i}$ son independientes e idénticamente distribuidas. Este modelo se estudiará en detalle en el capítulo 13.

11.4. Aspectos computacionales

Un ejemplo de esta situación es el caso de datos de reaseguros (Rytgaard, 1990), donde el reasegurador tiene información sobre todas las pérdidas individuales que exceden de una cantidad determinada c a lo largo de un periodo de T años. Rytgaard (1990) ajustó un modelo compuesto de Poisson con muestreo de Pareto I, $PaI(a, b)$, para la componente que mide la cantidad individual de las pérdidas,

$$f(y|a, b) = \frac{ab^a}{y^{a+1}}, \quad y \geq b > c,$$

con $a > 0$, $c \geq 0$. Desde la perspectiva bayesiana, los parámetros a y b pueden considerarse aleatorios y se debe asignar una densidad a priori. Como en Scollnik (2000) suponemos que b es aleatorio de tal manera que podrá ser estimado, lo que permitirá interpretar a c como una cota inferior. El modelo propuesto es (Scollnik, 2000):

$$\begin{aligned} Y_{t,i} &\sim PaI(a, b), \quad t = 1, \dots, T; \quad i = 1, \dots, N_t, \\ N_t &\sim P(\lambda), \quad t = 1, \dots, T, \\ a &\sim G(\alpha_a, 1/\beta_a), \\ b &\sim G(\alpha_b, 1/\beta_b), \\ \lambda &\sim G(\alpha_\lambda, 1/\beta_\lambda), \end{aligned}$$

con la restricción $\min\{Y_{t,i}\} \geq b > c$, donde los parámetros $\alpha_a, \beta_a, \alpha_b, \beta_b, \alpha_\lambda, \beta_\lambda$ serán asignados a priori (habitualmente se toman valores pequeños para hacer no informativas las densidades a priori).

Obtenida la muestra MCMC, generar N_{T+1} , el número futuro de reclamaciones en el año $T+1$ e Y_{T+1} , la pérdida individual futura en dicho año puede hacerse considerando

$$\begin{aligned} \Pr(N_{T+1} = k | N_1, \dots, N_T) &= \int_0^\infty \Pr(N_{T+1} = k | \lambda) \pi(\lambda | N_1, \dots, N_T) d\lambda \\ &\approx \frac{1}{n-m} \sum_{j=m+1}^n \exp(-\lambda^{(j)}) \frac{(\lambda^{(j)})^k}{k!}, \end{aligned}$$

de manera análoga se generaría Y_{T+1} . Para la distribución de la cantidad total reclamada $S_{T+1} = Y_{T+1,1} + \dots + Y_{T+1,N_{T+1}}$, tendremos

$$f(S_{T+1} | \underline{X}) = \int_0^\infty \int_0^\infty \int_c^{\min(Y_{T,i})} f(S_{T+1} | \lambda, a, b) \pi(\lambda, a, b | \underline{X}) d\lambda da db.$$

Puesto que $Y_{T+1,i} \sim PaI(a, b)$ ($i = 1, \dots, N_{T+1}$) y $N_{T+1} \sim P(\lambda)$ tendremos un método de muestreo para S_{T+1} sin más que tener en cuenta que para cada valor de la muestra MCMC, $(\lambda^{(j)}, a^{(j)}, b^{(j)})$ podemos proceder:

Algoritmo 11.4

1. Muestrear $N_{T+1} \sim \mathcal{P}(\lambda^{(j)})$,
2. Si $N_{T+1} = 0$, entonces $S_{T+1} = 0$.
3. Si $N_{T+1} > 0$, entonces muestrear $Y_{T+1,i} \sim \text{Poi}(a^{(j)}, b^{(j)})$, $i = 1, \dots, N_{T+1}$, y hacer $S_{T+1} = Y_{T+1,1} + \dots + Y_{T+1,N_{T+1}}$.

Ejemplo 11.42 Los datos en la tabla 11.8 indican las pérdidas individuales en 5 años para un reaseguro con cota inferior $c = 1.5$. Se trata de ajustar un modelo como el dado anteriormente, para el caso no informativo $\alpha_a = \alpha_b = \alpha_\lambda = \beta_a = \beta_b = \beta_\lambda = 0.001$.

Tabla 11.8: Reclamaciones excediendo de $c = 1.5$ millones u.m. durante un periodo de 5 años (Rytgaard, 1990)

Año					
1	2	3	4	5	
2,495	1,985	3,215	—	19,180	
2,120	1,810	2,105	—	1,915	
2,095	1,625	1,765	—	1,790	
1,700	—	1,715	—	1,755	
1,650	—	—	—	—	

Solución: El código WinBUGS para este problema, contiene también la distribución predictiva de la cantidad total:

```
model; {
  for (t in 1:T){
    for(i in 1:N[t]){
      Y[t,i]~dpar(a,b);
    }
    N[t]~dpois(lambda); }

  N6~dpois(lambda)

  for(j in 1:100){ Y6[j]~dpar(a,b); Ind[j]<-step(N6-j+0.1);
    V[j]<-Y6[j]*Ind[j]; }
```

11.4. Aspectos computacionales

```
S6<-sum(V[])

a~dgamma(alpha.a,beta.a); b~dgamma(alpha.b,beta.b)I(b.min,b.max);
lambda~dgamma(alpha.l,beta.l);

} list(T=5, alpha.a=0.001, beta.a=0.001, alpha.b=0.001,
beta.b=0.001, alpha.l=0.001, beta.l=0.001,b.min=1.5,b.max=1.625)
list(N=c(5,3,4,0,4))

Y[,1]  Y[,2]  Y[,3]  Y[,4]  Y[,5]

2.495  2.12   2.095  1.7  1.65

1.985  1.81   1.625  NA  NA

3.215  2.105  1.765  1.715 NA

NA NA NA  NA  NA

19.18  1.915  1.79  1.755  NA
END
```

Los resultados obtenidos de la estimación con un muestra MCMC de tamaño $n = 60000$ con burn-in de $m = 10000$, pueden verse en la figura 11.40

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
N6	3.212	1.98	0.008908	0.0	3.0	4.0	10001	50000
S6	8.462	22.24	0.1014	0.0	7.072	23.26	10001	50000
a	2.501	0.7454	0.003592	1.84	2.625	4.553	10001	50000
b	1.593	0.02327	2.084E-4	1.519	1.602	1.624	10001	50000
lambda	1.201	0.0066	0.003547	1.024	1.127	1.248	10001	50000

Figura 11.40: Resultados de la estimación para el modelo del ejemplo 11.42

Estimamos que la media del número de reclamaciones que exceden de $c = 1.5$ es aproximadamente 3, con un intervalo bayesiano de credibilidad al 95 % de (1,824; 4,948). Veamos también que el número de reclamaciones para la siguiente anualidad en $\hat{N}_6 = 3$ (su mediana) con un intervalo bayesiano al 95 % dada por (0,8). Del mismo modo, la predicción para la cantidad reclamada en la siguiente anualidad tiene un intervalo bayesiano al 95 % de (0,0; 23,26) con media 8,462 y mediana 7,072.

11.5. Problemas propuestos

1. El servicio de auditoría interna de una compañía aseguradora desea estudiar el grado de cumplimiento de determinadas pruebas en cuanto a varios procesos de control interno de la misma. Las tasas de fallo del control consideradas "normales" son aquellas inferiores al 3% pero se tiene la impresión de que no se están llevando bien los procesos de control. La siguiente tabla proporciona la información histórica que posee la empresa del año anterior correspondiente a las tasas de fallo.

Tasa de fallo	Prob. a priori
0,001	0,05
0,01	0,10
0,015	0,16
0,02	0,30
0,025	0,15
0,03	0,10
0,04	0,01
0,05	0,01
0,06	0,02
0,07	0,02

Supongamos que se observan $n = 10$ pólizas de las que $y = 2$ contienen un error interno. Se pide:

- a) Estudiar la posibilidad de que el proceso de control interno esté "fuera de control", o equivalentemente, la probabilidad de que la tasa de fallo sea mayor del 3%. Realizar el mismo estudio si hubiésemos observado $y = 0$ errores. Comentar.
 - b) Estudiar la influencia de la información a priori en la situación anterior. Para ello, realizar el mismo estudio del apartado anterior pero con una a priori no informativa, es decir, cuando todas las tasas de fallo tienen la misma probabilidad a priori de ocurrir (en este caso, $1/8 = 0,125$).
 - c) Realizar el análisis anterior pero con una densidad continua para la tasa de fallo que tenga la misma media y moda que en el apartado anterior.
2. Desea estudiarse si hay diferencias en el efecto de una campaña de publicidad realizada de dos formas distintas (mediante envío de mensajes SMS o por llamadas telefónicas) para una nueva póliza de seguro de automóvil para una población menor de 35 años. Para el caso de los mensajes SMS se realizaron 1000 envíos de los que 550 resultaron afirmativos. Para el caso de las llamadas

11.5. Problemas propuestos

telefónicas se realizaron menos entrevistas debido a que se tenía información inicial sobre su impacto: las llamadas realizadas fueron 200 de las que 101 resultaron afirmativas. Se pide:

- a) Estudiar las diferencias de éxito entre ambos procedimientos, para un caso no informativo para la tasa de éxito en el envío de mensajes SMS y una a priori $Be(20, 20)$ para el procedimiento telefónico.
 - b) Idem al anterior pero con una a priori para el caso de envío de mensajes SMS en la que la media vale 0,5 y se sabe que la probabilidad de éxito no es nunca menor del 15%. Para el caso telefónico, la misma densidad a priori anterior.
3. Una compañía aseguradora promociona sus productos en dos áreas de una gran ciudad utilizando una serie de anuncios televisivos. La respuesta a tal campaña se realiza en 10 tiendas de cada área recogiendo los porcentajes de incremento en las ventas después de la campaña (los datos se presentan en la siguiente tabla):

Area 1:	38	39	37	33	19	28	60	38	29	37
Area 2:	14	19	52	23	16	20	17	38	2	21

Utilizando la distribución asintótica de la densidad a posteriori, se pide:

- a) Suponiendo que las muestras son normales e independientes con varianza común, comparar el éxito de la campaña en las dos áreas.
 - b) Obtener un HDI al 90% para σ_2 (la variabilidad de la respuesta entre las tiendas).
 - c) Calcular las probabilidades de que σ_2 sea menor que el extremo inferior del HDI anterior y de que sea superior al extremo superior. Calcular un intervalo simétrico al 90%.
4. Las compañías aseguradoras dedican una gran cantidad de fondos en la previsión de éstos para futuras reclamaciones. En tal proceso, los fallos en la calibración de los accidentes que realizan los técnicos puede suponer importantes pérdidas. Supongamos que una de las principales preocupaciones de estas compañías fuese el número de fallos que se encuentran en las distintas reclamaciones. La proporción de fallos, ϕ , puede ser debida a diversos factores y cada fallo detectado puede causar graves perjuicios a la compañía. Se consideran los siguientes modelos:

- **Modelo 1.** Seleccionadas n reclamaciones al azar se comprueba si existe o no error en su certificación técnica con lo cual el número de errores R detectados tiene una verosimilitud Binomial de parámetros n y ϕ :

$$f_1(r|\phi) = \binom{n}{r} \phi^r (1-\phi)^{n-r}, \quad r = 0, 1, \dots, n$$

- Modelo 2. Utilizar la aproximación del modelo 1 mediante una verosimilitud de Poisson de parámetro $n \cdot \phi$, esto es:

$$f_2(r|\phi) = \frac{e^{-n\phi}(n\phi)^r}{r!}, \quad r = 0, 1, \dots$$

- Modelo 3. Supongamos ahora que el proceso de muestreo consiste en revisar las reclamaciones hasta obtener exactamente r de ellas con fallos en sus certificaciones. Es decir un verosimilitud Binomial Negativa:

$$f_3(n|\phi) = \binom{n-1}{r-1} \phi^r (1-\phi)^{n-r}, \quad n = r, r+1, \dots$$

- Encontrar distribuciones a priori conjugadas para cada uno de los modelos.
- Supongamos que la compañía supone que lo más habitual es que no haya errores y que por término medio el error es del 5%. Obtener las distribuciones a priori conjugadas anteriores con esta información inicial. Calcular también los intervalos bayesianos a priori al 95% para cada modelo.
- Se decidió muestrear 100 reclamaciones, apareciendo 10 errores entre ellas, lo cual causó alarma en la empresa con planteamientos de estadística clásica pues se estima el error en un 10%.
 - Obtener las distribuciones a posteriori para cada modelo.
 - Obtener las estimaciones bayesianas bajo pérdidas cuadráticas y absolutas de la tasa de error.
 - Calcular los intervalos a posteriori al 95%.
- En la situación anterior y sabiendo que el número de reclamaciones actuales es de 4500, se pide contrastar (para cada modelo):

$$H_0 : \text{número de errores} \leq 300$$

$$H_1 : \text{número de errores} > 300$$

Como señal de seguridad, la compañía admite como buena aquella hipótesis que tenga el triple de probabilidades de ser cierta.

- En general en todos los apartados, ¿las decisiones dependen del modelo elegido?
5. Antes de la firma de un determinada póliza para el aseguramiento de un bien natural desea analizar su valoración. Supongamos que la disposición a pagar que tienen los individuos por la preservación y mantenimiento de un determinado parque natural sabemos que va de 0 a 10 (en miles de euros). De estudios históricos y sociológicos se cree que por término medio la cantidad a pagar se sitúa en 1 (es decir, 1000 euros).

- Construir una densidad a priori gamma para esta información inicial.
 - Tomada una muestra de 10 individuos sus disposiciones a pagar fueron: 1,5; 0; 0; 0,75; 0,5; 1; 1; 4; 0; 0,25. Estimar la disposición media a pagar (λ) mediante un intervalo al 95% y predecir una siguiente observación, asumiendo que la verosimilitud es gamma, utilizando (si es necesario) WinBUGS.
 - Elegida una segunda muestra de 5 individuos los resultados fueron: 0, 0, 2, 1, 1. Contrastar la hipótesis de que la disposición a pagar sea mayor 750 euros.
6. Una compañía aseguradora supone que el número de reclamaciones en un año tiene distribución de Poisson de parámetro λ y que este número es independiente de un año a otro. Supongamos que se observan las reclamaciones en T años de un asegurado elegido al azar de entre una cartera. Se pide:
- Encontrar una distribución a priori conjugada para λ conociendo que la compañía estima como más frecuente 1 reclamación al año y que no más de 4 reclamaciones son asumibles en un año.
 - Supongamos que en los últimos 10 años el asegurado presenta el siguiente número de reclamaciones: 0, 0, 1, 2, 3, 0, 0, 1, 1, 0 (introducir estos datos en FirstBayes como un fichero). Obtener la densidad a posteriori y un intervalo de confianza a posteriori al 99%.
 - Suponiendo que la compañía tiene 1000 asegurados en esta cartera y que destina 20 u.m. para cada reclamación, obtener un intervalo al 95% de previsión de costes para el siguiente año.
 - Realizar el mismo análisis anterior pero con densidad a priori no informativa de Jeffrey. Esta distribución puede verse como límite de la conjugada.
 - Realizar el mismo análisis de los apartados anteriores pero con densidad a priori de la familia Weibull. Realizar este apartado con WinBUGS.
7. Una empresa aseguradora desea introducir una nueva póliza para la que estima una gran demanda en el mercado local. El número de clientes N en dicha póliza tiene una distribución del tipo:

$$\Pr(N=n|\alpha, \beta) = \begin{cases} \alpha, & n=0 \\ (1-\alpha)\beta(1-\beta)^{n-1}, & n=1, 2, \dots \end{cases}$$

con $0 < \alpha, \beta < 1$.

- En una muestra de tamaño t observaciones, se han detectado r ceros y el resto valores positivos: $n_1, \dots, n_{t-r}$. Obtener la función de verosimilitud.

- b) Suponiendo independencia entre α y β y que asignamos distribuciones a priori betas a cada parámetro, es decir: $\alpha \sim Be(\alpha_1, \alpha_2)$, $\beta \sim Be(\beta_1, \beta_2)$ con $\alpha_i, \beta_i > 0$, $i = 1, 2$ conocidos a priori, obtener las distribuciones a posteriori de cada parámetro.
- c) Supongamos que se han tomado 10 observaciones con los siguientes resultados: $n_1 = 0, n_2 = 1, n_3 = 1, n_4 = 5, n_5 = 0, n_6 = 5, n_7 = 3, n_8 = 3, n_9 = 2, n_{10} = 1$. Calcular la probabilidad de que otra observación n_{11} sea igual a 1.
- d) Obtener un intervalo bayesiano a posteriori al 90 % para α y β .
8. Las siguientes expresiones son útiles cuando resulta difícil encontrar una expresión explícita de la densidad a posteriori de un parámetro, pero es posible encontrar algunas medidas descriptivas del mismo:

$$E(\theta|x) = \bar{x} + \frac{1}{n} \tau^2 \frac{\partial \log L(\bar{x} | \theta)}{\partial \bar{x}},$$

$$\text{Var}(\theta|x) = \frac{1}{n} \tau^2 + \frac{1}{n^2} \tau^4 \frac{\partial^2 \log L(\bar{x} | \theta)}{\partial \bar{x}^2},$$

siendo $\bar{x}$ la media muestral, τ la dispersión a priori y n el tamaño muestral. Supongamos que $y_1, y_2, \dots, y_n$ constituyen una muestra de una población $N(\theta, 1)$ y que el único conocimiento sobre θ es que varía entre -1 y 1 . Obtener la distribución predictiva de $\bar{x}$ y la media y varianza a posteriori de θ .

9. Consideremos el caso de aumento de datos para cuantía de reclamaciones del ejemplo 11.40. Desarrollar el mismo ejemplo con densidad a priori para μ del tipo log-normal con la misma media y varianza a priori.
10. Desarrollar el modelo jerárquico par datos de frecuencia de la sección 11.4.3 para el caso que θ_i , α y β tengan densidades a priori normales con las mismas medias y varianzas a priori que en el caso gamma.
11. En el caso del ejemplo 11.42, realizar la estimación para el caso $c = 2$ y $c = 1$. Estudiar si existen diferencias para los distintos caso de cota inferior para el reaseguro.

Capítulo 12

Tarificación

12.1. Introducción

La cobertura de un riesgo por parte de una compañía aseguradora se establece con la garantía de un contrato, la *póliza* y exige al asegurado pagar un precio, la *prima*. En este capítulo se introducen los diferentes sistemas de tarificación más utilizados en la literatura actuarial. Se estudiarán sus propiedades, así como el sistema de tarificación comúnmente empleado en Europa en el sector automovilístico, el llamado *sistema bonus-malus*.

Ajustar una prima como una suma convexa de la prima que debería pagar un asegurado de acuerdo a su experiencia personal y la que debería pagar por pertenecer a un colectivo (la cartera) con unas características peculiares, forma parte del atractivo escenario en la ciencia actuarial denominado *teoría de la credibilidad*. Comprobaremos que la metodología bayesiana conduce en ocasiones a primas que se pueden expresar de esta forma.

Finalmente estudiaremos el reaseguro, un instrumento que permite a la compañía aseguradora acomodar su estructura de riesgos a su capacidad financiera.

12.2. Principios de cálculo de prima

La prima es el precio para el seguro (o reaseguro) vendido por la compañía aseguradora. Puesto que lo que la compañía vende es la cobertura de un riesgo, podemos especificar más la definición anterior como sigue.

Definición 12.1 *La prima es el pago que un asegurado hace a un asegurador por la cobertura total o parcial contra un riesgo.*

De forma reducida, una prima mínima técnica está compuesta de los siguientes elementos:

- Prima pura de riesgo.
- Sobreprima de seguridad.
- Costo adicional para el beneficio.

Por tanto, la prima o precio del servicio es el coste que para la empresa suponen los siniestros más el margen de beneficio. En este texto nos centraremos en las dos primeras componentes y no haremos mención a la tercera, que en principio no parece tener un componente estocástico.

El precio correcto, que es llamado *rating*, es vital, pues si es demasiado bajo representa una pérdida para la compañía aseguradora y si es demasiado alto se pierde competitividad frente a otras. Por tanto, una de las labores del actuario consiste en encontrar métodos de cálculo de primas, generalmente llamados en la literatura actuarial *principios de cálculo de primas*.

Para un actuario un riesgo es lo mismo que una variable aleatoria. Si denotamos por X la variable aleatoria número de reclamaciones o cantidad reclamada (o una combinación de ambas), un principio de cálculo de prima se define como sigue.

Definición 12.2 *Un principio de cálculo de prima es una función $\mathcal{H}(X)$ que asigna a un riesgo X un número real, que es la prima.*

En la práctica, el principio de cálculo de prima dependerá de la función de distribución $F(x)$ que siga la variable aleatoria X , por lo que en vez de hablar de $\mathcal{H}(X)$ como una función debería hablarse en términos más precisos del funcional $\mathcal{H}(F(x))$ como aparece en Gerber (1979).

12.2.1. Propiedades

Una prima debe de satisfacer una serie de propiedades ideales o axiomas. Sin embargo, no existe en la literatura actuarial un sistema axiomático comúnmente aceptado de propiedades que un principio de cálculo de prima debería satisfacer. Sin ser exhaustivos, contribuciones importantes en esta materia pueden encontrarse en Gerber (1979), Heilmann (1989) y Hürlimann (1994).

Gerber (1979) sostiene que las cinco propiedades que un principio de cálculo de prima $\mathcal{H}(X)$ debería satisfacer son:

1. *Sobreprima de seguridad no negativa.*

$$\mathcal{H}(X) \geq E(X),$$

Esto significa que para evitar la ruina técnica la ganancia esperada $\mathcal{H}(X) - E(X)$ será no negativa.

12.2. Principios de cálculo de prima

2. *No estafa.* La prima no excederá a la reclamación máxima posible, r_X :

$$\mathcal{H}(X) \leq r_X.$$

3. *Consistencia.* Para cada riesgo X y cada constante c ,

$$\mathcal{H}(X + c) = \mathcal{H}(X) + c.$$

Esto significa que si el beneficio se incrementa en una constante esta constante tiene que ser añadida a la prima.

4. *Aditividad.* Si X_1 y X_2 son riesgos independientes entonces:

$$\mathcal{H}(X_1 + X_2) = \mathcal{H}(X_1) + \mathcal{H}(X_2).$$

Esto quiere decir que la incorporación de riesgos independientes no afectan a la prima total.

5. *Iteratividad.* Si X y Θ son dos riesgos arbitrarios dependientes, entonces:

$$\mathcal{H}(X) = \mathcal{H}[\mathcal{H}(X|\Theta)].$$

Esto significa que la prima para X puede calcularse en dos pasos. Primero calcular la prima condicionada para X , $\mathcal{H}(X|\Theta)$ aplicando $\mathcal{H}$ a la distribución condicional de X . Esta prima condicional es una función de Θ y por lo tanto una variable aleatoria en sí misma. Entonces se aplica $\mathcal{H}$ a la distribución de $\mathcal{H}(X|\Theta)$ para obtener $\mathcal{H}[\mathcal{H}(X|\Theta)]$.

Heilmann (1989) sólo presta atención a la primera de estas propiedades, mientras que Hürlimann (1994) no considera la quinta y, sin embargo, añade otras:

6. $\mathcal{H}(c) = c$, para toda constante $c \geq 0$.

Esto significa que para un riesgo no aleatorio $X = c$, con $\Pr(X = c) = 1$, la prima a cobrar será c .

7. *Homogeneidad positiva.*

$$\mathcal{H}(cX) = c\mathcal{H}(X), \text{ para todo } c \geq 0,$$

que resulta conveniente para corregir efectos inflacionarios.

La lista de las propiedades que debería satisfacer un buen principio de cálculo de prima no acaba aquí. Otras propiedades pueden encontrarse en Young (2004).

12.3. Prima de riesgo, colectiva y Bayes

Una vez establecido un principio de cálculo de prima a aplicar a un riesgo X el siguiente paso consistirá en calcular la prima asociada a X conforme a una determinada distribución de probabilidad asociada al riesgo. En este sentido es conveniente comentar que en algunos casos las variables aleatorias que intervienen en el proceso de riesgo degeneran en variables deterministas. Por ejemplo en muchas de las formas de los seguros de vida la cantidad reclamada es fija. En otras ocasiones, tanto los costes como el número de siniestros o reclamaciones son variables aleatorias, como ocurre en seguros de accidentes, especialmente en seguros de automóviles. En este caso el asegurador desconoce las siguientes cuestiones:

- ¿Qué persona asegurada declarará un siniestro?
- ¿Cuántos ocurrirán?
- ¿Cuántos siniestros se declararán?
- ¿De qué cuantía serán los siniestros?

Por otro lado, la forma de recogida de datos por parte de las compañías aseguradoras determinará la metodología de trabajo. Señalamos las siguientes:

- En algunas ocasiones, las compañías recogen datos solamente de la cantidad total reclamada en unidades monetarias generada por cada póliza y año. En este caso la única vía para trabajar es utilizar esta cantidad y todos los modelos y/o estimadores se referirán a la distribución de la cantidad total reclamada.
- Los datos se recogen separadamente para el número de reclamaciones y el coste de cada uno de ellos. En este caso, el modo en que se trabaja es componer los dos modelos, del número de reclamaciones y de la cuantía de las mismos, para obtener la distribución de la cantidad total reclamada, esto es, la distribución de la variable aleatoria compuesta, $X = \sum_{i=1}^N X_i$, donde N es la variable aleatoria asociada al número de reclamaciones y X_i la variable aleatoria asociada a la cuantía del i -ésimo siniestro.
- Por último, en algunas ocasiones se cree que una vez ocurrido un siniestro la cuantía del mismo está fuera de control del asegurador, de modo que el número de reclamaciones o siniestros es la única componente a considerar. En este caso, el modo de trabajar es por medio del número de reclamaciones y no de la cantidad total reclamada. Este es el caso habitual en el ramo de seguros de automóviles, en el que para conductores precavidos, y mediante bonificaciones en la prima, se puede estimular al mismo a tomar una conducta más prudente.

12.3. Prima de riesgo, colectiva y Bayes

De aquí en adelante cuando nos referiramos a un riesgo X y salvo que se diga lo contrario, éste representará indistintamente el número, la cuantía o la cantidad total o agregada.

La siguiente metodología de cálculo de prima se basa en Heilmann (1989), donde se construyen diversos principios de cálculo de prima mediante el uso de funciones de pérdidas en el escenario de la teoría de la decisión, equivalente en algunas ocasiones a utilizar funciones de utilidad.

Recordemos que según la definición 10.6, una función de pérdida $\mathcal{L}(\tilde{\theta}, \theta)$ describe la pérdida soportada por un decisor que elige el estimador $\tilde{\theta}$ en vez del verdadero valor del parámetro θ .

Consideremos ahora una función de pérdida $\mathcal{L} : \mathbb{R}^2 \rightarrow \mathbb{R}$ que atribuya a algún $(x, P) \in \mathbb{R}^2$ la pérdida soportada por un decisor que toma la acción P y se encuentra con el resultado x de algún experimento aleatorio. La prima de riesgo se define de la siguiente manera.

Definición 12.3 Dados un riesgo X con función de densidad $f(x)$ y una función de pérdida $\mathcal{L} : \mathbb{R}^2 \rightarrow \mathbb{R}$, la prima de riesgo es el valor de P que minimiza la pérdida esperada

$$\int_{\mathbb{R}} \mathcal{L}(x, P) f(x) dx = E_f[\mathcal{L}(X, P)], \quad (12.1)$$

donde x es el resultado del experimento aleatorio X y P la prima cobrada por tomar x .

Obviamente, si X es discreta P deberá minimizar la pérdida esperada

$$\sum_{x=0}^{\infty} \mathcal{L}(x, P) f(x),$$

donde ahora $f(x) = \Pr(X = x)$ es la función de densidad discreta.

Para obtener las diversas primas de riesgo consideramos funciones de pérdidas de la forma

$$\mathcal{L}(x, P) = g(x) [h(x) - h(P)]^2, \quad (12.2)$$

donde $g(x)$ y $h(x)$ son funciones apropiadas cuyas esperanzas bajo $f(\cdot)$ existen. Ahora utilizando (12.1) y el siguiente resultado podemos obtener la prima de riesgo.

Teorema 12.1 Si $h(x)$ es estrictamente creciente y diferenciable (y por tanto invertible) y $g(x)$ es no negativa, entonces para todo riesgo X con $E_f[g(X)] < \infty$ y $E_f[g(X)h(X)] < \infty$, se tiene que

$$\mathcal{H}(X) = h^{-1} \left(\frac{E_f[g(X)h(X)]}{E_f[g(X)]} \right).$$

Demostración: Derivando con respecto a P el funcional

$$\int \mathcal{L}(x, P) f(x) dx = \int g(x) [h(x) - h(P)]^2 f(x) dx,$$

resulta

$$-2 \int g(x) [h(x) - h(P)] h'(P) f(x) dx = 0,$$

de donde

$$h'(P) \int g(x) h(x) f(x) dx - h(P) h'(P) \int g(x) f(x) dx = 0.$$

Ahora, puesto que $h'(P) > 0$ resulta:

$$h(P) = \frac{\int g(x) h(x) f(x) dx}{\int g(x) f(x) dx},$$

y por tanto:

$$P = \mathcal{H}(X) = h^{-1} \left(\frac{\int g(x) h(x) f(x) dx}{\int g(x) f(x) dx} \right) = h^{-1} \left(\frac{E_f[g(X)h(X)]}{E_f[g(X)]} \right).$$

Esta metodología de cálculo de prima utilizando funciones de pérdidas, fue propuesta por Heilmann (1989), obteniendo de esta manera muchos de los principios de cálculo de prima que ya se utilizaban así como otros nuevos.

Las siguientes proposiciones son consecuencia de aplicar el teorema 12.1 a funciones particulares $f(x)$ y $g(x)$.

Proposición 12.1 Si consideramos la función de pérdida cuadrática, dada por

$$\mathcal{L}(x, P) = (x - P)^2,$$

resulta,

$$P = E_f(X), \quad (12.3)$$

denominado principio de prima neta o de equivalencia.

Proposición 12.2 Si consideramos la función de pérdida exponencial, dada por

$$\mathcal{L}(x, P) = \frac{1}{\alpha} (e^{\alpha x} - e^{\alpha P})^2,$$

con $\alpha > 0$, resulta,

$$P = \frac{1}{\alpha} \log E_f(e^{\alpha X}), \quad (12.4)$$

denominado principio de utilidad exponencial

Observemos que este principio de cálculo de prima viene dado en términos del logaritmo de la función generatriz de momentos de la variable aleatoria X . En teoría de la decisión a α se le denomina *constante de aversión al riesgo* (también llamada medida de Arrow-Pratt) asociada al decisor que toma la función de pérdida $\mathcal{L}(x, P)$. Cuanto mayor es α más adverso al riesgo será el decisor (en nuestro caso la compañía aseguradora).

Proposición 12.3 Si consideramos la función de pérdida cuadrática ponderada, con peso $g(x) = e^{\alpha x}$, dada por

$$\mathcal{L}(x, P) = e^{\alpha x} (x - P)^2,$$

con $\alpha > 0$, entonces

$$P = \frac{E_f(X e^{\alpha X})}{E_f(e^{\alpha X})}, \quad (12.5)$$

denominado principio Esscher.

El parámetro α de (12.5) tiene la misma interpretación que en el caso anterior.

Proposición 12.4 Si consideramos la función de pérdida cuadrática ponderada, con peso $g(x) = x$, dada por

$$\mathcal{L}(x, P) = x(x - P)^2,$$

entonces:

$$P = \frac{E_f(X^2)}{E_f(X)} = E_f(X) + \frac{\text{Var}_f(X)}{E_f(X)}, \quad (12.6)$$

denominado principio de varianza.

La ventaja de este principio es que no sólo estima la siniestralidad media del riesgo, sino que proporciona además el recargo de seguridad que debe llevar la prima para atender a las desviaciones aleatorias de la siniestralidad. En muchos textos la expresión de P se presenta como

$$P = E(X) + \delta \text{Var}(X),$$

siendo $\delta > 0$ un parámetro y se dice entonces que la sobreprima de seguridad es proporcional a la varianza.

El siguiente resultado se muestra útil para probar la propiedad de sobreprima de seguridad no negativa de los principios de cálculo de prima antes presentados.

Teorema 12.2 Si $h(x) = x$, es decir $\mathcal{L}(x, P) = g(x)(x - P)^2$ y $g: \mathbb{R}^+ \rightarrow \mathbb{R}^+$, entonces $g(x)$ es creciente (decreciente) si y sólo si para todo riesgo X con $\Pr(X > 0) = 1$ se verifica:

$$\mathcal{H}(X) = \frac{E_f[g(X)X]}{E_f[g(X)]} \geq (\leq) E_f(X). \quad (12.7)$$

Ejemplo 12.1 Demostrar que el principio Esscher verifica las propiedades 1, 2, 3, 4 y 6 de las propiedades deseables para un principio de cálculo de prima.

Solución:

1. Puesto que el principio Esscher se deriva de la función de pérdida $\mathcal{L}(x, P) = e^{\alpha x}(x - P)^2$, y esta es de la forma (12.2), utilizando el resultado (12.7) se obtiene

$$\mathcal{H}(X) = P = \frac{E_f(Xe^{\alpha X})}{E_f(e^{\alpha X})} \geq E_f(X).$$

2. Tenemos $X \leq r_X$, de donde $Xe^{\alpha X} \leq r_X e^{\alpha X}$, luego

$$E_f(Xe^{\alpha X}) \leq r_X E_f(e^{\alpha X}),$$

$$\text{y de aquí } P = \frac{E_f(Xe^{\alpha X})}{E_f(e^{\alpha X})} \leq r_X.$$

- 3.

$$\begin{aligned} \mathcal{H}(X+c) &= \frac{E_f[(X+c)e^{\alpha(X+c)}]}{E_f[e^{\alpha(X+c)}]} \\ &= \frac{E_f[Xe^{\alpha(X+c)} + ce^{\alpha(X+c)}]}{E_f[e^{\alpha(X+c)}]} \\ &= \frac{E_f[Xe^{\alpha(X+c)}] + cE_f[e^{\alpha(X+c)}]}{E_f[e^{\alpha(X+c)}]} \\ &= \frac{E_f[Xe^{\alpha(X+c)}]}{E_f[e^{\alpha(X+c)}]} + c \\ &= \mathcal{H}(X) + c. \end{aligned}$$

4. Sean X_1 y X_2 dos riesgos independientes, entonces:

$$\begin{aligned} \mathcal{H}(X_1 + X_2) &= \frac{E_f[(X_1 + X_2)e^{\alpha(X_1 + X_2)}]}{E_f[e^{\alpha(X_1 + X_2)}]} \\ &= \frac{E_f(X_1 e^{\alpha X_1} e^{\alpha X_2} + X_2 e^{\alpha X_1} e^{\alpha X_2})}{E_f(e^{\alpha X_1} e^{\alpha X_2})} \\ &= \frac{E_f(X_1 e^{\alpha X_1}) E_f(e^{\alpha X_2}) + E_f(X_2 e^{\alpha X_2}) E_f(e^{\alpha X_1})}{E_f(e^{\alpha X_1}) E_f(e^{\alpha X_2})} \\ &= \frac{E_f(X_1 e^{\alpha X_1})}{E_f(e^{\alpha X_1})} + \frac{E_f(X_2 e^{\alpha X_2})}{E_f(e^{\alpha X_2})} \\ &= \mathcal{H}(X_1) + \mathcal{H}(X_2). \end{aligned}$$

donde se ha hecho uso de la hipótesis de independencia.

12.3. Prima de riesgo, colectiva y Bayes

5. Finalmente:

$$\mathcal{H}(c) = \frac{E_f[ce^{\alpha c}]}{E_f[e^{\alpha c}]} = \frac{ce^{\alpha c}}{e^{\alpha c}} = c.$$

El lector puede ahora demostrar las propiedades que satisfacen el resto de los principios de cálculo de primas y que se recogen en la tabla 12.1. $\diamond$

Tabla 12.1: Cuatro principios y las propiedades que verifican

Propiedad	Prima Neta	Exponencial	Esscher	Varianza
1	SI	SI	SI	SI
2	SI	SI	SI	NO
3	SI	SI	SI	SI
4	SI	SI	SI	SI
5	SI	SI	NO	NO
6	SI	SI	SI	SI
7	SI	NO	NO	NO

Los principios de cálculo de primas mostrados son los más utilizados en la literatura actuarial. Sin embargo, existen otra serie de principios que ahora señalamos.

- Principio del valor esperado. La prima de riesgo viene dada mediante:

$$P = (1 + \lambda)E(X), \quad \lambda > 0.$$

- Principio de desviación típica. La prima de riesgo, en este caso, viene dada por:

$$P = E(X) + \lambda \sqrt{\text{Var}(X)}, \quad \lambda > 0.$$

- Principio de prima suizo. La prima de riesgo P es la solución de la ecuación:

$$E[v(X - zP)] = v((1 - z)P),$$

en la que $v(\cdot)$ es una función peso verificando $v'(z) > 0$, $v''(z) \geq 0$, si $z > 0$.

- Principio de Orlicz. La prima de riesgo es la solución de la ecuación:

$$E\left[\Phi\left(\frac{X}{P}\right)\right] = 1,$$

donde $\Phi(\cdot)$ es una función peso con $\Phi' > 0$, $\Phi'' \geq 0$.

- Principio de Wang. La prima de riesgo viene dada por:

$$P = \int_0^\infty g[S_X(t)] dt,$$

donde $S_X(t) = \Pr(X > t)$ es la función de supervivencia de X y g es una función no decreciente con dominio en $[0, 1]$ y recorrido en $[0, 1]$.

- Principio holandés. La prima de riesgo es:

$$P = E(X) + \lambda E[(X - \alpha E(X))_+], \quad \alpha \geq 1, \quad 0 < \lambda \leq 1,$$

donde $(X - \alpha E(X))_+ = \max\{(X - \alpha E(X)), 0\}$.

Young (2004) ha estudiado alguna de las propiedades que verifican estos principios. Por otro lado, cabe también la posibilidad de generar principios de cálculo de primas considerando otras funciones de pérdidas. De este modo, bajo la función de pérdida:

$$\mathcal{L}(x, P) = \frac{(x - P)^2}{x}, \quad x > 0, \quad \Pr(X > 0) = 1,$$

se obtiene la prima de riesgo,

$$P = \frac{1}{E\left(\frac{1}{X}\right)}.$$

Si se considera la función de pérdida

$$\mathcal{L}(x, P) = \frac{(x - P)^2}{x(x+1)}, \quad x > 0, \quad \Pr(X > 0) = 1,$$

se obtiene la prima de riesgo

$$P = \frac{E\left(\frac{1}{X+1}\right)}{E\left(\frac{1}{X(X+1)}\right)}.$$

Finalmente, bajo la función de pérdida

$$\mathcal{L}(x, P) = (\log x - \log P)^2, \quad x > 0, \quad P > 0, \quad \Pr(X > 0) = 1,$$

la prima de riesgo resultante es

$$P = \exp\{E[\log(X)]\}.$$

Los principios de cálculo de primas mostrados pueden estudiarse siempre que la función de densidad $f(x)$ sea conocida. En la literatura actuarial es habitual considerar que todos o algunos de los parámetros de los que depende esta densidad de probabilidad son desconocidos. Así, si suponemos ahora que la densidad $f(x)$ depende de un parámetro desconocido θ , $\theta \in \Theta$, entonces la densidad de probabilidad será $f(x; \theta)$ o $f(x|\theta)$ dependiendo que el parámetro sea fijo o aleatorio. Podemos ahora suponer que dicho parámetro se distribuye entre toda la cartera de seguros de acuerdo a cierta función de densidad $\pi(\theta)$. Desde un punto de vista bayesiano ésta no es más que la distribución a priori, denominada en el escenario actuarial *función estructura*. Ahora, la prima de riesgo P depende del parámetro desconocido y por tanto será notada como $P(\theta)$. En principio, la mejor estimación que puede obtenerse de la misma es la prima colectiva que se define de la siguiente forma.

Definición 12.4 Dados un riesgo X con función de densidad $f(x|\theta)$, siendo θ un parámetro desconocido con función de densidad a priori $\pi(\theta)$ y una función de pérdida $\mathcal{L} : \mathbb{R}^2 \rightarrow \mathbb{R}$, la prima colectiva es el valor P' que minimiza la pérdida esperada

$$\int_{\Theta} \mathcal{L}(P(\theta), P') \pi(\theta) d\theta,$$

siendo $P(\theta)$ la prima de riesgo definida en (12.1).

La prima colectiva tal y como está definida arriba representa la mejor decisión que estima la prima de riesgo (obviamente desconocida). Observemos que para calcularla se necesitará que el actuario defina una distribución de probabilidad (distribución a priori) para el valor del parámetro desconocido θ . Para ello será fundamental la experiencia de lo acontecido en los períodos precedentes o en otros contratos similares.

Ejemplo 12.2 Sea un riesgo X con función de densidad de probabilidad $f(x|\theta)$, dependiente del parámetro θ desconocido y aleatorio y con distribución a priori (función estructura) $\pi(\theta)$. Calcular la prima colectiva para los principios de prima neta, exponencial, Esscher y de varianza.

Solución:

1. Para el principio de prima neta tenemos que $\mathcal{L}(P(\theta), P') = [P(\theta) - P']^2$, entonces $P(\theta)$ es como en (12.3) y se obtiene,

$$P' = \int_{\Theta} \left[\int_{\mathbb{R}} x f(x|\theta) dx \right] \pi(\theta) d\theta = E_{\pi}[E_f(X|\theta)]. \quad (12.8)$$

2. Para el principio de utilidad exponencial tenemos:

$$\mathcal{L}(P(\theta), P') = \frac{1}{\alpha} (e^{\alpha P(\theta)} - e^{\alpha P'})^2,$$

con $\alpha > 0$, entonces $P(\theta)$ es como en (12.4), de donde,

$$P' = \frac{1}{\alpha} \log \int_{\Theta} e^{\alpha P(\theta)} \pi(\theta) d\theta = \frac{1}{\alpha} \log E_{\pi} [e^{\alpha P(\theta)}]. \quad (12.9)$$

3. Para el principio Esscher tenemos que

$$\mathcal{L}(P(\theta), P') = e^{\alpha P(\theta)} [P(\theta) - P']^2, \quad \alpha > 0,$$

entonces $P(\theta)$ viene dada en (12.5), y se obtiene,

$$P' = \frac{\int_{\Theta} P(\theta) e^{\alpha P(\theta)} \pi(\theta) d\theta}{\int_{\Theta} e^{\alpha P(\theta)} \pi(\theta) d\theta} = \frac{E_{\pi} [P(\theta) e^{\alpha P(\theta)}]}{E_{\pi} [e^{\alpha P(\theta)}]}. \quad (12.10)$$

4. Finalmente, para el principio de varianza tenemos que

$$\mathcal{L}(P(\theta), P') = P(\theta) [P(\theta) - P']^2,$$

entonces $P(\theta)$ viene dada como en (12.6), y se deduce:

$$P' = \frac{\int_{\Theta} P(\theta)^2 \pi(\theta) d\theta}{\int_{\Theta} P(\theta) \pi(\theta) d\theta} = \frac{E_{\pi} [P(\theta)^2]}{E_{\pi} [P(\theta)]}. \quad (12.11)$$

◇

Para finalizar este apartado expondremos el caso en el que la distribución de X está especificada mediante un parámetro desconocido y además se incorpora experiencia de siniestralidad individual.

En este caso, el análisis bayesiano nos permitirá combinar la información inicial o a priori que se tiene sobre el parámetro θ con la información muestral para obtener la distribución a posteriori del parámetro. Si $\pi(\theta)$ es la densidad a priori (que refleja las creencias sobre θ antes de obtener la información muestral), y $\mathbf{x} = (x_1, \dots, x_t)$ es un vector de datos observados que recoge la información muestral, la verosimilitud del dato observado la denotaremos por $L(\mathbf{x}|\theta)$, y el teorema de Bayes nos permitirá obtener la distribución a posteriori $\pi(\theta|\mathbf{x})$ de la siguiente manera:

$$\pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}|\theta)\pi(\theta)}{\int_{\Theta} L(\mathbf{x}|\theta)\pi(\theta)d\theta} \propto L(\mathbf{x}|\theta)\pi(\theta),$$

es decir $\pi(\theta|\mathbf{x})$ es el cociente entre la distribución conjunta $L(\mathbf{x}|\theta)\pi(\theta)$ y la distribución predictiva $p(\mathbf{x}) = \int_{\Theta} L(\mathbf{x}|\theta)\pi(\theta)d\theta$ como ya hemos visto. Esto permite construir la prima Bayes o a posteriori que se define de la siguiente manera.

12.3. Prima de riesgo, colectiva y Bayes

375

Definición 12.5 Dados un riesgo X con función de densidad de probabilidad dada por $f(x|\theta)$, siendo θ un parámetro desconocido con distribución a priori $\pi(\theta)$, una función de pérdida $\mathcal{L} : \mathbb{R}^2 \rightarrow \mathbb{R}$ y un vector de datos observados $\mathbf{x}$, la prima Bayes es el valor $P(\mathbf{x})$ que minimiza:

$$\int_{\Theta} \mathcal{L}(P(\theta), P(\mathbf{x})) \pi(\theta|\mathbf{x}) d\theta,$$

siendo $\pi(\theta|\mathbf{x})$ la distribución a posteriori de θ dada la muestra y $P(\theta)$ la prima de riesgo definida anteriormente.

Ejemplo 12.3 Sea un riesgo X con función de densidad de probabilidad $f(x|\theta)$, dependiente del parámetro θ desconocido y aleatorio con distribución a priori $\pi(\theta)$. Calcular la prima Bayes para los cuatro principios de prima neta, exponencial, Esscher y de varianza.

Solución: Las expresiones de las primas Bayes se obtienen intercambiando en (12.8), (12.9), (12.10) y (12.11) $\pi(\theta)$ por $\pi(\theta|\mathbf{x})$, obteniéndose:

$$P(\mathbf{x}) = \int_{\Theta} \left[\int_{\mathcal{X}} x f(x|\theta) dx \right] \pi(\theta|\mathbf{x}) d\theta = E_{\pi(\theta|\mathbf{x})} [E_f(X|\theta)], \quad (12.12)$$

para el principio de prima neta. Entonces:

$$P(\mathbf{x}) = \frac{1}{\alpha} \log \int_{\Theta} e^{\alpha P(\theta)} \pi(\theta|\mathbf{x}) d\theta = \frac{1}{\alpha} \log E_{\pi(\theta|\mathbf{x})} [e^{\alpha P(\theta)}], \quad (12.13)$$

para el principio exponencial.

$$P(\mathbf{x}) = \frac{\int_{\Theta} P(\theta) e^{\alpha P(\theta)} \pi(\theta|\mathbf{x}) d\theta}{\int_{\Theta} e^{\alpha P(\theta)} \pi(\theta|\mathbf{x}) d\theta} = \frac{E_{\pi(\theta|\mathbf{x})} [P(\theta) e^{\alpha P(\theta)}]}{E_{\pi(\theta|\mathbf{x})} [e^{\alpha P(\theta)}]}, \quad (12.14)$$

para el principio Esscher.

$$P(\mathbf{x}) = \frac{\int_{\Theta} P(\theta)^2 \pi(\theta|\mathbf{x}) d\theta}{\int_{\Theta} P(\theta) \pi(\theta|\mathbf{x}) d\theta} = \frac{E_{\pi(\theta|\mathbf{x})} [P(\theta)^2]}{E_{\pi} [P(\theta)]}, \quad (12.15)$$

para el principio de varianza.

Ejemplo 12.4 Calcular la prima de riesgo, colectiva y Bayes bajo el principio de varianza suponiendo que el riesgo X sigue la distribución gamma con parámetros $\mathcal{G}(\theta, 1/\nu)$, con ν conocido y θ sigue en el colectivo la distribución gamma con parámetros $\mathcal{G}(a, 1/b)$.

Solución: Es inmediato deducir que en este caso la prima de riesgo es

$$P(\theta) = \theta + 1,$$

y la prima colectiva

$$P' = (\nu + 1) \frac{a}{b - 2}.$$

Ahora teniendo en cuenta que si $X \sim \mathcal{G}(\theta, 1/\nu)$ y $X_i, i = 1, \dots, t$ son i.i.d. con media muestral $\bar{x}$ y $\theta \sim \mathcal{G}(a, 1/b)$, entonces la distribución a posteriori es de nuevo una gamma con parámetros $a + t\bar{x}$ y $1/(b + t\nu)$, y por tanto:

$$P(x) = (\nu + 1) \frac{a + t\bar{x}}{b + t\nu - 2}.$$

Ejemplo 12.5 Supongamos que el número de reclamaciones de una cartera de seguros sigue una distribución binomial negativa con parámetros r y θ de la forma:

$$\Pr(X = x|\theta) = \binom{r+x-1}{x} \left(\frac{r}{r+\theta}\right)^r \left(\frac{\theta}{r+\theta}\right)^x, \quad x = 0, 1, \dots; \quad r, \theta > 0,$$

y θ sigue una distribución beta de segunda especie con parámetros $r, b, \nu > 0$, de modo que

$$\pi(\theta) = \frac{r^b}{B(\nu, b)} \frac{\theta^{\nu-1}}{(r+\theta)^{b+\nu}}.$$

Calcular bajo el principio de prima neta la prima de riesgo, colectiva y Bayes.

Solución: La prima de riesgo es $P(\theta) = \theta$, mientras que la prima colectiva viene dada por

$$P' = E_{\pi}(\theta) = \frac{r\nu}{b-1}, \quad b > 1.$$

Para calcular la prima Bayes obtengamos primero la distribución a posteriori de θ . Para ello dada una muestra con media $\bar{x} = \sum_{i=1}^t x_i/t$ tenemos:

$$\begin{aligned} \pi(\theta|x) &\propto \left(\frac{r}{r+\theta}\right)^{tr} \left(\frac{\theta}{r+\theta}\right)^{t\bar{x}} \frac{\theta^{\nu-1}}{(r+\theta)^{b+\nu}} \\ &\propto \frac{\theta^{\nu+t\bar{x}-1}}{(r+\theta)^{b+\nu+t\bar{x}+tr}}, \end{aligned}$$

que es de nuevo una distribución beta de segunda especie con parámetros $r, b + tr, \nu + t\bar{x}$. Luego, la prima Bayes es:

$$P(x) = r \frac{\nu + t\bar{x}}{b + tr - 1}. \quad (12.16)$$

Para acabar con esta sección expondremos el siguiente resultado que muestra que la media de la distribución a posteriori de θ es igual a la media de la distribución predictiva X_{t+1} , siempre que $E(X_i|\theta) = \theta, i = 1, 2, \dots, t$.

Teorema 12.3 Sean $X_1, X_2, \dots, X_t$ variables aleatorias i.i.d. tales que $E(X_i|\theta) = \theta, i = 1, 2, \dots, t$. Entonces:

$$E(X_{t+1}|x_1, x_2, \dots, x_t) = E(\theta|x_1, x_2, \dots, x_t).$$

Demostración:

$$\begin{aligned} E(X_{t+1}|x_1, x_2, \dots, x_t) &= \int_{\mathcal{X}} x f(x_{t+1}|x_1, x_2, \dots, x_t) dx \\ &= \int_{\mathcal{X}} x \left(\int_{\Theta} f(x_{t+1}|\theta) \pi(\theta|x_1, x_2, \dots, x_t) d\theta \right) dx \\ &= \int_{\Theta} \left(\int_{\mathcal{X}} x f(x_{t+1}|\theta) dx \right) \pi(\theta|x_1, x_2, \dots, x_t) d\theta \\ &= E(\theta|x_1, x_2, \dots, x_t). \end{aligned}$$

Por tanto, la prima neta Bayes coincide con la media de la distribución predictiva.

12.4. La teoría de la credibilidad

Las primeras ideas sobre credibilidad aparecen a principios del siglo XX en los trabajos de Mowbray (1914) y Whitney (1918). El problema básico es el siguiente. Supongamos que disponemos para un asegurado o contrato de la experiencia de siniestralidad $X_1, \dots, X_t$ de modo que $E(X_j) = \varepsilon$ y $\text{Var}(X_j) = \sigma^2$, para todo $j = 1, \dots, t$. El objetivo de la aseguradora es decidir qué prima cargar a esa póliza o asegurado. Existen tres alternativas posibles:

1. Ignorar la experiencia de siniestralidad y cargar lo que en la literatura actuarial se le conoce como prima manual o de libro, M . Esta prima está basada en la experiencia de otros contratos similares. Por ejemplo, en el seguro de automóviles son contratos similares los que incluyan asegurados con la misma edad o propietarios de un vehículo con igual cilindrada.
2. Cobrarle $\bar{X} = \frac{1}{t} \sum_{j=1}^t X_j$, es decir dar credibilidad total a la experiencia del asegurado.
3. Cobrar una prima que venga dada como un punto medio o combinación lineal convexa entre la experiencia individual y M . Esto es:

$$\text{Prima} = Z(t)\bar{X} + [1 - Z(t)]M, \quad (12.17)$$

donde el factor, $Z \in [0, 1]$, recibe el nombre de factor de credibilidad y la fórmula (12.17) fórmula de credibilidad.

Lo razonable es que el asegurador se decante por $\bar{X}$ si la experiencia es estable, es decir si tiene una varianza pequeña. Esta idea tan simple no admite una respuesta sencilla y han surgido distintas ramas dentro de la teoría de la credibilidad cada una con nombre propio y que pasamos a exponer.

12.4.1. Credibilidad total

Parece lógico que los asegurados con una experiencia de reclamación que les sea favorable quieran que la prima que tengan que pagar esté basada únicamente en su propia experiencia de siniestralidad, es decir que la aseguradora le asigna a ésta un 100 % de credibilidad. Sin embargo, desde el punto de vista de la aseguradora, esto sólo será posible si la experiencia de reclamación es estable. Una manera de resolver este problema es suponer que $\bar{X}$ es estable si existe una probabilidad alta de que la diferencia entre $\bar{X}$ y ε sea pequeña. En términos matemáticos esto supondría suponer credibilidad total si

$$\Pr(|\bar{X} - \varepsilon| \leq c\varepsilon) = \Pr((1 - c)\varepsilon \leq \bar{X} \leq (1 + c)\varepsilon) \geq p, \quad (12.18)$$

siendo $0 < p < 1$ y $c > 0$. En la práctica lo razonable es elegir un valor de p cercano a 1 y un valor de c cercano a 0. Normalmente suelen considerarse 0,9 y 0,05 para p y c , respectivamente.

Reescribimos (12.18) en la forma:

$$\Pr\left(\left|\frac{\bar{X} - \varepsilon}{\sigma/\sqrt{t}}\right| \leq \frac{c\varepsilon\sqrt{t}}{\sigma}\right) \geq p,$$

y definimos ahora x_p como

$$x_p = \inf_x \left\{ \Pr\left(\left|\frac{\bar{X} - \varepsilon}{\sigma/\sqrt{t}}\right| \leq x\right) \geq p \right\}.$$

Suponiendo que $\bar{X}$ sigue una distribución de tipo continua, esta última expresión es equivalente a:

$$\Pr\left(\left|\frac{\bar{X} - \varepsilon}{\sigma/\sqrt{t}}\right| \leq x_p\right) = p. \quad (12.19)$$

Por tanto, la condición que ha de verificarse para suponer credibilidad total es

$$\frac{c\varepsilon\sqrt{t}}{\sigma} \geq x_p,$$

12.4. La teoría de la credibilidad

o de forma equivalente:

$$\frac{\sigma}{\varepsilon} \leq \frac{c}{x_p} \sqrt{t} = \sqrt{\frac{t}{\lambda_0}}, \quad (12.20)$$

siendo $\lambda_0 = (x_p/c)^2$. La expresión (12.20) puede interpretarse en el sentido siguiente: se supone credibilidad total si el coeficiente de variación es menor o igual que $\sqrt{t/\lambda_0}$. También, a partir de (12.20) se observa que se supone credibilidad total si:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{t} \leq \frac{\varepsilon^2}{\lambda_0},$$

y, por otro lado, el valor que ha de tomar t para suponer credibilidad total ha de cumplir:

$$t \geq \lambda_0 \left(\frac{\sigma}{\varepsilon}\right)^2$$

En la práctica, si la experiencia del asegurado es suficientemente grande, de acuerdo al teorema central del límite, entonces $(\bar{X} - x)/(\sigma/\sqrt{t})$ sigue aproximadamente una distribución normal con media cero y desviación típica 1. Así (12.19) puede entonces escribirse como $p = 2\Phi(x_p) - 1$, donde $\Phi(x)$ es la función de distribución de la normal tipificada, luego x_p es el $(1 + p)/2$ percentil de la distribución normal tipificada.

Ejemplo 12.6 Supongamos que se cuenta con la experiencia X_j , $j = 1, \dots, t$ de un contrato de seguro perteneciente a una cartera de seguros y que $X_1, \dots, X_t$ son variables aleatorias independientes e idénticamente distribuidas Poisson de parámetro $\theta = 200$. Obtener el valor más pequeño de t para suponer credibilidad total a la experiencia observada, suponiendo $r = 0,04$, $p = 0,95$ y que la aseguradora tarifica atendiendo sólo al número de reclamaciones.

Solución: En este caso $\varepsilon = \sigma^2 = 200$. Dados los valores de c y p resulta $x_p = 1,96$, luego:

$$\lambda_0 = \left(\frac{x_p}{c}\right)^2 = 2401,$$

y

$$t \geq 2401 \frac{200}{200^2} = 12,05.$$

12.4.2. Credibilidad parcial

Para muchos asegurados la experiencia de siniestralidad es insuficiente para suponer credibilidad total, es decir que el factor $Z(t)$ sea igual a 1. Ahora se supone que la prima a cargar sea una combinación lineal entre la experiencia del asegurado y la experiencia del colectivo o prima manual, de modo que:

$$P = Z(t)\bar{X} + [1 - Z(t)]M,$$

y habrá, por tanto, que determinar el valor de $Z(t)$ para obtener la prima. Dado que:

$$\text{Var}(P) = \text{Var}[Z(t)\bar{X} + [1 - Z(t)]M] = Z(t)^2 \text{Var}(\bar{X}) = Z(t)^2 \frac{\sigma^2}{t},$$

igualando este último término a ε^2/λ_0 resulta,

$$Z(t) = (\varepsilon/\sigma)\sqrt{t/\lambda_0},$$

de modo que se elige $Z(t)$ de acuerdo a la expresión:

$$Z(t) = \min \left\{ \frac{\varepsilon}{\sigma} \sqrt{\frac{t}{\lambda_0}}, 1 \right\}. \quad (12.21)$$

Ejemplo 12.7 Con los datos del ejemplo 12.6 se pide ahora calcular el valor del factor de credibilidad para una experiencia de reclamaciones correspondiente a 10 años.

Solución: Usando (12.21) resulta:

$$Z(10) = \min \left\{ \sqrt{\frac{10 \times 200}{2401}}, 1 \right\} = 0,9126.$$

◇

Ejemplo 12.8 Con los datos del ejemplo 12.6 se pide calcular el factor de credibilidad cuando se han observado 850 reclamaciones para ese grupo de asegurados.

Solución: En este caso resulta conveniente estimar $t\theta$ por $N_1 + \dots + N_t$, de manera que:

$$Z(t) = \min \left\{ \sqrt{\frac{850}{2401}}, 1 \right\} = 0,595.$$

◇

12.4.3. Credibilidad e inferencia bayesiana

El uso de distribuciones a priori, con un marcado carácter subjetivo, resulta útil en el mercado de seguros, sobre todo si se tiene en cuenta que cuando se quiere tarificar un riesgo nuevo no se cuenta con datos disponibles.

La visión bayesiana se incorporó rápidamente a la disciplina actuarial no tardando en demostrarse (Bailey (1945) y Mayerson (1964)) que algunas primas obtenidas mediante la metodología bayesiana podían escribirse como fórmulas de credibilidad. Así fue como surgió el campo dentro de la ciencia actuarial de la *teoría de la credibilidad*, que hoy en día abarca un terreno mucho más amplio que el inicialmente establecido. El problema de la teoría de la credibilidad consiste en determinar las ponderaciones que afectan a la experiencia de siniestralidad de una póliza respecto a la experiencia de un colectivo al que pertenece dicha póliza.

Consideremos la cartera de seguros que aparece en la tabla 12.2, que consta de k pólizas o asegurados y t períodos de observación de las mismas.

Tabla 12.2: Cartera de seguros

	1	2	...	j	...	k
1	x_{11}	x_{21}	...	x_{j1}	...	x_{k1}
2	x_{12}	x_{22}	...	x_{j2}	...	x_{k2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
t	x_{1t}	x_{2t}	...	x_{jt}	...	x_{kt}

La cuestión básica de la teoría de la credibilidad es determinar una prima establecida como una combinación lineal o convexa entre la experiencia particular de un asegurado y la experiencia del colectivo, esto es de toda la cartera. Una expresión válida sería:

$$P_j = [1 - Z(t)]P_0 + Z(t)\tilde{P}_j,$$

donde:

- P_j : Prima a aplicar a los asegurados al riesgo j .
- P_0 : Prima a aplicar a un colectivo al que pertenece el asegurado j .
- $\tilde{P}_j$: Prima obtenida en base a la experiencia del asegurado j .
- $Z(t)$: Factor de credibilidad que verifica $\lim_{t \rightarrow \infty} Z(t) = 1$, siendo t el número de expuestos al riesgo j o el período de observación de la póliza j . Por tanto, si $Z(t) = 1$ la experiencia del asegurado es creíble al 100 %, mientras que si

$Z(t) = 0$, $P_j = P_0$ y la prima del asegurado j coincide con la del colectivo al que pertenece dicha póliza.

La fórmula de credibilidad puede por tanto interpretarse también de la siguiente manera: puede considerarse a P_0 como la información a priori; $\bar{P}_j$ la nueva información obtenida mediante la observación de la siniestralidad del riesgo j y P_j el resultado de combinar la información a priori con la información adquirida. Por tanto,

Prima (a posteriori) = $[1 - Z(t)]$ Prima a priori + $Z(t)$ Experiencia observada.

Visto de esta manera, la teoría de la credibilidad sigue un esquema bayesiano, donde se da entrada a la información a priori con la información muestral, para obtener finalmente un estimador revisado de la prima.

La siguiente definición de teoría de la credibilidad fue propuesta por Hickmann (1975).

Definición 12.6 La teoría de la credibilidad es el mecanismo que permite el ajuste sistemático de las primas de seguros a medida que se obtiene la experiencia de siniestralidad.

Una de las principales aplicaciones de la teoría de la credibilidad se presenta en el seguro de automóviles, en el que la prima inicial se va modelando sucesivamente a medida que se incorpora la información de la siniestralidad. Son los denominados *sistemas de tarificación bonus-malus*. Se parte de un nivel x neutro, de modo que para niveles superiores a x el asegurado entra en la escala *malus* y para niveles inferiores a x el asegurado entra en la escala *bonus*.

Ejemplo 12.9 Comprobar que la prima Bayes obtenida en el ejemplo 12.4 se puede escribir como una fórmula de credibilidad.

Solución: La prima Bayes obtenida fue:

$$P(x) = (\nu + 1) \frac{a + t\bar{x}}{b + t\nu - 2},$$

que puede reescribirse como,

$$P(x) = \frac{(\nu + 1)t}{b + t\nu - 2} \bar{x} + \frac{a(\nu + 1)}{b + t\nu - 2}.$$

Ahora, multiplicando y dividiendo el primer sumando de esta expresión por ν y el segundo sumando por $b - 2$ resulta,

$$P(x) = \frac{\nu t}{b + t\nu - 2} \frac{\nu + 1}{\nu} \bar{x} + \frac{b - 2}{b + t\nu - 2} \frac{a(\nu + 1)}{b - 2},$$

que puede escribirse como

$$P(x) = Z(t) \left(\frac{\nu + 1}{\nu} \bar{x} \right) + [1 - Z(t)] P',$$

$$\text{con } Z(t) = \frac{\nu t}{b + t\nu - 2}.$$

◇

Ejemplo 12.10 Sean X_i variables aleatorias i.i.d. que siguen una distribución de Poisson de media θ , con función estructura gamma. Comprobar que la prima calculada bajo el principio de prima neta se puede escribir como una fórmula de credibilidad.

Solución: Si la distribución a priori es $\mathcal{G}(a, 1/b)$, sabemos que la distribución a posteriori es $\mathcal{G}(a + t\bar{x}, 1/(b + t))$. Utilizando (12.12) resulta:

$$P(x) = \frac{a + t\bar{x}}{b + t},$$

que puede reescribirse como

$$P(x) = \frac{t}{b + t} \bar{x} + \frac{b}{b + t} \frac{a}{b},$$

donde se ha multiplicado y dividido el segundo sumando por b . Entonces resulta:

$$P(x) = Z(t) \bar{x} + [1 - Z(t)] E(\theta),$$

$$\text{con } Z(t) = \frac{t}{b + t}.$$

◇

Ejemplo 12.11 Comprobar que la prima Bayes obtenida en el ejemplo 12.5 se puede escribir como una fórmula de credibilidad.

Solución: Es inmediato que (12.16) puede reescribirse como

$$Z(t) \bar{x} + [1 - Z(t)] P',$$

$$\text{con } Z(t) = \frac{rt}{b + tr - 1}.$$

◇

12.4.4. Modelo de Bühlmann de distribución libre

Dentro de los modelos de credibilidad clásicos más destacados figuran el modelo de Bühlmann de distribución libre y el modelo de Bühlmann-Straub. Ambos modelos constituyen el punto de partida de la moderna teoría de la credibilidad.

El objetivo de ambos modelos es estimar la prima correspondiente a un asegurado o grupo de asegurados que conforman una póliza en una cartera de seguros, restringiéndose a las primas lineales y utilizando el método de los mínimos cuadrados. La diferencia fundamental entre ambos modelos radica en que el segundo admite observaciones ponderadas. Nos limitaremos en este texto a considerar el modelo de Bühlmann de distribución libre. Lo relevante del modelo propuesto es la no necesidad de establecer hipótesis alguna, ni sobre la distribución que gobierna los riesgos individuales, ni sobre la distribución a priori de los parámetros de riesgo, de ahí el nombre de modelo de distribución libre.

Para su descripción consideremos de nuevo la cartera de seguros que aparece en la tabla 12.2, en la que θ_j representa el parámetro de riesgo para la póliza j -ésima. Se trata de una variable estructural que describe las características de riesgo del contrato j -ésimo. En la ciencia actuarial es costumbre considerar a dicho parámetro desconocido y aleatorio.

La variable X_{ij} representa la experiencia de reclamaciones para la póliza j -ésima en el período i -ésimo. Se trata de una variable aleatoria con realizaciones observables.

Denotaremos mediante

$$\mu(\theta_j) = E(X_{ij}|\theta_j),$$

a la prima de riesgo para la póliza j ,

$$m = E[P(\theta_j)],$$

al valor esperado de todas las primas de riesgo, es decir, la prima colectiva. Finalmente,

$$a = \text{Var}[\mu(\theta_j)],$$

es la varianza de las primas de riesgo, que es un indicador de la heterogeneidad de la cartera.

El objetivo del modelo de Bühlmann consiste en calcular la mejor prima lineal

$$\mathcal{H}(\mu(\theta_j)|X_{j1}, X_{j2}, \dots, X_{jt}),$$

dependiente de los datos observados, mediante el método de los mínimos cuadrados. Para ello establecemos la siguiente notación previa, en la que prescindiremos del subíndice j :

- $\mu(\theta) = E(X|\theta)$: Prima de riesgo individual
- $m = E_{\text{Total}}(X) = E[\mu(\theta)]$: Prima de riesgo colectiva. Valor esperado de todas las primas de riesgo individuales.
- $a = \text{Var}[E(X|\theta)] = \text{Var}[\mu(\theta)]$: Varianza de las primas de riesgo individuales, indicador de la heterogeneidad de la cartera.

- $s^2 = E[\text{Var}(X|\theta)]$: Medida global de la dispersión de la siniestralidad individual.

Se supone también que $X_1|\theta, X_2|\theta, \dots, X_t|\theta$ están idénticamente distribuidas con media y varianza comunes $\mu(\theta)$ y $\sigma^2(\theta)$, respectivamente. Antes de entrar en el modelo de Bühlmann necesitamos el siguiente resultado.

Proposición 12.5 Si X e Y son variables aleatorias con distribución conjunta dependiente de la variable aleatoria Θ se verifica:

$$\begin{aligned} E(X) &= E_{\Theta}[E_X(X|\Theta)], \\ \text{Cov}(X, Y) &= E[\text{Cov}(X, Y|\Theta)] + \text{Cov}[E(X|\Theta), E(Y|\Theta)]. \end{aligned} \quad (12.22)$$

Demostración: La primera relación ya ha sido demostrada en el teorema 4.9 del capítulo 4. En cuanto a la segunda tenemos:

$$\begin{aligned} \text{Cov}(X, Y) &= E\{[X - E(X)][Y - E(Y)]\} \\ &= E\{[X - E(X|\Theta) + E(X|\Theta) - E(X)][Y - E(Y|\Theta) + E(Y|\Theta) - E(Y)]\} \\ &= E_{\Theta}E_{X,Y|\Theta}\{[X - E(X|\Theta)][Y - E(Y|\Theta)]\} \\ &\quad + E_{\Theta}E_{X,Y|\Theta}\{[X - E(X|\Theta)][E(Y|\Theta) - E(Y)]\} \\ &\quad + E_{\Theta}E_{X,Y|\Theta}\{[E(X|\Theta) - E(X)][Y - E(Y|\Theta)]\} \\ &\quad + E_{\Theta}E_{X,Y|\Theta}\{[E(X|\Theta) - E(X)][E(Y|\Theta) - E(Y)]\} \\ &= E[\text{Cov}(X, Y|\Theta)] + 0 + 0 + \text{Cov}[E(X|\Theta), E(Y|\Theta)]. \end{aligned}$$

Obsérvese que de (12.22) se deduce:

$$\text{Var}(X) = E[\text{Var}(X|\theta)] + \text{Var}[E(X|\theta)], \quad (12.23)$$

haciendo $X = Y$.

Vamos a probar el resultado clásico de Bühlmann(1967).

Teorema 12.4 La mejor aproximación lineal a $\mathcal{H}(\mu(\theta)|X_1, \dots, X_t)$ es:

$$a + b\bar{X} = a + b\frac{1}{t} \sum_{i=1}^t X_i,$$

donde:

$$\begin{aligned} a &= (1-b)m, \\ b &= \frac{t}{t+k}, \\ k &= \frac{E[\sigma^2(\theta)]}{\text{Var}[\mu(\theta)]}. \end{aligned}$$

Demostración: Queremos encontrar la mejor estimación de la prima neta de riesgo que dependa linealmente de los datos observados, esto es:

$$\mathcal{H}(\mu(\theta)|X_1, \dots, X_t) = c_0 + \sum_{s=1}^t c_s X_s.$$

Para ello hagamos mínima la esperanza del cuadrado de la desviación de la prima de riesgo individual respecto a $\mathcal{H}(\mu(\theta)|X_1, \dots, X_t)$. Esto es:

$$\min_{c_i} E \left[\left(\mu(\theta) - c_0 - \sum_{s=1}^t c_s X_s \right)^2 \right].$$

Calculando las derivadas oportunas se obtiene el sistema de ecuaciones:

$$\left. \begin{aligned} E \left[\mu(\theta) - c_0 - \sum_{s=1}^t c_s X_s \right] &= 0, \\ E \left[X_r \left(\mu(\theta) - c_0 - \sum_{s=1}^t c_s X_s \right) \right] &= 0, \quad r = 1, 2, \dots, t. \end{aligned} \right\}$$

Multiplicando la primera ecuación por $E(X_r)$ y restándosela a la segunda obtenemos:

$$\text{Cov}[\mu(\theta), X_r] = \sum_{s=1}^t c_s \text{Cov}(X_r, X_s), \quad r = 1, 2, \dots, t. \quad (12.24)$$

Teniendo en cuenta ahora:

$$\begin{aligned} \text{Cov}(X_r, X_s) &= E[\text{Cov}(X_r, X_s|\theta)] + \text{Cov}[E(X_r|\theta), E(X_s|\theta)] = s^2 + a, \quad r \neq s \\ \text{Cov}(X_r, X_s) &= \text{Cov}[\mu(\theta), \mu(\theta)] = \text{Var}[\mu(\theta)] = a, \quad r = s, \end{aligned}$$

el sistema (12.24) puede reescribirse como:

$$\left. \begin{aligned} s^2 c_r + \sum_{s=1}^t c_s a &= a, \\ c_0 &= m - m \sum_{s=1}^t c_s, \end{aligned} \right\}$$

donde se ha tenido en cuenta que de $E[\mu(\theta) - c_0 - \sum_{s=1}^t c_s X_s] = 0$, y por tanto:

$$c_0 = E[\mu(\theta)] - \sum_{s=1}^t c_s E(X_s) = m - m \sum_{s=1}^t c_s.$$

12.4. La teoría de la credibilidad

Debido a la simetría del sistema resulta que $c_1 = \dots = c_t$, luego:

$$\left. \begin{aligned} s^2 c + atc &= a, \\ c_0 + mtc &= m. \end{aligned} \right\}$$

De donde se deduce:

$$\left. \begin{aligned} c &= \frac{a}{s^2 + at}, \\ c_0 &= m(1 - tc) = m \left(1 - \frac{ta}{s^2 + at} \right) = m \frac{s^2}{s^2 + at}. \end{aligned} \right\}$$

Por tanto,

$$\begin{aligned} \mathcal{H}(\mu(\theta)|X_1, \dots, X_t) &= c_0 + \sum_{s=1}^t c_s X_s = m \frac{s^2}{s^2 + at} + ct\bar{x} \\ &= m \frac{s^2}{s^2 + at} + \frac{at}{s^2 + at} \bar{x} = [1 - Z(t)]m + Z(t)\bar{x}, \end{aligned}$$

con:

$$Z(t) = \frac{at}{at + s^2} = \frac{t \text{Var}[\mu(\theta)]}{t \text{Var}[\mu(\theta)] + E[\sigma^2(\theta)]} = \frac{t}{t + k}.$$

Obsérvese que el resultado no depende de la distribución de probabilidad de X ni de la distribución de probabilidad de θ , de ahí el término de *distribución libre*.

Las cantidades $a = \text{Var}[\mu(\theta)]$, $s^2 = E[\sigma^2(\theta)]$ y $m = \bar{X}$ suelen llamarse parámetros estructurales del modelo y pueden estimarse a partir de:

$$\hat{m} = \frac{1}{k} \sum_{j=1}^k \bar{x}_j = \frac{1}{k} \sum_{j=1}^k \sum_{s=1}^t \frac{x_{js}}{t}, \quad (12.25)$$

$$\hat{s}^2 = \frac{1}{k} \sum_{j=1}^k \hat{s}_j^2, \quad \hat{s}_j^2 = \frac{1}{t-1} \sum_{s=1}^t (x_{js} - \bar{x}_j)^2, \quad (12.26)$$

$$\hat{a} = \frac{1}{k-1} \sum_{j=1}^k (\bar{x}_j - \bar{x})^2 - \frac{1}{t} \hat{s}^2. \quad (12.27)$$

Finalmente, puede probarse que estos estimadores son insesgados y consistentes. Esto es:

$$\begin{aligned} E(\hat{m}) &= m, \\ E(\hat{s})^2 &= s^2, \\ E(\hat{a}) &= a, \\ (\hat{m}, \hat{s}, \hat{a}) &\rightarrow (m, s^2, a), \text{ cuando } t \rightarrow \infty. \end{aligned}$$

Resulta interesante destacar las siguientes propiedades del factor de credibilidad. Se verifica que:

- $Z(t)$ es una función creciente en t , de modo que $Z(t) \rightarrow 1$ cuando $t \rightarrow \infty$, mientras que $Z(t) \rightarrow 0$ cuando $t \rightarrow 0$. Por tanto $t = 0$ supone que no se dispone de experiencia para el asegurado (se trata de un contrato nuevo), y la prima a cobrar en este caso es simplemente la prima colectiva. En la medida en que aumenta t , y por tanto se dispone de más datos, pesa más la información individual.
- $Z(t)$ es también una función creciente de la varianza de las medias teóricas, $a = \text{Var}[E(X|\theta)]$, con límite 1 cuando aquélla tiende a infinito y cero cuando tiende a cero. Esto es lógico, pues si la cartera no es heterogénea, $a = 0$, entonces la prima colectiva es el mejor estimador de la prima individual, mientras que una mayor heterogeneidad de la cartera debe suponer dar mayor peso a la información individual.
- $Z(t)$ es una función decreciente respecto al valor esperado de la varianza teórica, $s^2 = E[\text{Var}(X|\theta)]$, de modo que cuanto mayor sea la varianza del individuo menor peso se da a su experiencia individual y mayor a la del colectivo.

Ejemplo 12.12 Una compañía de seguros tiene dos grupos de asegurados en una póliza que cubre determinado riesgo. La cantidad total reclamada (en millones de u.m.) para los tres primeros años de vigencia de la póliza se recogen en la siguiente tabla

Año	Grupos	
	$k = 1$	$k = 2$
$t = 1$	5	10
$t = 2$	6	13
$t = 3$	17	13

Utilizar el modelo de Bühlmann de distribución libre para estimar la prima neta para el cuarto año de la póliza para cada uno de los dos grupos de asegurados.

Solución: El estimador del factor de credibilidad es:

$$\hat{Z}(t) = \frac{\hat{a}t}{\hat{s}^2 + \hat{a}t}.$$

Utilizando (12.25), (12.26) y (12.27) obtenemos que

$$\hat{m}_1 = 4, \quad \hat{m}_2 = 12, \quad \hat{m} = \bar{x} = 8,$$

$$\hat{s}_1^2 = 87, \quad \hat{s}_2^2 = 3, \quad \hat{s}^2 = 30,$$

$$\hat{a} = 22, \quad \hat{Z}(t) = 0,6875.$$

El estimador de la prima neta para los dos grupos de asegurados es:

$$\hat{Z}(t)\bar{x}_1 + [1 - \hat{Z}(t)]\hat{m} = 0,6875 \times 4 + 0,3125 \times 8 = 5,25,$$

$$\hat{Z}(t)\bar{x}_2 + [1 - \hat{Z}(t)]\hat{m} = 0,6875 \times 12 + 0,3125 \times 8 = 10,75.$$

Obsérvese que la experiencia individual contribuye a la prima en un 68,75 % y el grupo en un 31,25 %.

Ejemplo 12.13 Comprobar que el factor de credibilidad obtenido en el ejemplo 12.10 mediante la metodología bayesiana coincide con el de Bühlmann.

Solución: El factor de credibilidad obtenido fue,

$$Z(t)_{\text{Bayes}} = \frac{t}{b+t}.$$

Por otro lado, el factor de credibilidad de Bühlmann viene dado por:

$$Z(t)_{\text{Bühlmann}} = \frac{t \text{Var}[E(X|\theta)]}{t \text{Var}[E(X|\theta)] + E[\text{Var}(X|\theta)]}.$$

Ahora,

$$E(X|\theta) = \text{Var}(X|\theta) = \theta, \quad E[\text{Var}(X|\theta)] = E(\theta) = \frac{a}{b},$$

$$\text{Var}[E(X|\theta)] = \text{Var}(\theta) = E(\theta^2) - E^2(\theta) = \frac{a(a+1)}{b^2} - \left(\frac{a}{b}\right)^2 = \frac{a}{b^2}.$$

Por tanto,

$$Z(t)_{\text{Bühlmann}} = \frac{t \frac{a}{b^2}}{t \frac{a}{b^2} + \frac{a}{b}} = \frac{t}{b+t} = Z(t)_{\text{Bayes}}.$$

Ya se comentó que en la década de los años 50 y 60 del siglo XX Bailey (1950) y Mayerson (1964) probaron que la fórmula de credibilidad era el estimador Bayes (la prima Bayes) para determinadas combinaciones de verosimilitudes y distribuciones a priori. Por ejemplo, para los pares Poisson-gamma, binomial-beta, etc. Jewell (1974) demostró posteriormente que estos resultados no eran más que casos particulares del caso general consistente en considerar como verosimilitud la familia exponencial. Esto se pone de manifiesto en el siguiente resultado.

Teorema 12.5 Dados un riesgo X con función de densidad $f(x|\theta)$, y la distribución a priori del parámetro conjugada para esa verosimilitud, entonces el estimador de Bühlmann de la prima neta y el estimador bayesiano (la prima neta Bayes) coinciden cuando ambas distribuciones pertenecen a la familia exponencial.

Demostración: La demostración se llevará a cabo considerando la familia exponencial continua, dejando para el lector la demostración para el caso discreto. Así, dada la familia exponencial de la forma:

$$f(x|\theta) = \frac{a(x)e^{-\theta x}}{c(\theta)}, \quad \theta \in \Theta,$$

en la que $c(\theta)$ es la constante de normalización. La distribución a priori conjugada natural para esta verosimilitud es:

$$\pi(\theta) = \frac{[c(\theta)]^{-n_0} e^{-\theta x_0}}{d(n_0, x_0)}, \quad (12.28)$$

donde $d(n_0, x_0)$ es de nuevo una constante de normalización y n_0 y x_0 dos parámetros de la que depende. La distribución a posteriori es de nuevo del tipo (12.28), pero con los parámetros actualizados:

$$\begin{aligned} n_0 &\rightarrow n_0 + t, \\ x_0 &\rightarrow x_0 + \sum_{i=1}^t x_i. \end{aligned}$$

La prima neta de riesgo y la varianza de X vienen dadas por:

$$\begin{aligned} P(\theta) = \mu(\theta) &= -\frac{c'(\theta)}{c(\theta)}, \\ \text{Var}(X|\theta) &= \frac{c''(\theta)c(\theta) - c'(\theta)^2}{c(\theta)^2} = -\frac{d}{d\theta} [P(\theta)]. \end{aligned}$$

Derivando (12.28) con respecto a θ se obtiene:

$$\begin{aligned} \pi'(\theta) &= \frac{1}{d(n_0, x_0)} \left\{ -n_0 [c(\theta)]^{-n_0-1} c'(\theta) e^{-\theta x_0} - x_0 e^{-\theta x_0} [c(\theta)]^{-n_0} \right\} \\ &= \pi(\theta) \left[\frac{-n_0 c'(\theta)}{c(\theta)} - x_0 \right] = \pi(\theta) [n_0 \mu(\theta) - x_0]. \end{aligned} \quad (12.29)$$

Integrando ahora (12.29) sobre Θ tenemos:

$$\pi(\theta)|_{\Theta} = n_0 \int_{\Theta} \mu(\theta) \pi(\theta) d\theta - x_0,$$

y suponiendo que $\pi(\theta)$ se anula en los extremos de Θ resulta:

$$\int_{\Theta} \mu(\theta) \pi(\theta) d\theta = \frac{x_0}{n_0} = m.$$

12.5. Sistemas bonus-malus

Entonces:

$$\int_{\Theta} \mu(\theta) \pi(\theta) x_1, \dots, x_t d\theta = \frac{x_0 + \sum_{i=1}^t x_i}{n_0 + t} = [1 - Z(t)] m + Z(t) \bar{x},$$

con $Z(t) = \frac{t}{n_0 + t}$. Derivando (12.29) con respecto a θ queda:

$$\begin{aligned} \pi''(\theta) &= \pi'(\theta) [n_0 \mu(\theta) - x_0] + \pi(\theta) n_0 \frac{-c''(\theta)c(\theta) + c'(\theta)^2}{c(\theta)^2} \\ &= \pi(\theta) [n_0 \mu(\theta) - x_0]^2 - \pi(\theta) n_0 \text{Var}(X|\theta). \end{aligned}$$

Finalmente, integrando (12.30) con respecto a Θ resulta:

$$\begin{aligned} \int_{\Theta} \pi''(\theta) d\theta &= \int_{\Theta} [n_0 (\mu(\theta) - m)]^2 \pi(\theta) d\theta - n_0 E[\text{Var}(X|\theta)] \\ &= n_0 \{n_0 \text{Var}[\mu(\theta)] - E[\text{Var}(X|\theta)]\}. \end{aligned}$$

Teniendo en cuenta que si $\pi(\theta)$ se anula en los extremos de Θ , también lo hará su derivada, concluimos que

$$n_0 = \frac{E[\text{Var}(X|\theta)]}{\text{Var}[E(X|\theta)]} = \frac{s^2}{a},$$

y, por tanto, el factor de credibilidad $Z(t)$ es igual al de Bühlmann.

En definitiva, el estimador de credibilidad de Bühlmann es igual al estimador bayesiano de la prima en un gran número de casos. Esto ocurre, por ejemplo, si la distribución a priori es conjugada y la verosimilitud es un miembro de la familia exponencial, entonces el estimador de credibilidad de Bühlmann de la prima neta coincide con el estimador de credibilidad bayesiano. Así ocurre con los pares de distribuciones beta-binomial, normal-normal, gamma-exponencial y Poisson-gamma, como se puso de manifiesto en el ejemplo 12.13.

12.5. Sistemas bonus-malus

El sistema bonus-malus es un sistema de tarificación en el que la prima inicial se va modelando a medida que se incorpora la experiencia de siniestralidad. Para ello se parte de un nivel x neutro; para niveles inferiores a x el asegurado entra en la escala *bonus*, mientras que para niveles superiores a x , el asegurado se incorpora a la escala *malus*.

Este tipo de sistemas está generalmente basado en el número de reclamaciones, y no en la cuantía. Expresando la prima como una función del número medio de reclamaciones $\bar{x}$, $t\bar{x} = \sum_{i=1}^t x_i$, y del periodo de tiempo t , representaremos la prima bonus-malus mediante $P_{BM}(\bar{x}, t)$.

Lo relevante de este sistema de tarificación es que un asegurado que en el período actual no presente reclamación se verá bonificado en el siguiente período mediante un descuento en la prima a pagar. Por el contrario, si experimenta reclamación se verá penalizado con un incremento de la prima. Luego, tendrán que verificarse las siguientes reglas de transición:

$$\frac{\partial P_{BM}(\bar{x}, t)}{\partial \bar{x}} > 0, \quad \frac{\partial P_{BM}(\bar{x}, t)}{\partial t} < 0.$$

12.5.1. Cálculo de primas bonus-malus. Método bayesiano

Una forma de obtener primas que cumplan las reglas de transición, utilizando la metodología bayesiana, consiste en dividir la prima Bayes entre la prima colectiva para los principios de cálculo de prima estudiados. Denotando ahora mediante $P(x, t)$ a la prima Bayes, la prima bonus-malus puede obtenerse como:

$$P_{BM}(\bar{x}, t) = \frac{P(\bar{x}, t)}{P'}, \quad (12.30)$$

donde P' representa la prima colectiva.

Ejemplo 12.14 Obtener las expresiones de la prima bonus-malus para los principios de cálculo de prima neta, exponencial, Esscher y varianza.

Solución: Utilizando las expresiones (12.30), (12.8) y (12.12), se deduce que la prima bonus-malus bajo el principio de prima neta es:

$$P_{BM}(\bar{x}, t) = \frac{E_{\pi(\theta|x)} [E_{f(x|\theta)} (X|\theta)]}{E_{\pi(\theta)} [E_{f(x|\theta)} (X|\theta)]}. \quad (12.31)$$

Utilizando (12.30), (12.9) y (12.13), se deduce que la prima bonus-malus bajo el principio de prima exponencial es:

$$P_{BM}(\bar{x}, t) = \frac{\log \{E_{\pi(\theta|x)} [e^{\alpha P(\theta)}]\}}{\log \{E_{\pi(\theta)} [e^{\alpha P(\theta)}]\}}, \quad (12.32)$$

donde

$$P(\theta) = \frac{1}{\alpha} \log \int_{\Theta} e^{\alpha x} f(x|\theta) dx.$$

Utilizando (12.30), (12.10) y (12.14), se deduce que la prima bonus-malus bajo el principio de prima Esscher es:

$$P_{BM}(\bar{x}, t) = \frac{E_{\pi(\theta|x)} [P(\theta) e^{\alpha P(\theta)}]}{E_{\pi(\theta|x)} [e^{\alpha P(\theta)}]} \frac{E_{\pi(\theta)} [e^{\alpha P(\theta)}]}{E_{\pi(\theta)} [P(\theta) e^{\alpha P(\theta)}]},$$

donde

$$P(\theta) = \frac{E_{f(x|\theta)} (X e^{\alpha X} | \theta)}{E_{f(x|\theta)} (e^{\alpha X} | \theta)}.$$

Finalmente, utilizando (12.30), (12.11) y (12.15), se deduce que la prima bonus-malus bajo el principio de prima de varianza es:

$$P_{BM}(\bar{x}, t) = \frac{E_{\pi(\theta|x)} [P(\theta)^2]}{E_{\pi(\theta|x)} [P(\theta)]} \frac{E_{\pi(\theta)} [P(\theta)]}{E_{\pi(\theta)} [P(\theta)^2]},$$

donde

$$P(\theta) = \frac{E_{f(x|\theta)} (X^2 | \theta)}{E_{f(x|\theta)} (X | \theta)}.$$

Ejemplo 12.15 Si el número de reclamaciones en una cartera de seguro de automóviles sigue la distribución de Poisson de parámetro θ , donde el parámetro θ sigue en el colectivo una distribución gamma, se pide obtener la prima bonus-malus bajo el principio de prima neta.

Solución: Utilizando (12.31) se deduce:

$$P_{BM}(\bar{x}, t) = \frac{a + t\bar{x}}{b + t} \frac{b}{a}, \quad \text{con } \sum_{i=1}^t x_i = t\bar{x}. \quad (12.33)$$

Ejemplo 12.16 La tabla 12.3 muestra el número de asegurados para las reclamaciones $x = 0, 1, \dots$ en una cartera de seguros de automóviles. Esta cartera de seguros está extraída de Lemaire (1979). Suponiendo que el modelo queda bien explicado con una verosimilitud Poisson y una distribución a priori gamma, se pide:

1. Obtener la distribución incondicional del número de reclamaciones.
2. Estimar mediante el método de los momentos los parámetros de la distribución gamma.
3. Obtener la tabla de frecuencias ajustadas.
4. Obtener una matriz de orden 4×6 en la que el elemento a_{ij} , $i = 1, 2, 3, 4$; $j = 1, 2, \dots, 6$ sea el porcentaje de prima a aplicar en el período i con j reclamaciones, bajo un sistema de tarificación bonus-malus y el principio de prima neta.

Tabla 12.3: Frecuencias observadas (Lemaire, 1979)

Número de reclamaciones	Frecuencias absolutas observadas
0	96978
1	9240
2	704
3	43
4	9
Más de 4	0
Total	106974

Solución:

1. Puesto que $X|\theta \sim \mathcal{P}(\theta)$ y $\theta \sim \mathcal{G}(a, 1/b)$, la distribución incondicional es una $\mathcal{BN}\left(a, \frac{b}{b+1}\right)$ por el teorema 6.5.
2. La media y la varianza de la distribución binomial negativa son $a\frac{1-p}{p}$ y $a\frac{1-p}{p^2}$, respectivamente, donde en nuestro caso $p = \frac{b}{b+1}$. La media y la varianza de la distribución observada son $\bar{x} = 0,1011$ y $s^2 = 0,1074$, respectivamente. Luego, utilizando el método de los momentos (ecuaciones (9.5) y (9.6)) resolvemos el sistema:

$$\begin{cases} a\frac{1-p}{p} = 0,1011, \\ a\frac{1-p}{p^2} = 0,1074, \end{cases}$$

y obtenemos los estimadores $\hat{a} = 1,6049$ y $\hat{b} = 15,8778$.

3. Las frecuencias observadas y esperadas del modelo aparecen en la tabla 12.4.
4. Utilizando (12.33) se obtiene la matriz pedida, que aparece representada en la tabla 12.5.

◇

12.5.2. Penalización de las sobrecargas

El propósito principal de los sistemas de tarificación bonus-malus es que los asegurados paguen una prima justa, esto es, la prima que corresponda a su propia

Tabla 12.4: Frecuencias observadas y ajustadas

Número de reclamaciones	Frecuencias absolutas	
	Observadas	Ajustadas
0	96978	96895,5
1	9240	9222,5
2	704	711,7
3	43	50,7
4	9	3,6
Más de 4	0	0
Total	106974	106974

Tabla 12.5: Primas bonus-malus

t	t $\bar{x}$						
	0	1	2	3	4	5	6
0	100						
1	94,07	152,69	211,30	269,92	328,54	387,16	445,79
2	88,81	144,15	199,48	254,82	310,16	365,51	420,24
3	84,10	136,51	188,92	241,32	293,73	346,14	398,55
4	79,87	129,64	179,41	229,18	278,95	328,73	378,50

experiencia de reclamación. Sin embargo, la mayoría de estos sistemas penalizan injustamente a determinados asegurados, haciéndoles pagar más de lo que realmente les corresponde. Por otro lado, en muchas ocasiones las bonificaciones establecidas son pequeñas, lo que puede acarrear serios problemas de competitividad y, en consecuencia, de equilibrio financiero a la compañía aseguradora (Baione et al., 2002, pp. 159–160). Además, es costumbre en el mercado de seguro de automóviles, que el asegurado cambie de compañía aseguradora buscando precios más competitivos, más si tenemos en cuenta que cuando un asegurado cambia de compañía se lleva consigo su historial de siniestralidad, pudiendo por tanto mantener su bonificación. Esto obviamente representa un problema para la compañía aseguradora, pues los asegurados situados en la clase bonus ($t\bar{x} = 0$) pueden optar por abandonar dicha compañía para asegurarse en otra con precios más bajos. Además, para la compañía, el perder los ingresos que le reporta estos clientes supone no poder compensar el balance de la empresa, pues aunque los asegurados situados en las clases malus ($t\bar{x} > 0$) paguen más, es generalmente una población menos

numerosa la que figura en estas clases.

Por otro lado, también puede argumentarse en este otro sentido. La experiencia demuestra que los asegurados situados en la clase bonus prefieren pagar una prima ligeramente mayor ahora de modo que si incurren en una reclamación al año siguiente su prima no se incremente demasiado.

Diversos modelos se han elaborado tratando de resolver estos conflictos. El primero de estos modelos fue propuesto por Ferreira (1977), que puede verse también en Lemaire (1979, 1985, 1995), en el que se propone un modelo que aumente ligeramente las primas que pagan los asegurados bonus como contrapartida a la disminución de las primas pagadas por los asegurados malus. En Gómez-Déniz y León (2005) se propone un mecanismo similar con la función de pérdida Esscher que realiza el proceso contrario. Ver también Sarabia et al. (2004).

Las ideas sobre penalización fueron inicialmente propuestas por Lemaire (1979), donde el autor expone un procedimiento para reducir el porcentaje de incremento de la prima que permite mantener el ajuste presupuestario de la compañía aseguradora. Para ello se utilizará el principio exponencial, minimizando la diferencia entre la prima $P(x, t)$ y el valor del parámetro θ , sujeto a la restricción presupuestaria. Así, denominando m al número máximo de clases en la cartera, N_x al número de asegurados en dichas clases y $N = \sum_{x=0}^m N_x$, formalmente el problema a resolver tendrá la siguiente formulación:

$$\left. \begin{aligned} \text{Min. } & \frac{1}{N} \sum_{x=0}^m N_x \int_{\Theta} \frac{1}{\alpha} \left[e^{\alpha\theta - e^{\alpha P(x, t)}} \right]^2 \pi(\theta|x) d\theta, \\ \text{s.a. } & \frac{1}{N} \sum_{x=0}^m N_x P(x, t) = E(\theta). \end{aligned} \right\} \quad (12.34)$$

Mediante la formulación de este problema el asegurado minimiza la pérdida esperada de la operación de aseguramiento sujeta a la restricción que permite el equilibrio financiero.

La solución a este problema de optimización restringida se presenta en la siguiente proposición.

Proposición 12.6 La solución del problema de optimización (12.34) viene dada por:

$$\begin{aligned} P(\bar{x}, t) &= E(\theta) + \frac{1}{\alpha} \left[\frac{1}{N} \sum_{x=0}^m N_x \log \int_{\Theta} e^{-\alpha\theta} \pi(\theta|x) d\theta \right. \\ &\quad \left. - \log \int_{\Theta} e^{-\alpha P(\theta)} \pi(\theta|\bar{x}) d\theta \right]. \end{aligned} \quad (12.35)$$

Demostración: El problema planteado equivale al problema de maximización:

$$\begin{aligned} \text{Max. } & \frac{1}{N} \sum_{x=0}^m N_x \int_{\Theta} \frac{1}{\alpha} \left\{ 1 - e^{\alpha[\theta - P(\bar{x}, t)]} \right\} \pi(\theta|x) d\theta, \\ \text{s.a. } & \frac{1}{N} \sum_{x=0}^m N_x P(\bar{x}, t) = E(\theta). \end{aligned} \quad (12.36)$$

La función lagrangiana es:

$$\begin{aligned} \psi &= \frac{1}{N} \sum_{x=0}^m N_x \int_{\Theta} \frac{1}{\alpha} \left\{ 1 - e^{\alpha[\theta - P(\bar{x}, t)]} \right\} \pi(\theta|x) d\theta \\ &\quad - \beta \left(\frac{1}{N} \sum_{x=0}^m N_x P(\bar{x}, t) - E(\theta) \right), \end{aligned}$$

en la que β es el correspondiente multiplicador de Lagrange. Ahora,

$$\begin{aligned} \frac{\partial \psi}{\partial \beta} = 0 &\implies \frac{1}{N} \sum_{x=0}^m N_x P(\bar{x}, t) = E(\theta), \\ \frac{\partial \psi}{\partial P(\bar{x}, t)} = 0 &\implies \int_{\Theta} e^{\alpha P(\bar{x}, t)} e^{-\alpha\theta} \pi(\theta|x) d\theta = \beta, \quad \bar{x} = 0, \dots, m. \end{aligned}$$

Tomando logaritmos en ambos lados en la última igualdad y despejando $P(\bar{x}, t)$ se obtiene:

$$P(\bar{x}, t) = \frac{1}{\alpha} \log \beta - \frac{1}{\alpha} \log \int_{\Theta} e^{-\alpha\theta} \pi(\theta|x) d\theta. \quad (12.37)$$

Dividiendo ahora por N , multiplicando por N_x y sumando para todo x resulta:

$$\frac{1}{N} \sum_{x=0}^m N_x P(\bar{x}, t) = \frac{1}{\alpha} \log \beta - \frac{1}{N\alpha} \sum_{x=0}^m N_x \log \int_{\Theta} e^{-\alpha\theta} \pi(\theta|x) d\theta.$$

Finalmente, despejando de esta expresión $\frac{1}{\alpha} \log \beta$, sustituyendo en (12.37) y teniendo en cuenta (12.36) se obtiene el resultado. $\square$

Ahora podemos construir una prima bonus-malus como el cociente:

$$F_{BM}(\bar{x}, t) = \frac{P(\bar{x}, t)}{P(0, 0)}. \quad (12.38)$$

Ejemplo 12.17 El número de reclamaciones de una cartera de seguro de automóviles sigue una distribución de Poisson de parámetro θ , y se conoce que este parámetro sigue en el colectivo de asegurados una distribución a priori gamma con parámetros 2 y 1/5. Se pide:

1. Si la constante de aversión al riesgo es $\alpha = 0,4$, calcular las primas bonus-malus utilizando el principio de utilidad exponencial.
2. Si se sabe que los asegurados están distribuidos en la cartera de la forma en que aparece en la tabla 12.6 (Gómez-Déniz et al., 2005), calcular de nuevo las primas bonus-malus utilizando la expresión (12.38) tomando $\alpha = 15$.

Tabla 12.6: Número de asegurados en la cartera en cada una de las clases

t	$t\bar{x}$			
	0	1	2	≥ 3
0	1486			
1	1125	274	69	18
2	322	458	154	52
3	601	523	247	115

Solución: Bajo el principio exponencial la prima de riesgo se calcula como:

$$P(\theta) = \frac{1}{\alpha} \log \int e^{\alpha x} f(x|\theta) dx = \frac{1}{\alpha} \log e^{\theta(e^{\alpha}-1)} = \frac{\theta}{\alpha} (e^{\alpha} - 1).$$

Ahora, de (12.32) se deduce:

$$P_{BM}(\bar{x}, t) = \frac{a + t\bar{x} \log \left(\frac{b+t}{b+t-e^{\alpha}-1} \right)}{a \log \left(\frac{b}{b-e^{\alpha}-1} \right)}.$$

Las primas correspondientes, multiplicadas por 100 aparecen en la tabla 12.7. Utilizando (12.38), donde ahora $P(\bar{x}, t)$ es como en (12.35), y multiplicando el

Tabla 12.7: Número de asegurados en la cartera en cada una de las clases

t	$t\bar{x}$			
	0	1	2	≥ 3
0	100			
1	82,59	123,89	165,19	206,49
2	70,35	105,53	140,71	175,89
3	61,27	91,91	122,55	153,19

12.5. Sistemas bonus-malus

resultado por 100 se obtienen las nuevas primas que aparecen en la tabla 12.8. Comparando ahora los valores en las tablas 12.7 y 12.8 se observa que el porcentaje de incremento de las primas, y por tanto las penalizaciones, han disminuido para $t\bar{x} > 1$, mientras que la prima para los asegurados pertenecientes a la clase $t\bar{x} = 0$ se han incrementado ligeramente. Estos porcentajes se han reflejado en la tabla 12.9. En esta tabla aparece el porcentaje de incremento de la prima cuando el asegurado se mueve de una clase a otra como consecuencia de experimentar un incremento en el número de reclamaciones, dado por $\Delta t\bar{x}$, para el caso inicial de la tabla 12.7 y el de las primas en la tabla 12.8 (en negrita). Obsérvese que esto se ha logrado con ligeros incrementos en las primas para el grupo de los buenos asegurados y ligeros decrementos en las primas para los malos asegurados.

Tabla 12.8: Nuevas primas, $\alpha = 15$

t	$t\bar{x}$			
	0	1	2	≥ 3
0	100			
1	94,04	113,80	133,56	153,32
2	89,39	107,51	125,63	143,75
3	85,93	102,69	119,45	136,20

Tabla 12.9: Porcentaje de incremento de la penalización

t	$\Delta t\bar{x}$		
	1	2	3
0	23,89	65,19	106,49
	13,80	33,56	53,22
1	27,22	70,37	112,96
	14,32	33,60	52,86
2	30,64	74,20	117,75
	14,87	33,62	52,36

Procedimientos similares pueden implementarse para el resto de principios de cálculo de prima. ◇

12.5.3. Método markoviano

Un sistema bonus-malus puede también verse como un proceso de Markov, en el sentido de que el asegurado se mueve de un estado a otro en el tiempo. Veamos un ejemplo sencillo para ilustrar estas ideas. Supongamos que una compañía de seguros divide las pólizas en 3 clases C_1 , C_2 y C_3 , en la que la prima para la clase C_i es menor que la prima para la clase C_j para $i < j$. El asegurado comienza en la clase C_1 . Si reclama un siniestro por el que la compañía tenga que pagar una indemnización a un tercero pasará de la clase C_1 , en la que actualmente está situado, a la clase C_2 al principio del año siguiente. Si el asegurado no reclama permanecerá en la clase en la que estaba, esto es C_1 . Ahora, si un asegurado está en la clase C_2 pasará a la clase C_3 si reclama y volverá a la clase C_1 si no reclama. Finalmente, si el asegurado está en la clase C_3 y experimenta reclamación permanecerá en esta clase al año siguiente, mientras que pasará a la clase C_1 si no reclama. De esta forma, el asegurado puede ver cada año bonificada o penalizada su prima si no experimenta o experimenta reclamación, respectivamente, a excepción de si está en la clase C_3 en la que permanecerá igual que estaba o se le bonificará.

Vamos a suponer además que la probabilidad de experimentar reclamación en un año es p y que no depende de cómo el asegurado llegó a la clase en la que está situado actualmente. Considerando el problema desde un punto de vista estocástico podemos decir que cada una de las clases corresponde a un estado de un sistema, cuya matriz de transición de probabilidades es $P = (p_{ij})$, $i, j = 1, 2, 3$, donde p_{ij} representa la probabilidad de transición del estado i al estado j . La matriz de transición para esta situación viene dada por:

$$P = \begin{bmatrix} q & p & 0 \\ q & 0 & p \\ q & 0 & p \end{bmatrix},$$

en la que $q = 1 - p$ es la probabilidad de no experimentar reclamación. Ahora p_{ij} es la probabilidad de transición de la clase C_i a la clase C_j . La matriz P es una matriz estocástica en la que cada fila representa una distribución de probabilidad de cada uno de los estados existentes. Luego $\sum_{j=1}^3 p_{ij} = 1$, para todo i .

El objetivo ahora es hallar la probabilidad de que los asegurados se encuentren en una clase determinada después de t años. Para ello podemos proceder de la siguiente forma. Si suponemos que para $t = 0$, la probabilidad de que cada asegurado se sitúe en el estado $j = 1, 2, 3$ es e_j , y obviamente $\sum_{j=1}^3 e_j = 1$, entonces,

$$\begin{aligned} m(1) &= (e_1, e_2, e_3)P = (q, e_1p, (e_2 + e_3)p), \\ m(2) &= m(1)P = (q, pq, p^2), \\ m(3) &= m(2)P = m(1)P^2 = (q, pq, p^2), \\ m(4) &= m(5) = \dots = m(\infty) = (q, pq, p^2). \end{aligned}$$

El vector $m(\infty)$ se denomina distribución de estado estacionario, y aunque en este caso la convergencia hacia el mismo ha sido inmediata, no siempre ocurre así.

Obsérvese que

$$\lim_{t \rightarrow \infty} m(t+1) = \lim_{t \rightarrow \infty} m(t)P,$$

luego $m(\infty) = m(\infty)P$, de donde se deduce que un procedimiento alternativo de obtener la distribución de estado estacionario, $m(\infty)$, es encontrar las soluciones no triviales del sistema homogéneo $(P^t - I)m(\infty) = (0, \dots, 0)'$ y normalizar el vector solución, esto es dividirlo por la raíz cuadrada de la suma de sus componentes al cuadrado, para hacer que $m(\infty)$ sea una distribución de probabilidad. Esto es equivalente a calcular los vectores propios de la matriz de transición de probabilidades P .

12.6. Reaseguros

El reaseguro es un instrumento del que dispone la empresa aseguradora para acomodar la estructura de riesgos asumido a su capacidad financiera. De forma muy simple, podemos decir que el reaseguro es el seguro de las compañías de seguros.

Definición 12.7 *Un reaseguro es una operación por la cual un asegurador distribuye sus riesgos, cediendo parte de los mismos a otra u otras entidades reaseguradoras con el objetivo de reducir el volumen de las pérdidas a unos límites soportables por la entidad aseguradora.*

A través de este instrumento una compañía aseguradora, la compañía cedente, traslada la totalidad o parte de los riesgos asumidos a otra empresa aseguradora, la compañía aceptante, a quien paga una prima de reaseguro por el riesgo asumido. La parte de riesgo transferida se denomina cesión y la parte no cedida de retención o pleno. Aunque por un lado mediante el reaseguro se reduce el riesgo para la compañía cedente, por otro lado tiene como contrapartida una reducción del beneficio esperado.

El contrato de reaseguro implica que si se produce un siniestro, el responsable frente al asegurado es el asegurador directo (la empresa cedente) que posteriormente repercutirá la parte correspondiente a la empresa reaseguradora en la forma que estipule el contrato acordado entre las partes. A su vez, la compañía reaseguradora puede hacer lo mismo, reasegurando parte del riesgo a una tercera compañía, y así sucesivamente, como se muestra en la figura 12.1.

Esta línea de actuación es común en los seguros contra grandes catástrofes, como terremotos, inundaciones o accidentes en centrales nucleares, por poner algunos ejemplos. Aunque también resulta conveniente el reaseguro para cubrir aumentos inesperados de la inflación. En general esta modalidad de seguro es susceptible de aplicarse cuando se espera que la varianza del riesgo sea grande.




Figura 12.1: Transferencias de riesgos a través del reaseguro

De entre las modalidades de reaseguros existentes, trataremos aquí las dos más conocidas: el reaseguro proporcional y el reaseguro *excess loss*. El reaseguro *stop-loss* es una adaptación del reaseguro *excess loss* a la cartera en su totalidad, de modo que todo lo que se comente en relación a los reaseguros *excess loss* es aplicable a los reaseguros *stop-loss*. Las franquicias, que no constituye de por sí un tipo de reaseguro pueden también ser contempladas como un caso particular de un reaseguro *excess loss*.

12.6.1. Reaseguro proporcional

En este caso la cesión es proporcional al riesgo asumido por la compañía cedente.

12.6. Reaseguros

Definición 12.8 Un reaseguro proporcional es una modalidad de reaseguro por la que el reasegurador recibe una cierta proporción de la prima original pagando la misma proporción de todas las pérdidas.

Si X es la variable aleatoria representativa del riesgo con función de distribución $F(x)$, entonces la compañía cedente paga una proporción fija a , mientras que el porcentaje restante $1-a$, lo paga la compañía aceptante. Si denominamos mediante Y la parte pagada por el asegurador y Z la parte pagada por el reasegurador, obviamente se cumple que

$$Y = aX, \quad Z = (1-a)X, \quad X = Y + Z.$$

Entonces las variables aleatorias Y y Z son transformaciones de escala de la variable aleatoria X y por tanto, en término de funciones de distribución se verifica:

$$\Pr(Y \leq x) = \Pr(aX \leq x) = \Pr(X \leq x/a) = F(x/a).$$

Ejemplo 12.18 Una compañía de reaseguro ha suscrito un contrato de reaseguro en la modalidad proporcional. Calcular la prima neta de riesgo de reaseguro, suponiendo que el riesgo X sigue una distribución gamma $\mathcal{G}(c, 1/\theta)$.

Solución: Por el teorema 5.11 tenemos:

$$f_Z(z) = f_X(z/(1-a)) \frac{1}{1-a} = \frac{\theta^c z^{c-1}}{\Gamma(c)(1-a)^c} e^{-\theta z/(1-a)},$$

que es una distribución gamma con parámetros c y $(1-a)/\theta$. Por tanto la prima neta de riesgo de reaseguro es:

$$P(\theta) = (1-a) \frac{c}{\theta}.$$

◇

12.6.2. Reaseguro excess loss

Definición 12.9 Un reaseguro *excess loss* es una modalidad de reaseguro por la cual el reasegurador cubre la parte del siniestro que excede del pleno fijado por la cedente para cada siniestro.

En esta modalidad, llamada también semicolectiva, el reasegurador asume la parte de cada siniestro que supera una determinada cantidad. Esta cantidad recibe el nombre de *cesión* en los seguros vida y *deducible* en los seguros no vida.

Así, si denotamos mediante M el pleno o deducible fijado por la cedente para cada siniestro:

1. Si $X \leq M$, el responsable es el asegurador y no hay reaseguro.

2. Si $X > M$, existe el reaseguro y éste cubre $X - M$,

donde X es la variable aleatoria asociada a la cuantía del siniestro. Por tanto, el asegurador paga $Y = \min\{X, M\}$, mientras que el reasegurador paga $Z = \max\{0, X - M\}$. Como ya se comentó en el capítulo 5, $\max\{0, X - M\}$ se representa también como $(X - M)_+$. Analicemos ahora el efecto del reaseguro *excess loss* sobre el asegurador y el reasegurador.

Punto de vista del asegurador

Si $F_Y(x)$ es la función de distribución asociada a la variable $Y = \min\{x, M\} = x \wedge M$ se verificará:

$$F_Y(x) = \begin{cases} F(x), & x \leq M, \\ 1, & x \geq M. \end{cases}$$

Ahora tenemos que

$$E(Y^n) = \int_0^\infty [\min\{X, M\}]^n f(x) dx,$$

y, teniendo en cuenta que:

$$\min\{X, M\} = \begin{cases} x, & 0 \leq x \leq M, \\ M, & x \geq M, \end{cases}$$

y dado que:

$$E(X \wedge M)^n = \int_0^M x^n f(x) dx + M^n [1 - F(M)],$$

tenemos que los pagos medios del asegurador son:

$$E(Y) = \int_0^M x f(x) dx + M [1 - F(M)]. \quad (12.39)$$

Ejemplo 12.19 Calcular la derivada, $\frac{dE(Y)}{dM}$, y los límites,

$$\lim_{M \rightarrow 0} E(Y), \quad \lim_{M \rightarrow \infty} E(Y).$$

Solución: Es inmediato probar que:

$$\frac{d}{dM} E(Y) = 1 - F(M) > 0, \quad \lim_{M \rightarrow 0} E(Y) = 0, \quad \lim_{M \rightarrow \infty} E(Y) = E(X).$$

La primera relación nos dice que el pago medio es una función creciente de M , que es lógico ya que un incremento de la retención tendrá como consecuencia un incremento de los pagos por parte de la compañía aseguradora. Esto puede verse en la figura 12.2, así como la interpretación de las otras dos relaciones.




Figura 12.2: Pagos medios en función de M desde el punto de vista del asegurador

Punto de vista del reasegurador

Si denotamos mediante $F_Z(x)$ la función de distribución asociada a la variable aleatoria $Z = (X - M)_+$, tenemos:

$$F_Z(x) = \begin{cases} F(M), & x = 0, \\ F(x + M), & x \geq 0, \end{cases}$$

luego, ahora:

$$E(Z^n) = \int_0^\infty [\max\{0, x - M\}]^n f(x) dx,$$

y, puesto que $\max\{0, x - M\} = 0$ si $0 \leq x \leq M$, tenemos:

$$E(Z^n) = \int_M^\infty (x - M)^n f(x) dx.$$

Ejemplo 12.20 Si X sigue una distribución exponencial con parámetro $\lambda > 0$, se pide calcular la función generatriz de momentos, $M_Z(t)$, así como $E(Z^j)$, $j = 0, 1, \dots$

Solución:

$$\begin{aligned} M_Z(t) &= \int_0^\infty e^{tZ} f(x) dx = \int_0^\infty e^{t \max\{0, x-M\}} \lambda e^{-\lambda x} dx \\ &= \int_0^M e^{t \max\{0, x-M\}} \lambda e^{-\lambda x} dx + \int_M^\infty e^{t \max\{0, x-M\}} \lambda e^{-\lambda x} dx. \end{aligned}$$

Ahora, teniendo en cuenta que en $[0, M]$, $X - M < 0$ entonces $\max\{0, X - M\} = 0$, y que en $[M, \infty)$, $X - M > 0$ y por tanto $\max\{0, X - M\} = X - M$, tenemos:

$$\begin{aligned} M_Z(t) &= \int_0^M \lambda e^{-\lambda x} dx + \int_M^\infty e^{t(x-M)} \lambda e^{-\lambda x} dx \\ &= 1 - e^{-\lambda M} + \lambda e^{-tM} \int_M^\infty e^{x(t-\lambda)} dx \\ &= 1 - e^{-\lambda M} + \frac{\lambda e^{-\lambda M}}{\lambda - t}, \quad \lambda > t. \end{aligned}$$

Por otro lado, $E(Z) = M'_Z(0) = \lambda^{-1} e^{-\lambda M}$, y se deduce que $E(Z^j) = \lambda^{-j} e^{-\lambda M}$, $j = 0, 1, \dots$

◇

Ejemplo 12.21 Calcular la prima de reaseguro *excess loss* para el principio de prima neta y el principio exponencial si la función de distribución de X es $F(x)$.

Solución:

$$\begin{aligned} P_R(M) &= \int_0^\infty \max\{0, x - M\} f(x) dx \\ &= \int_0^M \max\{0, x - M\} f(x) dx + \int_M^\infty \max\{0, x - M\} f(x) dx \\ &= \int_M^\infty (x - M) f(x) dx, \end{aligned} \quad (12.40)$$

ya que $\max\{0, X - M\} = 0$ para $x \in [0, M]$ y es $x - M$ para $x \in [M, \infty]$. Ahora haciendo el cambio de variable $t = x - M$, resulta:

$$\begin{aligned} P_R(M) &= \int_M^\infty (x - M) f(x) dx = \int_0^\infty t f(t + M) dt \\ &= \int_0^\infty [1 - F(t + M)] dt = \int_M^\infty [1 - F(x)] dx, \end{aligned}$$

para el principio de prima neta. Para el principio exponencial tenemos que, mediante integración por partes:

$$P_R(M) = \frac{1}{\alpha} \log \int_0^\infty e^{\alpha \max\{0, x-M\}} f(x) dx$$

$$\begin{aligned} &= \frac{1}{\alpha} \log \left\{ \int_0^M f(x) dx + \int_M^\infty e^{\alpha(x-M)} f(x) dx \right\} \\ &= \frac{1}{\alpha} \log \left\{ 1 + \alpha \int_M^\infty e^{\alpha(x-M)} [1 - F(x)] dx \right\}. \end{aligned}$$

◇

Ejemplo 12.22 Calcular la derivada $\frac{dP_R(M)}{dM}$, y los límites,

$$\lim_{M \rightarrow 0} P_R(M), \quad \lim_{M \rightarrow \infty} P_R(M)$$

para la prima neta del reasegurador.

Solución: Se comprueba que en este caso:

$$\frac{d}{dM} P_R(M) = F(M) - 1 < 0, \quad \lim_{M \rightarrow 0} P_R(M) = E(X), \quad \lim_{M \rightarrow \infty} P_R(M) = 0.$$

Ahora, obviamente, $P_R(M)$ es una función decreciente de M y la prima disminuye conforme aumenta la retención M . Esto se ilustra en la figura 12.3.




Figura 12.3: Prima neta excess loss en función de M . Punto de vista del reasegurador

◇

Ejemplo 12.23 Calcular los pagos medios para el reasegurador considerando un contrato de reaseguro *excess loss* si la variable aleatoria X sigue una distribución gamma $\mathcal{G}(a, 1/b)$.

Solución: Denotando mediante $f(x)$ la función de densidad de la variable aleatoria gamma, con distribución $F(x)$, y utilizando (12.39) se deduce:

$$E(Y) = \frac{a}{b} F^*(M) + M[1 - F(M)],$$

donde se ha tenido en cuenta:

$$\int_0^M x f(x) dx = \frac{a}{b} F^*(M),$$

siendo F^* la función de distribución de la variable aleatoria gamma con parámetros $a + 1$ y $1/b$.

Ahora utilizando (12.40) se deduce:

$$\begin{aligned} E(Z) &= \int_0^\infty (x - M) f(x) dx - \int_0^M (x - M) f(x) dx \\ &= \frac{a}{b} - M - M F(M) - \int_0^M x f(x) dx. \\ &= \frac{a}{b} [1 - F^*(M)] + M [F(M) - 1]. \end{aligned} \quad (12.41)$$

Obsérvese que esta última expresión no es más que la prima neta de reaseguro. $\diamond$

Ejemplo 12.24 Calcular los pagos medios para el asegurador y reasegurador considerando un contrato de reaseguro *excess loss* si la variable aleatoria X sigue una distribución gamma con parámetros $\mathcal{G}(5, 1/2)$ para valores de M entre 0 y 10.

Solución: Utilizando (12.39) y (12.41) se obtienen los valores pedidos que aparecen en la tabla 12.10. $\diamond$

Ejemplo 12.25 (Dickson, 2005) Hallar la función de densidad de V , siendo V la variable aleatoria que nos da los pagos (mayores que cero) hechos por el reasegurador.

Solución:

$$\begin{aligned} F_V(v) &= \Pr(V \leq v) = \Pr(Z \leq v | Z > 0) = \Pr(X \leq v + M | X > M) \\ &= \frac{\Pr(M < X \leq v + M)}{\Pr(X > M)} = \frac{F(v + M) - F(M)}{1 - F(M)}. \end{aligned}$$

Tabla 12.10: Pagos medios de asegurador y reasegurador

M	Asegurador	Reasegurador
0,0	0,000000	2,5000000000
0,5	0,499656	2,0003400000
1,0	0,988756	1,5112400000
1,5	1,432690	1,0673100000
2,0	1,794850	0,7051520000
2,5	2,061330	0,4386680000
3,0	2,240970	0,2590300000
3,5	2,353700	0,1463000000
4,0	2,420440	0,0795606000
4,5	2,458110	0,0418899000
5,0	2,478550	0,0214515000
5,5	2,489280	0,0107242000
6,0	2,494750	0,0052502300
6,5	2,497480	0,0025235200
7,0	2,498810	0,0011933800
7,5	2,499440	0,0005562640
8,0	2,499740	0,0002559610
8,5	2,499880	0,0001164190
9,0	2,499950	0,0000523987
9,5	2,499980	0,0000233605
10,0	2,499990	0,0000103247

Ahora derivando se obtiene que la función de densidad de probabilidad de V es:

$$f_V(v) = \frac{d}{dV} F_V(x) = \frac{f(v + M)}{1 - F(M)}. \quad (12.42)$$

Ejemplo 12.26 Calcular $f(v)$ si X sigue la distribución exponencial con parámetro $\lambda > 0$.

Solución: Utilizando (12.42) se obtiene que la densidad de V es la misma que la de X . $\diamond$

12.6.3. Reaseguro stop-loss

Se trata de una modalidad de reaseguro *excess loss* referente a toda la cartera.

Definición 12.10 El reaseguro *stop-loss* es una modalidad de reaseguro por la que el reasegurador se obliga a cubrir total o parcialmente el montante de las indemnizaciones correspondientes a un período de tiempo dado, siempre que aquél supere un determinado límite M .

De aquí deriva la nomenclatura *stop loss*, ya que desde el punto de vista del asegurador la pérdida se detiene en M . En este caso el reasegurador paga

$$\max \left\{ 0, \sum_{i=1}^N X_i - M \right\} = \max \{0, S - M\},$$

donde $S = \sum_{i=1}^N X_i$ es la cantidad total reclamada en la cartera de seguros, N es la variable aleatoria asociada al número de reclamaciones y X_i la cantidad reclamada en el i -ésimo siniestro.

Se les denomina también reaseguro totalmente colectivo, por el hecho de referirse a toda la cartera, y será analizado con cierto detalle en el próximo capítulo.

12.6.4. Otras formas de reaseguro

En los últimos años se han desarrollado otras formas de reaseguros que no se tratarán en esta obra. Estos son:

- **ECOMOR.** Se trata de las siglas *excédent du coût moyen relatif treaty*, y que podríamos traducir como excedente del coste medio relativo. Pensado para protegerse de la inflación, es una modalidad de reaseguro *excess loss* con una retención aleatoria, que cubre las indemnizaciones que superan la p -ésima mayor reclamación ($\text{ECOMOR}(p)$).
- **Pool.** Se trata de la asociación de compañías aseguradoras que se unen con el objetivo de ampliar su capacidad de acción. Suelen llevarse a cabo para líneas específicas de seguros, como seguro de aeronaves, centrales nucleares, etc.

12.6.5. Franquicias

Estrictamente no constituyen una modalidad de reaseguro. Se trata de una modalidad de seguro muy extendida en el ramo de automóviles, pudiendo ser estudiadas de la misma manera que los reaseguros *excess loss*. En este caso, el asegurado participa del pago de toda cantidad menor o igual que M , mientras que paga M para cualquier siniestro que exceda a M . Por tanto el asegurado paga $\min\{X, M\}$ y el asegurador paga $\max\{0, X - M\}$. Por tanto el tratamiento matemático de este tipo de seguros es igual al de reaseguros en la modalidad *excess loss*.

12.7. Problemas propuestos

12.7. Problemas propuestos

1. Demostrar que el principio de varianza puede obtenerse a partir del principio de utilidad exponencial para valores pequeños de la constante de aversión al riesgo. Indicación: desarrollar en serie de Taylor del principio exponencial.
2. Demostrar que si $S = \sum_{i=1}^n X_i$, donde X_i son variables aleatorias independientes, entonces:

$$\frac{1}{\alpha} \log [E(e^{\alpha S})] = \sum_{i=1}^n \frac{1}{\alpha} \log [E(e^{\alpha X_i})], \quad \alpha > 0.$$

3. Demostrar que el principio Esscher equivale al principio de prima neta para la variable $Y = X e^{\alpha X} / E(e^{\alpha X})$, $\alpha > 0$.
4. Demostrar que el principio de prima neta y exponencial son casos particulares del principio del valor medio, que se define por $\mathcal{H}(X) = v^{-1}(E[v(X)])$, siendo $v(\cdot)$ una función creciente y convexa.
5. Demostrar que el principio de utilidad exponencial es un caso particular del principio de prima suizo.
6. Demostrar que los estimadores $\hat{m}$, $\hat{s}$ y $\hat{a}$ del modelo de Bühlmann de distribución libre son insesgados y consistentes.
7. Calcular la prima de riesgo, colectiva y Bayes bajo el principio Esscher cuando el riesgo X sigue una distribución de Poisson con parámetro $\theta > 0$ y éste sigue en el colectivo una distribución gamma $\mathcal{G}(a, 1/b)$. Comprobar que la prima Bayes obtenida puede escribirse como una fórmula de credibilidad con factor de credibilidad como el de Bühlmann.
8. Sea X_i la variable aleatoria que denota el número de reclamaciones para el i -ésimo año de vigencia de una póliza en la que X_i sigue una distribución de Poisson de parámetro $\theta > 0$, y θ sigue la función de densidad $\pi(\theta) = e^{-\theta}$, $\theta > 0$. Se pide:
 - a) ¿Cuál es la probabilidad incondicional $\Pr(X_1 = 2)$?
 - b) Determinar la distribución predictiva $\Pr(X_2 = d | X_1 = 2)$, $d = 0, 1, \dots$
9. El número de reclamaciones anual X , para un asegurado sigue una distribución de Poisson de parámetro $\theta > 0$. Supongamos que la distribución a priori de este parámetro es la uniforme en el intervalo $(1, 3)$. El asegurado reclama un siniestro durante el primer año de vigencia de la póliza. Estimar el número de reclamaciones en el segundo año de la póliza:

- a) Utilizando la aproximación de Bühlmann.
- b) Utilizando la aproximación bayesiana.

Se supone que las variables X_1 y X_2 son independientes.

10. Para una variable no negativa X con función de distribución $F(x; \theta)$, se define la prima de riesgo bajo el principio de prima de riesgo ajustado como:

$$P(\theta) = \int_0^{\infty} [\Pr(X > x)]^{1/\rho} dx = \int_0^{\infty} [1 - F(x; \theta)]^{1/\rho} dx.$$

Demostrar que:

- a) Este principio satisface las propiedades 1, 2, 3 y 7 de las propiedades deseables para un principio de cálculo de prima.
 - b) Si X sigue una distribución exponencial con parámetro θ , entonces $P(\theta) = \rho/\theta$.
 - c) Si X sigue una distribución de Pareto con parámetros (α, θ) , α conocido, entonces $P(\theta) = \rho\theta/(\alpha - \rho)$, $\rho < \alpha$.
11. Si X sigue la distribución log-normal $\mathcal{LN}(\mu, \sigma)$, calcular $E(Y^n)$ y $E(Y)$ para un reaseguro *excess loss*.
12. Calcular la prima neta de reaseguro si la distribución de X es normal con parámetros μ y σ^2 .

Capítulo 13

Modelos de Riesgo Colectivo e Individual

13.1. Introducción

Como ya se comentó en el capítulo de tarificación, lo ideal en estadística actuarial es trabajar con las distribuciones del número de reclamaciones y de la cantidad reclamada para obtener la función de distribución de la cantidad total reclamada. Dicha distribución constituye uno de los tópicos más importantes en estadística actuarial, y de ello trataremos en este capítulo. Así, abordaremos el problema bajo el modelo colectivo e individual de la teoría del riesgo.

En el modelo colectivo se considera que la cartera consta de un número desconocido de pólizas. Aquí el número total de reclamaciones ocurridas en un período de tiempo es aleatorio, y se supone que las cuantías asociadas a las reclamaciones son independientes entre sí, idénticamente distribuidas e independientes del número de reclamaciones. Se supone también que cada riesgo o póliza puede dar lugar solamente a un siniestro. El modelo individual es similar al modelo colectivo aunque en vez de considerar número de reclamaciones se considera un número n de pólizas, donde n no es aleatorio. Además se supone independencia entre las pólizas, aunque puede eludirse el supuesto de igualmente distribuidas.

13.2. Modelo de riesgo colectivo

En esta sección introducimos el modelo de riesgo colectivo. Calcularemos la distribución de la cantidad total reclamada en un cierto período. Ahora vemos la cartera de clientes como un colectivo cuyo número es aleatorio. Representamos la cantidad total reclamada como una suma S de un número aleatorio de reclamaciones N ,

donde las cantidades reclamadas son $\{X_1, \dots, X_N\}$. De este modo:

$$S = X_1 + X_2 + \dots + X_N, \quad N = 0, 1, 2, \dots \quad (13.1)$$

donde por convenio $X = 0$ si $N = 0$. Con objeto de hacer el modelo tratable se establecen dos hipótesis:

1. Las variables aleatorias $X_1, X_2, \dots$ son independientes e igualmente distribuidas con función de distribución $F_X(\cdot)$
2. Las variables aleatorias $N, X_1, X_2, \dots$ son mutuamente independientes.

Todo esto queda resumido en la siguiente definición.

Definición 13.1 Un modelo de riesgo colectivo representa la cantidad total reclamada como la suma S de un número aleatorio N de cantidades $X_1, \dots, X_N$, i.e. $S = \sum_{i=1}^N X_i$, donde se supone que las X_i son variables aleatorias i.i.d. e independientes de N .

Proposición 13.1 La variable aleatoria $S = \sum_{i=1}^N X_i$ tiene como función de distribución:

$$F_S(x) = \sum_{n=0}^{\infty} p_n F^{*n}(x),$$

donde $F(x) = \Pr(X \leq x)$ es la función de distribución de las X_j , $p_n = \Pr(N = n)$ y $F^{*n}(x)$ es la convolución n -ésima de la función de distribución de X .

Demostración: Se obtiene a partir de:

$$\begin{aligned} F_S(x) &= \Pr(X \leq x) = E[\Pr(X \leq x|N)] \\ &= \sum_{n=0}^{\infty} p_n \Pr(X \leq x|N = n) = \sum_{n=0}^{\infty} p_n F^{*n}(x), \end{aligned}$$

donde se ha hecho uso de la hipótesis de independencia entre X_i y N primero y luego de la hipótesis de i.i.d. de X_i .

Se verifica que la función de densidad de probabilidad de S viene dada por:

$$f_S(x) = \sum_{n=0}^{\infty} p_n f^{*n}(x), \quad (13.2)$$

donde $f(x)$ es la función de densidad de X .

Definición 13.2 Dado el modelo colectivo compuesto definido en (13.1), se denominan distribuciones primaria y secundaria a las distribuciones del número de reclamaciones y de la cantidad reclamada, respectivamente.

13.2.1. Resultados generales

En esta sección presentamos algunas características importantes de la variable aleatoria S , como son su función generatriz de momentos y de probabilidades, así como la media y varianza.

Teorema 13.1 La función generatriz de momentos y la función generatriz de probabilidad de S definida en (13.1) vienen dadas por:

$$M_S(t) = M_N[\log M_X(t)], \quad (13.3)$$

$$P_S(z) = P_N[P_X(z)], \quad (13.4)$$

respectivamente, siendo $M_N(t)$ y $P_N(z)$ la función generatriz de momentos y de probabilidades de la distribución primaria y $M_X(t)$ y $P_X(z)$ la función generatriz de momentos y de probabilidades de la distribución secundaria.

Demostración: La fórmula (13.4) ha sido probada en el teorema 5.5 del capítulo 5. La prueba de (13.3) se realiza combinando (13.4) con (5.14). ■

Corolario 13.1 La esperanza y la varianza de S vienen dadas por:

$$E(S) = E(N)E(X), \quad (13.5)$$

$$\text{Var}(S) = E(N) \text{Var}(X) + E^2(X) \text{Var}(N), \quad (13.6)$$

respectivamente.

Demostración: Puesto que:

$$M'_S(t) = M'_N(\log M_X(t)) \frac{M'_X(t)}{M_X(t)},$$

tenemos que:

$$M'_S(0) = M'_N(\log M_X(0)) \frac{M'_X(0)}{M_X(0)} = M'_N(0) M'_X(0) = E(N)E(X),$$

donde se ha tenido en cuenta que $M_X(0) = 1$.

Por otro lado tenemos:

$$\begin{aligned} M''_S(t) &= M''_N(\log M_X(t)) \left[\frac{M'_X(t)}{M_X(t)} \right]^2 \\ &+ M'_N(\log M_X(t)) \frac{M''_X(t) M_X(t) - M'_X(t)^2}{M_X(t)^2}, \end{aligned}$$

y por tanto:

$$M''_S(0) = M''_N(0) M'_X(0)^2 + M'_N(0) [M''_X(0) - M'_X(0)^2].$$

Luego, $E(S^2) = E(N^2)E^2(X) + E(N)\text{Var}(N)$, y en definitiva:

$$\begin{aligned}\text{Var}(S) &= E(S^2) - E^2(S) = E(N^2)E^2(X) + E(N)\text{Var}(X) - E^2(N)E^2(X) \\ &= E(N)\text{Var}(X) + E^2(X)\text{Var}(N).\end{aligned}$$

Obsérvese que (13.6) se puede también deducir de (12.23) como proponemos en el siguiente ejemplo.

Ejemplo 13.1 Deducir la expresión (13.6) a partir de (12.23).

Solución: En efecto, tomando $X = S$ y $\Theta = N$:

$$\begin{aligned}\text{Var}(S) &= E[\text{Var}(S|N)] + \text{Var}[E(S|N)] \\ &= E[\text{Var}(\sum_{i=1}^N X_i|N)] + \text{Var}[E(\sum_{i=1}^N X_i|N)] \\ &= E[N\text{Var}(X)] + \text{Var}[NE(X)] \\ &= E(N)\text{Var}(X) + \text{Var}(N)E^2(X).\end{aligned}$$

Ejemplo 13.2 Si la distribución primaria es Poisson de parámetro 5 y la distribución secundaria es inversa gaussiana $IG(10, 6)$, calcular $E(S)$ y $\text{Var}(S)$.

Solución:

$$\begin{aligned}E(S) &= E(N)E(X) = 5 \cdot 10 = 50, \\ \text{Var}(S) &= 5 \cdot \frac{10^3}{6} + 10^2 \cdot 5 = 1333,33.\end{aligned}$$

Modelo de Poisson compuesto

Cuando la distribución primaria es Poisson con parámetro $\theta > 0$ y la distribución secundaria tiene por función de distribución F , se dice que S tiene la distribución de Poisson compuesta con parámetros θ y F . Entonces, de (13.5) y (13.6) se verifica que,

$$\begin{aligned}E(S) &= \theta E(X), \\ \text{Var}(S) &= \theta E(X^2).\end{aligned}$$

Un resultado importante que será de utilidad en el capítulo 14 dedicado a la teoría de la ruina, aparece en la siguiente proposición.

13.2. Modelo de riesgo colectivo

Proposición 13.2 La distribución de Poisson compuesta tiene coeficiente de asimetría positivo con valor

$$\gamma_1(S) = \frac{E(X^3)}{\sqrt{\theta [E(X^2)]^3}}. \quad (13.7)$$

Demostración: De (13.3) se deduce que

$$M_S(t) = e^{\theta [e^{\log M_X(t)} - 1]} = e^{\theta [M_X(t) - 1]}.$$

Se verifica que:

$$M_S'''(0) = E(S^3) = \theta E(X^3) + 3E(S)E(S^2) - 2E^3(S), \quad (13.8)$$

y por tanto

$$\begin{aligned}E[S - E(S)]^3 &= E[S^3 - 3S^2E(S) + 3SE^2(S) - E^3(S)] \\ &= E(S^3) - 3E(S)E(S^2) + 3E^2(S)E(S) - E^3(S).\end{aligned} \quad (13.9)$$

Sustituyendo ahora (13.8) en (13.9) se obtiene:

$$E[S - E(S)]^3 = \theta E(X^3). \quad (13.10)$$

Finalmente,

$$\gamma_1(S) = \frac{E[S - E(S)]^3}{\sqrt{\text{Var}(S)^3}} = \frac{E(X^3)}{\sqrt{\theta [E(X^2)]^3}} > 0.$$

Ejemplo 13.3 Si la distribución primaria es Poisson con parámetro 50 y la distribución secundaria es exponencial con parámetro 1000 se pide, para la variable aleatoria cantidad total reclamada, calcular su esperanza, varianza y coeficiente de asimetría.

Solución: Utilizando (13.5) y (13.6) resulta inmediato que $E(S) = 0,05$, $\text{Var}(S) = 10^{-4}$. Finalmente, usando (13.7) se obtiene que $\gamma_1(S) = 0,3$, para lo que se ha tenido en cuenta que $E(X^2) = 2/1000^2$ y $E(X^3) = 6/1000^3$.

Ejemplo 13.4 Si la distribución primaria es Poisson de parámetro 2 y la secundaria es log-normal con parámetros 1 y 0,2, calcular la esperanza, varianza y coeficiente de asimetría de la variable aleatoria cantidad total reclamada.

Solución: Sabemos que si $X \sim \mathcal{LN}(\mu, \sigma)$ entonces (teorema 7.8):

$$E(X^n) = e^{n\mu + \frac{1}{2}\sigma^2 n^2},$$

de donde ahora es inmediato obtener:

$$\begin{aligned} E(X) &= 2,77319, & E(X^2) &= 8,00447, \\ \text{Var}(X) &= 0,313886, & E(X^3) &= 24,0468. \end{aligned}$$

A partir de estos resultados resulta:

$$\begin{aligned} E(S) &= 5,54638, \\ \text{Var}(S) &= 16,0089, \\ \gamma_1(S) &= 0,750833. \end{aligned}$$

Una propiedad interesante de las variables aleatorias que siguen una distribución de Poisson compuesta aparece en el siguiente resultado.

Proposición 13.3 Si $\{S_i\}_{i=1}^n$ son variables aleatorias independientes con distribución de Poisson compuesta con parámetros (θ_i, F_i) , entonces $S = \sum_{i=1}^n S_i$ tiene la distribución de Poisson compuesta con parámetros (Θ, F) , con $\Theta = \sum_{i=1}^n \theta_i$ y $F = \frac{1}{\Theta} \sum_{i=1}^n \theta_i F_i(x)$.

Demostración: El resultado se prueba usando la función generatriz de momentos de S .

$$\begin{aligned} M_S(t) &= E(e^{tS}) = \prod_{i=1}^n E(e^{tS_i}) = \prod_{i=1}^n e^{\theta_i [M_i(t) - 1]} \\ &= e^{\sum_{i=1}^n \theta_i [M_i(t) - 1]} = e^{\Theta [\sum_{i=1}^n \frac{\theta_i M_i(t)}{\Theta} - 1]}. \end{aligned}$$

Ejemplo 13.5 Supongamos que S_1 sigue una distribución de Poisson compuesta con parámetro de Poisson $\theta_1 = 2$ y función de densidad $f(x) = e^{-x}$, $x > 0$ para la cantidad reclamada, mientras que S_2 sigue también una distribución de Poisson compuesta con parámetro de Poisson $\theta_2 = 1$ y $f(x) = (2\pi x^3)^{-1/2} e^{-(x-1)^2/(2x)}$, $x > 0$ para la cantidad reclamada, i.e. se trata de una inversa Gaussiana con parámetros $\mu = \phi = 1$. Suponiendo que S_1, S_2 son independientes, obtener la función de densidad de la variable aleatoria $S = S_1 + S_2$.

Solución: Utilizando el resultado de la proposición 13.3 se obtiene $\theta = 3$ y:

$$f(x) = \frac{2}{3}e^{-x} + \frac{1}{3}\sqrt{\frac{1}{2\pi x^3}}e^{-\frac{(x-1)^2}{2x}}, \quad x > 0.$$

13.2. Modelo de riesgo colectivo

13.2.2. Algunos modelos específicos

Es posible obtener expresiones cerradas para la distribución de la variable aleatoria S en algunos casos particulares. Así ocurre cuando la variable aleatoria X asociada a la cuantía tiene la distribución exponencial. En este caso, la convolución n -ésima de $f(x)$ se obtiene de una manera simple, como presentamos a continuación.

Teorema 13.2 Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes e idénticamente distribuidas con distribución exponencial de parámetro $\lambda > 0$, entonces se verifica:

$$f^{*n}(x) = \frac{\lambda^n}{(n-1)!} x^{n-1} e^{-\lambda x}, \quad n = 1, 2, \dots \quad (13.11)$$

que es la función de densidad de una variable aleatoria gamma $\mathcal{G}(n, 1/\lambda)$.

Demostración: Este resultado se puede probar mediante funciones características haciendo uso de 7.36. Veamos una demostración alternativa por medio de convoluciones de funciones de densidad. Usando (4.21) tenemos:

$$\begin{aligned} f * f(x) &= \int_0^x f(x-x_1)f(x_1)dx_1 = \int_0^x \lambda e^{-\lambda(x-x_1)}\lambda e^{-\lambda x_1}dx_1 \\ &= \lambda^2 x e^{-\lambda x}, \\ f * (f * f)(x) &= \int_0^x \lambda e^{-\lambda(x-x_1)}\lambda^2 x_1 e^{-\lambda x_1}dx_1 = \frac{\lambda^3}{2} x^2 e^{-\lambda x}. \end{aligned}$$

Por inducción matemática, supongamos cierto que $f^{*n}(x) = \frac{\lambda^n}{(n-1)!} x^{n-1} e^{-\lambda x}$, entonces:

$$\begin{aligned} f^{*(n+1)}(x) &= f * f^{*n}(x) = \int_0^x \lambda e^{-\lambda(x-x_1)}\lambda^n e^{-\lambda x_1} \frac{x_1^{n-1}}{(n-1)!} dx_1 \\ &= \frac{\lambda^{n+1}}{n!} x^n e^{-\lambda x} \end{aligned}$$

lo que prueba el resultado.

Modelo general exponencial

Teorema 13.3 Si la distribución primaria tiene por función de probabilidad p_n y la distribución secundaria es exponencial de parámetro $\lambda > 0$, entonces la función de densidad, así como la función de distribución de $S = \sum_{i=1}^N X_i$ vienen dadas por:

$$\begin{aligned} f_S(x) &= \frac{e^{-\lambda x}}{x} \sum_{n=1}^{\infty} p_n \frac{(\lambda x)^n}{(n-1)!}, \quad x > 0, \\ F_S(x) &= 1 - e^{-\lambda x} \sum_{j=0}^{\infty} \bar{P}_j \frac{(\lambda x)^j}{j!}, \quad x > 0, \end{aligned} \quad (13.12)$$

donde $\tilde{P}_j = \sum_{n=j+1}^{\infty} p_n$, $j = 0, 1, \dots$

Demostración: La función de densidad se obtiene utilizando las fórmulas (13.2) y (13.11).

Para obtener la función de distribución hacemos,

$$\begin{aligned} F_S(x) &= \int_0^x f_S(t) dt = \int_0^x \frac{e^{-\lambda t}}{t} \sum_{n=1}^{\infty} p_n \frac{(\lambda t)^n}{(n-1)!} dt \\ &= \sum_{n=1}^{\infty} \frac{p_n}{(n-1)!} \lambda^n \int_0^x t^{n-1} e^{-\lambda t} dt. \end{aligned}$$

Ahora utilizando el resultado:

$$\int_0^x t^{n-1} e^{-\lambda t} dt = 1 - \sum_{j=0}^{n-1} \frac{(\lambda t)^j e^{-\lambda t}}{j!},$$

se deduce que

$$F_S(x) = 1 - e^{-\lambda x} \sum_{j=0}^{\infty} \frac{(\lambda x)^j}{j!} \sum_{n=j+1}^{\infty} p_n = 1 - e^{-\lambda x} \sum_{j=0}^{\infty} \tilde{P}_j \frac{(\lambda x)^j}{j!}.$$

Ahora, dependiendo de la distribución de la variable aleatoria N se pueden obtener, como ya comentamos, algunas expresiones cerradas para la función de distribución de la cantidad total reclamada.

Proposición 13.4 Si la distribución primaria es de tipo Poisson con parámetro $\theta > 0$ y la distribución secundaria es exponencial con parámetro $\lambda > 0$, entonces la función de densidad de probabilidad de S viene dada por:

$$f_S(x) = \frac{e^{-(\theta+\lambda x)}}{x} \sum_{n=1}^{\infty} \frac{(\lambda \theta x)^n}{n!(n-1)!}, \quad x > 0, \quad (13.13)$$

con $f_S(0) = e^{-\theta}$.

Nótese que en este caso S es una variable aleatoria mixta.

Demostración: Se obtiene al aplicar la expresión general (13.12) al caso de Poisson.

Corolario 13.2 La función de densidad (13.13) puede reescribirse como:

$$f_S(x) = e^{-(\theta+\lambda x)} \sqrt{\lambda \theta / x} I_1 \left(2\sqrt{\lambda x \theta} \right), \quad x > 0, \quad (13.14)$$

donde:

$$I_\nu(x) = \sum_{k=0}^{\infty} \frac{(x/2)^{2k+\nu}}{k! \Gamma(\nu+k+1)}, \quad x \in \mathbb{R}, \quad \nu \in \mathbb{R}$$

es la función modificada de Bessel de clase ν .

Demostración: Es inmediato después de cambiar en (13.13) n por $k+1$. La importancia de este resultado se basa en que la función modificada de Bessel puede ser calculada de manera inmediata utilizando el programa Mathematica mediante la instrucción `N[BesselI[ $\nu$ ,  $z$ ],  $r$ ]`, que da una aproximación con r dígitos de la función de Bessel.

Ejemplo 13.6 Utilizando (13.14) calcular $F_S(x) = \Pr(X > x)$ para valores de $x = 0, 1, 0, 2, \dots, 10$, tomando $\theta = \lambda = 1$.

Solución: El resultado puede obtenerse a partir de la expresión:

$$\Pr(X > x) = 1 - \left(f_S(0) + \int_0^x f_S(t) dt \right),$$

que proporciona los valores que aparecen en la tabla 13.1. La gráfica de la función de densidad aparece en la figura 13.1

Tabla 13.1: Probabilidad de la cola. Modelo Poisson compuesto

x	$1 - F_S(x)$
0,1	0,59624200
0,2	0,32482000
0,3	0,17102000
0,4	0,08771100
0,5	0,04404980
0,6	0,02174310
0,7	0,01057720
0,8	0,00508150
0,9	0,00241483
1,0	0,00113662




Figura 13.1: Función de densidad del modelo de Poisson compuesto

Modelo geométrica compuesto

Proposición 13.5 Si la distribución primaria es geométrica con parámetro $\theta \in (0, 1)$ y la distribución secundaria es exponencial con parámetro $\lambda > 0$, entonces la función de densidad de probabilidad de S viene dada por:

$$f_S(x) = \theta(1 - \theta)\lambda e^{-\theta\lambda x}, \quad x > 0, \quad (13.15)$$

siendo $f_S(0) = \theta$.

Demostración: Puede obtenerse a partir de (13.12), o bien utilizando (13.2), (13.11) y el hecho de que $\Pr(N = n) = \theta(1 - \theta)^n$, de donde resulta:

$$\begin{aligned} f_S(x) &= \sum_{n=1}^{\infty} \theta(1 - \theta)^n \frac{\lambda^n e^{-\lambda x} x^{n-1}}{(n-1)!} = \frac{\theta}{x} e^{-\lambda x} \sum_{n=1}^{\infty} \frac{[(1 - \theta)\lambda x]^n}{(n-1)!} \\ &= \frac{\theta}{x} e^{-\lambda x} (1 - \theta)\lambda x \sum_{n=1}^{\infty} \frac{[(1 - \theta)\lambda x]^{n-1}}{(n-1)!} = \theta(1 - \theta)\lambda e^{-\theta\lambda x}. \end{aligned}$$

13.2. Modelo de riesgo colectivo

Nótese que nuevamente para este caso S es una variable aleatoria mixta.

Modelo binomial negativa compuesto

Proposición 13.3 Si la distribución primaria es binomial negativa con parámetros $r, \theta > 0$ y la distribución secundaria es exponencial con parámetro $\lambda > 0$, entonces la función de densidad de S viene dada por:

$$f_S(x) = (1 - \theta)\theta^r \lambda e^{-\lambda x} \sum_{n=1}^{\infty} \binom{r+n-1}{n} \frac{1}{(n-1)!} [(1 - \theta)\lambda x]^{n-1}, \quad x > 0, \quad (13.16)$$

con $f_S(0) = \theta^r$.

Demostración: Es inmediata a partir de (13.12).

Esta función de densidad puede expresarse de manera más simple cuando r es un entero positivo como aparece en el siguiente resultado.

Corolario 13.3 Si r es un entero positivo, la función de densidad (13.16) puede reescribirse como:

$$f_S(x) = -(1 - \theta)\theta^r \lambda e^{-\theta\lambda x} L'_r(-(1 - \theta)\lambda x), \quad x > 0,$$

donde $L'_r(\cdot)$ representa la derivada del polinomio de Laguerre.

Demostración: Si definimos,

$$T(z) = \sum_{n=1}^{\infty} \binom{r+n-1}{n} \frac{z^{n-1}}{(n-1)!},$$

tenemos que

$$\begin{aligned} T(z) &= \sum_{n=1}^{\infty} \binom{r+n-1}{n} \frac{z^{n-1}}{(n-1)!} = \frac{d}{dz} \sum_{n=0}^{\infty} \binom{r+n-1}{n} \frac{z^n}{n!} \\ &= \frac{d}{dz} \frac{(r+n-1)(r+n-2) \dots r z^n}{n!} = \frac{d}{dz} M(r, 1; z), \end{aligned}$$

donde $M(r, 1; z)$ representa la función confluyente hipergeométrica definida como:

$$M(a, b; x) = \sum_{n=0}^{\infty} \frac{a(a+1) \dots (a+n-1) x^n}{b(b+1) \dots (b+n-1) n!}.$$

Ahora utilizando las propiedades

$$\begin{aligned} \frac{d}{dx} M(a, b; x) &= \frac{a}{b} M(a+1, b+1; x), \\ M(a, b; x) &= e^x M(b-a, b; -x), \end{aligned}$$

tenemos

$$T(z) = e^z L'_{r-1}(-z),$$

donde

$$L_n^r(x) = \sum_{r=0}^n (-1)^r \binom{n+a}{n-r} \frac{x^r}{r!},$$

representa el polinomio de Laguerre. Finalmente, teniendo en cuenta que $\frac{d}{dx} L_r^0(x) = -L'_{r-1}(x)$, se obtiene el resultado. ■

Modelo logarítmico compuesto

Proposición 13.7 Si la distribución primaria es logarítmica con parámetro $0 < \theta < 1$ y la distribución secundaria es exponencial con parámetro λ , entonces la función de densidad de S viene dada por:

$$f_S(x) = -\frac{1}{\log(1-\theta)} \frac{e^{-\lambda x}}{x} (e^{\lambda \theta x} - 1), \quad x > 0.$$

Demostración: Se obtiene a partir de (13.12) usando la distribución logarítmica. ■

13.2.3. Fórmula de recursión de Panjer

En la mayoría de las ocasiones resulta difícil obtener una expresión analítica para la distribución de S , y puesto que desde el punto de vista actuarial resulta interesante poder calcular $\Pr(S \geq s)$, es decir la probabilidad de que la cantidad total reclamada exceda a un cierto nivel s , se precisan mecanismos que permitan llevar a cabo este cálculo o aproximarlos. De ahí que se hayan desarrollado métodos basados en algoritmos recursivos de cálculo numérico que permitan calcular o bien obtener un valor aproximado de dicha probabilidad. La fórmula de recursión de Panjer constituye junto con el método de distribución libre de Bühlmann y la desigualdad de Lundberg uno de los resultados más elegantes y prácticos de la estadística actuarial. Esta fórmula evita usar convoluciones o algún método de cálculo más tedioso que dicha fórmula. La utilización de sistemas de distribuciones como la clase $(a, b, 0)$ nos resultará de gran utilidad en nuestro propósito. Recordemos, como ya se comentó con anterioridad, que una distribución discreta $\{p_n\}_{n=0}^\infty$ pertenece a la clase $(a, b, 0)$ si

$$\frac{p_n}{p_{n-1}} = a + \frac{b}{n}, \quad n = 1, 2, \dots, \quad (13.17)$$

13.2. Modelo de riesgo colectivo

siendo a y b constantes.

Sundt y Jewell (1981) probaron que las únicas distribuciones discretas que pertenecen a dicha clase son las distribuciones de Poisson, binomial, binomial negativa y geométrica.

Ejemplo 13.7 Demostrar que las distribuciones de Poisson, binomial, binomial negativa y geométrica pertenecen a la clase $(a, b, 0)$ dando los valores de las constantes a y b en cada caso.

Solución: Para la distribución de Poisson de parámetros θ se tiene:

$$\frac{p_n}{p_{n-1}} = \frac{\theta}{n},$$

luego en este caso $a = 0$ y $b = \theta$.

Para la distribución binomial con parámetros N y θ resulta:

$$\frac{p_n}{p_{n-1}} = \frac{\theta}{1-\theta} \left(-1 + \frac{N+1}{n} \right),$$

y por tanto ahora $a = -\theta/(1-\theta)$, $b = \theta(N+1)/(1-\theta)$.

En el caso de la distribución binomial negativa con parámetros r y θ resulta:

$$\frac{p_n}{p_{n-1}} = (r+n-1)(1-\theta)/n,$$

por lo que $a = 1-\theta$ y $b = (r-1)(1-\theta)$.

Finalmente, y puesto que la distribución geométrica es un caso particular de la binomial negativa con $r = 1$, resulta que $a = 1-\theta$ y $b = 0$. ◇

Obsérvese ahora que (13.17) puede ser escrita de la forma:

$$n \frac{p_n}{p_{n-1}} = an + b, \quad n = 1, 2, \dots$$

lo que indica que np_n/p_{n-1} es una función lineal de n con pendiente a . Este valor es cero para la distribución de Poisson, negativo para la binomial y positivo para la binomial negativa y geométrica. Por tanto, a partir de la distribución empírica de frecuencia de las reclamaciones, un gráfico de np_n/p_{n-1} frente a n indica cuál de las tres distribuciones es aconsejable para ajustar la distribución de frecuencias observada.

Ejemplo 13.8 Consideremos los datos de reclamaciones que aparecen en la tabla 12.3. Calcular entonces los valores de np_n/p_{n-1} y decidir qué distribución entre la Poisson, binomial y binomial negativa es aconsejable elegir para ajustar esos datos.

Tabla 13.2: Frecuencias observadas

Número de reclamaciones	Observadas	$n \frac{p_n}{p_{n-1}}$
0	96978	
1	9240	0,09527
2	704	0,15238
3	43	0,18383
4	9	0,83721
Más de 4	0	
Total	106974	

Solución: Los valores de np_n/p_{n-1} aparecen en la tabla 13.2 y el correspondiente gráfico se muestra en la figura 13.2. A la vista del mismo se observa que la pendiente del ratio np_n/p_{n-1} puede suponerse que es positiva. Luego las distribuciones de Poisson y binomial negativa parecen adecuadas. Finalmente, puesto que la varianza de estos datos es ligeramente mayor que la media, lo razonable es elegir la distribución binomial negativa.

◇

La fórmula de recursión de Panjer, uno de los resultados más importantes en estadística actuarial, permite calcular de manera exacta y recursiva la distribución de la cantidad total reclamada. Esta distribución juega un papel destacado en el modelo colectivo compuesto y en teoría de la ruina. Para su obtención se requiere previamente del siguiente resultado.

Proposición 13.8 Sea $X = \sum_{i=1}^n X_i$, con X_i variables aleatorias i.i.d., entonces para todo $j, k \in \mathbb{N}$, $n = 1, 2, \dots$ se verifica:


$$E(X_1 | \sum_{i=1}^n X_i = j) = \frac{j}{n}, \quad (13.18)$$

$$\Pr(X_1 = k | \sum_{i=1}^n X_i = j) = \frac{f(k)f^{*(n-1)}(j-k)}{f^{*n}(j)}. \quad (13.19)$$

$$f^{*n}(x) = \frac{n}{ks} \sum_{j=1}^s j f^{*k}(j) f^{*(n-k)}(s-j), \quad (13.20)$$

donde $f(x) = \Pr(X = k)$, $k = 0, 1, \dots$

Demostración: Puesto que X_i están idénticamente distribuidas, para $X = \sum_{i=1}^n X_i$

Figura 13.2: Ratio $n \frac{p_n}{p_{n-1}}$ frente a n

tenemos:

$$\begin{aligned} nE(X_1 | X = j) &= \sum_{k=1}^n E(X_k | X = j) = E\left(\sum_{k=1}^n X_k | X = j\right) \\ &= E(X | X = j) = j. \end{aligned}$$

Por otro lado, puesto que $X_1, X_2, \dots$ son independientes:

$$\begin{aligned} \Pr(X_1 = k | \sum_{i=1}^n X_i = j) &= \frac{\Pr(X_1 = k, \sum_{i=2}^n X_i = j-k)}{\Pr(\sum_{i=1}^n X_i = j)} \\ &= \frac{\Pr(X_1 = k) \Pr(\sum_{i=2}^n X_i = j-k)}{\Pr(\sum_{i=1}^n X_i = j)} \\ &= \frac{f(k)f^{*(n-1)}(j-k)}{f^{*n}(j)}. \end{aligned}$$

Finalmente,

$$\begin{aligned} \Pr(X_1 + \dots + X_k = j | X_1 + \dots + X_n = i) \\ &= \frac{\Pr(X_1 + \dots + X_k = j, X_1 + \dots + X_n = i)}{\Pr(X_1 + \dots + X_n = i)} \\ &= \frac{\Pr(X_1 + \dots + X_k = j, X_{k+1} + \dots + X_n = i - j)}{\Pr(X_1 + \dots + X_n = i)} \\ &= \frac{f^{*k}(j) f^{*(n-k)}(i - j)}{f^{*n}(i)}, \end{aligned}$$

de donde,

$$\begin{aligned} \frac{ki}{n} &= E(X_1 + \dots + X_k = j | X_1 + \dots + X_n = i) \\ &= \frac{1}{f^{*n}(i)} \sum_{j=1}^i j f^{*k}(j) f^{*(n-k)}(i - j). \end{aligned}$$

Teorema 13.4 (Fórmula de recursión de Panjer: versión discreta) La función de densidad de probabilidad de $S = \sum_{i=1}^N X_i$, siendo X_i variables aleatorias i.i.d. e independientes de N , satisface la siguiente fórmula recursiva:

$$f_S(x) = \begin{cases} P_N(f(0)), & x = 0, \\ \frac{1}{1 - af(0)} \sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x - k), & x = 1, 2, \dots, \end{cases} \quad (13.21)$$

siendo $f(x)$ la función de probabilidad de la variable aleatoria X discreta y positiva asociada a la cantidad de reclamación, y N pertenece a la clase $(a, b, 0)$.

Demostración: Por el teorema de las probabilidades totales,

$$\begin{aligned} f_S(0) &= \sum_{n=0}^{\infty} \Pr(X_1 + \dots + X_n = 0) \Pr(N = n) \\ &= \sum_{n=0}^{\infty} f(0)^n \Pr(N = n) = P_N(f(0)). \end{aligned}$$

Por otro lado, utilizando (13.17) y (13.18) tenemos

$$f_S(x) = \sum_{n=0}^{\infty} p_n f^{*n}(x) = p_0 f^{*0}(0) + \sum_{n=1}^{\infty} p_n f^{*n}(x)$$

$$\begin{aligned} &= \sum_{n=1}^{\infty} \left(a + \frac{b}{n}\right) p_{n-1} f^{*n}(x) \\ &= \sum_{n=1}^{\infty} \left[a + bE\left(\frac{X_1}{j} \mid \sum_{i=1}^n X_i = j\right)\right] p_{n-1} f^{*n}(x) \\ &= \sum_{n=1}^{\infty} \left[a + b \sum_{k=0}^j \frac{k}{j} \Pr\left(X_1 = k \mid \sum_{i=1}^n X_i = j\right)\right] p_{n-1} f^{*n}(x). \end{aligned}$$

Usando ahora (13.19) resulta:

$$\begin{aligned} f_S(x) &= \sum_{n=1}^{\infty} \left[a + b \sum_{k=0}^x \frac{k}{x} \frac{f(k) f^{*(n-1)}(x - k)}{f^{*n}(x)}\right] p_{n-1} f^{*n}(x) \\ &= \sum_{n=1}^{\infty} \sum_{k=0}^x \left(a + \frac{bk}{x}\right) f(k) f^{*(n-1)}(x - k) p_{n-1} \\ &= \sum_{k=0}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x - k) \\ &= af(0)g(x) + \sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x - k). \end{aligned}$$

Por tanto,

$$[1 - af(0)] f_S(x) = \sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x - k),$$

de donde despejando $f_S(x)$ se obtiene el resultado. $\square$

Ejemplo 13.9 Obtener la fórmula de recursión de Panjer para el caso en que X_i sean de tipo discreto y no negativas y N se distribuya de acuerdo a las siguientes distribuciones de probabilidad: Poisson de parámetro θ , binomial de parámetros N y p , binomial negativa de parámetros r y p y geométrica de parámetro p .

Solución: Ahora, utilizando (13.21) y teniendo en cuenta que $f_S(0) = 0$, resulta:

$$f_S(x) = \frac{\theta}{x} \sum_{k=1}^x k f(k) f_S(x - k),$$

para la distribución de Poisson,

$$f_S(x) = \frac{\theta}{1 - \theta} \sum_{k=1}^x [(N + 1)k/x - 1] f(k) f_S(x - k),$$

para la distribución binomial,

$$f_S(x) = (1-\theta) \sum_{k=1}^x [1 + (r-1)k/x] f(k) f_S(x-k),$$

para la distribución binomial negativa, y

$$f_S(x) = (1-\theta) \sum_{k=1}^x f(k) f_S(x-k),$$

para la distribución geométrica.

Ejemplo 13.10 Si la distribución primaria es Poisson de parámetro 5 y la distribución secundaria es $f(x) = 0,8 \cdot (0,2)^{x-1}$, $x = 1, 2, \dots$, calcular $\Pr(S > 3)$.

Solución: Para la distribución de Poisson se tiene que $a = 0$, y en este caso $b = 5$, luego:

$$f_S(x) = \frac{20}{s} \sum_{k=1}^x k(0,2)^k f_S(x-k).$$

Como $f(0) = 0$ tenemos que $f_S(0) = P_N(0) = e^{-5}$, entonces:

$$f_S(1) = 0,02695,$$

$$f_S(2) = 0,0592924,$$

$$f_S(3) = 0,0945089,$$

y por tanto, $\Pr(S > 3) = 1 - \Pr(S \leq 3) = 0,812509$.

La fórmula de Panjer puede utilizarse también para calcular los momentos de cualquier orden de la variable aleatoria S de forma recursiva, como se prueba en el siguiente resultado.

Teorema 13.5 Los momentos de orden r , $r = 1, 2, \dots$ de la variable aleatoria $S = \sum_{i=1}^N X_i$ pueden obtenerse de manera recursiva como:

$$E(S^r) = \frac{1}{1-a} \sum_{i=0}^{r-1} \left[a \binom{r}{i} + b \binom{r-1}{i} \right] E(S^i) E(X_1^{r-i}).$$

Demostración: En efecto:

$$E(S^r) = \sum_{s=0}^{\infty} s^r f_S(s)$$

13.2. Modelo de riesgo colectivo

$$\begin{aligned} &= \frac{1}{1-af(0)} \sum_{k=1}^{\infty} s^r \sum_{k=1}^s \left(a + \frac{bk}{s} \right) f(k) f_S(s-k) \\ &= \frac{1}{1-af(0)} \sum_{k=1}^{\infty} \sum_{s=k}^{\infty} (as^r + bks^{r-1}) f(k) f_S(s-k). \end{aligned}$$

Haciendo $s = k + t$ y utilizando el desarrollo del binomio de Newton resulta:

$$\begin{aligned} E(S^r) &= \frac{1}{1-af(0)} \sum_{k=1}^{\infty} f(k) \sum_{t=0}^{\infty} [a(t+k)^r + bk(t+k)^{r-1}] f_S(t) \\ &= \frac{1}{1-af_S(0)} \sum_{k=1}^{\infty} f(k) \sum_{t=0}^{\infty} \left[a \sum_{i=0}^r \binom{r}{i} t^i k^{r-i} f_S(t) \right. \\ &\quad \left. + bk \sum_{i=0}^{r-1} \binom{r-1}{i} t^i k^{r-1-i} f_S(t) \right] \\ &= \frac{1}{1-af_S(0)} \left[a \sum_{i=0}^r \binom{r}{i} \left(\sum_{t=0}^{\infty} t^i f_S(t) \right) \sum_{k=1}^{\infty} k^{r-i} f(k) \right. \\ &\quad \left. + b \sum_{i=0}^{r-1} \binom{r-1}{i} \left(\sum_{t=0}^{\infty} t^i f_S(t) \right) \sum_{k=1}^{\infty} k^{r-i} f(k) \right] \\ &= \frac{1}{1-af_S(0)} \left\{ \sum_{i=0}^{r-1} \left[a \binom{r}{i} + b \binom{r-1}{i} \right] E(S^i) E(X^{r-i}) \right. \\ &\quad \left. + a E(S^r) \sum_{k=1}^{\infty} f(k) \right\}. \end{aligned}$$

Teniendo ahora en cuenta que $\sum_{k=1}^{\infty} f(k) = 1 - f(0)$ y después de algunos cálculos adicionales se obtiene el resultado.

La fórmula de recursión de Panjer dada en el teorema 13.4 es válida cuando la variable aleatoria cantidad reclamada es de tipo discreto. Sin embargo es posible obtener una versión de dicha fórmula para el caso continuo. Para ello es necesario el siguiente resultado.

Teorema 13.6 Se verifica que,

$$\int_0^x y f(y) f^{*n}(x-y) dy = \frac{x}{n+1} f^{*(n+1)}(x), \quad n = 1, 2, \dots \quad (13.22)$$

$$\int_0^x f(y) f^{*n}(x-y) dy = f^{*(n+1)}(x), \quad n = 1, 2, \dots \quad (13.23)$$

Demostración: La primera se puede deducir siguiendo un argumento similar a la demostración de la expresión (13.20). La prueba de la segunda es directa.

Ahora estamos en disposición de dar una versión continua del algoritmo de Panjer, que aparece recogida en el siguiente teorema.

Teorema 13.7 (Fórmula de recursión de Panjer: versión continua) *La función de densidad de $S = \sum_{i=1}^N X_i$, siendo X_i variables aleatorias i.i.d. e independientes de N , satisface la siguiente fórmula recursiva:*

$$f_S(x) = \begin{cases} P_N(f_S(0)), & x = 0, \\ p_1 f(x) + \int_0^x \left(a + \frac{by}{x}\right) f(y) f_S(x-y) dy, & x > 0, \end{cases} \quad (13.24)$$

siendo $f(x)$ la función de densidad de la variable aleatoria X positiva asociada a la cantidad de reclamación y N pertenece a la clase $(a, b, 0)$.

Demostración: En efecto, se tiene:

$$\begin{aligned} f_S(x) &= \sum_{n=1}^{\infty} p_n f^{*n}(x) = p_1 f(x) + \sum_{n=2}^{\infty} p_n f^{*n}(x) \\ &= p_1 f(x) + \sum_{n=1}^{\infty} p_{n+1} f^{*(n+1)}(x). \end{aligned}$$

Utilizando ahora (13.17) tenemos:

$$\begin{aligned} g_S(x) &= p_1 f(x) + \sum_{n=1}^{\infty} p_n \left(a + \frac{b}{n+1}\right) f^{*(n+1)}(x) \\ &= p_1 f(x) + \sum_{n=1}^{\infty} p_n \left[a f^{*(n+1)}(x) + \frac{b}{x} f^{*(n+1)}(x) \frac{x}{n+1} \right]. \end{aligned}$$

Utilizando ahora (13.22) queda:

$$f_S(x) = p_1 f(x) + \sum_{n=1}^{\infty} p_n \left[a f^{*(n+1)}(x) + \frac{b}{x} \int_0^x y f(y) f^{*n}(x-y) dy \right],$$

y utilizando (13.23) se obtiene:

$$\begin{aligned} f_S(x) &= p_1 f(x) + \sum_{n=1}^{\infty} p_n \int_0^x \left(a + \frac{by}{x}\right) f(y) f^{*n}(x-y) dy \\ &= p_1 f(x) + \int_0^x \left(a + \frac{by}{x}\right) f(y) \sum_{n=1}^{\infty} p_n f^{*n}(x-y) dy \\ &= p_1 f(x) + \int_0^x \left(a + \frac{by}{x}\right) f(y) f_S(x-y) dy. \end{aligned}$$

La expresión (13.24) es una ecuación integral, denominada así porque la función incógnita $f_S(x)$, aparece bajo el operador de la integral. Para resolverla existen diversos métodos que pueden proporcionar la solución exacta o bien una aproximación mediante métodos numéricos.

Obsérvese ahora que si X_i es discreta y positiva entonces (13.24) toma la forma:

$$f_S(x) = \sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x-k), \quad x = 1, 2, \dots$$

que se obtiene sustituyendo en (13.24) el operador integral por el de suma, y se corresponde con la expresión (13.21) para el caso en que $f_S(0) = 0$.

Ejemplo 13.11 Obtener la fórmula de recursión de Panjer para el caso en que X_i sea una variable aleatoria de tipo continuo y N siga una distribución de Poisson, binomial, binomial negativa y geométrica.

Solución: Utilizando (13.24) se obtienen las expresiones:

$$\begin{aligned} f_S(x) &= \theta e^{-\theta} f(x) + \frac{\theta}{x} \int_0^x y f(y) f_S(x-y) dy, \\ f_S(x) &= \frac{\theta}{1-\theta} \left[N(1-\theta)^N f(x) + \int_0^x \left[\frac{(N+1)y}{x} - 1 \right] f(y) f_S(x-y) dy \right], \\ f_S(x) &= (1-\theta) \left[r\theta^r f(x) + \int_0^x \left[1 + \frac{(r-1)y}{x} \right] f(y) f_S(x-y) dy \right], \\ f_S(x) &= (1-\theta) \left[\theta f(x) + \int_0^x f(y) f_S(x-y) dy \right], \end{aligned} \quad (13.25)$$

para los modelos de Poisson, binomial, binomial negativa y geométrica, respectivamente. $\diamond$

Ejemplo 13.12 Consideremos el modelo geométrico compuesto con parámetro $\theta = 1/2$ y supongamos que la cantidad reclamada sigue una distribución exponencial de parámetro $\lambda = 1$. Se pide calcular de manera exacta y utilizando la fórmula de recursión de Panjer en su versión continua las probabilidades de supervivencia $\Pr(X \geq x)$ para $x = 0,001, \dots, 1$.

Solución: Utilizando (13.15) se obtienen las probabilidades exactas y son las que aparecen en la tabla 13.3.

Por otra parte, utilizando (13.25) pueden obtenerse las probabilidades de manera recursiva. Una ecuación integral como la que nos ocupa puede en ocasiones

resolverse de manera exacta utilizando, por ejemplo, la herramienta de la transformada de Laplace. En este caso se obtiene la solución dada por (13.15). Sin embargo, esto no es lo habitual, es decir que la función de densidad sea conocida, y el problema que surge consiste en calcularla o aproximarla mediante algún método. Por tanto vamos a considerar que la densidad exacta es desconocida y que no podemos obtener la solución exacta. Para el valor de $\theta = 1/2$, la ecuación (13.25) resulta:

$$g(x) = \frac{1}{4}e^{-x} + \frac{1}{2} \int_0^x e^{-y} g(x-y) dy,$$

donde hemos puesto $f_S(x) = g(x)$. Esta expresión puede reescribirse, mediante el cambio $x - y = t$ como

$$g(x) = \frac{1}{4}e^{-x} + \frac{1}{2} \int_0^x e^{t-x} g(t) dt.$$

Esta última expresión se corresponde con una ecuación integral de Volterra de convolución de segunda especie. Para obtener una solución aproximada procederemos a sustituir el núcleo e^{t-x} por uno degenerado. Esto se consigue, por ejemplo, desarrollando en serie el núcleo y considerando un número finito de sumandos, por ejemplo tres. En este caso tomaremos como núcleo

$$e^{t-x} = (x-t) \sum_{n=0}^2 \frac{(t-x)^n}{n!},$$

y resolveremos la ecuación

$$\hat{g}(x) = \frac{1}{4}e^{-x} + \frac{1}{2} \int_0^x \sum_{n=0}^2 \frac{(t-x)^n}{n!} \hat{g}(t) dt.$$

Desarrollando la expresión anterior se obtiene,

$$\begin{aligned} \hat{g}(x) &= \frac{1}{4}e^{-x} + \frac{1}{2} \int_0^x \left[\left(1-x + \frac{x^2}{2} - \frac{x^3}{6}\right) + \left(1-x + \frac{x^2}{2}\right)t \right. \\ &\quad \left. + \left(\frac{1}{2} - \frac{x}{2}\right)t^2 + \frac{1}{6}t^3 \right] g(t) dt \\ &= \frac{1}{4}e^{-x} + \frac{1}{2} \left[\left(1-x + \frac{x^2}{2} - \frac{x^3}{6}\right) C_1 + \left(1-x + \frac{x^2}{2}\right) C_2 \right. \\ &\quad \left. + \left(\frac{1}{2} - \frac{x}{2}\right) C_3 + \frac{1}{6} C_4 \right], \end{aligned} \quad (13.26)$$

donde:

$$C_1 = \int_0^x g(t) dt, \quad C_2 = \int_0^x t g(t) dt, \quad C_3 = \int_0^x t^2 g(t) dt. \quad (13.27)$$

13.2. Modelo de riesgo colectivo

Sustituyendo (13.26) en (13.27) se obtiene un sistema de ecuaciones que permite obtener C_1 , C_2 y C_3 , que sustituidos en (13.26) proporciona la solución aproximada de $g(x)$.

Finalmente la probabilidad pedida se calcula mediante la expresión:

$$\Pr(X \geq x) = 1 - \Pr(X < x) = 1 - \left(g_S(0) + \int_0^x \hat{g}(t) dt \right),$$

que aparece tabulada en la tabla 13.3. Como se aprecia las probabilidades aproximadas y exactas difieren poco para valores pequeños de x , aumentando la discrepancia conforme aumentan los valores de x . Si se desea obtener una mejor aproximación se necesitará añadir más sumando al desarrollo en serie.

Tabla 13.3: Probabilidades exactas y aproximadas del modelo geométrica compuesto

x	Exacta	Aproximada
0,01	0,497506	0,497506
0,02	0,495025	0,495025
0,03	0,492556	0,492556
0,04	0,490099	0,490099
0,05	0,487655	0,487654
0,06	0,485223	0,485221
0,07	0,482803	0,482799
0,08	0,480395	0,480389
0,09	0,477999	0,477991
0,10	0,475615	0,475604
0,20	0,452419	0,452337
0,30	0,430354	0,430081
0,40	0,409365	0,408725
0,50	0,389400	0,388158
0,60	0,370409	0,368275
0,70	0,352344	0,348973
0,80	0,335160	0,330149
0,90	0,318814	0,311696
1,00	0,303263	0,293502

13.2.4. Otras fórmulas de recursión

Recordemos que una distribución discreta pertenece a la clase $(a, b, 1)$ si su función de probabilidad verifica:

$$p_n = \left(a + \frac{b}{n}\right) p_{n-1}, \quad n = 2, 3, \dots$$

donde a y b son constantes.

La diferencia de esta clase de distribuciones con la clase $(a, b, 0)$ es que el valor inicial es p_1 , que se supone mayor que cero. El siguiente resultado, cuya demostración se propone al lector, proporciona la fórmula recursiva para la distribución de la cantidad total reclamada.

Teorema 13.8 La función de densidad de $S = \sum_{i=1}^N X_i$, siendo X_i variables aleatorias i.i.d., e independientes de N , satisface la siguiente fórmula recursiva:

$$f_S(x) = \frac{1}{1 - af(0)} \left[\sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x-k) + (p_1 - (a+b)p_0 f(x)) \right] \quad (13.28)$$

donde la variable aleatoria N pertenece a la clase $(a, b, 1)$.

Ejemplo 13.13 Si N sigue la distribución logarítmica de parámetro $\theta = 0,2$ y la cantidad de reclamación es discreta con densidad $f(x) = 0,3 \cdot 0,7^x$; $j = 0, 1, \dots$ se pide calcular $\Pr(S \leq 5)$.

Solución: Es fácil comprobar que la distribución logarítmica con función de probabilidad

$$\Pr(X = x) = -\frac{1}{\log(1-\theta)} \frac{\theta^x}{x}, \quad 0 < \theta < 1,$$

pertenece a la clase $(a, b, 1)$, con $a = \theta$, $b = -\theta$. Utilizando (13.28) podemos calcular recursivamente las probabilidades $f_S(x)$ como:

$$f_S(x) = 0,21276 \sum_{k=1}^x \left(1 - \frac{j}{x}\right) f(k) f_S(x-k),$$

ya que:

$$f_S(0) = P_N(f(0)) = P_N(0,3) = \frac{\log(1-0,3 \cdot 0,2)}{\log(1-0,2)} = 0,27728,$$

donde se ha utilizado la fórmula (6.31):

$$P_N(r) = \frac{\log(1-\theta r)}{\log(1-\theta)},$$

correspondiente a la función generatriz de probabilidad de la densidad logarítmica de parámetro θ . Los valores $p(0)$ y $p(1)$ se calculan usando la expresión:

$$p(n) = -\frac{1}{\log(1-\theta)} \frac{\theta^n}{n} = -\frac{0,2^n}{n \log 0,8}.$$

Después de los cálculos oportunos se obtiene que la probabilidad pedida es 0,856802. $\diamond$

La clase $R2(a, b, c)$

La clase de distribuciones que se define a continuación fue propuesta por Schröter (1990).

Definición 13.3 Una distribución discreta se dice que pertenece a la clase $R2(a, b, c)$ si su función de probabilidad puede calcularse recursivamente a partir de la expresión:

$$p_n = \left(a + \frac{b}{n}\right) p_{n-1} + \frac{c}{n} p_{n-2}, \quad n = 1, 2, \dots \quad (13.29)$$

donde $a > 1$, b y c son constantes y p_{-1} es, por convenio cero.

Obsérvese que ahora la clase de distribuciones $(a, b, 0)$ es un caso particular de la clase $R2(a, b, c)$, que se obtiene cuando $c = 0$. El nombre de $R2$ obedece a que la función de probabilidad satisface cierta ecuación diferencial de segundo orden y a que es posible obtener una fórmula recursiva también para esta clase, como mostramos en el siguiente resultado.

Teorema 13.9 Si N pertenece a la clase $R2(a, b, c)$, entonces la función de densidad de $S = \sum_{i=1}^N X_i$, siendo X_i variables aleatorias i.i.d. e independientes de N , satisface la siguiente fórmula recursiva:

$$f_S(x) = \frac{1}{1 - af(0)} \sum_{k=1}^x \left[\left(a + \frac{bk}{x}\right) f(k) + \frac{ck}{2x} f(k)^2 \right] f_S(x-k).$$

Demostración: Utilizando (13.20), (13.22) y (13.29) se obtiene:

$$\begin{aligned} f_S(x) &= \sum_{n=1}^{\infty} \left[\left(a + \frac{b}{n}\right) p_{n-1} + \frac{c}{n} p_{n-2} \right] f^{*n}(x) \\ &= af(0) f_S(x) + \sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x-k) + \sum_{n=1}^{\infty} \frac{c}{n} p_{n-2} f^{*n}(x) \\ &= af(0) f_S(x) + \sum_{k=1}^x \left(a + \frac{bk}{x}\right) f(k) f_S(x-k) \end{aligned}$$

$$\begin{aligned}
& + \sum_{n=1}^{\infty} \frac{c}{n} p_{n-2} \left[\frac{n}{2x} \sum_{k=1}^x k f^{*2}(s) f^{*(n-2)}(x-k) \right] \\
& = af(0)f_S(x) + \sum_{k=1}^x \left[\left(a + \frac{bk}{x} \right) f(k) + \frac{c}{2x} k f^{*2}(x) \right] f_S(x-k).
\end{aligned}$$

Ahora, teniendo en cuenta que $p_{-1} = 0$ y despejando $f_S(x)$ se obtiene el resultado. ■

Haciendo uso de la expresión (13.55) que aparece en los ejercicios propuestos, se deduce:

1. Si $ca < 1$ y $\delta = 0$, entonces $R2(a, b, c)$ es la distribución de Poisson de parámetro $-c/a$.
2. Si $N \sim R2(a, b, c)$, entonces N es la distribución que concentra su probabilidad en los enteros $\{0, 1, \dots\}$ si y sólo si $a + b = c = 0$.
3. Si denotamos mediante $\mathcal{P}(\theta)$ la distribución de Poisson de parámetro $\theta > 0$ y por $R2(a, b)$ la clase $(a, b, 0)$, entonces:

$$\mathcal{P}(\theta) * R1(a, b) = R2(a, \theta + b, -a\theta),$$

donde $*$ es el símbolo de la convolución.

4. Si denotamos mediante $\mathcal{B}(m, p)$ la distribución binomial de parámetros $m = 1, 2, \dots$ y $p \in (0, 1)$, entonces:

$$\mathcal{P}(\theta) * \mathcal{B}(m, p) = R2\left(-\frac{p}{1-p}, \theta + \frac{p(m+1)}{1-p}, \frac{\theta p}{1-p}\right).$$

5. Si denotamos mediante $\mathcal{BN}(r, p)$ la distribución binomial negativa de parámetros $r \geq 0$, $p \in (0, 1)$, entonces:

$$\mathcal{P}(\theta) * \mathcal{BN}(r, p) = R2(1-p, \theta + (r-1)p, -\theta(1-p)),$$

además de otras relaciones que el lector puede consultar en Schröter (1990).

13.2.5. Aproximación de la cantidad total reclamada

Hemos visto que la distribución de la cantidad total reclamada

$$S = \begin{cases} \sum_{i=1}^N X_i & N \geq 1, \\ 0, & N = 0, \end{cases}$$

cuya función de densidad hemos denotado mediante $f_S(x)$, es un tema en la ciencia actuarial de especial importancia. Hemos visto que existen casos en que se obtiene

13.2. Modelo de riesgo colectivo

una expresión cerrada para la misma. Además, cuando la función de probabilidad de N pertenece a alguna de las clases $(a, b, 0)$, $(a, b, 1)$ o $R2(a, b, c)$ se dispone de un método recursivo para obtener los valores de $f_S(x)$. Sin embargo estas fórmulas recursivas adolecen de estar limitadas a distribuciones del número de reclamaciones perteneciente a dichas clases. De ahí que se hayan desarrollado algunos métodos de cálculo que permiten aproximar la distribución de la cantidad total reclamada independientemente de la distribución de N . Estudiaremos aquí algunos de ellos.

Aproximación normal

Este método se basa en aproximar la distribución de la cantidad total reclamada, $F_S(x) = \Pr(S \leq x)$, mediante una distribución normal con la misma media y varianza que S dadas por (13.5) y (13.6), respectivamente. Se tiene que,

$$F_S(x) \approx \Phi(z),$$

donde

$$Z = \frac{X - \mu_S}{\sigma_S},$$

y $\Phi(z)$ representa la función de distribución de la normal tipificada.

Puesto que S es la suma de un número aleatorio N de variables aleatorias independientes e idénticamente distribuidas, la aproximación se justifica haciendo uso del teorema central del límite. El problema que aparece con esta aproximación es que el número de sumandos es aleatorio y aunque el número esperado de reclamaciones sea suficientemente grande no parece razonable esperar que la distribución normal proporcione una buena aproximación a la distribución de S . Empíricamente se tiene que la aproximación es buena cuando el número esperado de reclamaciones es grande.

Ejemplo 13.14 Dado el modelo de Poisson compuesto en el que la distribución primaria es Poisson de parámetro $\theta > 0$ y la distribución secundaria es exponencial con parámetro $\lambda = 1$, se pide calcular $\Pr(S > x)$ para los valores de $\theta = 1$ y 25 y valores de x entre 0 y 20.

Solución: Los valores exactos se obtienen a partir de (13.14). Por otro lado utilizando la distribución normal de media y varianza como en (13.5) y (13.6), respectivamente se obtienen los valores aproximados. Los resultados aparecen en la tabla 13.4.

Puede observarse que la aproximación no es muy buena para $\theta = 1$ y mejora para $\theta = 25$. En la figura 13.3 aparecen las gráficas de la función de densidad exacta y aproximada para ambos valores de θ .

Tabla 13.4: Probabilidades exactas y aproximadas. Aproximación normal

x	$\theta = 1$		$\theta = 25$	
	Exacta	Aproximada	Exacta	Aproximada
0,2	0,562141	0,714196	1,000000	0,999774
0,4	0,499018	0,664313	1,000000	0,999748
0,6	0,442245	0,611351	1,000000	0,999720
0,8	0,391318	0,556231	1,000000	0,999690
1,0	0,345746	0,500000	1,000000	0,999656
2,0	0,182585	0,239750	1,000000	0,999428
3,0	0,093863	0,078649	0,999997	0,999069
4,0	0,047229	0,016947	0,999982	0,998510
5,0	0,023349	0,002338	0,999929	0,997661
6,0	0,011374	0,000203	0,999774	0,996395
7,0	0,005470	0,000011	0,999388	0,994545
8,0	0,005470	0,000011	0,998548	0,991895
9,0	0,002602	3,716E-7	0,996906	0,988174
10,0	0,001226	7,483E-9	0,993969	0,983053
20,0	0,000000	0,000000	0,749051	0,760250
25,0	0,000000	0,000000	0,471719	0,500000
30,0	0,000000	0,000000	0,228848	0,239750
35,0	0,000000	0,000000	0,086812	0,078649
40,0	0,000000	0,000000	0,026427	0,016947
45,0	0,000000	0,000000	0,006629	0,002338
50,0	0,000000	0,000000	0,001402	0,000203

Aproximación por medio de la distribución gamma trasladada

Es sabido que la distribución de Poisson compuesta y binomial negativa compuesta tienen coeficiente de asimetría positivo y por tanto no resulta adecuada la aproximación normal, estudiada en el apartado anterior. Una alternativa consiste en considerar la distribución gamma trasladada,

$$f(x) = \frac{b^a}{\Gamma(a)} (x-k)^{a-1} e^{-b(x-k)}, \quad x, a, b > 0,$$

y hacer:

$$F_S(x) \approx \int_0^x f(t) dt.$$

13.2. Modelo de riesgo colectivo




Figura 13.3: Función de densidad del modelo de Poisson compuesto: exacta y aproximada. Aproximación normal

Los parámetros de la nueva distribución pueden estimarse resolviendo el sistema que resulta de igualar los tres primeros momentos de la misma con la distribución de la cantidad total reclamada. La resolución de este sistema (utilizamos media, varianza y coeficiente de asimetría) proporciona los siguientes valores de los parámetros:

$$\begin{aligned} \hat{a} &= 4 \frac{\text{Var}(S)^3}{\{E[S - E(S)]^3\}^2}, \\ \hat{b} &= 2 \frac{\text{Var}(S)}{E[S - E(S)]^3}, \\ \hat{k} &= E(S) - 2 \frac{\text{Var}(S)^2}{E[S - E(S)]^3}, \end{aligned}$$

donde se ha tenido en cuenta que la distribución gamma trasladada tiene la misma varianza y coeficiente de asimetría que la gamma clásica.

Ejemplo 13.15 Con los datos del ejemplo 13.14 aproximar las probabilidades de la cola de la distribución de la cantidad total reclamada mediante la aproximación gamma.

Solución: Con las hipótesis del modelo de Poisson compuesto las ecuaciones anteriores se reducen a:

$$\hat{a} = 4\theta \frac{[E(X^2)]^3}{[E(X^3)]^2},$$

$$\hat{b} = 2 \frac{E(X^2)}{E(X^3)},$$

$$\hat{k} = \theta \left\{ E(X) - 2 \frac{[E(X^2)]^2}{E(X^3)} \right\}.$$

Las probabilidades pedidas, así como los valores de los estimadores $\hat{a}$, $\hat{b}$ y $\hat{k}$ aparecen en la tabla 13.5.

Tabla 13.5: Probabilidades exactas y aproximadas. Método de la gamma trasladada.

$\theta = 1$ $\hat{a} = \frac{8}{9}, \hat{b} = \frac{2}{3}, \hat{k} = -\frac{1}{3}$			$\theta = 25$ $\hat{a} = \frac{200}{9}, \hat{b} = \frac{2}{3}, \hat{k} = -\frac{25}{3}$	
x	Exacta	Aproximada	Exacta	Aproximada
0,2	0,562141	0,893358	1,000000	1,000000
0,4	0,499018	0,803951	1,000000	1,000000
0,6	0,442245	0,728078	1,000000	1,000000
0,8	0,391318	0,663255	1,000000	0,999999
1,0	0,345746	0,607633	1,000000	0,999999
2,0	0,182585	0,425212	1,000000	0,999997
3,0	0,093863	0,336167	0,999997	0,999989
4,0	0,047229	0,291999	0,999982	0,999961
5,0	0,023349	0,269909	0,999929	0,999881
6,0	0,011374	0,258805	0,999774	0,999681
7,0	0,005470	0,253205	0,999388	0,999232
8,0	0,005470	0,250373	0,998548	0,998316
9,0	0,002602	0,248939	0,996906	0,996597
10,0	0,001226	0,248211	0,993969	0,993602
20,0	0,000000	0,247460	0,749051	0,749912
25,0	0,000000	0,247459	0,471719	0,471784
30,0	0,000000	0,247459	0,228848	0,228287
35,0	0,000000	0,247459	0,086812	0,086520
40,0	0,000000	0,247459	0,026427	0,026461
45,0	0,000000	0,247459	0,006629	0,006728
50,0	0,000000	0,247459	0,001402	0,001460

El ajuste no es muy satisfactorio para $\theta = 1$ y mejora en el caso $\theta = 25$. Esto se ilustra en la figura 13.4.

13.2. Modelo de riesgo colectivo




Figura 13.4: Función de densidad del modelo de Poisson compuesto: exacta y aproximada. Aproximación gamma

Aproximación de Edgeworth

Consideremos la variable aleatoria $Z = (S - E(S))/\sqrt{\text{Var}(S)}$ cuya media es 0 y varianza 1 y denotemos mediante $M(t)$ la función generatriz de momentos de Z . Desarrollando en serie de Taylor dicha función alrededor del origen tenemos:

$$\log M(t) = \sum_{i=0}^{\infty} a_i t^i,$$

donde:

$$a_k = \frac{1}{k!} \frac{d^k}{dt^k} \log M(t) \Big|_{t=0}.$$

Llamando $\mu = E(S)$ y $\sigma = \sqrt{\text{Var}(S)}$ se obtiene que

$$a_0 = 0,$$

$$a_1 = \frac{M'(0)}{M(0)} = \frac{E(Z)}{M(0)} = 0,$$

$$a_2 = \frac{1}{2} \frac{M''(0)M(0) - M'(0)^2}{M(0)^2} = \frac{1}{2} \text{Var}(Z) = \frac{1}{2},$$

$$a_3 = \frac{1}{6} E(Z^3) = \frac{1}{6} \frac{E[(S - \mu)^3]}{\sigma^3},$$

$$a_4 = \frac{1}{24} \left\{ \frac{E[(S - \mu)^4]}{\sigma^4} - 3 \right\}.$$

etc. Ahora $M(t)$ puede escribirse como:

$$\begin{aligned} M(t) &= e^{\frac{1}{2}t^2} e^{a_3 t^3 + a_4 t^4 + \dots} = e^{\frac{1}{2}t^2} \sum_{k=0}^{\infty} \frac{(a_3 t^3 + a_4 t^4 + \dots)^k}{k!} \\ &= e^{\frac{1}{2}t^2} (1 + a_3 t^3 + a_4 t^4 + \dots). \end{aligned} \quad (13.30)$$

Observemos ahora que:

$$e^{\frac{1}{2}t^2} = \int_{-\infty}^{\infty} e^{tx} \phi(x) dx, \quad (13.31)$$

es decir, se trata de la función generatriz de momentos de la función de densidad normal tipificada. Multiplicando (13.31) por t e integrando por partes se obtiene que

$$t e^{\frac{1}{2}t^2} = - \int_{-\infty}^{\infty} e^{tx} \phi'(x) dx,$$

y multiplicando por t^2 obtenemos:

$$t^2 e^{\frac{1}{2}t^2} = \int_{-\infty}^{\infty} e^{tx} \phi''(x) dx,$$

y en general,

$$t^k e^{\frac{1}{2}t^2} = (-1)^k \int_{-\infty}^{\infty} e^{tx} \phi^{(k)}(x) dx,$$

de donde la ecuación (13.30) puede escribirse como:

$$f_S(z) = \phi(z) - a_3 \phi^{(3)}(z) + a_4 \phi^{(4)}(z) + \frac{a_3^2}{2} \phi^{(6)}(z) + \dots \quad (13.32)$$

La serie (13.32) se denomina serie de Edgeworth. La experiencia demuestra que una buena aproximación de la distribución de la cantidad total reclamada se obtiene tomando los cuatro primeros términos de esta serie. Así:

$$F_S(z) \approx \Phi(z) - a_3 \Phi^{(3)}(z) + a_4 \Phi^{(4)}(z) + \frac{a_3^2}{2} \Phi^{(6)}(z). \quad (13.33)$$

Por tanto,

$$F_S(x) = \Pr(S \leq x) = \Pr(Z \leq z) = F_S(z),$$

siendo $z = (x - E(S)) / \sigma_S$, donde σ_S es la desviación típica de S .

Ejemplo 13.16 Obtener la serie de Edgeworth para el modelo de Poisson compuesto en el que el parámetro de la Poisson es $\theta > 0$.

Solución: Utilizando (13.5), (13.6) y (13.10) se obtiene:

$$\begin{aligned} \mu = E(S) &= \theta E(X), \\ \sigma^2 &= \theta E(X^2), \\ E(S - \mu)^3 &= \theta E(X^3). \end{aligned}$$

A partir de la relación anterior se obtiene que

$$E[(S - \mu)^4] = \theta [E(X^4) + 3\theta E^2(X^2)].$$

Luego, la serie de Edgeworth (13.33) puede escribirse como:

$$F_S(z) \approx \Phi(z) - \frac{p_3}{6\alpha_2^{3/2}\sqrt{\theta}} \Phi^{(3)}(z) + \frac{1}{\theta} \left[\frac{\alpha_4}{24\alpha_2^2} \Phi^{(4)}(z) + \frac{\alpha_3^2}{72\alpha_2^3} \Phi^{(6)}(z) \right] + \dots \quad (13.34)$$

con $\alpha_k = E(X^k)$.

Ejemplo 13.17 Con los datos del ejemplo 13.14 aproximar las probabilidades de la cola de la distribución de la cantidad total reclamada mediante la aproximación Edgeworth.

Solución: En este caso $\alpha_1 = 1$, $\alpha_2 = 2$, $\alpha_3 = 6$ y $p_4 = 24$, luego (13.34) resulta:

$$F_S(z) \approx \Phi(z) - \frac{1}{\sqrt{8\theta}} \Phi^{(3)}(z) + \frac{1}{4\theta} \left[\Phi^{(4)}(z) + \frac{1}{4} \Phi^{(6)}(z) \right] + \dots$$

Después de las correspondientes operaciones se obtienen los resultados que aparecen en la tabla 13.6, en la que se observa que ahora hay un mejor ajuste para los dos casos considerados, aunque sigue siendo mejor el caso $\theta = 25$.

Aproximación de Esscher

Comencemos definiendo la transformada de Esscher.

Definición 13.4 Dada la variable aleatoria S con distribución $F_S(x)$ y función generatriz de momentos $M(t)$, para cualquier número real h , la función de distribución $\tilde{F}_S(x)$ dada por

$$d\tilde{F}_S(x) = \frac{1}{M(h)} e^{hx} dF(x), \quad (13.35)$$

se denomina transformada de Esscher de $F(x)$ con parámetro h .

Tabla 13.6: Probabilidades exactas y aproximadas. Aproximación de Edgeworth

x	$\theta = 1$		$\theta = 25$	
	Exacta	Aproximada	Exacta	Aproximada
0.2	0.562141	0.618254	1.000000	0.999853
0.4	0.499018	0.539733	1.000000	0.999853
0.6	0.442245	0.469557	1.000000	0.999864
0.8	0.391318	0.409325	1.000000	0.999872
1.0	0.345746	0.358953	1.000000	0.999881
2.0	0.182585	0.188259	1.000000	0.999949
3.0	0.093863	0.065677	0.999997	1.000000
4.0	0.047229	0.048073	0.999982	1.000000
5.0	0.023349	0.044964	0.999929	1.000000
6.0	0.011374	0.017672	0.999774	1.000000
7.0	0.005470	0.003166	0.999388	0.999992
8.0	0.005470	0.000285	0.998548	0.999159
9.0	0.002602	0.000013	0.996906	0.997421
10.0	0.001226	3.657E-7	0.993969	0.994295
20.0	0.000000	0.000000	0.749051	0.749128
25.0	0.000000	0.000000	0.471719	0.471791
30.0	0.000000	0.000000	0.228848	0.228903
35.0	0.000000	0.000000	0.086812	0.086432
40.0	0.000000	0.000000	0.026427	0.026517
45.0	0.000000	0.000000	0.006629	0.006937
50.0	0.000000	0.000000	0.001402	0.001403

Ahora $\tilde{F}_S(x)$ es la función de distribución asociada a una nueva variable aleatoria $\tilde{S}$.

Proposición 13.9 La función generatriz de momentos de $\tilde{F}_S(x)$ viene dada por

$$\tilde{M}(t) = \frac{M(t+h)}{M(h)}. \quad (13.36)$$

Demostración: Se obtiene usando la definición de función generatriz. $\blacksquare$

Ejemplo 13.13 Calcular las transformadas de Esscher de la distribución de Poisson, la distribución exponencial y de la distribución de Poisson compuesta con parámetro para la Poisson $\theta > 0$ y función generatriz de momentos $m(t)$ para la distribución de la cantidad reclamada.

13.2. Modelo de riesgo colectivo

Solución: Si la variable aleatoria X sigue una distribución de Poisson de parámetro $\theta > 0$ con distribución $F(x)$, entonces:

$$\tilde{F}(x) = \frac{1}{e^{\theta(e^h-1)}} \sum_{y=0}^x \frac{e^{hy} e^{-\theta} \theta^y}{y!} = \sum_{y=0}^x \frac{e^{-\theta e^h} (\theta e^h)^y}{y!},$$

que corresponde a una distribución de Poisson con parámetro θe^h .

Ahora, si $F(x)$ es la función de distribución de una variable aleatoria exponencial con parámetro $\lambda > 0$, entonces se comprueba que la transformada de Esscher de $F(x)$ es de nuevo una distribución exponencial con parámetro $\lambda - h$, siendo $\lambda > h$.

Finalmente si $F(x)$ es la función de distribución de un modelo de Poisson compuesto sabemos que la función generatriz de momentos es

$$M(t) = e^{\theta[m(t)-1]}$$

y por (13.36):

$$\begin{aligned} \tilde{M}(t) &= e^{\theta[m(t+h)-1]-\theta[m(h)-1]} = e^{\theta[m(t+h)-m(h)]} \\ &= e^{\theta m(h) \left[\frac{m(t+h)}{m(h)} - 1 \right]} = e^{\theta m(h)[\tilde{m}(t)-1]}. \end{aligned}$$

Por tanto, $\tilde{F}_S(x)$ es una distribución de Poisson compuesta con distribución primaria Poisson con parámetro $\theta m(h)$ y distribución secundaria la transformada de Esscher de la distribución secundaria original. $\diamond$

Ejemplo 13.19 Demostrar que $E(\tilde{S})$ es una función creciente respecto de h .

Solución: Utilizando (13.36) se deduce:

$$E(\tilde{S}) = \tilde{M}'(0) = \frac{M'(h)}{M(h)}.$$

Ahora:

$$\begin{aligned} \frac{dE(\tilde{S})}{dh} &= \frac{M''(h)M(h) - M'(h)^2}{M(h)^2} = \frac{M''(h)}{M(h)} - \frac{M'(h)^2}{M(h)^2} \\ &= E(\tilde{S}^2) - E(\tilde{S})^2 = \text{Var}(\tilde{S}) > 0. \end{aligned}$$

Esto prueba que la variable aleatoria $\tilde{S}$ concentra mayor masa de probabilidad a la derecha conforme aumenta el valor de h y puesto que el rango de $\tilde{S}$ coincide con el de S , ocurrirá lo mismo para la variable aleatoria S . $\diamond$

La idea de la aproximación de Esscher es muy simple. Para calcular $1 - F_S(x)$, transformamos la distribución $F_S(x)$ mediante la transformada de Esscher en $\tilde{F}_S(x)$ de modo que la media de $\tilde{F}_S(x)$ sea igual a x y aplicamos la aproximación de Edgeworth a la distribución $\tilde{F}_S(x)$. La razón de esto estriba en que la aproximación Edgeworth da lugar a buenos resultados para valores de x cercanos a la media y malos en la cola. Hacemos:

$$E(\tilde{S}) = \frac{M'(h)}{M(h)} = x, \quad (13.37)$$

ecuación que además permite obtener el valor de h . Ahora, considerando la serie (13.32) truncada a partir del segundo sumando obtenemos:

$$\tilde{f}_S(y)dy \approx \phi(z)dz - \frac{E(\tilde{S} - x)^3}{6[\text{Var}(\tilde{S})]^{3/2}} \phi^{(3)}(z)dz, \quad (13.38)$$

siendo $f_S(y)dy = dF_S(y)$ y $z = (y - x)/\sqrt{\text{Var}(\tilde{S})}$. De (13.35) tenemos:

$$f_S(y) = M(h)e^{-hy} \tilde{f}_S(y),$$

de donde se deduce:

$$1 - F_S(x) = M(h) \int_x^\infty e^{-hy} \tilde{f}_S(y)dy, \quad (13.39)$$

$$F_S(x) = M(h) \int_{-\infty}^x e^{-hy} \tilde{f}_S(y)dy. \quad (13.40)$$

Finalmente sustituimos (13.38) en (13.39) o en (13.40) dependiendo de si h es positivo o negativo, respectivamente.

Ejemplo 13.20 Con los datos del ejemplo 13.14 aproximar las probabilidades de la cola de la distribución de la cantidad total reclamada mediante la aproximación de Esscher.

Solución: En este caso, la ecuación (13.37) se convierte en:

$$\frac{M'(h)}{M(h)} = \theta m'(h) = \frac{\theta}{(1-h)^2} = x,$$

de donde se deduce que $h = 1 \pm \sqrt{\frac{\theta}{x}}$, y puesto que $\lambda > h$, entonces $h = 1 - \sqrt{\frac{\theta}{x}}$. Ahora, usando (13.39) y (13.40) se obtienen los datos que aparecen en la tabla 13.7.

◇

Tabla 13.7: Probabilidades exactas y aproximadas. Aproximación de Esscher

x	$\theta = 1$		$\theta = 25$	
	Exacta	Aproximada	Exacta	Aproximada
0,2	0,562141	0,470734	1,000000	1,000000
0,4	0,499018	0,290136	1,000000	1,000000
0,6	0,442245	0,270171	1,000000	1,000000
0,8	0,391318	0,215249	1,000000	1,000000
1,0	0,345746	0,158655	1,000000	1,000000
2,0	0,182585	0,010405	1,000000	0,999978
3,0	0,093863	0,000226	0,999997	0,999806
4,0	0,047229	2,168E-7	0,999982	0,997664
5,0	0,023349	0,000000	0,999929	0,988338
6,0	0,011374	0,000000	0,999774	0,964913
7,0	0,005470	0,000000	0,999388	0,920656
8,0	0,005470	0,000000	0,998548	0,852342
9,0	0,002602	0,000000	0,996906	0,762312
10,0	0,001226	0,000000	0,993969	0,657502

13.2.6. Tarificación bajo el modelo colectivo compuesto

Cálculo de primas y credibilidad

Es posible obtener expresiones de las primas de riesgo, colectiva y Bayes cuando se trabaja con el modelo colectivo compuesto para los modelos en los que la distribución de la cantidad total reclamada admite una expresión cerrada. En otro caso se requerirán métodos numéricos para obtener las primas.

Así, por ejemplo, en Freifelder (1974) se obtienen las primas bajo el modelo colectivo compuesto y utilizando el principio exponencial. En Gómez-Déniz et al. (2002a) se obtienen también bajo el modelo de Poisson compuesto las primas bajo los principios de Esscher y de varianza. Nos limitaremos aquí a mostrar algunos ejemplos, así como algunos ejercicios propuestos en la sección correspondiente, pudiendo el lector obtener las expresiones de las primas bajo los principios de cálculo de primas estudiados en el capítulo anterior.

Ejemplo 13.21 Si la distribución primaria es Poisson de parámetro θ y la distribución secundaria es exponencial de parámetro λ , calcular la prima de riesgo de Esscher basada en la cantidad total reclamada.

Solución: Utilizando (13.11) y (12.5) resulta:

$$P(\theta, \lambda) = \frac{\int s e^{\alpha s} f(s) ds}{\int e^{\alpha s} f(s) ds} = \frac{\lambda \theta}{(\lambda - \alpha)^2}. \quad (13.41)$$

◇

Ejemplo 13.22 Con los datos del ejemplo 13.21 y suponiendo que el parámetro θ siga en el colectivo de asegurados una distribución a priori gamma $\mathcal{G}(a, 1/b)$ con función de densidad $\pi(\theta) \propto \theta^{a-1} e^{-b\theta}$, calcular la prima colectiva y Bayes.

Solución: Utilizando ahora (13.41) y (12.10) se obtiene, después de algunos cálculos que la prima colectiva viene dada por:

$$P' = \frac{\lambda a}{b(\lambda - \alpha)^2 - \lambda \alpha}. \quad (13.42)$$

Ahora teniendo en cuenta que para una muestra con media $\bar{x}$ la distribución a posteriori del parámetro es conjugada para la verosimilitud Poisson, la prima Bayes se obtiene intercambiando en (13.42) a y b por $a + t\bar{x}$ y $b + t$, respectivamente, obteniéndose:

$$P' = \frac{\lambda(a + t\bar{x})}{(b + t)(\lambda - \alpha)^2 - \lambda \alpha}. \quad (13.43)$$

◇

Ejemplo 13.23 Con los datos del ejemplo 13.21 se pide calcular las primas bonus-malus basadas en la cantidad total reclamada para la cartera del ejemplo 12.16, para valores $t = 1, \dots, 4$, $t\bar{x} = 1, \dots, 4$, $\alpha = 0,4$ y $\lambda = 5$.

Solución: La prima bonus-malus viene dada por:

$$P_{BM}(\bar{x}, t) = \frac{\lambda(a + t\bar{x})}{(b + t)(\lambda - \alpha)^2 - \lambda \alpha} \cdot \frac{b(\lambda - \alpha)^2 - \lambda \alpha}{\lambda \alpha},$$

que se obtiene dividiendo (13.43) entre (13.42). Los estimadores de a y b , tomados del ejemplo 12.16 eran $\hat{a} = 1,6049$, $\hat{b} = 15,8778$. Después de los correspondientes cálculos se obtienen las primas que aparecen en la tabla 13.8

◇

Ejemplo 13.24 Calcular la prima de riesgo exponencial basada en la distribución de la cantidad total reclamada bajo el modelo geométrica exponencial.

13.2. Modelo de riesgo colectivo

Tabla 13.8: Primas bonus-malus para un modelo compuesto

t	t $\bar{x}$				
	0	1	2	3	4
0	1	1,623	2,246	2,869	3,492
1	0,940	1,526	2,112	2,698	3,284
2	0,887	1,440	1,993	2,546	3,099
3	0,840	1,363	1,887	2,411	2,934
4	0,797	1,295	1,729	2,289	2,786

Solución: Utilizando (12.4) y (13.15) resulta:

$$\begin{aligned} P(\theta) &= \frac{1}{\alpha} \log \int_0^\infty \theta(1-\theta) \lambda e^{-\theta \lambda x} e^{\alpha x} dx \\ &= \frac{1}{\alpha} \log \left[\lambda \theta(1-\theta) \int_0^\infty e^{-(\theta \lambda - \alpha)x} dx \right] \\ &= \frac{1}{\alpha} \log \left[\frac{\lambda \theta(1-\theta)}{\theta \lambda - \alpha} \right], \quad \alpha > 0. \end{aligned}$$

◇

Los modelos de credibilidad total y parcial estudiados en el capítulo anterior pueden aplicarse al modelo colectivo, como se pone de manifiesto en el siguiente ejemplo.

Ejemplo 13.25 Una empresa aseguradora ha seguido la evolución de la cantidad reclamada de un contrato de seguro durante 10 años. Si la distribución primaria es Poisson de parámetro 100 y la distribución secundaria tiene media 400 y varianza 100, se pide estimar el factor de credibilidad para la cantidad total reclamada. Se supone $c = 0,04$ y $p = 0,95$.

Solución: Se tiene que:

$$\begin{aligned} \varepsilon &= E(S) = 100 \times 400, \\ \text{Var}(S) &= 100(100 + 400^2), \end{aligned}$$

donde para el cálculo de la varianza se ha hecho uso de (13.5) y (13.6), respectivamente. Ahora $\lambda_0 = (1,96/0,04)^2 = 2401$, y usando (12.21) resulta $Z(10) = 0,64516$.

◇

Reaseguro

Para el modelo colectivo compuesto hay que tener en cuenta que en el caso de contrato de reaseguro la cantidad total reclamada está compartida por el asegurador y el reasegurador. Escribiremos $S = S_A + S_R$, donde S_A denota la cantidad total reclamada de la empresa aseguradora y S_R la cantidad total reclamada de la reaseguradora.

Reaseguro proporcional

Bajo un contrato de reaseguro proporcional con retención a , se verifica:

$$S_A = \sum_{i=1}^N aX_i = aS,$$

con $S_A = 0$ si $S = 0$. Por tanto $S_R = (1 - a)S$.

Ejemplo 13.26 Supongamos que la cantidad total reclamada S sigue una distribución de Poisson compuesta siendo el parámetro de la Poisson $\theta = 20$, mientras que la distribución secundaria es exponencial con parámetro $\lambda = 10$. Se pide calcular las distribuciones de S_A y S_R si la retención es $a = 0,6$.

Solución: Es fácil deducir que ambas distribuciones serán la Poisson compuesta con parámetros de $\theta = 20$ para la Poisson de S_A y S_R , mientras que, puesto que el asegurador paga el 60 %, los parámetros de la distribución exponencial para ambas distribuciones será $\lambda = 6$ para S_A y $\lambda = 4$ para S_R .

◇

Reaseguro stop-loss

Supongamos que el asegurador de un riesgo S ha efectuado un contrato de reaseguro con retención M . Por tanto,

$$S_A = \begin{cases} \sum_{i=1}^N \min\{X_i, M\}, & N > 0, \\ 0, & N = 0, \end{cases}$$

mientras que

$$S_R = \begin{cases} \sum_{i=1}^N \max\{0, X_i - M\}, & N > 0, \\ 0, & N = 0. \end{cases}$$

S_R también puede escribirse como

$$S_R = \begin{cases} \sum_{i=1}^{N_R} \tilde{X}_i, & N_R > 0, \\ 0, & N_R = 0, \end{cases}$$

13.3. Modelo de riesgo individual

donde N_R denota el número de reclamaciones a la aseguradora que superan el nivel de retención M , y por tanto constituyen reclamación para la reaseguradora y $\tilde{X}_i$ representa las cantidades correspondientes a la i -ésima reclamación mayor que M . Si denotamos:

$$I_j = \begin{cases} 1, & X_j > 0, \\ 0, & \text{otro caso,} \end{cases}$$

entonces:

$$\Pr(I_j = 1) = \Pr(X_j > M) = 1 - F(M) = g(M),$$

y

$$N_R = \begin{cases} \sum_{j=1}^N I_j, & N > 0, \\ 0, & N = 0. \end{cases}$$

Por tanto, N_R sigue una distribución compuesta con función generatriz:

$$P_{N_R}(r) = P_N[P_I(r)],$$

donde P_I es la función generatriz de probabilidad de cada una de las variables I_j , $j = 1, 2, \dots$ con:

$$P_I(r) = [1 - g(M)]r^0 + g(M)r = 1 + (r - 1)g(M).$$

Ejemplo 13.27 Si N sigue una distribución de Poisson de parámetro 10, obtener la distribución de probabilidad de N_R .

Solución: Mediante funciones generatrices,

$$P_{N_R}(r) = e^{10[1 + (r-1)g(M) - 1]} = e^{10(r-1)g(M)},$$

de donde se deduce que la distribución de N_R es de tipo Poisson de parámetro $10g(M)$.

◇

13.3. Modelo de riesgo individual

En el modelo colectivo que acabamos de estudiar se considera la cantidad total reclamada procedente de una cartera sin distinguir entre pólizas. Una aproximación alternativa consiste en considerar la cantidad total reclamada de la cartera como la suma de la cantidad total reclamada de las distintas pólizas que integran la cartera. Este planteamiento constituye el modelo individual que se analizará a continuación.

Definición 13.5 Un modelo de riesgo individual representa la cantidad total reclamada como la suma de las cantidades pagadas en cada una de las pólizas o contratos que componen la cartera de riesgos. Así, $S = \sum_{j=1}^n X_j$, donde X_j es la cantidad asegurada (pagada) en la póliza j -ésima y en el que se supone que $X_1, \dots, X_n$ son variables aleatorias independientes.

Obsérvese que n es el número total de pólizas en la cartera y no constituye una variable aleatoria. La variable X_j contiene, sin embargo, dos elementos aleatorios. Por un lado, la ocurrencia o no de siniestro para dicha póliza (excluiremos la posibilidad de más de un siniestro), y dado que ha ocurrido un siniestro, la cantidad reclamada por motivo del mismo. La cantidad total reclamada es $S = \sum_{j=1}^n X_j$, que contiene un número n conocido de sumandos. Se verifica:

$$E(S) = \sum_{i=1}^n E(X_i), \quad (13.44)$$

$$\text{Var}(S) = \sum_{i=1}^n \text{Var}(X_i). \quad (13.45)$$

Podemos escribir $X_j = I_j B_j$, siendo I_j una variable dicotómica con distribución Bernoulli de parámetro q_j y B_j la variable aleatoria asociada a la cantidad reclamada, con densidad $f_{X_j}(x)$. Así:

$$I_j = \begin{cases} 1, & q_j = 1 - p_j, \\ 0, & p_j, \end{cases}$$

$$f_{X_j}(x) = \begin{cases} p_j = 1 - q_j, & x = 0, \\ q_j, & x = b_j. \end{cases}$$

Ahora, la media y la varianza de la cantidad total reclamada es:

$$E(S) = \sum_{j=1}^n b_j q_j,$$

$$\text{Var}(S) = \sum_{j=1}^n b_j^2 q_j (1 - q_j).$$

Ejemplo 13.28 Supóngase que $E(X_j) = \mu_j$ y $\text{Var}(X_j) = \sigma_j^2$, $j = 1, 2, \dots, n$. Calcular $E(S)$ y $\text{Var}(S)$, siendo $S = \sum_{j=1}^n X_j$.

Solución: En primer lugar, obsérvese que la variable $X_j = I_j B_j$ puede también reescribirse como $X_j = \sum_{j=1}^{I_j} B_j$. Utilizando (13.5) resulta:

$$E(X_j) = E(I_j)E(B_j) = q_j \mu_j, \quad j = 1, 2, \dots, n.$$

13.3. Modelo de riesgo individual

Por otro lado, utilizando (13.6) tenemos:

$$\text{Var}(X_j) = q_j \sigma_j^2 + \mu_j^2 q_j (1 - q_j), \quad j = 1, 2, \dots, n.$$

Finalmente, de (13.44) y (13.45) se deduce:

$$E(S) = \sum_{j=1}^n q_j \mu_j, \quad (13.46)$$

$$\text{Var}(S) = \sum_{j=1}^n [q_j \sigma_j^2 + \mu_j^2 q_j (1 - q_j)]. \quad (13.47)$$

De nuevo, al igual que en el modelo colectivo, resulta de interés obtener la distribución de la cantidad total reclamada. Esta distribución puede obtenerse de manera exacta como mostramos en la siguiente sección. $\diamond$

13.3.1. Cálculo directo mediante convolución

Sea

$$f_S(x) = \Pr(X_1 + \dots + X_n = x) = f_{X_1} * \dots * f_{X_n}(x), \quad x = 0, 1, \dots$$

la función de densidad de probabilidad de la cantidad total reclamada S , donde

$$f_{X_j}(x) = \begin{cases} p_j = 1 - q_j, & x = 0, \\ q_j, & x = j, \end{cases}$$

es la función de densidad de probabilidad de la cuantía que se pagará en caso de siniestro para la póliza j -ésima, $j = 1, 2, \dots, n$. Supondremos que estas cantidades son un número entero múltiplo de la unidad monetaria que se adopte. Entonces, $f_S(x)$ se puede calcular mediante convolución de la siguiente manera:

$$f_S^{*1}(x) = \Pr(X_1 = x) = f_{X_1}(x), \quad (13.48)$$

$$f_S^{*k}(x) = \sum_{y=0}^x f_S^{*(k-1)}(x-y) f_{X_k}(y), \quad x = 0, 1, \dots \quad (13.49)$$

Ejemplo 13.29 Considérese la cartera (ficticia y válida sólo para efectos expositivos) formada por 2 contratos de seguros de vida y que aparece en la tabla 13.9. Las probabilidades de muerte de cada asegurado se calculan en la práctica de acuerdo a las tablas de mortalidad en función del sexo y edad del asegurado. Se pide calcular, mediante convolución la función de probabilidad para la variable aleatoria cantidad total reclamada.

Tabla 13.9: Cartera de seguros de vida. Capital asegurado

q_j	1	2
q_1	1	0
q_2	0	1

Solución: Obsérvese que la cartera se compone de dos asegurados con capital asegurado 1 y 2. Luego, la cantidad total reclamada máxima posible es 3. Utilizando (13.48) y (13.49) tenemos:

$$\begin{aligned}
 f_S^*(x) &= f_{X_1}(x), \\
 f_S^*(0) &= f_S^*(0) = f_S^*(0)f_{X_2}(0) = p_1p_2, \\
 f_S^*(1) &= f_S^*(1) = f_S^*(1)f_{X_2}(0) + f_S^*(0)f_{X_2}(1) = q_1p_2 + p_2 \cdot 0 = q_1p_2, \\
 f_S^*(2) &= f_S^*(2) = \sum_{y=0}^2 f_S^*(2-y)f_{X_2}(y) \\
 &= f_S^*(2)f_{X_2}(0) + f_S^*(1)f_{X_2}(1) + f_S^*(0)f_{X_2}(2) \\
 &= 0 \cdot p_2 + q_1 \cdot 0 + p_1q_2 = p_1q_2, \\
 f_S^*(3) &= f_S^*(3) = \sum_{y=0}^2 f_S^*(3-y)f_{X_2}(y) \\
 &= f_S^*(3)f_{X_2}(0) + f_S^*(2)f_{X_2}(1) + f_S^*(1)f_{X_2}(2) + f_S^*(0)f_{X_2}(3) \\
 &= 0 \cdot p_2 + 0 \cdot q_2 + q_1q_2 + p_1 \cdot 0 = q_1q_2.
 \end{aligned}$$

Obsérvese ahora que

$$\sum_{x=0}^3 f_S(x) = p_1p_2 + q_1p_2 + p_1q_2 + q_1q_2 = 1.$$

Como se aprecia, el cálculo de la distribución de la cantidad total reclamada puede resultar complicado y laborioso cuando el número de pólizas es grande. De ahí que se requieran de métodos más sencillos que permitan calcular dicha distribución. La fórmula de recursión de De Pril que se expone en la siguiente sección se muestra muy útil en este caso.

13.3.2. Fórmula de recursión de De Pril

La fórmula de recursión de De Pril (De Pril, 1986) puede ser vista como la contrapartida a la fórmula de recursión de Panjer del modelo colectivo para el modelo

13.3. Modelo de riesgo individual

individual, y mejora el método de aproximación de Kornya (1983) desarrollado para la aproximación de la distribución de S .

Resulta conveniente estructurar la cartera de acuerdo a la suma asegurada y a la probabilidad de siniestro. Para ello consideremos una cartera de pólizas de seguros independientes como la que aparece recogida en la tabla 13.10.

Tabla 13.10: Cartera de seguros de vida

	1	...	i	...	a
q_1	c_{11}	...	c_{i1}	...	c_{a1}
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
q_j	c_{1j}	...	c_{ij}	...	c_{aj}
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
q_b	c_{1b}	...	c_{ib}	...	c_{ab}

- La cartera consta de a sumas aseguradas. Se supondrá que estas cantidades son un número entero múltiplo de la unidad monetaria que se adopte.
- q_j es la probabilidad de siniestro para los asegurados en la fila j , $j = 1, \dots, b$.
- c_{ij} representa el número de asegurados con suma asegurada i y probabilidad de siniestro q_j . Se supondrá que cada asegurado puede producir un siniestro con probabilidad q_j o ninguno con probabilidad $p_j = 1 - q_j$. Esta situación no es la más apropiada para la mayoría de los ramos de seguros, aunque sí lo es en el caso de seguros vida, de ahí que la mayor aplicación del modelo individual se dé en este ramo de seguros. Por tanto, suponiendo que trabajamos con una cartera de seguros vida, tenemos que q_j es la probabilidad de fallecimiento, mientras que $p_j = 1 - q_j$ es la probabilidad de supervivencia para los asegurados en la fila j .
- $c_j = \sum_{i=1}^a c_{ij}$ es el número de asegurados con tasa de mortalidad q_j .
- $c = \sum_{j=1}^b c_j$ es el número de pólizas o asegurados.
- $m = \sum_{i=1}^a \sum_{j=1}^b ic_{ij}$ es la cantidad total reclamada máxima posible.

Teorema 13.10 (Fórmula de recursión de De Pril) Sea S la cantidad total reclamada con función de probabilidad $f_S(x)$. Sea también:

$$a(j, k) = \left(\frac{q_j}{p_j} \right)^k, \quad (13.50)$$

$$A(i, k) = (-1)^{k+1} i \sum_{j=1}^b c_{ij} a(j, k). \quad (13.51)$$

Entonces se verifica la siguiente recursión:

$$f_S(0) = \prod_{j=1}^b p_j^{c_j}, \quad (13.52)$$

$$f_S(x) = \frac{1}{x} \sum_{i=1}^{\min\{a, x\}} A(i, k) \sum_{k=1}^{\lfloor x/i \rfloor} f_S(x - ki), \quad x = 1, 2, \dots, m. \quad (13.53)$$

siendo

$$\lfloor x/i \rfloor = \max \{n \in \mathbb{N} : n \leq x/i\}.$$

Demostración: Obsérvese en primer lugar que la función generatriz de probabilidad de la variable aleatoria cantidad reclamada por un asegurado con tasa de mortalidad q_j y suma asegurada i es

$$P_{ij}(u) = 1 - q_j + q_j u^i.$$

Ahora, la función generatriz de probabilidad de la variable aleatoria S es

$$P_S(u) = \sum_{s=0}^m f_S(s) u^s = f_S(0) + \sum_{s=1}^m f_S(s) u^s.$$

Puesto que $X_1, X_2, \dots, X_n$ son independientes, tenemos:

$$\begin{aligned} P_S(u) &= P_{X_1+X_2+\dots+X_n}(u) = \prod_{i=1}^n P_{X_i}(u) \\ &= \prod_{i=1}^a \prod_{j=1}^b [P_{X_{ij}}(u)]^{c_{ij}} = \prod_{i=1}^a \prod_{j=1}^b (p_j + q_j u^i)^{c_{ij}}. \end{aligned}$$

Haciendo ahora $u = 0$ resulta $P_S(0) = \prod_{j=1}^b p_j^{c_j} = f_S(0)$. Por otro lado tenemos:

$$\frac{d}{du} \log P_S(u) = \frac{P'_S(u)}{P_S(u)} = \sum_{i=1}^a \sum_{j=1}^b c_{ij} i u^{i-1} \frac{q_j}{p_j + q_j u^i},$$

de modo que:

$$u P'_S(u) = P_S(u) \sum_{i=1}^a \sum_{j=1}^b c_{ij} i u^i \frac{q_j}{p_j + q_j u^i}$$

$$\begin{aligned} &= P_S(u) \sum_{i=1}^a \sum_{j=1}^b c_{ij} i u^i \frac{q_j}{p_j} \left(1 + \frac{q_j}{p_j} u^i\right)^{-1} \\ &= P_S(u) \sum_{i=1}^a \sum_{j=1}^b c_{ij} i u^i \frac{q_j}{p_j} \sum_{k=0}^{\infty} (-1)^k \left(\frac{q_j}{p_j} u^i\right)^k \\ &= P_S(u) \sum_{i=1}^a \sum_{j=1}^b c_{ij} i u^i \frac{q_j}{p_j} \sum_{k=1}^{\infty} (-1)^{k-1} \left(\frac{q_j}{p_j} u^i\right)^{k-1} \\ &= P_S(u) \sum_{i=1}^a \sum_{j=1}^b c_{ij} i \sum_{k=1}^{\infty} (-1)^{k-1} \left(\frac{q_j}{p_j}\right)^k u^{ik} \\ &= P_S(u) \sum_{i=1}^a \sum_{j=1}^b u^{ki} (-1)^{k-1} i \sum_{j=1}^b c_{ij} a(j, k). \end{aligned}$$

Definiendo:

$$A(i, k) = \begin{cases} (-1)^{k-1} i \sum_{j=1}^b c_{ij} a(j, k), & i = 1, 2, \dots, a, \\ 0, & \text{en otro caso,} \end{cases}$$

tenemos:

$$u P'_S(u) = P_S(u) \sum_{i=1}^a \sum_{j=1}^b A(i, k) u^{ki}.$$

Puesto que $P_S(u) = \sum_{x=0}^{\infty} u^x f_S(x)$, se tiene que $u P'_S(u) = \sum_{x=0}^{\infty} x u^x f_S(x)$, luego:

$$\sum_{x=0}^{\infty} x u^x f_S(x) = \sum_{x=0}^{\infty} u^x f_S(x) \sum_{i=1}^a \sum_{k=1}^{\infty} A(i, k) u^{ki}.$$

Ahora el coeficiente de u^x en el lado izquierdo es $x f_S(x)$, mientras que en el lado derecho se obtiene sumando $f_S(x - ki)$ sobre todo i y k tal que $1 \leq ki \leq x$. Luego:

$$x f_S(x) = \sum_{i=1}^a \sum_{k=1}^{\lfloor x/i \rfloor} f_S(x - ki) A(i, k),$$

de donde:

$$f_S(x) = \frac{1}{x} \sum_{i=1}^a \sum_{k=1}^{\lfloor x/i \rfloor} f_S(x - ki) A(i, k), \quad x = 1, 2, \dots$$

Finalmente, puesto que $A(i, k) = 0$ para $i > a$ resulta:

$$f_S(x) = \frac{1}{x} \sum_{i=1}^{\min\{a, x\}} \sum_{k=1}^{\lfloor x/i \rfloor} f_S(x - ki) A(i, k), \quad x = 1, 2, \dots$$

La importancia de la fórmula de recursión de De Pril radica en que, aunque $f_S(x)$ pueda obtenerse mediante convolución, su cálculo se hace tedioso y complicado cuando n es grande.

Ejemplo 13.30 Resolver el ejemplo 13.29 utilizando la fórmula de De Pril.

Solución: Tenemos ahora:

$$f_S(0) = \prod_{j=1}^2 p_j^{c_j} = p_1^{c_1} p_2^{c_2} = p_1 p_2.$$

Por otro lado:

$$\begin{aligned} f_S(1) &= \frac{1}{1} \sum_{i=1}^{\min\{2,1\}} \sum_{k=1}^{\lfloor 1/i \rfloor} f_S(1 - ki) \left[(-1)^{k+1} i \sum_{j=1}^2 c_{ij} \left(\frac{q_j}{1 - q_j} \right)^k \right] \\ &= \sum_{i=1}^1 \sum_{k=1}^1 f_S(1 - k) \frac{q_1}{1 - q_1} = q_1 p_2. \end{aligned}$$

$$\begin{aligned} f_S(2) &= \frac{1}{2} \sum_{i=1}^{\min\{2,2\}} \sum_{k=1}^{\lfloor 2/i \rfloor} f_S(2 - ki) A(i, k) \\ &= \frac{1}{2} \left[\sum_{k=1}^2 f_S(2 - k) A(1, k) + \sum_{k=1}^1 f_S(2 - 2k) A(2, k) \right] \\ &= \frac{1}{2} [f_S(1) A(1, 1) + f_S(0) A(1, 2) + f_S(0) A(2, 1)] \end{aligned}$$

Teniendo en cuenta que:

$$\begin{aligned} A(1, 1) &= (-1)^2 \cdot 1 \sum_{j=1}^2 c_{1j} \left(\frac{q_j}{1 - q_j} \right) = c_{11} \frac{q_1}{1 - q_1}, \\ A(1, 2) &= (-1)^3 \cdot 1 \sum_{j=1}^2 c_{1j} \left(\frac{q_j}{1 - q_j} \right)^2 = -c_{11} \left(\frac{q_1}{1 - q_1} \right)^2, \\ A(2, 1) &= (-1)^2 \cdot 2 \sum_{j=1}^2 c_{2j} \left(\frac{q_j}{1 - q_j} \right) = 2c_{22} \frac{q_2}{1 - q_2}, \end{aligned}$$

resulta:

$$f_S(2) = \frac{1}{2} \left(q_1 p_2 \frac{q_1}{p_1} - c_{11} p_1 p_2 \left(\frac{q_1}{p_1} \right)^2 + 2c_{22} p_1 p_2 \frac{q_2}{p_2} \right) = p_1 q_2.$$

Finalmente,

$$\begin{aligned} f_S(3) &= \frac{1}{3} \sum_{i=1}^{\min\{2,3\}} \sum_{k=1}^{\lfloor 3/i \rfloor} f_S(3 - ki) A(i, k) \\ &= \frac{1}{3} \left[\sum_{k=1}^3 f_S(3 - k) A(1, k) + \sum_{k=1}^1 f_S(3 - 2k) A(2, k) \right] \\ &= \frac{1}{3} [f_S(2) A(1, 1) + f_S(1) A(1, 2) + f_S(0) A(1, 3) + f_S(1) A(2, 1)], \end{aligned}$$

donde

$$A(1, 3) = (-1)^4 \cdot 1 \sum_{j=1}^2 c_{1j} \left(\frac{q_j}{1 - q_j} \right)^3 = c_{11} \left(\frac{q_1}{1 - q_1} \right)^3,$$

por lo que

$$\begin{aligned} f_S(3) &= \frac{1}{3} \left[p_1 q_2 \frac{q_1}{p_1} - c_{11} p_2 c_{11} \left(\frac{q_1}{1 - q_1} \right)^2 \right. \\ &\quad \left. + p_1 p_2 c_{11} \left(\frac{q_j}{1 - q_j} \right)^3 + 2c_{22} q_1 p_2 \frac{q_j}{1 - q_j} \right] = q_1 q_2. \end{aligned}$$

◇

Ejemplo 13.31 Considérese la cartera (ficticia y válida sólo para efectos expositivos) formada por 7 contratos de seguros de vida que aparece en la tabla 13.11. Se pide calcular, utilizando el algoritmo de De Pril la función de probabilidad, así como la función de distribución, para la variable aleatoria cantidad total reclamada.

Tabla 13.11: Cartera de seguros de vida. Capital asegurado

q_j	1	2	3	4
0,01	1	2	1	0
0,03	0	0	1	1
0,04	0	1	0	0

Solución: En este caso, la reclamación máxima posible es $m = 17$. Por otro lado, $a = 4$, $b = 3$. Los cálculos que se requieren son los siguientes:

$$f_S(0) = (1 - q_1)^4 (1 - q_2)^2 (1 - q_3) = 0,867672.$$

$$f_S(1) = A(1, 1)f_S(0) = 0,10101 \times 0,867672 = 0,08764,$$

donde:

$$A(1, 1) = 1 \times (-1)^{1+1} \sum_{j=1}^m c_{1j} \left(\frac{q_j}{1 - q_j} \right) = 0,10101.$$

$$f_S(2) = \frac{1}{2} \{A(1, 1)f_S(1) + [A(1, 2) + A(2, 1)] f_S(0)\} = 0,0536817,$$

y ahora:

$$A(1, 2) = 1 \times (-1)^3 \sum_{j=1}^3 c_{1j} \left(\frac{q_j}{1 - q_j} \right)^2 = -0,00010203,$$

y

$$\begin{aligned} A(2, 1) &= 2 \times (-1)^2 \sum_{j=1}^3 c_{2j} \left(\frac{q_j}{1 - q_j} \right)^1 \\ &= 2 \left[2 \left(\frac{0,01}{1 - 0,01} + 1 \left(\frac{0,04}{1 - 0,04} \right) \right) \right] = 0,123737. \end{aligned}$$

$$f_S(3) = \frac{1}{3} \left[\sum_{k=1}^3 A(1, k)f_S(3 - k) + A(2, k)f_S(3 - 2k) + A(3, k)f(4 - 3k) \right],$$

etc. Los valores de $A(i, k)$ requeridos aparecen en la tabla 13.12. Finalmente, los valores de $f_S(x)$ y $F_S(x)$ se muestran en la tabla 13.13.

En la práctica los valores de q_j son pequeños, de modo que para valores grandes de k los términos que configuran $A(i, k)$ son también pequeños, al igual que el propio $A(i, k)$. Por tanto, podemos reducir el número de cálculos sustituyendo (13.53) por

$$f_S^K(x) = \frac{1}{x} \sum_{i=1}^{\min\{x, a\}} \sum_{k=1}^{\min\{K, \lfloor x/i \rfloor\}} A(i, k)f_S(x - ki),$$

donde K es un número positivo. En la práctica, un valor de $K = 4$ proporciona una buena aproximación a la función de densidad de S (véase Klugman et al., 1998 y Dickson, 2005).

Por otro lado, la hipótesis de independencia entre las pólizas, que hace el modelo tratable matemáticamente, no refleja fielmente la realidad. Por ejemplo, puede

Tabla 13.12: Valores de $A(i, k)$

	$i = 1$	$i = 2$	$i = 3$	$i = 4$
$k = 1$	0,010100000000	0,123737000000	0,1230870000	0,12371100000
$k = 2$	-1,0203000E-4	-3,8803400E-3	-3,17568E-3	-0,0038261200
$k = 3$	1,03061000E-6	1,48798000E-4	9,184210E-5	0,00011833400
$k = 4$	-1,0410200E-8	-6,0698000E-6	-2,77609E-6	-3,6598100E-6
$k = 5$	1,0515400E-10	2,51594000E-7	8,520790E-8	-
$k = 6$	-1,062160E-12	-1,0469800E-8	-	-
$k = 7$	1,0728900E-14	4,3610800E-10	-	-
$k = 8$	-1,083720E-16	-1,816980E-11	-	-
$k = 9$	1,0946700E-18	-	-	-
$k = 10$	-1,105730E-20	-	-	-
$k = 11$	1,1169000E-22	-	-	-
$k = 12$	-1,128180E-24	-	-	-
$k = 13$	1,1395700E-26	-	-	-
$k = 14$	-1,15100E-28	-	-	-
$k = 15$	1,1627100E-30	-	-	-
$k = 16$	-1,174460E-32	-	-	-
$k = 17$	1,1863200E-34	-	-	-

darse el caso de varias pólizas en la cartera correspondientes a un mismo asegurado, pólizas de asegurados pertenecientes a una misma unidad familiar y, por tanto, compartiendo riesgos, etc. Aunque estas situaciones pueden evitarse mediante el reaseguro, por ejemplo, hay modelos en la literatura que tratan de resolver esta situación. Así, el lector interesado en esta materia puede consultar Dhaene y Goovaerts (1996, 1997) y Genest et al. (2003).

También se han desarrollado modelos que permiten la posibilidad de más de una reclamación por póliza para el modelo individual general (no para el caso de seguros vida); véase para ello Klugman et al. (1998) pág. 355.

13.3.3. Cálculo aproximado mediante el modelo colectivo

La fórmula de recursión de De Pril reduce el cálculo de la distribución de la cantidad total reclamada en el modelo de riesgo individual. A pesar de esto, su cálculo también resulta tedioso. De ahí que se hayan desarrollado métodos numéricos que aproximen la cantidad total reclamada.

En este sentido, es posible obtener una aproximación de la distribución de la cantidad total reclamada para el modelo individual utilizando el modelo colectivo.

Tabla 13.13: Distribución del capital asegurado

x	$f(x)$	$F(x)$
0	0,86767200000000000000	0,867672
1	0,00876436000000000000	0,876436
2	0,05368170000000000000	0,930118
3	0,03614180000000000000	0,966260
4	0,02801370000000000000	0,994273
5	0,00248183000000000000	0,996755
6	0,00195726000000000000	0,998712
7	0,00115416000000000000	0,999867
8	0,00005355760000000000	0,999920
9	0,000038552000000000E-6	0,999959
10	9,4124379326475050E-6	0,999968
11	7,8871359346990270E-7	0,999969
12	4,1923210489557720E-7	0,999968
13	0,00000000000000000000	0,999969
14	3,5352330626703665E-9	0,999969
15	3,624752745316704E-11	0,999969
16	0,00000000000000000000	0,999969
17	4,8325004091534100E-9	0,999969

Las variables X_j pueden escribirse como

$$X_j = \sum_{i=1}^{I_j} B_j. \quad (13.54)$$

La idea consiste en reemplazar I_j en (13.54) por una variable aleatoria de Poisson N_j con la misma media $\lambda_{k_j} = E(I_j)$, $j = 1, 2, \dots, n$. Entonces,

$$X_j^{\text{AMC}} = \sum_{i=1}^{N_j} B_j,$$

sigue una distribución de Poisson compuesta con parámetros $(\lambda_j, f_{X_j}(\cdot))$ y en la que AMC significa aproximación mediante el modelo colectivo. Ahora, teniendo en cuenta el resultado de la proposición 13.3 se deduce que la variable $S^{\text{AMC}} = \sum_{j=1}^n X_j^{\text{AMC}}$ seguirá una distribución de Poisson compuesta con parámetros

$$\lambda = \sum_{j=1}^n \lambda_j,$$

$$f(x) = \frac{1}{\lambda} \sum_{j=1}^n \lambda_j f_{X_j}(x).$$

Finalmente, utilizando la fórmula de recursión de Panjer la distribución de la cantidad total reclamada puede aproximarse mediante la fórmula de recurrencia siguiente:

$$f_S^{\text{AMC}}(x) = \begin{cases} e^{-\lambda}, & x = 0, \\ \frac{\lambda}{x} \sum_{k=1}^x k f(k) f_S^{\text{AMC}}(x-k), & x = 1, 2, \dots \end{cases}$$

Ejemplo 13.32 Calcular la media y varianza de la variable aleatoria S^{AMC} y comparar con las expresiones (13.46) y (13.47)

Solución: Se verifica que:

$$E(S) = \sum_{j=1}^n q_j \mu_j,$$

$$\text{Var}(S) = \sum_{j=1}^n q_j \mu_j^2 + \sum_{j=1}^n q_j \sigma_j^2,$$

por lo que se obtiene igual media y mayor varianza que para el modelo binomial compuesta en (13.46) y (13.47). Esta diferencia se hará menor en la medida en que las probabilidades de fallecimiento disminuyan. $\diamond$

Otras aproximaciones consideran $\lambda = \sum_{j=1}^n \lambda_j$, con $\lambda_j = -\log(1 - q_j)$. En este caso,

$$f_S^{\text{AMC}}(0) = e^{-\lambda} = \prod_{j=1}^n (1 - q_j),$$

y la probabilidad de que la cantidad total reclamada sea cero proporciona el valor exacto $f_S(0)$ dado en (13.52).

13.4. Problemas propuestos

1. Considérese una variable aleatoria $N \sim R2(a, b, c)$. Probar que verifica la ecuación diferencial en variables separadas:

$$P'_N(z) = azP'_N(z) + (a + b + cz)P_N(z),$$

donde $P_N(z)$ es la función generatriz de probabilidad de N .

2. Demostrar que si $N \sim R2(a, b, c)$, entonces:

a) La función generatriz de probabilidad de N es:

$$P_N(z) = e^{-c/a(z-1)} \left(\frac{1-a}{1-az} \right)^\delta, \quad (13.55)$$

donde $\delta = \frac{a(a+b)+c}{a^2}$.

b) Si $ca < 0$ y $\delta = 0$, entonces $R2(a, b, c)$ es la distribución de Poisson con parámetro $-c/a$.

3. Demostrar que si $N \sim R2(a, b, c)$ entonces:

$$E(N) = \frac{a+b+c}{1-a},$$

$$\text{Var}(N) = \frac{a+b+(2-a)c}{(1-a)^2}.$$

4. Demostrar que si N_1 y N_2 son dos variables aleatorias independientes donde N_1 pertenece a la clase $(a, b, 0)$ y N_2 es de tipo Poisson con parámetro $\theta > 0$, entonces la variable aleatoria $N_3 = N_1 + N_2$ pertenece a la clase $R2(a, b + \theta, -\theta a)$.

5. Obtener una fórmula de recursión para el número de reclamaciones a partir de (13.52) y (13.53). Indicación: tomar $a = 1$.

6. Demostrar que si N sigue una distribución geométrica con función de cuantía $\Pr(N = n) = p(1-p)^n$, $n = 0, 1, \dots$ entonces la función de distribución de la cantidad total reclamada puede obtenerse de manera recursiva mediante:

$$G(y) = g(0) + \frac{q}{1-qf(0)} \sum_{k=1}^y f(k)G(y-k),$$

siendo $f(x)$ la función de densidad de la cantidad reclamada por siniestro.

7. Probar que la función de densidad geométrica compuesta (13.15) verifica la ecuación integral (13.25).

8. En un contrato de reaseguro excess loss con retención M obtener la distribución de N_R sabiendo que la distribución del número de reclamaciones es $BN(2, 0, 6)$.

9. La tabla 13.14 representa una cartera de 31 seguros de vida que aparece recogida en Gerber (1979).

Haciendo uso de la fórmula recursiva de De Pril, calcular la función de densidad, así como la función de distribución, para la variable aleatoria cantidad total reclamada para valores $x = 0, 1, \dots, 50$.

13.4. Problemas propuestos

Tabla 13.14: Cartera de seguros de vida (Gerber, 1979). Capital asegurado

q_j	1	2	3	4	5
0,03	2	3	1	2	0
0,04	0	1	2	2	1
0,05	0	2	4	2	2
0,06	0	2	2	2	1

10. La tabla 13.15 representa una cartera de 322 seguros de vida (Kornya, 1983).

Tabla 13.15: Cartera de seguros de vida (Kornya, 1983). Capital asegurado

q_j	1	2	3	4	5
9,400E-4	12	1	0	19	6
1,910E-3	23	0	3	32	14
5,010E-3	2	6	13	24	1
1,320E-2	14	7	31	5	36
3,407E-2	20	0	0	31	22

Utilizando la fórmula recursiva de De Pril, calcular la función de densidad, así como la función de distribución, para la variable aleatoria cantidad total reclamada para valores $x = 0, 1, \dots, 50$.

Capítulo 14

El modelo IBNR

14.1. Introducción y conceptos básicos

Tanto las compañías aseguradoras como sus clientes conocen que la liquidación de reclamaciones es un proceso lento y sujeto a retrasos. Por tanto, constituye un elemento importante para el asegurador disponer de una provisión de reserva para aquellas reclamaciones en las que haya incurrido el asegurado durante el periodo que cubre su póliza y que no han sido aún liquidadas.

En este capítulo presentaremos la metodología bayesiana para la estimación de reservas para reclamaciones pendientes. Como en Goovaerts et al. (1990), bajo la denominación de IBNR (del inglés: *Incurred But Not Reported*) podemos considerar un amplio abanico de situaciones de reservas: reservas para reclamaciones aún pendientes, reservas para reclamaciones conocidas por la compañía pero no completamente pagadas, entre otras muchas situaciones. En general, suele referirse para reclamaciones pendientes como IBNR reservas o reservas para pérdidas. Este planteamiento genérico es el que consideraremos en este capítulo.

La estructura básica de los datos en un modelo IBNR corresponde a una disposición como la tabla 14.1. La columna A suele identificarse con el año de origen (del accidente) y la fila B suele corresponder con el año de desarrollo, año de pago, con un retraso de $t - 1$ años. Las celdas de la tabla 14.1 contienen las variables $X_{i,t}$ que denotan el número (o cantidad) de eventos (reclamaciones) en el año de desarrollo t correspondientes al año de origen (o año del accidente) i : $\{X_{i,t} : i = 1, \dots, r; t = 1, \dots, r\}$.

Aunque puede considerarse sin pérdida de generalidad que el número de años de desarrollo es el mismo que el de años de origen, no existe impedimento técnico para que fuesen distintos. Suponemos como es habitual, que el número de años de origen y desarrollo coinciden. En consecuencia, en una tabla IBNR encontramos un conjunto de variables conocidas u observadas (el triángulo superior izquierdo

de la tabla) formado por las variables $X_{i,t}$ para $i + t \leq r + 1$ y un conjunto de variables que debe predecirse (el triángulo inferior derecho), que denominaremos triángulo RT ("runoff triangle").

Existen diferentes aproximaciones estadísticas para la resolución de este modelo: mínimos cuadrados, credibilidad, regresión, etc., todas ellas bajo la perspectiva clásica. Algunas referencias importantes para estas aproximaciones son Goovaerts et al. (1990) y Taylor (2000).

Recientemente, la implantación generalizada de las metodologías MCMC han permitido desarrollar de forma satisfactoria este modelo bajo la perspectiva bayesiana, obteniendo resultados predictivos de gran interés y de natural interpretación dada la naturaleza bayesiana del problema donde parte de las variables deben ser pronosticadas utilizando las variables observadas. Por tanto, si las variables $X_{i,t}$ denotan reclamaciones en general (cocientes de pérdidas, frecuencias de reclamaciones, pérdidas, etc.), el triángulo no observado de la tabla debe ser estimado. Denotando por $f(x_{it}|\theta)$ a la densidad poblacional, se tiene que la verosimilitud del modelo tendrá la expresión

$$L(\mathbf{x}|\theta) = \prod_{i+t \leq r+1} f(x_{it}|\theta).$$

Con esta expresión se deducirán las densidades a posteriori:

$$\pi(\theta|\mathbf{x}) \propto L(\mathbf{x}|\theta)\pi(\theta),$$

siendo $\pi(\theta)$ la densidad a priori del parámetro del modelo y

$$\mathbf{x} = (x_{1,1}, \dots, x_{r,1}, x_{1,2}, \dots, x_{r-1,2}, \dots, x_{1,r})$$

el conjunto de datos observados, utilizados para la predicción de las observaciones z_{it} del triángulo inferior mediante la expresión de la distribución predictiva

$$f(z_{it}|\mathbf{x}) = \int_{\Theta} f(z_{it}|\theta)\pi(\theta|\mathbf{x})d\theta, \quad i, t \in \{1, \dots, r\} \text{ tales que: } i + t \geq r + 1.$$

El análisis bayesiano MCMC se convierte así en una herramienta útil para este propósito. Obtenida una muestra MCMC es fácil obtener muestras a posteriori de las variables de interés. Por ejemplo, $X_i = \sum_{t=r-2-i}^r X_{it}$, representa las reclamaciones pendientes del año i como suma de los valores de X_{it} generados con $i + t > r + 1$.

14.2. El modelo log-normal

El modelo más simple para una tabla IBNR es el modelo log-normal, que como veremos a continuación es un caso particular de análisis de la varianza (Verrall,

14.2. El modelo log-normal

Tabla 14.1: Reclamaciones (número o cantidades) observada en un modelo IBNR

A	B					
	1	2	...	t	...	r
1	$X_{1,1}$	$X_{1,2}$	...	$X_{1,t}$	...	$X_{1,r-1}$
2	$X_{2,1}$	$X_{2,2}$	...	$X_{2,t}$	...	$X_{2,r-1}$
...	...	...	...	...	...	...
r-1	$X_{r-1,1}$	$X_{r-1,2}$	...	$X_{r-1,t}$	...	$X_{r-1,r}$
r	$X_{r,1}$	-	...	-	...	-

1990 y 1996). Su planteamiento es el siguiente. Consideremos:

$$Z_{it} = \log \frac{X_{it}}{\delta_{it}}, \quad Z_{it} \sim \mathcal{N}(\mu_{it}, \sigma^2), \quad i, t \in \{1, \dots, r\}, \quad (14.1)$$

con

$$\mu_{it} = \mu + \alpha_i + \beta_t, \quad i, t \in \{1, \dots, r\}, \quad (14.2)$$

y δ_{it} es el factor de inflación de cada celda, necesario (en el caso de cantidades) a efectos comparativos. Observemos que en el caso de que la variable no se vea afectada por correcciones de inflación (por ejemplo, caso de número de reclamaciones), entonces $\delta_{it} = 1$ es un caso particular contemplado en la anterior modelización. Es obvio también, que podríamos modelizar análogamente $Z_{it} \sim \log X'_{it}$ sin más que considerar cada X'_{it} como la transformación de X_{it} corregida por la inflación. Una parametrización de este modelo es $Z_{it} = \log X_{it} - \log(\delta_{it}E_i)$, donde E_i es una medida del tamaño del grupo ("exposure"), por ejemplo, el tamaño de la cartera en el año i . Con esta modelización estamos suponiendo que la cantidad (reclamaciones) esperada (realmente su logaritmo ajustado por la inflación) μ_{it} (originado en el año i y pagado con un retraso de $t-1$ años) puede representarse linealmente como suma de una cantidad μ , logaritmo ajustado de las reclamaciones esperadas y ocurridas y pagadas el primer año de notificación del accidente, un factor α_i que refleja el cambio esperado debido al año de origen y un factor β_t que refleja el patrón del retraso en el pago.

Este modelo necesita alguna restricción para tener asegurada la identificabilidad de los parámetros. En concreto, en nuestro caso haremos $\alpha_1 = \beta_1 = 0$, y en definitiva, los parámetros a estimar serán: μ , σ^2 (o bien $\tau = 1/\sigma^2$), $\alpha = (\alpha_2, \dots, \alpha_r)^\top$, $\beta = (\beta_2, \dots, \beta_r)^\top$ y $Z^I = \{\log(X_{it}) : i + t > r + 1\}$. Para completar el análisis bayesiano, las distribuciones a priori para los parámetros son:

$$\mu \sim \mathcal{N}(0, \sigma_\mu^2),$$

$$\begin{aligned}\alpha_i &\sim N(0, \sigma_{\alpha_i}^2), \quad i = 2, \dots, r \\ \beta_j &\sim N(0, \sigma_{\beta_j}^2), \quad j = 2, \dots, r \\ \tau = \frac{1}{\sigma^2} &\sim G(\alpha_\tau, 1/\beta_\tau).\end{aligned}$$

Habitualmente, se eligen valores de los hiperparámetros que hagan no informativas estas distribuciones iniciales. En tal caso, bajo las hipótesis de independencia a priori y denotando por Z^I la parte inferior del triángulo (parte a predecir) y x la parte superior observada del triángulo, tendremos que las densidades a posteriori se deducen de

$$\begin{aligned}\pi(\mu, \alpha, \beta, \tau, Z^I | x) &\propto f(x | \mu, \alpha, \beta, \tau, Z^I) \cdot \pi(\mu, \alpha, \beta, \tau, Z^I) \\ &\propto f(Z^S | \mu, \alpha, \beta, \tau) f(Z^I | \mu, \alpha, \beta, \tau) \cdot \pi(\mu) \pi(\alpha) \cdot \pi(\beta) \cdot \pi(\tau).\end{aligned}\quad (14.3)$$

Esta distribución es complicada de muestrear, pero sin embargo sus distribuciones condicionadas permiten el muestreo MCMC. Las distribuciones condicionadas obtenidas pueden verse en la siguiente sección, donde se analiza un modelo que generaliza este modelo log-normal.

Ejemplo 14.1 Los datos de la tabla 14.2 muestran los valores de las cantidades (reclamaciones) pagadas por una compañía aseguradora con un retraso de $t-1$ años para accidentes registrados en el año i . Ajustar el modelo log-normal y obtener la predicción de las cantidades individuales (Ntzoufras y Dellaportas, 2002).

Tabla 14.2: Reclamaciones (en miles de u.m. ajustados por inflación)

Año de origen	Años hasta el pago ($t-1$)						
	0	1	2	3	4	5	6
1989	527003	183260	90539	50471	37785	10110	21165
1990	594059	237289	99640	52390	50723	39029	
1991	810593	257122	87318	72538	81336		
1992	1012181	339664	156531	181253			
1993	1459202	448651	188698				
1994	1689751	563683					
1995	1698534						

Solución: La tabla 14.2 contiene ya los datos ajustados por la inflación y por tanto consideramos directamente los elementos de la tabla en la modelización. En este ejemplo el valor de r es 7. Siguiendo un enfoque no informativo para las distribuciones a priori consideraremos los siguientes valores iniciales para los

hiperparámetros: $\sigma_\mu^2 = 1000$, $\sigma_{\alpha_i}^2 = \sigma_{\beta_i}^2 = 100$, $i = 2, \dots, 7$ y $\alpha_\tau = \beta_\tau = 0,001$. El código WinBUGS de este ejemplo es el siguiente:

```
model; {
  for( i in 1 : r ) {
    for( j in 1 : r ) {
      y[ i, j ] ~ dlnorm( mu.y[ i, j ], tau );
      mu.y[ i, j ] <- mu + alpha[ i ] + beta[ j ] - log( 1000 );
    }
  }

  alpha[1] <- 0
  beta[1] <- 0
  for( i in 2 : r ) {
    alpha[i] ~ dnorm( 0.0, tau.alpha );
    beta[i] ~ dnorm( 0.0, tau.beta );
  }
  mu ~ dnorm( 0.0, tau.mu );
  tau ~ dgamma( 0.001, 0.001 );
  sigma2 <- 1 / tau
  tau.mu <- 1 / 1000
  tau.alpha <- 1 / 100
  tau.beta <- 1 / 100

  for( i in 2 : r ) {
    fila.pend[ i ] <- sum( y[ i, ( r+2 - i ) : r ] ) / 1000
  }
  fila.pend[ 8 ] <- sum( fila.pend[ 2 : 7 ] )
  diag.pend[ 2 ] <- ( y[2,r] + y[3,r-1] + y[4,r-2] + y[5,r-3]
    + y[6,r-4] + y[7,r-5] ) / 1000
  diag.pend[ 3 ] <- ( y[3,r] + y[4,r-1] + y[5,r-2] + y[6,r-3]
    + y[7,r-4] ) / 1000
  diag.pend[ 4 ] <- ( y[4,r] + y[5,r-1] + y[6,r-2] + y[6,r-3] ) / 1000
  diag.pend[ 5 ] <- ( y[5,r] + y[6,r-1] + y[7,r-2] ) / 1000
  diag.pend[ 6 ] <- ( y[6,r] + y[7,r-1] ) / 1000
  diag.pend[ 7 ] <- ( y[7,r] ) / 1000
  diag.pend[ 8 ] <- sum( diag.pend[ 2 : 7 ] )

  } list(r=7);

  y[,1]  y[,2]  y[,3]  y[,4]  y[,5]  y[,6]  y[,7]
```

```
527003 183260 90539 50471 37875 10110 21165
```

```
594059 237289 99640 52390 50723 39028 NA
```

```
810593 257122 87318 72538 81336 NA NA
```

```
1012181 339664 156531 181253 NA NA NA
```

```
1459202 448651 188698 NA NA NA NA
```

```
1689751 563683 NA NA NA NA NA
```

```
1698534 NA NA NA NA NA NA
```

```
END
```

```
list(tau=1);
```

Observemos que la última línea del código `list(tau=1)` se incluye sólo a efectos de generar un valor inicial para τ pues al asignarle una densidad a priori $G(0,001; 1/0,001)$ puede presentar algún problema en la generación de un valor inicial de la cadena. El resto de los valores se pueden generar directamente con la opción `gen init`. Con una muestra de 60000 realizaciones de las que hemos excluido un "burn-in" de 10000 se obtuvieron las estimaciones que aparecen en las figuras 14.1 y 14.2.

En el código para la simulación de la tabla IBNR del ejemplo, hemos introducido las variables de interés a predecir. En concreto, `fila.pend` corresponde a la predicción para el total de reclamaciones (cantidades) con diferentes años de origen (filas de la tabla 14.2). Los valores de `diag.pend` corresponden a la predicción para el total de reclamaciones (cantidades) pagadas en futuros años (diagonales no observadas de la tabla 14.2). Se consideran sus valores expresados en millones de unidades monetarias para reducir el tamaño de las cifras de la tabla. Los resultados obtenidos para el caso del total de reclamaciones con diferentes años de origen pueden verse en la figura 14.2.

Observemos que los valores `fila.pend[2]` al `fila.pend[7]` se corresponden con la predicción para cada año de origen, es decir, de 1990 a 1995. Finalmente, `fila.pend[8]` es la predicción del agregado total de todos los años de origen. Los resultados para la predicción de las diagonales no observadas pueden verse en la figura 14.2.

Observemos que los valores `diag.pend[2]` al `diag.pend[7]` se corresponden con la predicción de las cantidades que deberán abonarse cada año próximo, es decir del 1996 al 2001. El valor de `diag.pend[8]` corresponde al total agregado

14.2. El modelo log-normal

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
alpha[2]	0.3592	0.1652	0.001272	0.03179	0.3588	0.687	10001	50000
alpha[3]	0.4716	0.1775	0.001361	0.1182	0.4713	0.8249	10001	50000
alpha[4]	0.9177	0.1923	0.00142	0.5356	0.9175	1.3	10001	50000
alpha[5]	1.069	0.2128	0.001612	0.647	1.068	1.491	10001	50000
alpha[6]	1.275	0.2482	0.001751	0.7805	1.274	1.767	10001	50000
alpha[7]	1.29	0.3307	0.002296	0.6362	1.288	1.95	10001	50000
beta[2]	-1.08	0.1645	0.001743	-1.406	-1.08	-0.7531	10001	50000
beta[3]	-1.937	0.1763	0.001949	-2.291	-1.937	-1.589	10001	50000
beta[4]	-2.245	0.1919	0.002195	-2.631	-2.245	-1.867	10001	50000
beta[5]	-2.439	0.213	0.002432	-2.864	-2.439	-2.017	10001	50000
beta[6]	-3.337	0.2472	0.002688	-3.828	-3.336	-2.854	10001	50000
beta[7]	-3.093	0.3295	0.003564	-3.747	-3.092	-2.439	10001	50000
mu	19.96	0.1662	0.002989	19.63	19.96	20.29	10001	50000
sigma2	0.08151	0.03437	2.145E-4	0.03869	0.07401	0.1682	10001	50000
tau	14.13	5.141	0.03035	5.946	13.51	25.85	10001	50000

Figura 14.1: Estimaciones a posteriori de los parámetros del modelo para el ejemplo 14.1

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
fila.pend[2]	33.42	15.9	0.06748	12.86	30.32	72.55	10001	100000
fila.pend[3]	66.04	22.68	0.09834	33.6	62.4	120.1	10001	100000
fila.pend[4]	212.8	61.65	0.2836	119.3	204.0	357.4	10001	100000
fila.pend[5]	403.8	111.4	0.5063	233.3	398.2	563.8	10001	100000
fila.pend[6]	760.4	221.6	1.063	425.8	730.1	1284.0	10001	100000
fila.pend[7]	1424.0	537.0	2.676	874.7	1331.0	2714.0	10001	100000
fila.pend[8]	2900.0	643.4	4.022	1935.0	2807.0	4418.0	10001	100000

Figura 14.2: Media a posteriori, desviación estándar, mediana e intervalo bayesiano al 95 % para la predicción de las reclamaciones (cantidades) para cada año de origen (año del accidente) para el ejemplo 14.1. Resultados en millones de u.m. y ajustados por inflación

de todos los años futuros. Como podemos observar cada una de estas cantidades tiene su correspondiente intervalo bayesiano de credibilidad al 95 % cuyos extremos inferior y superior lo forman el cuantil 2,5 % y 97,5 %, respectivamente.

Otra de las ventajas del análisis MCMC consiste en que las variables X_{it} del triángulo inferior son tratadas como nodos estocásticos y por tanto pueden predecirse, lo cual permite completar de forma predictiva la tabla original (ver tabla 14.3).

node	mean	sd	MC error 2.5%	median 97.5%	start	sample
diag.pend[2]	1220.0	331.0	1.594	754.7	1165.0	2004.0
diag.pend[3]	672.1	189.7	0.9353	421.7	847.5	1069.0
diag.pend[4]	461.1	127.3	0.8277	289.6	442.5	760.5
diag.pend[5]	298.4	97.48	0.5538	180.4	282.2	533.9
diag.pend[6]	152.4	58.58	0.3174	71.84	142.2	294.2
diag.pend[7]	88.38	53.04	0.2627	27.33	76.93	216.9
diag.pend[8]	2892.0	615.6	3.859	1956.0	2808.0	4332.0

Figura 14.3: Media a posteriori, desviación estándar, mediana e intervalo bayesiano al 95 % para la predicción de las reclamaciones (cantidades) que deberán ser pagadas cada próximo año para el ejemplo 14.1

Tabla 14.3: Predicción de cantidades individuales (media a posteriori, en negrita) para la tabla del ejemplo 14.1.

Año origen	Años hasta el pago ($t-1$)						
	0	1	2	3	4	5	6
1989	527003	183260	90539	50471	37785	10110	21165
1990	594059	237289	99640	52390	50723	39029	33420
1991	810593	257122	87318	72538	81336	28640	37410
1992	1012181	339664	156531	181253	10930	44970	58570
1993	1459202	448651	188698	154800	128000	52510	68510
1994	1689751	563683	260400	191400	158600	65080	84920
1995	1698534	633500	270300	199300	164900	67520	88380

14.3. Un modelo más general

El modelo log-normal presenta algunas desventajas. Por ejemplo, el hecho de no considerar el número de accidentes (o reclamaciones) le hace desechar esta información disponible en las compañías aseguradoras. Ntzoufras y Dellaportas (2002) sugieren un modelo más general y flexible que incluya al anterior y que permita incorporar esta información del número de reclamaciones, n_{it} . Suponiendo que $n_{it} > 0, \forall i, t$, la formulación de este nuevo modelo es la siguiente. Consideremos:

$$Z_{it} = \log \frac{X_{it}}{\delta_{it}}, \quad Z_{it} \sim \mathcal{N}(\mu_{it}, \sigma^2), \quad i, t \in \{1, \dots, r\}, \quad (14.4)$$

siendo

$$\mu_{it} = \mu + \alpha_i + \beta_t + \log(n_{it}) \quad i, t \in \{1, \dots, r\}, \quad (14.5)$$

14.3. Un modelo más general

con $(n_{i1}, \dots, n_{ir}) \sim \text{Mult}(T_i, \pi_1, \dots, \pi_r)$, y $T_i = n_{i.} = \sum_{t=1}^r n_{it}$.

El vector $(n_{i1}, \dots, n_{ir})$ indica el número de reclamaciones originadas en el año i y cada π_t es la probabilidad de que una reclamación sea saldada con un retraso de $t-1$ años. Habitualmente suele utilizarse también el vector de componentes $\beta_t^* = \log(\pi_t/\pi_1)$. Una parametrización alternativa de este modelo consiste en considerar $n_{it} \sim \mathcal{P}(\lambda_{it})$ con $\log(\lambda_{it}) = \mu^* + \alpha_i^* + \beta_t^*$.

Utilizaremos la primera formulación a efectos de construir el modelo de muestreo de manera análoga a Ntzoufras y Dellaportas (2002). De modo análogo a como hicimos en el modelo log-normal, las cantidades μ , α_i y β_t tienen la misma interpretación, junto con β_t^* que representa el logaritmo del cociente de probabilidades entre que una reclamación (accidente) sea pagada con un retraso de $t-1$ años frente a una reclamación (accidente) abonada sin retraso. Los parámetros a estimar en esta ocasión serán: μ , σ^2 (o $\tau = 1/\sigma^2$), $\alpha = (\alpha_2, \dots, \alpha_r)^\top$, $\beta = (\beta_2, \dots, \beta_r)$, $Z^I = \{\log(X_{it}) : i+t > r+1\}$ y $N^I = \{n_{it} : i+t > r+1\}$, donde los datos observados serán

$$\mathbf{x} = (x_{1,1}, \dots, x_{r,1}, x_{1,2}, \dots, x_{r-1,2}, \dots, x_{1,r}),$$

igual que en el modelo anterior y

$$\mathbf{n} = (n_{1,1}, \dots, n_{r,1}, T_1, n_{1,2}, \dots, n_{r-1,2}, T_2, \dots, n_{1,r}, T_r),$$

donde aparecen también los valores de T_i . En la práctica, los valores de T_i también pueden ser desconocidos y el modelo reparametrizado como $n_{it} \sim \mathcal{P}(\lambda_{it})$, con $\log(n_{it}) = \mu^* + \alpha_i^* + \beta_t^*$, y por tanto no constituye un problema adicional en la modelización.

Las densidades a priori elegidas para los parámetros son análogas a las del modelo previo, esto es:

$$\mu \sim \mathcal{N}(0, \sigma_\mu^2), \quad (14.6)$$

$$\alpha_i \sim \mathcal{N}(0, \sigma_{\alpha_i}^2), \quad i = 2, \dots, r \quad (14.7)$$

$$\beta_t \sim \mathcal{N}(0, \sigma_{\beta_t}^2), \quad t = 2, \dots, r \quad (14.8)$$

$$\tau = \frac{1}{\sigma^2} \sim \mathcal{G}(\alpha_\tau, 1/\beta_\tau) \quad (14.9)$$

$$\beta_t^* \sim \mathcal{N}(0, \sigma_{\beta_t^*}^2), \quad t = 2, \dots, r. \quad (14.10)$$

Los valores de los hiperparámetros pueden asignarse de modo que hagan no informativas a las densidades a priori anteriores.

Las distribuciones condicionadas pueden obtenerse ahora como en Ntzoufras y Dellaportas (2002) de forma inmediata. Así, obtenemos:

$$(a) \quad \pi(\mu|\mathbf{x}, \mathbf{n}) \sim \mathcal{N}\left(\frac{a}{u(\mathbf{x}) + \sigma^2/\sigma_\mu^2}, \frac{\sigma^2}{u(\mathbf{x}) + \sigma^2/\sigma_\mu^2}\right), \text{ donde:}$$

$$a = \sum_{i=1}^r \sum_{t=1}^{r-i+1} x_{it} - \sum_{i=1}^r \sum_{t=1}^{r-i+1} \log(n_{it}) - \sum_{i=1}^r (r-i+1)\alpha_i + \sum_{t=1}^r (r-t+1)\beta_t,$$

siendo $u(x)$ el número de casillas de la tabla IBNR que contienen observaciones, es decir es el orden máximo del vector observado x .

(b) Para cada $i = 2, \dots, r$ se tiene que

$$\pi(\alpha_i | x, n) \sim \mathcal{N} \left(\frac{a_i}{(r-i+1) + \sigma^2/\sigma_{\alpha_i}^2}, \frac{\sigma^2}{(r-i+1) + \sigma^2/\sigma_{\alpha_i}^2} \right),$$

$$\text{con } a_i = \sum_{t=1}^{r-i+1} x_{it} - \sum_{t=1}^{r-i+1} \log(n_{it}) - (r-i+1)\mu + \sum_{t=1}^{r-i+1} \beta_t.$$

(c) Para cada $t = 2, \dots, r$ se tiene

$$\pi(\beta_t | x, n) \sim \mathcal{N} \left(\frac{b_t}{(r-t+1) + \sigma^2/\sigma_{\beta_t}^2}, \frac{\sigma^2}{(r-t+1) + \sigma^2/\sigma_{\beta_t}^2} \right),$$

donde:

$$b_t = \sum_{i=1}^{r-t+1} x_{it} - \sum_{i=1}^{r-t+1} \log(n_{it}) - (r-t+1)\mu + \sum_{i=1}^{r-t+1} \alpha_i.$$

(d) $\pi(\tau | x, n) \sim \mathcal{G}(\alpha_r + u(x)/2, 1/(\beta_t + s/2))$, donde $s = \sum_{i=1}^r \sum_{t=1}^{r-i+1} (x_{it} - \mu_{it})^2$ con $\mu_{it} = \mu + \alpha_i + \beta_t + \log(n_{it})$ y $\alpha_1 = \beta_1 = 0$.

(e) Para cada $i = 2, \dots, r$; $t = r-i+2, \dots, r$ se tiene:

$$f(z_{it} | x, n) \sim \mathcal{N}(\mu_{it}, \sigma^2).$$

(f) Para cada $t = 2, \dots, r$ se tiene:

$$\pi(\beta_t^* | x, n) \propto \exp \left\{ \beta_t^* n_{..} - n_{..} \log \left[\sum_{k=1}^r \exp\{\beta_k^*\} \right] - \frac{1}{2} \frac{(\beta_t^*)^2}{\sigma_{\beta_t^*}^2} \right\},$$

con $n_{..} = \sum_{i=1}^r \sum_{t=1}^r n_{it}$, $n_{..} = \sum_{i=1}^r n_{it}$ y $\beta_1^* = 0$, densidad que resulta logcóncava en β_t^* y por tanto fácil de muestrear mediante Metropolis-Hastings.

(g) Finalmente, la predicción de las celdas de conteo podemos muestrearlas atendiendo a lo siguiente. Puesto que $n_{ir} = T_i - \sum_{t=1}^{r-1} n_{it}$, tendremos que

$$\pi(n_{it} | x, n) \propto \pi_t^{n_{it}} \pi_r^{s_{it} - n_{it}},$$

con $s_{it} = T_i - \sum_{k \neq j, r} n_{ik}$. De modo equivalente llamando:

$$p_i = \frac{\pi_t}{\pi_t + \pi_r} = \frac{1}{1 + \exp(\beta_r^* - \beta_t^*)},$$

14.3. Un modelo más general

se obtiene que:

$$\pi(n_{it} | x, n) \propto p_t^{n_{it}} (1 - p_t)^{s_{it} - n_{it}} \sim \text{Be}(s_{it}, p_t).$$

Una extensión más flexible y realista de este modelo se formula de manera inmediata sin más que considerar que el parámetro β_t puede ser reemplazado por β_{it} , de tal forma que el efecto de demora sobre el logaritmo (ajustado) de las cantidades reclamadas cambia también con el año de origen i . En definitiva, un planteamiento más general del modelo es el siguiente. Escribimos:

$$Z_{it} = \log \frac{X_{it}}{\delta_{it}}, \quad Z_{it} \sim \mathcal{N}(\mu_{it}, \sigma^2), \quad i, t \in \{1, \dots, r\},$$

siendo

$$\mu_{it} = \mu + \alpha_i + \beta_{it} + \log(n_{it}) \quad i, t \in \{1, \dots, r\},$$

con $(n_{i1}, \dots, n_{ir}) \sim \text{Mult}(T_i, \pi_1, \dots, \pi_r)$, y

$$T_i = n_{i.} = \sum_{t=1}^r n_{it}, \beta_i^* = \log \left(\frac{\pi_i}{\pi_1} \right), \beta_1^* = 0.$$

Suponemos las siguientes asociaciones recursivas (Ntzoufras y Dellaportas, 2002):

$$\pi_{it} = \beta_{i-1,t} + v_i, \quad v_i \sim \mathcal{N}(0, \sigma_v^2), \quad i, t \in \{2, \dots, r\}.$$

$$\alpha_i = \alpha_{i-1} + h_i, \quad h_i \sim \mathcal{N}(0, \sigma_h^2), \quad i \in \{2, \dots, r\},$$

de donde tenemos que $\text{var}(Z_{it} | \cdot) = \sigma^2 + (i-1)(\sigma_v^2 + \sigma_h^2)$.

Los parámetros a estimar en esta ocasión serán: μ, σ^2 (o $\tau = 1/\sigma^2$), σ_v^2, σ_h^2 , $\alpha = (\alpha_2, \dots, \alpha_r)^T, \beta^T = (\beta_2^T, \dots, \beta_r^T)$, con $\beta_i^T = (\beta_{i2}, \dots, \beta_{ir})$, $i = 2, \dots, r$, $\beta^* = (\beta_2^*, \dots, \beta_r^*)^T$, $Z^I = \{\log(X_{it}) : i+t > r+1\}$ y $N^I = \{n_{it} : i+t > r+1\}$.

Las densidades a priori asignadas para los parámetros son análogas a las dadas en (14.6)-(14.10) y las distribuciones conjugadas son análogas a las deducidas anteriormente en los comentarios (a)-(g).

Ejemplo 14.2 Supongamos ahora que junto con la tabla 14.2 para cantidades reclamadas, disponemos también de la tabla 14.4 para el número de reclamaciones liquidadas. Siendo los valores de la columna referenciada como "Total", los valores de totales de número de reclamaciones que se han observado cada año de origen (en nuestra notación, $T_i, i = 1, \dots, r$). Se trata de desarrollar el modelo general para este ejemplo (Ntzoufras y Dellaportas, 2002).

Solución: Observemos que en este caso ($r = 7$) tenemos $Z_{it} = \log X_{it} \sim \mathcal{N}(\mu_{it}, \sigma^2)$, con $\mu_{it} = \mu + \alpha_i + \beta_{it} + \log(n_{it})$ donde suponemos que existe una estructura recursiva entre los parámetros α_i, β_{it} dada por

$$\beta_{it} = \beta_{i-1,t} + v_i, \quad v_i \sim \mathcal{N}(0, \sigma_v^2), \quad i, t \in \{2, \dots, 7\},$$

Tabla 14.4: Número de reclamaciones

Año de origen	Años hasta la liquidación ($t-1$)							Total
	0	1	2	3	4	5	6	
1989	6622	1943	489	138	61	223	66	9542
1990	6943	2133	632	154	162	390		10496
1991	8610	2216	736	651	256			12601
1992	9791	3167	1579	624				15565
1993	11722	3192	1773					17735
1994	13684	3664						19746
1995	13068							18600

$$\alpha_i = \alpha_{i-1} + h_i, \quad h_i \sim \mathcal{N}(0, \sigma_h^2), \quad i \in \{2, \dots, 7\},$$

con las restricciones de identificabilidad: $\alpha_1 = \beta_{i1} = 0, \forall i = 1, \dots, 7$.

El código WinBUGS de este modelo es algo más complejo que el anterior. Presentamos una versión reducida del código realizado por Scollnik (2002). Observemos que realmente en la tabla de número de reclamaciones tenemos dos filas completas pues el elemento n_{27} se deduce de $n_{27} = T_2 - \sum_{t=1}^6 n_{2t} = 32$. Al mismo tiempo al incluir una columna adicional para indicar los valores de T_i , podemos seguir la estrategia siguiente para repartir la diferencia del total y la suma observada en el resto de las casillas que hay que predecir. En efecto, pensemos por ejemplo, en la tercera fila (8610, 2216, 736, 651, 256, n_{36}) y entonces asignar el valor de n_{36} de la expresión $T_3 - \sum_{t=1}^5 n_{3t} = 132$, y por tanto, podemos considerar que (8610, 2216, 736, 651, 256, 132) es una realización de una distribución $\text{Mult}(T_3, \pi_1, \pi_2, \pi_3, \pi_4, \pi_5, 1 - \sum_{t=1}^5 \pi_t)$. Condicionando ahora al número conocido de reclamaciones pagadas en el año anterior, las cantidades restantes tienen distribución condicionada $\mathcal{B}(132, \pi_6/(\pi_6 + \pi_7))$ que es inmediata de muestrear. Estos comentarios han sido tenidos en cuenta en la programación del código.

```
model;
{
# Primeros dos años de origen
for( i in 1 : 2 ) {
  for( t in 1 : r ) {
    y[ i, t ] ~ dlnorm(mu.y[i,t],tau)
    mu.y[ i, t ] <- mu + alpha[i] + beta[i,t] - log(1000)+ log(n[i,t])
  }
}
```

14.3. Un modelo más general

Año 3 en adelante.

```
for( i in 3:r ) {
  for( t in 1:(r+1-i) ) {
    y[i,t] ~ dlnorm(mu.y[i,t], tau )
    mu.y[i,t] <- mu + alpha[i] + beta[i,t] - log(1000) + log(n[i,t])
  }
  for( t in (r+2-i):r ) {
    y[i,t] ~ dlnorm(mu.y[i,t],tau)
    mu.y[i,t] <- mu + alpha[i] + beta[i,t] - log(1000)+log(n[i,t+1])
  }
  n[1,1:r] ~ dmulti(pi[],T[1])
  n[2,1:r] ~ dmulti(pi[],T[2])
}
```

Definición de la distribución multinomial para las celdas

```
for(i in 3:r) {
  for(t in 1:(r+1-i)) {
    pi.marg[i,t] <- pi[t]
  }
  pi.marg[i,r+2-i] <- 1 - sum(pi.marg[i,1:(r+1-i)])
  n[i,1:(r+2-i)] ~ dmulti(pi.marg[i,1:(r+2-i)],T[i])
}
for(i in 3:r) {
  for(t in (r+3-i):(r+1)) {
    pi.cond[i,t] <- pi[t-1] / pi.marg[i,r+2-i]
  }
  n[i,(r+3-i):(r+1)] ~ dmulti(pi.cond[i,(r+3-i):(r+1)],n[i,r+2-i])
}
for( i in 1:(r - 1)){
  p[i] ~ dnorm(0.0,tau.p)
  p.exp[i] <- exp( p[i])
  pi[i+1] <- p.exp[i] / (1 + sum(p.exp[1:(r-1)]))
}
pi[1] <- 1 - sum(pi[2:r])
```

Definición de las relaciones recursivas.

```
for(i in 2:r){
  for(t in 2:r){
    beta[i,t] <- beta[i -1,t] + v[i]
  }
}
```

```

alpha[i] <- alpha[i-1] + h[i]
v[i] ~ dnorm(0.0,tau.v)
h[i] ~ dnorm(0.0,tau.h)
}

# Restricciones
alpha[1] <- 0
for(i in 1:r){
  beta[i,1] <- 0 }

# Resto de las priors
for(t in 2:r) {
  beta[1,t] ~ dnorm(0.0,tau.betait)
}

mu ~ dnorm(0.0,tau.mu)
tau.mu <- 1 / 1000
tau ~ dgamma(0.001,0.001)
sigma2 <- 1/tau
tau.h ~ dgamma(0.00001,0.00001)
sigma2.h <- 1/tau.h
tau.v ~ dgamma(0.00001,0.00001)
sigma2.v <- 1/tau.v
tau.betait <- 1/100
tau.p <- 1/100

# Cantidades a predecir
for(i in 2:r) {
  fila.pend[i] <- sum(y[i,(r+2-i):r])/1000
}

diag.pend[2] <- (y[2,r]+y[3,r-1]+ y[4,r-2]+ y[5,r-3]
               +y[6,r-4]+y[7,r-5])/1000
diag.pend[3] <- (y[3,r]+y[4,r-1]+y[5,r-2]+y[6,r-3]+
               y[7,r-4])/ 1000
diag.pend[4] <- (y[4,r]+y[5,r-1]+y[6,r-2]+y[7,r-3])/1000
diag.pend[5] <- (y[5,r]+y[6,r-1]+y[7,r-2])/1000
diag.pend[6] <- (y[6,r]+y[7,r-1])/1000
diag.pend[7] <- (y[7,r])/1000
diag.pend[8] <- sum(diag.pend[2:7])
}

# Datos

```

14.3. Un modelo más general

```
list( r = 7, T = c( 9542,10496,12601,15565,17735,19746,18600 ) )
```

y[,1]	y[,2]	y[,3]	y[,4]	y[,5]	y[,6]	y[,7]
527003	183260	90539	50471	37875	10110	21165\\
594059	237289	99640	52390	50723	39028	NA\\
810593	257122	87318	72538	81336	NA	NA\\
1012181	339664	156531	181253	NA	NA	NA\\
1459202	448651	188698	NA	NA	NA	NA\\
1689751	563683	NA	NA	NA	NA	NA\\
1698534	NA	NA	NA	NA	NA	NA\\

END

n[,1]	n[,2]	n[,3]	n[,4]	n[,5]	n[,6]	n[,7]	n[,8]
6622	1943	489	138	61	223	66	0\\
6943	2133	632	154	162	390	82	0\\
8610	2216	736	651	256	132	NA	NA\\
9791	3167	1570	624	413	NA	NA	NA\\
11722	3192	1773	1048	NA	NA	NA	NA\\
13684	3664	2398	NA	NA	NA	NA	NA\\
13068	5532	NA	NA	NA	NA	NA	NA\\

END


```
# Algunos valores iniciales
```

```
list(p = c(1,1,1,1,1,1), mu=0.0, tau=0.001, tau.v=1, tau.h = 1)
```

Las estimaciones de los parámetros $\alpha, \beta, \mu, \sigma^2$ etc. se realiza de forma inmediata, obteniéndose los resultados que aparecen en la figura 14.2. A efectos comparativos con los resultados obtenidos con el modelo para cantidades desarrollado en el ejemplo 14.1, hemos prescindido de las estimaciones de los parámetros β_{it} .


Igual que en el ejemplo 14.4 los valores fila.pend[2] al fila.pend[7] se corresponden con la predicción para cada año de origen, es decir, de 1990 a 1995. Los resultados para la predicción de las filas no observadas pueden verse en la figura 14.3.

Observemos que en comparación con los resultados en la figura 14.2 las estimaciones difieren bastante salvo en la predicción correspondiente al año de origen 1990 (fila.pend[2] cuyas medias a posteriori valen 33,42 y 29,1 para el modelo log-normal y el general, respectivamente. Para el resto de los años existen diferencias entre los modelos. Los resultados para la predicción de las diagonales no observadas pueden verse en la figura 14.3.



node	mean	sd	MC error	2.5%	median	97.5%	start	sample
alpha[2]	-0.002298	0.06828	5.207E-4	-0.1593	-5.324E-4	0.1485	10001	100000
alpha[3]	-0.02818	0.09953	0.001035	-0.3034	-0.004748	0.1285	10001	100000
alpha[4]	-0.005673	0.1006	8.503E-4	-0.2438	-9.854E-4	0.2098	10001	100000
alpha[5]	0.01997	0.1112	0.001051	-0.1905	0.004055	0.3007	10001	100000
alpha[6]	0.04226	0.1308	0.001353	-0.1617	0.008926	0.3989	10001	100000
alpha[7]	0.04898	0.1501	0.001513	-0.1832	0.01013	0.4598	10001	100000
mu	11.54	0.1448	0.001414	11.25	11.54	11.82	10001	100000
sigma2	0.1108	0.03947	2.023E-4	0.05713	0.1033	0.2079	10001	100000
sigma2.h	0.009919	0.04951	3.674E-4	9.083E-6	9.152E-4	0.07439	10001	100000
sigma2.v	0.01927	0.0724	6.048E-4	1.099E-5	0.001805	0.1476	10001	100000
tau	10.97	3.276	0.01743	4.311	9.88	17.51	10001	100000

Figura 14.4: Estimaciones a posteriori de los parámetros del modelo para el ejemplo 14.2




node	mean	sd	MC error	2.5%	median	97.5%	start	sample
fila.pend[2]	29.1	15.35	0.05408	9.987	25.89	86.65	10001	100000
fila.pend[3]	15.62	6.097	0.03426	7.098	14.45	39.38	10001	100000
fila.pend[4]	92.72	29.45	0.1286	49.42	88.02	162.9	10001	100000
fila.pend[5]	286.4	74.41	0.2918	154.1	255.3	441.2	10001	100000
fila.pend[6]	487.2	135.5	0.7418	289.5	465.6	812.4	10001	100000
fila.pend[7]	929.1	335.0	1.759	520.6	871.1	1852.0	10001	100000

Figura 14.5: Media a posteriori, desviación estándar, mediana e intervalo bayesiano al 95 % para la predicción de las reclamaciones (cantidades) para cada año de origen (año del accidente) para el ejemplo 14.2. Resultados en millones de u.m. y ajustados por inflación

Las diferencias con el modelo log-normal (ejemplo 14.1) aparecen de nuevo. A modo de comentario, observemos que el total acumulado `diag.pend[8]` tiene media a posteriori de 1817,0 frente a los 2892,0 estimados en el modelo log-normal. Obviamente, el mismo análisis puede hacerse para el número de reclamaciones. Finalmente, de forma paralela al ejemplo 14.1 podemos completar la tabla de cantidades al estilo de la tabla 14.3 (a efectos de comparación de ambos modelos).

Análogamente para el número de reclamaciones, la tabla se completa con las predicciones del modelo (utilizamos en este caso la mediana a posteriori de la distribución predictiva para cada celda) y se muestran en la tabla 14.6.



node	mean	sd	MC error	2.5%	median	97.5%	start	sample
diag.pend[2]	864.6	245.6	1.151	528.3	825.2	1430.0	10001	100000
diag.pend[3]	451.0	133.1	0.6813	264.9	430.2	758.7	10001	100000
diag.pend[4]	282.1	86.54	0.4184	158.1	268.0	490.7	10001	100000
diag.pend[5]	141.6	55.19	0.2476	70.79	131.7	268.8	10001	100000
diag.pend[6]	50.7	21.11	0.0892	22.39	45.85	101.3	10001	100000
diag.pend[7]	27.34	17.05	0.06801	7.973	23.5	66.46	10001	100000
diag.pend[8]	1817.0	418.5	2.382	1231.0	1754.0	2782.0	10001	100000

Figura 14.6: Media a posteriori, desviación estándar, mediana e intervalo bayesiano al 95 % para la predicción de las reclamaciones (cantidades) que deberán ser pagadas cada próximo año para el ejemplo 14.2

Tabla 14.5: Predicción de cantidades individuales (media a posteriori, en negrita) para la tabla del ejemplo 14.2

Año origen	Años hasta el pago ($t-1$)						
	0	1	2	3	4	5	6
1989	527003	183260	90539	50471	37785	10110	21165
1990	594059	237289	99640	52390	50723	39029	29100
1991	810593	257122	87318	72538	81336	7113	8405
1992	1012181	339664	156531	181253	60010	15040	17670
1993	1459202	448651	188698	135700	84670	21170	24830
1994	1689751	563683	193100	149800	93470	23360	27390
1995	1698534	439500	193100	149500	93390	23310	27340

Ejercicios propuestos

- Para la tabla 14.7 obtenida de De Alba (2002), realizar su estimación bajo el modelo log-normal.
- En el ejercicio anterior, considerar también la información adicional aportada por la tabla 14.8 (De Alba, 2002) para el número de reclamaciones, y desarrollar un modelo general con la parametrización dada por $n_{it} \sim P(\lambda_{it})$ con $\log(\lambda_{it}) = \mu^* + \alpha_i^* + \beta_t^*$.
- Estimar un modelo general como el propuesto en este capítulo para las tablas 5 y 6 en De Alba (2002). Realizar el código WinBUGS y las predicciones correspondientes.

Tabla 14.6: Predicción (mediana a posteriori) del número de reclamaciones

Año de origen	Años hasta la liquidación ($t-1$)							Total
	0	1	2	3	4	5	6	
1989	6622	1943	489	138	61	223	66	9542
1990	6943	2133	632	154	162	390	82	10496
1991	8610	2216	736	651	256	106	26	12601
1992	9791	3167	1579	624	144	217	52	15565
1993	11722	3192	1773	490	195	293	70	17735
1994	13684	3664	1299	514	204	307	74	19746
1995	13068	3189	1270	502	199	300	72	18600

Tabla 14.7: Pérdidas acumuladas en miles de u.m.

Año origen	Año de desarrollo				
	0	1	2	3	4
1988	2000	6000	9000	11200	14000
1989	2600	6840	10920	15600	
1990	2380	3960	14400		
1991	3120	10800			
1992	3800				

Tabla 14.8: Número de reclamaciones

Año origen	Año de desarrollo				
	0	1	2	3	4
1988	400	700	850	930	1000
1989	480	790	1000	1140	
1990	500	950	1190		
1991	570	1050			
1992	600				

Capítulo 15

Teoría de la Ruina

15.1. Introducción

Controlar la solvencia de las empresas de seguros supone una de las principales ocupaciones de la ciencia actuarial. Obviamente, para una compañía de seguros, y para cualquier empresa, es vital prevenirse de resultados negativos.

Una empresa de seguros es solvente si posee suficientes activos para hacer frente a sus pasivos. Aunque esto es cierto para cualquier empresa o negocio, en las compañías de seguros el asunto toma otro cariz. En el negocio del seguro los pasivos no son nunca conocidos y pueden extenderse a muchos años en el futuro.

En este capítulo se considerará la evolución de la operación de aseguramiento a lo largo del tiempo. Para ello supondremos que la compañía aseguradora comienza con una cantidad de dinero positiva (reservas iniciales en el tiempo 0), recauda primas y paga las indemnizaciones correspondientes en la medida en que se producen. Si las reservas o capital disponible por la aseguradora llegan a ser negativas o nulas, se dice entonces que ocurre la ruina.

La teoría de la ruina se desarrollará en el marco de un modelo colectivo de riesgo, tradicionalmente el modelo de Poisson compuesto. El objetivo fundamental de la teoría de la ruina es el cálculo de la probabilidad de ruina. Éste es un indicador útil para la compañía de seguros ya que un valor alto de la misma indica inestabilidad, lo que supone que la compañía tome medidas como el reaseguro o cambie su política de primas, por ejemplo.

Introduciremos algunos resultados para obtener las probabilidades de ruina, así como la desigualdad de Lundberg, uno de los resultados más importantes de la ciencia actuarial. Daremos soluciones explícitas para la probabilidad de ruina, así como métodos numéricos para aproximarla en caso de no existencia de soluciones explícitas.

15.2. Proceso de riesgo

En la teoría de la ruina el proceso de reservas de una compañía de seguros se modela de acuerdo a un proceso estocástico de riesgo. De ahí que introduzcamos en esta sección, y de manera somera, el proceso estocástico de Poisson. Sobre este tema pueden consultarse Gerber (1979), Grandell (1991), Rolski et al. (1999) y Seal (1979), entre otros.

Un proceso estocástico relaciona variables aleatorias y tiempo. En nuestro caso el proceso es un modelo que describe el desarrollo del número de reclamaciones $N(t)$ a lo largo del tiempo.

Definición 15.1 *Un proceso estocástico de Poisson es un proceso $N(t)$ en el que:*

1. Dado $\lambda > 0$ se verifica:

$$N(t+h) - N(t) \sim P(\lambda h),$$

para todo $t > 0, h > 0$.

2. Es de incrementos independientes, es decir la ocurrencia de un siniestro no tiene influencia en la ocurrencia del siguiente. Formalmente:

$$N(t_1+h) - N(t_1) \quad \text{y} \quad N(t_2+h) - N(t_2),$$

son independientes.

3. Es de incrementos estacionarios, lo que supone que el número de reclamaciones en un intervalo fijo depende sólo de la longitud del intervalo de tiempo, formalmente $N(t+h) - N(t) \sim P(\lambda h)$, $\forall t$ depende de h y no de t .

El parámetro λ se denomina intensidad de reclamaciones y se corresponde con el número medio de reclamaciones correspondiente a un intervalo temporal unitario. Estrictamente, la condición 3 viene implicada por la condición 1.

Si $N(t)$ es un proceso de Poisson, se dirá entonces que $S = \sum_{i=1}^{N(t)} X_i$ es un proceso de Poisson compuesto.

15.3. El problema de la ruina

El proceso de riesgo de una empresa de seguros se modela mediante un proceso estocástico. Mediante $\{N(t)\}_{t \geq 0}$, representaremos el proceso asociado al número de reclamaciones, esto es, $N(t)$ proporciona el número de reclamaciones en el intervalo $(0, t]$. Se supondrá que $\{N(t)\}_{t \geq 0}$ es un proceso de Poisson. Las cantidades reclamadas se consideran como una sucesión de variables aleatorias $\{X_i\}_{i=1}^{\infty}$ independientes e idénticamente distribuidas e independientes de $N(t)$, de manera que X_i representa la cantidad asociada a la i -ésima reclamación. Por tanto, la

15.3. El problema de la ruina

cantidad total reclamada hasta el instante t vendrá dada por $S(t) = \sum_{i=1}^{N(t)} X_i$, suponiendo que $S(t) = 0$ si $N(t) = 0$. Por tanto, $S(t) = \sum_{i=1}^{N(t)} X_i$ es un proceso de Poisson compuesto.

Consideremos ahora una compañía aseguradora que presenta la siguiente estructura de reserva en el momento t :

$$U(t) = u + c \cdot t - S(t), \quad (15.1)$$

donde $u = U(0)$ representa el valor inicial de la reserva, $c \cdot t$ el monto de primas cobradas y $S(t)$ la cantidad total reclamada hasta el instante t .

Se supondrá que $c > E[S(t)]$, es decir que la prima recaudada por unidad de tiempo supera a la cantidad reclamada también por unidad de tiempo. Se dice entonces que la sobreprima de seguridad es positiva. Normalmente se escribe $c = (1 + \theta)\lambda E(X)$, donde $\theta > 0$ es la sobreprima de seguridad.

Una representación del proceso $U(t)$ se muestra en la figura 15.1. La compañía parte con una reserva inicial u , que se incrementa con el pago de primas y decrece con el pago de siniestros. Aquí $T_1, T_2, \dots$ representan las variables aleatorias que nos dan los puntos del intervalo $(0, t]$ en el que ocurren reclamaciones, y entonces las reservas de la compañía disminuyen. Puesto que para T_3 el total de reclamaciones $X_1 + X_2 + X_3$ es mayor que las reservas iniciales u más el monto de primas cobrado cT_3 , las reservas totales $U(T_3)$ están por debajo de 0, y se dice que el suceso ruina ha ocurrido.

Existen diversos problemas con una formulación similar que nada tienen que ver con operaciones de seguros. Por ejemplo, se llena una presa mediante agua procedente de ríos y lluvia a una tasa constante c . A intervalos aleatorios se extraen del depósito cantidades $X_1, X_2, \dots$. Si z representa el contenido inicial de la presa, entonces la reserva total de agua en el tiempo t vendrá dado por $z + ct - X(t)$; siendo $X(t)$ el proceso compuesto de Poisson y X_i realizaciones de $X(t)$.

Ejemplo 15.1 Probar que dados dos procesos de riesgo $U(t) = u + ct - S(t)$ y $\bar{U}(t) = u + \bar{c}t - \bar{S}(t)$ en el que $\bar{S}(t)$ es un proceso de Poisson compuesto en el que la distribución de la cantidad reclamada es exponencial con parámetro $\bar{\alpha} > 0$ y $N(t)$ es un proceso de Poisson con parámetro λt , se verifica:

1. Si $E[U(t)] = E[\bar{U}(t)]$, entonces $c - \lambda E(X) + \bar{\lambda}/\bar{\alpha} = \bar{c}$.
2. Si $E[U(t) - E(U(t))]^j = E[\bar{U}(t) - E(\bar{U}(t))]^j$, para $j = 2, 3$, entonces $\lambda E(X^2) = 2\bar{\lambda}/\bar{\alpha}^2$ y $\lambda E(X^3) = 6\bar{\lambda}/\bar{\alpha}^2$.

Solución:

1. Puesto que la única componente aleatoria de un proceso de riesgo es $S(t)$ obviamente se verifica que $E[U(t)] = u + ct - E[S(t)] = u + ct - \lambda E(X)t$. Por tanto, $E[\bar{U}(t)] = u + \bar{c}t - E[\bar{S}(t)] = u + \bar{c}t - \bar{\lambda}/\bar{\alpha}^2 t$. Igualando ambas ecuaciones se obtiene que $\bar{c} = c - \lambda E(X) + \bar{\lambda}/\bar{\alpha}$.




Figura 15.1: Proceso de riesgo

2. Obsérvese que

$$U(t) - E[U(t)] = u + ct - S(t) - u - ct + \lambda t E(X) - \lambda t E(X) - S(t), \quad (15.2)$$

$$\bar{U}(t) - E[\bar{U}(t)] = \bar{\lambda}/\bar{\alpha}t - \bar{S}(t). \quad (15.3)$$

La ecuación (15.2) equivale a $E[U(t) - E(U(t))]^2 = E[(S(t) - (\lambda E(X)t)]^2$, de donde $\text{Var}[U(t)] = \text{Var}[S(t)]$ y obviamente de (15.3) se deduce que $\text{Var}[\bar{U}(t)] = \text{Var}[\bar{S}(t)]$ y utilizando (13.6), se comprueba que $\lambda E(X^2) = 2\bar{\lambda}/\bar{\alpha}^2$. Un argumento similar para $j = 3$, conduce a $\lambda E(X^3) = 6\bar{\lambda}/\bar{\alpha}^3$.

◇

15.4. La probabilidad de supervivencia

15.3.1. Ruina con horizonte infinito

Se define en el caso continuo la probabilidad de ruina con horizonte infinito, también conocida como última probabilidad de ruina, como:

$$\phi(u) = \Pr[U(t) < 0, \text{ para algún } t > 0].$$

Se trata de la probabilidad de que las reservas de la compañía aseguradora caigan por debajo de cero para algún $t > 0$.

Para el caso de tiempo discreto, la probabilidad de ruina, o de última ruina es:

$$\phi(u) = \Pr[U(t) < 0, \text{ para algún } t, t = r, 2r, 3r, \dots].$$

Se verifica que si la ruina ocurre en tiempo discreto también ocurrirá bajo tiempo continuo. El recíproco no es cierto.

15.3.2. Ruina con horizonte finito

La probabilidad de ruina con horizonte finito, también conocida como probabilidad última de ruina, se define para el caso de tiempo continuo como:

$$\phi(u, t) = \Pr[U(s) < 0, \text{ para algún } s, 0 < s \leq t].$$

Se trata de la probabilidad de que las reservas de la compañía aseguradora caigan por debajo de cero para algún valor de t en el intervalo $(0, t]$.

Para el caso de tiempo discreto, la probabilidad de ruina o probabilidad de última ruina con horizonte finito es:

$$\phi(u, t) = \Pr[U(s) < 0, \text{ para algún } s, s = r, 2r, 3r, \dots, t],$$

siendo t un entero múltiplo de r .

En este capítulo nos limitaremos a calcular la probabilidad de ruina en tiempo continuo con horizonte infinito. Los restantes modelos, tiempo discreto (horizonte finito e infinito) y tiempo continuo (horizonte finito) tienen un tratamiento similar al desarrollado aquí, pudiendo el lector consultarlos en Dickson (2005) y Rolski et al. (1999).

15.4. La probabilidad de supervivencia

A efectos de calcular la probabilidad de ruina $\phi(u)$ es recomendable trabajar con la probabilidad complementaria o de supervivencia $\Phi(u) = 1 - \phi(u)$, es decir la probabilidad de que cuando se comienza con unas reservas iniciales u la ruina nunca ocurra. El siguiente teorema establece una ecuación integro diferencial que verifica la probabilidad de no ruina o supervivencia.

Teorema 15.1 La función probabilidad de supervivencia satisface la ecuación integral diferencial

$$\Phi'(u) = \frac{\lambda}{c} \left(\Phi(u) - \int_0^u f(x) \Phi(u-x) dx \right). \quad (15.4)$$

Demostración: Observemos que dado (15.1) la ruina ocurre si $S(t) > u + c \cdot t$, mientras que la ruina no ocurre (y por tanto ocurre el suceso supervivencia) si $S(t) \leq u + c \cdot t$, o lo que es equivalente $S(t) - x \leq u + c \cdot t - x$. Luego,

$$\Pr(\text{No ruina}) = \Pr(S(t) - x \leq u + ct - x) = \Phi(u + ct - x),$$

y por tanto,

$$\begin{aligned} \Phi(u) &= \int_{t=0}^{\infty} \int_{x=0}^{u+ct} \Phi(u+ct-x) f(x) g(t) dx dt \\ &= \int_0^{\infty} \lambda e^{-\lambda t} \int_0^{u+ct} f(x) \Phi(u+ct-x) dx dt. \end{aligned} \quad (15.5)$$

Haciendo el cambio de variable $s = u + c \cdot t$ en la ecuación (15.5) tenemos:

$$\begin{aligned} \Phi(u) &= \frac{1}{c} \int_u^{\infty} \lambda e^{-\frac{\lambda}{c}(s-u)} \int_0^s f(x) \Phi(s-x) dx ds \\ &= \frac{\lambda}{c} e^{\frac{\lambda u}{c}} \int_u^{\infty} e^{-\frac{\lambda s}{c}} \int_0^s f(x) \Phi(s-x) dx ds \\ &= \frac{\lambda}{c} e^{\frac{\lambda u}{c}} \left(\int_0^{\infty} e^{-\frac{\lambda s}{c}} \int_0^s f(x) \Phi(s-x) dx ds \right. \\ &\quad \left. - \int_0^u e^{-\frac{\lambda s}{c}} \int_0^s f(x) \Phi(s-x) dx ds \right). \end{aligned}$$

Calculando la derivada de la expresión anterior con respecto de u en ambos lados de la igualdad se obtiene,

$$\begin{aligned} \Phi'(u) &= \frac{\lambda^2}{c^2} e^{\frac{\lambda u}{c}} \left(\int_0^{\infty} e^{-\frac{\lambda s}{c}} \int_0^s f(x) \Phi(s-x) dx ds \right. \\ &\quad \left. - \int_0^u e^{-\frac{\lambda s}{c}} \int_0^s f(x) \Phi(s-x) dx ds \right) \\ &= \frac{\lambda}{c} e^{\frac{\lambda u}{c}} \int_0^u e^{-\frac{\lambda s}{c}} f(x) \Phi(u-x) dx \\ &= \frac{\lambda}{c} \left(\Phi(u) - \int_0^u f(x) \Phi(u-x) dx \right), \end{aligned}$$

donde se ha hecho uso del teorema fundamental del cálculo.

Esta última expresión es una ecuación integral diferencial puesto que la función incógnita $\Phi(u)$ aparece en términos de derivada y bajo el símbolo de la integral simultáneamente. Obsérvese que la integral en el segundo miembro es la convolución $f * \Phi$.

El siguiente teorema proporciona la probabilidad de ruina para $u = 0$.

Teorema 15.2 La probabilidad de ruina en $u = 0$ viene dada por

$$\phi(0) = \frac{\lambda E(X)}{c}. \quad (15.6)$$

Demostración: Intercambiando en la ecuación (15.4) Φ por $1 - \phi$ tenemos:

$$-\phi'(u) = \frac{\lambda}{c} - \frac{\lambda}{c} \phi(u) - \frac{\lambda}{c} \int_0^u f(x) dx + \frac{\lambda}{c} \int_0^u f(x) \phi(u-x) dx.$$

Por tanto,

$$\begin{aligned} \phi'(u) &= \frac{\lambda}{c} \phi(u) - \frac{\lambda}{c} \int_0^u f(x) \phi(u-x) dx - \frac{\lambda}{c} \left(1 - \int_0^u f(x) dx \right) \\ &= \frac{\lambda}{c} \phi(u) - \frac{\lambda}{c} \int_0^u f(x) \phi(u-x) dx - \frac{\lambda}{c} [1 - F(u)], \end{aligned}$$

en la que $F(x)$ es la función de distribución de X , la cantidad de reclamación.

Integrando ahora en ambos lados de la igualdad sobre u desde cero hasta infinito tenemos:

$$\begin{aligned} \int_0^{\infty} \phi'(u) du &= \frac{\lambda}{c} \int_0^{\infty} \phi(u) du - \frac{\lambda}{c} \int_0^{\infty} \int_0^u f(x) \phi(u-x) dx du \\ &\quad - \frac{\lambda}{c} \int_0^{\infty} [1 - F(u)] du. \end{aligned} \quad (15.7)$$

La doble integral en (15.7) puede ser reescrita, haciendo el cambio de variable $u - x = y$, como

$$\int_0^{\infty} \int_0^u f(x) \phi(u-x) dx du = \int_0^{\infty} \int_0^{\infty} \phi(y) dy f(x) dx = \int_0^{\infty} \phi(y) dy.$$

Sustituyendo este último resultado en (15.7) resulta

$$\int_0^{\infty} \phi'(u) du = -\frac{\lambda}{c} \int_0^{\infty} [1 - F(u)] du.$$

Ahora teniendo en cuenta que,

$$\int_0^{\infty} \phi'(u) du = \phi(\infty) - \phi(0) = 0 - \phi(0) = -\phi(0),$$

y

$$\int_0^{\infty} [1 - F(u)] du = E(X),$$

se obtiene:

$$\phi(0) = \frac{\lambda E(X)}{c}.$$

Ejemplo 15.2 Obtener la función $\phi(u)$, la probabilidad de ruina, cuando la cantidad reclamada sigue una distribución exponencial de parámetro $\alpha > 0$.

Solución: En este caso $f(x) = \alpha e^{-\alpha x}$, y usando (15.4) resulta:

$$\Phi'(u) = \frac{\lambda}{c} \Phi(u) - \frac{\lambda \alpha}{c} \int_0^u e^{-\alpha x} \Phi(u-x) dx.$$

Mediante el cambio de variable $z = u - x$ tenemos:

$$\begin{aligned} \Phi'(u) &= \frac{\lambda}{c} \Phi(u) + \frac{\lambda \alpha}{c} \int_u^0 e^{-\alpha(u-z)} \Phi(z) dz \\ &= \frac{\lambda}{c} \Phi(u) - \frac{\lambda \alpha}{c} e^{-\alpha u} \int_0^u e^{\alpha z} \Phi(z) dz. \end{aligned} \quad (15.8)$$

Derivando respecto de u en ambos lados de (15.8) tenemos:

$$\Phi''(u) = \frac{\lambda}{c} \Phi'(u) + \frac{\lambda \alpha^2}{c} e^{-\alpha u} \int_0^u e^{\alpha z} \Phi(z) dz - \frac{\lambda \alpha}{c} \Phi(u). \quad (15.9)$$

Usando (15.8) se tiene que:

$$\int_0^u e^{\alpha z} \Phi(z) dz = \left[\frac{\lambda}{c} \Phi(u) - \Phi'(u) \right] \frac{ce^{\alpha u}}{\lambda \alpha}.$$

Sustituyendo esta última expresión en (15.9) tenemos:

$$\Phi''(u) = \frac{\lambda}{c} \Phi'(u) + \frac{\lambda \alpha}{c} \Phi(u) - \alpha \Phi'(u) - \frac{\lambda \alpha}{c} \Phi(u).$$

Por tanto,

$$\Phi''(u) + \left(\alpha - \frac{\lambda}{c} \right) \Phi'(u) = 0,$$

que corresponde a una ecuación diferencial de segundo orden con coeficientes constantes cuya solución general (ver Hirsch y Smale, 1974) es:

$$\Phi(u) = a_0 + a_1 e^{-(\alpha - \frac{\lambda}{c})u}.$$

15.5. Coeficiente de ajuste y desigualdad de Lundberg

495

De acuerdo con (15.6), $\phi(0) = \lambda E(X)/c$, y $E(X)$ es $1/\alpha$, de donde $\Phi(0) = 1 - \phi(0) = 1 - \lambda/(\alpha c) = a_0 + a_1$. Por otro lado, teniendo en cuenta que $\lim_{u \rightarrow \infty} \Phi(u) = 1$, se deduce que $a_0 = 1$. Por tanto, la solución de la ecuación diferencial es:

$$\Phi(u) = 1 - \frac{\lambda}{\alpha c} e^{-(\alpha - \frac{\lambda}{c})u},$$

y la probabilidad de ruina es:

$$\phi(u) = 1 - \Phi(u) = \frac{\lambda}{\alpha c} e^{-(\alpha - \frac{\lambda}{c})u}. \quad (15.10)$$

Ejemplo 15.3 Calcular la probabilidad de ruina si X sigue una distribución exponencial con parámetro $\alpha = 1$, mientras que $c = 0,2$ y $\lambda = 0,1$, teniendo en cuenta que las reservas iniciales son $1, 2, 3, \dots, 20$.

Solución: Sustituyendo los valores de α , c y λ en (15.10) se obtienen los valores para la probabilidad de ruina que aparecen en la tabla 15.1.

Tabla 15.1: Probabilidad de ruina para distintos valores de u

u	$\phi(u)$	u	$\phi(u)$
1	0,3032650000	11	0,0020433900
2	0,1839400000	12	0,0012393800
3	0,1115650000	13	0,0007517200
4	0,0676676000	14	0,0004559410
5	0,0410425000	15	0,0002765420
6	0,0248935000	16	0,0001677310
7	0,0150987000	17	0,0001017340
8	0,0091578200	18	0,0000617049
9	0,0055545000	19	0,0000374259
10	0,0033689700	20	0,0000227000

Obsérvese que, como cabía esperar, la probabilidad de ruina disminuye conforme se incrementan las reservas iniciales. $\diamond$

15.5. Coeficiente de ajuste y desigualdad de Lundberg

En esta sección se introduce el coeficiente de ajuste, que se muestra como una poderosa herramienta para obtener una cota superior de la probabilidad de ruina.

Definición 15.2 El coeficiente de ajuste, R , se define como la única raíz positiva de la ecuación

$$\lambda \int_0^{\infty} e^{rx} f(x) dx = \lambda + rc. \quad (15.11)$$

Obsérvese que la ecuación (15.11) tiene al menos una solución distinta de la trivial ($r = 0$), puesto que el lado derecho de la ecuación es una función lineal de r y el lado izquierdo es una función convexa.

El coeficiente de ajuste juega un papel importante en teoría de la ruina puesto que $\phi(u) \leq e^{-Ru}$ como se prueba en el siguiente teorema.

Teorema 15.3 Supongamos que $R > 0$ satisface la ecuación (15.11). Entonces la probabilidad de ruina verifica

$$\phi(u) \leq e^{-Ru}, \quad u \geq 0. \quad (15.12)$$

Demostración: Sea $\phi_n(u)$ la probabilidad de que la ruina ocurra en la reclamación n -ésima o antes, $n = 0, 1, \dots$. Ahora procederemos por inducción sobre n . Para $n = 0$ obviamente se verifica que $\phi_0(u) = 0 < e^{-Ru}$. Supongamos ahora que $\phi_n(u) \leq e^{-Ru}$, entonces:

$$\begin{aligned} \phi_{n+1}(u) &= \int_0^{\infty} \lambda e^{-\lambda t} \int_0^{\infty} \phi_n(u + ct - x) f(x) dx dt \\ &\leq \int_0^{\infty} \lambda e^{-\lambda t} \int_0^{\infty} e^{-R(u+ct-x)} f(x) dx dt \\ &= e^{-Ru} \int_0^{\infty} \lambda e^{t(-\lambda - Rc)} \left(\int_0^{\infty} e^{Rx} f(x) dx \right) dt. \end{aligned} \quad (15.13)$$

Ahora, puesto que R es solución de la ecuación (15.11) tenemos que

$$\int_0^{\infty} e^{Rx} f(x) dx = \frac{\lambda + Rc}{\lambda}. \quad (15.14)$$

Sustituyendo, finalmente, (15.14) en (15.13) y resolviendo la integral correspondiente se obtiene el resultado. ■

Ejemplo 15.4 Determinar una cota superior para la probabilidad de ruina con los mismos datos del ejemplo 15.3.

Solución: Puesto que $E(e^{rx}) = 1/(1-r)$, el coeficiente de ajuste es la solución positiva de la ecuación

$$\frac{\lambda}{1-r} = \lambda + rc,$$

que es $R = 0.5$. Luego $\phi(u) \leq e^{-0.5u}$ y por tanto la cota superior de la probabilidad de ruina para los distintos valores de u son las que se muestran en la tabla 15.2. ♦

Obsérvese ahora que las probabilidades de ruina calculadas en el ejemplo 15.3 se sitúan por debajo de estas cotas superiores.

Tabla 15.2: Cota superior para $\phi(u)$

u	$\phi(u)$	u	$\phi(u)$
1	0,6065310000	11	0,0040867700
2	0,3678790000	12	0,0024787500
3	0,2231300000	13	0,0015034400
4	0,1353350000	14	0,0009118820
5	0,0820850000	15	0,0005530840
6	0,0497871000	16	0,0003354630
7	0,0301974000	17	0,0002034680
8	0,0183156000	18	0,0001234100
9	0,0111090000	19	0,0000748518
10	0,0067379500	20	0,0000453999

15.6. Cálculo exacto y aproximado de la probabilidad de ruina. Cotas

15.6.1. Cálculo exacto de la probabilidad de ruina

La transformada de Laplace constituye una potente herramienta matemática de utilidad en la resolución de ecuaciones diferenciales e integro diferenciales y por tanto, un elemento de importancia en teoría de la ruina. Comencemos esta sección introduciendo la transformada de Laplace, así como algunas propiedades de la misma que nos serán de utilidad.

Definición 15.3 Dada una función $g(y)$ definida para todo $y \geq 0$, se define la transformada de Laplace de $g(y)$ como:

$$g^*(s) = \int_0^{\infty} e^{-sy} g(y) dy.$$

La ecuación (15.4) puede resolverse con la ayuda de esta herramienta, para lo que se precisa de las siguientes propiedades de la transformada de Laplace. El lector interesado en profundizar en la transformada de Laplace, así como en las diversas técnicas de resolución de ecuaciones diferenciales, integrales e integro diferenciales utilizando esta y otras metodologías, puede consultar Krasnov et al. (1982) y Duchateau y Zachmann (1986).

Proposición 15.1 Supongamos que $g_1(y)$ y $g_2(y)$ son dos funciones cuyas transformadas de Laplace existen y $g(y)$ es una función derivable cuya transformada de Laplace también existe. Entonces:

1.

$$\int_0^{\infty} e^{-sy} [\alpha_1 g_1(y) + \alpha_2 g_2(y)] dy = \alpha_1 g_1^*(s) + \alpha_2 g_2^*(s), \quad (15.15)$$

donde $\alpha_1, \alpha_2 \in \mathbb{R}$.

2.

$$\int_0^{\infty} e^{-sy} g'(y) dy = sg^*(s) - g(0). \quad (15.16)$$

3. Si

$$g(x) = \int_0^x g_1(y)g_2(x-y)dy,$$

se tiene que

$$g^*(s) = g_1^*(s)g_2^*(s). \quad (15.17)$$

El siguiente resultado proporciona la transformada de Laplace de la función probabilidad de supervivencia $\Phi(u)$.

Teorema 15.4 La transformada de Laplace de la función $\Phi(s)$ en la ecuación integral diferencial (15.4) es

$$\Phi^*(s) = \frac{c\Phi(0)}{cs - \lambda[1 - f^*(s)]}. \quad (15.18)$$

Demostración: El resultado se obtiene haciendo uso de las relaciones (15.15), (15.16) y (15.17). $\square$

Ejemplo 15.5 Calcular de manera exacta la probabilidad de ruina para $u = 1, 2, \dots, 20$ en el caso de que la cantidad reclamada siga una distribución gamma de parámetros 2 y 1 y $c = 1/(2, 1\lambda)$.

Solución: Utilizaremos la expresión (15.18). Se necesita por tanto conocer $f^*(s)$. Ahora bien $\Phi(0) = 1 - \phi(0) = 1 - \frac{2\lambda}{2, 1\lambda} = \frac{1}{21}$. Por otro lado, la transformada de Laplace de $f(x)$ viene dada por

$$f^*(s) = \int_0^{\infty} e^{-sx} f(x) dx = \int_0^{\infty} x e^{-(s+1)x} dx = \frac{1}{(s+1)^2}.$$

Ahora, de (15.18) se tiene que:

$$\begin{aligned} \Phi^*(s) &= \frac{2,1\lambda \frac{1}{21}}{2,1\lambda s - \lambda[1 - (s+1)^{-2}]} \\ &= \frac{0,47(s+1)^2}{s(s+0,032)(s+1,491)} \\ &= \frac{0,985}{s} - \frac{0,942}{s+0,032} + \frac{0,00505}{s+1,491}. \end{aligned}$$

Invirtiendo la transformada de Laplace obtenemos:

$$\Phi(u) = 0,985s - 0,942e^{-0,032u} + 0,00505e^{-1,491u}.$$

Finalmente, calculando $\phi(u) = 1 - \Phi(u)$, se obtienen las probabilidades exactas de ruina que aparecen en la tabla 15.3.

Tabla 15.3: Probabilidades exactas de ruina

u	$\phi(u)$	u	$\phi(u)$
1	0,926396	11	0,674114
2	0,898179	12	0,652937
3	0,870162	13	0,632425
4	0,842871	14	0,612558
5	0,816402	15	0,593315
6	0,790758	16	0,574676
7	0,765917	17	0,556623
8	0,741856	18	0,539137
9	0,718551	19	0,522200
10	0,695978	20	0,505795

◇

15.6.2. Cálculo aproximado de la probabilidad de ruina

Aunque existen diversos métodos para encontrar una aproximación de la probabilidad de ruina, en este texto nos limitaremos a presentar el método de De Vylder. Este método se basa en aproximar el proceso $\{U(t)\}$, del que se desea conocer la probabilidad de ruina, mediante otro proceso más simple $\{\bar{U}(t)\}$ tal que:

$$\bar{U}(t) = u + \bar{c}t - \bar{S}(t),$$

donde:

- $\bar{U}(0) = U(0) = u$.
- $\bar{c}$ es la nueva prima recaudada por unidad de tiempo.
- $\bar{S}(t)$ es la cantidad total reclamada cuando la cantidad individual de reclamaciones sigue una distribución exponencial con parámetro $\alpha > 0$, esto es $\bar{F}(x) = 1 - e^{-\alpha x}$, $x > 0$.

De este modo, la probabilidad de ruina se aproxima a través de (15.10). Los nuevos parámetros se obtienen resolviendo el sistema

$$E[U(t)] = E[\bar{U}(t)], \quad (15.19)$$

$$E[U(t) - E(U(t))]^j = E[\bar{U}(t) - E(\bar{U}(t))]^j, \quad j = 2, 3. \quad (15.20)$$

Ejemplo 15.6 Calcular de manera aproximada las probabilidad de ruina obtenidas de manera exacta en el ejemplo 15.5.

Solución: Las ecuaciones (15.19) y (15.20) resultan (véase ejemplo 15.1):

$$\begin{aligned} \bar{c} &= c - \lambda E(X) + \bar{\lambda}/\bar{\alpha}, \\ \lambda E(X^2) &= 2\bar{\lambda}/\bar{\alpha}^2, \\ \lambda E(X^3) &= 6\bar{\lambda}/\bar{\alpha}^3. \end{aligned}$$

Obsérvese que en este sistema se igualan los momentos de los dos procesos de riesgo. En nuestro caso se obtiene que $E(X) = 2$, $E(X^2) = 6$ y $E(X^3) = 24$ y puesto que $c = 2,1\lambda$ la solución del sistema es $\bar{\alpha} = 4/3$, $\bar{\lambda} = 16/3\lambda$, $\bar{c} = 4,1\lambda$. Ahora sustituyendo estos resultados en la ecuación (15.10) se obtiene $\phi(u) = 0,975e^{-0,03u}$. Finalmente las probabilidades de ruina obtenidas a partir de esta expresión se muestran en la tabla 15.4 y no se aprecia excesiva diferencia con los datos de la tabla 15.3.

◇

15.6.3. Cotas inferior y superior de la probabilidad de ruina

En esta sección estudiaremos la conexión que existe entre la probabilidad de ruina y la cantidad máxima total reclamada, que sigue como veremos, una distribución geométrica compuesta.

Para ello consideremos la máxima cantidad total reclamada, es decir la máxima diferencia entre los pagos realizados y las primas recaudadas en $(0, t]$. Escribiremos:

$$U(t) = u + ct - S(t) = u - [S(t) - ct],$$

y denominaremos:

$$L = \max_{t \geq 0} \{S(t) - ct\}.$$

Tabla 15.4: Probabilidades aproximadas de ruina

u	$\phi(u)$	u	$\phi(u)$
1	0,946184	11	0,700951
2	0,918220	12	0,680234
3	0,891083	13	0,660130
4	0,864747	14	0,640621
5	0,839190	15	0,621687
6	0,814388	16	0,603314
7	0,790320	17	0,585483
8	0,766962	18	0,568180
9	0,744295	19	0,551387
10	0,722298	20	0,535091

Ahora, la ruina ocurre si $u - L < 0$, o equivalentemente si $L > u$, y la probabilidad de ruina será:

$$\phi(u) = \Pr(u < L).$$

Teorema 15.5 Sea N la variable aleatoria que proporciona el número de veces que ocurre L , entonces la distribución de N es geométrica de parámetro $\phi(0)$.

Demostración: Sea $L > 0$, y entonces la cantidad total reclamada máxima es positiva. Si las reservas caen por debajo de las reservas iniciales u , la probabilidad de que esto ocurra es $\phi(0)$. Si esto ocurre, y las reservas iniciales caen a un nivel $u - l_1$ entonces $L = l_1$. Situados en este punto (digamos t_1), la probabilidad de que vuelva a ocurrir que $L > 0$ es de nuevo $\phi(0)$, cayendo ahora las reservas por debajo del nivel $u - l_1$. Continuando con este argumento se observa que la probabilidad de que el suceso cantidad total reclamada máxima ocurra n veces es:

$$\phi(0)^n [1 - \phi(0)] = \phi(0)^n \Phi(0),$$

que corresponde a una distribución geométrica con parámetro $\phi(0)$. ■

Corolario 15.1 Sea $L = \sum_{i=1}^N L_i$, siendo N la variable aleatoria que nos da el número de veces en que $L > 0$, con $\{L_i\}_{i=1}^N$ variables aleatorias i.i.d. e independientes de N , entonces L sigue una distribución geométrica compuesta, esto es:

$$\Pr(L \leq u) = \sum_{n=0}^{\infty} \phi(0)^n \Phi(0) K^{n*}(u),$$

siendo $K(x) = \Pr(L \leq x)$, con función de densidad $k(x)$.

Proposición 15.2 La transformada de Laplace de L viene dada por

$$L^*(s) = \frac{cs\Phi(0)}{cs - \lambda[1 - f^*(s)]}. \quad (15.21)$$

Demostración: En efecto:

$$\begin{aligned} L^*(s) &= E(e^{-sL}) = \int_0^\infty e^{-su} d\Phi(u) du \\ &= \Phi(0) + \int_0^\infty e^{-su} \frac{d}{du} [\Phi(u)] du = \Phi(0) + s\Phi^*(s) - \Phi(0) = s\Phi^*(s), \end{aligned}$$

donde se ha utilizado el hecho de que la distribución de L es una variable aleatoria mixta con masa de probabilidad en cero dada por $\Pr(L=0) = \Phi(0)$. Utilizando ahora (15.18) se obtiene el resultado. ■

Teorema 15.6 La función de densidad de L viene dada por:

$$k(x) = \frac{1}{E(X)} [1 - F(x)],$$

siendo $F(x)$ la función de distribución de la variable aleatoria cantidad reclamada.

Demostración: Puesto que L sigue una distribución geométrica compuesta resulta:

$$E(e^{-sL}) = \frac{\Phi(0)}{1 - \phi(0)k^*(s)}, \quad (15.22)$$

donde se ha utilizado el hecho de que:

$$E(e^{-sL}) = E[E(e^{-sL} | N)] = E[k^*(s)^N].$$

Igualando (15.21) con (15.22) y teniendo en cuenta (15.6) se obtiene, después de algunos cálculos:

$$k^*(s) = \frac{1}{E(X)s} [1 - f^*(s)],$$

e invirtiendo la transformada de Laplace resulta:

$$k(x) = \frac{1}{E(X)} [1 - F(x)].$$

Ahora ya estamos en disposición de incluir el siguiente resultado, debido a Govaerts y De Vylder (1984), también ilustrado en Dufresne y Gerber (1989). ■

Teorema 15.7 Las cotas inferiores y superiores de la probabilidad de ruina se obtienen a partir de:

$$1 - \Phi_s(u) \leq \phi(u) \leq 1 - \Phi_i(u),$$

donde:

$$\Phi_i(u) = \Phi(0) + \phi(0) \sum_{j=1}^u k_i(j) \Phi_i(u-j),$$

$$\Phi_i(0) = \Phi(0),$$

$$\Phi_s(u) = \frac{1}{1 - \phi(0)k_s(0)} \left[\Phi(0) + \phi(0) \sum_{j=1}^u k_s(j) \Phi_s(u-j) \right],$$

$$\Phi_s(0) = \frac{\Phi(0)}{1 - \phi(0)k_s(0)},$$

con

$$k_s(j) = K(j+1) - K(j), \quad j = 0, 1, \dots, \quad (15.23)$$

$$k_i(j) = K(j) - K(j-1), \quad j = 1, 2, \dots \quad (15.24)$$

Demostración: Definamos las variables aleatorias $L_s = \sum_{j=1}^N L_{s,j}$ con $\{L_{s,j}\}_{j=1}^\infty$ variables aleatorias i.i.d. cada una con función de densidad k_s como en (15.23) y la variable aleatoria $L_i = \sum_{j=1}^N L_{i,j}$ con $\{L_{i,j}\}_{j=1}^\infty$ i.i.d. cada una con función de densidad k_i como en (15.24). Entonces:

$$K_s(u) \geq K(u) \geq K_i(u),$$

por tanto:

$$K_s^{n*}(u) \geq K^{n*}(u) \geq K_i^{n*}(u).$$

Puesto que

$$\Phi(u) = \Phi(0) + \sum_{n=1}^\infty \phi(0)^n \Phi(0) K^{n*}(u),$$

tenemos

$$\Pr(L_s < u) \geq \Pr(L < u) \geq \Pr(L_i < u),$$

donde se ha tenido en cuenta el hecho de que L_i y L_s son variables aleatorias discretas, y por tanto:

$$\Pr(L_s < u) < \Pr(L_s \leq u),$$

$$\Pr(L_i < u) < \Pr(L_i \leq u).$$

En consecuencia:

$$\Pr(L_i < u) \leq \Phi(u) \leq \Pr(L_s < u),$$

y

$$1 - \Pr(L_s < u) \leq \phi(u) \leq 1 - \Pr(L_i < u).$$

Finalmente, el resultado se obtiene después de aplicar la fórmula de recursión de Panjer (13.21) para calcular $\Pr(L_s < u)$ y $\Pr(L_i < u)$.

Tabla 15.5: Cotas inferiores, superiores y valor exacto de la probabilidad de ruina para distintos valores de u

u	Cota inferior	Valor exacto	Cota superior
1	0,2689420	0,30326500	0,500000
2	0,1431120	0,18394000	0,441140
3	0,0757330	0,11156500	0,412824
4	0,0394468	0,06766760	0,399105
5	0,0199040	0,04104250	0,392458
6	0,0093800	0,02489350	0,389238
7	0,0037120	0,01509870	0,387673
8	0,0006600	0,00915782	0,386555
9	0,0000000	0,00555450	0,386378
10	0,0000000	0,00336897	0,386292

Ejemplo 15.7 Para los datos del ejemplo 15.3 calcular las cotas inferiores y superiores de la probabilidad de ruina.

Solución: Se necesitan las siguientes cantidades:

$$k(x) = e^{-x}, \quad K(x) = 1 - e^{-x}, \quad \phi(0) = \Phi(0) = 1/2,$$

$$\Phi_s(0) = \frac{1/2}{1 - 1/2(1 - e^{-1})} = 0,731058, \quad \Phi_i(0) = 1/2,$$

y las fórmulas de recurrencia a utilizar son:

$$\Phi_s(u) = 0,731058 \left[1 + \sum_{j=1}^u k_s(j) \Phi_s(u-j) \right],$$

$$\Phi_i(u) = \frac{1}{2} \left[1 + \sum_{j=1}^u k_i(j) \Phi_i(u-j) \right].$$

Las cotas pedidas aparecen en la tabla 15.5 junto con los valores exactos de la probabilidad de ruina.

15.7. Problemas propuestos

1. Demostrar que $\Phi(0)$ viene dada por

$$\Phi(0) = \frac{\theta}{1 + \theta},$$

donde θ es la sobreprima de seguridad.

2. Demostrar que el coeficiente de ajuste R corresponde a la constante de aversión al riesgo cuando se utiliza el principio de utilidad exponencial y la prima resultante es c .
3. Demostrar que si la distribución de la cantidad reclamada es exponencial con parámetro $\alpha > 0$, entonces el coeficiente de ajuste es la solución positiva de la ecuación:

$$1 + (1 + \theta)E(X)r = \frac{\delta}{\delta - r},$$

siendo $\delta = \frac{1}{E(X)}$.

4. Demostrar que $0 \leq R \leq 2\theta\mu_1/\mu_2$, siendo $\mu_1 = E(X)$, $\mu_2 = E(X^2)$ y θ la sobreprima de seguridad.
5. Comprobar que el coeficiente de ajuste para el caso en que X siga una distribución exponencial con parámetro 2, $\lambda = 0,1$ y $c = 1,1$ es aproximadamente 0,40909.
6. Utilizar la expresión (15.21) para demostrar que $\phi(0) = \lambda E(X)/c$.
7. Calcular de forma exacta la probabilidad de ruina para $u = 5, 10, 15, 20$ si la cantidad reclamada tiene por función de densidad:

$$f(x) = e^{-3x} + \frac{10}{3}e^{-5x}, \quad x > 0,$$

sabiendo que $c = 15/11$.

8. Obtener cotas inferiores y superiores para la probabilidad de ruina si $u = 1, 5, 10, 15$, $f(x) = 12(e^{-3x} - e^{-4x})$, $\lambda = c = 1$ y $\theta = 5/7$.

Apéndice A

Breve manual de FirstBayes

A.1. Presentación

El programa FirstBayes (O'Hagan, 2005; en su última versión) ha sido diseñado para facilitar la enseñanza y el aprendizaje de la estadística bayesiana básica. Permite la implementación de varios modelos estadísticos simples pero de gran aplicación. La forma en que se presentan los diferentes modelos es muy directa e intuitiva, facilitando el entendimiento de cómo funciona la aproximación bayesiana.

Se ofrece de forma gratuita para todos aquellos interesados en las herramientas bayesianas. La última versión desarrollada es la 1.3. Toda la información necesaria para descargar el programa puede obtenerse en la dirección:

<http://www.firstbayes.co.uk>

A.2. Contenido

El programa incluye cuatro de los principales modelos conjugados en el análisis bayesiano: beta-binomial, gamma-Poisson, gamma-gamma y normal con varianza conocida. El usuario podrá fijar los parámetros de la distribución a priori correspondiente a cada modelo. A continuación se añadirán los datos en el análisis para obtener la distribución a posteriori. La forma en la que la información es incorporada en el análisis facilita al usuario el entendimiento del método bayesiano, donde la distribución a priori y la verosimilitud son combinados a través del teorema de Bayes. Tanto la distribución a priori, como la verosimilitud y la distribución a posteriori pueden ser representadas simultáneamente a través de la herramienta triplot.

El programa también permite el análisis descriptivo de trece familias de distribuciones. Dichas distribuciones son: beta, beta-binomial, χ^2 , $\mathcal{F}$ de Snedecor,

geométrica, gamma, hipergeométrica, inversa χ^2 , binomial negativa, normal, Poisson y t de Student.

Además incluye otros dos modelos. Uno es la distribución normal con varianza conocida y el otro la regresión lineal. Para ambos modelos permite el cálculo de las distribuciones a posteriori marginal para cada parámetro. En el caso de la regresión lineal también permite representar gráficamente el ajuste y los residuos estimados.

Del análisis bayesiano se obtienen las distribuciones predictivas, que permiten aproximar los valores futuros de la variable de interés. El programa FirstBayes permite su cálculo para los modelos comentados anteriormente.

A.3. Instalación

El proceso de instalación del FirstBayes no es sencillo, ni se limita a realizar un doble click sobre un archivo ejecutable. Si el programa ha sido obtenido a partir del archivo comprimido disponible en la página web mencionada anteriormente se deberán seguir los pasos explicados en el manual de uso incluido en el archivo comprimido.

Una vez hayamos descargado el fichero debemos ejecutarlo realizando un doble click. Se nos preguntará en qué directorio queremos que sea instalado el programa. Debemos escribir C:\+ (la instalación no se completará correctamente si seleccionamos otro directorio).

A continuación aparecerán dos accesos directos en el escritorio, FirstBayes y Registrar FirstBayes. Antes de poder usar el programa debemos registrarlo. Para ello realizamos doble click sobre el archivo "Registrar FirstBayes". Respondemos Si a la pregunta que se nos plantea y un mensaje nos confirmará que la información ha sido introducida en el registro.

Si se han seguido los pasos correctamente, hemos completado la instalación. Podemos ahora eliminar el acceso directo Registrar FirstBayes. El programa se ejecutará realizando doble click sobre el acceso directo FirstBayes.

A.4. Iniciando FirstBayes

Una vez ha sido instalado el FirstBayes, podemos iniciar el programa de forma similar al resto de programas de Windows, realizando un doble click sobre su icono. La figura A.1 muestra la pantalla inicial del programa.

El programa FirstBayes está basado en el uso de barras de menú. En la parte superior de la pantalla se observan dos barras informativas. La primera de ellas muestra en el lado izquierdo el nombre del programa y la versión FirstBayes, v1.3. En la parte derecha se incluyen tres iconos que permiten, respectivamente,

A.4. Iniciando FirstBayes




Figura A.1: Pantalla inicial del programa

minimizar la ventana, maximizar la ventana ajustando el tamaño del menú a la pantalla, o salir del programa.

La segunda barra corresponde con la barra de menú. La ventana del programa se completa con un área gris, denominada área de trabajo, sobre la cual se dispondrán las ventanas de trabajo. A continuación se describe de forma breve en qué consiste cada menú.

- **File.** En este menú observamos dos opciones. La primera Data se refiere al tratamiento de los datos. En una sección analizamos de forma detallada el tratamiento de los datos en el FirstBayes. La segunda opción Exit permite salir del programa.

Una tercera opción está disponible sólo en algunos casos. La opción Print active plot se activa únicamente cuando generamos un gráfico. Esta opción permite imprimir la gráfica.

- **Distributions.** Seleccionando este menú tenemos acceso a trece familias de distribuciones de probabilidad.
- **Analysis.** A partir de este menú tenemos acceso a los seis tipos de análisis que realiza FirstBayes.

- **Options.** Este menú permite activar la opción APL Data entry. Dicha activación facilita la entrada y edición de datos en la opción Data del menú File, usando el lenguaje APL. Se recomienda activar esta opción al comenzar el FirstBayes.
- **Windows.** Este menú permite modificar el ordenamiento de las diferentes ventanas de trabajo. Si elegimos la opción Cascade, las ventanas adoptarán una posición de cascada, superponiéndose parcialmente una sobre la otra. La opción Tile Horizontally divide el espacio de trabajo entre las diferentes ventanas de trabajo de forma horizontal. De forma similar Tile Vertically divide el espacio de forma vertical. La opción arrange actúa sobre el icono de las ventanas que han sido minimizadas, ordenándolas en la parte baja de la ventana FirstBayes.

La parte inferior del menú Windows permite desplazarnos de una ventana de trabajo a otra.

- **Help.** A partir de este menú únicamente podemos obtener información sobre la versión del programa que estamos utilizando.

A.5. Tratamiento de los datos

FirstBayes permite cargar, manipular y crear nuevos datos. A la ventana de datos se accede a través del menú File de la barra de herramientas. Los datos son cargados por defecto de la carpeta C:\1b\). Podemos modificar dicho directorio sin más que seleccionar la opción Change. La figura A.2 muestra el menú correspondiente al tratamiento de datos.

A.6. Cargar datos

El programa FirstBayes incluye un listado de bases de datos que pueden ser utilizadas como ejemplos ilustrativos de los diferentes modelos propuestos. Para cargar una de las bases de datos debemos seguir el siguiente procedimiento:

1. En primer lugar debemos marcar la base de datos que queremos cargar, por ejemplo "CANCER". Al marcar dicha base de datos se activa la pantalla central de datos. En ella se muestra la siguiente información: el nombre, una breve descripción de los datos y los propios datos.
2. Para poder utilizar los datos en los modelos posteriores debemos cargar dichos datos en memoria. Para ello debemos seleccionar la opción Load. En la parte izquierda de la ventana se muestra el listado de los datos cargados en memoria.

A.7. Crear una nueva base de datos




Figura A.2: Ventana de tratamiento de datos




Figura A.3: Cargar datos

A.7. Crear una nueva base de datos

El programa permite también la incorporación de nuevos datos. Para ello debemos seguir los siguientes pasos:

1. Para crear nuevos datos debemos señalar el icono New situado en la esquina inferior derecha de la ventana de datos.
2. De esta forma se activa la ventana central. Esto nos permitirá escribir el nombre de la base de datos, una breve descripción y los datos. Los datos deben estar separados por un espacio. Al finalizar debemos presionar OK.
3. Los datos se guardan momentáneamente en memoria. Para poder utilizar los datos debemos confirmar su grabación a través del icono Save. Los datos quedaran guardados para poder ser utilizados posteriormente.

A.8. APL data entry

Normalmente, cuando tratamos de guardar en memoria nuevos datos el programa comprueba que los datos editados contienen únicamente una secuencia de números separados por un espacio. Si se detecta algún símbolo extraño se mostrará un mensaje de error.

Sin embargo, si la opción APL data entry es activada en el menú de opciones esta comprobación no se realiza. De esta forma, aquellos usuarios familiarizados con el lenguaje APL podrán describir los datos a través de operaciones complejas permitidas por dicho lenguaje, así como la generación de números aleatorios. Debido al carácter introductorio de este manual omitimos la descripción de dichas operaciones. El manual de instrucciones para el uso del FirstBayes (O'Hagan, 1996) muestra algunas de estas operaciones.

A.9. Distribuciones

Al abrir la ventana correspondiente a una de las trece distribuciones que incluye FirstBayes, obtenemos un menú con dos partes diferenciadas.

La parte de la derecha permite definir los parámetros de la distribución que estamos analizando. La región de la izquierda muestra diferentes momentos y características de la distribución. Las medidas de análisis que nos ofrece el programa son la media, mediana, moda, desviación típica, varianza y cuartiles. Además podemos examinar diferentes características de la distribución:

- Probabilities. De esta forma podemos obtener la probabilidad de un intervalo cualquiera sin más que escribir dos números separados por un espacio, extremo inferior y superior, en el recuadro de la izquierda. Al seleccionar la opción Calc obtendremos el resultado.
- Highest density intervals. Proporciona el intervalo de probabilidad de menor amplitud para una probabilidad dada. También requiere seleccionar la opción Calc para su cálculo.

A.10. Algunas distribuciones

- %-ile. Muestra el inverso de la función de distribución para un valor dado q , o lo que es lo mismo, el percentil q -ésimo.
- Plot. Por último, también podemos obtener la representación gráfica de la función de densidad, o cuantía en su caso.

A.10. Algunas distribuciones

En esta sección repasamos algunas de las distribuciones de probabilidad más utilizadas en el análisis bayesiano.

A.10.1. Distribución beta

La distribución beta depende de dos parámetros, denominados por el FirstBayes como p y q , que se corresponden con los parámetros α y β usuales. Supongamos la distribución beta de parámetros (5,2). La expresión de la media y la moda de la distribución beta son: $E(X) = 0,7143$ y $\text{Moda}(X) = 0,8$. Realicemos ahora el análisis utilizando el programa FirstBayes. Para ello seleccionamos la distribución beta del menú de distribuciones. A continuación damos valores a los parámetros, siendo $p = 5$ y $q = 2$. Confirmando los valores con la tecla ENTER obtenemos los descriptivos de dicha función. Además se proporcionan los valores de la mediana, desviación típica, varianza y cuartiles.

Supongamos que estamos interesados en conocer la probabilidad de que variable X tome valores entre 0,5 y 0,7. Para ello introducimos dichos valores en la sección "Prob". Además queremos saber el intervalo de máxima densidad del 90 % y el valor que deja a su izquierda una probabilidad igual al 0,5 %. Este análisis se puede realizar a partir del menú denominado More summaries.

La figura A.4 muestra los resultados del análisis y la representación gráfica de la distribución beta señalada.

A.10.2. Distribución binomial

Una variable sigue una distribución binomial si puede ser expresada como el número de éxitos en n ensayos. Los dos parámetros que definen la distribución binomial son el número de ensayos (number of trials) y la probabilidad de éxito en cada ensayo (probability). La figura A.5 muestra un ejemplo de esta distribución.

A.10.3. Distribución gamma

Los parámetros que definen la distribución gamma son los parámetros de forma y escala. Habitualmente en la distribución gamma definida como $G(\alpha, 1/\beta)$, el primer parámetro α se refiere al parámetro de forma, y el segundo parámetro β se refiere al de escala. Es importante señalar que el programa FirstBayes intercambia el




Figura A.4: Distribución beta

orden de los parámetros, siendo el primer parámetro el inverso del parámetro de escala y el segundo el de forma.

Supongamos el ejemplo de la distribución gamma de parámetros $(4, 1/2)$. En FirstBayes debemos señalar como parámetro de escala (scale) el valor 2 y parámetro de forma (shape) el valor 4. La figura A.6 muestra algunas características de dicha distribución.

A.10.4. Distribución normal

La distribución normal queda definida a partir de la media (mean) y la varianza (variance). La figura A.7 muestra un ejemplo de esta distribución.

A.10.5. Distribución Poisson

Depende de un único parámetro λ que coincide con la media y la varianza de la distribución.




Figura A.5: Distribución binomial

A.11. Mezclas

En la parte derecha de cada uno de los menús de distribuciones observamos una casilla denominada peso (Weight). Si no señalamos ningún valor en dicha casilla tomará el valor 1 por defecto. El FirstBayes permite el análisis de mezclas o mixturas de distribuciones para la misma familia. Por ejemplo, podemos considerar que una determinada variable sigue una distribución normal de parámetros $(5, 3)$ con un peso de 0,6 y una distribución normal $(10, 2)$ con un peso de 0,4.

Para analizar esta distribución en el FirstBayes debemos introducir la información de la primera distribución (media=5, varianza=3), y asignarle un peso de 0,6. De esta forma se activa la opción Parameter set no, en la parte superior de la ventana de la derecha, que nos permite ir de una distribución a otra. Marcando la flecha hacia arriba podremos introducir los parámetros y el peso de la segunda distribución. De esta forma podremos analizar mixturas para cada una de las distribuciones anteriores. La figura A.9 muestra el ejemplo para el caso normal.




Figura A.6: Distribución gamma

A.12. Los seis análisis

Al seleccionar alguna de las seis opciones Binomial sample, Gamma sample, Normal sample, known variance, Poisson sample, Normal sample(s), unknown variance, ó Regression data del menú Analyses, abrimos la ventana de análisis. Cada análisis permite que la distribución a priori conjugada sea combinada con los datos para obtener la distribución a posteriori.

- Binomial sample. En este caso los datos son pruebas independientes con probabilidad de éxito ϕ para cada una de ellas. Los datos serán por tanto una serie de unos (indican éxito) y ceros (fracasos). La distribución del número de éxitos es binomial. La familia a priori conjugada para esta verosimilitud es la distribución beta.
- Gamma sample. En este caso los datos se obtienen a partir de una distribución gamma, con parámetro de forma k conocido, y media k/θ . Los datos deben ser positivos. La familia a priori conjugada para θ es la distribución gamma.
- Poisson sample. Los datos se distribuyen según una distribución Poisson con media λ . Los datos deben ser valores enteros positivos. La familia a priori conjugada es la distribución gamma.

A.13. Análisis beta-binomial




Figura A.7: Distribución normal

- Normal sample, known variance. Los datos son observaciones independientes e idénticamente distribuidas de una distribución normal con media μ y varianza conocida σ^2 . La familia a priori conjugada para la media μ es la distribución normal.
- Normal sample(s), unknown variance. En este caso los datos son observaciones independientes e idénticamente distribuidas de una distribución normal con media μ y varianza σ^2 desconocida. En este análisis se supone una distribución a priori no informativa.
- Regression data. El programa FirstBayes permite también realizar un análisis de regresión lineal con una variable explicativa. Al igual que en el modelo anterior suponemos carencia de información a priori.

A continuación analizamos de forma más detallada los modelos.

A.13. Análisis beta-binomial

Con objeto de facilitar el estudio del modelo beta-binomial presentamos un ejemplo práctico. Supongamos que durante el proceso de auditoría a una empresa se estudia




Figura A.8: Distribución Poisson

la existencia o no de errores en la contabilidad de las facturas. Se revisan 10 facturas observándose que 1 de ellas no ha sido correctamente contabilizada.

El primer paso para resolver este problema es introducir los datos en el programa.

A.13.1. Datos

La introducción de datos ha sido comentada en la sección anterior. Debemos seguir los siguientes pasos:

1. Desplegar el menú File y seleccionar la opción Data.
2. Los datos que utilizaremos no están en la base de datos que nos ofrece el programa por defecto. Debemos crear nuevos datos. Para ello seleccionamos la opción New.
3. Una vez marcada dicha opción pasamos a introducir el nombre y una breve descripción de la base de datos. Este último apartado no es imprescindible pero facilita el manejo de los datos en futuras ocasiones.
4. Para el caso binomial los datos únicamente pueden tomar dos valores, 0 ó 1 en caso de fracaso o éxito, respectivamente. En nuestro ejemplo se revisan 10

A.13. Análisis beta-binomial




Figura A.9: Mezcla de distribuciones normales

facturas donde 1 de ellos presenta error. Debemos recordar que los términos éxito y fracaso hacen siempre referencia a la variable que estamos estudiando. En nuestro ejemplo queremos estimar la probabilidad de que exista error en una factura, por lo que éxito se corresponde con encontrar error y fracaso con el caso contrario. Por lo tanto, nos encontramos ante 9 casos de fracaso, y 1 éxito. Debemos incorporar los datos en el apartado Data separados por un espacio.

5. Para que los datos puedan ser utilizados en la sección de análisis de datos, tenemos que confirmarlos y guardarlos seleccionando los botones OK y Save. Los datos han sido guardados.

A.13.2. Incorporación de información a priori

En la zona superior derecha del menú del análisis beta-binomial se encuentra la ventana correspondiente a la distribución a priori. Para incorporar dicha información se debe seleccionar la opción Edit. Se abrirá una nueva ventana denominada Beta Prior Distribution. En ella podremos añadir los parámetros de la distribución a priori.




Figura A.10: Análisis beta-binomial




Figura A.11: Datos binomiales

Siguiendo con el ejemplo, supongamos que un experto nos comunica que esta empresa ha sido auditada durante los últimos 10 años, siendo la situación más frecuente que no se encontrasen errores. La media de errores de los años anteriores ha sido de un 1%.

A partir de la media y la moda podemos obtener los parámetros de la distri-

A.13. Análisis beta-binomial

bución a priori. La información a priori ofrecida por el experto se corresponde con una distribución $Be(1, 99)$. Debemos notar que el cálculo de los parámetros de la distribución a priori deberá realizar al margen del FirstBayes. En este programa únicamente debemos incorporar los parámetros ya calculados.

Una vez introducimos los parámetros a priori podemos obtener información sobre la distribución. Podemos finalizar la incorporación de información a priori pulsando Quit.




Figura A.12: Distribución a priori. Análisis beta-binomial

A.13.3. Distribución a posteriori

Llegados a este punto hemos definido la distribución a priori y hemos grabado los datos. Únicamente resta combinar ambos para obtener la distribución a posteriori. Para ello debemos señalar en la pestaña correspondiente a los datos (Data) la base de datos que hemos denominado binomial_ejemplo.

Inmediatamente el programa obtiene la distribución a posteriori. En este caso la distribución $Be(2, 108)$. El programa ofrece información sobre la media, mediana, moda, varianza, desviación típica cuartiles, probabilidad, intervalos de densidad máxima y percentiles. Además, el programa permite tres análisis no vistos hasta ahora:

- **Triplot.** La opción triplot permite representar gráficamente las tres distribuciones de interés, es decir, distribución a priori, verosimilitud y distribución a posteriori. Así podemos analizar el efecto de los datos y de la información a priori sobre las conclusiones finales. En nuestro ejemplo el triplot puede verse en la figura A.13




Figura A.13: Triplot. Análisis beta-binomial

- **Predictive analysis.** El análisis a través de la distribución predictiva muestra el número de éxitos predichos para un número determinado de futuras observaciones. La distribución predictiva en este análisis es beta-binomial. En nuestro ejemplo supongamos que deseamos predecir el número de errores en las próximas 5 facturas. Señalamos 5 en el número de observaciones y seleccionamos la opción Show Predictive. La ventana se modifica mostrando la distribución predictiva. En este caso no se esperan encontrar facturas erróneas ya que la media y la moda son iguales a 0. Para volver a analizar la distribución a posteriori debemos elegir la opción Show Posterior.

- **Update.** En programa también permite realizar análisis secuencial, donde la distribución a posteriori del primer análisis sea la distribución a priori del segundo. La opción update facilita este proceso ya que si la seleccionamos, automáticamente la distribución a posteriori pasará a ser considerada distribución a priori.

A.14. Análisis gamma-Poisson

523

Figura A.14: Distribución predictiva. Análisis beta-binomial

A.14. Análisis gamma-Poisson

Acompañaremos la descripción de este análisis con un caso práctico que hemos utilizado a lo largo del libro. Una compañía de seguros de automóvil supone que el número de reclamaciones en un año sigue una distribución de Poisson de parámetro λ y que este número es independiente de un año a otro. Un cliente potencial pretende establecer un seguro con esta compañía. Se conoce que el número de reclamaciones de los últimos dos años de dicho cliente son 0 y 1, respectivamente. La compañía se asegura fijará la prima a cobrar en función del número medio de reclamaciones. Supongamos que estamos interesados en conocer la prima que deberá cargarse.

A.14.1. Datos

Los pasos serán los siguientes:

1. Abrir la ventana de datos: File - Data.
2. Crear nuevos datos a través de la opción New.




Figura A.15: Análisis gamma-Poisson

3. Introducir el nombre y una breve descripción de la base de datos.
4. Los datos de este ejemplo son {0, 1}. Debemos introducirlos en el apartado Data separados por un espacio. Los datos para el caso Poisson deben ser siempre enteros y positivos.
5. Confirmar y grabar los datos con OK y Save.




Figura A.16: Datos Poisson

A.14.2. Incorporación de información a priori

Para incorporar información a priori debemos seleccionar la opción Edit. Se abrirá una nueva ventana. En ella podremos añadir los parámetros de la distribución a priori.

Siguiendo el ejemplo anterior, supongamos que se trata de un cliente joven que posee un vehículo antiguo. El experto conoce que el número medio de reclamaciones para este tipo de clientes es de 4 reclamaciones al año, con una varianza de 2 unidades. La distribución a priori conjugada gamma que se ajusta a esta información es $G(8, 1/2)$. Debemos recordar que FirstBayes modifica el orden de los parámetros de la distribución gamma e invierte el de escala. Es decir, la distribución gamma con parámetro de forma 8 y parámetro de escala $1/2$ se corresponde con la distribución $G(2, 8)$ del programa. Podemos finalizar la incorporación de información a priori pulsando Quit.




Figura A.17: Distribución a priori. Análisis gamma-Poisson

Observación: El programa FirstBayes no permite dar una valor igual a 0 a ninguno de los parámetros de la distribución a priori. Así por ejemplo, si quisiésemos asumir la distribución a priori no informativa $G(0, 0)$, debemos incorporar en el programa una aproximación, por ejemplo $G(0,0001, 1/0,0001)$.

A.14.3. Distribución a posteriori

Incorporamos los datos al análisis señalando en la pestaña correspondiente a los datos (Data) la base de datos que hemos denominado poisson_ejemplo.

La distribución a posteriori obtiene es la distribución $G(9, 1/4)$ de media $9/4 = 2,25$ y moda $(9 - 1)/4 = 2$. Podemos obtener información de diferentes momentos

a posteriori del parámetro de interés. Completaremos el análisis con las siguientes opciones:

- **Triplot.** Representa gráficamente las tres distribuciones de interés, es decir, distribución a priori, verosimilitud y distribución a posteriori.




Figura A.18: Triplot. Análisis gamma-Poisson

- **Predictive analysis.** El análisis a través de la distribución predictiva muestra el número de eventos predichos en las futuras observaciones. La distribución predictiva en este análisis es la distribución binomial-negativa. Si queremos predecir el número de reclamaciones del próximo año, 1 observación, seleccionamos la opción **Show Predictive**. La media de la distribución predictiva es de 2,25 reclamaciones.
- **Update.** Al igual que para el caso beta-binomial, podemos realizar análisis secuencial sin más que suponer que la distribución a posteriori del primer análisis es la distribución a priori del segundo. La opción **update** realiza esta acción.

A.15. Análisis normal con varianza conocida

FirstBayes incorpora dentro de los posibles análisis el de la distribución normal con varianza conocida. Consideremos el siguiente ejemplo. Estamos interesados en estudiar el logaritmo de las cuantías abonadas por una compañía aseguradora en una determinada región. El investigador supone que el gasto se distribuye de forma normal, con media θ y varianza conocida e igual a 200 euros. Una vez entrevistadas 5 personas se obtienen los siguientes resultados: 450, 500, 650, 600 y 550.

A.15. Análisis normal con varianza conocida




Figura A.19: Distribución predictiva. Análisis gamma-Poisson




Figura A.20: Análisis normal, con varianza conocida

A.15.1. Datos

Los pasos serán los siguientes:

1. Abrir la ventana de datos: **File - Data**.
2. Crear nuevos datos a través de la opción **New**.
3. Introducir el nombre y una breve descripción de la base de datos.

- Los datos de este ejemplo son {450, 500, 650, 600, 550}. Debemos introducirlos en el apartado Data separados por un espacio.
- Confirmar y grabar los datos con OK y Save.




Figura A.21: Datos normales

A.15.2. Incorporación de información a priori

Al tratarse del análisis para datos normales con varianza conocida debemos incorporar información a priori únicamente para la media. Para ello debemos seleccionar la opción Edit. La distribución a priori conjugada para la media es la distribución normal, que quedará definida a través de la media y la varianza.

Supongamos que de años anteriores se conoce que la esperanza de la cuantía media es de 500 euros, con una varianza de 50 euros. Estos parámetros definirán la distribución a priori. Finalizamos la incorporación de información a priori pulsando Quit.

A.15. Anal3isis normal con varianza conocida




Figura A.22: Distribución a priori. Análisis normal-normal

A.15.3. Distribución a posteriori

Incorporamos los datos en el análisis señalando en la pestaña correspondiente a los datos (Data) la base de datos normal_ejemplo. El análisis quedará completo si señalamos la varianza conocida, en este caso 200. Asignamos dicho valor en la ventana situada en la parte superior derecha de la pantalla.

La distribución a posteriori obtenida es la distribución $N(527,78; 22,22)$. El programa ofrece una amplia gama de características a posteriori del parámetro de interés. Finalmente comentamos los tres análisis para el caso normal-normal.

- Triplot. Representa gráficamente la distribución a priori, la verosimilitud y la distribución a posteriori.
- Predictive analysis. El análisis a través de la distribución predictiva muestra la media de la variable de interés en futuras observaciones. La distribución predictiva en este análisis es normal. Si queremos predecir el gasto medio de los próximos 2 años, señalando 2 en el número de observaciones y seleccionamos la opción Show Predictive.
- Update. Si seleccionamos esta opción la distribución a posteriori será considerada distribución a priori para el siguiente análisis.




Figura A.23: Triplot. Análisis normal-normal




Figura A.24: Distribución predictiva. Análisis normal-normal

Apéndice B

Breve manual de WinBUGS

B.1. Presentación

El programa WinBUGS (la versión para el sistema operativo Windows del programa BUGS: Análisis Bayesiano usando Gibbs Sampling) es un paquete estadístico versátil diseñado para llevar a cabo análisis MCMC para una amplia variedad de modelos. Este software está distribuido electrónicamente a través de la página web del proyecto BUGS en la dirección

<http://www.mrc-bsu.cam.ac.uk/>

El software que podemos descargar de esta página está restringido a un número cada vez mayor de modelos, pero puede ser convertido a su versión completa adquiriendo una licencia, actualmente sin coste alguno, a través de la página web del proyecto. Otras versiones de BUGS para sistemas operativos distintos pueden encontrarse en la página del proyecto BUGS.

Al instalar WinBUGS también podemos tener acceso a un amplio manual de usuario (Spielgelhalter et al., 2002) y a ejemplos desarrollados. El manual y los ejemplos se encuentran en la opción Help del menú principal de la pantalla WinBUGS (figura B.1). El manual de usuario es una referencia muy práctica y detallada para el correcto aprendizaje del WinBUGS. Sin embargo, la forma más sencilla de familiarizarnos con la programación en WinBUGS y su sintaxis es a través de los ejemplos.

WinBUGS implementa varios algoritmos MCMC para generar observaciones simuladas de la distribución a posteriori de las cantidades desconocidas (parámetros o nodos) en un modelo estadístico. Este procedimiento está basado en la idea de que con un número suficientemente grande de observaciones simuladas es posible obtener la forma ajustada de la distribución.

Un análisis con WinBUGS incluye la especificación del modelo, los datos, valores iniciales y resultados. Todo ello vendrá indicado en un único documento de for-




Figura B.1: Pantalla principal de WinBUGS, mostrando el menú de ayuda desplegado

mato WinBUGS. Las herramientas de análisis están disponibles a través de menús desplegables. Los archivos de datos son incluidos a través de listas (o pueden venir expresados en otros documentos anexos). WinBUGS no puede leer datos de archivos externos o en otro formato, pero sí pueden ser insertados en el texto usando las instrucciones copiar, pegado especial/texto plano. Los resultados se muestran en ventanas independientes.

B.2. Especificando el modelo: distribución a priori y verosimilitud

Para calcular la distribución a posteriori es necesario informar al programa qué distribución a priori y qué distribución de verosimilitud utilizar. Las distribuciones y verosimilitudes disponibles en WinBUGS están recogidas en la tabla I del manual de usuario del WinBUGS, y algunas de ellas son descritas en esta sección. Destacar que todos los nombres de las distribuciones y verosimilitudes comienzan por la letra *d*, haciendo referencia a la palabra distribución.

$\text{dnorm}(\mu, \tau)$ es la distribución normal con parámetros μ y $\tau = 1/\sigma^2$, como precisión.

Es importante entender que el WinBUGS especifica la distribución en términos de la media μ y la precisión τ , en lugar de la manera más habitual de hacerlo en términos de la media μ y la desviación típica σ . La relación entre la desviación típica y la precisión es $\sigma = 1/\sqrt{\tau}$. Un caso límite de especial importancia es el

B.3. Inferencia sobre una proporción

de $\text{dnorm}(0, 0)$, que asigna la misma probabilidad para todos los números reales. Se trata por tanto de una distribución “plana”. Esta distribución es impropia en el sentido de que el área bajo la función de densidad es infinito. En la práctica, una distribución $\text{dnorm}(0, \epsilon)$ es usada para representar la ignorancia, donde ϵ es un número pequeño como por ejemplo 0,001.

$\text{dbern}(p)$ es la distribución de Bernoulli con parámetro p , probabilidad de éxito.

$\text{dbin}(p, n)$ es la distribución binomial con parámetros n y p .

$\text{dpois}(\lambda)$ es la distribución de Poisson de parámetro λ .

$\text{dbeta}(a, b)$ es la distribución beta de parámetros a y b .

Conocemos que se trata de una familia de distribuciones muy flexible. Se aplica a cantidades desconocidas que pueden tomar valores entre 0 y 1, como por ejemplo la tasa de éxito de un experimento. Un caso de especial relevancia es el de $\text{dbeta}(1, 1)$, que coincide con la distribución uniforme en el intervalo (0,1). Sin embargo, la distribución $\text{dbeta}(0, 0)$ se utiliza a menudo para representar desconocimiento total acerca del parámetro p porque implica que la expresión $\ln(p/(1-p))$, conocida como *log odds*, tiene una distribución uniforme sobre los números reales. $\text{dbeta}(0, 0)$ es una distribución a priori impropia con área bajo la curva infinita, y en la práctica $\text{dbeta}(\epsilon, \epsilon)$ es utilizada para reflejar ignorancia a priori, con ϵ tomando valores pequeños como 0,001.

$\text{dgamma}(a, s)$ es la distribución gamma.

Del mismo modo, se trata de una familia de distribuciones muy flexible. Se aplica a cantidades desconocidas que toman valores entre 0 e ∞ , como por ejemplo la precisión τ de una cantidad desconocida. Completa ignorancia acerca del valor del parámetro positivo desconocido suele representarse como una distribución $\text{dgamma}(0, 0)$. Debido a que esta distribución es impropia, en la práctica se utiliza $\text{dgamma}(\epsilon, \epsilon)$, con $\epsilon \rightarrow 0$.

B.3. Inferencia sobre una proporción

Daremos los primeros pasos en WinBUGS introduciendo los elementos esenciales mediante un ejemplo. Supongamos que se lanza una moneda 25 veces y se observan 11 caras. El objetivo es obtener la distribución a posteriori de p , la probabilidad de que al lanzar una moneda salga cara. Al tratarse de un parámetro que puede tomar valores entre 0 y 1 lo más conveniente es representar su comportamiento a través de una distribución beta. Por ejemplo, consideramos el caso en el que no

tenemos información a priori y utilizar una distribución no informativa:

$$p \sim \text{dbeta}(1, 1)$$

De esta forma, las creencias a priori del parámetro p quedan recogidas en la distribución $\text{Be}(1, 1)$.

El segundo paso que el WinBUGS necesita es indicar qué distribución siguen los datos x . El número de caras puede ser modelizado como el número de éxitos en n ensayos de una distribución Bernoulli. De esta forma x vendrá especificado como:

$$x \sim \text{dbin}(p, n)$$

La figura B.2 muestra el programa WinBUGS que recogería este ejercicio. La instrucción Model sirve de introducción al modelo. WinBUGS analiza todos los comandos incluidos entre las llaves de apertura y de clausura del modelo $\{\}$ que deben incluir la distribución a priori del parámetro p y la verosimilitud de los datos x . Los datos observados son introducidos por medio de listas separadas por comas. La instrucción list y los paréntesis son necesarios. La lista de datos incluye los inputs del análisis: las creencias a priori ($a = b = 1$) y los datos observados ($x = 11$ caras en $n = 25$ lanzamientos).




Figura B.2: Programa WinBUGS para calcular la distribución a posteriori de la tasa de éxito en los lanzamientos de una moneda

B.4. Ejecutando el modelo

Iniciar WinBUGS. El archivo ejecutable, que viene representada por una forma de telaraña, está en el mismo directorio en el que se ha instalado WinBUGS. Es conveniente incluir un acceso directo del WinBUGS en el escritorio. Lee y después cierra la ventana del acuerdo de licencia, y abre una nueva ventana de documento (Menú:

B.4. Ejecutando el modelo

file/new)

Especificar el modelo. Escribir los contenidos de la figura B.2 en la ventana del documento recientemente abierto. Para grabar el programa, seleccionar la ventana que contiene el programa, desplegar el menú File, seleccionar Save as, y entrar el nombre del archivo (WinBUGS añadirá la extensión .odc), seleccionar la carpeta apropiada, y grabar el archivo.

Comprobar la sintaxis. Desplegar el menú Model, y seleccionar Specification. La ventana specification tool se abrirá (figura B.3). Realizar un click en cualquier parte del modelo (entre las llaves), y entonces realizar un click en el botón check model. Revisar el mensaje que aparece en la barra inferior de la ventana del WinBUGS. Debe aparecer la frase, model is syntactically correct. En caso de que el modelo no esté bien definido aparecerán diferentes mensajes de error. Por ejemplo, en la figura B.4, al realizar el código se escribió $p = \text{dbeta}(1, 1)$ en vez de $p \sim \text{dbeta}(1, 1)$. Observar como en ese caso el cursor se sitúa tras el símbolo que ha causado el error. La barra del cursor es difícil de ver en muchos casos. Esta barra puede hacerse más visible modificando la función Thick Caret en el menú Edit/Preferences/dialog box. Corregir el error y repetir el check model. Una vez que el modelo no tenga errores podemos continuar con el siguiente paso.




Figura B.3: Specification tool. Situar el cursor en la ventana de programa, y entonces pulsar check model en la ventana Specification tool

Introducir datos. Escrito los datos en forma de lista, debemos marcar sobre cualquier parte de la instrucción `list` y realizar un click sobre la opción `load data` de la ventana `Specification tool`. Si marcamos en otro lugar, aparecerá un mensaje de error. Los datos pueden venir definidos en diferentes listas. En ese caso debemos repetir el proceso tantas veces como sea necesario, realizando un click sobre `load data` para cada lista.




Figura B.4: Un error de sintaxis. Se ha escrito `p =` en el programa en lugar de `p ~`. WinBUGS marcará la posición del error mediante el cursor y describirá el error en la línea inferior de la ventana.

Compilar el modelo. Una vez el modelo haya sido comprobado y los datos cargados podemos compilar el modelo. Para ello realizamos un click sobre la opción `compile`. Si el modelo se compila correctamente aparecerá el mensaje `model compiled` en la barra de mensajes de la ventana de WinBUGS. En caso contrario aparecerá un mensaje de error. La figura B.5 muestra un error de compilación causado por la omisión del valor del parámetro `b` en la lista de datos. Otro error común de compilación es debido a la transcripción de las variables. WinBUGS es sensible al uso de mayúsculas y minúsculas, es decir, para WinBUGS el parámetro `B` es diferente al parámetro `b`. La escritura inconsistente de un mismo parámetro es uno de los errores más habituales de compilación.

Observemos que WinBUGS utiliza la palabra `node` en el mensaje de error de la figura B.5. Un *nodo* es cualquier variable o constante mencionada en el modelo. En nuestro ejemplo los nodos son `a`, `b`, `n`, `p` y `x`. El nodo `p` es una cantidad desconocida, el resto de nodos son cantidades conocidas introducidas en el modelo a través de




Figura B.5: Un error de compilación. Se ha omitido el valor de `b`

los datos.

Generar valores iniciales. Marcamos la opción `gen inits` en la ventana `Specification tool`. En algunas ocasiones WinBUGS puede dar un mensaje de error indicando que no es posible generar dichos valores. Esto suele ocurrir cuando existan nodos con valores acotados, como por ejemplo la precisión o varianza, que solo está definida para valores positivos, o la proporción de éxito, que toma valores entre 0 y 1. En ese caso debemos proporcionar nosotros los valores iniciales. Para ello debemos incluir una nueva lista (`list`) con los valores iniciales de los nodos desconocidos. Si la simulación MCMC converge, los resultados no deben venir afectados por los valores iniciales que utilizemos. Una vez los datos iniciales hayan sido generados o cargados aparecerá el mensaje `initial values generated, model initialized` o `model initialized`, respectivamente.

B.5. Obteniendo la distribución a posteriori

Generando la muestra burn-in. Con el modelo inicializado, podremos comenzar a simular valores a través de las técnicas MCMC. Es habitual realizar una primera muestra que no será utilizada para estimar la distribución a posteriori. De esta forma tratamos de minimizar el efecto de los valores iniciales en el resultado final del estudio. Esta muestra es denominada muestra "burn in". Para obtenerla debemos desplegar la herramienta `Update`, dentro del menú `Model`. La figura B.6 muestra la ventana `update`. En la casilla `updates` escribimos el número deseado

de simulaciones (por ejemplo, 10.000). Hacer click sobre la opción update para comenzar las simulaciones. Las simulaciones pueden ser paradas y reiniciadas pulsando el botón update. El número de simulaciones recomendadas para la muestra burn-in dependerá de la dificultad que presente el modelo. En modelos sencillos 10000 simulaciones son suficientes.




Figura B.6: Ventana Update Tool. Escribir el número deseado de simulaciones en el espacio updates

Seleccionar los nodos que van a ser grabados. Una vez hemos simulado la muestra burn-in comenzaremos a grabar los resultados. Para ello debemos indicar qué nodos queremos grabar. Por supuesto, únicamente señalaremos los nodos desconocidos y que tratamos de estimar. En nuestro ejemplo, el nodo de interés es la proporción de éxitos p . Para realizar esta fase debemos desplegar el menú Inference y seleccionar la opción Samples. La ventana Sample Monitor Tool (figura B.6) servirá para introducir los nodos de interés. Escribiremos p en la opción "node" y pulsaremos la opción Set. De esta forma el WinBUGS guardará las simulaciones de la variable p , así como calculará algunos estadísticos de dicha variable, como por ejemplo media, moda, mediana y percentiles. En modelos más complejos debemos repetir este proceso para cada uno de los nodos de interés. Si al escribir algún nodo el botón set no se oscurece es porque dicha variable no se encuentra en el modelo. Debemos comprobar que se ha escrito el nombre del parámetro correctamente.

Generar valores simulados de la cantidades desconocidas. Desplegar el menú Model y seleccionar nuevamente la opción Update. Volvemos a escribir en la opción Updates el número de simulaciones que queremos hacer. En este caso los valores de los nodos incluidos en el Sample se guardarán. La opción refresh mide cada cuántas simulaciones se actualizan los cálculos. Normalmente no modificamos la cantidad por defecto de 100.

Ocasionalmente, un mensaje de error Trap aparecerá como en la figura B.8. Si esto ocurre, debemos volver a pulsar la opción Update dos veces para reiniciar la simulación. Si el error continúa apareciendo deberemos modificar el modelo. Normalmente el problema se resuelve usando distribuciones a priori más informativas.

B.5. Obteniendo la distribución a posteriori




Figura B.7: Ventana Sample Monitor Tool. Escribir el nombre de cada nodo en la sección node y guardarlo pulsando la opción set




Figura B.8: Error durante el proceso de simulación. Este error puede ser transitorio o puede requerir de la variación del modelo

Examinar la distribución a posteriori. Regresar a la ventana Sample Monitor Tool. En la casilla node escribimos el nombre de la variable que queremos examinar. Observamos como al hacerlo se activan el resto de opciones del menú. A continuación describimos las opciones más relevantes. La opción density muestra la gráfica de la densidad (realmente del kernel) a posteriori del parámetro, la opción stats muestra algunas características de la distribución a posteriori. Por

defecto el WinBUGS muestra la media a posteriori y la desviación típica, junto con la mediana y el intervalo de credibilidad al 95 %. Sin embargo, podemos modificar los percentiles que nos ofrece el programa por defecto marcando los percentiles que queremos en la opción percentiles del menú Sample Monitor Tool. Para seleccionar un percentil basta con situar el curso sobre la cantidad y pulsar el botón izquierdo del ratón. Si queremos señalar varios percentiles volvemos a pulsar sobre otro percentil manteniendo pulsada la tecla CTRL. De esta forma no se desactivará el percentil anterior. La figura B.9 muestra un ejemplo donde se añaden los percentiles 5 y 95, que componen los extremos del intervalo de credibilidad al 90 %.




Figura B.9: Ventana Sample Monitor Tool. En este caso solicitamos el cálculo de los percentiles 2,5, 5, 50, 95 y 97,5

La figura B.10 muestra un análisis completo con WinBUGS. La ventana kernel density muestra el histograma alisado de las simulaciones y es una buena aproximación de la distribución a posteriori. La ventana node statistics incluye la media y desviación típica de la distribución a posteriori para cada nodo de interés. Por defecto, en esta ventana también se incluyen la mediana y los percentiles 2,5 y 97,5. Las columnas de dicha ventana son etiquetadas de la siguiente forma:

- **node.** El nombre de la cantidad desconocida.
- **media.** La media aritmética de las simulaciones, una aproximación de la media de la distribución a posteriori de la cantidad desconocida.
- **sd.** La desviación típica de las simulaciones, una aproximación de la desviación típica de la distribución a posteriori.
- **MC error.** Cálculo de la precisión de la estimación de la media.
- **2,5 %.** El percentil 2,5 de las simulaciones, una aproximación al extremo inferior del intervalo de credibilidad al 95 % de la distribución a posteriori.
- **median.** La mediana o percentil 50 de las simulaciones.
- **97,5 %.** El percentil 97,5 de las simulaciones, una aproximación al extremo superior del intervalo de credibilidad al 95 % de la distribución a posteriori.

B.5. Obteniendo la distribución a posteriori

- **start.** La primera simulación utilizada en el análisis (después de eliminar la muestra burn-in).
- **sample.** El número de simulaciones utilizadas para aproximar la distribución a posteriori.




Figura B.10: Una sesión completa de WinBUGS. La distribución a posteriori de p , la tasa de ocurrencia de caras al lanzar la moneda, es aproximadamente normal, con media 0,444 y desviación 0,094, puede apreciarse una buena aproximación normal

El error MC es puramente técnico y puede ser reducido sin más que aumentar el tamaño del número de simulaciones. Por otro lado, la desviación típica a posteriori del parámetro, el análogo del error estándar en un análisis convencional, representa la incertidumbre acerca del parámetro y no puede reducirse sin obtener nuevos datos. Observemos también que 50000 en la columna samples en la tabla Node statistics se refiere al número de simulaciones, no al tamaño muestral, que en nuestro ejemplo es $n = 25$. Los resultados del programa WinBUGS mostrado en la figura B.10 indican que la distribución a posteriori de p , la tasa de ocurrencia de caras tiene media $\mu = 0,4441$ y desviación $\sigma = 0,0939$. Estos números han sido calculados con una precisión de $\pm 0,0004$ (MC error).

Observemos que este ejemplo dada su sencillez no es un ejemplo que se adapte estrictamente a la metodología MCMC. De hecho sabemos que el modelo utilizado es conjugado y por tanto la densidad a posteriori se obtiene como

$$\pi(p|\underline{x}) \propto L(\underline{x}|p)\pi(p) \propto p^{11}(1-p)^{14} \sim \text{Be}(12, 15).$$

B.6. Dos tasas de fallo, diferencia de tasas, riesgo relativo y odds ratio

En este apartado utilizaremos datos de un estudio que compara un tratamiento basado en radioterapia, frente a un tratamiento basado en la cirugía, para un determinado tipo de cáncer. Tras el tratamiento de radioterapia, 3 de los 18 pacientes permanecen fuera de control, mientras que del grupo de 23 pacientes que fueron intervenidos con cirugía son 2 los que permanecen fuera de control tras el tratamiento. La figura B.11 muestra el análisis. Denominamos como p_{rad} y p_{cir} a las desconocidas tasas de fallo de la radiación y cirugía, respectivamente. Por otro lado, x_{rad} , n_{rad} , x_{cir} y n_{cir} son los datos observados. Las distribuciones a priori de las cantidades desconocidas p_{rad} y p_{cir} son $\text{dbeta}(0,5, 0,5)$, lo que hace que la diferencia ($\Delta = p_{rad} - p_{cir}$) tenga una distribución muy cercana a la distribución uniforme. Para un mejor entendimiento de la figura B.11, debemos señalar que los textos que vayan precedido por el signo # son interpretados como comentarios y no son utilizados por WinBUGS en la definición del modelo.

En este ejemplo mostramos el uso del símbolo en forma de flecha ($\leftarrow$) para asignar valores de nodos lógicos. En algunos ejercicios podemos estar interesados en cantidades desconocidas que son calculadas a partir de cantidades desconocidas básicas. Este sería el caso de la diferencia en la tasa de fallo. La diferencia en la tasa de fallos entre ambas intervenciones se obtiene a partir de la diferencia de las tasas de fallo ($DIFF = p_{rad} - p_{cir}$). Además de la diferencia en la tasa de fallo en este ejemplo se calcula el riesgo relativo ($RR = p_{rad}/p_{cir}$) y la odds ratio ($OR = (p_{rad}/(1 - p_{rad})) / (p_{cir}/(1 - p_{cir}))$).

Las cantidades fundamentales en este ejemplo son las tasas de fallo de cada tratamiento. Sin embargo, para responder a la pregunta de qué tratamiento es preferido debemos comparar ambas cantidades desconocidas. En este tipo de análisis en los que se comparan dos tasas de fallo podemos utilizar tres medidas de toma de decisión distintas: la diferencia ($DIFF$), la odds ratio (OR), y el riesgo relativo (RR). El tratamiento basado en la cirugía será preferible si su tasa de fallo p_{cir} es menor que la tasa de fallo de terapia basada en la radiación p_{rad} . Si traducimos esta idea a las tres medidas de toma de decisión llegamos a la conclusión de que la cirugía es preferida si:

$$\begin{aligned} DIFF &> 0, \\ OR &> 1, \end{aligned}$$

B.6. Dos tasas de fallo, diferencia de tasas, riesgo relativo y odds ratio




Figura B.11: Comparando dos tasas

$$RR > 1.$$

Para definir estas tres medidas en WinBUGS, el lenguaje de programación no utiliza el signo ($=$). En WinBUGS, la identidad ($=$) es usada sólo en lista de datos, mientras que para definir identidades en el modelo utilizamos el símbolo ($\leftarrow$). Por ejemplo, el RR se obtiene dividiendo la tasa de fallo de radiación y tasa de fallo de la cirugía. Traducido al WinBUGS, $RR \leftarrow p_{rad}/p_{cir}$.

Recordemos que el símbolo ($\sim$) lo utilizamos para indicar que un nodo sigue una distribución particular, como por ejemplo $x \sim \text{dbin}(p, n)$. El uso inadecuado del símbolo $=$ para señalar la distribución de un nodo o para especificar una relación entre variables es una de las razones más comunes de error. El símbolo ($=$) sólo es utilizado para la lista de datos.

Al realizar este análisis también podemos estar interesados en conocer la probabilidad de elegir la cirugía a la radiación, es decir, la probabilidad de que la diferencia entre las tasas de fallo sea positiva, o que la OR sea mayor que 1, o que el RR sea mayor que 1. Para calcular estas probabilidades WinBUGS utiliza la función `step`. A continuación mostramos cómo se utiliza esta función. Si V es un nodo cualquiera, entonces `step(V)` tomará valor 1 si $V \geq 0$, y tomará valor 0 si $V < 0$. De una forma similar, `step(a - U)` toma valor 1 si $a - U \geq 0$ y 0 en caso contrario. La función `step()` puede ser utilizada para calcular probabilidades de las colas derecha o izquierda de una distribución, del siguiente modo:

$$\begin{aligned}
 \Pr(U \leq a) &: \text{nuevo.nodo1} < -\text{step}(a - U) \\
 \Pr(U < a) &: \text{nuevo.nodo2} < -1 - \text{step}(U - a) \\
 \Pr(U \geq b) &: \text{nuevo.nodo3} < -\text{step}(U - b) \\
 \Pr(U > b) &: \text{nuevo.nodo4} < -1 - \text{step}(b - U)
 \end{aligned} \quad (\text{B.1})$$

El nombre `nuevo.nodo` se refiere al nombre genérico de una nueva variable. El valor medio de estas variables indicadoras se interpretan como probabilidades. Es decir, la media del nodo `nuevo.nodo1` es la estimación Monte-Carlo de $\Pr(U \leq a)$. La tabla B.1 muestra algunas otras funciones disponibles en WinBUGS. Una lista completa de las funciones del WinBUGS se muestran en el manual de usuario de WinBUGS (Spiegelhalter et al., 2002). Comentar que, por ejemplo, el logaritmo natural $\ln$ es llamado *log* en WinBUGS, y que la función *pow* se utiliza para elevar un número a una potencia.

Tabla B.1: Algunas funciones matemáticas en WinBUGS

Nombre	Acción
$\text{step}(x)$	1 si $x \geq 0$, 0 en otro caso
$\log(x)$	$\ln(x)$
$\text{logit}(p)$	$\ln[p/(1-p)]$
$\exp(x)$	$\exp(x)$
$\text{abs}(x)$	$ x $
$\text{pow}(x, c)$	x^c
$\text{sqr}(x)$	$\sqrt{x}$

Para calcular la distribución a posteriori de *DIFF*, *RR* y *OR*, debemos seguir los pasos vistos anteriormente con el siguiente cambio: una vez vayamos a señalar qué nodos queremos que sean guardados (menú *Sample Monitor Tool*), debemos entrar cuatro nombres. Primero escribiremos *DIFF* en la casilla *node* y pulsamos *set*. Después hacemos lo mismo con *OR*, *RR*, y *POR*. A estas cuatro medidas también podemos incluir *p.rad* y *p.cir*.

Un segundo cambio aparece en el último paso, "Examinar la distribución a posteriori". Para obtener la función de densidad, la media, desviación y cuantiles debemos señalar uno de los nodos en la casilla *node*. Otra opción es escribir en *node* el símbolo * (asterisco). De esta forma obtenemos las diferentes medidas para todos los nodos analizados.

La figura B.12 muestra la ventana *Sample Monitor Tool* que dará lugar a la figura B.13. En la figura B.13 se muestran los resultados. Si tomamos como criterio




Figura B.12: Cómo solicitar las distribuciones a posteriori de todos los nodos guardados. Escribir * en la casilla *node* y después pulsar sobre la opción *stats*

node	mean	sd	MC error	2.5%	50%	median	95.0%	97.5%	start	sample
DIFF	0.1241	0.1122	0.001091	-0.0791	-0.04394	0.1303	0.3228	0.362	11001	10000
OR	4.591	3.813	0.08826	0.5265	0.7003	2.971	15.17	21.98	11001	10000
RR	0.8921	0.3103	0.002757	0.0	0.0	1.0	1.0	1.0	11001	10000
POR	3.792	5.953	0.06033	0.5921	0.7428	2.479	10.68	15.38	11001	10000
p.cir	1.112	0.9344	0.009261	-0.6227	-0.3563	1.059	2.719	3.689	11001	10000
p.rad	0.1035	0.08161	5.892E-4	0.01709	0.02332	0.0926	0.2175	0.2514	11001	10000

Figura B.13: Resultados del modelo que compara dos tasas después de 10000 simulaciones

de decisión la media concluimos que tanto por *DIFF*, *OR* ó *RR*, el tratamiento preferido es la cirugía. El intervalo de credibilidad al 95% del nodo *DIFF* es $(-0.1232; 0.2997)$. Así podríamos obtener el resto de intervalos de credibilidad. Los MC error son todos inferiores a 0,09, lo que indica que podemos estar seguros de los resultados hasta al menos el primer decimal. La probabilidad a posteriori de que la radiación tenga una tasa de fallo mayor que la cirugía es del 89,21 %.

La figura B.14 muestra las distribuciones a posteriori de todos los nodos. Como era esperado, la *OR* y el *RR* tienen distribuciones asimétricas, pero la diferencia entre tasas de éxito y el logaritmo de la *OR* parecen tener distribuciones cercanas a la normal. La distribución de *POR* es diferente ya que se trata de una variable indicadora que únicamente puede tomar dos valores 0 y 1. Los valores 1 indican simulaciones en las cuales la cirugía es mejor que la radiación. El valor 0 indica lo contrario. La media (proporción de unos) se interpreta como una probabilidad y describe el resultado por lo que el histograma y cualquier otro estadístico como desviación típica o cuantiles no aportan más información y no deben ser interpretados.




Figura B.14: Distribuciones a posteriori de todos los nodos. Los nodos que se expresan a través de una variable indicadora (1, éxito; 0, fracaso) quedan totalmente definidos por la media

B.7. Función for

El propósito de la especificación del modelo WinBUGS es introducir las distribuciones a priori de las cantidades de interés y la función de verosimilitud de los datos observados. Modelos con componentes repetidas pueden ser especificadas usando la función for. Otras estructuras comunes en programas estadísticos como if, then ó else no están disponibles en WinBUGS.

Usando la estructura for: El estudio de mortalidad en pediatría. Se poseen datos del número de pacientes y el número de fallecimientos en 12 hospitales. El programa WinBUGS que se muestra en la figura B.15 utiliza la estructura for para especificar el modelo. A continuación mostramos cómo la función for permite especificar un modelo de forma mucho más compacta:

B.8. Entrada de datos




Figura B.15: Código WinBUGS para el estudio de los hospitales

```
for (i in 1:k){
  # Distribución a priori de la tasa de fallecimientos en el hospital
  i.
  p[i] ~ dbeta(a,b)
  # Verosimilitud de los datos del hospital i
  x[i] ~ dbin(p[i], n[i])
}
```

Las variables de interés en este ejemplo son las tasas de mortalidad de cada hospital, $p[i]$, los datos observados son el número de pacientes $n[i]$ y el número de muertes $x[i]$, en cada hospital.

WinBUGS utiliza corchetes ([]) para indicar subíndices. De esta forma $p[i]$ es lo que se denomina habitualmente como p_i . Al utilizar la función for debemos indicar el subíndice que variará (en nuestro ejemplo i) y el rango de variación (1 : k). Este rango sólo puede incluir valores enteros positivos.

B.8. Entrada de datos

Los datos para una variable con subíndice pueden ser introducidos a través de una lista o de una tabla. Por ejemplo, en la figura B.15 los datos han sido introducidos a través de una lista:

```
list$(k=12, n=c(47, 148, 119, 810, 211, 196, 148, 215, 207, 97,
256, 360), x=c(0,18,8,46,8,13,9,31,14,8,29,24))$
```

Números individuales como k se introducen simplemente como $k = 12$. Los datos de las variables con subíndices como n o x se introducen como colectivos. Por

esta razón antes de introducir los datos entre paréntesis y separados por comas debemos incorporar la letra c. Los datos a través de una lista son convenientes si no son muchos datos. Si el número de datos es mayor es preferible introducirlos a través de una tabla.

B.8.1. Datos en forma de tablas

Los datos de los nodos con subíndices también pueden ser incorporados a través de una tabla. Cada nodo se corresponderá con una columna de la tabla. Para distinguir entre columnas debemos separarlas con un espacio o con un tabulado. El nombre de los nodos deberá venir acompañado por un corchete abierto y cerrado ([]). Nunca debemos escribir dentro de estos corchetes el subíndice correspondiente. Al final de las columnas debemos incluir la palabra END. Para cargar los datos debemos situar el cursor en alguna letra del nombre del primer nodo. Una vez marcada, en la ventana Specification Tool pulsamos la pestaña load data. De esta forma se cargarán todos los datos de la tabla. No es necesario repetir el proceso con cada columna, al hacerlo con la primera se cargarán los datos de todas las columnas. La figura B.16 muestra cómo introducir los datos a través de una tabla.

B.8.2. Importar datos de Excel

WinBUGS también permite importar datos de Excel. El procedimiento a seguir es el siguiente. Primero escribimos los datos en Excel (figura B.17). Marcamos las columnas de datos y utilizamos la herramienta Copiar. A continuación pasamos a trabajar con el programa WinBUGS. Es importante notar que para pegar los datos debemos utilizar la herramienta Paste Special (Pegado Especial). Dentro de los diferentes tipos de pegado propuesto seleccionamos la opción Plain Text (figura B.18). Los datos serán incorporados en la ventana de trabajo WinBUGS. Posteriormente añadimos la instrucción END al final de las columnas.

B.9. Datos normales y validez del modelo

En esta sección profundizaremos en los conceptos explicados hasta ahora en relación al uso del WinBUGS avanzando aún más en las múltiples opciones que nos ofrece el programa. Para ello utilizaremos datos de un análisis coste-efectividad que analiza el coste y la efectividad de un tratamiento antirretroviral para pacientes afectados por el virus VIH.

Tenemos dos variables de interés. Por un lado el coste del tratamiento (c), medido en euros, y por otro la efectividad del tratamiento (e), medida a través de un índice de mejora de la calidad de vida. En este ejemplo suponemos que ambas

B.9. Datos normales y validez del modelo




Figura B.16: Programa WinBUGS para el estudio de los hospitales con los datos en forma de columna

variables se distribuyen de forma normal. Así, las cantidades o nodos de interés serán el coste y la efectividad media ($\mu.c$ y $\mu.e$), así como la precisión del coste y de la efectividad ($\text{prec}.c$ y $\text{prec}.e$).

La distribución a priori asignada para los nodos que hacen referencia a la media será la distribución normal. Sin embargo, la precisión solo puede tomar valores positivos por lo que debemos utilizar una distribución a priori acotada a valores positivos. En este caso utilizaremos la distribución gamma.

Además del coste y la efectividad media, en los análisis coste efectividad es habitual calcular el cociente $\mu.c/\mu.e$, es decir, la ratio coste-efectividad (RCE). Este valor se interpreta como el coste del tratamiento por unidad de efectividad. RCE es un nodo desconocido que se obtiene como combinación de nodos desconocidos básicos. Debemos por tanto especificar que se trata de un nodo lógico ($<-$).

La distribución normal en WinBUGS se define a partir de la media y la precisión. Sin embargo, a la hora de interpretar los resultados podemos estar interesados en conocer la media a posteriori de la varianza, o incluso de la desviación típica. Para lograr esta información incluiremos en el modelo los nodos desconocidos varianza de la efectividad y el coste ($\text{var}.e$ y $\text{var}.c$) y las desviaciones típicas de la efectividad y el coste ($\text{des}.e$ y $\text{des}.c$).

	A	B	C	D	E
1	1	12.71	937.05	0.0091	0.001
2	2	11.97	932.34	0.0091	0.001
3	3	10.76	938.51	0.0091	0.001
4	4	11.21	935.99	0.0091	0.001
5	5	8.33	943.92	0.0091	0.001
6	6	10.59	938.51	0.0091	0.001
7	7	11.31	915.31	0.0091	0.001
8	8	11.59	967.05	0.0091	0.001
9	9	11.94	938.51	0.0091	0.001
10	10	13.13	938.51	0.0091	0.001
11	11	8.99	938.51	0.0091	0.001
12	12	10.23	938.51	0.0091	0.001
13	13	13.93	938.51	0.0091	0.001
14	14	11.87	938.51	0.0091	0.001
15	15	8.18	938.51	0.0091	0.001

Figura B.17: Datos del estudio de los hospitales en formato Excel




Figura B.18: Ventana de pegado especial. Para importar datos de Excel debemos pegarlos en WinBUGS en formato plain text

Se conocen datos de 15 pacientes. Estos datos están en formato Excel por lo que para trabajar en WinBUGS debemos utilizar la instrucción copiar/pegado especial-Plain Text. Señalemos que en función de cómo tengamos definido Excel, la separación de decimales vendrá dada por comas o puntos. Para que WinBUGS reconozca la separación decimal debemos utilizar la separación con puntos. La figura B.19 muestra el modelo final programado en WinBUGS.

Como observamos, para definir la verosimilitud utilizamos la función `for`. Cada uno de los datos, tanto de coste como de efectividad, se distribuyen según una

```

model{
  for(i in 1:n){
    #Verosimilitud
    ci~dnorm(mu.c,tau.c)
    ei~dnorm(mu.e,tau.e)
  }

  #Distribuciones a priori
  mu.c~dnorm(0,0.0091)
  tau.c~dgamma(0.001,0.001)
  mu.e~dnorm(0,0.001)
  tau.e~dgamma(0.001,0.001)

  #Metodos de calculo
  RCE~mu.c/mu.e
  var.c~1/tau.c
  var.e~1/tau.e
  des.c~sqrt(var.c)
  des.e~sqrt(var.e)
}

#Datos
list<-list(
  ci, ei
)

#Valores iniciales
ini(mu.c=0,tau.c=1,prec.e=1,prec.c=1)

```

Figura B.19: Programa WinBUGS para el análisis coste-efectividad con datos normales

normal: $e_i \sim \mathcal{N}(\mu_e, \tau_e)$ y $c_i \sim \mathcal{N}(\mu_c, \tau_c)$. Las distribuciones a priori tanto de las medias como de la precisión son consideradas no informativas, situando todo el peso del análisis en los datos.

Una vez escrito el modelo nos disponemos a compilarlo en WinBUGS. El primer paso será comprobar la correcta escritura. Desplegamos el menú `Specification Tool` (menú `Model`). Una vez situado el cursor entre las llaves `{ }` del modelo pulsamos la opción `check model`. A continuación cargaremos los datos. Los datos vienen distribuidos en una lista de datos y dos columnas. Comenzaremos cargando la lista de datos. Situamos el cursor sobre la palabra `list` y pulsamos `load data`. Para cargar los datos de la tabla situamos el cursor sobre el nombre de la primera columna (`c`) y pulsamos. Volvemos a la ventana `Specification Tool` y pulsamos `load data`. De esta forma cargaremos los datos de las dos columnas. Finalmente el

modelo se compila correctamente (ver el mensaje en la parte inferior de la ventana WinBUGS: model compiled).

Antes de comenzar las simulaciones MCMC debemos conocer los valores iniciales. En este ejemplo no podemos utilizar la opción `gen.inits`. Los valores generados por WinBUGS para el parámetro de forma de la precisión es demasiado pequeño (ver figura B.20). La alternativa será escribir nosotros los valores iniciales.




Figura B.20: Mensaje de error de WinBUGS al generar los valores iniciales del proceso

Ya podemos comenzar la simulación. Utilizamos una muestra *burn-in* de tamaño 10000. A continuación desplegamos el menú *Samples*, dentro de la opción *Inference*. En node escribimos el nombre de las variables desconocidas (*mu.e*, *mu.c*, *prec.e*, *prec.c*, *var.e*, *var.c*, *des.c*, *des.e*, *RCE*). Para guardar sus simulaciones pulsamos *Set* después de cada nodo. Simulamos 50000 valores para la estimación de la distribución a posteriori.

Dentro de la ventana *Sample Monitor Tool* escribimos asterisco (*) en el node para mostrar los resultados a posteriori de todos los nodos. En esta ventana hay varios botones que aún no han sido explicados. A continuación mostramos la utilidad de cada opción.

- **clear:** Elimina la variable señalada.
- **trace:** Gráfica de la variable para las últimas simulaciones (figura B.21).
- **history:** Gráfica de la variable para todas las simulaciones guardadas (figura B.22).




Figura B.21: Traza de los nodos del ejemplo coste-efectividad

- **density:** funciones de densidad estimadas para cada nodo (figura B.23).
- **stats:** Estadísticos de los nodos simulados (figura B.24).
- **coda:** muestra en un archivo distinto todas las simulaciones guardadas para nodo señalado en node (figura B.25).
- **quantiles:** Muestra la media y el intervalo de confianza al 95 % de las últimas simulaciones.




Figura B.22: Historia de los nodos del ejemplo coste-efectividad

- `bgr diag`: calcula el estadístico de convergencia Gelman-Rubin a partir de las simulaciones. Este estadístico es de mucha utilidad para analizar la convergencia.

- `auto cor`: muestra las funciones de autocorrelación de cada nodo. Es deseable que la autocorrelación de un nodo sea prácticamente nula a partir del orden 20 (figura B.26).

B.9. Datos normales y validez del modelo




Figura B.23: Funciones de densidad alisadas de cada nodo

node	mean	sd	MC error	2.5%	median	97.5%	start	sample
RCE	18.01	10.6	0.07054	-2.175	17.45	38.54	10001	50000
dsa.c	600.7	200.9	1.257	479.2	778.9	1263.0	10001	50000
dsa.e	1.743	0.3595	0.001791	1.209	1.694	2.61	10001	50000
mu.e	199.6	118.9	0.002295	10.17	11.38	434.1	10001	50000
dsa.s	11.68	0.4816	0.00775	-24.06	12.9	12.9	10001	50000
mu.s	1.372E-6	1.813E-6	7.569E-9	6.221E-7	1.637E-6	4.357E-6	10001	50000
dsa.v	0.268	0.1382	6.703E-4	0.1469	0.2164	0.8838	10001	50000
mu.v	681500.0	263200.0	2153.0	229600.0	683388.0	1.897E+6	10001	50000
var.e	3.168	1.419	0.007114	1.463	2.37	8.811	10001	50000

Figura B.24: Estadísticos de los nodos guardados, media, desviación típica, varianza, mediana y estimación por intervalo al 95 %




Figura B.25: Estadísticos de los nodos guardados, media, desviación típica, varianza, mediana y estimación del intervalo al 95 %

B.10. Programación en Doodle

WinBUGS ofrece una forma alternativa de programar los modelos, se trata de la programación a través de Doodle. Doodle es un método gráfico, intuitivo y que requiere un menor conocimiento de los comandos WinBUGS.

Como ejemplo de cómo utilizar la programación Doodle repetiremos el ejercicio de la sección anterior. El primer paso para programar en Doodle es abrir un nuevo Doodle. Para ello desplegamos el menú Doodle de la barra de herramientas WinBUGS y seleccionamos la opción New. Se abre una ventana donde podemos definir el tamaño del Doodle que queremos crear (figura B.27). La opción view width nos permite modificar el ancho de la ventana, la opción view height permite modificar el alto y la opción node width permite modificar el tamaño del doodle. Llamaremos doodle a los óvalos que crea WinBUGS y que se refieren a cada uno de los nodos del modelo. Dejamos las opciones por defecto y pulsamos ok.




Figura B.26: Funciones de autocorrelación de los nodos




Figura B.27: Al crear un nuevo doodle podremos definir el tamaño del mismo. En modelos complejos es conveniente aumentar el alto y el ancho de la ventana

Una vez creada la ventana doodle podemos comenzar a especificar el programa. Para cada uno de los nodos o parámetros del programa debemos crear un doodle. Un doodle se crea pulsando con el botón izquierdo del ratón sobre la

ventana. Inmediatamente se creará el óvalo correspondiente. Si cometemos algún error creando un doodle innecesario la forma de eliminarlo es pulsar sobre el doodle (quedará resaltado en gris) y pulsar simultáneamente CTRL + Supr.




Figura B.28: Cada nodo vendrá especificado por un óvalo o doodle

Además de los doodle, podemos crear plates. Un plate es utilizado para definir la función for. Para crear un plate pulsamos de forma simultánea la tecla CTRL y el botón izquierdo del ratón. Un plate quedará totalmente definido al indicar la letra usada como subíndice (index) y los extremos que puede tomar (from, up to).

Hay tres tipos de nodos distintos: estocásticos, lógicos y constantes. Un nodo será estocástico cuando se refiera a un parámetro o variable aleatoria. En un análisis bayesiano se consideran variables aleatorias los datos, definidos a través de su función de verosimilitud, y los parámetros desconocidos, a los que asignamos una distribución a priori. Continuando con el ejemplo de la sección anterior (análisis coste-efectividad) podemos crear el nodo correspondiente a la efectividad (e). Para ello creamos un doodle que llamaremos $e[i]$ (entre corchetes indicamos el subíndice). En type debemos marcar la opción stochastic ya que se trata de una variable aleatoria. En density indicamos qué distribución sigue ese nodo. En nuestro ejemplo la efectividad se distribuye según una normal. Para modificar la distribución pulsamos con el botón izquierdo del ratón sobre density, y sin dejar de pulsar marcamos la distribución. Obsérvese la gran variedad de distribuciones que tiene definido WinBUGS por defecto. Una vez seleccionamos la distribución, el siguiente paso será dar nombre a los parámetros de esa distribución. La distribución normal viene definida por la media (mean) y la precision (precision). Las

B.10. Programación en Doodle

opciones lower bound y upper bound permiten acotar la distribución entre dos valores. En nuestro ejemplo no es necesario definir cotas a la distribución.

La efectividad posee el subíndice i . Debemos utilizar la función for para asignar valores a este subíndice. Como comentamos anteriormente, la opción doodle utiliza el plate para definir subíndices. La figura B.29 muestra cómo queda definido el nodo de la efectividad.




Figura B.29: Especificación del nodo de la efectividad a través de un doodle estocástico

Los nodos lógicos los componen cantidades desconocidas obtenidas a partir de otras cantidades desconocidas básicas. La forma de definir un nodo lógico es crear el doodle, seleccionar en type, la opción logical y definir en value su expresión. Por ejemplo, el nodo lógico RCE , que es igual al cociente entre la media del coste y de la efectividad se define como se muestra en la figura B.30.

Los parámetros que definen la distribución a priori son constantes. Los doodles constantes tomarán forma rectangular.

Si creamos doodles para cada uno de los nodos del ejercicio coste-efectividad obtenemos la siguiente estructura doodle (figura B.31).

Una vez hayan sido creados y definidos todos los doodle debemos señalar a WinBUGS la relaciones entre ellos. Las relaciones entre nodos se representan por flechas, finas para dependencia estocástica, huecas para relaciones lógicas. Para crear una flecha hay que mantener iluminado el nodo "hijo" y pulsar CTRL + click sobre el nodo "padre". Por ejemplo, el nodo efectividad $e[i]$ viene definido a través de los nodos $mu.e$ y $prec.e$ (media y precisión de su distribución. Para señalar esta relación marcamos el nodo $e[i]$ (quedará resaltado en gris) y, una vez pulsado la tecla CTRL hacemos click con el botón izquierdo del ratón en los nodos $mu.e$ y $prec.e$. Se crearán dos flechas apuntando al nodo $e[i]$. Para borrar una




Figura B.30: Especificación del nodo *RCE* a través de un doodle lógico




Figura B.31: Programación en Doodle del análisis coste-efectividad con datos normales

flecha errónea simplemente volvemos a repetir el proceso. Hacemos lo mismo con todos los nodos relacionados. En los nodos lógicos, como por ejemplo *RCE*, las flechas generadas son huecas. La figura B.32 muestra cómo queda finalmente el modelo.

En la ventana doodle únicamente podemos definir el modelo pero no podemos ejecutarlo. Una vez creado el modelo debemos trasladarlo a una nueva ventana para ejecutarlo. Los pasos son los siguientes. En primer lugar seleccionamos el doodle a través del menú Edit/Select document. El doodle quedará bordeado




Figura B.32: Programación en Doodle del análisis coste-efectividad con datos normales (continuación)

por una línea azul. Una vez seleccionado lo copiamos Edit/Copy. Abrimos un nuevo documento File/New y pegamos el doodle Edit/Paste. En la parte inferior al doodle podremos incluir las listas o tablas de datos. Para ejecutar el modelo seguimos los mismos pasos que en las secciones anteriores. La única diferencia es que para validar el modelo a través de check model debemos marcar el doodle realizando un doble click sobre él. De esta forma el doodle quedará resaltado con un marco gris, como muestra la figura B.33.

B.11. Recursos adicionales

Los lectores interesados en un conocimiento más profundo de WinBUGS deben consultar el manual de usuario. Este manual está disponible en la opción Help del programa. Además se muestran dos listados de ejercicios resueltos. Una buena forma de aprender a usar WinBUGS con datos propios es imitar un ejemplo similar y a partir de ese modelo adecuarlo a nuestro análisis (figura B.34).




Figura B.33: Programación en Doodle del análisis coste-efectividad con datos normales (continuación)




Figura B.34: En la ayuda del WinBUGS podemos obtener el manual y dos volúmenes de ejercicios resueltos

Bibliografía

- [1] Arnold, B.C. (1983). *Pareto Distributions*. International Co-operative Publishing House, Fairland, MD.
- [2] Arnold, B.C., Castillo, E., and Sarabia, J.M. (1992). *Conditionally Specified Distributions*. Lecture Notes in Statistics, Vol. 73. Springer-Verlag, New York.
- [3] Arnold, B.C., Castillo, E., and Sarabia, J.M. (1999). *Conditional Specification of Statistical Models*. Springer-Verlag, New York.
- [4] Artís, M., Ayuso, M., and Guillén, M. (1999). Modelling different types of automobile insurance fraud behavior in the Spanish market. *Insurance: Mathematics and Economics*, 24, 67–81.
- [5] Artís, M.; Ayuso, M., and Guillen, M. (2002). Detection of automobile insurance fraud with discrete choice models and misclassified claims. *Journal of Risk and Insurance*, 69, 325–340.
- [6] Bailey, A. (1945). A generalized theory of credibility. *Proceedings of the Casualty Actuarial Society*, XXXII, 13, 13–20.
- [7] Baione, F., Levantesi, S., and Menzietri, M. (2002). The development of an optimal bonus-malus system in a competitive market. *Astin Bulletin*, 32, 1, 159–169.
- [8] Balakrishnan, N., and Nevzorov, V.B. (2003). *A Primer on Statistical Distributions*. John Wiley & Sons, New York.
- [9] Bayarri, M.J., and Berger, J.O. (2000). *P-values for composite null models (with discussion)*. *Journal of the American Statistical Association*, 95, 1127–1142.
- [10] Bayes, T. (1763). An essay towards solving a problem in the doctrine of chances. *Philos. Trans. Royal Soc. London*, V61.53, 370–418.

- [11] Benktander, G. (1970). Schadenverteilungen nach Grosse in der Nicht-Lebensversicherung. *Bulletin of the Swiss Association of Actuaries*, 263–283.
- [12] Benktander, G., and Segerdahl, C.O. (1960). On the analytical representation of claim distributions with special reference to excess of loss reinsurance. *Transactions of the 16th International Congress of Actuaries*, 1, 626–648.
- [13] Berger, J.O. (1984). The robust bayesian viewpoint (with discussion). In: *Robustness in Bayesian Statistics*, J. Kadane, Ed., 63–124, North-Holland, Holland.
- [14] Berger, J.O. (1985). *Statistical Decision Theory and Bayesian Analysis*, 2nd ed. Springer-Verlag, New York.
- [15] Berger, J.O. (1990). Robust bayesian analysis: sensitivity to the prior. *Journal of Statistical Planning and Inference*, 25, 303–328.
- [16] Berger, J.O. (1994). An overview of robust bayesian analysis. *TEST*, 3, 5–125.
- [17] Bernardo, J. M. (2003). Bayesian statistics. In: *Encyclopedia of Life Support Systems (EOLSS)*. Probability and Statistics, (R. Viertl, ed). Oxford, UK. Disponible en www.eolss.net
- [18] Berry, D.A. (1996). *Statistics, a Bayesian Perspective*. International Thomson Publishing Inc., London.
- [19] Betrò, B., and Guglielmi, A. (2000). Methods for global prior robustness under generalized moment conditions. In: *Robust Bayesian Analysis* (D. Rios, F. Ruggeri, editors). Springer-Verlag, New York, 273–293.
- [20] Betrò, B., Ruggeri, F., and Męczarski, M. (1994). Robust bayesian analysis under generalized moments conditions. *Journal of Statistical Planning and Inference*, 41, 257–266.
- [21] Bühlmann, H. (1967). Experience rating and credibility. *Astin Bulletin*, 4, 199–207.
- [22] Castillo, E., Hadi, A.S., Balakrishnan, N., and Sarabia, J.M. (2005). *Extreme Value and Related Models with Applications in Engineering and Science*. John Wiley & Sons, New York.
- [23] Chib, S., and Greenberg, E. (1995). Understanding the Metropolis-Hastings algorithms. *The American Statistician*, 49, 327–335.
- [24] Colquitt, L. (2003). An analysis of risk, insurance and actuarial research: Citations from 1996 to 2000. *Journal of Risk and Insurance*, 70, 315–338.

- [25] Congdon, P. (2001). *Bayesian Statistical Modelling*. John Wiley & Sons, New York.
- [26] Cowles, M.K., and Carlin, B.P. (1996). Markov chain monte carlo convergence diagnostics: a comparative review. *Journal of the American Statistical Association*, 91, 883–904.
- [27] Cramér, H. (1946). *Mathematical Methods of Statistics*, Princeton University Press, Princeton.
- [28] De Alba, E. (2002). Bayesian estimation of outstanding claim reserves. *North American Actuarial Journal*, 6, 1–20.
- [29] De Finetti, B. (1937). La prévision: ses lois logiques, ses sources subjectives. *Ann. Inst. H. Poincaré*, 7, 1–68.
- [30] De Finetti, B. (1974). *Theory of Probability* vol. 1. Wiley, Chichester.
- [31] De Finetti, B. (1975). *Theory of Probability* vol. 2. Wiley, Chichester.
- [32] DeGroot, M.H. (1970). *Optimal Statistical Decisions*. McGraw-Hill, New York.
- [33] Denuit, M. (1997). A new distribution of Poisson-type for the number of claims. *ASTIN Bulletin*, 27, 229–242.
- [34] De Pril, N. (1986). On the exact computation of the aggregate claims distribution in the individual life model. *Astin Bulletin*, 16, 109–112.
- [35] Dhaene, J., and Goovaerts, M.J. (1996). Dependency of risks and stop-loss order. *Astin Bulletin*, 26, 201–212.
- [36] Dhaene, J., and Goovaerts, M.J. (1996). On the dependency of risks in the individual life model. *Insurance: Mathematics and Economics*, 19, 243–253.
- [37] Dickson, D.C.M. (2005). *Insurance Risk and Ruin*. Cambridge University Press, Cambridge.
- [38] Dubey, S.D. (1965). Asymptotic properties of several estimators of Weibull parameters. *Technometrics*, 7, 423–434.
- [39] Duchateau, P., y Zachmann, D. (1986). *Ecuaciones Diferenciales Parciales*. McGrawHill, Madrid.
- [40] Dufresne, F., and Gerber, H. (1989). Three methods to calculate the probability of ruin. *Astin Bulletin*, 19, 71–90.
- [41] *Encyclopedia of Actuarial Science* (2004). John Wiley & Sons, New York.

- [42] Ericksen, L. (2002). Sum of powers from uniform distribution moments. *Journal of Statistical Planning and Inference*, 101, 57-79.
- [43] Ferreira, J. (1977). Identifying equitable insurance premiums for risk classes: an alternative to the classical approach. *Twenty-third International Meeting of the Institute of Management Sciences. Athens*.
- [44] Fisher, R.A., and Tippet, L.H.C. (1928). Limiting forms of the frequency distributions of the largest or smallest member of a sample. *Proceedings of the Cambridge Philosophical Society*, 24, 180-190.
- [45] Freifelder, F. (1974). Statistical decision theory and procedures. In Kahn, P.M. ed. *Credibility theory and applications*, pp. 71-88. Academic Press, New York.
- [46] Gamerman, D. (1997). *Markov Chain Monte Carlo*. Chapman and Hall, New York.
- [47] Gelfand, A.E., and Smith, A.F.M. (1990). Sampling-based approaches to calculating marginal densities. *Journal of the American Statistical Association*, 85, 398-409.
- [48] Gelman, A., Carlin, J.B., Hal, S.S., and Rubin, D.B. (2003). *Bayesian: Data Analysis* 2nd ed. Chapman and Hall, New York.
- [49] Genest, C., Marceau, E., and Mesfioui, M. (2003). Compound Poisson approximations for individual models with dependent risks *Insurance: Mathematics and Economics*, 32, 73-91.
- [50] Gerber, H.U. (1979). *An Introduction to Mathematical Risk Theory*. Huebner Foundation Monograph 8.
- [51] Gilks, W.R., Richardson, S., and Spiegelhalter, D.J. Ed. (1996). *Markov Chain Monte Carlo in Practice*. Chapman and Hall, Londres.
- [52] Gilks, W.R., and Wild, P. (1992). Adaptive rejection sampling for Gibbs sampling. *Applied Statistics*, 41, 337-348.
- [53] Glasser, G.J. (1962). Minimum variance unbiased estimators for Poisson probabilities. *Technometrics*, 4, 409-418.
- [54] Gómez-Déniz, E., Bermúdez, L., and Morillo, I. (2005). Computing bonus-malus premiums under partial prior information. *British Actuarial Journal*, 11, 361-374.
- [55] Gómez-Déniz, E., Calderín, E., and Cabrera, I. (2006). A simple method to study sensitivity of BMP's. *Communications in Statistics: Theory and Methods*, 35, 583-591.

- [56] Gómez-Déniz, E., Hernández, A., and Vázquez-Polo, F. (2000). Robust bayesian premium principles in actuarial science. *Journal of the Royal Statistical Society D*, 49, 241-252.
- [57] Gómez-Déniz, E., Hernández, A., and Vázquez-Polo, F. (2002a). Bounds for ratios of posterior expectations: applications in the collective risk model. *Scandinavian Actuarial Journal*, 1, 37-44.
- [58] Gómez-Déniz, E., y León, M. (2005). Un modelo de tarificación bonus-malus bajo el principio Esscher con tarifas más competitivas. *Estudios de Economía Aplicada*, 23, 79-91.
- [59] Gómez-Déniz, E., Pérez, J.M., Hernández, A., and Vázquez-Polo, F. (2002b). Measuring sensitivity in a bonus-malus system. *Insurance: Mathematics and Economics*, 31, 105-113.
- [60] Gómez-Déniz, E., and Vázquez-Polo, F. (2005). Modelling uncertainty in insurance bonus-malus premium principles by using a Bayesian robustness approach. *Journal of Applied Statistics*, 32, 771-784.
- [61] Goovaerts, M.J., and De Vylder, F. (1984). A stable algorithm for evaluation of ultimate ruin probabilities. *Astin Bulletin*, 14, 53-59.
- [62] Goovaerts, M.J., Kaas, R., Van Heerwaarden, A.E., and Bauwelincx, T. (1990). *Effective Actuarial Methods*. North-Holland, Amsterdam.
- [63] Goutis, C. (1994). Ranges of posterior measures for some classes of priors with specified moments. *International Statistical Review*, 62, 245-256.
- [64] Grandell, J. (1991). *Aspects of Risk Theory*. Springer-Verlag, New York.
- [65] Greenwich, M. (1992). A unimodal hazard rate function and its failure distribution. *Statistische Hefte*, 33, 187-202.
- [66] Haberman, S. (1996). Landmarks in the history of actuarial science (up to 1919). *Actuarial Research Paper*, 84. University of London.
- [67] Haldane, J.B.S. (1948). The precision of observed values of small frequencies. *Biometrika*, 35, 297-303.
- [68] Heilmann, W. (1989). Decision theoretic foundations of credibility theory. *Insurance: Mathematics and Economics*, 8, 77-95.
- [69] Herzog, T.N. (1996). *Introduction to Credibility Theory*. ACTEX, New York.
- [70] Heywood, G. (1985). Edmond Halley: astronomer and actuary. *JIA*, 112, 279-301.

- [71] Hickmann, J. (1975). Introduction and historical overview of credibility. In: *Credibility. Theory and Applications*. P.M. Kahn Ed.. Academic Press, New York.
- [72] Hirsch, M., and Smale, S. (1974). *Differential Equations, Dynamical Systems and Linear Algebra*. Academic Press, San Diego.
- [73] Hürlimann, W. (1994). A note on experience rating, reinsurance and premium principles. *Insurance: Mathematics and Economics*, 14, 197–204.
- [74] Jeffreys, H. (1961). *Theory of Probability*. Oxford University Press and Clarendon Press, Oxford.
- [75] Jewell, W.S. (1974). Credible means are exact Bayesian for exponential family, *Astin Bulletin*, 8, 79–90.
- [76] Johnson, N.L., Kemp, A.W., and Kotz, S. (2005). *Univariate Discrete Distributions*. 3rd ed. John Wiley & Sons, New York.
- [77] Johnson, N.L., Kotz, S., and Balakrishnan, N. (1994). *Continuous Univariate Distributions*. Vol. 1, 2nd ed. John Wiley & Sons, New York.
- [78] Johnson, N.L., Kotz, S., and Balakrishnan, N. (1995). *Continuous Univariate Distributions*. Vol. 2, 2nd ed. John Wiley & Sons, New York.
- [79] Kleiber, C., and Kotz, S. (2003). *Statistical Size Distributions in Economics and Actuarial Science*. John Wiley & Sons, New York.
- [80] Klugman, S.A. (1991). *Bayesian Statistics in Actuarial Science: with emphasis on credibility*. Kluwer Academic Publishers, Massachusetts.
- [81] Klugman, S.A., Panjer, H.H., and Willmot, G.E. (1998). *Loss Models: from Data to Decisions*. John Wiley & Sons, New York.
- [82] Koop, G. (2003). *Bayesian Econometrics*. John Wiley & Sons, West Sussex, England.
- [83] Kornya, P.S. (1983). Distribution of aggregate claims in the individual risk theory model (with discussion). *Transactions of the Society of Actuaries*, 35, 823–858.
- [84] Krasnov, M., Kisiliov, A., y Makarenko, G. (1982). *Ecuaciones Integrales*. Mir, Moscú.
- [85] Landsman Z., and Makov U.E. (1999). Credibility evaluation for the exponential dispersion family. *Insurance: Mathematics and Economics*, 24, 23–29.

- [86] Laplace, P.S. (1774, 1814). *Essai Philosophique sur les Probabilités*. Dover Publications, New York.
- [87] Lee, P. M. (1997). *Bayesian Statistics. An Introduction*. Arnold Publishers, London.
- [88] Lee, P. M. (2003). *Bayesian Statistics. An Introduction*. 2nd. ed. Arnold Publishers, London.
- [89] Lehmann, E. (1986). *Testing Statistical Hypotheses*. John Wiley & Sons, New York.
- [90] Lemaire, J. (1979). How to define a bonus-malus system with an exponential utility function. *Astin Bulletin*, 10, 274–282.
- [91] Lemaire, J. (1985). *Automobile Insurance. Actuarial Models*. Kluwer-Nijhoff Publishing, Dordrecht.
- [92] Lemaire, J. (1995). *Bonus-Malus Systems in Automobile Insurance*. Kluwer Academic Publishers, London.
- [93] Malik, H.J. (1970). Estimation of the parameters of the Pareto distribution. *Metrika*, 15, 126–132.
- [94] Mayerson, A.L. (1964). A Bayesian view of credibility. *Proceedings of the Casualty Actuarial Society*, 51, 85–104.
- [95] Metropolis, N. Rosenbluth, A.W., Rosenbluth, N.N., Teller, A.H., and Teller, E. (1953). Equation of state calculations by fast computing machine. *Journal of Chemical Physics*, 21, 1087–1091.
- [96] Mowbray, A. (1914). How extensive a payroll is necessary to give dependable pure premium? *Proceedings of the Casualty Actuarial Society*, 1, 24–30.
- [97] Neyman, J., and Pearson, E.S. (1933). On the problem of the most efficient tests of statistical hypotheses. *Phil. Trans. Roy. Soc.*, A231, 289–337.
- [98] Ntzoufras, I., and Dellaportas, P. (2002). Bayesian modelling of outstanding liabilities incorporating claim count uncertainty (with discussion). *North American Actuarial Journal*, 6, 113–128.
- [99] O'Hagan, A. (2005). FirstBayes version 1.3. Disponible en www.firstbayes.co.uk
- [100] O'Hagan, A., and Forster, J. (2004). *Bayesian Inference*. 2nd. ed. Kendall's Advanced Theory of Statistics, Vol. 2B. Arnold Publishers, London.

- [101] Panjer, H.J. (1981). Recursive evaluation of a family of compound distributions. *Astin Bulletin*, 12, 22-26.
- [102] Press, S.J. (2003). *Subjective and Objective Bayesian Statistics: Principles, Models and Applications*. John Wiley & Sons, New York.
- [103] Ríos-Insúa, D., and Ruggeri, F. (2000). *Robust Bayesian Statistics*. Springer-Verlag, New York.
- [104] Robert, C.P., and Casella, G. (1999). *Monte Carlo Statistical Methods*. Springer-Verlag, New York.
- [105] Roberts, G. O. (1996). Markov chain concepts related to sampling algorithms. In: *Markov Chain Monte Carlo in Practice* (Gilks, W.R., Richardson, S. and Spiegelhalter, D.J., editors). Chapman and Hall, London, 45-57.
- [106] Rohatgi, V.K. (1976). *An Introduction to Probability Theory and Mathematical Statistics*. John Wiley & Sons, New York.
- [107] Rolski, T., Schmidli, H. Schmidt, V., and Teugel, J. (1999). *Stochastic Processes for Insurance and Finance*. John Wiley & Sons, New York.
- [108] Rytgaard, M. (1990). Estimation in the Pareto distribution. *ASTIN Bulletin*, 20, 201-216.
- [109] Sarabia, J.M., Castillo, E., Gómez-Déniz, E., and Vázquez-Polo, F. (2005). A class of conjugate priors for log-normal claims based on conditional specification. *Journal of Risk and Insurance*, 72, 479-495.
- [110] Sarabia, J.M., Gómez-Déniz, E., and Vázquez-Polo, F. (2004). On the use of conditional specification models in claim count distributions: an application to bonus-malus systems. *Astin Bulletin*, 34, 85-98.
- [111] Schröter, K.J. (1990). On a family of counting distributions and recursions for related compound distributions. *Scandinavian Actuarial Journal*, 161-175.
- [112] Scollnik, D.P.M. (1996). An introduction to Markov chain monte carlo methods and their actuarial applications. *Proceeding of the Casualty Actuarial Society*, LXXXIII, 114-165.
- [113] Scollnik, D.P.M. (2000). Actuarial modeling with MCMC and BUGS: additional worked examples. Working paper (www.math.ualgary.ca/~scollnik/abcd/).
- [114] Scollnik, D.P.M. (2001). Actuarial modeling with MCMC and BUGS. *North American Actuarial Journal*, 5, 96-125.

- [115] Scollnik, D.P.M. (2002). Implementation of four models for outstanding liabilities in WinBUGS: A discussion of a paper by Ntzoufras and Dellaportas (2002). *North American Actuarial Journal*, 6, 128-136.
- [116] Seal, H.L. (1979). *Stochastic Theory of a Risk Business*. John Wiley and Sons, New York.
- [117] Shpilberg, D.C. (1977). The probability distribution of fire loss amount. *Journal of Risk and Insurance*, 44, 103-115.
- [118] Sivaganesan, S. (1991). Sensitivity of some posterior summaries when the prior is unimodal with specified quantiles. *The Canadian Journal of Statistics*, 19, 57-65.
- [119] Sivaganesan, S., and Berger, J.O. (1989). Ranges of posterior measures for priors with unimodal contaminations. *Annals of Statistics*, 17, 868-889.
- [120] Spiegelhalter, D., and the BUGS project (2005). WinBUGS version 1.4.1. (<http://www.mrc-bsu.cam.ac.uk/bugs/winbugs/contents.shtml>)
- [121] Spiegelhalter, D., Abrams, K., and Myles, J. (2004) *Bayesian Approaches to Clinical Trials and Health-Care Evaluation*. John Wiley & Sons, New York.
- [122] Sundt, B., and Jewell, W. (1981). Further results on recursive evaluation of compound distributions. *Astin Bulletin*, 12, 27-39.
- [123] Tanner, M.A. (1993). *Tools for Statistical Inference*. 2nd. ed. Springer-Verlag, New York.
- [124] Tanner, M.A., and Wong, W.H. (1987). The calculation of posterior distributions by data augmentation. *Journal of the American Statistical Association*, 82, 528-540.
- [125] Taylor, G.C. (2000). *Claim Reserving. An Actuarial Perspective*. Elsevier Science Publishers, New York.
- [126] Tiago de Oliveira, J. (1963). Decision results for the parameters of the extreme value (Gumbel) distribution based on the mean and the standard deviation. *Trabajos de Estadística*, 14, 61-81.
- [127] Varian, H.R. (1975). A Bayesian approach to real estate assessment. In: *Studies in Bayesian Econometrics and Statistics in Honor of Leonard J. Savage*, S. Fienberg and A. Zellner, Ed. North Holland, Amsterdam, 195-208.
- [128] Verrall, R. (1990). Bayes and empirical Bayes estimation for the chain ladder model. *ASTIN Bulletin*, 20, 2, 217-243.

- [129] Verrall, R. (1996). Claims reserving and generalised additive models. *Insurance: Mathematics and Economics*, 19, 31–43.
- [130] Whitney, A. (1918). The theory of experience rating. *Proceedings of the Casualty Actuarial Society*, 4, 274–292.
- [131] Winkler, R.L. (1967). The assessment of prior distributions in Bayesian analysis. *Journal of the American Statistical Association*, 776–800.
- [132] Young V. (2004). Premium principles. *Encyclopedia of Actuarial Science*, 3, 1322–1331.
- [133] Zellner, A. (1986). On assessing prior distributions and Bayesian regression analysis with g-prior distributions. In: *Bayesian Inference and Decision Techniques: Essays in Honor of Bruno de Finetti*. P. Goel and A. Zellner, ed. North Holland, New York, 233–243.

Índice alfabético

- APL data entry, 321
 Analyses, 321
 Binomial sample, 321
 CTRL, 540
 Data, 322
 Distributions, 334
 Doodle, 339, 347, 353, 556
 END, 548
 Excel, 548
 File, 535
 FirstBayes, 286, 293, 296–299, 318,
 321, 323, 327, 330, 333, 334,
 361
 HDI, 296, 323
 Inference, 538
 Model, 534, 538
 New, 322, 556
 Next, 321
 Nul, 322
 Options, 321
 Paste Special, 548
 Plain Text, 548
 Prob., 323
 Quit, 322
 Sample Monitor Tool, 538–540, 544
 Samples, 538
 Sample, 538
 Save as, 535
 Save, 322
 Set, 538
 Show predictive, 330
 Specification Tool, 548
 Specification tool, 536, 537
 Specification, 535
 Thick Caret, 535
 Time parameter, 293
 Trap, 538
 Updates, 538
 Update, 537, 538
 WinBUGS, 338, 352, 531–534, 536, 537,
 542, 543, 556
 burn in, 537
 check model, 535
 compile, 536
 dbern, 533
 dbeta, 533
 dbin, 533
 density, 558
 dgamma, 533
 dnorm, 532
 dpois, 533
 for, 546
 from, 558
 gen inits, 537
 initial values generated, 537
 kernel density, 540
 list, 534, 536, 537
 load data, 536, 548
 logical, 559
 lower bound, 559
 mean, 558
 model initialized, 537
 node statistics, 540
 node width, 556
 node, 536, 539, 544
 parameter p, 321

parameter q , 321
 percentiles, 540
 plate, 558
 precision, 558
 refresh, 538
 scale, 293
 set, 538
 shape parameter, 298
 shape, 293
 specification tool, 535
 stats, 539
 step, 543
 stochastic, 558
 triplot, 293
 type, 558
 up to, 558
 upper bound, 559
 value, 559
 view height, 556
 view width, 556

 actuario, 1
 aditividad, 365
 AIC, Akaike's Information Criterion, 248
 algoritmo
 de aumento de datos, 344
 de Metropolis-Hastings, 343
 análisis de sensibilidad, 283
 anualidad, 5
 aperiodicidad, 343
 aproximación
 de la cantidad total reclamada, 438
 Edgeworth, 443, 448
 Esscher, 445
 gamma trasladada, 440
 normal, 439
 de la verosimilitud relativa, 284
 del histograma, 284
 asegurado, 1, 399, 400, 469
 aseguradora, 1, 369, 379, 401, 489, 491

aversión, 369, 398, 411, 505
 Bayes, 3, 363, 374, 381, 383, 391, 412
 BIC, Bayesian Information Criterion, 248
 bondad de ajuste, 240
 bonus-malus, 7, 363, 382, 391-394, 397, 398, 400, 450
 burn-in, 339, 344, 353

 cantidad de información
 esperada o de Fisher, 183
 observada, 183
 cartera, 454
 de seguros, 363, 373, 376, 379, 381, 384, 393, 397, 457
 cesión, 401, 403
 clase
 $(a, b, 0)$, 114, 437, 439
 $(a, b, 1)$, 115, 436, 439
 $R2(a, b, c)$, 437-439
 cobertura, 2
 cociente de verosimilitudes, 208
 coeficiente
 de ajuste, 496, 505
 de asimetría, 417, 440, 441
 de una variable aleatoria, 40
 de curtosis
 de una variable aleatoria, 40
 de variación, 379
 de correlación lineal, 54
 compañía de seguros, 1, 388, 469
 conjunto de credibilidad de alta densidad, 267
 consistencia, 365
 constante de Euler, 155, 236
 contraste
 bilateral, 203
 de hipótesis, 197
 unilateral, 203
 contrato de seguro, 2
 convergencia
 en distribución, 132

en probabilidad, 176
 convolución, 419, 493
 corrección por continuidad, 132
 cota
 de Cramér-Rao, 185, 191
 cotas de la probabilidad de ruina, 495, 496, 500, 503-505
 covarianza, 54
 credibilidad, 363, 377, 380-383, 388, 389, 391, 411, 470
 parcial, 380
 total, 378-380
 criterio
 bayesiano
 de información, 248
 de Schwartz, 247
 de factorización de Fisher, 179
 de información de Akaike, 248
 de parsimonia, 246
 general de información, 248
 cuantil, 278
 de una variable aleatoria, 41
 cumulantes, 82

 decisiones
 no comparables, 276
 preferibles, 276
 deducible, 403
 delta método, 190
 densidad
 a priori, 261, 285, 477
 de Jeffreys, 301
 escéptica, 284
 estructural, 284
 informativa, 283
 no informativa, 284, 300
 impropia, 300
 desigualdad
 de Bonferroni, 15
 de Lundberg, 424, 487, 495
 de Chebyshev, 39
 desviación típica
 de un estimador, 172

de una variable aleatoria, 36
 diferencia
 de sucesos, 12
 simétrica de sucesos, 12
 distribución
 a posteriori, 263, 265, 266, 278, 282, 321, 336, 344, 374, 376
 a priori, 373, 384
 beta, 332, 391
 beta con cuatro parámetros, 125
 beta de primera especie, 123
 beta de segunda especie, 376
 binomial, 96, 288, 316, 391, 425, 429, 433
 binomial negativa, 109, 220, 289, 298, 376, 423, 425, 426, 429, 433
 chi-cuadrado de Pearson, 163
 conjugada, 450
 de Benktander I, 160
 de Benktander II, 160
 de Bernoulli, 95
 de Burr tipo XII, 167
 de Erlang, 151
 de estado estacionario, 401
 de Fréchet, 158
 de Gompertz, 162
 de Gumbel, 154, 236
 de Makeham, 162
 de Neyman tipo A, 118
 de Pareto, 138
 de Pareto generalizada, 142
 de Pareto tipo I, 138, 227
 de Pareto tipo II, 138, 232
 de Poisson, 99, 219, 289, 361, 391, 411, 416, 417, 420, 425, 426, 429, 433, 449, 450, 453, 466
 de un estadístico de orden, 89
 de Weibull, 157, 235
 del máximo, 88
 del mínimo, 88
 estacionaria, 343

- estacionaria de renovación, 72
- exponencial, 148, 391, 412, 417, 419, 420, 422-424, 449, 452, 489, 494, 495, 500, 505
- F de Snedecor, 165
- gamma, 151, 225, 391, 393, 397, 403, 408, 450, 498
- gamma generalizada, 153
- generalizada inversa Gaussiana, 146
- geométrica, 106, 422, 425, 429, 433, 466, 501
- geométrica compuesta, 502
- hipergeométrica, 105
- inversa Gaussiana o de Wald, 145, 233, 416
- log-normal, 134, 223, 412, 417, 470, 477, 484
 - con tres parámetros, 137
- logarítmica, 113, 222, 424, 436
- multinomial, 114
- normal, 126, 346, 379, 391, 412
 - multivariante, 342
 - tipificada, 127, 379, 444
- predictiva, 256, 261, 264, 273, 296, 298, 329, 330, 344, 351, 374, 377, 411
- primaria, 416, 417, 419, 449
- secundaria, 416, 417, 419, 449
- t de Student, 164
- uniforme, 120, 290, 337
 - discreta, 93
 - condicionada, 52
- distribución beta-binomial, 320
- distribuciones
 - compuestas, 116
 - conjugadas, 288
 - de extremos, 88
- ecuación
 - diferencial, 494, 497
 - integral, 466
 - integral de Volterra, 434
- íntegro diferencial, 491
- ecuaciones de verosimilitud, 183
- eficiencia relativa de un estimador, 172
- elicitación, 284
- entropía, 247
- error
 - tipo I, 197
 - tipo II, 197
 - estándar de un estimador, 172
- espacio
 - muestral, 11
 - probabilístico, 14
- esperanza
 - matemática, 33
 - condicionada, 57
- estadísticos
 - de orden, 88
- estimación
 - por intervalos de confianza, 194
 - puntual, 169
- estimador
 - bayesiano, 275
 - de máxima verosimilitud, 221, 224, 226, 229, 233, 234
 - de mínimos cuadrados, 228
 - de momentos, 220, 223, 225, 228, 232, 234
 - puntual bayesiano, 277
 - bayesiano, 265
 - consistente, 176
 - de máxima verosimilitud, 265
 - insesgado, 171
 - uniforme de varianza mínima, 191
 - suficiente, 179
- estimadores de Bühlmann-Straub, 353
- experimentos, 11
- fórmula
 - de De Pril, 456, 460, 461, 463
 - de Panjer, 424, 426, 428-432, 504
 - de Laplace, 16

- factor
 - Bayes, 268, 270, 299, 300, 325
 - de credibilidad, 389
- familia
 - cerrada bajo muestreo, 288
 - exponencial, 292, 389
 - uniparamétrica, 204
- franquicia, 410
- función
 - beta incompleta, 89
 - característica, 73
 - confluente hipergeométrica, 423
 - de cuantía, 29
 - de decisión no aleatorizada, 276
 - de densidad, 30
 - de distribución, 26
 - bidimensional, 47
 - marginal, 48
 - de importancia, 338
 - de pérdida, 275, 367-369, 372, 373, 375
 - de utilidad, 275
 - digamma, 221, 226
 - envolvente, 338
 - estructura, 373
 - generatriz, 73
 - de cumulantes, 82
 - de momentos, 73, 79, 80, 369, 415, 418, 443-447
 - de probabilidad, 415, 437, 453, 458, 465
 - lagrangiana, 397
 - modificada de Bessel, 146, 421
 - potencia de un test de hipótesis, 198
 - de azar, 67
 - de supervivencia, 67
- GIC, 248
- gráfico
 - P - P, 238
 - Q - Q, 237
- HDI, 266
- hipótesis
 - alternativa, 197, 268
 - alternativa simple, 197
 - bilaterales, 205
 - compuestas, 197
 - nula, 197, 268
 - compuesta frente alternativa compuesta, 271
 - simple, 197
 - simple frente alternativa compuesta, 273
 - simple frente alternativa simple, 269
 - paramétrica, 197
- homogeneidad positiva, 365
- horizonte
 - finito, 491
 - infinito, 491
- HPD, 267
- IBNR, 469
- igualdad de sucesos, 12
- inclusión de sucesos, 12
- indemnización, 2
- independencia
 - de sucesos, 17
- inflación, 365, 471, 472
- información, 183
- insolvencia, 3
- intersección de sucesos, 12
- intervalo
 - bayesiano de credibilidad, 266
 - de dos colas con igual área, 266
 - de una cola, 266
- irreducibilidad, 343
- iteratividad, 365
- leyes
 - asociativas, 12
 - conmutativas, 12
 - de De Morgan, 12
 - distributivas, 12

- método
 - de De Vylder, 499
 - de estimación
 - basados en los percentiles, 230
 - de máxima verosimilitud, 132
 - de momentos, 181
 - de Monte Carlo, 337
 - de Newton-Raphson, 189
 - de rechazo, 338
- Markov, 400
- matriz de transición, 400, 401
- MCMC, 4, 341, 345
- media a posteriori, 278
- mediana a posteriori, 278
- medida de Arrow-Pratt, 369
- Metropolis-Hasting, 4, 478
- mezclas
 - de distribuciones, 87
- mixturas
 - de densidades, 292
 - de distribuciones, 87
- moda
 - a posteriori, 279
 - de una variable aleatoria, 41
- modelo
 - binomial negativa compuesto, 423, 440
 - colectivo, 413, 453, 456
 - colectivo compuesto, 449, 452
 - compuesto, 3
 - de Bühlmann, 383, 388, 389, 391, 411, 412, 424
 - de Poisson compuesto, 6, 416-418, 441, 452, 487
 - de riesgo individual, 2
 - general exponencial, 419
 - geométrica compuesto, 422, 450, 466, 501
 - individual, 413, 453, 457
 - logarítmico compuesto, 424
- momento
 - centrado
 - de una variable aleatoria, 36
 - no centrado
 - de una variable aleatoria, 36
 - mortalidad, 457
 - muestreo
 - de Gibbs, 344, 345
 - de importancia, 337
 - nivel de significación, 198
 - NLL, 246
 - no informativa, 265
 - odds
 - a posteriori, 268, 298, 325
 - a priori, 268
 - p-valor, 202, 268
 - pérdida, 1
 - pérdidas
 - 0 - 1, 278
 - absolutas, 278
 - bilineales, 277, 278
 - cuadráticas ponderadas, 277
 - exponenciales, 277
 - linex, 277
 - póliza, 5, 363, 381, 382, 388, 453, 454, 457, 463, 469
 - parámetro estructural, 387
 - paradigma bayesiano, 261
 - paradoja de Lindley, 273
 - pensión, 5
 - percentil, 379
 - perspectiva
 - bayesiana, 253
 - frecuentista, 253
 - polinomio de Laguerre, 423, 424
 - prima, 1, 2, 5, 7, 363, 364, 366, 380, 391, 394, 487, 500
 - Bayes, 366, 375-377, 382, 389, 392, 411, 449, 450
 - bonus-malus, 382, 391-393, 450
 - colectiva, 366, 373, 376, 388, 411, 449, 450

- de desviación típica, 371
- de libro, 377
- de Orlicz, 371
- de riesgo, 366, 367, 373, 376, 384, 411, 449
- de riesgo ajustado, 412
- de varianza, 369, 371, 373-375, 392, 449
- de Wang, 372
- del valor esperado, 371
- del valor medio, 411
- Esscher, 369-371, 373-375, 392, 411, 449
- exponencial, 368, 371, 373, 375, 392, 398, 406, 411, 449, 450, 505
- holandesa, 372
- manual, 377, 380
- neta, 371, 373, 375, 376, 383, 389, 392, 393, 406, 411
- suiza, 371, 411
- principio
 - de cálculo de prima, 363, 364, 366, 371, 373, 399, 412
 - de inclusión exclusión, 14
- probabilidad
 - a posteriori, 255
 - a priori, 255
 - de transición, 400
 - axiomas, 14
 - condicionada, 16
- problema de decisión bayesiano, 275
- proceso
 - de Poisson, 489
 - estocástico, 488
- propiedad
 - de invarianza del EMV, 186
 - de pérdida de memoria, 148
- rating, 364
- razón
 - de verosimilitud, 204
 - monótona, 204
- de verosimilitudes, 207
- reasegurador, 403
- reaseguradora, 401
- reaseguro, 3, 5, 355, 363, 401, 452, 463
- colectivo, 410
- ECOMOR, 410
- excess loss, 402, 403, 408
- Pool, 410
- proporcional, 402, 452
- semicolectivo, 403
- stop-loss, 402, 409, 452
- recursión, 424, 428, 430, 436, 437, 458, 463, 466
- región crítica, 197
- regla
 - Bayes, 276
 - de la esperanza iterada, 57
 - del producto, 17
- reserva, 2, 469, 487, 489, 491, 495, 501
- retención, 452
- riesgo, 1, 5, 363, 388
- robustez, 304
- ruina, 3, 364, 416, 487-489, 491, 493-500, 505
- SBC, Schwartz Bayesian Criterion, 247
- seguros, 363
 - no vida, 1, 6, 403
 - vida, 2-4, 6, 403, 455, 457, 461, 463
- selección de modelos, 237
- sobrecarga, 394
- sobredispersión, 242
- sobreprima, 364, 369, 489, 505
- soivencia, 487
- suceso, 11
 - complementario, 12
 - elemental, 11
 - imposible, 11
 - seguro, 11
- sucesos

- disjuntos, incompatibles o mutuamente excluyentes, 12
- equiprobables, 16
- supervivencia, 457, 491
- tamaño de un test de hipótesis, 198
- tarificación, 363, 379, 392, 449
- teoría de la decisión, 275
- teorema
 - central del límite, 132, 379, 439
 - de Bayes, 20, 261
 - de las probabilidades totales, 20
 - de Markov, 39
 - de Moivre-Laplace, 132
- test
 - de Barlett, 214
 - de hipótesis, 279
 - de hipótesis insesgado, 203, 205
 - de razón de verosimilitudes, 207
 - no aleatorizado, 199
 - unilaterales, 271
- transformación
 - de variables aleatorias, 42
 - bidimensional continua, 60
 - bidimensional discreta, 60
 - de escala, 86
 - integral, 121
 - inversa, 86
 - potencial, 86
 - stop-loss, 83
- transformada
 - de Esscher, 445
 - de Laplace, 434, 497, 498, 502
- unión de sucesos, 12
- unimodal, 268
- validación de modelos, 237
- variable
 - aleatoria, 25
 - bidimensional, 47
 - bidimensional continua, 50
 - bidimensional discreta, 49
 - continua, 30
 - discreta, 29
 - mixta, 32, 420, 423, 502
 - límite de pérdida, 85
- varianza
 - condicionada, 59
 - de una variable aleatoria, 36
 - vida residual media, 71